



WBA0870_v1.0

Análise e Modelagem Preditiva



Otimização de Modelos

Introdução à otimização de modelos

Bloco 1

Orlando da Silva Junior



➤ Otimização de modelos preditivos

- Não basta construir um modelo, também é necessário avaliar e otimizar.
- **Otimizar um modelo** significa que buscar melhorar o desempenho preditivo desse modelo antes de entregá-lo em produção.
 - Comparação com *baseline*.




➤ Importância dos atributos

- Provost e Fawcett (2016) sugerem que pensemos o processo da modelagem preditiva como uma segmentação supervisionada.
 - **Objetivo:** criar grupos a partir de um critério que gostaríamos de predizer.
 - **Atributo-alvo:** pode ser trabalhado de maneira positiva ou negativa.



➤ Elementos-chave da otimização

Figura 1 – Esquema-resumo sobre a otimização de modelos preditivos



Fonte: elaborada pelo autor.

➤ Atributos

- Devem ser importantes para o problema e também informativos a respeito das entidades que serão representadas.
- Os atributos escolhidos para a modelagem devem reduzir a incerteza a respeito do que queremos descobrir.
- Quando temos um atributo-alvo, a busca pelos atributos informativos se torna mais fácil.
- Nossa busca tem como meta aqueles atributos que apresentam maior correlação com o atributo-alvo.



➤ Modelo

- Quando um novo modelo preditivo é gerado, é criado a partir de um processo de **indução**.
- Será a regra geral construída a partir dos casos únicos e individuais de um conjunto de dados, por meio de um **algoritmo de indução**.

O algoritmo construído a partir desse processo será o **preditor**.



➤ Modelagem

- Na modelagem preditiva, usamos os atributos de entrada para descrever um modelo, observando o atributo-alvo.
- Utilizando dados, produzimos a estrutura de um modelo e os parâmetros numéricos desse modelo.
- **Como aprender um modelo?**
 - Partir da especificação da estrutura do modelo, deixando alguns parâmetros numéricos sem especificação.
 - Ao longo da aprendizagem, o processo calculará os melhores valores dos parâmetros a partir do conjunto de dados para construir o modelo.



➤ Modelagem

- O objetivo da **mineração de dados** é o ajuste dos parâmetros, de modo que o modelo se ajuste aos dados da melhor forma possível:
- **Modelagem paramétrica:** assume que o conjunto de dados é proveniente de um tipo de distribuição de probabilidade e faz inferências sobre os parâmetros da distribuição.
- **Modelagem não paramétrica:** compreende técnicas que não dependem de nenhuma distribuição de dados particular.



► Problemas

- *Overfitting.*
- *Underfitting.*
- Regularização.



➤ Estratégias

- Busca em grade.
- Busca aleatória.



Otimização de Modelos

Overfitting e underfitting

Bloco 2

Orlando da Silva Junior



➤ Modelos

- Você já sabe que é importante ter um modelo que represente bem os dados.
- No treinamento, o modelo observará os dados do treinamento (entrada).
- No futuro, o modelo observará novos dados nunca antes vistos pelo treinamento.



➤ Generalização

- A flexibilidade é importante para a busca de padrões, mas pode reconhecer como padrões o que são ocorrências ao acaso.
- Nossos modelos devem priorizar a **generalização**, ou seja, a predição de novos casos que ainda não foram observados.
 - Memorização **modelo de tabela**.
 - Inteligência?




➤ *Overfitting*

- *Overfitting* é um fenômeno nos dados.
- O modelo que não é capaz de extrapolar além do que já foi observado, ajusta-se perfeitamente aos dados de treinamento, que são os dados de entrada.
 - Modelos preditivos com tendência em se adaptar aos dados de treinamento.
 - Prejudicam a generalização em pontos de dados não observados.



➤ Overfitting

Figura 2 - Comparação entre o modelo ideal (vermelho) e o modelo sobreajustado (azul)



Fonte: elaborada pelo autor.

➤ *Overfitting*

- **Causas:**
 - Poucos dados para treinamento do modelo.
 - Aplicação de algoritmos mais complexos que o necessário para resolver o problema.
 - Ruído nos dados, como valores extremos, incorretos, ausentes etc.
- **Prevenção:**
 - Técnicas de regularização.



➤ *Underfitting*

- No *underfitting*, o modelo construído faz pouco esforço para se ajustar aos dados.
 - Modelos com alto viés e baixa variância.
- **Soluções:**
 - Utilizar mais atributos (novos e significativos).
 - Modelos mais complexos.



Otimização de Modelos

Estratégias de otimização


Bloco 3

Orlando da Silva Junior



➤ Estratégias de otimização

Figura 3 – Esquema-resumo das estratégias de otimização



Demonstração prática

1. Busca em grade.
2. Busca aleatória.



Teoria em Prática

Bloco 4

Orlando da Silva Junior



➤ Reflita sobre a seguinte situação

- O hospital ABC, localizado na cidade Praia Grande, no estado de São Paulo, possui uma equipe de análise de dados capaz de construir modelos preditivos a partir dos dados dos pacientes internados naquela unidade hospitalar. Anualmente, o hospital atende cerca de cem mil pessoas, sendo fevereiro o mês com maior quantidade de atendimentos. Segundo o diretor do hospital, 55% dos atendimentos são destinados a consultas de pronto atendimento, e 0,25% para tratamento de câncer.
- Um **modelo de diagnóstico de câncer de mama** foi avaliado pela equipe com 63% de acurácia, 52% de precisão e 78% de sensibilidade.
 1. O que você acha do desempenho desse modelo?
 2. É possível melhorar? Em caso positivo, como?



► Norte para a resolução...

- Começaremos analisando o problema:
 - **População:** 100 mil pessoas.
 - **Quem pode realizar o exame para diagnóstico?** - 100 mil.
- 1. É difícil dizer se o desempenho desse modelo é bom ou ruim, pois não temos uma base de comparação. Isso significa que não definimos, inicialmente, qual será nosso modelo de base. Embora supere o modelo aleatório, não podemos afirmar que o modelo construído está pronto para ser implantado em produção.
- 2. Ainda que os resultados sejam bons, podemos afirmar que esse modelo pode ser melhorado, de diferentes formas:
 - Empregando técnicas mais modernas e complexas.
 - Utilizando mais dados para treinamento.



Dica do (a) Professor (a)

Bloco 5


Orlando da Silva Junior



➤ Otimização mais eficiente!

- *Scikit-Optimize* é uma biblioteca simples e eficiente para minimizar as funções custosas e caixa preta da otimização.
- Linguagem *Python*.
- Construída sobre *NumPy*, *SciPy* e *Scikit-Learn*.

Figura 4 – Página de instalação do Scikit-Optimize



Fonte: print de tela de Scikit-Optimize.



Referências

PROVOST, F.; FAWCETT, T. **Data science para negócios.**
Tradução de Marina Boscatto. Rio de Janeiro: Alta Books,
2016.



Bons estudos!

