



APRENDIZAGEM EM FOCO

ANÁLISE E MODELAGEM PREDITIVA



APRESENTAÇÃO DA DISCIPLINA

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Olá, caro(a) aluno(a)!

O uso massivo da tecnologia na sociedade passou a exigir que novas aplicações e funcionalidades fossem desenvolvidas de forma a tornar os sistemas mais responsivos às necessidades dos usuários. Essas exigências têm transformado o usuário comum e a sociedade em agentes mais empoderados de decisões a partir do conhecimento provocado pela tecnologia geral e, em especial, pelos sistemas de Big Data.

A construção do conhecimento a partir de grandes e distintos volumes de dados trafegando continuamente só é viável por meio de técnicas de computação e estatística adequadas às características desses novos tipos de dados. Assim, representar o conhecimento em modelos de informação torna-se um desafio para o profissional do século XXI.

Nesta disciplina de *Análise e Modelagem Preditiva*, você vai aprender a:

- Descrever técnicas de análise e modelagem preditiva.
- Discutir problemas preditivos e suas soluções.
- Revisar estratégias de classificação de dados.
- Aplicar conceitos de análise preditiva e classificação em Python.

Esta disciplina é muito importante para a sua formação acadêmica, pois é com ela que você vai aprender a analisar e modelar problemas preditivos em ciência de dados. A partir da sua evolução nela, você será capaz de implementar de forma eficiente os algoritmos de aprendizagem preditiva e reconhecer quais estruturas servem para a resolução de problemas em domínios particulares.

Você irá observar que as técnicas de análise preditiva e a classificação de dados a serem estudadas terão um impacto muito grande na sua atuação como um profissional de Ciência de Dados. Atualmente, a maior parte dos trabalhos realizados pelos profissionais dessa área empregam os algoritmos que você vai aprender para construir sistemas inteligentes, elaborar relatórios técnicos e extrair insights de grandes bases de dados. A partir do estudo desta disciplina, o profissional torna-se capaz de contribuir com análises relevantes para o negócio e a criar produtos de dados de diferentes fontes de informação.

INTRODUÇÃO

Olá, aluno (a)! A *Aprendizagem em Foco* visa destacar, de maneira direta e assertiva, os principais conceitos inerentes à temática abordada na disciplina. Além disso, também pretende provocar reflexões que estimulem a aplicação da teoria na prática profissional. Vem conosco!

A photograph of a young man with dark, curly hair, smiling broadly. He is wearing a light grey t-shirt. He is in the center of a crowd of other people, who are slightly out of focus. The background shows green trees and a building. The image is overlaid with several geometric shapes: a large teal triangle in the top left, a smaller teal triangle in the middle left, a yellow triangle in the bottom left, and a dark blue triangle in the bottom right.

TEMA 1

Engenharia de Atributos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva



DIRETO AO PONTO

A *Analytics* é uma disciplina focada em entender os porquês de um determinado fenômeno estar acontecendo e/ou o que vai acontecer com esse fenômeno no futuro. Um estudo analítico trabalhará com um conjunto de dados formado por objetos que representarão o foco do estudo por meio de atributos, que representarão as características desse objeto.

Por exemplo, ao estudar uma população de funcionários de uma determinada empresa, os objetos do conjunto de dados serão os dados desses funcionários, como o nome, a data de admissão e o salário. Essas três características formam os três atributos que representam a população de objetos que serão estudados.

Como os atributos são fundamentais para o desempenho da solução que você irá construir, uma forma de melhorar a qualidade destes é por meio da **engenharia de atributos**, que busca pré-processar e selecionar atributos para o problema de modelagem. Ela pode ser considerada uma etapa da análise preditiva e se destaca como uma das mais importantes para o processo de modelagem. Em problemas reais, acredita-se que 80% dos esforços em aplicações de *Machine Learning* sejam consumidos durante essa fase.

Na prática, a engenharia de atributos fornecerá a você duas grandes áreas para trabalhar os atributos de um conjunto de dados, que são:

- Técnicas para o pré-processamento dos dados.
- Estratégias para a seleção de atributos.


Quando falamos em **pré-processamento de dados**, estamos nos referindo a técnicas que podem incluir, deletar ou transformar dados. Essas técnicas não devem ser vistas como opcionais nem

como obrigatórias, mas como um conjunto de ferramentas que visam suportar o processo de análise e modelagem preditiva.

Assim, em alguns contextos, as técnicas de pré-processamento de dados serão mandatórias; em outros, serão opcionais, cabendo a você decidir o que fazer. A observação do problema sob a ótica de alguns fatores pode ajudar, como: o volume de dados disponível, a quantidade de atributos, a complexidade do problema, o tempo computacional exigido pela técnica e a sua recorrência de aplicação.

Embora muitas vezes tenhamos o foco nos processos de modelagem e *Machine Learning*, a preparação de dados pode fazer a diferença no desempenho preditivo do modelo. A Figura 1 esquematiza os principais desafios e/ou abordagens para o pré-processamento de dados em problemas de *Analytics*.

Figura 1 – Esquema-resumo das técnicas para pré-processamento de dados



Fonte: elaborada pelo autor.

Na engenharia de atributos, queremos selecionar os melhores atributos para serem incluídos no processo de modelagem de dados. A segunda área que pode ajudar nesse propósito é a **seleção de atributos**. Nela, são fornecidas técnicas que visam selecionar novos atributos, formando um subconjunto dos atributos antigos, a fim de reduzir a dimensão do conjunto de dados original.

Embora muitos algoritmos de *Machine Learning* sejam projetados para selecionar os atributos mais apropriados de acordo com o critério de representação do próprio algoritmo, um conjunto de técnicas externas pode colaborar com a escolha das melhores características. Quando a seleção de atributos é realizada automaticamente, podemos aplicar uma das seguintes abordagens (CAI et al., 2018):

- **Filtro:** a seleção de atributos acontece antes da geração do modelo de aprendizado, filtrando os atributos menos importantes de acordo com algum critério.
- **Wrapper:** a seleção de atributos acontece paralelamente à utilização do algoritmo de aprendizagem em *Machine Learning*. A cada nova iteração, um subconjunto de dados é selecionado e o processo é repetido para cada subconjunto de atributos, até que um determinado critério de parada seja satisfeito.
- **Embutida:** utiliza um critério interno do algoritmo de aprendizagem para realizar a seleção dos atributos.

Tanto as estratégias de seleção de atributos quanto as técnicas de pré-processamento de dados podem ser utilizadas de maneira exaustiva como recursos para a melhoria de modelos analíticos. Dessa forma, essas duas áreas da engenharia de atributos tornam-se partes essenciais do processo de análise e modelagem preditiva.

Referências bibliográficas

CAI, Jie *et al.* Feature selection in machine learning: A new perspective. **Neurocomputing**, [s.l.], v. 300, p. 70-79, 2018.

PARA SABER MAIS

Em ambientes organizacionais, o propósito de uma aplicação de *Analytics* é permitir que você compreenda a situação atual do negócio e forneça ao tomador de decisão um arcabouço de conhecimentos a partir das informações que são disponibilizadas a ele.

Nesse contexto, os dados são essenciais para a construção de uma aplicação analítica, pois são insumos fornecidos por processos de negócio para o entendimento dos fenômenos que estão acontecendo na organização. Sem os bancos de dados, a aplicação de *Analytics* enfraquece o poder de escolha do tomador de decisão.

Por isso, para tirar o máximo proveito dos dados, é importante modelar o problema adequadamente, e uma forma de fazer isso é compreender o funcionamento das principais tarefas analíticas. Entre elas, destacamos as quatro mais comumente encontradas no mercado brasileiro (PROVOST; FAWCETT, 2016, p. 20-23):

- **Classificação:** tem como meta prever (ou prever), para cada indivíduo de uma população, a que conjunto de classes ele pertence.
- **Regressão:** deseja estimar ou prever um valor numérico para cada indivíduo da população.

- **Agrupamento:** reunir indivíduos de uma população por meio de similaridade, sem, no entanto, estar motivado por algum propósito.
- **Mineração de itens frequentes:** busca por associações entre entidades com base em transações que as envolvem.
- **Redução de dados:** procura substituir um grande conjunto de dados por um outro conjunto com menos informações, mantendo a mesma qualidade de informações relevantes.

Ao se deparar com um desafio de *Analytics*, você deverá escolher uma dessas abordagens para construir sua solução. Embora muitos problemas possam se encaixar em mais de uma abordagem, convém escolher aquela que torna o problema o mais simples possível de ser resolvido.

Para exemplificar as abordagens na prática, considere o desafio da rotatividade de clientes (*turnover*) em uma empresa de telefonia celular. Abordando-o como uma tarefa de classificação, o objetivo desse problema será de, observando uma base histórica de clientes, discriminar os clientes entre aqueles que abandonaram a companhia e os que se mantiveram fiéis. Como uma tarefa de agrupamento, o objetivo poderá ser de organizar em grupos as características dos clientes que sejam mais ou menos prováveis de abandonar o serviço ofertado pela companhia; e, como uma tarefa de regressão, um índice poderá ser construído para indicar a probabilidade de um cliente abandonar a companhia.

Veja, portanto, que o objetivo da aplicação dependerá do problema que se pretende resolver e da abordagem a ser adotada. Esse conjunto de tarefas analíticas é capaz de trabalhar o mesmo problema em diferentes visões.

Referências bibliográficas

PROVOST, Foster; FAWCETT, Tom. **Data Science para Negócios**. Tradução de Marina Boscatto. Rio de Janeiro: Alta Books, 2016.

TEORIA EM PRÁTICA

Na prática dos negócios, *Analytics* é uma ferramenta que deve ser empregada para melhorar a capacidade de trabalho. Para o tomador de decisão, o objetivo desta é descrever, prever e melhorar o desempenho do negócio. Dessa forma, ferramentas da matemática e da estatística ajudam a investigar, explorar, modelar e apresentar soluções utilizando dados e recursos computacionais disponíveis pela organização.

Pensando no papel do tomador de decisão e em como ele pode entender uma solução analítica para contribuir com ela e, posteriormente, usufruir dela, como você explicaria o seu papel para o tomador de decisão? Como ele pode contribuir com o processo de engenharia de atributos?

Para conhecer a resolução comentada proposta pelo professor, acesse a videoaula deste *Teoria em Prática* no ambiente de aprendizagem.

LEITURA FUNDAMENTAL

Indicações de leitura

Prezado aluno, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o log in por meio do seu AVA), e outras podem estar disponíveis em

sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!

Indicação 1

No capítulo *Preparação dos dados* do livro indicado, são descritas diferentes estratégias para a preparação de dados qualitativos. O capítulo foca em formulários de entrevista e textos digitados, instrumentos muito comuns nas ciências humanas.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

GIBBS, Graham. Preparação dos dados. *In*: GIBBS, Graham. **Análise de dados qualitativos**: coleção pesquisa qualitativa. Porto Alegre: Artmed, 2009.

Indicação 2

O capítulo indicado apresenta diferentes tópicos sobre o uso de dados na computação, como a relação entre dados, informação e conhecimento; a representação digital do dado em dispositivos analógicos; e a codificação binária.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

CARVALHO, André C. P. L. F.; LORENA, Ana Carolina. Dados. *In*: CARVALHO, André C. P. L. F.; LORENA, Ana Carolina. **Introdução à computação**: hardware, software e dados. Rio de Janeiro: LTC, 2017.

QUIZ

Prezado aluno, as questões do Quiz têm como propósito a verificação de leitura dos itens *Direto ao Ponto, Para Saber Mais, Teoria em Prática e Leitura Fundamental*, presentes neste *Aprendizagem em Foco*.

Para as avaliações virtuais e presenciais, as questões serão elaboradas a partir de todos os itens do *Aprendizagem em Foco* e dos slides usados para a gravação das videoaulas, além de questões de interpretação com embasamento no cabeçalho da questão.

1. As técnicas de pré-processamento de dados são muito úteis para incluir, deletar ou transformar os atributos de um conjunto de dados. A respeito dessas técnicas, é possível afirmar que
 - a. Eliminar atributos manualmente é uma atividade realizada previamente à integração de dados.
 - b. A integração de dados acontece quando os dados necessários estão distribuídos em diferentes locais.
 - c. A integração de dados é responsável por gerar novos dados artificiais para o conjunto de dados original.
 - d. A remoção de objetos da classe majoritária é uma técnica para o balanceamento de classes.

- e. Limpar dados ruidosos é uma técnica destinada a remover objetos que se repetem muitas vezes nos dados.
2. A tarefa analítica que melhor descreve o propósito de discriminar um indivíduo entre conjuntos pré-existentes é:
- a. A classificação.
 - b. O agrupamento.
 - c. A regressão.
 - d. A redução de dados.
 - e. A mineração de itens frequentes.



GABARITO

Questão 1 - Resposta B

Resolução: A integração de dados é uma atividade destinada à agregação de dados distribuídos em diferentes locais, como servidores e dispositivos. Para gerar dados artificialmente ou remover objetos da classe majoritária, você deve utilizar técnicas de balanceamento de dados. A limpeza de dados ruidosos e de dados redundantes são técnicas diferentes pertencentes à mesma categoria.

Questão 2 - Resposta A

Resolução: A classificação é uma tarefa que tem como propósito prever a classe à qual pertence um indivíduo de uma população.



TEMA 2

Avaliação de Modelos Preditivos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva



DIRETO AO PONTO

Estudar e programar os algoritmos de *Machine Learning* é certamente a parte mais divertida para um entusiasta da área. No entanto, avaliar a qualidade do modelo gerado por esses algoritmos é tão importante quanto construí-los. Mesmo com muitos métodos sofisticados disponíveis atualmente e uma grande quantidade de dados que ajuda a corroborar o desempenho de qualquer algoritmo, trabalhar com um processo rigoroso que valide os resultados é fundamental para assegurar que tudo foi desenvolvido como o esperado.

Podemos afirmar que não existe apenas uma única técnica universal para a solução de todos os problemas de *Analytics*. Inclusive, o propósito de estudar diferentes métodos é poder experimentá-los conforme as diferentes abordagens que cada um deles oferece.


Outro ponto importante a ser considerado é o estudo das características dos métodos. De acordo com o paradigma adotado, o método ou algoritmo selecionado poderá nos ajudar a determinar com mais segurança como os dados serão tratados e extrapolados. Por exemplo, o algoritmo 1-NN não parece ser uma boa opção em um problema cujo conjunto de dados apresente altas dimensões. Nesse caso, o mais adequado é descartá-lo da nossa lista de algoritmos candidatos e selecionar um outro que tenha maior chance de resolver um problema com essa característica.

Perceba ainda que, como você deverá realizar diversos experimentos para encontrar não apenas o melhor método, mas também a melhor configuração de hiperparâmetros para ele, é necessário planejar adequadamente os experimentos, a fim de que o algoritmo demonstre a sua eficácia e seja reproduzível no futuro.

Observando a Figura 1, você vai perceber um modelo genérico para o processo de avaliação de desempenho de um algoritmo preditivo. Esse modelo consiste em três etapas:

1. Divisão da base de dados histórica em três subconjuntos de dados disjuntos: treinamento, validação e teste.
2. Treinamento, otimização e avaliação do modelo preditivo construído nos dados de treinamento sobre os dados de validação.
3. Estimação ou classificação, que corresponde à aplicação do preditor ótimo gerado nas etapas anteriores sobre os dados de teste.

Figura 1 – Modelo genérico de processo para a avaliação de modelos preditivos



Fonte: elaborada pelo autor.

É importante esclarecer que a divisão dos dados históricos é realizada porque, ao empregar os mesmos dados para treinamento e predição, o desempenho preditivo deverá computar estimativas otimistas para o preditor, já que todos os algoritmos tentam melhorar o seu desempenho preditivo durante a fase de treinamento usando esses dados (FACELI *et al.*, 2011).

Referências bibliográficas

FACELI, Katti *et al.* **Inteligência Artificial:** uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.




PARA SABER MAIS

Você sabia que existem outras formas de avaliar um modelo preditivo?

Além da acurácia, da matriz de confusão e das diversas medidas de desempenho que você já conhece, uma forma alternativa e que tem sido bastante discutida pela comunidade de Machine Learning é a Análise ROC, destinada a problemas de classificação com apenas duas classes. Por meio das curvas ROC (Receiving Operating Characteristic), o desempenho de um classificador pode ser plotado em um gráfico, permitindo que ele seja avaliado (FACELLI *et al.*, 2011).

Na Figura 2, é possível observar a interpretação de um gráfico ROC, plotado de forma bidimensional. O eixo X representa a taxa de falsos positivos (TFP); o eixo Y representa a taxa de verdadeiros positivos (TVP); e a linha diagonal representa um classificador aleatório. Assim, qualquer classificador abaixo dessa linha será considerado um classificador pior que o aleatório. Além disso, quanto mais próximo do ponto (0, 1), melhor será esse classificador.

Figura 2 – Curva ROC



Fonte: elaborada pelo autor.

Referências bibliográficas

FACELI, Katti *et al.* **Inteligência Artificial:** uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.



TEORIA EM PRÁTICA

Imagine que você foi contratado por um banco para resolver o problema de análise de crédito de uma população local. Naquela localidade, o banco possui 200 mil clientes e pretende oferecer crédito a pelo menos 60% deles. Assim, após a análise do banco de dados com as informações dos clientes em potencial, você observou

uma quantidade significativa de atributos relevantes para ajudá-lo na solução.

Sabendo que os dados estão disponíveis, quais seriam os próximos passos que você daria para resolver esse problema? Como você determinaria quem são os “bons pagadores” e os “maus pagadores”, uma vez que o banco nunca forneceu crédito antes de sua chegada à empresa?

Para conhecer a resolução comentada proposta pelo professor, acesse a videoaula deste *Teoria em Prática* no ambiente de aprendizagem.



LEITURA FUNDAMENTAL

Indicações de leitura

Prezado aluno, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o log in por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!

Indicação 1

No livro indicado, você vai encontrar detalhes sobre o processo de amostragem. O livro trata de maneira abrangente a estatística e descreve de maneira bastante didática como os elementos fundamentais dessa área de estudo podem ser aplicados.

Para realizar a leitura, acesse a plataforma Biblioteca Virtual e busque pelo título da obra no buscador.

RIBEIRO-SANTOS, Thatiane Cristina S. C. **Probabilidade e Estatística**. Londrina: Editora e Distribuidora Educacional S.A., 2016.

Indicação 2

O capítulo indicado tem como foco o estudo da relação entre duas variáveis quantitativas, com uma abordagem inicial para introduzir a análise de regressão.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

MOORE, David S. Regressão. In.: MOORE, David S. **A estatística básica e sua prática**. 7. ed. Rio de Janeiro: LTC, 2017. cap 5. p. 105-133.

QUIZ

Prezado aluno, as questões do Quiz têm como propósito a verificação de leitura dos itens *Direto ao Ponto, Para Saber Mais, Teoria em Prática e Leitura Fundamental*, presentes neste *Aprendizagem em Foco*.

Para as avaliações virtuais e presenciais, as questões serão elaboradas a partir de todos os itens do *Aprendizagem em Foco* e dos slides usados para a gravação das videoaulas, além de questões de interpretação com embasamento no cabeçalho da questão.

1. A respeito da avaliação de modelos preditivos, é correto afirmar que:
 - a. Os dados históricos devem ser divididos em subconjuntos distintos para fins experimentais.
 - b. Uma mesma medida de desempenho pode ser aplicada em problemas de regressão e classificação.
 - c. A avaliação é realizada sobre os dados de treinamento durante a otimização do modelo.
 - d. A avaliação é realizada sobre os dados de treinamento em problemas de regressão.
 - e. A estimação ou classificação sobre novos dados é realizada antes da etapa de treinamento.

2. A _____ é uma estratégia alternativa à matriz de confusão para a avaliação de problemas preditivos. Nessa estratégia, devemos construir um _____ e nele plotar o desempenho do modelo observando os resultados dos/da _____ e dos/da _____, respectivamente aos eixos X e Y.
Assinale a alternativa que completa adequadamente as lacunas.
 - a. Curva ROC; gráfico; falsos positivos; verdadeiros positivos.
 - b. Curva ROC; gráfico bidimensional; verdadeiros positivos; falsos positivos.

- c. Estratégia ROC; gráfico bidimensional; taxa positiva; taxa negativa.
- d. Análise ROC; gráfico bidimensional; taxa de falsos positivos; taxa de verdadeiros positivos.
- e. Análise ROC; gráfico; taxa de verdadeiros positivos; taxa de falsos positivos.



GABARITO

Questão 1 - Resposta A

Resolução: Considerando o processo de avaliação de modelos, é correto dividir os dados históricos em subconjuntos distintos. Problemas de regressão e classificação utilizam medidas diferentes em razão do rótulo. A avaliação é sempre realizada sobre os dados não vistos no treinamento. A última etapa do processo de avaliação é a predição de novos valores.

Questão 2 - Resposta D

Resolução: A **análise ROC** é uma estratégia alternativa à matriz de confusão para a avaliação de problemas preditivos. Nessa estratégia, devemos construir um **gráfico bidimensional** e nele plotar o desempenho do modelo observando os resultados da **taxa de falsos positivos** e da **taxa de verdadeiros positivos**, respectivamente aos eixos X e Y.



TEMA 3

Otimização de Modelos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva



DIRETO AO PONTO

O desenvolvimento de modelos de *Machine Learning* é uma atividade presente na etapa de modelagem de um projeto de ciência de dados que requer validações sobre os resultados do modelo. Avaliar a sua importância para o problema de negócio também é uma atividade importante para o projeto.

Quando avaliamos a primeira vez um modelo, podemos encontrar resultados ruins para ele. Nesse caso, nossa nova missão é otimizar esse modelo, buscando melhorar o desempenho preditivo antes de entregá-lo em produção.

Um ponto importante nesse processo de otimização é que a nossa primeira melhoria deve ter como base de comparação não o modelo em si mesmo, mas um preditor de base (*baseline*), que é um modelo cujos resultados já temos antes mesmo de começar. Em muitas situações, o *baseline* é um modelo aleatório que apresenta 50% de acertos. Ou seja, se o nosso modelo acertar mais que o *baseline*, precisaremos apenas nos concentrar em ajustá-lo por meio de estratégias de otimização.

Tendo em mente essas primeiras considerações, observe na Figura 1 como o processo de otimização de modelos pode ser compreendido com mais detalhes. Nela, encontramos as áreas de apoio da otimização:

- **Atributos:** os atributos selecionados devem ser importantes para o problema e informativos a respeito das entidades que serão representadas. Os atributos escolhidos para a modelagem devem reduzir a incerteza a respeito do que queremos descobrir. Quando temos um atributo-alvo, a busca pelos atributos informativos torna-se mais fácil, uma

vez que nossa busca tem como meta aqueles atributos que apresentam maior correlação com o atributo-alvo.

- **Modelo:** quando um novo modelo preditivo é gerado, ele é criado a partir de um processo de indução. Ele será a regra geral construída a partir dos casos únicos e individuais de um conjunto de dados por meio de um algoritmo de indução, que é o responsável por construir essa regra geral. O algoritmo construído a partir desse processo será o preditor.
- **Modelagem:** enquanto a modelagem paramétrica assume que o conjunto de dados é proveniente de um tipo de distribuição de probabilidade e faz inferências sobre os parâmetros da distribuição, a modelagem não paramétrica compreende técnicas que não dependem de nenhuma distribuição de dados particular.
- **Problemas:** no *overfitting* (sobreajuste), os modelos tendem a se adaptar aos dados de treinamento. Nesse caso, o modelo que não é capaz de extrapolar além do que já foi observado, ajusta-se perfeitamente aos dados de treinamento, que são os dados de entrada. No *underfitting* (subajuste), o modelo construído faz pouco esforço para se ajustar aos dados. Em geral, modelos com alto viés e baixa variância sofrem de subajuste. Os melhores modelos são aqueles que se encaixam melhor aos dados e ao mesmo tempo são mais simples. Podemos utilizar técnicas de regularização para otimizar não apenas o ajuste do modelo aos dados, mas também combinar o ajuste e a complexidade do modelo (FACELLI et al., 2011).
- **Estratégias:** a busca em grade e a busca aleatória são as principais estratégias para buscar os hiperparâmetros ótimos no espaço de hiperparâmetros (BERGSTRA; BENGIO, 2012). Na busca em grade, a ideia fundamental é gerar exaustivamente candidatos a partir de uma grade de valores pré-determinados manualmente e varrer o espaço de hiperparâmetros até que

os hiperparâmetros ótimos sejam encontrados. Na busca aleatória, a combinação exaustiva da busca em grade é substituída por um conjunto de configurações, em que cada configuração é selecionada a partir de uma distribuição de possíveis valores de parâmetros.

Figura 1 – Esquema-resumo sobre a otimização de modelos preditivos

Atributos	Modelo	Modelagem	Problemas	Estratégias
• Informativos. • Relevantes. • Suficientes.	• Algoritmo de indução (indutor). • Algoritmo de predição (preditor).	• Paramétrica. • Não paramétrica • Linear. • Não linear.	• <i>Overfitting</i>. • <i>Underfitting</i>. • Regularização.	• Busca em grade. • Busca aleatória.

Fonte: elaborada pelo autor.

Referências bibliográficas

BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. **The Journal of Machine Learning Research**, [s.l.], v. 13, n. 1, p. 281-305, 2012.

FACELLI, Katti *et al.* **Inteligência Artificial: uma abordagem de aprendizado de máquina**. Rio de Janeiro: LTC, 2011.

PARA SABER MAIS

A maior parte dos métodos de *Machine Learning* são paramétricos e baseados em modelos lineares. Por exemplo, podemos discriminar (separar) os objetos de treinamento de duas classes se introduzirmos um limite, que é uma linha reta não perpendicular aos eixos. Ao traçarmos uma reta criando essa separação, construiremos um **classificador linear**, que consiste essencialmente

na soma ponderada dos valores dos atributos. No caso de termos dois atributos, teríamos uma equação representada desta forma:

$$y = ax + b$$

Nessa equação, a corresponde à inclinação da reta e b é a interceptação y , quando $x = 0$. Assim, um novo objeto x pode ser classificado como positivo (azul) se ele estiver acima da linha imaginária; e como negativo (vermelho) se ele estiver abaixo dessa linha. Ainda podemos reorganizar a função de classificação em uma **função por partes**, como:

$$classe(x) = \begin{cases} \text{azul}, & ax + b > 0 \\ \text{vermelho}, & ax + b \leq 0 \end{cases}$$

Esse tipo de função por partes é conhecido como **discriminante linear**, pois ele discrimina (separa) os objetos entre as classes conhecidas. A nossa linha imaginária, existindo, passa a ser a **combinação linear** dos atributos do problema, sendo conhecida como limite de decisão. No exemplo imaginário, a combinação linear é uma reta e o limite de decisão pode ser um plano, quando temos três dimensões ou um hiperplano para mais dimensões.

No caso da **regressão linear**, o atributo-alvo é uma variável numérica e o algoritmo de aprendizagem tem como meta ajustar o modelo aos dados de entrada, buscando pelos parâmetros ótimos da função linear, que toma como base a ideia da função discriminante linear conhecida anteriormente, na seguinte forma:

$$y = f(x) = w_0 + w_1x_1 + w_2x_2 + \dots$$

Considerando a otimização de um modelo como um problema a ser solucionado pelos algoritmos de aprendizagem, precisaremos responder a algumas perguntas, como:

- Quais ponderações ou pesos devemos escolher?

- Quão longe estão os valores estimados dos valores reais sobre os dados de treinamento?
- Quão grande é o erro a ser ajustado ao modelo?



TEORIA EM PRÁTICA

O Hospital ABC, localizado na Praia Grande, em São Paulo, possui uma equipe de análise de dados capaz de construir modelos preditivos a partir dos dados dos pacientes internados naquela unidade hospitalar. Anualmente, o hospital atende cerca de 100 mil pessoas, sendo fevereiro o mês com maior quantidade de atendimentos. Segundo o diretor do hospital, 55% dos atendimentos são destinados a consultas de pronto atendimento, enquanto 0,25% para tratamento de câncer.

Um modelo de diagnóstico de câncer de mama foi avaliado pela equipe com 63% de acurácia, 52% de precisão e 78% de sensibilidade.

O que você acha do desempenho desse modelo? É possível melhorá-lo? Se sim, como?

Para conhecer a resolução comentada proposta pelo professor, acesse a videoaula deste *Teoria em Prática* no ambiente de aprendizagem.



LEITURA FUNDAMENTAL

Indicações de leitura

Prezado aluno, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o log in por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!

Indicação 1

No livro indicado, você vai encontrar mais informações sobre o processo de modelagem matemática e otimização. Além dos conceitos básicos, o livro é aplicado a sistemas agroindustriais.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

CAIXETA-FILHO, José Vicente. **Pesquisa operacional:** técnicas de otimização aplicadas a sistemas agroindustriais. São Paulo: Atlas, 2011.

Indicação 2

O capítulo indicado reflete sobre a atividade do raciocínio e sobre a busca pela razão sob a ótica da lógica. O livro é apresentado como uma obra filosófica introdutória que trata de questões sobre os problemas da filosofia da lógica.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

GOLDSTEIN, Laurence *et al.* Razão, desrazão e lógica. *In.*: GOLDSTEIN, Laurence *et al.* **Lógica**: conceitos-chave em filosofia. Porto Alegre: Artmed, 2007. cap. 1.



QUIZ

Prezado aluno, as questões do Quiz têm como propósito a verificação de leitura dos itens *Direto ao Ponto, Para Saber Mais, Teoria em Prática e Leitura Fundamental*, presentes neste *Aprendizagem em Foco*.

Para as avaliações virtuais e presenciais, as questões serão elaboradas a partir de todos os itens do *Aprendizagem em Foco* e dos slides usados para a gravação das videoaulas, além de questões de interpretação com embasamento no cabeçalho da questão.

1. Otimizar um modelo é uma etapa importante em projetos de ciência de dados. A respeito da otimização de modelos preditivos, é correto afirmar:

- a. A otimização corresponde ao processo de melhora no desempenho preditivo, realizado antes da implantação do modelo em produção.
- b. O processo de otimização se caracteriza pela busca de parâmetros e hiperparâmetros ótimos em um conjunto pré-definido de modelos.
- c. O preditor base é a referência do processo de otimização algorítmica, sendo responsável por prever o desempenho dos modelos lineares.
- d. A base da classificação de dados é a otimização de modelos preditivos em um processo centrado na aprendizagem de dados.
- e. O desempenho de um modelo de classificação depende da otimização de hiperparâmetros realizada em conjunto com a regularização.

2. Na modelagem preditiva, _____ corresponde à generalização de _____ a partir de casos específicos. Considerando a base de dados como sendo esses casos específicos, o modelo preditivo corresponde à regra geral construída a partir deles. Assim, o _____ é o responsável por construir essa regra geral.

Assinale a alternativa que completa adequadamente as lacunas.

- a. A indução; regras específicas; algoritmo de aprendizagem.
- b. A indução; regras gerais; algoritmo de indução.
- c. A regra geral; bases de dados; processo.
- d. A regra geral; bases de dados; algoritmo de aprendizagem.
- e. A regra específica; regras gerais; algoritmo de indução.



GABARITO

Questão 1 - Resposta A

Resolução: Otimizar um modelo significa buscar melhorar o desempenho preditivo desse modelo antes de entregá-lo em produção. Podemos até pensar que isso é realizado na fase de modelagem, mas na maior parte das vezes o processo de modelagem é experimental, com o objetivo de melhorar o desempenho do preditor de base, e não encontrar o melhor resultado possível.

Questão 2 - Resposta B

Resolução: Na modelagem preditiva, **a indução** corresponde à generalização de **regras gerais** a partir de casos específicos. Considerando a base de dados como sendo esses casos específicos, o modelo preditivo corresponde à regra geral construída a partir deles. Assim, o **algoritmo de indução** é o responsável por construir essa regra geral.



TEMA 4

Aplicações de Análise e Modelagem Preditiva

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

DIRETO AO PONTO

A Figura 1 ilustra o processo de ciência de dados que adaptamos da literatura de mineração de dados e *Machine Learning* (CHAPMAN *et al.*, 2000; FACELI *et al.*, 2011) para apresentar aqui uma das melhores formas para trabalhar com a linguagem Python em projetos de análise e modelagem preditiva.

Figura 1 – Processo de Ciência de Dados



Fonte: Lorem ipsum dolor sit amet.

O processo é bastante simples e você pode estudá-lo de forma sequencial, embora, muitas vezes, ele seja iterativo. Para simplificar o entendimento de um projeto tantas vezes complexo, listamos as

sete etapas que você deverá realizar para entregar esse projeto, independentemente da sua complexidade ou do seu volume de dados:

- 1. Análise do problema do negócio:** nesta etapa, vamos compreender o problema e o domínio de negócio que queremos resolver. Também vamos definir o objetivo do projeto; a tarefa que será realizada; os métodos de aprendizagem de máquina que serão aplicados; e as métricas que deverão ser coletadas para mensurar os resultados.
- 2. Obtenção dos dados:** aqui vamos importar as bibliotecas necessárias no ambiente de programação e carregar os dados disponíveis em memória para fins experimentais.
- 3. Visualização dos dados:** após o carregamento dos dados, vale a pena explorarmos a sua configuração inicial a partir de gráficos e diagramas.
- 4. Preparação dos dados para modelagem:** nesta etapa, vamos processar as linhas e as colunas do conjunto de dados estruturado usando as técnicas de engenharia de atributos.
- 5. Treinamento e avaliação de modelos:** com os dados pré-processados e prontos para treinamento, aplicaremos os algoritmos selecionados, buscando pelo modelo mais adequado ao problema em análise.
- 6. Otimização do modelo escolhido:** nesta etapa, vamos trabalhar com o algoritmo que apresentou o melhor resultado na etapa anterior. Aplicaremos estratégias de otimização para ajustar os hiperparâmetros do algoritmo e torná-lo ainda mais eficiente.
- 7. Distribuição:** destinada à implantação do modelo construído no formato esperado pelo tomador de decisão, como um relatório, um conjunto de planilhas ou uma aplicação *mobile*.

Seguindo esse processo metodológico, você poderá trabalhar em qualquer projeto de ciência de dados. Ao escolher a linguagem

Python é um ambiente adequado para executá-la (como a distribuição Anaconda ou o Google Colab), você poderá criar scripts ou notebooks muito rapidamente, acelerando o desenvolvimento do projeto e as suas entregas.

Referências bibliográficas

CHAPMAN, Pete *et al.* CRISP-DM 1.0: Step-by-step data mining guide. **SPSS inc**, [s.l.], v. 9, p. 13, 2000.

FACELI, Katti *et al.* **Inteligência Artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.



PARA SABER MAIS

Em 2012, o professor Pedro Domingos, da Universidade de Washington e autor do livro *O Algoritmo Mestre* (2017), publicou o artigo *A few useful things to know about machine learning* (em tradução literal: “Algumas coisas úteis para saber sobre o aprendizado de máquina”) na *Communications of the ACM*, um importante periódico com alto fator de impacto na comunidade científica.

Nesse artigo, o autor quer comunicar a outros pesquisadores da área o que a teoria da aprendizagem de máquina nem sempre consegue mostrar. O texto destaca 12 lições importantes para os praticantes de *Machine Learning*, que são:

1. Aprendizagem = representação + avaliação + otimização.
2. O importante é generalizar.
3. Dados sozinhos não fazem milagres.
4. *Overfitting* tem muitas faces.
5. A intuição falha em altas dimensões.
6. Garantias teóricas não são o que parecem.
7. Engenharia de atributos é a chave.

8. Algoritmos muito inteligentes podem ser superados por mais dados.
9. Aprenda muitos modelos, e não apenas um.
10. Simplicidade não implica acurácia.
11. Representação de dados não implica aprendizagem.
12. Correlação não implica causalidade.

Cada uma dessas lições pode ser compreendida em detalhes com a leitura simples e agradável que o artigo procura ter para atrair a comunidade científica e manter a atenção dos praticantes de *Machine Learning*. Assim como qualquer outra disciplina, a aprendizagem de máquina também possui muita “sabedoria popular”. Dessa forma, esse artigo procura contar um pouco da experiência do autor nos tópicos mais proeminentes dos seus anos de estudo.

Em suma, para o professor Pedro Domingos (2012), *Machine Learning* pode descobrir como desempenhar importantes tarefas por meio da generalização de exemplos. Frequentemente, isso é viável e tem bom custo-benefício onde a programação manual não é. Quanto mais dados estiverem disponíveis, mais ambiciosos serão os problemas abordados.

Referências bibliográficas

DOMINGOS, Pedro. A few useful things to know about machine learning. **Communications of the ACM**, [s.l.], v. 55, n. 10, p. 78-87, 2012.

DOMINGOS, Pedro. **O Algoritmo Mestre**. São Paulo: Novatec, 2017.

TEORIA EM PRÁTICA

Os funcionários da empresa onde você trabalha estão recebendo muitos e-mails não solicitados, sendo alguns deles indevidos. Como

a empresa passou por uma recente reestruturação, o servidor ainda não possui um detector de SPAM; assim, o diretor responsável que você construiu do zero um sistema que eliminasse as mensagens antes que as caixas de e-mail ficassem lotadas.

Em apenas uma semana, os 50 funcionários receberam 1.252 mensagens indevidas. Você tem 15 dias para construir e implantar o sistema. Qual é a sua estratégia?

Para conhecer a resolução comentada proposta pelo professor, acesse a videoaula deste *Teoria em Prática* no ambiente de aprendizagem.



LEITURA FUNDAMENTAL

Indicações de leitura

Prezado aluno, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o log in por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!

Indicação 1

No livro indicado, você terá uma visão da ciência de dados aplicada à educação. Os capítulos descrevem conceitos fundamentais da área, cases e aplicações no mercado educacional.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

FILATRO, Andrea. **Data Science na Educação:** presencial, a distância e corporativa. São Paulo: Saraiva Educação, 2021.

Indicação 2

O livro indicado apresenta conceitos, exemplos e aplicações práticas da aprendizagem de máquina usando a linguagem Python.

Para realizar a leitura, acesse a nossa plataforma Biblioteca Virtual e busque pelo título da obra no parceiro Minha Biblioteca.

LENZ, Maikon Lucian *et al.* **Fundamentos de aprendizagem de máquina.** Porto Alegre: SAGAH, 2020.



QUIZ

Prezado aluno, as questões do Quiz têm como propósito a verificação de leitura dos itens *Direto ao Ponto, Para Saber Mais, Teoria em Prática e Leitura Fundamental*, presentes neste *Aprendizagem em Foco*.

Para as avaliações virtuais e presenciais, as questões serão elaboradas a partir de todos os itens do *Aprendizagem em Foco*

e dos slides usados para a gravação das videoaulas, além de questões de interpretação com embasamento no cabeçalho da questão.

1. Em 2012, o professor Pedro Domingos publicou o artigo *A few useful things to know about machine learning* com 12 lições sobre a prática de *Machine Learning* para pesquisadores e profissionais. Assinale a alternativa que apresenta uma dessas lições.
 - a. Aprendizagem = representação + avaliação.
 - b. Aprendizagem = representação + otimização.
 - c. Aprendizagem = representação + avaliação + otimização.
 - d. Aprendizagem = representação + avaliação + modelagem.
 - e. Otimização = aprendizagem + avaliação + representação.

2. A ciência de dados pode ser formulada a partir de um processo que enxergue o desenvolvimento de projetos analíticos como uma série de etapas, que vão da _____ até o/a _____ do que foi construído. Entre essas etapas, o cientista de dados ou especialista em *Analytics* deverá aplicar estratégias para obter e _____; preparar os dados obtidos para modelagem; executar o treinamento e a avaliação dos modelos; e, finalmente, _____ o melhor modelo da etapa anterior.
Assinale a alternativa que completa adequadamente as lacunas.
 - a. Análise de dados; implantação; pré-processar dados; implantar.
 - b. Análise do problema de negócio; implantação; visualizar dados; implantar.
 - c. Análise de dados; distribuição; visualizar dados; otimizar.
 - d. Análise do problema de negócio; pré-processamento; visualizar dados; otimizar.

- e. Análise do problema de negócio; distribuição; visualizar dados; otimizar.



GABARITO

Questão 1 - Resposta C

Resolução: A alternativa “Aprendizagem = representação + avaliação + otimização” apresenta a primeira lição presente no artigo do professor Pedro Domingos.

Questão 2 - Resposta E

Resolução: A ciência de dados pode ser formulada a partir de um processo que enxergue o desenvolvimento de projetos analíticos como uma série de etapas, que vão da **análise do problema de negócio** até a **distribuição** do que foi construído. Entre essas etapas, o cientista de dados ou especialista em *Analytics* deverá aplicar estratégias para obter e **visualizar dados**; preparar os dados obtidos para modelagem; executar o treinamento e a avaliação dos modelos; e, finalmente, otimizar o melhor modelo da etapa anterior.



BONS ESTUDOS!