

Podcast

Disciplina: Análise e Modelagem Preditiva

Título do tema: Aplicações de Análise e Modelagem Preditiva

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Abertura:

Olá, tudo bem? Aqui é o professor Orlando Junior e, no podcast de hoje, você vai conhecer 12 lições importantes para trabalhar com *Machine Learning*.

Em 2012, o professor Pedro Domingos, da Universidade de Washington e autor do livro “O Algoritmo Mestre”, pela Novatec, no Brasil, publicou o artigo “Algumas coisas úteis para saber sobre o aprendizado de máquina” pelas Comunicações da ACM.

Nesse artigo, o professor Domingos relata 12 lições importantes sobre *Machine Learning* pensando em pessoas como você, que desejam trabalhar com essa tecnologia.

Embora o artigo não seja recente, as lições que ele apresenta continuam sendo muito úteis nos dias de hoje, especialmente aos ingressantes na carreira de ciência de dados.

Vamos conhecer essas 12 lições?

A primeira é: aprendizagem é = a representação + avaliação + otimização. Para o professor, o segredo da aprendizagem de máquina é escolher uma boa representação para os dados, uma boa função de avaliação para o algoritmo de aprendizagem e um método de busca para otimizar os resultados.

A segunda lição é: prepare tudo para generalizar! O que realmente importa em Machine Learning é generalizar além dos dados de treinamento.

A terceira lição é a seguinte: apenas dados não são suficientes! Para generalizar bem, toda função precisa incorporar conhecimento ou premissas além dos dados. Neste ponto, ter o máximo de informações sobre o problema é crucial.

Nossa quarta lição é sobre *overfitting* e suas diversas faces. Mesmo que forneçamos dados e conhecimento à função de aprendizagem, ainda podemos sofrer com *overfitting*. E melhor maneira de descobrir a causa é decompondo o erro de generalização em viés e variância.

Na quinta lição, o professor Pedro Domingos vai nos ensinar que a intuição falha em altas dimensões. A “maldição da dimensionalidade” é um problema que pode nos atormentar a qualquer momento ao trabalharmos com grandes conjuntos de dados.

A sexta lição nos diz que as garantias teóricas nem sempre são o que parecem. Em processos indutivos, como os de aprendizagem de máquina, sempre estamos apostando nos resultados, mas nem sempre conseguiremos explicar os efeitos. Nesse caso, a estatística e a probabilidade podem nos ajudar.

Na sétima lição, o professor Domingos traz um assunto que nós revisitamos diversas vezes nessa unidade, que é a importância da engenharia de atributos. Segundo ele, os atributos são um dos fatores mais importantes em um projeto de ciência de dados.

A oitava lição pode até ser um pouco contraditória com o que falamos até aqui, mas tem se tornado uma realidade com os avanços de Big Data. Na oitava lição, o professor defende que usar mais dados pode superar os problemas que até mesmo algoritmos muito inteligentes não conseguem resolver.

Na nova lição, o professor Domingos nos ensina que o processo de experimentação é a chave do sucesso e que não devemos nos apegar a apenas um algoritmo, geralmente o nosso favorito, mas experimentar diferentes modelos e compará-los, terminando por ficar com o melhor.

Na décima lição vamos aprender que a simplicidade não implica em acurácia. É verdade que devemos priorizar os modelos mais simples, mas isso não quer dizer que sempre teremos os modelos mais acurados.

Estamos chegando ao fim!

A décima primeira lição diz que a representação é importante, mas que apenas ela não trará a aprendizagem. Mesmo com dados, tempo e memória suficientes, as funções de aprendizagem só conseguirão aprender representações limitadas.

E a última lição é: correlação não implica em causalidade! Esse é um mantra muito popular na comunidade de *Machine Learning* que mostra a relação causa-efeito em sistemas inteligentes. Na prática, algoritmos de aprendizagem podem extrair informações causais, mas suas aplicações são bastante restritas.

Fechamento:

E aí, o que você achou do nosso *podcast*? Fique ligado e até a próxima!