

Podcast

Disciplina: Análise e Modelagem Preditiva

Título do tema: Engenharia de Atributos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Abertura:

Olá, tudo bem? Aqui é o professor Orlando Junior e, no *podcast* de hoje, vamos falar sobre seleção de atributos e como você pode utilizá-la em seus projetos de Analytics.

A seleção de atributos é uma parte crítica no processo de modelagem de dados, porque é nela que nós escolhemos quais atributos farão parte do nosso modelo.

Além disso, com a seleção de atributos:

- Melhoramos o desempenho dos algoritmos de aprendizado de máquina que utilizarmos;
- Simplificamos os modelos preditivos;
- Reduzimos o custo computacional para executar os modelos; e
- Fornecemos – a nós e todos que olharem nosso modelo – um melhor entendimento sobre os resultados encontrados.

Trabalhar com seleção de atributos é, na prática, realizar estudos que nos ajudam a entender melhor a importância dos atributos para os dados que temos à disposição.

Mas como trabalhar com seleção de atributos?

Existem diversas formas de escolhermos os melhores atributos. Podemos fazer isso manualmente ou através de métodos automáticos, que são técnicas que escolherão por nós.

A melhor forma de começar é por meio de uma análise sobre os atributos que temos no conjunto de dados que está sendo investigado. Essa análise pode ser feita observando como os atributos se relacionam com o atributo de saída. Estatísticas e gráficos podem ser extraídos a partir daí.

Podemos ainda aproveitar os atributos que já temos e criar novos atributos, formando um segundo conjunto de dados. Por exemplo: imagine um conjunto de dados de veículos com os atributos VELOCIDADE MÉDIA e TEMPO PERCORRIDO. Por que não criar também o atributo ACELERAÇÃO MÉDIA

a partir desses dois atributos? Como naqueles clássicos problemas da Física, basta dividirmos a VELOCIDADE MÉDIA pelo TEMPO PERCORRIDO para encontrarmos a ACELERAÇÃO MÉDIA e aí computarmos esses novos valores para todos os objetos do conjunto de dados.

Outra estratégia comum em problemas de Analytics é utilizar uma abordagem automática para detectar quais atributos são mais relevantes.

A abordagem *wrapper* se destaca com uma das principais abordagens por avaliar diversos conjuntos de atributos usando aprendizagem de máquina. Como a seleção de atributos já é comumente utilizada em Machine Learning, nada melhor do que usar também uma abordagem de seleção de atributos baseada em aprendizado.

Porém, o que pode ser uma dádiva também pode ser uma maldição. Na abordagem *wrapper*, o melhor conjunto de atributos é ajustado ao algoritmo de aprendizado. Os melhores atributos para redes neurais podem não ser os melhores para árvores de decisão. Portanto, se você pensa em utilizar mais de um método de aprendizagem, tome cuidado com essa abordagem.

Uma alternativa ao método *wrapper* é a abordagem filtro. Nela, a seleção de atributos é feita antes da aplicação de qualquer algoritmo de aprendizagem. Com isso, filtramos os atributos irrelevantes de acordo com algum critério que podemos escolher e não ficamos mais dependentes do algoritmo de aprendizagem.

A seleção de atributos é um universo amplo da análise e modelagem preditiva.

Fechamento:

E aí, o que você achou do nosso *podcast* de hoje? Fique ligado no próximo assunto e até mais!