



ANÁLISE E MODELAGEM PREDITIVA

Proposta de Resolução

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Proposta de Resolução

Para resolver o desafio, você deverá buscar por estratégias que respondam objetivamente às perguntas feitas. O mais importante neste desafio não é encontrar a resposta correta (a qual você só saberá depois de muitos experimentos ao final do projeto), mas fornecer uma solução inicial sustentável que faça sentido considerando o processo de desenvolvimento de projetos de ciência de dados.

Um norte para a resolução é responder às perguntas:

1. Qual é o objetivo do projeto de ciência de dados?

Para o problema apresentado, você pode escolher um dos seguintes objetivos:

- Identificar os produtos mais rentáveis.
- Identificar os clientes mais propensos a comprar por ofertas enviadas por e-mail.
- Identificar os clientes que mais realizaram compras nos últimos doze meses.

2. Qual é e como foi determinado o atributo-alvo (classe) do problema?

O atributo-alvo do problema será determinado a partir dos dados disponíveis e do objetivo determinado na primeira questão. É importante observar que o atributo-alvo não precisa estar originalmente presente nos conjuntos de dados fornecidos, sendo possível construí-lo a partir de todos dados disponíveis.

3. Quais são as métricas importantes para avaliar a solução?

Independentemente do objetivo escolhido, o problema de modelagem preditiva deverá considerar o problema como uma tarefa de classificação. Portanto, a matriz de confusão será uma grande aliada neste problema, uma vez que, a partir dela, é possível derivar diversas métricas.

4. Quais técnicas de engenharia de atributos você deve utilizar?

Observando os atributos do conjunto de dados inicial, podemos considerar:

- Registro: eliminação do atributo antes da modelagem.
- Tempo de cadastro: padronização ou normalização.
- Cidade: transformação nominal para numérico.



- UF: transformação nominal para numérico.
- Compras realizadas: padronização ou normalização.
- Soma das compras: padronização ou normalização.
- Valor da última compra: padronização ou normalização.

5. Quais algoritmos você escolheria para experimentar inicialmente?

Diferentes algoritmos de aprendizagem podem ser experimentados neste problema. Inicialmente, vale a pena considerar abordagens que trabalhem facilmente com os dados do problema, como árvores de decisão e regressão logística, que são métodos mais simples para representar dados tabulares e compreender a saída do modelo.

6. Que estratégias de otimização você poderia adotar?

Considerando a utilização de dois ou mais algoritmos, vale a pena adotar a busca em grade para a automatização da busca pelos hiperparâmetros ótimos.

7. Qual é a melhor forma de distribuir esse projeto?

Para distribuir esse projeto, devemos pensar no usuário da aplicação ou no tomador de decisão. Nesse caso, podemos elaborar um relatório com os produtos ou clientes identificados, uma planilha com as mesmas informações ou uma implantação na intranet local para consumo das informações em painéis. Independentemente do produto que construiremos, precisamos pensar em quem utilizará.

A implantação deve considerar também como as informações do classificador serão guardadas. Atualmente, consideramos a geração de bases de dados em *data lakes* corporativos com acessos limitados aos tomadores de decisão.





Bons estudos!