



WBA0870_v1.0

Análise e Modelagem Preditiva



Avaliação de Modelos Preditivos

Processo de avaliação e métricas de erro

Bloco 1

Orlando da Silva Junior



➤ Como garantir que meu modelo está construído corretamente?

Figura 1 – Rapaz com dúvida



Fonte: Aaron Amat/iStock.com.


► Como garantir que meu modelo está construído corretamente?

- **Realizar experimentos é necessário!**
 - Não existe uma única técnica capaz de resolver todos os problemas.
 - Métodos de diferentes paradigmas precisam ser experimentados.
 - Diferentes algoritmos podem ser avaliados também.
 - A melhor configuração de hiperparâmetros deve ser encontrada.



➤ Processo de avaliação

Figura 2 – Processo de avaliação de modelos preditivos





Processo de avaliação

- Na **primeira etapa**, os dados históricos são divididos três bases de dados distintas:
 - **Dados de treinamento:** correspondem aos dados que serão fornecidos como entrada para o algoritmo de aprendizagem.
 - **Dados de validação:** realizarão os ajustes no modelo, otimizando o modelo e trazendo melhores resultados. Em geral, são originados dos dados de treinamento.
 - **Dados de teste:** compreender a menor fatia e simulam a apresentação de novos dados nunca apresentados ao preditor.



➤ Por que dividir a base de dados histórica?

- Ao empregar os mesmos dados para treinamento e predição, o desempenho preditivo deverá computar estimativas otimistas para o preditor, já que todos os algoritmos tentam melhorar seu desempenho preditivo durante a fase de treinamento (FACELI *et al.*, 2011)





Métricas de erro

- Precisamos também de uma **medida** para analisar quantitativamente a qualidade do nosso modelo.
- Desejamos analisar o desempenho da função preditora construída pelo algoritmo de aprendizagem.
- Uma **métrica de erro** mostrará quanto a função preditora ficou distante da realidade.
- **Como computar?**
 - As métricas de erro deverão ser computadas sobre o subconjunto dos dados não vistos.



➤ Métricas de erro para classificação

- Podemos usar a **taxa de erro**:

$$erro(\hat{f}) = \frac{\sum_{i=1}^n I(y_i \neq \hat{f}(x_i))}{n}$$

- Ou a **acurácia** (complemento da taxa de erro):

$$acurácia(\hat{f}) = 1 - erro(\hat{f})$$



➤ Métricas de erro para regressão

- Usaremos, principalmente o **erro médio quadrático**:

$$MSE(\hat{f}) = \frac{\sum_{i=1}^n (y_i - \hat{f}(x_i))^2}{n}$$



Avaliação de Modelos Preditivos

Medidas de desempenho para classificação

Bloco 2

Orlando da Silva Junior





Matriz de confusão

- A **matriz de confusão** apresenta a quantidade de predições corretas e incorretas de cada classe.
- Uma matriz de confusão, para um **problema com duas classes**, considera as classes com os termos classe positiva (+) e classe negativa (-) para designar as classes que estão sendo avaliadas.





Matriz de confusão

A matriz é formada por quatro elementos:

- **Verdadeiros Positivos (VP):** quantidade de objetos positivos corretamente classificados como positivos pelo preditor.
- **Falsos Negativos (FN):** quantidade de objetos positivos incorretamente classificados como negativos.
- **Falsos Positivos (FP):** quantidade de objetos negativos incorretamente classificados como positivos.
- **Verdadeiros Negativos (VN):** quantidade de objetos negativos corretamente classificados como negativos pelo preditor.





Matriz de confusão

Figura 3 – Matriz de confusão

		CLASSE PREDITA	
CLASSE VERDADEIRA		CLASSE POSITIVA (+)	CLASSE NEGATIVA (-)
	CLASSE POSITIVA (+)	Verdadeiros Positivos (VP).	Falsos Negativos (FN).
	CLASSE NEGATIVA (-)	Falsos Positivos (FP).	Verdadeiros Negativos (VN).

Fonte: elaborada pelo autor.





Matriz de confusão

Figura 4 – Exemplo de matriz de confusão

28	24
19	29

Fonte: elaborada pelo autor.

A soma de todos os valores da matriz corresponde à quantidade total de objetos avaliados:

$$N = VP + FN + FP + VN$$

No exemplo ao lado:

$$N = 28 + 24 + 19 + 29$$



➤ Medidas de desempenho para classificação

A partir da matriz de confusão, ainda podemos derivar várias novas medidas de desempenho:

- **Taxa de erro na classe positiva:** também conhecida como taxa de falsos negativos (TFN).

$$err_+(\hat{f}) = \frac{FN}{VP + FN}$$

- **Taxa de erro na classe negativa:** também conhecida como taxa de falsos positivos (TFP).

$$err_-(\hat{f}) = \frac{FP}{VN + FP}$$

- **Taxa de erro total:** corresponde à soma da diagonal secundária dividida pela quantidade total de objetos avaliados.

$$err(\hat{f}) = \frac{FP + FN}{N}$$



➤ Medidas de desempenho para classificação

- **Acurácia:** pode ser entendida como um valor que mede o grau de conformidade de um valor obtido com seu valor real.

$$acurácia(\hat{f}) = \frac{VP + VN}{N}$$

- **Precisão:** proporção de objetos positivos preditos corretamente entre todos aqueles preditos como positivos.

$$precisão(\hat{f}) = \frac{VP}{VP + FP}$$



► Medidas de desempenho para classificação

- **Sensibilidade (ou *recall*):** corresponde à taxa de acerto na classe positiva.

$$recall(\hat{f}) = \frac{VP}{VP + FN}$$

- **Especificidade:** corresponde à taxa de acerto na classe negativa.

$$especificidade(\hat{f}) = \frac{VN}{VN + FP}$$



Avaliação de Modelos Preditivos

Técnicas de reamostragem

Bloco 3

Orlando da Silva Junior



➤ Técnicas de reamostragem


- Utilizar o mesmo conjunto de dados para as fases de treinamento e avaliação do preditor pode prejudicar a análise do desempenho do algoritmo, uma vez que podemos produzir estimativas otimistas sobre os resultados.
- Dessa forma, utilizar **técnicas de reamostragem** é uma estratégia importante para a avaliação de modelos preditivos.





Amostragem *holdout*

Figura 5 – *Holdout*




Fonte: elaborada pelo autor.

- **Treinamento:** p .
- **Teste:** $(1 - p)$.
- Fácil de ser implementada.
- Preferível para muitos dados.
- Não usa todos os dados.
- Pode subestimar a taxa de erro.



➤ Amostragem por validação cruzada

Figura 6 – Validação cruzada



Fonte: elaborada pelo autor.

- Partições: k .
- Repetições: k .
- Treinamento: $k - 1$.
- Teste: 1.
- Preferível para poucos dados.
- Usa todos os dados.
- Computacionalmente custoso.
- $k = 10$ é o preferido.



► Demonstração prática

1. Amostragem *holdout*.
2. Amostragem por validação cruzada.



Teoria em Prática

Bloco 4

Orlando da Silva Junior



► Reflita sobre a seguinte situação

Imagine que você foi contratado por um banco para resolver o problema de análise de crédito de uma população local. Naquela localidade, o banco possui 200 mil clientes, sendo que pretende oferecer crédito a pelo menos 60% deles. Após a análise do banco de dados, com as informações dos clientes em potencial, você observou uma quantidade significativa de atributos relevantes para ajudar na solução.

- **Sabendo que os dados estão disponíveis:**
 1. Quais seriam os próximos passos que você daria para resolver esse problema?
 2. Como você determinaria quem são os bons e os maus pagadores, uma vez que o banco nunca forneceu crédito antes de sua chegada à empresa?



► Norte para a resolução...

- Começamos analisando o problema:
 - **População local:** 200 mil.
 - **Clientes potenciais:** 120 mil.
 - **Dados dos clientes:** disponível.
- 1. Os próximos passos são: reunir todos os dados, definir a classe do problema, determinar uma métrica de desempenho, executar reamostragem, aplicar os métodos de classificação e avaliar o desempenho dos modelos.
- 2. Podemos definir a classe do problema observando o comportamento do cliente internamente, por transações realizadas, pagamentos efetuados em dia, cartões de crédito, etc., e também no mercado externo, como *bureaus* de crédito ou informações do Cadastro Positivo (Lei n. 12.414/2011).



Dica do (a) Professor (a)

Bloco 5

Orlando da Silva Junior



► Uma introdução à análise ROC

- Artigo científico de referência.
- Coautor do livro *Data Science para negócios*.
- Definições e conceitos.
- Métricas derivadas, como AUC.
- Aplicações.





Referências

FACELI, K. *et al.* **Inteligência Artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.

FAWCETT, T. An introduction to ROC Analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861-874, 2006.



Bons estudos!

