



WBA0870_v1.0

Análise e Modelagem Preditiva



Aplicações de Análise e Modelagem Preditiva

Introdução ao desenvolvimento de projetos de ciência de dados


Bloco 1

Orlando da Silva Junior



➤ Processo de Ciência de Dados

Figura 1 – Processo de *Data Science*



Fonte: elaborado pelo autor.

Desenvolvendo um projeto de Ciência de Dados com uma **metodologia** em sete etapas:

1. Análise do problema de negócio.
2. Obtenção dos dados.
3. Visualização dos dados.
4. Preparação dos dados para modelagem.
5. Treinamento e avaliação de modelos.
6. Otimização do modelo escolhido.
7. Distribuição.



➤ Processo de Ciência de Dados

1. **Análise do problema do negócio:** nesta etapa, poderemos compreender o problema e o domínio de negócio que queremos resolver.
 - Objetivo do projeto.
 - Tarefa que será realizada.
 - Métodos de aprendizagem de máquina.
 - Métricas para mensuração dos resultados.




➤ Exemplo: análise do problema de negócio

- **Objetivo da aplicação:** identificar a existência de tumores em imagens médicas, com foco no diagnóstico de câncer de mama.
- **Dados disponíveis:** os atributos foram coletados a partir de uma punção aspirativa por agulha fina da massa mamária, que consiste na retirada de uma pequena porção de tecido (biópsia).



➤ Exemplo: análise do problema de negócio

Figura 2 – Representação do núcleo celular (contornos)



Fonte:, Street, Wolberg e Mangasarian (1993).



Exemplo: análise do problema de negócio

Figura 3 – Amostra dos dados para identificação de câncer de mama

	1º obj.	2º obj.	3º obj.	4º obj.	5º obj.
mean radius	17,99	20,57	19,69	11,42	20,29
mean texture	10,38	17,77	21,25	20,38	14,34
mean perimeter	122,8	132,9	130	77,58	135,1
mean area	1001	1326	1203	386,1	1297
mean smoothness	0,118	0,085	0,110	0,143	0,100
mean compactness	0,278	0,079	0,160	0,284	0,133
mean concavity	0,300	0,087	0,197	0,241	0,198
mean concave points	0,147	0,07	0,128	0,105	0,104
mean symmetry	0,242	0,181	0,207	0,26	0,181
mean fractal dimension	0,079	0,057	0,06	0,097	0,059
radius error	1,095	0,544	0,746	0,496	0,757
texture error	0,905	0,734	0,787	1156	0,781
perimeter error	8589	3398	4585	3445	5438
area error	153,4	74,08	94,03	27,23	94,44
smoothness error	0,006	0,005	0,006	0,009	0,011
compactness error	0,049	0,013	0,04	0,075	0,025
concavity error	0,054	0,019	0,038	0,057	0,057
concave points error	0,016	0,013	0,021	0,019	0,019
symmetry error	0,03	0,014	0,023	0,06	0,018
fractal dimension error	0,006	0,004	0,005	0,009	0,005
worst radius	25,38	24,99	23,57	14,91	22,54
worst texture	17,33	23,41	25,53	26,5	16,67
worst perimeter	184,6	158,8	152,5	98,87	152,2
worst area	2019	1956	1709	567,7	1575
worst smoothness	0,162	0,124	0,144	0,21	0,137
worst compactness	0,666	0,187	0,425	0,866	0,205
worst concavity	0,712	0,242	0,45	0,687	0,4
worst concave points	0,265	0,186	0,243	0,258	0,163
worst symmetry	0,46	0,275	0,361	0,664	0,236
worst fractal dimension	0,119	0,089	0,088	0,173	0,077

- As imagens já foram analisadas e um **conjunto de dados** foi gerado a partir das características encontradas:
- 30 atributos de entrada numéricos.
- Um atributo de saída (tumor maligno ou benigno).



Fonte: elaborada pelo autor.

➤ Exemplo: análise do problema de negócio

- **Sua missão:** criar um modelo de decisão que observe as características das imagens e informe se a imagem analisada apresenta um tumor benigno ou maligno.

A etapa de análise do problema de negócio deve fazer com que você identifique elementos-chave do problema, como o objetivo da aplicação, os dados disponíveis e sua missão no projeto.



Processo de Ciência de Dados

2. **Obtenção dos dados:** aqui, importaremos as bibliotecas necessárias no ambiente de programação e carregar os dados disponíveis em memória para fins experimentais.
3. **Visualização dos dados:** após o carregamento dos dados, vale a pena explorarmos sua configuração inicial a partir de gráficos e diagramas.



Processo de Ciência de Dados

4. **Preparação dos dados para modelagem:** nesta etapa, processaremos as linhas e colunas do conjunto de dados estruturado, usando as técnicas de engenharia de atributos.
5. **Treinamento e avaliação de modelos:** com os dados pré-processados e prontos para treinamento, aplicaremos os algoritmos selecionados, buscando pelo modelo mais adequado ao problema em análise.



➤ Processo de Ciência de Dados

6. **Otimização do modelo escolhido:** nesta etapa, trabalharemos com o algoritmo que apresentou o melhor resultado na etapa anterior.
 - Estratégias de otimização.
 - Ajuste de hiperparâmetros.
7. **Distribuição:** destinada à implantação do modelo construído no formato esperado pelo tomador de decisão, como um relatório, um conjunto de planilhas ou uma aplicação *mobile*.



Aplicações de Análise e Modelagem Preditiva

Desafios de análise e modelagem preditiva

Bloco 2

Orlando da Silva Junior





Principais desafios

- **Aprendizagem de dados não-estruturados, como textos.**
- Atributos irrelevantes ou pouco significativos.
- Baixa quantidade de dados.
- **Desbalanceamento de classes.**
- Fluxos de dados (*streaming*).
- **Identificação de anomalias.**
- Maldição da dimensionalidade.
- *Overfitting/ underfitting.*



➤ Preparação de dados textuais

- A maior parte dos problemas de *Analytics* trabalha com dados estruturados.
- *Big Data* está fazendo com que as empresas utilizem mais dados não estruturados, como textos, áudio e imagens.
- Para trabalhar com bases de dados textuais, precisamos de técnicas específicas para o processamento dos textos, a fim de compreender melhor a linguagem.



➤ Preparação de dados textuais

- ***Corpora***: conjuntos de dados textuais.
- ***Corpus***: apenas um conjunto de dados de textos.
- Em um *corpus*, cada objeto é tratado como um **documento**, que pode ter diferentes características:
 - Tamanho do texto (sequência de caracteres).
 - Tipo de conteúdo (assunto).
 - Idioma (inglês, português, japonês etc.).
 - Tipo de linguagem (formal, poética, irônica etc.).



➤ Preparação de dados textuais

- ***Bag of words***: técnica para representação de documentos.
 - Construção de listas de ocorrências.
 - Formação de um dicionário de palavras.
 - Desconsidera a estrutura gramatical.
- Na modelagem preditiva, a ocorrência de cada palavra do texto é usada como um atributo para treinamento de um classificador.





Detecção de anomalias

- A detecção de anomalias (***outliers***) é uma tarefa muito requisitada em projetos de Ciência de Dados.
 - Tem sido usada para detectar objetos anômalos da base de dados e, quando possível, executar alguma ação sobre eles.
- **Não podemos ignorar** a importância de detectar as anomalias na base de dados.
 - Apenas uma fraude, entre milhares de transações de cartão de crédito, ainda pode ser prejudicial.





Detecção de anomalias

- **O que é uma anomalia?**
 - Valor discrepante no conjunto de dados.
 - Valor que se localiza significativamente distante dos valores considerados normais.
- O objeto que apresenta esse valor discrepante parece desviar fortemente de outros membros da amostra à qual pertence.
 - Objeto inconsistente com o restante da base de dados.
- As anomalias são padrões que não estão de acordo com uma noção bem definida de comportamento normal.



► Detecção de anomalias

- Para detectar anomalias:
 1. Definir o que é a anomalia a ser encontrada.
 2. Considerar o problema como sendo de **classificação binária** (existindo rótulos).
 3. Aplicar o processo de Ciência de Dados.
 4. Avaliar o modelo com métricas importantes para área, como:
 - Acurácia.
 - Sensibilidade (taxa de detecção).
 - Taxa de falsos positivos.



➤ Desbalanceamento de classes

Figura 4 – Cibercriminoso fraudando cartão de crédito



Fonte: Diy13/ iStock.com.

➤ Desbalanceamento de classes

- As fraudes que acontecem em cartões de crédito são eventos raros frente às milhões de transações diárias em um sistema de meio de pagamentos.
- Se a quantidade de transações rejeitadas fosse proporcional à quantidade de transações aceitas, certamente o pagamento por cartão de crédito seria proibido e muitas pessoas deixaram de confiar nessa forma de pagamento.



➤ Desbalanceamento de classes

- Caso o desbalanceamento de classes não seja tratado, os algoritmos poderão favorecer a classificação de novos dados na classe majoritária.
- No caso do cartão de crédito, novas transações serão classificadas como transações comuns, ainda que sejam fraudes verdadeiras.



Aplicações de Análise e Modelagem Preditiva

Preparação de dados textuais

Bloco 3

Orlando da Silva Junior



➤ Preparação de dados textuais

Figura 5 – Processo para preparação de dados textuais



Fonte: elaborada pelo autor.



Demonstração prática

1. **Análise lexical:** geração de *tokens*, removendo pontuações e outros caracteres desnecessários.
2. **Eliminação de termos irrelevantes:** remoção de artigos, preposições, pronomes etc.
3. **Redução do termo ao radical:** identificação de radicais.
 - *Ambiente e ambientação* devem ser consideradas como uma mesma palavra.
4. **Representação:** mapeamento das relações entre termos, documentos e corpus para dados numéricos.



Teoria em Prática

Bloco 4

Orlando da Silva Junior



➤ Reflita sobre a seguinte situação

- Os funcionários da empresa onde você trabalha estão recebendo muitos e-mails não solicitados, sendo alguns indevidos. Como a empresa passou por uma recente reestruturação, o servidor ainda não possui um detector de *spam* e o diretor da empresa solicitou que você construa, do zero, um sistema que elimine as mensagens antes que as caixas de e-mail fiquem lotadas.
- Em apenas uma semana, os cinquenta funcionários receberam 1252 mensagens indevidas. Você tem quinze dias para construir e implantar o sistema. **Qual seria sua estratégia?**



► Norte para a resolução...

O prazo para desenvolvimento e implantação é muito apertado. Por isso, é preciso elaborar uma estratégia que seja eficaz e traga resultados acurados rapidamente.

- **Uma sugestão é aplicar as seguintes etapas:**
 1. Recuperar todos os 1252 e-mails indevidos e rotulá-los como *spam*.
 2. Selecionar outros 1252 e-mails comuns, dos cinquenta funcionários, e rotulá-los como *não spam*.
 3. Preparar os dados textuais, pré-processando os objetos.
 4. Aplicar, por exemplo, o algoritmo *naïve Bayes* para construir um classificador.
 5. Implantar o classificador no servidor de e-mails, buscando aplicar a função assim que um novo e-mail chegar.



Dica do (a) Professor (a)

Bloco 5

Orlando da Silva Junior



➤ Construa um *pipeline*

- O *scikit-learn* utiliza a noção de *pipeline*.
- Montagem de várias etapas que podem ser validadas juntas, enquanto são definidos diferentes parâmetros.
- O *pipeline* aplica, sequencialmente, uma lista de transformações e um estimador final.
- *from sklearn.pipeline import Pipeline.*





Referências

STREET, W. N.; WOLBERG, W. H.; MANGASARIAN, O. L. Nuclear feature extraction for breast tumor diagnosis. *In: **Biomedical image processing and biomedical visualization***, p. 861-870. International Society for Optics and Photonics, [s.l.], 1993.



Bons estudos!

