

Podcast

Disciplina: Análise e Modelagem Preditiva

Título do tema: Otimização de Modelos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Abertura:

Olá, tudo bem? Aqui é o professor Orlando Junior e, no podcast de hoje, vamos falar sobre otimização de modelos preditivos. Fique ligado e acompanhe o nosso podcast!

Entre os muitos temas da otimização de modelos que você já deve ter estudado, queremos discutir hoje sobre as técnicas de regularização.

Você já sabe que, quando um modelo não generaliza bem, tem um fenômeno acontecendo com ele chamado *overfitting*.

O *overfitting* acontece quando o modelo aprende tudo sobre os dados de treinamento, não dando nenhuma margem ao aprendizado de novos dados. Em geral, modelos que apresentam 100% de acurácia sofrem de *overfitting*.

Esse problema não é muito bom para os nossos modelos preditivos porque parece que o algoritmo está “decorando” os dados, e não aprendendo-os de fato, que é o propósito do treinamento na aprendizagem de máquina.

Agora... quais são as suas causas? O que faz com que um modelo sofra de *overfitting*?

Entre as principais, podemos apontar:

- Poucos dados para treinamento do modelo;
- Aplicação de algoritmos mais complexos que o necessário para resolver o problema;
- Ruído nos dados, como valores extremos, incorretos, ausentes, etc.;

Essas são as principais causas, embora possam ter outras.

Caso você tenha visto tudo isso em primeiro lugar e ainda não identificou, uma ideia que pode ajudar você é plotar um gráfico comparando o desempenho do preditor nos conjuntos de treinamento e teste. Ou seja, você vai aplicar o preditor construído nos dados de treinamento e também nos dados de teste. E nesse gráfico você vai observar a variância entre os modelos. Assim, se ela for muito alta, seu modelo não está generalizando bem e está sofrendo de *overfitting*.

E aí você me pergunta: tá bom, professor Orlando, e onde a regularização entra nisso tudo?

Aí é que está: alguns algoritmos de aprendizagem de máquina usam técnicas de regularização para evitar que o *overfitting* aconteça.

Nem sempre teremos uma mesma técnica para todo problema e todo algoritmo. Por isso, é importante sempre experimentar e ver como os diferentes modelos construídos se comportam com os dados.

Por exemplo, em uma árvore de decisão você poderá utilizar um tipo de regularização que só se encaixa em modelos de árvores, que é a poda. Quando você poda uma árvore, você está diminuindo o tamanho dela, deixando-a menos complexa e menos “hiper especializada”, ou seja, diminuindo o *overfitting*.

Existem várias outras técnicas de regularização que você poderá conhecer e estudar, como:

- Regularização L1 e L2, para algoritmos que penalizam funções de custo;
- Dropout, um tipo de camada para redes neurais; e
- *Early stopping*, para métodos estatísticos.

Fechamento:

E aí, o que você achou do nosso *podcast* de hoje? Fique ligado no próximo assunto e até mais!