

Pós-Graduação

Análise Multivariada e Modelos de Regressão

Tema 07 – Definições em regressão

Bloco 1

Professor Dr. Fábio Santiago



Análise de resíduos

Regressão linear simples e Regressão linear múltipla → resultados confiáveis?

- Análise dos resíduos: técnicas usadas para investigar a adequabilidade de um modelo de regressão >> uso de resíduos.
- Resíduo: diferença entre variável resposta observada e variável resposta estimada.

Análise de resíduos

Modelo apropriado:

- Resíduos são independentes;
- Variância dos resíduos = constante;
- Resíduos: normalidade;
- Ausência de outliers.

Análise de resíduos

Técnicas para verificação:

- Informais (gráficos) → subjetivas

>> Gráfico dos resíduos versus valores ajustados; gráfico dos resíduos studentizados versus valores ajustados; gráfico dos resíduos padronizados versus valores ajustados...

Análise de resíduos

- Formais (testes) → mais indicadas

>> Teste de normalidade; teste de Durbin-Watson; teste de Breusch-Pagan e Goldfeld-Quandt...

Análise de resíduos

Homocedasticidade:

“Variância constante dos erros para observações distintas”

Teste de hipótese:

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 \\ H_1 : \text{pelo menos um dos } \sigma_i^2 \text{ diferente, } i = 1, \dots, k \end{cases}$$



Análise de resíduos

Gráfico de Resíduos versus Valores Ajustados:


- Verificará a presença de heteroscedasticidade;
- Existência de relação linear entre as variáveis explicativas com a resposta: tendência dos pontos.



Análise de resíduos

→ Pontos aleatoriamente distribuídos em torno do zero, sem comportamento tendencioso: **VARIÂNCIA HOMOSCEDÁSTICA.**

Análise de resíduos



Fonte: Carreira et al., 2009.

Disponível em: <https://goo.gl/cD8bjz>. Acesso em: 08 out. 2017.

Análise de resíduos

Exemplo de aplicação do teste de homoscedasticidade **Breusch-Pagan**:

- Testa $\underline{H}_0 \rightarrow$ variâncias dos erros são iguais;
- $\underline{H}_1$: variâncias dos erros são uma função multiplicativa de uma ou mais variáveis (heteroscedasticidade);
- Indicado para grandes amostras;
- Suposição de normalidade nos erros.

Análise de resíduos: Breusch-Pagan

1. Ajusta-se o modelo de regressão linear (1 ou + variáveis independentes);
2. Calcula-se os valores ajustados;
3. Determina-se os resíduos ($\mathbf{e}_i$);
4. Calculamos os resíduos ao quadrado ($\mathbf{e}^2_i$);
5. Padronizamos os resíduos ($\mathbf{w}_i$) por:

$$w_i = \frac{e_i^2}{SQE/k}, \text{ com } i = 1, \dots, k \longrightarrow SQE = \sum_{i=1}^k e_i^2$$

Análise de resíduos: Breusch-Pagan

6. Regressão de $\mathbf{w}_i$ com valores ajustados;
7. Cálculo de Soma de Quadrados da Regressão, SQR (w com valores estimados);
8. Estatística de Qui-quadrado com $SQR/2$ e 1 grau de liberdade.

Análise de resíduos: Durbin-Watson

- Usado para: verificar a dependência nos resíduos

$$dv = \frac{\sum_{i=2}^k (e_i - e_{i-1})^2}{\sum_{i=1}^k (e_i)^2}$$

Análise de resíduos: Durbin-Watson

	Nível de significância	Número de variáveis explicativas									
		1		2		3		4		5	
n		d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U	d_L	d_U
	0,01	0,81	1,07	0,7	1,25	0,59	1,46	0,49	1,7	0,39	1,96
15	0,025	0,95	1,23	0,83	1,4	0,71	1,61	0,59	1,84	0,48	2,09
	0,05	1,08	1,36	0,95	1,54	0,82	1,75	0,69	1,97	0,56	2,21
	0,01	0,95	1,15	0,86	1,27	0,77	1,41	0,63	1,57	0,6	1,74
20	0,025	1,08	1,28	0,99	1,41	0,89	1,55	0,79	1,7	0,7	1,87
	0,05	1,2	1,41	1,1	1,54	1	1,68	0,9	1,83	0,79	1,99
	0,01	1,05	1,21	0,98	1,3	0,9	1,41	0,83	1,52	0,75	1,65

Análise de resíduos: Durbin-Watson

se $0 \leq dv < dL$ (dependência);

se $dL \leq dv \leq dU$ (inconclusivo);

se $dU < dv < 4-dU$ (independência);

se $4-dU \leq dv \leq 4-dL$ (inconclusivo);

se $4-dL < dv \leq 4$ (dependência).

Pós-Graduação

Análise Multivariada e Modelos de Regressão

Tema 07 – Definições em regressão

Bloco 2

Professor Dr. Fábio Santiago



Análise de falta de ajuste: MRLM

- Extensão do modelo de regressão linear simples.
- As hipóteses válidas são:
 - >> Distribuição normal dos resíduos;
 - >> Homocedasticidade;
 - >> Ausência de autocorrelação;
 - >> Linearidade nos parâmetros;
 - >> Ausência de multicolinearidade.



Análise de falta de ajuste: MRLM

Análise de Colinearidade e Multicolinearidade

Informalmente: a ausência de colinearidade diz que nenhum dos regressores pode ser escrito como uma combinação linear exata dos demais regressores do modelo.



Análise de falta de ajuste: MRLM

Análise de Colinearidade e Multicolinearidade

1. Qual a natureza da multicolinearidade?
2. A multicolinearidade é um problema?
3. Quais são suas consequências?
4. Como a detectamos?



A natureza da multicolinearidade

- O termo multicolinearidade deve-se a Ragnar Frisch.
- Significava a existência de uma relação linear “perfeita” ou exata entre algumas ou todas as variáveis explanatórias do modelo de regressão.

A natureza da multicolinearidade

Regressão com k variáveis, $X_1, X_2, \dots, X_k$:

- Existe uma relação linear exata se a seguinte condição for satisfeita:

$$\lambda_1 \cdot X_1 + \lambda_2 \cdot X_2 + \dots + \lambda_k \cdot X_k = 0$$

$\lambda_1, \lambda_2, \dots, \lambda_k$: constantes nem todas simultaneamente iguais a zero.



A natureza da multicolinearidade


- O termo multicolinearidade tem sido empregado em um sentido amplo.
- Pretende-se incluir o caso de multicolinearidade perfeita, assim como o caso em que as variáveis X estão inter-relacionadas, mas não perfeitamente.

A natureza da multicolinearidade


$$\lambda_1 \cdot X1 + \lambda_2 \cdot X2 + \cdots \lambda_k \cdot Xk + v_i = 0$$

Onde v_i é o termo estocástico.

Diagrama de Ballentine




Ausência de
colinearidade




Baixa
colinearidade

Diagrama de Ballentine



Alta
colinearidade



Muito alta
colinearidade



Fontes de multicolinearidades

Multicolinearidade pode ocorrer devido a:

- Método de coleta de dados empregado.
- Restrições ao modelo ou à população que está sendo amostrada.



Fontes de multicolinearidades

- Especificação do modelo.
- Um modelo sobredeterminado.
- Nos dados de séries temporais, pode ser que os regressores incluídos no modelo tenham uma tendência comum: todos aumentam ou diminuem ao longo do tempo.

Detecção da multicolinearidade

- Não existe um método para detectá-la ou para mensurar sua força.
- Temos regras práticas: informais e outras formais.
- R^2 alto, mas poucas razões t significativa.
- Altas correlações entre pares de regressores.
- Exame de correlações parciais.
- Tolerância e fator de inflação da variância.

Medidas corretivas

- Uma informação a priori.
- Combinação de dados de corte transversal e de séries temporais.
- Exclusão de variável(is) e viés de especificação.
- Transformação de variáveis.
- Dados adicionais ou novos.

Ajuste sobre variável qualitativa

Analizamos até então: Regressão sobre variáveis independentes (1 ou mais)
quantitativa contínua. Ex.: Gasto em supermercado em função do processo de produtos alimentícios, eletrodoméstico, produtos de limpeza.



Ajuste sobre variável qualitativa

Se tivermos um estudo com variável **independente qualitativa**, como por exemplo sexo, grau de escolaridade, atividade de uma empresa, região?

Ajuste sobre variável qualitativa

Uso de variáveis categóricas no modelo:

Variáveis dummies // nominais // binárias
// indicadoras

>> Variável qualitativa binária: assume apenas duas possíveis categorias → **sexo:** masculino ou feminino → $x=0$ (M) ou $x=1$ (F)

Ajuste sobre variável qualitativa

- Exemplo para a incorporação de variável dummy, ou seja, informações binárias, em modelos de regressão.
- Adicionaremos uma variável à equação como uma variável independente qualquer.

Ajuste sobre variável qualitativa

- Supondo que o estudo seja: definição da hora de trabalho em função do sexo e dos anos de estudo.
- Variáveis: anos de estudo (quantitativa) e sexo (qualitativa dummy).

Ajuste sobre variável qualitativa

$$\text{Salário} = \beta_0 + \alpha, \text{feminino} + \beta_1 \text{educação}$$

- Realizo os procedimentos já adotados

$$\text{Salário} = 1 + 2,5\text{masculino} + 7\text{educação}$$

Em média, o salário é maior em 2,5 para o sexo masculino em relação ao feminino para um mesmo nível de educação.

Exemplo: Regressão com var. dummy

y	x2	x3	atributo
800	2	0,8	sim
1160	4	0,7	sim
1580	6	0,5	sim
2010	8	0,4	sim
1890	7	0,2	sim
2600	12	0,2	sim
2070	11	0,8	não
1890	10	0,7	não
1830	9	0,6	não
1740	8	0,1	não
1380	6	0,5	não
1060	4	0,4	não

Exemplo: Regressão com var. dummy

y	x2	x3	atributo
800	2	0,8	1
1160	4	0,7	1
1580	6	0,5	1
2010	8	0,4	1
1890	7	0,2	1
2600	12	0,2	1
2070	11	0,8	0
1890	10	0,7	0
1830	9	0,6	0
1740	8	0,1	0
1380	6	0,5	0
1060	4	0,4	0

Exemplo: Regressão com var. dummy

Excel: Análise de dados (Suplementos)

	<i>Coeficientes</i>
Interseção	536,09285
x2	161,86571
x3	-327,77786
atributo	238,07634

Exemplo: Regressão com var. dummy


Excel: Análise de dados (Suplementos)

<i>valor-P</i>	<i>95% inferiores</i>	<i>95% superiores</i>
3E-05	387,7100	684,4757
2E-09	149,5540	174,1774
0,001	-478,7667	-176,7890
5E-05	168,2890	307,8637

$R^2_{\text{ajustado}}=0,99007$

Exemplo: Regressão com var. dummy

Gráfico dos resíduos:



Fonte: O autor.

