



# BI: A inteligência de negócios

Michel Bernardo Fernandes da Silva

**Presidente** Rodrigo Galindo

**Vice-Presidente de Pós-Graduação  
e Educação Continuada**

Paulo de Tarso Pires de Moraes

Carlos Roberto Pagani Junior  
Camila Braga de Oliveira Higa  
Carolina Yaly

**Conselho Acadêmico** Danielle Leite de Lemos Oliveira  
Juliana Caramigo Gennarini  
Mariana Ricken Barbosa  
Priscila Pereira Silva

**Coordenador** Mariana Ricken Barbosa

**Revisor** Fábio Ferreira Cardoso

Alessandra Cristina Fahl  
Daniella Fernandes Haruze Manta  
Flávia Mello Magrini  
**Editorial** Leonardo Ramos de Oliveira Campanini  
Mariana de Campos Barroso  
Paola Andressa Machado Leal

Dados Internacionais de Catalogação na Publicação (CIP)

---

S586b Silva, Michel Bernardo Fernandes da  
BI : a inteligência dos negócios / Michel Bernardo  
Fernandes da Silva. – Londrina: Editora e Distribuidora  
Educacional S.A., 2018.  
107 p.

ISBN 978-85-522-0646-0

1. Inteligência Competitiva. 2. Negócios. I. Silva, Michel  
Bernardo Fernandes da. II. Título.

CDD 330

---

Responsável pela ficha catalográfica: Thamiris Mantovani CRB: 8/9491

# SUMÁRIO

|                                                              |     |
|--------------------------------------------------------------|-----|
| Tema 1: Introdução ao BI.....                                | 6   |
| Tema 2: Data <i>warehouse</i> .....                          | 17  |
| Tema 3: Mineração de dados e inteligência artificial.....    | 33  |
| Tema 4: Modelos descritivos.....                             | 45  |
| Tema 5: Modelos preditivos.....                              | 58  |
| TEMA 6: Análise de negócios e visualização de dados I .....  | 73  |
| Tema 7: Análise de negócios e visualização de dados II ..... | 88  |
| Tema 8: Business performance management (BPM) .....          | 100 |

# APRESENTAÇÃO DA DISCIPLINA

As empresas de todas as áreas de atuação constantemente tomam decisões sobre suas operações, tanto em níveis estratégicos, como na entrada de um novo mercado, quanto em níveis gerenciais, na mudança de um dos processos produtivos, ou mesmo em níveis operacionais: como atender a reclamação de um cliente.

O ambiente no qual as empresas operam está se alterando cada vez mais rápido. Tal fato pressiona as empresas a decidirem em tempos cada vez mais curtos. Para serem mais assertivas em suas decisões, é fundamental que as pessoas responsáveis pelas decisões tenham disponíveis informações necessárias para um melhor embasamento de seu parecer.

Um nível de acerto maior nas decisões representa um importante diferencial competitivo para as empresas. Para prover as melhores e mais atualizadas informações e também projeções futuras, são construídos sistemas computadorizados de inteligência de negócios ou Business Intelligence (BI).

Tais sistemas são capazes de prover informações armazenadas e, adicionalmente, podem elaborar análises nos dados. O conceito de Business Intelligence engloba arquiteturas, ferramentas, bancos de dados, aplicações e metodologias. Um elemento frequentemente utilizado por ferramentas BI é o *Data Warehouse*, bancos de dados ou “armazéns de dados” que contemplam dados e informações de toda a empresa. Posteriormente, foram desenvolvidos Modelos Descritivos, focados na caracterização dos dados observados com base em modelos de agrupamento que separam os dados em clusters e algoritmos de redes neurais. Foi necessário criar interfaces mais amigáveis para visualização dos dados, os Dashboards. Em alguns casos, não

bastava somente os dados passados, era necessário projetar o futuro, como em um orçamento.

Assim, foram desenvolvidos Modelos Preditivos, que podem incluir métodos probabilísticos, métodos baseados em distância, como regressões, e métodos baseados em procuras, como árvores de decisão. Outras ferramentas desenvolvidas são *Business Performance Management* – BPM e Mineração dos Dados. Um assunto bastante relevante nas pesquisas e muito promissor para o futuro é a utilização de Inteligência Artificial, em que um computador aprende com base em situações passadas, desenvolvendo um tipo de inteligência que é aplicada para que o agente escolha a melhor ação possível para uma determinada situação (RUSSEL; NORVIG, 1995).

Nesta disciplina, são abordados temas relevantes de BI, desde os conceitos de um sistema de BI, os detalhes de seus elementos, a interligação entre os elementos, os principais métodos desenvolvidos para modelos descritivos e preditivos, bem como as formas de apresentação de resultados.

Bons estudos!

A hand is shown pointing at a tablet screen. The image is overlaid with a large, bold black number '1'. The background features geometric shapes in shades of blue and a light blue gradient.

**1**

# **Introdução ao BI**



## Objetivos Específicos

- Analisar como a alteração do ambiente de negócios implicou na criação de sistema de BI (*Business Intelligence*).
- Apresentar os conceitos dos sistemas de inteligência de negócios ou BI.
- Entender as questões principais ao implementar o *Business Intelligence*.

## Introdução

Desde o fim da década de 90, o ambiente de negócios se modificou radicalmente, com efeito da globalização, da revolução da tecnologia de informação e comunicação, entre outros (LAUDON; LAUDON, 2011). Com isso, houve um maior nível de competição para a empresa e ela teve de tomar decisões mais rapidamente. Para isso e para ter uma maior assertividade nas decisões retirando subjetividade, é necessário um sistema computadorizado de apoio à decisão.

Neste contexto, surgiram sistemas computadorizados de apoio à decisão que ficaram conhecidos como *Business Intelligence* (BI) ou Inteligência de Negócios. BI contempla uma série de ferramentas, bancos de dados, interfaces para o usuário e monitores de desempenho para acompanhamento de resultados, seja de uma área ou da empresa como um todo. Para cada componente, existem diversas opções disponíveis no mercado de software.

Adicionalmente, serão analisados quais os benefícios gerados pelos BI. Um dos benefícios principais é a transformação de dados em informação, assim como a transformação de informação em conhecimento. Tal fato irá auxiliar a empresa na tomada de decisões mais assertiva, que é considerada como uma vantagem competitiva em função das decisões mais rápidas, também pode ocorrer reduções de custo relacionadas aos processos.

Para uma correta implementação de sistemas de BI, devem ser avaliadas as condições necessárias para propiciar esse fato, pois a implantação de BI costuma ser lenta e custosa (CECI, 2012). Deve ser realizado, ainda, o mapeamento de todas as dificuldades de implementação e elaborar um plano de ação.

# 1. Ambiente de negócios, BI e seus componentes

O termo *Business Intelligence* (BI) ou inteligência de negócios foi patenteado por Gartner Group em meados da década de 1990. Entretanto, já existiam sistemas computadorizados desde os anos 1970, que ainda não possuíam opções de análise e tinham baixa capacidade de customização. Tais sistemas foram chamados de Decision Support Systems (DSS) ou Sistemas de Suporte à Decisão.

Na década de 1980, surgiu o conceito de Executive Information Systems (EIS) ou Sistemas de Informações Executivas que simplificavam o uso dos DSS e traziam informações estratégicas para os analistas e executivos. Existia, no entanto, a limitação a alguma tela e relatórios. Posteriormente, na década de 1990, surgiram soluções por meio das quais era possível inserir análises, tendências e gerar relatórios dinâmicos e inclusive produtos comerciais com essas características.


Com a globalização e com as facilidades de transporte internacional de carga, as empresas puderam entrar em novos mercados internacionais e comprar de fornecedores internacionais (TURBAN *et al.*, 2009). Contudo, por outro lado, diversos concorrentes de outros países surgiram em seu mercado nacional. Tal fato aumentou o nível de concorrência em diversos mercados e, com isso, muitas empresas foram compradas ou encerraram suas operações (OLIVEIRA, 2010).

Além disso, a evolução da Tecnologia da Informação e Comunicação (TIC), possibilitou tanto mudanças na empresa quanto no público consumidor. Antes da proliferação da Internet e de mídias sociais, os consumidores tinham um pequeno poder frente às empresas (CARVALHO, 2015). Com essas ferramentas, o consumidor irá pesquisar as informações do produto antes de comprar, comparar com concorrentes e ler opiniões de usuários do produto. Caso compre o produto e não esteja satisfeito, certamente irá utilizar suas mídias sociais para reclamar desse fornecedor. Com isso, há significativo aumento das demandas do consumidor que desejam produtos, bem como uma ampla gama de produtos que podem, ainda, ser customizados, ter qualidade excelente e entrega o mais breve possível. Além de deterem mais poder na relação com as empresas, os consumidores estão menos fiéis, podendo facilmente trocar a empresa por concorrentes (OLIVEIRA, 2010).



Considerando o cenário ilustrado na Figura 1, a seguir, e com base nas análises, informações e previsões que normalmente são obtidas por meio de sistemas computadorizados de suporte para decisão, a empresa terá uma reação frente ao mercado.

**FIGURA 1: RELAÇÃO ENTRE AS DECISÕES COM SUPORTE COMPUTADORIZADO, REAÇÕES DA ORGANIZAÇÃO E FATORES DO AMBIENTE**




**FONTE:** Turban et al. (2009, p. 24).

Para análise do ambiente de negócios, é importante o conhecimento da Matriz de Oportunidade, Ameaças, Forças e Fraquezas.

# 1.1 Definição de BI

Segundo Silva (2011, p.32), *Business Intelligence* (BI) ou inteligência de negócios pode ser definida como a transformação metódicos dos dados oriundos de quaisquer fontes de dados, sejam eles estruturados e não estruturados, em novas formas de propiciar informação e conhecimento dirigido aos negócios e orientado aos resultados.

Segundo Laudon e Laudon (2011), um sistema de informação pode ser definido tecnicamente como um conjunto de componentes que são coletados, processados, armazenados e distribuem informação para auxiliar no processo decisório e no controle da organização.



## Para saber mais

A análise SWOT é um dos métodos mais tradicionais para definir a estratégia de um negócio. Essa técnica permite revelar os pontos fortes e fracos da empresa, e as oportunidades e ameaças do mercado.



## Assimile

BI pode ser considerado como uma estrutura que contempla arquiteturas, ferramentas, bancos de dados, metodologia e aplicações. Assim, BI é considerado um termo “guarda-chuva”, pois embaixo dele estão diversas outras expressões como Competitive Intelligence ou Inteligência Competitiva, Market Intelligence ou Inteligência de Mercado, Customer Intelligence ou Inteligência do Consumidor.

# 1.2 Arquitetura e componentes de BI


Sistemas de BI podem ser divididos em quatro componentes principais: um *data warehouse* (DW) com seus dados-fonte, a análise de negócios, uma coleção de ferramentas para manipular e analisar os dados no *data warehouse*, inclui-se ainda o *data mining* e business performance management (BPM), para monitoria e análise do desempenho e uma interface de usuário, por exemplo: o dashboard. Já existem ferramentas de inteligência artificial que estão dentro do escopo de BI.

O *Data Warehouse* é um banco de dados ou repositório de dados especialmente preparado para dar suporte a aplicações de tomada de decisão. Para a análise de negócios dos *data warehouse*, existem ferramentas que realizam consultas e relatórios customizados. Adicionalmente, o processamento analítico online (OLAP) é uma das formas de modelagem do *Data Warehouse*.

Em um *data mining*, há o processo de identificação de padrões úteis, previamente desconhecidos de bases de dados que permitem a construção de modelos. Os modelos podem ser preditivos como Classificação, Regressão, baseados em probabilidades e Árvores de Decisão, ou podem ser modelos descritivos como análise de *clusters* e regras de associação.


O BPM se baseia na reengenharia de processos que são necessários para que a empresa obtenha um aumento na produtividade. Por sua vez, Dashboards propiciam uma demonstração visual de diversos indicadores de desempenho e suas tendências.

Nas próximas unidades, será abordado cada componente de sistemas de BI.



#### Para saber mais

O objetivo da Inteligência Artificial (IA) é o desenvolvimento de sistemas que realizem tarefas que, no momento, são melhor realizadas por seres humanos do que por máquinas, ou não possuem uma solução de algoritmo que seja implementável e viável pela computação tradicional (RUSSEL; NORVIR, 1995).



#### Para saber mais

Um exemplo de ferramenta de BI é Power BI da Microsoft, em que o usuário transforma dados em dashboards em diferentes plataformas, como computador, notebook e celular.

## 1.3 Benefícios do BI

Pode-se definir Dado como uma representação de atributos que podem representar transações e operações de um determinado produto (CECI, 2012). Por sua vez, informação é um conjunto de dados que cria um padrão e apresenta um significado. Para Fialho *et al.* (2006), pode-se definir conhecimento como um conjunto completo de informações, dados e relações que auxiliam os indivíduos na tomada de decisão, na realização de tarefas e na geração de novas informações e conhecimentos.

Com adoção de técnicas de BI, além de ser capaz de transformar dados brutos em informação e, também, informação em conhecimento, existe uma maior agilidade na elaboração das informações, automação dos processos de informação, possibilidade de análise de indicadores de gestão e menor tempo para disponibilizar informações, resultando em uma maior capacidade de análise.



## 1.4 Implantação de sistemas de BI

A implantação de uma iniciativa de BI não é uma atividade simples, rápida, nem de baixo custo. E caso não seja considerada uma série de demandas, a implementação pode resultar em falha (TURBAN, 2009). Um ponto fundamental para investimento em BI é o alinhamento com a estratégia de negócios da empresa. O BI deve ser utilizado para melhoria dos processos da empresa (GARTNER, 2004).

Uma das primeiras etapas do processo de implementação de BI é avaliar a organização do sistema de informação, os conjuntos de habilidades das possíveis classes de usuários e se a cultura da empresa é receptiva a mudanças. Baseando-se nessa avaliação inicial e existindo justificativa e necessidade para implantar o BI, a empresa pode preparar um plano de ação detalhado. Isso deve ocorrer devido ao fato que um sistema de BI pode possuir três dimensões: a primeira dimensão é a tecnológica; a segunda dimensão é organizacional, na qual estão os processos de negócio, a cultura, a estrutura e as pessoas; por fim, a terceira dimensão é a gerencial, para a resolução de conflitos.

A comunidade de usuários de BI dentro de uma mesma organização pode ser de diferentes áreas e de diferente nível de conhecimento, acerca das ferramentas, e nível hierárquico (LAUDON, 2011). Um fator que dificulta a implantação é o tamanho e diversidade da comunidade de usuários, pois o sucesso do BI será maior quanto mais usuários estiverem utilizando as informações vindas dele.

Atualmente, muitas empresas fornecedoras de *software* disponibilizam ferramentas diversificadas, algumas delas são totalmente pré-programadas (chamadas *shells*).

### Exemplificando

No final dos anos 1990, nos EUA, a Toyota estava com problemas na cadeia de fornecimentos. Além disso, os custos de logística, para armazenar os carros, aumentaram muito. Foi instalado um sistema de BI com data warehouse e dashboard. Rapidamente, depois da instalação, o sistema detectou um erro de US\$ 800.000 e possibilitou o aumento do volume de veículos sem praticamente não aumentar o número de funcionários. Desse modo, soluções de BI foram aplicadas em diversas áreas da Toyota USA e de outras fábricas pelo mundo.

Fonte: adaptado de Cio Insight (2004) e Turban et al. (2009).

## Questão para reflexão

Como foi visto, a implementação de sistema de BI não é uma tarefa simples e sistemas de BI possuem três dimensões: Tecnológica, Organizacional e Gerencial. Quais devem ser as razões para que a implementação de BI na empresa seja realizada com sucesso e quais são as boas práticas para uma implementação de sucesso?

## Considerações finais

- O ambiente externo das empresas está cada vez mais competitivo. Por um lado, as empresas têm novos mercados para explorar e fornecedores de todo o mundo, contudo possuem novos concorrentes internacionais, os consumidores são mais exigentes, menos fiéis e a tecnologia está evoluindo mais rápido.
- Para uma tomada de decisões melhor e mais rápida, os executivos precisam das informações certas na hora certa e no lugar certo. Sistemas de BI possibilitam o envio dessas informações, contribuindo para um diferencial competitivo da empresa.
- BI contempla diversos componentes, metodologias, interfaces, tais como o Dashboard, e ferramentas de análise, como o *Data Mining* e os bancos de dados ou *Data Warehouse*.
- Informação é um conjunto de dados com um padrão, criando um significado. Sistemas de BI conseguem obter informações de um grande conjunto de dados. Um conjunto de informações forma conhecimento.
- O BI deve estar alinhado com a estratégia da empresa e deve ser utilizado para melhorar os processos nas diversas áreas.

## Glossário

**Business Intelligence (BI):** Inteligência de negócios, um “guarda-chuva” que contempla arquiteturas, ferramentas, bancos de dados, metodologia e aplicações.

**Data Warehouse (DW):** repositório de dados especial, preparado para dar suporte a aplicações de tomada de decisão.

**Data Mining:** ferramenta para construção de modelos de análise e previsão.

**Dashboard:** um painel para exibição visual das informações mais importantes e necessárias para alcançar um ou mais objetivos, consolidados e organizados em uma única tela, para que a informação possa ser monitorada de relance (FEW, 2006).

## Verificação de leitura

**QUESTÃO 1-** Qual o componente do BI consiste em um banco de dados com a finalidade de oferecer suporte às outras aplicações.

- a) SQL.
  - b) *Dashboard*.
  - c) DSS.
  - d) DW.
  - e) BPM.
- 

**QUESTÃO 2-** Sobre a relação entre fatores do ambiente de negócios, reação das empresas e sistemas computadorizados de apoio à decisão, assinale a alternativa correta.

- a) A Internet e as mídias sociais levaram mais informações aos consumidores, mas isso não mudou a relação deles com as empresas, na qual os consumidores são o elo mais fraco.
  - b) As empresas líderes de seus respectivos setores não precisam implantar sistemas de BI.
  - c) A necessidade de uma maior agilidade na tomada de decisão é uma das motivações para implementação de sistemas de BI.
  - d) Marcos regulatórios não interferem no ambiente das empresas e nem em seus sistemas de informação.
  - e) O ambiente de negócios somente tem trazido pressões e prejuízos para empresas.
- 

**QUESTÃO 3-** Sobre a implementação de BI, um fator que colabora para o seu sucesso é:

- a) a compra de todas as ferramentas comerciais.
  - b) a realização uma avaliação inicial da organização dos sistemas de informação, dos usuários do sistema e da cultura da empresa.
  - c) a cultura da empresa não permitir essa mudança.
  - d) a permissão para que somente um pequeno grupo de pessoas utilize o sistema.
  - e) a contratação de uma empresa terceirizada para instalação do sistema de BI.
-



## Referencias bibliográficas

- CARVALHO, Cristina. O consumidor está no poder. **Harvard Business Review**, 23 mar. 2015. Disponível em: <<http://hbrbr.uol.com.br/o-consumidor-esta-no-poder/>>. Acesso em: 7 maio 2018.
- CECI, Flávio. *Business intelligence*. Palhoça: UnisulVirtual, 2012. Disponível em: <[http://www.smpark.com.br/site/static/placar/%5B6432\\_-\\_19829%5Dbussines\\_intelligence.pdf](http://www.smpark.com.br/site/static/placar/%5B6432_-_19829%5Dbussines_intelligence.pdf)>. Acesso em: 7 de maio de 2018.
- CIO INSIGHT. **Toyota's Business Intelligence**: Oh! What a Feeling. 2004. Disponível em: <<https://www.cioinsight.com/c/a/Case-Studies/Toyotas-Business-Intelligence-Oh-What-a-Feeling>>. Acesso em: 21 maio 2018.
- FEW, Stephen. **Common pitfalls in Dashboard Design**. Perceptual Edge. 2006. Disponível em: <[https://www.perceptualedge.com/articles/Whitepapers/Common\\_Pitfalls.pdf](https://www.perceptualedge.com/articles/Whitepapers/Common_Pitfalls.pdf)>. Acesso em: 7 maio 2018.
- FIALHO, Francisco Antônio Pereira *et al.* **Gestão do conhecimento e aprendizagem**: as estratégias competitivas da sociedade pós-industrial. Florianópolis: Visualbooks, 2006.
- GARTNER Inc. **Using Business Intelligence to Gain a Competitive Edge**. A special report. Gartner: Stamford CT, 2004.
- LAUDON, Jane P.; LAUDON, Kenneth C. **Sistema de Informações Gerenciais**. 11ª ed. São Paulo: Pearson, 2011.
- OLIVEIRA, Marco César de. Efeitos da Globalização. **O Economista**, Joinville, 31 maio 2010. Disponível em: <<https://www.oeconomista.com.br/efeitos-da-globalizacao/>>. Acesso em: 7 maio 2018.
- PAULILLO, Gustavo. Tudo o que você tem que saber sobre análise SWOT de uma empresa. **Blog Agendor**, s. d. Disponível em: <<https://www.agendor.com.br/blog/analise-swot-de-uma-empresa/>>. Acesso em: 07 de maio de 2018.
- RUSSELL, S. J.; NORVIG, P. **Artificial Intelligence**: A modern approach. Prentice Hall, 1995.
- SILVA, Dhiogo Cardoso da. **Uma arquitetura de business intelligence para processamento analítico baseado em tecnologias semânticas e em linguagem natural**. 2011. 161 f. Dissertação (Mestrado em Engenharia do Conhecimento) – Universidade Federal de Santa Catarina, Florianópolis, 2011.
- TURBAN, Efraim *et al.* *Business intelligence*: um enfoque gerencial para a inteligência do negócio. Porto Alegre: Bookman, 2009.

## Gabarito

**QUESTÃO 1**-Resposta Certa D: *Data Warehouse* (DW) é um banco ou repositório de dados especial, preparado para dar suporte a aplicações de tomada de decisão.

-----

**QUESTÃO 2**-Resposta Certa C: No ambiente de negócios, existem tanto pressões quanto oportunidades. Sendo assim, empresa precisa rapidamente tomar uma decisão. Suporte computadorizado à decisão integrada, *Business Intelligence*, irá reunir dados de todas as áreas da empresa, gerando informações, e um conjunto dessas informações irá gerar o conhecimento que embasará uma decisão mais rápida e assertiva.

-----

**QUESTÃO 3**-Resposta Certa B: Uma das primeiras etapas do processo de implementação de BI é avaliar a organização do sistema de informação, os conjuntos de habilidades das possíveis classes de usuários e se a cultura da empresa é receptiva a mudanças. Baseada nessa avaliação inicial e existindo justificativa e necessidade para implantar o BI, a empresa pode preparar um plano de ação detalhado.

-----

A hand is shown interacting with a tablet screen. The image is overlaid with a large, bold black number '2'. The background features geometric shapes in shades of blue and a light blue gradient.

**2**

***Data  
warehouse***

## Objetivos Específicos

- Entender as definições básicas, conceitos e arquiteturas de *data warehouse*.
- Descrever os processos usados no desenvolvimento e gerenciamento de *data warehouse*.
- Explicar as operações e o papel de *data warehouses* em suporte para decisão.
- Explicar os processos de integração de dados e de extração, transformação e carga (ETL).

## Introdução

Devido ao aumento de pontos de contato entre a empresa e o cliente, como lojas físicas, site, terminais de autoatendimento, ocorreu um aumento do número de sistemas de informação orientados a transações. Com isso, existe uma tendência de os dados serem armazenados em bases de dados independentes. Apesar de funcionar bem para o contexto operacional, do ponto de vista gerencial, ter muitas bases de dados independentes e dispersas é um problema, posto que não traz uma visão sistêmica da empresa.

Neste texto, serão definidos conceitos relacionados ao *data warehouse* e banco de dados como de bit, byte, campo, registro, arquivo, banco de texto. Um *data warehouse* pode ser definido como um banco de dados que armazena dados, atuais e históricos, de interesse potencial para os tomadores de decisão dentro de uma empresa. Após esses conceitos iniciais, as principais arquiteturas de *data warehouse* serão abordadas, verificando a quantidade de camadas, componentes e funções desses componentes (TURBAN *et al.*, 2009). Adicionalmente, as arquiteturas serão comparadas para verificar as suas características, vantagens e desvantagens. Posteriormente, serão analisados os processos de integração de dados com foco no processo que realiza a extração, transformação e carregamento dos dados. Por fim, serão analisados os passos para o desenvolvimento de um *data warehouse*, bem como os benefícios de sua implantação.

# 1. *Data warehouse*

No item 1.1, serão abordados conceitos introdutórios ao armazenamento de dados, como banco de dados e registro. No item 1.2, é definido o conceito de *Data Warehouse* e são listadas as suas principais características. No item 1.3, são definidos os conceitos de *Data Mart*. O item 1.4 mostra as arquiteturas principais de *Data Warehouse*. Os itens 1.5 e 1.6 analisam os processos de obtenção, transformação e carregamento dos dados (ETL) e, posteriormente, o processo de desenvolvimento do *data warehouse*.

## 1.1 Conceito de Armazenamento de dados

Um sistema de informações provê aos usuários informações precisas, relevantes, no tempo certo para as pessoas que irão decidir ter o melhor embasamento.

O computador organiza os dados em uma hierarquia que inicia com bit e bytes, evoluindo para campos, registros, arquivos e banco de dados. A palavra BIT é uma abreviação para Binary DigiT e corresponde à menor informação computacional, possui 2 estados (0 ou 1). O byte é um agrupamento de oito bits que representa um caractere, por exemplo, uma letra. Um grupo de caracteres ou um grupo de palavras pode formar um campo como no caso de o nome de uma pessoa ou no caso de um endereço.

Adicionalmente, um número pode representar um campo como no caso de idade ou valor de um produto. Um grupo de campos relacionados forma um registro e um grupo de registro, por sua vez, forma um arquivo. Um banco de dados pode ser definido como um conjunto de arquivos relacionados entre si com registros que descreve uma entidade, a qual pode ser uma pessoa, lugar, produto ou evento, sobre a qual se armazenar informações. Cada característica descrita por uma entidade é chamada de Atributo. A figura 1 ilustra a hierarquia entre cada um desses elementos.

**FIGURA 1: A HIERARQUIA DE DADOS**



**FONTE:** o autor.

As motivações que levaram ao desenvolvimento das tecnologias do armazenamento de dados iniciaram na década de 1970, quando o poder computacional estava concentrado em mainframes. Adicionalmente, apenas existiam estruturas de banco de dados primitivas e entradas de dados simples. Uma empresa de destaque foi fundada em julho de 1979, nos Estados Unidos, com o nome de Teradata, a fim de representar a capacidade de gerenciar Terabytes (Tb) de dados.

Com a década de 1980 e com o advento dos computadores pessoais, foi acarretado o problema de ilhas de dados. A solução para esse problema é um novo tipo de software, chamado de sistema distribuído de gerenciamento de banco de dados. Utilizando bases de dados por meio da organização, todos os dados passam a ser colocados em um mesmo repositório, consolidados, classificados, filtrados com o que for necessário para responder a uma questão de usuário.

## 1.2 Definição e características do *Data Warehouse*

Na década de 1990, houve uma nova abordagem para a solução do problema de ilhas de dados. O início do *Data Warehouse* ocorre sem o acesso direto a arquivos e banco de dados, mas a cópia local. Nos anos 2000, a popularidade e a quantidade de dados aumentam. Adicionalmente, surgem diversos fabricantes e produtos no mercado.

**Data Warehouse (DW)** pode ser definido como um conjunto de dados produzidos para dar suporte ao processo de decisão.

Os dados armazenados serão estruturados para disponibilizar o processamento de métodos analíticos, por exemplo: *data mining*, elaboração de relatórios, realização de pesquisas e processamento analítico online (online analytical processing - OLAP).

Um *Data Warehouse* é orientado a um assunto, integrado, variante no tempo, não volátil, sendo uma coleção de dados em suporte do processo de decisão gerencial. Em relação à organização por assunto, um *Data Warehouse* pode ser organizado por produtos, clientes, compras e canais, devendo conter apenas as informações relevantes para o processo de decisão.

Adicionalmente, o *Data Warehouse* deve ser integrado, trazendo dados de diferentes fontes em um formato consistente. Analisando a questão temporal, *Data Warehouse* se trata de variantes no tempo, pois os dados retratam a situação que estamos analisando em um determinado ponto do tempo. Assim, é necessário manter um histórico temporal.

Por fim, os dados não são voláteis, uma vez que depois de entrarem no *Data Warehouse*, os usuários não podem alterar ou atualizar tais dados.

Outras características de *Data Warehouse* são o uso da estrutura relacional ou da estrutura multidimensional e a existência de metadados, que documentam sobre como os dados estão organizados e como é possível utilizá-los efetivamente. Também, normalmente, são projetados como aplicações Web. Um *Data Warehouse* utiliza a arquitetura cliente/servidor para prover acesso aos usuários finais.



### Assimile

*Data Warehouse* é um repositório de dados atuais e históricos de potencial interesse para os administradores por meio da organização.





## 1.3 *Data Mart*

Um *Data Mart* é normalmente menor e foca em um departamento ou assunto específico. Sendo assim, é um subconjunto de *Data Warehouse*, consistindo de apenas uma única área de interesse.

### Exemplificando

As áreas de finanças, operações, vendas e marketing podem ter *Data Warehouse* customizado para elas, sendo denominado *Data Mart*. Assim, cada área pode ter visões diferentes dos dados centralizados.

Um *Data Mart* pode ser tanto dependente quanto independente. Um *Data Mart* dependente é um subconjunto, que é criado diretamente para o *Data Warehouse*. A vantagem é o uso de um modelo de dados consistentes e provimento de qualidade de dados.

Por sua vez, um *Data Mart* independente é um pequeno *Warehouse* projetado para uma unidade de negócios ou um departamento, e não para uma empresa como um todo, pois o custo de um *Data Warehouse* é um limitador de sua utilização em grandes empresas (TURBAN, 2009).

Um armazenamento de dados operacional (ODS) é um tipo de banco de dados utilizado para memória de curto prazo. Um *Enterprise Data Warehouse* (EDW) é um *Warehouse* de grande escala que é utilizado por meio da empresa para suporte à decisão.

## 1.4 Arquiteturas de *Data Warehouse*

Estas arquiteturas são normalmente denominadas cliente/servidor ou arquiteturas de n camadas, sendo as arquiteturas de duas e três camadas mais comuns. Existem três partes em um *Data Warehouse*: o conjunto de dados e o *software* associado aos dados; o *software* de aquisição de dados ou back-end, responsável pela extração dos dados dos sistemas legados e fontes externas, pela consolidação e totalização desses registros e pelo seu carregamento no *Data Warehouse*; e o *software* cliente, chamado de front-end, que permite aos usuários acessarem e analisarem os dados do *Data Warehouse*.

Em uma arquitetura de duas camadas, como ilustrado na figura 2 a seguir, a primeira camada é formada pela estação de trabalho. Já a segunda, contempla tanto os servidores de aplicação quanto os servidores de banco de dados.


FIGURA 2: ARQUITETURA DE *DATA WAREHOUSE* DE DUAS CAMADAS



FONTE: adaptado de Turban et al. (2009).

Em uma arquitetura de três camadas, como ilustrado na figura 3 a seguir, a primeira camada é formada pela estação de trabalho. Já a segunda, contempla os servidores de aplicação e a última camada, por sua vez, possui os servidores de banco de dados.

FIGURA 3: ARQUITETURA DE *DATA WAREHOUSE* DE TRÊS CAMADAS



FONTE: adaptado de Turban et al. (2009).

Com o advento da Internet, passou a existir a integração de tecnologia de *Data Warehouse* com base em dados captados ou armazenados na internet. A arquitetura também possui três camadas: estação de trabalho do cliente, o servidor Web e o servidor de aplicação. São vantagens dessa




#### Para saber mais

Existem várias questões que devem ser consideradas na escolha da arquitetura de *Data Warehouse*. Qual o sistema de gerenciamento de banco de dados deve ser utilizado? Quais ferramentas de migração podem ser usadas para carregar o *Data Warehouse*? Quais ferramentas podem ser utilizadas para suportar a análise e recuperação de dados?

arquitetura o baixo custo e o fácil acesso para os usuários, uma vez que é realizado por meio de browser ou navegador, não dependendo de instalações de novos pacotes de softwares, que poderiam ser incompatíveis com computador do usuário final. A figura 4 mostra essa arquitetura de *Data Warehouse* baseada na Web.

**FIGURA 4: ARQUITETURA DE *DATA WAREHOUSE* BASEADO NA WEB**




**FONTE:** adaptado de Turban et al. (2009).

## 1.5 Processo de Integração, Extração, Transformação e Carregamento de Dados

Por um lado, trabalhar com múltiplas bases de dados, sejam elas integradas a um *Data Warehouse* ou não, é um desafio muito complexo que requer muita expertise. Por outro lado, os benefícios podem ser de grandes proporções, excedendo em muitas vezes o custo dessa tarefa. O processo para *Data Warehouse* inclui fontes de dados, extração e transformação de dados, carregamento de dados, banco de dados, metadados e ferramentas de *middleware*. A figura 5, a seguir, ilustra as relações existentes entre os componentes, a partir da obtenção dos dados para a visualização das informações.

FIGURA 5: ESTRUTURA E VISUALIZAÇÃO DE UM DATA WAREHOUSE



FONTE: Turban et al. (2009, p. 58)

As fontes de dados são originadas de múltiplos independentes sistemas “legados” e, provavelmente, de provedores de dados externos como o Instituto Brasileiro de Geografia e Estatística – IBGE. Adicionalmente, os dados podem surgir de sistemas transacionais online (OLTP) ou de um sistema de planejamento de recursos, isto é, Enterprise Resource Planning (ERP). Dados da Web, em forma de web logs, podem também alimentar o *Data Warehouse*.

Os dados são extraídos e transformados usando softwares comerciais ou customizados, chamados de Extraction Transformation Loading (ETL).

Os dados são carregados em uma área de teste, na qual são transformados e limpos. A partir disso, os dados estão prontos para serem carregados em um *Data Warehouse* ou em um *Data Marts*.

Os bancos de dados devem ser compreensíveis, pois, essencialmente, o *data warehouse* da organização é utilizado para dar suporte a análises de decisões, com o fornecimento de informações detalhadas e totalizadas de diversas fontes distintas

Os Metadados são mantidos para que possam ser acessados pelos responsáveis de TI e usuários. Tal estrutura tem objetivo de facilitar a recuperação e organização e representa informações sobre os dados existentes (CECI, 2012).

Ferramentas de *Middleware* permitem o acesso ao *Data Warehouse*. Usuários com determinadas permissões, como analistas de sistemas, podem escrever suas consultas em SQL. Usuários com permissões mais restritivas, como analistas de negócios, podem somente acessar dados. Existem diversas aplicações front-end, isto é, processos que interagem diretamente com o usuário de negócios por meio de interfaces. E por meio dessas interações, os dados são armazenados em repositórios, incluindo o *Data Mining*, OLAP, ferramentas de relatórios e visualizadores de dados.

A integração compreende três processos principais: acessos aos dados, serviços de federação de dados e captura de mudanças. Quando os três processos são corretamente implementados, os dados podem ser acessados e ser acessíveis para um conjunto de ETL e ferramentas de análises e ambientes de Data Warehousing. Os serviços de federação de dados possibilitam, por meio de técnicas e softwares, a coleta de dados de fontes distintas e a agregação de todos os dados coletados em um repositório virtual, para que seja utilizado em análise de BI.

Alguns fornecedores de *software* se notabilizaram por oferecer ferramentas de integração de dados. O SAS Institute, por exemplo, possui ferramentas de integração de dados de clientes que melhoram a qualidade dos dados no processo de integração.


Várias tecnologias de integração possibilitam a integração de dados e metadados:

- Enterprise application integration (EAI);
- Service-oriented architecture (SOA);
- Enterprise information integration (EII);
- Extraction, transformation, and load (ETL).

Integração de Aplicações corporativas (Enterprise application integration - EAI) é uma tecnologia que provê um meio para disparar os dados de seus sistemas de fonte para o *Data Warehouse*.

A categoria Enterprise information integration (EII) é uma ferramenta em desenvolvimento que promete uma integração de dados em tempo real e de diversas fontes, tais como: bancos de dados relacionais, serviços Web e banco de dados multidimensionais.

O processo mais comum de Data Warehousing é baseado na extração, transformação e carregamento, ou seja, extraction, transformation, and load (ETL). O processo ETL é tipicamente um projeto centrado em dados. O processo ETL consiste na extração, leitura dos dados de uma ou mais base de dados, e na transformação, isto é, na conversão dos dados extraídos de sua forma anterior para a forma necessária, para que ele possa ser colocado no *Data Warehouse*, e no carregamento, ou seja, deve-se imputar os dados no *Data Warehouse*.



**Para saber mais**

O SAS Institute está presente em 140 países do mundo e tem mais de 70 mil empresas, governos ou universidades como clientes.


## 1.6 Desenvolvimento de um *Data Warehouse*

Um projeto de Data Warehousing é um importante ativo para qualquer organização e é muito mais complexo do que um projeto somente tecnológico, pois o projeto compreende e

influencia em muitas áreas da empresa, que terão interfaces de entradas e saídas, assim como pode ser parte da estratégia de negócios.

Um *Data Warehouse* proporciona uma série de benefícios diretos e indiretos. Entre os benefícios diretos, pode-se destacar que os usuários finais terão capacidade de realizar análises extensivas de diversas formas. Além disso, é possível uma visão consolidada dos dados da organização e permite que o proces-

samento da informação passe de sistemas operacionais de alto desempenho e custo para servidores de baixo custo. Por fim, o acesso aos dados é simplificado.



#### Para saber mais

Existem questões que afetam se uma organização comprará uma ferramenta de transformação de dados ou se ela mesma construirá um processo de transformação, tais como: preço das ferramentas de transformação de dados; ferramentas de transformações de dados podem ter uma curva de aprendizado longa; há a dificuldade de mensurar como a empresa de TI está desempenhando até que ela tenha aprendido a usar as ferramentas de transformações de dados (LAUDON; LAUDON, 2011).

## Questão para reflexão

Considere uma pequena loja de conveniência dentro de uma rede de postos de gasolina. Quais as características da empresa que devem ser consideradas para o projeto de um *Data Warehouse*? Quais fontes de dados devem ser consideradas?

## Considerações finais

- *Data Warehouse* é um repositório de dados atuais e históricos de potencial interesse para os administradores da organização. Além de possuir como características: ser orientado por assunto, integrado, variante no tempo, não volatilidade e incluir o metadados.
- Existem três partes em um *Data Warehouse*: o conjunto de dados e o *software* associado aos dados, o *software* de aquisição de dados ou back-end e o *software* cliente, chamado de front-end que permite aos usuários acessar e analisar os dados do *data warehouse*.



- O processo mais comum de Data Warehousing é baseado na extração, transformação e carregamento, ou seja, extraction, transformation and load (ETL).
- O desenvolvimento de um projeto de *Data Warehouse* é um importante ativo para a empresa.

## Glossário

**Data Warehouse:** conjunto de dados produzidos para dar suporte ao processo de decisão.

**Data Mart:** subconjunto de *data warehouse*, consistindo em apenas uma única área de interesse.

**Enterprise Data Warehouse (EDW) :** *warehouse* de grande escala que é utilizado por meio da empresa para suporte à decisão.

## Verificação de leitura

**QUESTÃO 1-** Um subconjunto de um *Data Warehouse*, com uma única área da empresa, é conhecido como:

- a) metadados;
  - b) base de dados;
  - c) *Data Mart*;
  - d) Repositório das informações;
  - e) SAS.
- 

**QUESTÃO 2-** Quais as etapas em processo ETL?

- a) Extração; Transporte; Limpeza dos dados.
  - b) Extração; Transformação; Carregamento dos dados.
  - c) Especialização; Tratamento; Lavagem dos dados.
  - d) Escovação; Transformação; Carregamento dos dados.
  - e) Empreendedorismo; Turismo; Labuta dos dados.
-

**QUESTÃO 3-** Assinale a alternativa em que existe benefício em relação ao *Data Warehouse*.

- a) Sistemas de *Data Warehouse* são sempre de baixo custo de hardware.
  - b) Com um *Data Warehouse* eficiente, é possível ter um bom balizamento para decisões.
  - c) Se um concorrente usa um *Data Warehouse*, a empresa também deve fazer um, mesmo que não o utilize.
  - d) É de fácil implantação, afinal é somente uma base de dados.
  - e) Unir dados de diversas fontes de dados auxilia nas decisões gerenciais.
- 

## Referências bibliográficas

CECI, Flávio. **Business intelligence**. Palhoça: UnisulVirtual, 2012. Disponível em: <[http://www.smpark.com.br/site/static/placar/%5B6432\\_-\\_19829%5Dbussines\\_intelligence.pdf](http://www.smpark.com.br/site/static/placar/%5B6432_-_19829%5Dbussines_intelligence.pdf)>. Acesso em: 08 de maio de 2018.

LAUDON, Jane P.; LAUDON, Kenneth C. **Sistema de Informações Gerenciais**. 11ª ed. São Paulo: Pearson, 2011.

TURBAN, Efraim *et al.* **Business intelligence**: um enfoque gerencial para a inteligência do negócio. Porto Alegre: Bookman, 2009.

## Gabarito

**QUESTÃO 1-** Resposta Correta C. *Data Mart*: subconjunto de *data warehouse*, consistindo em apenas uma única área de interesse.

-----

**QUESTÃO 2-** Resposta Correta B. ETL: Extration: Extração; Transformation: Transformação; Load: Carregamento dos dados.

-----

**QUESTÃO 3-** Resposta Correta B. Com a existência e utilização de um *Data Warehouse*, serão fornecidas informações mais precisas aos tomadores de decisão, os quais serão mais assertivos e trarão uma vantagem competitiva para a empresa

-----



**3**

**Mineração  
de dados e  
inteligência  
artificial**

## Objetivos Específicos

- Descrever a mineração dos dados ou Data Mining e listar seus objetivos e benefícios.
- Entender diferentes aplicações e métodos de Data Mining, principalmente a árvore de decisão e os modelos de agrupamento.
- Aprender o processo dos projetos de Data Mining.
- Conhecer conceitos e aplicações de Inteligência Artificial (IA), do inglês Artificial Intelligence (AI), em sistema de BI.

## Introdução

Com o aumento da quantidade de dados gerados para uma empresa nas suas operações, é necessário que exista capacidade para analisar a base de dados originada. Dificilmente seria possível identificar padrões de comportamento dos dados somente com capacidade humana. As ferramentas de mineração de dados contribuem na identificação desses padrões, na realização, nas classificações, na *clusterização* da base de dados e nas previsões de comportamento futuro. Esses resultados podem ser aplicados a diversos setores de atuação, desde bancos, varejo a governos. Além disso, é possível realizar descoberta de conhecimento em banco de dados, quando são realizadas etapas adicionais, tais como Seleção de dados, Pré-processamento, Transformação, *Data mining* e, por fim, deve-se avaliar e interpretar. Um tema corriqueiro é a inteligência artificial, na qual um agente se comporta de modo que um observador qualquer pareceria ser inteligente.

# 1. Mineração de dados e inteligência artificial

No item 1.1, serão elaboradas definições sobre Mineração de dados e serão verificadas algumas das principais aplicações. No item 1.1.1, serão analisadas as principais características de *Data Mining* e seus objetivos. Já o item 1.1.2, explora as classificações de *Data Mining* e as diferentes técnicas existentes. A seção 1.2, por sua vez, aborda sobre a descoberta do conhecimento em banco de dados. Por fim, a seção 1.3 elabora uma introdução à Inteligência Artificial.

## 1.1 Definição de Mineração de Dados e principais aplicações

Nos últimos anos, os volumes de dados armazenados e disponíveis aumentaram rapidamente nas empresas dos diversos setores, contudo a capacidade de análise de dados, sem ferramentas específicas, não. Assim, foram desenvolvidas ferramentas de inteligência de negócios ou *Business Intelligence* (BI) que, a partir dos dados coletados, realiza categorizações, classificações, organizações, filtragens e processamentos para uma organização. Tais ferramentas são chamadas de Mineração de Dados ou *Data Mining*.

De acordo com Hand, Mannila e Smyth (2001, p. 6), pode-se definir, sob uma perspectiva estatística, que a “Mineração de Dados é a análise de grandes conjuntos de

dados a fim de encontrar relacionamentos inesperados e de resumir os dados de uma forma que eles sejam tanto úteis quanto compreensíveis ao dono dos dados”.

Como o custo de armazenar dados e de processá-los diminuiu de forma drástica desde os anos



### Assimile

Pode-se definir de mineração de dados como um processo que utiliza técnicas matemáticas, estatísticas, de inteligência artificial e de aprendizado de máquina para extrair e identificar informações úteis e, consequentemente, conhecimento de bases de dados de larga escala

2000, a resultante desses fatos foi que a quantidade de dados armazenados em formatos digitais cresceu em uma velocidade exponencial (TURBAN *et. al*, 2009). Com a geração de grandes bancos de dados, existe um maior foco na análise desses dados coletados pela empresa.

A mineração de dados é utilizada em pesquisas acadêmicas, em áreas com abundância de dados experimentais, como física, astronomia, medicina e farmácia. Já no mundo corporativo, os setores financeiro, varejista e de seguros de saúde são os que mais fazem a aplicação de *Data Mining*.

O *Data Mining* já é amplamente usado para melhor visar clientes e, com o desenvolvimento do comércio eletrônico, que pode inclusive gravar informações sobre navegação, preferências e produtos desejados, a tendência é que isso se torne mais importante com o passar do tempo. Um exemplo de ferramenta de *Data Mining* pode ser encontrado em (SAS INSTITUTE, 2016).



#### Exemplificando

O *Data Mining* é usado para: reduzir perdas de crédito de clientes com empréstimos pessoais ou cartões de crédito; identificar padrões de compra do cliente; recuperar clientes rentáveis e não perder esse cliente para seus concorrentes; identificar regras de negócio a partir de dados históricos; ofertas de produtos diferenciados por clientes, dependendo do seu perfil e seu ciclo de vida.

### 1.1.1 Principais características e objetivos de *Data Mining*

O ambiente de *Data Mining* geralmente é uma arquitetura cliente/servidor ou uma arquitetura baseada na Web. O miner é um usuário final, capacitado com ferramentas poderosas de consulta para obter respostas rapidamente, requerendo pouca ou nenhuma habilidade de programação.

Tais ferramentas sofisticadas, incluindo ferramentas de visualização avançada, ajudam a retirar informações escondidas tanto em arquivos corporativos quanto aquelas arquivadas em registros públicos. Ferramentas de *Data Mining* são facilmente combinadas com planilhas e com outras ferramentas para desenvolvimento de software.

Sem ferramentas de *Data Mining*, seria necessário tirar a sorte grande, o que, muitas vezes,

envolve descobrir um resultado inesperado e exige que os usuários finais pensem de forma criativa. Com as ferramentas, as informações são descobertas por meio da junção e da sincronização de dados para a obtenção dos resultados certos.

Eventualmente, devido às grandes quantidades de dados e iniciativas sólidas de pesquisa, é necessário usar processamento paralelo para *Data Mining*. Assim, o *Data Mining* inclui tarefas como: extração de conhecimento; arqueologia de dados; exploração de dados; processamento de padrões de dados; limpeza de dados; colheita de informação.

## 1.1.2 Classificações de *Data Mining*

Uma das utilizações de Ferramentas de *Data Mining* é a obtenção de padrões em dados e, eventualmente, a dedução das regras desses padrões, a partir dos dados. Existem três tipos de métodos que são usados para identificar padrões em dados.

- Modelos simples: consultas baseadas em linguagem SQL, isto é, Linguagem Estruturada para Consulta ou Structured Query Language, processamento analítico online (OLAP) e raciocínio humano.
- Modelos intermediários: regressão, árvores de decisão e agrupamento.
- Modelos complexos: redes neurais e outra indução de regras.

Tais padrões e regras podem ser utilizados para o processo de tomada de decisão e para previsão do resultado das potenciais decisões.



### Para saber mais

Uma Rede Neural Artificial (RNA) pode ser definida como um conjunto de neurônios artificiais interconectados, os quais são um construto matemático inspirado no neurônio biológico.

É possível acelerar o desempenho da análise ao focar nas variáveis mais relevantes. Habitualmente, os algoritmos de *Data Mining* são divididos em quatro categorias amplas: classificação, agrupamento, associação e descoberta de sequência. Existem outras ferramentas de análise de dados, como visualização, regressão de dados e análise de séries temporais que encontram ampla aplicação prática.

A classificação de dados ou Data Classification consiste no processo de encontrar propriedades



comuns e um determinado conjunto de objetos de um banco de dados, classificá-los em diferentes classes, de acordo com um modelo de classificação, e gerar um modelo que pode, automaticamente, gerar uma previsão do comportamento futuro. As ferramentas mais comuns de classificação são redes neurais, regras se-então-senão e árvores de decisão, que são definidas como uma raiz seguida de nós internos, em que cada nó é nomeado com uma questão e arcos associados, com cada nó cobrem todas as possíveis respostas associadas ao nó.


Outra categoria é conhecida como Agrupamento ou *Clusterização*, que consiste na divisão do banco de dados em segmentos que possuem características semelhantes. Uma diferença entre a categoria de classificação e o agrupamento é que os *clusters* são desconhecidos no agrupamento quando o algoritmo começa (TURBAN *et al.*, 2009).

A Associação é uma categoria de algoritmo de *Data Mining*, a qual estabelece relações entre os itens que ocorrem conjuntamente em um mesmo registro. Uma das aplicações primárias dessa técnica é a análise de cesta de supermercado, em operações de venda.

A descoberta de sequência, por sua vez, trata-se de uma identificação de associações ao longo do tempo. No momento em que as informações estão disponíveis, quando ocorre a identificação de um cliente na loja, ocorre uma análise temporal para identificar o comportamento ao longo do tempo.

A visualização pode ser utilizada em conjunto com o *Data Mining* para ganho de entendimento dos relacionamentos existentes entre os dados. A

Regressão é uma técnica estatística muito conhecida que relaciona os dados das bases como uma variável dependente com valores de uma predição. Já a Previsão estima valores futuros baseados em padrões de conjuntos de extensos dados. Um exemplo é o cálculo de valores futuros de índices baseados em comportamentos desse índice no passado.



**Para saber mais**

No trabalho “Mineração de dados: conceitos, tarefas, métodos e ferramentas” (CAMILO; SILVA, 2009), além dos conceitos fundamentais, tarefas, métodos e variante dos métodos de Mineração de Dados, é apresentada uma lista das principais ferramentas para trabalhar com mineração.

Há diversos métodos para elaboração de *Data Mining*. Um *software* de *Data Mining*, por exemplo, pode implementar uma ou mais dessas técnicas.

Com os dados organizados e armazenados no *Data Warehouse*, o próximo passo para a descoberta de conhecimento é aplicar métodos de análises estatísticas e de Inteligência Artificial (IA). Dessa maneira, novas relações e informações serão descobertas (CARVALHO, 2005).

As ferramentas de *Data Mining* podem prever futuras tendências e comportamentos, permitindo às empresas um novo processo de tomada de decisão, baseado, principalmente, no conhecimento acumulado que, frequentemente, é deixado de lado, contido em seus próprios bancos de dados.

O *Data Mining* pode ser tanto baseado em hipótese quanto baseado em descoberta. Se baseado em hipótese, inicia-se com uma proposição do usuário que, então, busca validar a veracidade da afirmação. Se baseado em descoberta, encontra padrões, associações e relações entre os dados. Dessa forma, pode revelar fatos que uma empresa desconhecia ou ignorava no passado (CARVALHO, 2005).

Outro conceito importante é *Text Mining* que pode ser definido como a aplicação de *Data Mining* em arquivos de texto não estruturados ou menos estruturados. Também existe Web Mining, que pode ser definida como a descoberta e análise de informações úteis e interessantes provenientes da Web, sobre a Web e, geralmente, por meio de ferramentas baseadas na Web (TURBAN *et al.*, 2009).


Outra classificação das ferramentas e técnicas é baseada na estrutura dos dados e nos algoritmos utilizados. Assim, pode-se dividir em computação neural, algoritmos genéticos, agentes inteligentes, razões baseadas em casos e outras ferramentas, como indução das regras e visualização dos dados.

Ferramentas de *Data Mining* são aplicadas aos mais diversos setores, desde seguros, bancos, eleitoral, telemarketing, segurança, policial, recursos humanos, companhias aéreas, sistemas de saúde e medicina, empresas de *software* e *hardware*, produção e manufatura, vendas, *marketing* etc.

## 1.2 Descoberta de conhecimento em Banco de Dados

A Descoberta de conhecimento em bancos de dados, ou *Knowledge Discovery in Databases* (KDD), pode ser definida como um processo que usa os métodos de *Data Mining* para encontrar informações e padrões úteis nos dados (FAYYAD; PIATETSKY-SHAPIRO; SMYTH, 1998). A figura 1, a seguir, mostra cada uma das etapas desse processo que se inicia com a seleção dos dados do *Data Warehouse* e que, a partir disso, são pré-processados e posteriormente transformados. Com os dados transformados, é realizada a etapa de mineração dos dados. Assim, são detectados padrões de comportamento dos dados e, com base na avaliação e no entendimento desses padrões, pode-se construir um conhecimento sobre os dados analisados.

FIGURA 1: PROCESSO DE KDD



FONTE: adaptado de Fayyad, Piatetsky-Shapiro e Smyth (1998).

## 1.3 Inteligência Artificial

Na década de 1950, surgiram os primeiros estudos sobre Inteligência Artificial (IA) ou *Artificial Intelligence* (AI), cujo objetivo era o desenvolvimento de sistemas para realizar tarefas que, no momento, são melhor realizadas por seres humanos do que por máquinas, ou não possuem solução algorítmica viável pela computação convencional. Assim, Inteligência Artificial é o estudo dos sistemas que agem de um modo que, para um observador qualquer, parece ser inteligente e envolve utilizar métodos baseados no comportamento inteligente de humanos e outros animais para solucionar problemas complexos (COPPIN, 2017).

A IA tem interface com diversas ciências, tais como: computação, engenharia, matemática, sociologia, neurofisiologia, linguística, filosofia, psicologia, entre outras. Possui diversas aplicações, como exemplo: atendimento simples a clientes, treinamentos, assistentes virtuais e robôs autônomos.

## Questão para reflexão

Mesmo as tarefas domésticas, como preparar refeições, utilização de equipamentos eletrônicos para entretenimento e passar roupas, estão se modificando com a utilização de diferentes tecnologias. Com a evolução da Inteligência Artificial e utilização de redes neurais, quais atividades domésticas poderão ser mais impactadas no seu cotidiano nos próximos dez anos?

## Considerações finais

- Mineração de Dados é a análise de grandes conjuntos de dados, a fim de encontrar relacionamentos inesperados e de resumir os dados de uma forma que eles sejam tanto úteis quanto compreensíveis ao dono dos dados.
- Três tipos de métodos são usados para identificar padrões em dados: Modelos simples, como SQL ou raciocínio humano; Modelos intermediários, como árvores de decisão, regressão; e Modelos complexos, como redes neurais.
- Algoritmos de Data Mining podem ser divididos nas seguintes categorias: classificação; agrupamento ou cluster; associação e descoberta de sequência; regressão de dados; análise de séries temporais; e visualização.
- Inteligência Artificial é o estudo dos sistemas que agem de modo que, para um observador qualquer, pareceria ser inteligente.

## Glossário

**Mineração de Dados ou *Data Mining*:** processo que utiliza técnicas matemáticas, estatísticas, de inteligência artificial e de aprendizado de máquina para extrair e identificar informações úteis e, conseqüentemente, conhecimento de bases de dados em larga escala.

**Inteligência artificial (IA) ou Artificial Intellingence (AI):** Estudo dos sistemas que agem de modo que, para um observador qualquer, pareceria ser inteligente.

**Rede Neural Artificial (RNA):** conjunto de neurônios artificiais interconectados, que são um construto matemático inspirado no neurônio biológico.

## Verificação de leitura

**QUESTÃO 1-** Uma ferramenta de Data Mining possui nós e ligações entre os nós. Cada nó indica um teste feito sobre um valor e as ligações entre nós representam os valores possíveis do teste do nó superior. Qual o nome dessa ferramenta?

- a) Redes Neurais.
  - b) Árvores de Decisão.
  - c) Clusterização.
  - d) Análise Temporal.
  - e) Regressão.
- 

**QUESTÃO 2-** Assinale a alternativa correta em relação à Mineração de Dados.

- a) Mesmo sem ferramentas, é muito fácil descobrir padrões nos dados para bases de dados muito grandes.
  - b) A análise dos dados existe e não é uma tarefa relevante.
  - c) Data Mining só tem aplicação teórica e não foi aplicada com sucesso na prática.
  - d) Só existe uma única técnica de Mineração de dados: Classificação.
  - e) A Mineração de Dados pode ser aplicada com sucesso em diversos setores de negócio.
- 

**QUESTÃO 3-** Com o surgimento da Inteligência Artificial,

- a) verificou-se que o computador não aprende.
  - b) utilizou-se uma rede artificial de neurônios para transmissão da informação.
  - c) os robôs poderão ter emoção.
  - d) não é mais necessário armazenar dados.
  - e) foram desenvolvidos sistemas para realizar tarefas que antes eram melhor realizadas por seres humanos do que por máquinas.
-

## Referências bibliográficas

CAMILO, Cássio Oliveira; SILVA, João Carlos. **Mineração de Dados**: Conceitos, Tarefas, Métodos e Ferramentas. Goiás, 2009. Disponível em: <[http://www.portal.inf.ufg.br/sites/default/files/uploads/relatorios-tecnicos/RT-F\\_001-09.pdf](http://www.portal.inf.ufg.br/sites/default/files/uploads/relatorios-tecnicos/RT-F_001-09.pdf)>. Acesso em: 21 maio 2018.

CARVALHO, Luís Alfredo Vidal de. **Data Mining**: A Mineração de Dados no Marketing, Medicina, Economia, Engenharia e Administração. Rio de Janeiro: Ciência Moderna, 2005.

COPPIN, Ben. **Inteligência artificial**. Trad. Jorge Duarte Pires Valério. Rio de Janeiro: LTC, 2017.

FAYYAD, Usama; PIATETSKY-SHAPIO, Gregory; SMYTH, Padhraic. From *Data Mining to Knowledge Discovery in Databases*. **AI Magazine**, v. 17, n. 3, p. 37-54, 1996.

HAND, David; MANNILA, Heikki; SMYTH, Padhraic. **Principles of Data Mining**. Cambridge: MIT Press, 2001.

SAS INSTITUTE. *Data Mining From A to Z: How to Discover Insights and Drive Better Opportunities*. 2016, Disponível em: <[https://www.sas.com/content/dam/SAS/en\\_us/doc/whitepaper1/data-mining-from-a-z-104937.pdf](https://www.sas.com/content/dam/SAS/en_us/doc/whitepaper1/data-mining-from-a-z-104937.pdf)>. Acesso em: 8 maio 2018.

TURBAN, Efraim *et al.* **Business Intelligence**: um enfoque gerencial para a inteligência do negócio. Porto Alegre: Bookman, 2009.

## Gabarito

**QUESTÃO 1**-Resposta B: Árvore de Decisão. As árvores de decisão são definidas como uma raiz seguida de nós internos. Cada nó é nomeado com uma questão e arcos associados, com cada nó cobrem todas as possíveis respostas associadas ao nó.

-----

**QUESTÃO 2**-Resposta E: Ferramentas de Data Mining são aplicadas nos mais diversos setores: seguros, bancos, eleitoral, telemarketing, segurança, policial, recursos humanos, companhias aéreas, sistemas de saúde e medicina, empresas de software e hardware, produção e manufatura, vendas, marketing etc.

-----

**QUESTÃO 3**-Resposta E. A Inteligência Artificial possibilita agentes inteligentes, os quais podem aprender com o ambiente e responder de formas tão satisfatórias quanto humanos.

-----

A hand is pointing at a tablet screen. A large, bold black number '4' is overlaid on the image. The background is a collage of blue geometric shapes and a blurred image of a hand pointing at a tablet.

**4**

**Modelos  
descriptivos**



## Objetivos Específicos

- Identificar a necessidade de modelos descritivos.
- Apresentar diferentes algoritmos de modelos descritivos.
- Explicar parâmetros que comparam o desempenho de diferentes modelos.

# Introdução

Uma classe importante de métodos de mineração de dados são os modelos descritivos ou modelos de aprendizado não supervisionado. São utilizados apenas dados históricos, com suas respectivas variáveis, para a construção de um modelo, e inexistente uma figura externa para guiar o aprendizado. Assim, para obter informações, são verificados se os dados passados possuem um padrão de comportamento.

Esse tipo de modelo possui aplicação em diversas áreas de conhecimento, nas quais exista abundância de dados experimentais, como Física, Medicina, *Marketing* e Engenharia. Existem diversas técnicas de algoritmos para realização de modelos descritivos. Em modelos de associação, busca-se de padrões frequentes de associações entre os atributos de um conjunto de dados. Por sua vez, o agrupamento trata de identificar grupos de dados com base na semelhança entre os objetos.

Existem diversas técnicas de algoritmos de agrupamento, a saber: hierárquicos, particionais baseados em erro quadrático, baseados em densidade, baseados em grafo, baseados em redes neurais e, também, baseados em *grid*. É possível comparar o desempenho dos modelos por meio de indicadores pré-definidos.

## 1. Modelos descritivos

Na modelagem de um processo de *Data Mining*, uma classe importante de métodos de mineração de dados são os modelos descritivos ou modelos de aprendizado não supervisionado. Nesse tipo de modelo, são utilizados apenas dados históricos, com suas respectivas variáveis, para a construção de um modelo. Além disso, inexistente uma figura externa para guiar o aprendizado.

Assim, para obter informações, são verificados se os dados passados possuem padrões de comportamento e se as representações dos dados auxiliam na tomada de decisões. Considerando um conjunto de dados, um algoritmo de aprendizado de máquina não supervisionado busca como representar as entradas, segundo um critério de qualidade previamente definido (TURBAN *et al.*, 2009).

A associação está relacionada à busca de padrões frequentes de associações entre os atributos de um conjunto de dados. Conforme já mencionado, o agrupamento busca identificar grupos de dados com base na semelhança entre os objetos e suas técnicas são valiosas para explorar dados, tendo aplicação em áreas diversas, tais como: Engenharia, *Marketing*, Medicina, Biologia e Física.

Na análise de agrupamento, o aprendizado está focado nos dados e não são necessários conhecimentos anteriores sobre as classes ou as categorias que formarão os agrupamentos (MITCHELL, 1997).

As regras de associações, por sua vez, são utilizadas para descobrir o relacionamento entre variáveis em grandes bases de dados, por exemplo: pesquisas em supermercados detectaram que existe uma forte correlação entre quem são os clientes que compram fraldas e os clientes que compram cervejas.

O fato, nesse caso, foi explicado pelo perfil de cliente, que era predominantemente masculino e, após comprar tal item para o seu filho, busca um produto para o seu consumo. Assim, diversas promoções de *marketing* ou de decisão sobre onde realizar a colocação de produtos são realizadas com bases em modelos de associações. Adicionalmente, as regras podem ser aplicadas para mineração de dados na Web, detecção de intrusos e sistemas de recomendação.

## 1.1 Definições sobre *clusters*

Existem definições sobre características de *cluster*. Segundo Barbara (2000), um *cluster* bem separado é um conjunto de pontos de modo que qualquer ponto em um determinado *cluster* está próximo, ou é mais similar, a cada ponto nesse *cluster* do que qualquer ponto não pertencente a ele.

Já um *cluster* baseado em centro considera um conjunto de pontos, de forma que qualquer ponto, em um dado *cluster*, está mais próximo ao centro desse *cluster* do que ao centro de qualquer outro.

Também existe o *cluster* contínuo ou encadeado, no qual um conjunto de pontos assim como qualquer ponto, em um dado *cluster*, está mais próximo a um ou mais pontos nesse *cluster* do que a

qualquer outro que não pertence a ele.

Outro tipo de *cluster* é baseado em densidade, em que o *cluster* será uma região densa de pontos, separada de outras regiões de alta densidade e por regiões de baixa densidade. Existem *clusters* baseados em similaridade, no qual o *cluster* é um conjunto de pontos similares, enquanto um ponto fora do *cluster* não é similar.

## 1.2 Medidas para Atributos

É possível mensurar os atributos tanto de forma qualitativa quanto de forma quantitativa. As tarefas descritivas possuem diferentes fases, tais como: sumarização, associação e agrupamento. Nessas etapas, podem ser aplicadas desde medidas estatísticas mais rudimentares, como média e desvio padrão, até complexas técnicas de visualização dos relacionamentos existentes entre atributos (FACELLI *et al.*, 2011).

A análise de cestas de compras é uma aplicação técnica de mineração de um conjunto de itens frequentes, o que se trata de uma área de pesquisa com muitos estudos e descobertas de conhecimento para bases de dados, podendo descrever o comportamento de compra de clientes. O objetivo dessa mineração de um conjunto de itens frequentes é a descoberta de grupos de produtos que são comprados conjuntamente com uma frequência maior do que outras combinações de produtos e também descobrir a inferência dos produtos que são adquiridos, considerando os que foram comprados anteriores.

Os algoritmos de agrupamento são classificados com base em modelos. Assim é necessário ter sempre em mente a escolha do algoritmo e em que instante ocorrerá a comparação.

## 1.3 Interpretação dos *clusters*

Denomina-se interpretação o processo de exame de cada *cluster* em relação aos seus componentes para identificar esses elementos com rótulos, tendo como objetivo descrever a natureza do *cluster*. Nessa etapa, busca-se mais que simplesmente descrever, mas também um modo de confirmação da hipótese inicial e permitir avaliações subjetivas que possuam um significado.

Um facilitador é o conhecimento do domínio dos dados, pois pode contribuir na identificação de *cluster* com um significado. Para fornecer subsídios ao especialista, existem ferramentas para visualizar os *clusters* identificados no modelo.

## 1.4 Algoritmos de agrupamento

Será previamente estabelecido um critério de avaliação do algoritmo para saber se são necessárias novas divisões. Ao aplicar os dados obtidos no algoritmo escolhido, caso o parâmetro do modelo esteja em conformidade com as exigências dos critérios, a estrutura verdadeira de *clusters* pode ser encontrada.

As categorias em que foram divididos os algoritmos de agrupamento são: hierárquicos, particionais baseados em erro quadrático, baseados em densidade, baseados em grafo, baseados em redes neurais e baseados em *grid*. É possível que os algoritmos sejam enquadrados em mais de uma categoria.




### Assimile

Os algoritmos de agrupamento existentes apresentam diferentes formas de explorar e verificar estruturas presentes em um conjunto de dados

### 1.4.1 Algoritmo de agrupamento o hierárquico

Em um algoritmo de agrupamento hierárquico, cria-se uma hierarquia de relacionamentos entre os elementos e, assim, é gerada uma sequência de partições aninhadas. Existe a abordagem divisiva, na qual um *cluster* inicia com todos os objetivos, e a sequência é formada a partir da divisão sucessiva desse *cluster*. Na abordagem aglomerativa, no início, existe vários *clusters*, ou  $n$  *clusters*, com um único objeto. A sequência de partições é formada por meio do agrupamento de *clusters*. A seguir, a Figura 1 mostra um exemplo de aplicação dos algoritmos hierárquicos divisivo e aglomerativo.

FIGURA 1: FUNCIONAMENTO DOS ALGORITMOS HIERÁRQUICOS AGLOMERATIVOS E DIVISIVOS




FONTE: Facelli et al. (2011).

### 1.4.2 Algoritmos participais baseados em erro quadrático

Essa categoria consiste de um algoritmo de partição que otimiza o critério de agrupamento utilizando uma técnica iterativa. O passo inicial consiste na elaboração de uma partição inicial. Posteriormente, os objetos são movidos de um *cluster* para outro, com o objetivo de melhorar o valor do critério de agrupamento. Esses algoritmos são computacionalmente eficientes, porém podem convergir para um ótimo local, e não mostra o resultado considerando todo o domínio dos *clusters*.

O objetivo desse tipo de agrupamento é encontrar uma partição contendo  $k$  *clusters*, o que

minimiza  $E$  para um valor de  $k$  fixo. A partição resultante é denominada de partição de variância mínima. Por sua vez, minimizar essa função é um problema NP-hard (JAIN; DUBES; DUBES, 2010). Assim, os algoritmos dessa categoria são gulosos e podem convergir para ótimos locais. Com o erro quadrático, existe uma garantia da propriedade de compactação dos *clusters*.



#### Para saber mais

O erro quadrático médio é definido como sendo a média da diferença entre o valor do estimador e do parâmetro ao quadrado.

Um algoritmo  $k$ -médio divide um conjunto de dados em  $k$  *clusters*, no qual o valor de  $k$  é fornecido pelo usuário (DUDA; HART; STORK, 2001).

### 1.4.3 Algoritmos Baseados em Densidade

Esses algoritmos assumem que os *clusters* são regiões de alta densidade de objetos, separadas por regiões com baixa densidade, no espaço de objetos. Um *cluster* definido como um componente denso conectado, cresce em qualquer direção dada pela densidade (BERKHIN, 2002), de modo que esses algoritmos baseados em densidade podem resultar em *clusters* de formas arbitrárias, de difícil interpretação.

Um dos algoritmos de densidade é o algoritmo DENCLUE (do inglês, *DENSITY-based CLUstEring*). O algoritmo DENCLUE modela a densidade global de um conjunto de pontos, como o somatório de funções “influência” associadas a cada *cluster* (HINNEBURG; KEIM, 1998). Uma desvantagem desse algoritmo é que a função de densidade global resultante tem picos locais, os quais podem ser utilizados para definir *clusters*.

Além dos DENCLUE, também podem ser mencionados os algoritmos DBSCAN (do inglês, *Density-Based Spatial Clustering of Applications with Noise*) (ESTER *et al.*, 1996) e *Wave-cluster* (que também é baseado em *grid*) (SHEIKHOLESMANI; CHATTERJEE; ZHANG, 1998) como baseados em densidade.

## 1.4.4 Algoritmos Baseados em Redes Neurais

Redes neurais são sistemas paralelos distribuídos, compostos por unidades de processamento simples que computam determinadas funções matemáticas, sendo dispostas em uma ou mais camadas e interligadas por um grande número de conexões.

O algoritmo SOM (*Self-Organizing Map*) (KOHONEN, 2001) é uma rede neural artificial não supervisionada, usualmente utilizada em tarefas de agrupamento e visualização de dados. Trata-se do algoritmo mais tradicional dessa categoria.

## 1.4.5 Algoritmo baseado em *grid*

Esse grupo de algoritmos define um *grid* (reticulado) para o espaço de dados e realiza todas as operações nesse espaço reticulado. Em termos gerais, essa abordagem é muito eficiente para grandes conjuntos de dados, é capaz de encontrar *clusters* de formas arbitrárias e lida bem com outliers (FACELI, 2011).



### Para saber mais

**Outlier** Outlier é um dado observacional numericamente diferente. Em outras palavras, o outlier é consideravelmente diferente dos demais dados observados em determinada amostra.

Usado em estudos estatísticos, pode tanto apontar erros de medição, como também diagnosticar anormalidades.

## 1.5 Modelos Múltiplos Descritivos

A análise de agrupamento compreende diversos aspectos e possui uma série de complicações. Na tentativa de superar as limitações discutidas, várias abordagens que combinam diferentes agrupamentos, ou consideram distintos critérios de forma combinada, foram propostas na literatura. Essas abordagens se mostram robustas perante a diferentes conformações dos dados.

Os ensembles, por exemplo, são direcionados à obtenção de uma única estrutura que melhor se ajuste aos dados, além disso, necessitam de ajustes de parâmetros.

A combinação de estimadores independentes em comitês ou ensembles é uma técnica comumente empregada em problemas de classificação e regressão, a fim de melhorar a precisão de estimadores individuais, aproveitando as características intrínsecas de cada um.

## 1.6 Avaliação de Modelos Descritivos

A análise e a comparação de resultados em análise de agrupamento podem ser consideradas sob o ponto de vista de dois objetivos diferentes: avaliação e comparação de algoritmos de agrupamento e validação das estruturas encontradas por algoritmos de agrupamento. Esses dois objetivos possuem em comum o fato de estarem ligados ao tema de validação de agrupamentos.

Os critérios relativos comparam diversos agrupamentos com respeito a algum aspecto. Já critérios internos, estes mensuram a qualidade de um agrupamento com base apenas nos dados originais, isto é, na matriz de objetos ou na matriz de similaridade. Por sua vez, os critérios externos avaliam um agrupamento de acordo com uma estrutura estabelecida previamente, que pode refletir, por exemplo, na intuição do pesquisador sobre a estrutura presente nos dados.

### Questão para reflexão

Uma empresa do segmento de varejo construirá um modelo descritivo para representar sua base de clientes, separando os clientes pela receita do último ano. Como saber qual o melhor modelo para representar esses dados? Quais métricas podem ser utilizadas para comparar os modelos?

### Considerações finais

- Para obter informações do modelo, são verificados se os dados passados possuem padrões de comportamento e se as representações dos dados auxiliam na tomada de decisões.
- É possível mensurar os atributos tanto de forma qualitativa quanto de forma quantitativa.
- As categorias em que foram divididos os algoritmos de agrupamento são: hierárquicos, particionais baseados em erro quadrático, baseados em densidade, baseados em grafo, baseados em redes neurais e baseados em grid.

### Glossário

**Cluster bem separado:** conjunto de pontos de modo que qualquer ponto em um determinado *cluster* está próximo, ou é mais similar, a cada ponto nesse *cluster* do que qualquer ponto não pertencente a ele.



**Erro quadrático médio:** média da diferença entre o valor do estimador e do parâmetro ao quadrado.

**Outlier:** dado observacional consideravelmente diferente em termos numéricos das outras observações.

## Verificação de leitura

**QUESTÃO 1-** Com relação a definições de cluster, assinale V para as afirmativas verdadeiras e F para as falsas.

( ) *Cluster* bem separado é um conjunto de pontos de modo que qualquer ponto em um determinado *cluster* está próximo, ou é mais similar, a cada ponto nesse *cluster* do que qualquer ponto não pertencente a ele.

( ) *Cluster* baseado em centro considera um conjunto de pontos oriundos de dois *clusters* menores e que compartilham parte dos dados, de forma que esse ponto de compartilhamento é chamado de centro.

( ) *Cluster* contínuo ou encadeado, no qual um conjunto de pontos assim como qualquer ponto, em um dado *cluster*, está mais próximo a um ou mais pontos nesse *cluster* do que a qualquer outro que não pertence a ele.

( ) *Cluster* é baseado em densidade, em que o cluster será uma região densa de pontos, separada de outras regiões pela similaridade dos dados.

( ) *Cluster* baseado em similaridade, considera um conjunto de pontos similares, enquanto um ponto fora do *cluster* não é similar

Assinale a única alternativa que apresenta a sequência correta:

a) F – F – V – V – V

b) V – V – F – F – F

c) V – F – V – F – V

d) F – F – V – F – V

e) V – V – F – V – F .

**QUESTÃO 2-** Os algoritmos de agrupamento existentes apresentam diferentes formas de explorar e verificar estruturas presentes em um conjunto de dados e é possível que os algoritmos sejam enquadrados em mais de uma categoria. Assinale a alternativa que apresenta uma categoria de algoritmo de agrupamento NÃO existente:

- a) Algoritmo de agrupamento hierárquico.
  - b) Algoritmos participais baseados em erro sistemático.
  - c) Algoritmos baseados em densidade.
  - d) Algoritmos baseados em Redes Neurais.
  - e) Algoritmo baseado em espaço reticulado.
- 

**QUESTÃO 3-** Uma classe importante de métodos de mineração de dados são os modelos descritivos ou modelos de aprendizado não supervisionado. Com relação aos modelos descritivos, analise as afirmativas a seguir:

- I. São utilizados apenas dados históricos, com suas respectivas variáveis, para a construção de um modelo, e exige-se uma figura externa para guiar o aprendizado.
- II. Na modelagem de um processo de *Data Mining*, uma classe importante de métodos de mineração de dados são modelos de aprendizado supervisionado.
- III. Na análise de agrupamento, o aprendizado está focado nos dados e não são necessários conhecimentos anteriores sobre as classes ou as categorias que formarão os agrupamentos.
- IV. É possível mensurar os atributos apenas de forma quantitativa, usando, por exemplo, medidas estatísticas, como média e desvio padrão.
- V. A análise e a comparação de resultados em análise de agrupamento podem ser consideradas sob o ponto de vista de dois objetivos diferentes: avaliação e comparação de algoritmos de agrupamento e validação das estruturas encontradas por algoritmos de agrupamento

Assinale a única alternativa que compreende apenas as afirmativas corretas:

- a) Apenas II e IV.
  - b) Apenas I, II e V.
  - c) Apenas III e V.
  - d) Apenas III, IV e V.
  - e) Apenas I, III e IV.
-

## Referencias bibliográficas

- BARBARA, D. **An introduction to *cluster analysis for data mining***. 2000. Disponível em: <[http://www-users.cs.umn.edu/~han/dmclass/cluster\\_survey\\_10\\_02\\_00.pdf](http://www-users.cs.umn.edu/~han/dmclass/cluster_survey_10_02_00.pdf)>. Acessado em: 10 maio 2018.
- BERKHIN, Pavel. **Survey Of Clustering Data Mining Techniques**. São Jose: Accrue Software, 2002.
- DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification**. 2ª ed. Nova Jersey: Wiley-Interscience, 2001.
- ESTER, M.; KRIEGEL, H. P.; SANDER, J.; XU, X. A density-based algorithm for discovering *clusters* in large spatial databases with noise. In: SIMOUDIS, E.; HAN, J.; FAYYAD, U. **Proceedings of 2nd Int. Conf. on Knowledge Discovery and Data Mining**. Palo Alto: AAAI Organization, 1996, p. 226–231.
- FACELI, Katti *et al.* **Inteligência Artificial: Uma abordagem de aprendizagem de máquina**. Rio de Janeiro: LTC, 2011.
- HINNEBURG, A.; KEIM, D. A. An efficient approach to *clustering* in large multimedia databases with noise. In: AGRAWAL, R.; STOLORZ, P.; PIATETSKY, G. (Org.) **Proceedings of 4rd Int. Conference on Knowledge Discovery and Data Mining**. Barcelona: AAAI Press, 1998, p. 58–65.
- JAIN, A. K., DUBES, R. C. e CHEN, C.-C. Bootstrap techniques for error estimation. **IEEE – Transactions on Pattern Analysis and Machine Intelligence**, v. 9, n. 5, p. 628–633, 1987.
- KOHONEN, Teuvo. **Self-Organizing Maps**. Berlin: Springer, 2001.
- MITCHELL, Tom M. **Machine Learning**. Nova York: McGraw-Hill, 1997.
- SHEIKHOESLAMI, G.; CHATTERJEE, S.; ZHANG, A. WaveCluster: A multi-resolution *clustering* approach for very large spatial databases. In: GUPTA, A.; SHMUELI, O.; WIDOM, J. **Proceedings of the 24th International Conference on Very Large Data Bases**. New York: ACM Press, 1998, p. 428–439.
- TURBAN, Efraim *et al.* **Business intelligence: um enfoque gerencial para a inteligência do negócio**. Porto Alegre: Bookman, 2009.

## GABARITO

**QUESTÃO 1-** Resposta C: A segunda e a quarta afirmativa são falsas, pois um *cluster* baseado em centro considera um conjunto de pontos, de forma que qualquer ponto, em um dado *cluster*, está mais próximo ao centro desse *cluster* do que ao centro de qualquer outro; um *cluster* baseado em densidade, considera que o *cluster* será uma região densa de pontos, separada de outras regiões de alta densidade e por regiões de baixa densidade.

-----

**QUESTÃO 2-** Resposta B: As categorias em que foram divididos os algoritmos de agrupamento são: hierárquicos, particionais baseados em erro quadrático (e não sistemático), baseados em densidade, baseados em grafo, baseados em redes neurais e baseados em *grid* (espaço reticulado).

-----


**QUESTÃO 3-** Resposta C. Apenas as afirmativas III e V estão corretas.

A afirmativa I está incorreta porque, na verdade, inexiste uma figura externa para guiar o aprendizado.

A afirmativa II está incorreta, pois na modelagem de um processo de *Data Mining*, são empregados os modelos descritivos ou modelos de aprendizado não supervisionado.

A afirmativa IV está incorreta, pois é possível mensurar os atributos tanto de forma qualitativa quanto de forma quantitativa. As tarefas descritivas possuem diferentes fases, tais como: sumarização, associação e agrupamento. Nessas etapas, podem ser aplicadas desde medidas estatísticas mais rudimentares, como média e desvio padrão, até complexas técnicas de visualização dos relacionamentos existentes entre atributos

-----



**5**

**Modelos  
predictivos**

## Objetivos Específicos

- Apresentar o conceito de modelos preditivos e as classes de classificação e regressão.
- Explicar o funcionamento dos modelos baseados em distância.
- Elucidar sobre o funcionamento dos modelos probabilísticos.
- Apresentar o funcionamento dos modelos baseados em procura.

## Introdução

As duas classes de métodos de mineração de dados são os modelos descritivos e os modelos preditivos (FACELI *et al.*, 2011). Um modelo preditivo, também conhecido como aprendizado supervisionado, utiliza dados de histórico, chamados de conjunto de treinamento, para criar uma função que estima o valor de  $f(x)$  dado um valor de  $x$  que não estava no conjunto original. Os modelos preditivos podem ser divididos em classes de classificadores e regressores, dependendo do domínio dos valores da variável de entrada. O erro mínimo de um classificador é conhecido como erro de Bayes.

Um dos métodos preditivos é baseado na distância, que pode considerar apenas o vizinho mais próximo ou  $k$  vizinhos mais próximos. Adicionalmente, existem métodos probabilísticos que consideram a probabilidade condicional, o Teorema de Bayes. A forma gráfica para representação de modelos probabilísticos é chamada de Redes de Classificação Bayesiana. Um outro tipo de modelo é o baseado em Busca, no qual existe árvore de decisão, árvore de regressão e modelos baseados em regras (FACELI *et al.*, 2011).

Uma árvore de decisão utiliza a estratégia de dividir para conquistar, e os nós representam, nesse caso, elementos e os ramos os critérios de decisão. Por sua vez, uma regra de decisão representa uma implicação. Para métodos de otimização, as técnicas mais difundidas são as Redes Neurais Artificiais (RNA) e as máquinas de vetores de suporte.

# 1. métodos preditivos e classes

Existem duas classes de métodos de mineração de dados: os modelos descritivos e os modelos preditivos. Nos modelos descritivos, são utilizados apenas dados históricos, com suas respectivas variáveis, para a construção de um modelo. Além disso, inexistente uma figura externa para guiar o aprendizado.

Por sua vez, um algoritmo de aprendizado de máquina preditivo, também conhecido como aprendizado supervisionado, é representado por uma função que constrói um estimador com base em um conjunto de dados rotulados.

Uma definição formal de modelo preditivo é dada a um conjunto de observações de pares ordenados  $(x_i, f(x_i))$  para os diversos pontos em que  $f(x)$  é a função dada pelo algoritmo preditivo, que aprende uma aproximação de  $f(x)$ , permitindo a estimativa dos valores de  $f(x)$  para outros valores de  $x$  que não estavam presentes no conjunto anterior.

Os rótulos indicam o domínio dos valores. Caso o domínio consistir em conjuntos finitos de valores nominais, como os meses do ano no formato de texto, existe um problema de classificação, e o estimador a ser gerador é um classificador. Entretanto, se os domínios forem um conjunto infinito de valores numéricos, ocorre uma regressão, e o estimador é chamado de regressor. Tanto um classificador como um regressor são funções que dado um valor, não rotulado atribuem a este uma das possíveis classes ou um valor real, respectivamente (DIETTERICH, 1998).




## Exemplificando

A Figura 1, a seguir, exemplifica os dois tipos de classes de funções: classificação (gráfico a) e regressão (gráfico b). Na Gráfico (a) ou classificação, com base no resultado em dois exames, os pacientes são separados em duas classes: classe saudável e classe doente. Isso é obtido por meio da fronteira de decisão, a partir da qual o paciente muda em classe, com um pequeno deslocamento do resultado dos exames, que será calculado por meio dos modelos preditivos, e a determinação dessa fronteira é o foco da implementação desse tipo de modelo.

Por sua vez, o gráfico (b), exemplifica uma regressão cujo objetivo é encontrar a função que melhor descreve o comportamento da vazão média da água de um determinado rio, medida no decorrer de diversos anos. No caso, existe uma variável dependente, a vazão em que será feita a regressão, e uma independente, o tempo em anos. Também é possível realizar regressões com múltiplas variáveis, o que irá formar superfícies na regressão.

FIGURA 1. EXEMPLOS DE CLASSES DE MODELOS PREDITIVOS: (A) CLASSE DE CLASSIFICAÇÃO E (B) CLASSE DE REGRESSÃO



FONTE: Faceli et al. (2011, p. 55).

Os dados podem estar representados em forma de tabela ou em forma gráfico. A função  $f$  pode ser de variadas formas, por exemplo, pode ser representada por combinações lineares, ou seja, somas de atributos de entradas multiplicados por constantes; combinações não lineares, quando os multiplicadores não são constantes; expressões lógicas; e funções por ramos.

Para compreender um problema de classificação, assuma que é conhecida a função densidade de probabilidade (fpd). É possível dividir em duas classes e elaborar fpd para cada classe. O melhor




classificador possível é aquele que divide as fdp's no ponto de intersecção. Desse modo, classifica um objeto conforme sua maior probabilidade.

Esse classificador possui um erro mínimo, pois movendo em qualquer direção, o erro cresce sempre. Esse erro mínimo é conhecido como erro de Bayes ótimo e é um mínimo teórico da capacidade de generalização de classificadores.

## 1.1 Métodos baseados em distância

Uma das técnicas de aprendizado de máquina é baseada na proximidade dos dados na realização de predições. A premissa é que os dados similares se concentrem em uma mesma região do espaço das variáveis de entrada. Já dados não similares, estão distantes entre si.

O algoritmo mais simples dessa técnica é chamado de algoritmo dos vizinhos mais próximos, que classifica um novo ponto, baseado no conjunto de dados próximos a ele, utilizados no treinamento. Esse algoritmo apenas memoriza os objetos de treinamento, não aprende um modelo compacto para os dados. Sendo assim, é considerado um algoritmo preguiçoso (*lazy*). Um benefício é que pode ser aplicado tanto em questões de regressão como em questões de classificação, com apenas pequenos ajustes, segundo Faceli *et al.* (2011).



### Para saber mais

**Função densidade de Probabilidade:** seja  $X$  uma variável aleatória contínua. A função de densidade de probabilidade (f.d.p.)  $f(x)$  é uma função que satisfaz as seguintes condições:

❶  $f(x) \geq 0, \quad \forall x \in R_x$

❷  $\int_{-\infty}^{+\infty} f(x)dx = 1$

❸ Sejam  $a$  e  $b$  quaisquer no intervalo,  
 $-\infty < a < b < +\infty$  temos que

$$P(a \leq X \leq b) = \int_a^b f(x)dx$$

Figura 2: Condições da função densidade de probabilidade  
Fonte: Pires (2014, p. 19)



### Assimile


O erro de Bayes ótimo é um classificador que atribui a classe de maior probabilidade de fdp e possui o menor erro como classificador.

Dependendo do número de vizinhos, o algoritmo dos vizinhos mais próximos possui variações. No algoritmo mais simples, é considerado apenas um elemento da vizinhança, esse algoritmo é chamado de 1-Vizinho mais próximo (1-NN, do inglês: 1-Nearest Neighbour).

Inicialmente, existe uma fase de treinamento, na qual o algoritmo armazenará os resultados obtidos, que fazem parte do conjunto de treinamento. Para classificar um elemento que ainda não esteja rotulado, calcula-se a distância entre esse ponto e o vetor de valores. O ponto de treinamento que estiver com a menor distância, em relação ao elemento não rotulado, será o vizinho mais próximo, e a classificação do elemento não rotulado será dada pela classificação do vizinho mais próximo (FACELI *et al.*, 2011).

Verifica-se que é um algoritmo bastante simples, entretanto as superfícies de decisão desenhadas pelo algoritmo 1-NN não são elementares e são representadas por poliedros convexos, com centro em cada objeto do conjunto de treinamento. O conjunto desses poliedros é chamado de diagrama de Voronoi.

**FIGURA 3: DIAGRAMA DE VORONOI**



É possível estender o algoritmo 1-NN, para considerar os  $k$  vizinhos mais próximos em vez de considerar somente o vizinho mais próximo. Com isso, serão utilizados os  $k$  objetos do conjunto de treinamento mais próximos do ponto de teste  $x_t$ , em que  $k$  é um parâmetro de entrada do algoritmo.

Objetos com características semelhantes pertencem ao mesmo grupo. Por sua vez, o algoritmo de treinamento consiste apenas em armazenar objetos.

O  $k$ -NN constrói aproximações locais da função objetivo, diferentes para cada novo dado a ser classificado. Essa característica pode ser vantajosa quando a função objetivo é muito complexa, mas ainda pode ser descrita por uma coleção de aproximações locais de menor complexidade (MITCHELL, 1997).


Esse algoritmo é aplicável mesmo em problemas de alta complexidade e, ao passo que novos pontos de treinamento são inseridos, o modelo considerará esse novo conjunto, funcionando de forma incremental. Para um número infinito de objetos, o erro do 1-NN é majorado pelo dobro do erro do Bayes ótimo, e o erro do  $k$ -NN tende para o erro do Bayes ótimo.

O algoritmo de vizinhos mais próximos possui, entretanto, desvantagens em relação a não obter uma representação compacta dos objetos. Adicionalmente, a fase de treinamento só inclui a memorização dos dados e pouco processamento. Para classificar um objeto, é necessário calcular a distância do objeto em relação a todos os elementos do conjunto de treinamento, que já pode ter armazenado muitas informações. Dessa forma, computacionalmente, a predição pode ser custosa, e para um conjunto grande de objetos, esse processo pode ser lento.

O número de atributos define a quantidade de dimensões do espaço e existem trabalhos de pesquisa relacionados ao algoritmo  $k$ -NN que investigam a redução do espaço do problema.

## 1.2 Métodos Probabilísticos

Os métodos probabilísticos bayesianos consideram que a probabilidade de ocorrência de um evento  $A$ , dado um evento  $B$ , não depende apenas da relação entre  $A$  e  $B$ , mas também da probabilidade de observar  $A$ , independentemente de observar  $B$ . O evento  $A$  pode ser uma classe, por exemplo, um aluno aprovado, e o evento  $B$  pode ser um atributo de entrada, por exemplo, as notas obtidas por esse aluno.



O modelo probabilístico quantitativo é representado por tabelas com a distribuição das variáveis. Já um modelo probabilístico gráfico é implementado pelo modelo qualitativo, um grafo cujos nós representam as variáveis.

Dos classificadores bayesianos, o mais popular é o *naive Bayes*. O termo *naive* é derivado da hipótese de que os valores dos atributos de um exemplo são independentes de sua classe. Nesse modelo, um problema de duas classes, definido por atributos booleanos, é um hiperplano. Assim, a superfície de decisão é linear.

O modelo *naive Bayes* possui bom desempenho em diversos domínios, mesmo quando existe dependência entre os atributos. Além disso, não é sensível a características irrelevantes e lida bem com dados reais, contínuos e discretos. Um ponto negativo, para esse modelo, é que se assume uma independência das características, de acordo com Faceli *et al.* (2011).

#### Para saber mais

O Teorema de Bayes é usado para calcular a probabilidade a posteriori de um evento, sua probabilidade e sua verossimilhança do novo dado. O teorema é baseado na probabilidade condicional, colocada a seguir.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Assim, é possível chegar no teorema de Bayes, que é dado por:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

## 1.2.1 Rede Bayesianas para Classificação

Há independência condicional quando existe uma relação estatística entre duas variáveis e quando uma terceira variável é conhecida. Matematicamente, X é, condicionalmente, independente de Y dado a Z, se  $P(X|Y,Z) = P(X|Z)$ .

Os modelos gráficos probabilísticos ou redes bayesianas, com base no conceito de independência condicional, verificam quais os parâmetros a serem utilizados e qual a representação de dependência entre as entradas.

Pode ser apresentado como um modelo qualitativo, denominado como grafo acíclico direcionado, cujos nós representam as variáveis e um modelo quantitativo, com tabelas de distribuição da variável resposta, dadas as outras variáveis que podem modificá-la.

Um arco entre dois nós denota influência ou correlação. O conjunto de variáveis aleatórias, nós do grafo, que influenciam uma variável resposta  $y_i$  é conhecimento, como Pais de  $y_i$ .

A dificuldade na escolha da estrutura para uma determinada questão está ligada à seleção de modelos, verificando entre diversos modelos possíveis que “melhor se ajustam” em relação ao conjunto de dados de treinamento. De certa forma, existe um problema de busca, no qual as propostas de modelos são avaliadas por meio de uma função de pontuação, a qual mede a qualidade de cada hipótese candidata.

No extremo mais geral, temos classificadores que assumem que todos os atributos interagem entre si. Entre os dois extremos, temos modelos de granularidade crescente. É possível utilizar os modelos gráficos probabilísticos em diferentes tarefas de aprendizado, desde previsão, em que se deseja obter o resultado mais provável para os dados de entrada, até o diagnóstico, em que se pretende encontrar as causas mais prováveis para os efeitos observados.

## 1.3 Métodos baseados em procura

É possível organizar o problema de aprendizado com uma procura em um espaço de diversas soluções possíveis. Por esse raciocínio, é possível construir modelos baseados em árvores, tanto uma árvore de decisão quanto uma árvore de regressão e modelos baseados em regras.

### 1.3.1 Árvore de Decisão e Regressão

Em uma árvore de decisão, para a resolução de um problema, utiliza-se a estratégia de dividir para conquistar, quebrando um problema complexo em problemas mais simples recursivamente, até que existam problemas simples de solução já conhecida. Os algoritmos ID3, Assistant e CART são exemplos de algoritmos baseados em árvores de decisão.

Um nó folha é rotulado com uma função. Um nó de divisão contém um teste condicional baseado nos valores do atributo. Cada nó da árvore corresponde a uma região nesse espaço. As regiões definidas pelas folhas da árvore são mutuamente excludentes, e a reunião dessas regiões cobre todo o espaço definido pelos atributos.

O espaço de hipóteses das árvores de decisão é enquadrado no formalismo: Forma Normal Disjuntiva (FND). Uma fórmula estará na forma normal disjuntiva quando for:  $A \vee A$  ou apenas  $A$ . Para cada FND, as condições ao longo de um ramo são conjunções de condições, já os ramos individuais são disjunções.

As árvores de decisão possuem diversas vantagens e são aplicadas tanto no meio acadêmico como no meio empresarial. Uma vantagem é que não é necessário assumir nenhuma distribuição dos dados, sendo o modelo muito flexível. Adicionalmente, as árvores de decisão são muito robustas e selecionam os atributos que farão parte do modelo de decisão. Além disso, possuem fácil interpretação e, por ser um algoritmo guloso, é construído de cima para baixo e utiliza a estratégia de dividir para conquistar.

Se um dos atributos não for conhecido, no entanto, podem surgir problemas de decisão. Também pode ocorrer uma duplicação de testes em diferentes ramos da árvore. Dependendo dos dados de entrada, o modelo obtido pode não ser estável.

## 1.3.2 Regras de Decisão

Uma regra de decisão representa uma implicação, descrito como: **se A então B**. O termo condicional pode ser uma junção de condições. Em uma condição, existe uma relação entre um atributo e os valores do seu domínio.

Cada regra cobre certa região do espaço das instâncias. As regras de decisão removem condições em uma regra sem remover outra regra e perdem a distinção entre testes perto da raiz e perto das folhas.

Martin (1997) agrupa as medidas nas seguintes categorias das chamadas funções de mérito: Medidas de função de impureza, medidas para enfatizar a disparidade dos subconjuntos e medidas estatísticas de independência.

Entropia mede a aleatoriedade de uma variável aleatória. A poda de uma árvore é



### Exemplificando

Idade  $\geq 18 \vee$  Passou teste motorista = Sim  $\rightarrow$  Carta de Motorista = Sim

Celular = Pré-Pago  $\vee$  Saldo = 0  $\rightarrow$  Ligação efetuada = Não

a troca de nós profundos por folhas. Também pode ser entendida quando serão removidos os sub-nós de um nó de decisão. Poda é considerada a parte mais importante do processo de construção da árvore, pelo menos em domínios com ruídos. Holte (1993) implementou o algoritmo OneR, do inglês OneRule, o qual constrói regras baseadas em um atributo único.

## 1.4 Métodos baseado em otimização

Em problemas de otimização, a meta é maximizar ou minimizar o valor de uma função objetivo. As duas técnicas mais difundidas em aprendizado de máquina, que utilizam otimização de uma função em seu treinamento, são: as Redes Neurais Artificiais (RNA) e as máquinas de vetores de suporte, do inglês *Support Vector Machine* (SVM).

Uma RNA é um sistema computacional distribuído que consiste em unidades de processamento interconectadas, com alta densidade e simples. Essas unidades são denominadas neurônios artificiais e realizam o processamento de funções matemáticas. As unidades são dispostas em camadas e interligadas por numerosas conexões. Essas conexões simulam as sinapses biológicas e têm pesos associados, que ponderam a entrada recebida por cada neurônio da rede. Esses pesos podem ter valores positivos ou negativos, dependendo do comportamento da conexão, e seus valores são ajustados pelo processo de aprendizado (MITCHELL, 1997).

As SVMs possuem suas origens na aplicação de conceitos da Teoria de Aprendizados Estatístico (TAE). A TAE determina condições matemáticas que auxiliam na escolha de um classificador particular, a partir de um conjunto de dados de treinamento (FACELI *et al.*, 2011).

### Questão para reflexão

Considerando um conjunto de dados numéricos em uma empresa no setor de vendas, como saber qual método preditivo aplicar para obter o menor erro na predição para as vendas nos próximos dois meses?

## Considerações Finais

- Para um modelo preditivo, é dado um conjunto de observações de pares ordenados  $(x_i, f(x_i))$  para os diversos pontos em que  $f(x)$  é a função dada pelo algoritmo preditivo, o qual aprende uma aproximação de  $f(x)$ , estima-se os valores de  $f(x)$  para outros valores de  $x$  que não estavam presentes no conjunto anterior.
- Os principais tipos de modelos preditivos são: métodos baseados em distância, métodos probabilísticos, métodos de procura e métodos de otimização.
- Um dos métodos preditivos é baseado na distância, que pode considerar apenas o vizinho mais próximo ou  $k$  vizinhos mais próximos.
- Outros tipos de modelos são os baseados em Busca, no qual existem árvore de decisão, árvore de regressão e modelos baseados em regras. Uma árvore de decisão utiliza a estratégia de dividir para conquistar, e os nós representam elementos e os ramos os critérios de decisão.
- Para métodos de otimização, as técnicas mais difundidas são as Redes Neurais Artificiais (RNA) e as máquinas de vetores de suporte.

## Glossário

**Redes Neurais Artificiais (RNA):** técnicas computacionais que apresentam um modelo matemático inspirado na estrutura neural de organismos inteligentes e que adquirem conhecimento por meio da experiência.

**Diagrama de Voronoi:** conjunto dos poliedros de decisão de um algoritmo do método de distância com um vizinho.

**Erro de Bayes ótimo:** menor erro possível em um sistema de classificação.



## Verificação de leitura

**QUESTÃO 1-** Classifique os métodos das seguintes técnicas de modelos preditivos: Redes Neurais e Árvore de Decisão.

- a) Baseados em Otimização; baseados em Distância.
  - b) Probabilístico; baseados em Otimização.
  - c) Baseados em Otimização; baseados em Procura.
  - d) Baseados em Distância; Probabilístico.
  - e) Baseados em Otimização; baseados em Otimização.
- 

**QUESTÃO 2-** A técnica de árvores de decisão utiliza uma abordagem de cima para baixo, ou seja, top-down e possui uma estratégia computacional. Qual é essa estratégia?

- a) Explorar todos os casos.
  - b) Dividir para conquistar.
  - c) Programação orientada a objeto.
  - d) Fazer tudo de uma única vez.
  - e) O pré-processamento é simples, só armazena as informações.
- 

**QUESTÃO 3-** Em relação ao método baseado em distâncias com a técnica do vizinho mais próximo, assinale a alternativa correta.

- a) O algoritmo é de fácil implementação.
  - b) O erro é minimizado com esse algoritmo.
  - c) A superfície de decisão é composta por círculos.
  - d) Não é possível fazer com mais de 1 vizinho.
  - e) A fase de treinamento é muito complexa computacionalmente.
-

## Referências Bibliográficas

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895-1924, 1998.

FACELI, Katti *et al.* **Inteligência Artificial: Uma abordagem de aprendizagem de máquina**. Rio de Janeiro: LTC, 2011.

HOLTE, R. C. Very simple classification rules perform well on most commonly used datasets. **Machine Learning**, v. 11, p. 63-91, 1993.

MARTIN, J. An exact probability metric for decision tree splitting and stopping. **Machine Learning**, v. 28, p. 257-291, 1997.

MEDEIROS, Anderson. Diagrama de Voronoi e suas aplicações em SIG. **Anderson Medeiros: Consultor em Geotecnologias**, 2 jan. 2013. Disponível em: <<http://www.andersonmedeiros.com/diagrama-de-voronoi-aplicacoes-sig/>>. Acesso em: 10 maio 2018.

MITCHELL, Tom M. **Machine Learning**. Nova York: McGraw-Hill, 1997.

PIRES, Juliana Freitas. **Cálculo de Probabilidades e Estatística I**, Universidade Federal da Paraíba. 2014. Disponível em <<http://www.de.ufpb.br/~juliana/Calculo%20das%20Probabilidades%20e%20Estatistica%20I/Aula3.pdf>>. Acesso em: 10 maio 2018.

## Gabarito

### QUESTÃO 1- Resposta C.

Redes Neurais Artificiais são uma técnica de métodos de otimização. Árvores de decisão são técnicas de modelos de busca.

-----

### QUESTÃO 2- Resposta B.

É utilizada a Estratégia de Dividir para conquistar, o que consiste em dividir um problema complexo em problemas mais simples.

-----

### QUESTÃO 3- Resposta A.

O algoritmo é bem simples e está em diversos livros.

-----



# 6

**Análise de  
negócios e  
visualização  
de dados I**

## Objetivos Específicos

- Descrever a análise de negócios ou *Business Analysis* (BA) e a sua importância para as organizações.
- Apresentar e descrever sucintamente os principais métodos e ferramentas de BA.
- Compreender as razões pelas quais o processamento analítico online ou *OnLine Analytical Processing* (OLAP), a visualização de dados e a multidimensionalidade podem melhorar a tomada de decisões.

## Introdução

O volume de informações que as empresas possuem aumentou exponencialmente nos últimos anos, mas ter os dados não é suficiente. É necessário analisá-los de forma automatizada para que esses dados se transformem em informações e estas se transformem em conhecimento. A Análise de Negócios ou *Business Analysis* (BA) compreende uma ampla gama de aplicações e técnicas para reunir, armazenar, analisar e fornecer acesso aos dados, com o objetivo de ajudar os usuários da empresa a tomarem melhores decisões operacionais, comerciais e estratégicas.

A BA é conhecida também como processamento analítico, ferramentas de BI, aplicações de BI e simplesmente BI. Pode-se dividir as ferramentas de BA em três grupos: descoberta de informações e conhecimento, suporte à decisão e sistemas inteligentes e visualização. Os sistemas OLAP se enquadram no grupo de descoberta de informações e conhecimento e se referem a uma grande quantidade de atividades normalmente executadas por usuários finais no ambiente online. Inclui como suas atividades a geração e a resposta de consultas, solicitações de relatórios e gráficos *ad hoc* e a execução deles. Os tipos de sistemas OLAP são: ROLAP, MOLAP, HOLAP, DOLAP e WOLAP.

Uma característica fundamental de sistemas OLAP é ser capaz de filtrar os dados por diversas formas e modos customizados pelo usuário. Podem, ainda, sumarizar o conteúdo em uma estrutura chamada de cubo OLAP. Existem algumas funcionalidades em um sistema OLAP para manipulação dos dados como: *slide-dice*, *drill-up*, *drill-down*, *drill-across* e *drill-through*.

# 1. Análise de negócios e visualização de dados

Conforme já visto anteriormente, a inteligência de negócios ou *Business Intelligence* (BI) implica em obter dados e informações, se possível transformando informações em conhecimento, de uma grande variedade de fontes, e organiza-los em um *Data Warehouse* para usá-los na tomada de decisões.

Por sua vez, a Análise de Negócios ou *Business Analysis* (BA) compreende uma ampla gama de aplicações e técnicas para reunir, armazenar, analisar e fornecer acesso aos dados, com o objetivo de ajudar os usuários da empresa a tomarem melhores decisões operacionais, comerciais e estratégicas (TURBAN *et al.*, 2009). A BA é conhecida, ainda, como *processamento analítico, ferramentas de BI, aplicações de BI* e simplesmente BI.

A BA oferece os modelos e procedimentos de análise para a BI. Existem muitos métodos e centenas de ferramentas de *software* para conduzir análises.

Uma aplicação analítica é um passo rumo ao refinamento, em relação ao simples oferecimento de técnicas ou ferramentas de análise. Essa aplicação permite atividades como:

- automatização do processamento e, na maioria dos casos, de uma parte da tomada de decisões de um ser humano;
- uso disseminado de técnicas quantitativas complexas, como análise de Regressão multivariada, *Data Mining*, Inteligência Artificial ou Programação não linear.

As soluções de *Business Intelligence* são compostas por uma série de componentes tecnológicos que possibilitam um ambiente propício para tomada de decisão. Essas soluções podem combinar os componentes para cada situação. Para a camada de apresentação dos dados e das informações, utilizam-se as soluções OLAP (*OnLine Analytical Processing*), isto é, processamento analítico online.

As soluções OLAP apresentam uma alternativa para a publicação dos dados e informações vindas dos modelos dimensionais. A apresentação dessas informações pode ser de maneira tabular ou gráfica, tanto dos dados históricos, armazenados nos repositórios *Data Warehouse*, quanto dos dados reais para auxiliar o processo decisório.

Ao usar *software* para BA, o usuário pode fazer consultas, requisitar relatórios ad hoc ou realizar análises. É possível, por exemplo, fazer análises executando consultas em várias camadas.


As aplicações mais sofisticadas de BA, que estão no chamado estado-da-arte, incluem atividades como modelagem financeira, orçamentos, alocação de recursos e inteligência competitiva. Tais sistemas avançados de BA envolvem componentes como modelos de decisão, análise do desempenho dos negócios, perfis de dados, métricas, ferramentas de reengenharia e podem ser usados em tempo real.

Ao identificar o cliente, por meio de uma aplicação analítica, com enfoque na parte comercial, pode surgir uma tela que, além das informações de cadastrado, pode conter as últimas compras e visitas desse cliente, bem como os produtos que ele tem maior propensão de compra.

## 1.1 Tipos de ferramentas de BA

A BA emprega um grande número de ferramentas e técnicas de análise. *Podemos dividi-las em três grandes categorias, conforme apresentado na Figura 1 a seguir. A primeira categoria é a descoberta de informações e conhecimento, que contempla as ferramentas OLAP, a ser detalhada posteriormente: consultas e relatórios ad hoc, data mining, web mining, text mining e mecanismos de busca. A segunda categoria é o suporte à decisão e sistemas inteligentes, como exemplo: inteligência artificial, análise estatística, análises preditivas, suporte executivo e corporativo. A última categoria é visualização, que contempla análise visual, dashboards, scorecards e realidade virtual 3D.*

FIGURA 1: CATEGORIAS DE ANÁLISE DE NEGÓCIOS



FONTE: Turban et al. (2009, p. 103).

Os fornecedores possuem diferentes formas de classificação das ferramentas de BA.

Diversas empresas de diferentes segmentos de negócios e espalhadas por todo o mundo utilizam ferramentas de *Business Analytics*. O elemento Exemplificando abaixo mostra como a Nestlé utilizada BA para previsão de demandas com ferramentas analíticas do SAS.



## 1.2 OLAP

Uma arquitetura de *Business Intelligence* é composta por vários componentes, os quais podem ser combinados para que se obtenha a melhor solução para o problema em questão da organização.

Após finalizar a concepção dos repositórios de dados, o próximo passo é identificar qual a melhor abordagem para consumir os dados, bem como apresentar as informações e conhecimentos descobertos.

Usualmente, podem-se utilizar duas abordagens diferentes para a etapa de consumo e processamento, transformando os dados em informações e conhecimento para, posteriormente, o seu processamento. As abordagens citadas são:

- **Mineração de dados (*Data Mining*)**: técnicas e ferramentas com base na Estatística ou de Inteligência Artificial, as quais possuem como função explicitar os conhecimentos implícitos, seja nos repositórios ou nos seus documentos.

- **Sistemas OLAP**: sigla para a expressão **Processamento Analítico Online** (em inglês:



### Link

Existem vários fornecedores de ferramentas de BA como:

- Microstrategy.
- SAP, empresa líder em software empresarial.
  - O SAS, empresa líder global de solução de *Analytics*.



### Exemplificando

A Nestlé, empresa multinacional, com unidades de negócio também no Brasil, possui um contrato global com a SAS. A solução apoia o processo de aquisição de recursos voltados para inteligência analítica. O objetivo da estratégia supracitada é aprimorar o planejamento de demandas, de modo que seja possível prever a necessidade impressa na cadeia de suprimentos, bem como o faturamento de cada período.

Outro ganho, com o planejamento de demanda assertivo, diz respeito aos parâmetros utilizados no plano de produção em cada uma das fábricas da empresa, tais como: ocupação de linhas, definição de mão de obra, reposição de insumos etc.


Com a utilização de análises preditivas, a empresa atingiu 9% de taxa de melhoria na adequação dos planos de produção, possibilitando trabalhar com inventários menores.

*Online Analytical Processing*). Esses sistemas se referem a uma grande quantidade de atividades, normalmente executadas por usuários finais no ambiente online. Inclui como suas atividades a geração e a resposta de consultas, solicitações de relatórios e gráficos *ad hoc* e a execução deles (TURBAN *et al.*, 2009).

O processamento OLAP, aplicado pelas ferramentas de apoio à decisão, possibilita a navegação de forma amigável pelo modelo multidimensional do *Data Warehouse*. Tal fato é importante para a transformação de informação em conhecimento.

A distinção entre OLAP e Mineração de Dados vai além das distinções entre dados de resumo e detalhes. As funções ou algoritmos normalmente encontrados em ferramentas OLAP são funções de modelagem descritiva. No caso da mineração de dados, são funções de descoberta de padrão e modelagem explicativa (THOMSEN, 2002).

Existem funções e algoritmos utilizados pelos sistemas OLAP que podem ser classificados em: agregação, alocações, razões, produtos, entre outros.



#### Para saber mais

As ferramentas desenvolvidas para Business Intelligence (BI) que, a partir dos dados coletados, realiza categorizações, classificações, organizações, filtros e processamentos para uma organização são chamadas de Mineração de Dados ou Data Mining.



#### Assimile

O termo OLAP (*Online Analytical Processing*) se refere à tecnologia de processamento analítico, que é designada para obter novas informações de negócio por meio de um conjunto de transformações e cálculos executados sobre as fontes de dados.

## 1.3 Tipos de OLAP


As formas de processamento OLAP variam, principalmente conforme o tipo de armazenamento de dados utilizado. Os principais tipos de OLAP são:

- **OLAP multidimensional (MOLAP):** *quando o OLAP é implementado por meio de um banco de dados multidimensional especializado, ele é chamado de OLAP multidimensional (MOLAP), porque resume transações em visões multidimensionais com antecedência. Os dados são organizados em uma estrutura de cubos que o usuário pode girar, o que é adequado principalmente a resumos financeiros. Com o MOLAP, as consultas são mais rápidas, pois a consolidação já foi feita.*
- **OLAP relacional (ROLAP):** *quando um banco de dados OLAP é implementado sobre um banco de dados relacional existente, ele é chamado de OLAP relacional (ROLAP). As ferramentas do OLAP relacional extraem dados de bancos de dados relacionais. Ao usar declarações de SQL complexas em relação a tabelas relacionais, o ROLAP pode também criar visões multidimensionais dinamicamente. O ROLAP tende a ser usado em dados que apresentam um grande número de atributos, em que não possam ser colocados facilmente em uma estrutura de cubos. Os dados do cliente com diversos campos descritivos, por exemplo, ao contrário dos dados financeiros, são normalmente candidatos a ROLAP.*
- **Database OLAP e Web OLAP (DOLAP e WOLAP):** o database OLAP se refere a um sistema de gerenciamento de banco de dados relacional (SGBDR), projetado para hospedar estruturas e executar cálculos de OLAP. O Web OLAP se refere aos dados de OLAP acessíveis de um navegador da Web.
- **Desktop OLAP.** o desktop OLAP envolve ferramentas OLAP simples e baratas, que executam análise local multidimensional e apresentação de dados baixados de bancos de dados relacionais ou multidimensionais para as máquinas do cliente. Versões da Web movem, constantemente, o processamento de desktop para um servidor intermediário, o que aumenta a escalabilidade, no entanto, na melhor das hipóteses, a funcionalidade é *comparável à versão de desktop*.
- **Hybrid OLAP (HOLAP):** o Híbrido OLAP combina as formas ROLAP e MOLAP, ou seja, as formas relacional e multidimensional.

## 1.4 Características do OLAP

Uma principal característica que está presente em todas as abordagens é o cubo multidimensional, capaz de filtrar os dados por diversas formas e modos customizados pelo usuário e podem sumarizar o conteúdo em uma estrutura denominado também cubo OLAP ou hipercubo (CECI, 2012). A Figura 2 ilustra uma representação de um cubo tridimensional. Essa estrutura estabelece um formato em que perspectivas de visualização de informações podem ser facilmente criadas conforme a interação com o usuário.

FIGURA 2: EXEMPLO DE CUBO MULTIDIMENSIONAL



FONTE: Gouveia e Ranito (2011, p. 134).

Além da visão multidimensional dos dados e dos Cubos OLAP, é possível a realização de sumarização e agregação de dados. Existe capacidade de consultas e análises interativas sobre o retorno dos dados, bem como suporte para que os analistas de negócio customizem suas próprias consultas, relatórios e cálculos.

Por muito tempo, o foco dos sistemas de TI era, principalmente, o processamento de transações corporativas. O processamento de transações online (OLTP) ofereceu uma solução eficaz, para tarefas repetitivas e rotina, usando um ambiente de banco de dados relacional distribuído. Tanto as aplicações de OLTP quanto de sistemas de suporte a *gerência (MSS) necessitam de acesso aos dados constantemente. Infelizmente, tentar servir os dois tipos de solicitação* pode ser uma tarefa problemática, portanto algumas empresas escolhem separar os sistemas de informações em tipos OLTP e tipos OLAP.

*O OLTP é voltado para o processamento de transações repetitivas em grandes quantidades e manipulações simples. O OLAP envolve o exame de muitos itens de dados, entre alguns milhares até milhões, em relacionamentos complexos. Além de responder às consultas dos usuários, o OLAP consegue analisar esses relacionamentos e buscar padrões, tendências e exceções. Concluindo, o OLAP é um método direto de suporte à decisão.*

*As ferramentas OLAP têm características que as diferenciam das ferramentas de SIG, cujo propósito é suportar aplicações tradicionais de relatórios de OLTP. E. F. Codd, Codd e Salley (1993) definiram sucintamente as características das ferramentas OLAP nas doze regras.*

Com base na padronização da modelagem de dados multidimensionais, são definidos quatro tipos de processamento executados pelos analistas em uma organização.

1. A análise categórica é uma análise estática baseada em dados históricos. Ela se vale da premissa de que o desempenho passado é um indicador do futuro. Essa é a análise básica suportada por bancos de dados OLTP baseados em transação.
2. A análise exegética também toma como base os dados históricos e acrescenta a capacidade de análise drilldown. Por sua vez, a análise drilldown é a capacidade de consultar os dados mais a

fundo para determinar os dados detalhados usados para definir um valor derivado.

3. A análise contemplativa permite que um usuário altere um único valor, a fim de determinar seu impacto.
4. A análise formalista permite alterações a múltiplas variáveis.

## 1.5 Funcionalidade do OLAP

Com o intuito de navegar e localizar informações a partir do repositório de dados, as ferramentas OLAP fornecem diversas funcionalidades, destacam-se principalmente:

- **Slice-dice:** capacidade de acessar o DW por meio de qualquer uma de suas dimensões de maneira igual. É o processo de separação e combinação de dados, com várias possibilidades de cruzamento de informações (KIMBALL; ROSS, 2002).
- **Drill-up ou Roll-up:** permite navegar até um nível ou hierarquia de detalhe imediatamente superior (mais granular) a partir de uma dimensão. Normalmente, associado à ação de remover um cabeçalho de linha ou uma coluna para resumir um conjunto de dados (INMON, 1997; KIMBALL; ROSS, 2002).
- **Drill-down:** ao contrário de *roll-up*, refere-se à ação de percorrer uma hierarquia de nível superior de agregação para níveis de menor detalhamento (INMON, 1997).
- **Drill-across:** possibilita a combinação de dados entre duas ou mais tabelas de fatos em uma única análise, quase sempre envolvendo consultas separadas que são posteriormente unidas (KIMBALL; ROSS, 2002).
- **Drill-through:** ocorre quando o usuário faz análises de distintas visões proporcionadas por troca de informações entre dimensões, por exemplo: o usuário realiza análises de indicadores pela dimensão geografia e, posteriormente, passa a analisar sobre a dimensão tempo (SELL, 2006).

## Questão para reflexão

Considere uma empresa de bens de consumo de médio porte de destruição nacional, que analise seus resultados de vendas por meio de relatórios. Como os benefícios de ferramentas OLAP podem gerar resultado em uma empresa?

## Considerações Finais

- **Business Analysis (BA):** compreende uma ampla gama de aplicações e técnicas para reunir, armazenar, analisar e fornecer acesso aos dados, com o objetivo de ajudar os usuários da empresa a tomarem melhores decisões operacionais, comerciais e estratégicas.
- **Sistemas OLAP:** referem-se a uma grande quantidade de atividades normalmente executadas por usuários finais no ambiente *on-line*, tais como a geração e a resposta de consultas, solicitações de relatórios e gráficos *ad hoc*.
- **Tipos de sistemas OLAP:** ROLAP, MOLAP, HOLAP, DOLAP e WOLAP.
- **Característica fundamental de sistemas OLAP:** é ser capaz de filtrar os dados por diversas formas e modos customizados pelo usuário, bem como pode sumarizar o conteúdo em uma estrutura chamada de cubo OLAP.

## Glossário

**OLAP:** processamento analítico online ou *OnLine Analytical Processing*.

**OLTP:** processamento de transações online.

## Verificação de leitura

**QUESTÃO 1-** Uma estrutura que diferencia os sistemas OLAP ou sistemas de BI é:

- a) a árvore;
  - b) o relatório ad hoc;
  - c) gráficos;
  - d) cubos multidimensionais;
  - e) redes neurais.
- 

**QUESTÃO 2-** Comparando um sistema online de processamento de transação (OLTP) com sistemas OLAP, assinale a alternativa correta.

- a) Enquanto OLTP trabalha com dados presentes, OLAP trabalha com dados passados, presentes e projetados.
  - b) Em ambos os sistemas, as telas são definidas pelo usuário.
  - c) A OLAP é focada em atividades repetitivas e a OLTP é focada em análise.
  - d) Ambas possuem as mesmas rotinas.
  - e) Os relacionamentos entre os itens de dados na OLAP são simples.
- 

**QUESTÃO 3-** Em uma OLAP, a ação de percorrer uma hierarquia de nível superior de agregação para níveis inferiores de detalhamento é chamada de:

- a) *Slice-dice*;
  - b) *Drill-down*;
  - c) *Drill-across*;
  - d) *Drill-up*;
  - e) *Drill-through*.
-



## Referências Bibliográficas

CECI, Flávio. **Business intelligence**. Palhoça: UnisulVirtual, 2012.

COOD, E. F.; CODD, S. B.; SALLEY, C. T. **Providing OLAP to User-Analysts**: An IT Mandate. White Paper, E.F. 1993. Disponível em: <[http://www.uniriotec.br/~tanaka/SAIN/providing\\_olap\\_to\\_user\\_analysts.pdf](http://www.uniriotec.br/~tanaka/SAIN/providing_olap_to_user_analysts.pdf)>. Acesso em: 10 maio 2018.

GOUVEIA, Luís Borges; RANITO, João. **Sistemas de informação de apoio à gestão**. Porto: Sociedade Portuguesa de Inovação, 2004.

INMON, W. H. **Como construir o Data Warehouse**. Rio de Janeiro: Campus, 1997.

KIMBALL, Ralph; ROSS, Margy. **The Data Warehouse Toolkit**: The Complete Guide to Dimensional Modeling. New Jersey: Wiley, 2002.

MICROSTRATEGY. **Análises empresariais e mobilidade**. Disponível em: <<https://www.microstrategy.com/br>>. Acesso em: 10 maio 2018.

SAP. **Soluções de Business Intelligence (BI)**. Disponível em: <<https://www.sap.com/brazil/products/analytics/business-intelligence-bi.html>>. Acesso em: 10 maio 2018.

SAS – The power to know. **Nestlé aprimora previsão de demanda com soluções de análise do SAS**. Disponível em: <[https://www.sas.com/pt\\_br/customers/nestle-aprimora-previsao-demanda-com-solucoes-analise-SAS.html](https://www.sas.com/pt_br/customers/nestle-aprimora-previsao-demanda-com-solucoes-analise-SAS.html)>. Acesso em: 10 maio 2018.

SAS. **Software & Soluções de Analytics**. Disponível em: <[https://www.sas.com/pt\\_br/home.html](https://www.sas.com/pt_br/home.html)>. Acesso em: 10 maio 2018.

SELL, Denilson. **Uma arquitetura para business intelligence baseada em tecnologias semânticas para suporte a aplicações analíticas**. 2006. 265 f. Tese (Doutorado) – Universidade Federal de Santa Catarina, Centro Tecnológico. Programa de Pós-Graduação em Engenharia de Produção, Florianópolis, 2006.

THOMSEN, Erik. **OLAP Solutions**: building multidimensional information systems. 2ª ed. New York: John Wiley & Sons, 2002.

TURBAN, Efraim. *et al.* **Business intelligence**: um enfoque gerencial para a inteligência do negócio. Porto Alegre: Bookman, 2009.

## Gabarito

### QUESTÃO 1- Resposta certa: D.

Todos os sistemas OLAP podem ser representados por cubos.

-----

### QUESTÃO 2- Resposta certa: A.


Um sistema OLTP verifica as transações correntes. Já um sistema OLAP, além das transações atuais, verifica as transações passadas e realiza projeções de dados futuros, por meio de ferramentas preditivas.

-----

### QUESTÃO 3- Resposta certa: B.

*Drill-down* se refere à ação de percorrer uma hierarquia de nível superior de agregação para níveis inferiores de detalhamento.

-----



**7**

**Análise de  
negócios e  
visualização  
de dados II**

## Objetivos Específicos

- Apresentar tipos e aplicações de consultas e relatórios em *Business Intelligence* (BI).
- Descrever como a visualização de dados pode melhorar a tomada de decisões.
- Listar ferramentas de análise dos principais fornecedores.
- Apresentar os sistemas de informações geográficas (GIS) e seu apoio à tomada de decisões.

## Introdução

Após a realização de processamento analítico online (OLAP), visto anteriormente, é possível a geração de relatórios e consultas para exibição de resultados. Existe uma correlação entre consultas e relatórios, posto que o resultado de consultas pode gerar um relatório, assim como o desenho de um relatório pode gerar uma consulta.

Os relatórios podem ser de rotina ou *ad hoc*. Relatórios de rotina são gerados automaticamente e distribuídos com periodicidade aos interessados em uma lista de discussão. Por exemplo, relatórios de vendas semanais são fundamentais para o gerenciamento de uma loja de qualquer segmento, pois, com posse desse relatório, o gerente pode determinar um plano de ação e verificar os problemas que ocorreram no período anterior. Um relatório *ad hoc* possui um objetivo específico, sendo realizado pelo determinado usuário com um subconjunto dos dados e períodos de referência, diferentes do relatório de rotina.

Diversos fornecedores de *software* de BI realizam relatórios, consultas, análises e visualização de dados. Para bancos de dados, a linguagem SQL é uma linguagem padronizada para realização de operações. A visualização é referente à forma de apresentação dos dados presentes no banco de dados, que pode auxiliar na identificação de explicações para alguns resultados presentes nos relatórios.

Adicionalmente, existem sistemas que além dos dados, também gravam as informações de posições geográficas. Os sistemas de informações geográficas (GIS) são muito utilizados para determinação

de local para estabelecimentos, alterações de rotas logísticas e análise de público potencial em uma determinada região. A forma de representação em mapas auxilia na diminuição da quantidade de números mostrados, tornando a análise humana mais simples.

# 1. análise de negócios e visualização de dados II

Como visto anteriormente, o processamento analítico online OLAP (*Online Analytical Processing*) é uma tecnologia designada para obter novas informações de negócios por meio de um conjunto de transformações e cálculos executados sobre as fontes de dados (TURBAN *et al.*, 2009).

## 1.1 Relatórios e Consulta

Relatórios e consultas são as atividades mais antigas de inteligência de negócios (BI) e de OLAP. Em muitos casos, existe uma correlação entre o relatório e a consulta, pois um relatório pode designar uma consulta e a consulta, por sua vez, resulta em um relatório. A geração de relatórios OLAP deve ser flexível e ajustável, visando facilitar a criação de relatórios pelo usuário, para que ele possa analisar o desempenho diário.

É possível classificar os relatórios em dois tipos: rotina e *ad hoc*. Os relatórios de rotina são aqueles gerados automaticamente e distribuídos aos assinantes em listas de discussão periodicamente. Por sua vez, relatórios *ad hoc* são criados para um usuário específico, quando houver necessidade. Adicionalmente, podem conter um subconjunto dos dados ou intervalos de tempos diferentes em relação aos relatórios de rotina.

Um exemplo muito frequente de relatório de rotina são os relatórios de desempenho recebidos semanalmente para uma loja, que pode ser uma farmácia, uma loja de roupas e calçados, uma


loja de eletrônicos, entre outras. Com base no histórico de volume, quantidade de vendas e na quantidade de horas trabalhadas, pode-se verificar como as vendas se comportaram em outros períodos. Já um exemplo de relatório *ad hoc* são listagens de clientes que se interessaram por um determinado produto, mas ainda não o compraram.

Softwares de BI são utilizados para produzir relatórios em diversas áreas funcionais. Na área de finanças e contabilidade, os relatórios realizados são análise do fluxo de caixa, previsão e orçamento financeiro, análise da demonstração de resultados e relatório de contas a pagar. Para serviços Web, os relatórios são análise de comércio eletrônico, análise de tráfego na Web, análise de visitantes na Web e análise da navegação Web.

Uma funcionalidade útil de softwares de BI é o envio de alertas e entregas de relatórios, proativamente, a muitos usuários das empresas, sejam internos ou externos.

Consulta *ad hoc* é o tipo de consulta que não pode ser determinada antes de ser realizada. Ao fim da consulta, o usuário poderá receber um relatório. A vantagem desse tipo de consulta é a flexibilidade de conteúdo, estrutura e avaliações, os quais podem incluir informações não disponíveis em relatórios periódicos.

Para acesso e manipulação de dados, em um sistema de gerenciamento de banco de dados, utiliza-se a Linguagem de Consulta Estruturada (SQL), que é padronizada e usada em diversos softwares de bancos de dados, como Microsoft Access 2016, Oracle 10i e 11g e Microsoft SQL Server 2016.



#### **Para saber mais**

Um Sistema Gerenciador de Bancos de Dados (SGBD) é um software instalado em um computador (servidor) que tem a função de gerenciar um ou mais bancos de dados. Quando existe um identificador único entre tabelas diferentes, tem-se o Banco de Dados Relacionais.

Os Bancos de Dados relacionais Possuem uma característica comum: a utilização da linguagem chamada SQL (Structured Query Language). SQL não é uma linguagem de programação, mas uma linguagem usada exclusivamente para criar tabelas, manipular os dados das tabelas e, principalmente, consultar os dados.

## 1.2 Exemplos de fornecedores de soluções de BI

Existem diversos fornecedores específicos para análise de BI, a fim de atender aos diferentes setores e tamanhos de empresa. A Microstrategy é uma dessas empresas, a qual lançou, em 2016, o MicroStrategy 10, que possui mais de 400 funções estatísticas, matemáticas e financeiras para criação de relatórios e análise de seus resultados e possibilita acesso móvel à plataforma.

O *IBM SPSS Statistics* é o principal *software* estatístico do mercado, o qual proporciona encontrar novos insights nos dados existentes de forma rápida. Outro *software* da IBM é o *IBM Cognos Analytics on Cloud*, que além de análises de séries temporais e tendências personalizáveis, faz análise da concorrência, detalhamento e otimização.


A SAS é líder em Análise Preditiva e *Data Mining*. Uma de suas ferramentas é a SAS Enterprise Miner. Ela fornece ferramentas financeiras, estatísticas e de previsão para a solução de problemas. Uma área de destaque é a de avaliação e gerenciamento de risco, usando modelos de pontuação de crédito (*credit scoring*).

Outros fornecedores nesse grupo são Tableau, Microsoft, Oracle, Totvs, SAP, Insightful Corp., StatSoft Inc., Knowledge eXtraction ENgines, Unica e Angoss Software.



### Link

No site da Microstrategy é possível verificar todas as capacidades e recursos da ferramenta mencionada. Disponível em: <<https://www.microstrategy.com/br/products>>. Acesso em: 11 maio 2018.



### Para saber mais

O Credit Scoring é uma espécie de pontuação de crédito, usada por bancos e financeiras para medir o risco ao qual se submeteriam caso concedessem crédito a uma determinada cliente. Tal pontuação representa o histórico financeiro de quem solicita crédito no mercado e na instituição em que está solicitando o crédito.

## 1.3 Visualização de dados

Em muitos casos, os dados fornecidos pelos relatórios exigem ações adicionais. Uma das ações consistem na Visualização dos Dados, que são tecnologias para dar suporte à exibição e, eventualmente, à interpretação de dados e informações ao longo da cadeia de processamento (FAYYAD; PIATESKY-SHAPIO; SMYTH, 1996).

Essas tecnologias visuais podem condensar milhares de números em uma única imagem e permitir que as aplicações de suporte à decisão sejam mais atraentes e compreensíveis aos usuários.

Essa etapa inclui imagens digitais, sistemas geográficos, interfaces gráficas de usuário, gráficos, realidade virtual, representações dimensionais, vídeos e animações. As ferramentas visuais podem ajudar a identificar relações, tais como: tendências. A visualização de dados se torna de mais fácil implementação quando os dados necessários estão em um *Data Warehouse*, ou, melhor ainda, em um banco de dados multidimensional especial ou servidor.

Uma das aplicações frequentes da visualização de dados de BI é na área financeira. Para evitar que sistemas identifiquem automaticamente padrões inexpressivos nos dados, os diretores financeiros (CFOs) querem ter certeza de que a capacidade de processamento de um computador sempre será ajustada pelo discernimento de um ser humano.

### 1.3.1 Visualização por planilhas

As planilhas são as principais ferramentas do usuário final para programação de aplicações de suporte à decisão. O Microsoft Excel oferece dezenas de ferramentas matemáticas, estatísticas, de geração de relatório e de consulta, como regressões, identificação de objetivos, histogramas, elaboração de cenários, entre outras ferramentas de BI.

Os principais fornecedores de OLAP oferecem ferramentas de visualização tridimensional, junto com suas ferramentas de suporte à decisão. Existem ferramentas de desenvolvimento que têm uma versão para visualização tridimensional, permitindo aos usuários ver e gerenciar facilmente múltiplas dimensões de dados em uma única vista. Novas ferramentas visuais são desenvolvidas continuamente para analisar o desempenho de websites.



## 1.3.2 Dashboards e indicadores

É comprovado que a visualização é extremamente importante para executivos atarefados. O sistema de informações gerenciais (EIS), dos anos 90, era repleto de gráficos e tabelas. Ele evoluiu para produtos de gerenciamento de *cockpit* e, posteriormente, para *dashboards* e indicadores.

## 1.3.3 Análise visual

Atualmente, a análise de dados empresariais pode ser feita por usuários não técnicos que colhem informações valiosas, provenientes de dados comerciais. A VizQL (da Tableau Software) é uma linguagem visual de consulta a banco de dados que ativa o Hyperion Visual Explorer. Diversas outras empresas fornecem ferramentas para análise visual, por exemplo: Analytica (lumina.com) e Endeca (endeca.com). A análise visual pode ser feita de maneira interativa, por exemplo NAVTEQ (navteq.com).

## 1.4 Sistemas de informação geográfica (GIS)

Um sistema de informações geográficas (GIS) é um sistema baseado em computador para captura, armazenamento, modelagem, recuperação, verificação, integração, manipulação, análise e exibição de dados citados, geograficamente, por meio do uso de mapas digitais.

A característica mais distintiva do GIS é que cada registro ou objeto digital tem uma localização geográfica identificada. Ao integrar mapas aos bancos de dados orientados espacialmente, denominados de geocodificação, a outros bancos de dados, os usuários podem gerar informações para planejamento, resolução de problemas e tomada de decisão, aumentando, com isso, sua produtividade e a qualidade de suas decisões. Diversas áreas aplicam o GIS com êxito desde o início dos anos 70, tais como: varejo, bancos, transportes, agricultura, gestão de recursos naturais, administração pública, controle do espaço aéreo, militar, serviço de emergência e planejamento urbano (URSERY, 2004).

É frequente a utilização de GIS em instituições financeiras para suporte de atividades como determinação da localização de agências e caixas eletrônicos, análise dos padrões de volume e tráfego das atividades comerciais, análise da área geográfica atendida pela agência e avaliação dos pontos fortes e fracos em relação aos pontos da concorrência. Em varejistas, é comum o uso do GIS para

planejamento das rotas rodoviárias. Tanto a Toyota quanto outros fabricantes automotivos utilizam GIS e o sistema de posicionamento global (GPS), ou *Global Positioning System*, como ferramenta para orientar motoristas aos seus destinos nas melhores rotas.

O GIS oferece uma grande quantidade de informações extremamente úteis que podem ser analisadas e utilizadas na tomada de decisão. O formato gráfico de um GIS facilita a visualização de dados pelos gerentes.

Segundo Janet M. Hamilton, gerente de pesquisa de mercado da Dow Elanco, fabricante de defensivos agrícolas de US\$ 2 bilhões, com sede em Indianápolis: “Posso colocar planilhas de 80 páginas com milhares de linhas em um único mapa. Levaria algumas semanas para compreender todas as informações da planilha, mas, em um mapa, a história pode ser contada em segundos” (HAMILTON, 1996, p. 5).



#### Assimile

GIS é um sistema constituído por um conjunto de “ferramentas” especializadas em adquirir, armazenar, recuperar, transformar e emitir informações espaciais (CÂMARA; ORTIZ, 1998).

### 1.4.1 GIS associado ao GPS

O Departamento de Defesa dos EUA investiu cerca de US\$21 bilhões em sistemas de satélite que alimentam sistemas de posicionamento global (GPS). Os dispositivos GPS são wireless e usam satélites para permitir que os usuários detectem a posição na Terra dos itens nos quais os dispositivos estão anexados, por exemplo: carros e pessoas, com precisão razoável. Se desejar mais informações sobre GPS, consulte: <trimble.com/gps>. O GPS, em conjunto com o GIS, está trazendo grandes progressos nas aplicações de BI. São inúmeros os usos comerciais e governamentais, pois os dispositivos de detecção são relativamente baratos.

## Questão para reflexão

Um site de *e-commerce* é voltado à distribuição de produtos para computadores e *tablets*. Entre os dispositivos vendidos estão: placas de circuitos de vídeo de última geração, processadores de alto desempenho, memórias de alta capacidade e baixo tempo de acesso. Como é possível aplicar as ferramentas de GIS para análise visando aumentar as receitas?

## Considerações Finais

- Existem relatórios de rotina e *ad hoc* e podem ser aplicados a diversas áreas. Também existem alertas e entrega de relatórios de modo automático.
- Vários fornecedores de *software* desenvolveram soluções de BI, como a Microstrategy, o SAS, a SAP, a IBM, entre outras.
- Uma das ações consistem na Visualização dos Dados, que são tecnologias para dar suporte à exibição e, eventualmente, à interpretação de dados e informações ao longo da cadeia de processamento.
- Um sistema de informações geográficas (GIS) é um sistema baseado em computador para captura, armazenamento, modelagem, recuperação, verificação, integração, manipulação, análise e exibição de dados citados, geograficamente, por meio do uso de mapas digitais.

## Glossário

**GIS:** sistema constituído por um conjunto de “ferramentas” especializadas em adquirir, armazenar, recuperar, transformar e emitir informações espaciais.

**GPS:** Sistema de Posicionamento Global.

**Ad hoc:** específico.

**SQL:** Linguagem de Consulta Estruturada.

**OLAP:** Processamento Analítico Online.

## Verificação de leitura

**QUESTÃO 1-** Um sistema constituído por um conjunto de “ferramentas” especializadas em adquirir, armazenar, recuperar, transformar e emitir informações espaciais é conhecido como:

- a) SIG;
  - b) OLAP;
  - c) *ad hoc*;
  - d) GIS;
  - e) *Text mining*.
- 

**QUESTÃO 2-** Quais são as características de consultas *ad hoc*?

- a) São como consultas de rotina.
  - b) Geram relatórios de rotina.
  - c) Possuem flexibilidade de conteúdo, estrutura e avaliações, podendo incluir informações não disponíveis em relatórios periódicos.
  - d) Os softwares de BI não possuem capacidade de realizar consultas *ad hoc*.
  - e) São consultas genéricas, feitas para rotinas.
- 

**QUESTÃO 3-** A Linguagem SQL é utilizada em(na):

- a) construção de sites de Internet;
  - b) construção de programas em linguagens de alto nível, como Java, C#;
  - c) construção de programas em linguagens de baixo nível, como *Assembler*;
  - d) criação de mensagens criptografadas;
  - e) sistemas gerenciadores de bancos de dados.
-

## Referências Bibliográficas

CÂMARA, Gilberto; ORTIZ, Manoel Jimenez. Sistemas de Informação Geográfica para Aplicações Ambientais e Cadastrais: Uma Visão Geral. In: SOUZA E SILVA, M. **Cartografia, Sensoriamento e Geoprocessamento**. Lavras: UFLA/SBEA, 1998, p. 59-88. Disponível em: <<http://www.dpi.inpe.br/geopro/trabalhos/analise.pdf>>. Acesso em: 11 maio 2018.

FAYYAD, Usama; PIATETSKY-SHAPIO, Gregory; SMYTH, Padhraic. From *Data Mining* to Knowledge Discovery: An Overview. In: FAYYAD, Usama *et al.* **Advances in Knowledge Discovery and Data Mining**. AAAI Press, 1996.

HAMILTON, Janet M. A Mappable Feast. **CIO Magazine**, 15 mar. 1996.

MICROSTRATEGY. **Relatórios empresariais**. Disponível em: <<https://www.microstrategy.com/br/products/capabilities/enterprise-reporting>>. Acesso em: 11 maio 2018.

MICROSTRATEGY. **Produtos**. Disponível em: <<https://www.microstrategy.com/br/products>>. Acesso em: 11 maio 2018.

URSERY, S. GIS more prevalent in big cities. **The American City and County**, fevereiro, 2004.

TRIMBLE. **GPS Tutorial**. Disponível em: <[trimble.com/gps](http://trimble.com/gps)>. Acesso em: 11 maio 2018.

TURBAN, Efraim; SHARDA, Ramesh; ARONSON, E.; KING, David. **Business Intelligence: Um Enfoque Gerencial**. Porto Alegre: Bookman, 2009.

## Gabarito

### QUESTÃO 1- Resposta certa: D.

O sistema definido no enunciado é um Sistema de Informações Geográficas (GIS).

-----

### QUESTÃO 2- Resposta certa: C.

As consultas *ad hoc* possuem flexibilidade de conteúdo, estrutura e avaliações, podendo incluir informações não disponíveis em relatórios periódicos

-----

### QUESTÃO 3- Resposta E.

A linguagem SQL é utilizada para realizar operações em bancos de dados relacionais.

-----

The background features a blurred image of hands interacting with a tablet. This image is overlaid with several geometric shapes: a large blue triangle in the top left, a smaller light blue triangle in the top right, and a large light blue triangle in the bottom right. A white diagonal line separates the tablet image from the bottom right triangle.

**8**

***Business  
performance  
management  
(BPM)***

## Objetivos Específicos

- Compreender o conceito do Business Performance Management (BPM).
- Descrever algumas das melhores práticas de planejamento e relatório de gerenciamento.
- Apresentar os elementos básicos das metodologias Balanced Scorecard.
- Apontar os usos potenciais de monitoramento de atividades de negócios (BAM).

## Introdução

Desde a década de 1970, os métodos de avaliação de processo evoluíram muito, partindo da Gestão da Qualidade Total, *Total Quality Management* (TQM) em inglês, passando pelas metodologias *Lean* e *Six Sigma* e, por fim, resultando na abordagem de Gerenciamento de processos de negócio, do inglês, *Business Process Management* (BPM).

Os sistemas de informação e inteligência de negócios evoluíram muito os primeiros sistemas computadores da década de 1960. Essa evolução passou por sistemas suporte à decisão (DSS), ferramentas de BI até BPM. É possível entender o *Business Process Management* (BPM), ou gerenciamento de processos de negócios, como uma estrutura para organizar, automatizar e analisar as metodologias de negócios, métricas, processos e sistemas, de modo a impelir o desempenho geral da empresa.

O BPM é um processo contínuo e engloba um conjunto de processos em um ciclo fechado, partindo desde a estratégia até a execução, com objetivo de otimizar o desempenho dos negócios. O primeiro passo é fazer a estratégia, respondendo ao questionamento “Aonde a empresa quer ir?”. Depois será definido como implementar essa estratégia por meio de um plano que procura detalhar “Como a empresa irá chegar lá?”. Posteriormente, a empresa irá monitorar os resultados dos indicadores frente às metas estabelecidas que é análogo à pergunta “Como a empresa está fazendo?”. Por fim, a empresa deve realizar ações e ajustes, que representa “O que a empresa deve fazer de forma diferente?”.

Uma metodologia para gerenciar e medir o desempenho é o *Balanced Scorecard*. Além da perspectiva financeira, são incluídas as perspectivas Clientes, Processos Internos de Negócio e Aprendizado e Crescimento da empresa, com um conjunto de iniciativas a serem implementadas.



Visando uma interface mais fácil para análise do resultado, são elaborados *dashboards* e *scorecards*. Por fim, é apresentado o monitoramento de atividades de negócios (BAM), que alerta os gerentes em tempo real sobre eventos que podem impactar a empresa.

# 1. Business performance management (BPM)

Desde a década de 1970, os métodos de avaliação de processo evoluíram continuamente. Uma metodologia inicial foi a Gestão da Qualidade Total, em inglês, *Total Quality Management (TQM)*, passando pelas metodologias *Lean* e *Six Sigma*. Como resultado desses esforços realizados, surgiu a abordagem de Gerenciamento de processo de negócio, do inglês, *Business Process Management (BPM)*.

Os sistemas de informação também obtiveram grande evolução. Os primeiros sistemas foram os sistemas de suporte à decisão, sistemas de informações gerenciais e *Business Intelligence (BI)*. No suporte à decisão, o BPM representa mais do que uma tecnologia.

## 1.1 Definição de BPM

*Business Performance Management (BPM)* é um conjunto integrado de processos, metodologias, métricas e aplicações projetadas para impelir o desempenho geral financeiro e operacional de uma empresa.

A utilização do BPM contribui fortemente com as empresas, pois estas convertem suas estratégias e objetivos em planos, monitoram o desempenho frente aos planos, analisam variações entre resultados medidos e resultados pretendidos, bem como ajustam seus objetivos e ações em resposta a essa análise. Assim, os resultados mostrados



### Assimile

Segundo o BPM Standards Group (2005), define-se BPM como: uma estrutura para organizar, automatizar e analisar as metodologias de negócios, métricas, processos e sistemas, de modo a impelir o desempenho geral da empresa.

no BPM podem trazer ideias para melhoria do desempenho financeiro e operacional.

Na literatura de negócios, a gestão de desempenho possui diversos nomes, como BPM, gestão de desempenho corporativo (CPM), gestão estratégica da empresa (SEM) e gestão de desempenho empresarial (EPM). Entretanto, vale ressaltar, o termo padronizado é BPM.

## 1.2 Diferenças entre BPM e BI

O BPM é um resultado da inteligência de negócios (BI) e incorpora muitas tecnologias, aplicações e técnicas de BI, entretanto existem diferenças consideráveis entre BI tradicional e BI para BPM, uma vez que o BPM possui concentração em estratégia e objetivos.

O BI para BPM foca em questões empresariais, enquanto BI se concentra em questões departamentais. A visualização dos indicadores de desempenho de BPM ocorre em painéis ou placares. As métricas de BI, por sua vez, são exibidas em tabelas ou diagramas. Enquanto o BPM procura gerar alertas atuando de forma proativa, o BI é reativo e atende perguntas *ad hoc*.

## 1.3 Resumo de processos BPM

Todas as empresas melhor estruturadas possuem processos em operação como orçamento e planos detalhados. O diferencial do BPM é integrar os processos existentes, metodologias, métricas e sistemas.

O BPM é um processo contínuo e engloba um conjunto de processo em um ciclo fechado, partindo desde a estratégia até a execução, com objetivo de otimizar o desempenho dos negócios. A seguir, a figura 1 retrata o ciclo do BPM.

FIGURA 1: PROCESSO DE CICLO FECHADO DE BPM



FONTE: Turban (2009, p. 192).

Analisando o ciclo, é possível verificar que o desempenho perfeito é alcançado pela definição de metas e objetivo, isto é, por elaborar estratégias para depois propor e iniciar planos para chegar às metas, ou seja, planejar. Posteriormente, o desempenho será monitorado e comparado com as metas e objetivos, deve-se, portanto, monitorar os resultados e, por fim, ações corretivas devem ser tomadas, ou seja, deve-se agir e ajustar.

## 1.3.1 Estratégia

Uma estratégia possui elementos como metas, objetivos, prioridades, pensamento crítico e planos. Uma questão-chave para definir a estratégia é “Aonde queremos ir no futuro?”. As respostas para essa questão são fornecidas no plano estratégico.

Inicialmente, os planos estratégicos devem ser realizados para a empresa como um todo. Posteriormente, podem ser criados planos estratégicos para as unidades de negócios ou unidades funcionais da empresa. As etapas do planejamento estratégico são comuns e independem do nível de planejamento realizado (WADE; RECARDO, 2001).

A primeira etapa é conduzir uma análise da situação atual, o que serve para examinar a empresa naquele momento (“onde estamos?”) e para estabelecer os parâmetros de referência para o desempenho financeiro e operacional.

Na segunda etapa, o foco é determinar o horizonte de planejamento, que pode ser de um ano ou por um período maior de tempo. Posteriormente, ocorre a etapa de conduzir uma varredura de ambiente, analisando os pontos fortes e fracos, fraquezas e oportunidades (SWOT) da empresa. A quarta etapa é identificar os fatores críticos de sucesso.

A próxima etapa é a análise de compleição de lacuna ou análise de *gap*. Ao encontrar lacunas, serão priorizadas forças e fraquezas internas no processo da empresa, estruturas, tecnologias



### Assimile

As oito etapas do planejamento estratégico são:

1. conduzir uma análise de situação atual;
2. determinar o horizonte de planejamento;
3. conduzir uma varredura do ambiente;
4. identificar fatores críticos de sucesso;
5. analisar de compleição de uma lacuna ou análise de *gap*;
6. criar uma visão estratégica;
7. desenvolver uma estratégia de negócios;
8. identificar objetivos e metas estratégicas.



### Para saber mais

Fatores críticos de sucesso (FCS) delineiam atributos que a empresa deve sobressair para obter sucesso no seu nicho de mercado.

e aplicações. Segundo Niven (2005), existem quatro fontes para a lacuna entre a execução e a estratégia: visão, pessoas, gerenciamento e recursos.

A sexta etapa é a criação de uma visão estratégica, que projeta a empresa no futuro. Na penúltima etapa, é desenvolvida uma estratégia de negócios, a qual deve ser coerente com a visão estratégica da empresa.

Por fim, o objetivo da última etapa é identificar objetivos e metas estratégicas, tornando claros os objetivos estratégicos e refinando as metas.



#### Para saber mais

Um objetivo estratégico é uma declaração ampla ou o curso geral de uma ação que prescreve direções com alvo para uma empresa. Uma meta estratégica é a quantificação de um objetivo para um período designado de tempo.

## 1.3.2 Plano

A elaboração do Plano busca responder a pergunta “Como chegaremos lá?”. Quando os gerentes operacionais sabem e entendem o que (i.e., os objetivos e metas organizacionais), eles podem vir com o como (i.e., planos detalhados operacionais e financeiros). Um plano operacional converte uma estratégia operacional e metas em um conjunto de iniciativas e táticas previamente definidas, exigência de recursos e resultados esperados para o próximo período, normalmente um ano. O planejamento operacional pode ser centrado em orçamento ou em táticas.

Já no planejamento e orçamento financeiro, como existem restrições de recursos, a empresa deve aplicar recursos financeiros e humanos onde suas estratégias e táticas estejam vinculadas. É necessário alinhar o orçamento e os objetivos táticos e estratégicos, para isso o plano financeiro deve estar baseado no plano operacional.

## 1.3.3 Monitoração

A maior dificuldade da estrutura de monitoramento é ter o conhecimento de: “O que monitorar?” e “Como monitorar?”. Depois da escolha dos indicadores, é necessário definir uma estratégia para monitorar os fatores e responder efetivamente.

Por sua vez, um sistema de controle de diagnóstico é um sistema computacional, o que significa que tem entradas, um processo para transformar as entradas em saídas, um padrão ou marca comparativa, com a qual se pode comparar as saídas, e um canal de retorno, a fim de permitir que informações sobre variâncias entre as saídas e o padrão sejam comunicadas e agilizadas.

### 1.3.4 Ação e Ajuste

As empresas utilizam muitos recursos financeiros e tempo desenvolvendo planos, coletando dados e gerando relatórios de gerenciamento, que são desperdiçados, a não ser que a empresa tome uma atitude em relação aos dados de desempenho coletados. As empresas que possuem as melhores práticas usam “previsões contínuas” para fazer esses ajustes, e não somente o orçamento do fim do ano anterior.

## 1.4 Medida de desempenho

BPM possui um sistema de medida de desempenho. Esse tipo de sistema auxilia os gerentes a rastrear as implementações de estratégia de negócios, comparando os resultados reais com as metas estratégicas e objetivos. Tal sistema geralmente engloba métodos sistemáticos de união de metas de negócios com relatórios de retorno periódicos, os quais indicam progresso contra metas.

O sistema mais popular em uso é uma variante do indicador balanceado, do inglês, *Balanced Scorecard* (BSC), de acordo com Kaplan e Norton (1996). Segundo Britto (2012), o principal tópico da metodologia BSC é uma visão holística de um sistema de medidas ligado à direção estratégica da empresa, baseado em quatro perspectivas do mundo, com a medida financeira suportada por cliente, interno, e métricas de aprendizado e crescimento.

Ao medir e gerenciar o negócio usando esse conjunto de métricas, uma empresa pode assegurar implementação rápida e eficaz da estratégia e facilitar a comunicação e o alinhamento organizacional.

Os Relatórios financeiros mensais, trimestrais e anuais são importantes componentes da maior parte dos sistemas de medida de desempenho. Esse fato pode ser explicado, pois a maioria desses sistemas

está sob a competência do departamento financeiro. Adicionalmente, a maior parte dos executivos não confia plenamente em outras métricas, mas somente em informações financeiras e operacionais.


A sobrecarga de medida e a obliquidade de medida são também problemas que confrontam a atual safra de sistemas. Para muitas das medidas, sendo rastreadas, o gerenciamento tem falta de controle direto. Michael Hammer (2003) denominou tal fato de princípio de obliquidade. Por um lado, medidas como rendimentos por ação, retorno sobre patrimônio, lucratividade, participação no mercado e satisfação do cliente precisam ser monitoradas.

### 1.4.1 BSC

As medidas devem se concentrar em fatores cruciais, tais como: as medidas devem ser uma mistura de passado, presente e futuro. Adicionalmente, elas devem equilibrar as necessidades dos acionistas, colaboradores, parceiros, fornecedores e *stakeholders*. Também o fluxo das medições deve ser do topo para baixo. Por fim, as medidas precisam ter metas que se baseiam em pesquisa e realidade, em vez de serem arbitrárias.

*Balanced Scorecard* (BSC) é tanto uma medida de desempenho e metodologia de gerenciamento que ajuda a traduzir os objetivos e metas financeiras, de clientes, de processos internos e de aprendizado e crescimento de uma empresa em um conjunto de iniciativas passíveis de implementação. Como uma metodologia de medida, o BSC é planejado para superar as limitações de sistemas que possuem foco financeiro.

Os objetivos não financeiros caem em uma das três perspectivas: Clientes, Processos internos de negócio e Aprendizado e crescimento. Na perspectiva Clientes, os objetivos definem como a empresa deveria aparecer para os seus clientes, se for realizar sua visão. Analisando os processos internos de negócios, esses objetivos especificam os processos nos



#### Para saber mais

O *Balanced Scorecard Institute* (BSI) pode ajudar as empresas a implementação do BSC por meio de treinamentos ou consultoria especializada. O site do BSI também contém diversos artigos e vídeo sobre BSC.

quais a empresa deve se superar, de modo a satisfazer seus clientes e acionistas. Por fim, em relação ao Aprendizado e crescimento, os objetivos indicam como uma empresa pode melhorar sua capacidade de mudar e melhorar para alcançar sua visão.

## 1.4.2 Etapas do BSC

O BSC permite o alinhamento das estratégias da empresa. Para isso, é necessária a realização de um fluxo de etapas inter-relacionadas. A primeira etapa é identificar objetivos estratégicos para cada perspectiva. Depois, deve-se associar medidas com cada um dos objetivos estratégicos. Além disso, uma composição de quantitativo e qualitativo deve ser utilizada. Então, é necessário atribuir metas para as medidas. A próxima etapa é listar iniciativas estratégicas para realizar cada um dos objetivos. Por fim, associa-se aos vários objetivos estratégicos por meio de um diagrama de causa e efeito chamado de mapa estratégico.

Como outros mapas estratégicos, este começa no topo com um objetivo financeiro. Esse objetivo é impulsionado por um objetivo de cliente. Por sua vez, o objetivo do cliente é o resultado de um objetivo de processo interno. O mapa continua até o fim de uma hierarquia, em que os objetivos de aprendizado são encontrados, desenvolvendo habilidades-chave.



### Exemplificando

Um objetivo financeiro é o crescimento em segmentos-chave de 10% no próximo ano em relação ao resultado atual. O objetivo de Cliente é construir fortes relações com o cliente por meio de relacionamento. Como Processo interno, a empresa busca reduzir custos de contato com o cliente. Como Aprendizado e crescimento, a empresa busca novas oportunidades de negócio.

## 1.4.3 Six Sigma

Desde a década de 80, o Six Sigma desfrutou de ampla adoção pelas empresas ao redor do mundo. Empresas o utilizam como uma metodologia de melhoria de processos, que permite analisar esses processos, apontar problemas e aplicar soluções. Esta metodologia aplica um processo de melhoria de negócios chamada DMAIC, que representa as etapas: Definir, Medir, Analisar, Melhorar e Controlar.



Como o BPM, o DMAIC é um modelo de melhoria de negócios de circuito fechado que engloba as etapas: definição, medida, análise, melhoria e controle de um processo.

## 1.5 Arquitetura de BPM

O BPM é suportado por diversas tecnologias e aplicações. Na falta de uma lista ou coleção definitiva, o *BPM Standards Group* ([bpmstandardsgroup.org](http://bpmstandardsgroup.org)) propôs uma arquitetura da tecnologia de BPM, que destaca as tecnologias capacitadoras e algumas das aplicações cruciais necessárias para oferecer suporte aos processos de BPM de ciclo fechado, os quais conectam a estratégia à execução.

Um sistema de BPM necessita de três componentes a fim de contribuir para a implementação bem-sucedida da estratégia: camada de banco de dados, camada de aplicações e camada de cliente ou interface de usuário.

A camada de banco de dados proporciona os metadados e os dados sobre os quais se suportam as aplicações de BPM. Os metadados incluem definições de campo, estruturas hierárquicas, definições de medidas, atribuições de conta, métodos de conversão de moedas, entre outros. A maioria dos sistemas de BPM usa *Datamarts* ou um *Data Warehouse*, que normalmente armazenam os dados em um Banco de dados multidimensional ou de Processamento analítico online (OLAP).

No BPM, é necessária uma grande variedade de aplicações para abranger os processos de ciclo fechado, que partem de planejamento estratégico ao planejamento operacional e orçamentos para monitoramento a ajustes e ação.

### 1.5.1 Benefícios do BPM

Os principais benefícios são Melhoria de Serviço, Redução de Custo e Maior Lucro. Também ocorre melhoria de qualidade da informação para a tomada de decisão. Com BPM, a decisão estratégica é, finalmente, embasada na capacidade real dos processos e seu alinhamento com os objetivos do negócio, e não mais apoiada em suposições funcionais e percepções múltiplas e desconectadas do todo.

Com isso, será mais fácil que os colaboradores das diversas áreas trabalhem com o mesmo propósito, buscando maximizar as métricas e medidas da organização, diferentemente do que ocorre quando cada área busca atingir os melhores resultados individualmente.

## 1.6 Aplicações de *Scorecards*

*Scorecards* são um recurso genérico de BI que também podem vincular indicadores de desempenho a um mapa estratégico, a partir de uma relação hierárquica de causa e efeito entre os KPIs.

A interface de usuário é o ponto de contato entre as aplicações de BPM e o usuário final. A interface particular fornecida depende da aplicação específica que está sendo acessada, bem como do papel do usuário, seus objetivos e sua experiência.

*Scorecards* e *Dashboards* são componentes comuns de quase todos os sistemas de gerenciamento do desempenho, sistemas de medição do desempenho e pacotes de softwares de BPM.

Tanto *Dashboards* quanto *Scorecards* proporcionam exibições visuais de informações relevantes, que são consolidadas e organizadas em uma tela única, para que sejam absorvidas rapidamente e exploradas facilmente.

Um *Dashboard* exibe vários dados de KPI e pipeline para uma empresa de software, que produz componentes especializados de gráficos e apresentações visuais para desenvolvedores de *software* e os vende diretamente pela Web. Enquanto um *Scorecard* mapeia o progresso, o *Dashboard* mede o desempenho. O *Dashboard* é voltado para um público específico e especialista, enquanto o *scorecard* é utilizado por executivos, gerentes e demais funcionários.

## 1.7 Monitoramento de atividade de negócio (BAM)

Monitoramento de atividades de negócios (BAM) é um termo inventado pela Gartner, uma empresa de consultoria fundada em 1979 por Gideon Gartner. O termo reflete o interesse da empresa e de outras consultorias nos conceitos estratégicos da empresa de latência zero e de processamento direto (*straight-through processing*) (MCKIE, 2003).

Uma empresa de latência zero é aquela na qual os dados estão imediatamente disponíveis, permitindo a uma empresa ser proativa ao invés de reativa. Processamento direto se refere ao processo no qual etapas ineficientes (como registro manual) são eliminadas.

Essencialmente, os dois benefícios mais importantes são acesso em tempo real aos dados, em um formato utilizável, e acesso às ferramentas para colaboração e modelagem do problema, levando a uma solução rápida.

## Situação problema

Em 1946, foi fundada na Austrália a transportadora TNT com apenas um caminhão. Em 1958, a empresa atendia toda a Austrália. E em 1978, mudou sua sede para a Inglaterra. Em 2015, essa corporação era uma das maiores transportadoras de carga expressa do mundo e tinha mais de 56.000 funcionários em 61 países. Por ser uma empresa global, TNT buscou projetar uma imagem consistente pelo mundo com o slogan “Sure we can”.

Alguns dos valores da empresa são satisfazer seus clientes a todo tempo, desafiar e melhorar tudo que a empresa faz e medir o sucesso por meio de um lucro sustentável. A estratégia de negócios foca na entrega como uma experiência do consumidor superior aos concorrentes. Para isso, a TNT empregava sofisticada tecnologia para checar exatamente onde as entregas dos clientes estavam em tempo real.

No mapa estratégico, foi definido que, para se chegar ao lucro sustentável, a empresa deveria possuir excelência operacional, trazer inovações e gerenciar o relacionamento com seus clientes.

Como a empresa conseguiu integrar seus objetivos estratégicos com entregas operacionais?

A empresa implementou um sistema de medição das ações, o Balanced Scorecard (BSC). Com ele, era possível estabelecer uma ligação entre as atividades operacionais e a estratégia, mensurando o impacto. O mapa estratégico da TNT e seu plano de comunicação foi considerado o melhor da categoria. Desde a implantação do BSC, a empresa aumentou *market share*, aumentou a fidelização de seus clientes e alcançou um maior retorno percentual sobre o faturamento.

Para manter a excelência de seus serviços, a empresa precisava de um sistema avançado de análise de dados, e o degrau para alcançar esse objetivo foi a Inteligência de Negócios ou *Business Intelligence* (BI).

Como a empresa poderia dar um próximo passo, além de monitorar onde a entrega estava?

A empresa adotou ferramentas de BI que eram capazes de realizar análises preditivas para melhorar sua eficiência operacional, além de dar continuidade na qualidade de serviços oferecidos aos consumidores por meio de novas técnicas estatísticas. Com isso, foi possível prever determinados problemas ou situações inconvenientes, as quais poderiam ocorrer com as entregas dos clientes.

A TNT escolheu as ferramentas SAS Analytics e SAS Statistics como nova plataforma de BI. Com base nas novas ferramentas obtidas, foi possível desenvolver novas soluções que apoiaram a estratégia da empresa e trouxeram indicadores importantes para melhoria da capacidade analítica da empresa. Em 13 de maio de 2016, a empresa TNT Express foi adquirida pela americana Fedex, em um negócio de 4 bilhões de euros. Nada mal para quem começou com apenas um caminhão.

## Bibliografia Adicional Referente à Situação Problema

BUSINESS CASE STUDIES. **Delivering a business strategy: A TNT case study**. Disponível em: <<https://businesscasestudies.co.uk/tnt/delivering-a-business-strategy/introduction.html>>. Acesso em: 12 maio 2018.

TI INSIDE ONLINE. TNT usa novas ferramentas analíticas para melhorar eficiência operacional. 2015. Disponível em: <<http://tiinside.com.br/tiinside/services/12/08/2015/tnt-usa-novas-ferramentas-analiticas-para-melhorar-eficiencia-operacional/>>. Acesso em: 12 maio 2018.

## Questão para reflexão

É mais difícil ser conciso em aspectos de medição de indicadores do que ter muitas medições. No caso de uma empresa que atue em vários segmentos, como deve ser realizado o *Balanced Scorecard* dessa organização?

## Considerações finais

- BPM é uma estrutura para organizar, automatizar e analisar as metodologias de negócios, métricas, processos e sistemas, de modo a impelir o desempenho geral da empresa.
- *Balanced Scorecard* (BSC) é uma medida de desempenho e metodologia de gerenciamento, que ajuda a traduzir os objetivos e metas financeiras, de clientes, de processos internos e de aprendizado e crescimento de uma empresa em um conjunto de iniciativas passíveis de implementação.
- Com a implantação do BPM será possível que os colaboradores das diversas áreas trabalhem com o mesmo propósito, buscando maximizar as métricas e medidas da organização.
- Monitoramento de atividade de negócio (BAM) são sistemas em tempo real que alerta os gerentes sobre possíveis oportunidades, problemas iminentes e ameaças, capacitando-os a reagir com modelos e colaboração.

## Glossário

**Balanced Scorecard (BSC):** metodologia de gerenciamento e medição de desempenho que ajuda a traduzir os processos financeiros, de cliente, objetivos e metas de aprendizado e crescimento da empresa em um conjunto de iniciativas acionáveis.

**Business performance management (BPM):** abordagem avançada de medição e análise de desempenho que inclui planejamento e estratégia.

**Dashboard:** apresentação visual de dados críticos para executivos, mostrando claramente pontos de atenção.

**Fatores críticos de sucesso (FCS):** fatores-chave que descrevem as ações que uma empresa deve primar para ser bem-sucedida no seu espaço de mercado.

## Verificação de leitura

**QUESTÃO 1-** A primeira etapa para um BPM é:

- a) fazer a estratégia;
  - b) elaborar o *scorecard*;
  - c) definir o orçamento;
  - d) instalar todos os *softwares* para BSC;
  - e) monitorar o desempenho.
- 

**QUESTÃO 2-** Complete a frase: \_\_\_\_\_ e \_\_\_\_\_ são componentes comuns em quase todos os sistemas de gerenciamento do desempenho, sistemas de medição do desempenho e pacotes de *softwares* de \_\_\_\_\_.

- a) estratégia; planos; BPM.
  - b) *scorecard*; *dashboard*; BPM.
  - c) financeiro; produtos; BSC.
  - d) *balanced*; *scorecard*; BAM.
  - e) *Data warehouse*; ferramentas de análise; BI.
- 

**QUESTÃO 3-** Assinale a alternativa correta.

- a) No BPM, basta medir vários indicadores, sem que seja preciso analisá-los.
  - b) BPM é uma abordagem avançada de medição e análise de desempenho, mas não inclui a estratégia.
  - c) BPM e BI são sinônimos e não há diferença entre eles.
  - d) O BPM não acrescentou nenhuma melhoria em relação ao gerenciamento de qualidade total (TQM).
  - e) BPM auxilia na execução da estratégia da empresa.
-

## Referências bibliográficas

BPM STANDARDS GROUP. **Business Performance Management**: Industry Framework Document. 2005. Disponível em: <[www.bpmpartners.com/documents/BPMIndustryFramework-V5.pdf](http://www.bpmpartners.com/documents/BPMIndustryFramework-V5.pdf)>. Acesso em: 12 maio 2018.

BRITTO, Gart Capote de. **BPM Para Todos**: Uma Visão Geral Abrangente, Objetiva e Esclarecedora sobre Gerenciamento de Processos de Negócio. 1ª ed. Rio de Janeiro: Gart Capote, 2012. Disponível em: <[http://www2.unifap.br/clauidiomarcio/files/2016/10/bpm\\_para\\_todos-\\_julho\\_2013.pdf](http://www2.unifap.br/clauidiomarcio/files/2016/10/bpm_para_todos-_julho_2013.pdf)>. Acesso em: 12 maio 2018.

HAMMER, Michael. **Agenda**: What Every Business Must Do to Dominate the Decade. Pittsburgh: Three Rivers Press, 2003.

KAPLAN, R.; NORTON, D. **The Balanced Scorecard**: Translating Strategy into Action. Boston: Harvard University Press, 1996.

MCKIE, S. The Big BAM. **Intelligent Enterprise**, 18 jul. 2003.

NIVEN, P. **Balanced Scorecard Diagnostics**. Hoboken: Wiley, 2005.

TURBAN, Efraim; SHARDA, Ramesh; ARONSON, E.; KING, David. **Business Intelligence**: Um Enfoque Gerencial. Porto Alegre: Bookman, 2009.

WADE, D.; RECARDO, R. **Corporate Performance Management**. Boston: Butterworth-Heinemann, 2001.

## Gabarito

### QUESTÃO 1- Resposta A.

A primeira etapa é fazer a estratégia, pois o plano, o monitoramento e as ações e ajustes irão depender dessa etapa.

-----

### QUESTÃO 2- Resposta B.

*Scorecards* e *Dashboards* são componentes comuns de quase todos os sistemas de gerenciamento do desempenho, sistemas de medição do desempenho e pacotes de softwares de BPM.

-----

### QUESTÃO 3- Resposta E.

BPM é uma abordagem avançada de medição e análise de desempenho que inclui planejamento e estratégia.

-----



