FIAP ON

BIG DATA

INTRODUÇÃO AO BIG DATA

1

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 – Métricas e valores correspondentes.....5
Figura 2 – A nova era digital.....6
Figura 3 – A nova era digital.....7
Figura 4 – The Nexus of Forces (por Gartner) 9
Figura 5 – Novo *mindset* 9
Figura 6 – Evolução da computação 10
Figura 7 – Volume e complexidade 12
Figura 8 – Os 3Vs de Big Data.....13
Figura 9 – Volume relativo.....13
Figura 10 – Analogia entre volume e o microscópio.....15
Figura 11 – Arquitetura analítica tradicional 16
Figura 12 – Exemplo de velocidade – Google.....18
Figura 13 – Dados produzidos a cada 60 segundos 20
Figura 14 – Data Science.....25

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE QUADROS

Quadro 1 – Definições de dados estruturados, não estruturados e semiestruturados 19
Quadro 2 – Um novo modelo de negócios baseado em APIs (*APIs as a Business*).24

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

BIG DATA - O INÍCIO 5
1 POR QUE BIG DATA? 5
2 A EVOLUÇÃO COMPUTACIONAL 10
3 OS VS DE BIG DATA 12
3.1 Volume 13
3.2 Velocidade 16
3.3 Variedade 18
3.4 Veracidade 21
3.5 Valor 22
3.5.1 Monetização dos dados: 22
4 TEOREMA CAP 25
REFERÊNCIAS 29
GLOSSÁRIO 30

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

BIG DATA - O INÍCIO

1 POR QUE BIG DATA?

Se você nasceu a partir de meados da década de 1990, pode se considerar um cidadão nativo da era digital. Caso tenha alguns anos adicionais, você pode se considerar um imigrante digital.

Em 2012, um dos executivos da Google, Eric Schmidt, mencionou: “[...] a cada dois dias, produzimos um volume de conteúdos digitais equivalente ao que geramos dos primórdios da civilização até 2003 – ou seja, cerca de cinco exabytes de informações” (SCHMIDT; COHEN, 2013, p. 261). E este ritmo está aumentando. Em 2015, esse volume foi produzido em menos de 24 horas. A Figura mostra a métrica e seu valor correspondente. Estamos rumo ao yottabyte.

Decimal		
Value	Metric	
1000	kB	kilobyte
1000^2	MB	megabyte
1000^3	GB	gigabyte
1000^4	TB	terabyte
1000^5	PB	petabyte
1000^6	EB	exabyte
1000^7	ZB	zettabyte
1000^8	YB	yottabyte

Figura 1 – Métricas e valores correspondentes
Fonte: FIAP (2018)

Em décadas passadas, vários autores e fontes previam o crescimento exponencial do consumo de dados com o passar dos anos. Essas previsões provaram ser acertadas, atualmente, consumimos dados em atividades que vão desde o acesso a material educacional online e a jogos digitais até teletrabalho e consultas médicas usando telemedicina.

O tamanho do universo digital dobrará de dois em dois anos pelo menos, um crescimento de 50 vezes desde 2010 até 2020. Até 2025, a criação de dados globais deverá crescer para mais de 180 zettabytes. Em 2020, a quantidade de dados criados e replicados atingiu um novo recorde. O crescimento foi maior do que o esperado anteriormente, causado pelo aumento da demanda devido à pandemia da COVID-19.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Os dados gerados por humanos e máquinas estão passando por uma taxa de crescimento global 10 vezes maior do que os dados dos negócios tradicionais e os dados das máquinas a uma taxa de crescimento 50 vezes maior.

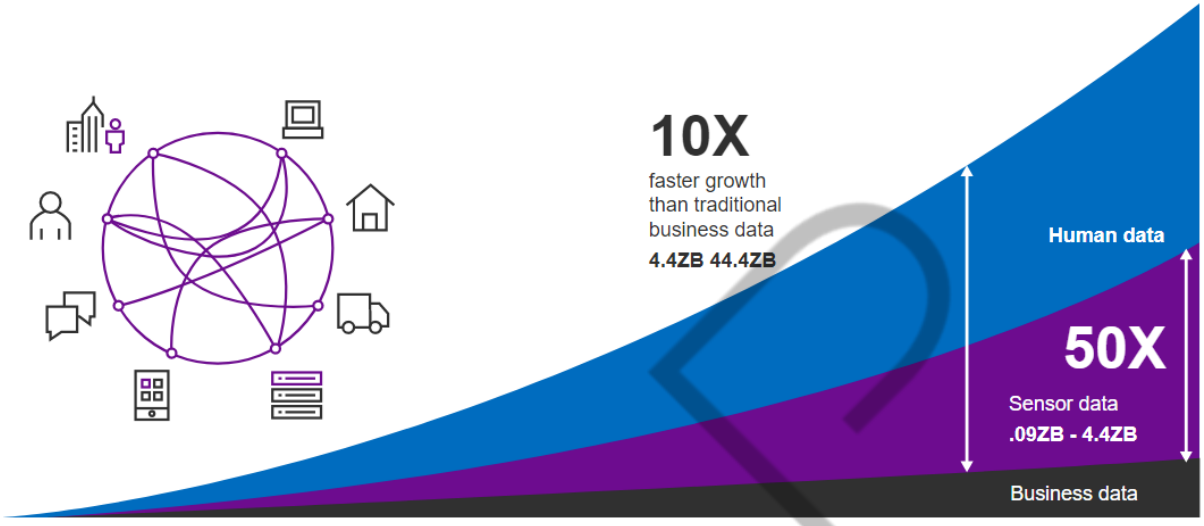

Figura 2 – A nova era digital
Fonte: Elaborado pelo autor (2016)

Raras transformações no mundo ocorreram de forma tão rápida e expressiva, quebrando paradigmas e mudando a sociedade. Em pouco mais de uma década, impérios foram construídos sobre o domínio da tecnologia da informação. Empresas digitais, como Google, Amazon e Facebook, se tornaram motores de inovação e são alimentadas com um valioso combustível chamado “dados”.

A sociedade mudou, interagimos através de uma rede *on-line* e construímos relacionamentos virtuais com nossos familiares, amigos e pessoas que fazem parte do nosso ambiente profissional ou possuem interesses comuns aos nossos. As novas gerações (nativos da era digital) estão naturalmente conectadas e produzindo a matéria-prima para esta nova era, uma fonte inesgotável.

A economia também mudou, agora devemos acrescentar dados para compor a equação (Cesar Taurion – Big Data).

Economia = (Capital + Trabalho + **Dados**)

Hoje, não fazemos negócios e não tomamos uma única decisão sem a análise criteriosa de dados. Vale lembrar de como somos orientados quando dirigimos, dos filmes que assistimos ou dos amigos que adicionamos nas redes sociais. E nas empresas a competência de usar os dados para direcionar a tomada de decisão é

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

determinante para se manter competitivo nesta nova economia, seja para entender melhor a necessidade do seu cliente, seja para criar um produto novo, alterar os processos de negócio, para fazer ou evitar um novo investimento e combater fraudes.

Você pode se perguntar: “Dados não fazem parte da história e evolução da humanidade?”

Sim. Claro!

Temos experimentos científicos que dependem de várias pesquisas documentadas com dados importantes, usados para correlações e estatísticas de pesquisas avançadas. Fazemos isso há anos.

Na Segunda Guerra Mundial, a Inglaterra deu início à construção de uma máquina idealizada pelo matemático britânico Alan Turing, tido como o inventor do computador. O filme *O Jogo da Imitação*, dirigido por Morten Tyldum, conta de maneira contundente como a estratégia baseada em dados para decifrar a criptografia alemã ajudou a finalizar a guerra com anos de antecedência. A importância de analisar os dados criptografados (não estruturados) com latência abaixo de 24 horas, para se antecipar aos ataques alemães, era crucial para vencer esse desafio.

Como podemos perceber, os dados ajudaram a direcionar a evolução da humanidade de maneira expressiva, porém em um ritmo “tímido e limitado” perto da revolução que estamos iniciando.

Proponho definirmos um marco para o Big Data, vamos usar a frase de Eric Shmidt da Google e apontar para o ano de 2003:

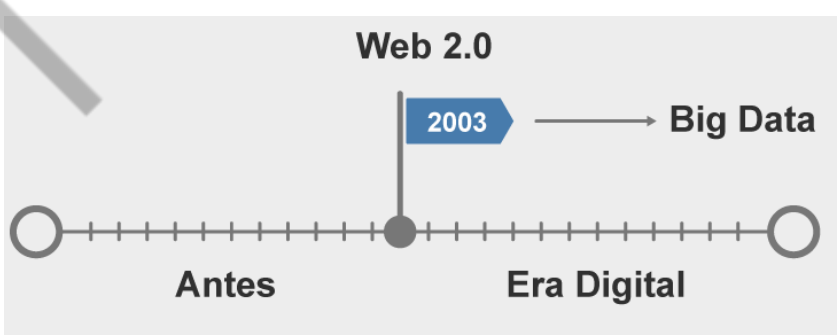

Figura 3 – A nova era digital
Fonte: Elaborado pelo autor (2016)

Definitivamente, estamos usando o adjetivo “BIG” para expressar o que realmente mudou de maneira significativa, que é a dimensão de volume de dados produzidos a partir de 2003 (um marco simbólico).

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Empresas como Google, Amazon, Facebook, eBay, LinkedIn, Netflix, Airbnb e Uber são exemplos de empresas nativas da era digital e representam um novo modelo de negócios estruturado em rede. As redes permitem um crescimento orgânico e acelerado, que transpõe facilmente as fronteiras geográficas. Quanto maior a presença dessas empresas no cotidiano das pessoas, maior sua escalabilidade e maior o potencial de criar Big Data(s). Essas empresas foram pioneiras e atingiram grande parte da população mundial. A tecnologia existente na época não estava preparada para esse nível de escalabilidade, portanto, as gigantes digitais aprenderam a primeira grande lição da era da informação**:**

A inovação deve fazer parte do seu DNA. Só existe uma maneira de continuar crescendo e está diretamente ligada à criação de novas tecnologias. E a capacidade de fazer isso no prazo mais agressivo determina o sucesso dos negócios.

Empresas tradicionais de tecnologia, como Oracle, IBM, HP, Microsoft, entre outras, não almejavam criar soluções para atender startups com propósitos incompreensíveis, do ponto de vista de negócios, e talvez não imaginassem a real capacidade de transformação (inovação) dessas novas empresas. Isso é mais um fator determinante para toda a evolução da tecnologia que vamos abordar mais adiante.

As empresas que direcionam a evolução das tecnologias e arquitetura de Big Data “não” são as empresas tradicionais, e sim os gigantes da era digital. É com eles que vamos aprender sobre Big Data.

O Gartner usou a abordagem “*The Nexus of Forces*” em 2013 para definir os pilares para a TI nesta nova era digital, como mostra a figura “The Nexus of Forces (por Gartner)”:

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

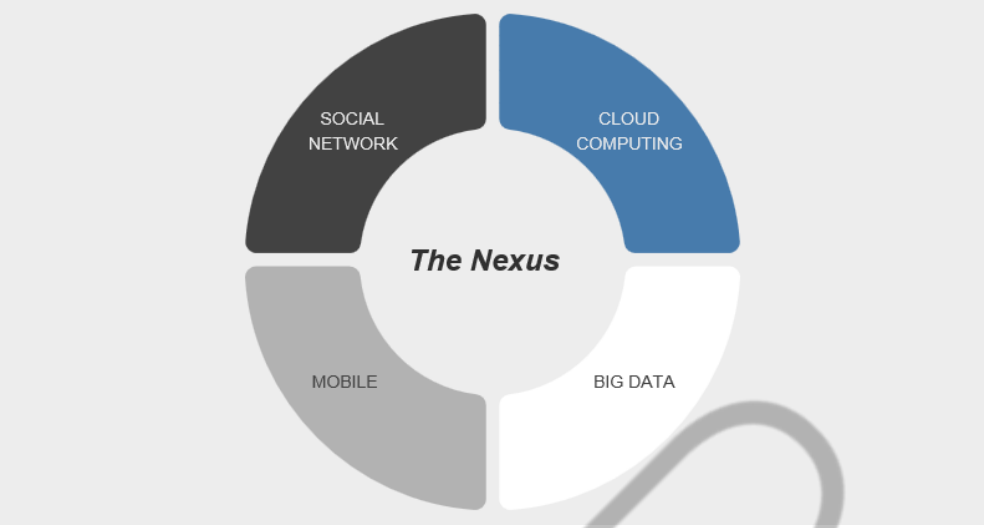

Figura 4 – The Nexus of Forces (por Gartner)
Fonte: Elaborado pelo autor (2016)

A Tecnologia da Informação começou a ser estruturada nesses quatro pilares abordados pelo Gartner: Social Network, Cloud Computing, Mobile e Big Data. Praticamente todas as empresas tradicionais de tecnologia passaram a adotar esse modelo para definir seus pilares de soluções no mercado de TI.

Quando analisamos uma empresa nativa digital, compreendemos que ela já tem essa estrutura bem definida, desde o startup. Isso aumenta muito o seu potencial de inovação e a coloca em vantagem para escalabilidade de Big Data.

Apesar de ser um assunto que requer grande profundidade, vamos resumir uma primeira definição para Big Data como sendo um novo mindset.

Figura 5 – Novo *mindset*
Fonte: Elaborado pelo autor, adaptado por FIAP (2017)

Temos uma grande história de TI e vamos entender melhor essa transição, porém, para avançarmos, é necessário um ajuste no seu mapa mental. Durante anos, acumulamos aprendizado, mitos, pequenos vícios; e tudo isso ocupa um espaço no seu “cache” (memória), bloqueando a entrada de novas maneiras de

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

inovar e resolver problemas. Quanto mais conseguirmos trabalhar essa mudança de mindset, mais fácil será o aprendizado sobre Big Data.

Estamos na quarta revolução industrial e na terceira geração computacional, e para essa nova fase não podemos usar o mapa mental antigo.

2 A EVOLUÇÃO COMPUTACIONAL

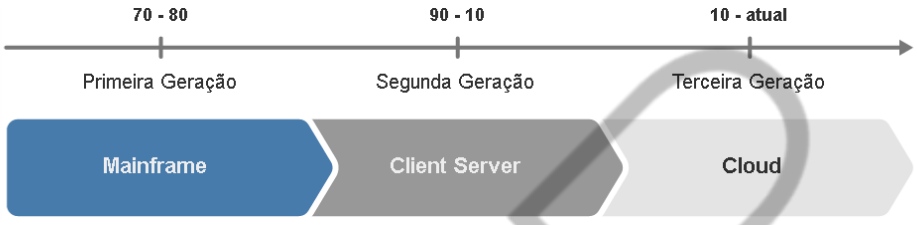

Figura 6 – Evolução da computação
Fonte: Elaborado pelo autor (2016)

Mainframe: computação centralizada e monolítica de implementação relativamente simples. Poucas empresas têm acesso à computação, devido ao alto custo, principalmente. As aplicações eram monolíticas – atendiam aos departamentos e não eram integradas. Do ponto de vista de desenvolvimento, os programadores eram orientados para eficiência tanto pelos recursos limitados computacionais – CPU, storage e memória − como pelo valor ($) de otimizar o uso de recursos.

Client Server: a chegada dos microcomputadores permitiu a computação distribuída e, com isso, muitas soluções de hardware e softwares foram criadas e vários fornecedores surgiram para compor soluções para uma gama maior de empresas. Tudo isso implica uma arquitetura cada vez mais complexa com camadas para representar a interface com o usuário, o processamento das aplicações e o armazenamento de dados. Nas décadas de 80 e 90 foi fortemente trabalhado para implementar o ERP e CRM, principalmente para integração dos dados e processos das empresas existentes em diferentes aplicações. No final da década de 90 se iniciou o “mundo Web” para transformar os negócios em modelos digitais. O desenvolvimento de software desta segunda geração foi orientado para agilidade; devido ao baixo custo de hardware foi perdida um pouco a orientação à eficiência no desenvolvimento. Com o avanço da computação cliente-servidor, a TI se tornou mais democrática e praticamente todas as empresas e pessoas possuem acesso à computação. Os custos associados aos recursos de hardware, software e

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

peopleware desta arquitetura também aumentaram muito. Datacenters foram construídos e equipes, tanto para suporte como para desenvolvimento, foram criadas para tecnologias específicas.

Cloud: a computação em nuvem é o modelo de arquitetura para a terceira geração. Não se engane definir nuvem apenas como um provedor remoto de computação, mas sim um novo padrão de arquitetura para a TI, desde a engenharia de software, plataformas, implementação e principalmente infraestrutura. Os novos modelos são baseados em:

- Flexibilidade;
- Elasticidade;
- Escalabilidade;
- Economia em escala

A arquitetura que suporta os grandes cases de Big Data foram criadas por provedores que adotaram o modelo de arquitetura em nuvem com padrões baseados em web-scale, arquitetura open, altamente eficiente. Em relação à eficiência, imagine uma otimização de um código do Google, consumindo menos 1KB de memória por conexão ao aplicativo do Google Maps. Os ganhos em escala são fatores fundamentais para manutenção dos serviços e garantia da evolução.

Com o *time-to-market* cada vez mais agressivo e as necessidades de tomada de decisões *real time*, a TI tradicional passou a não atender mais as demandas de negócios. Devido à agilidade requerida, este é o principal ponto que impacta negativamente a segunda geração da computação. Precisamos eliminar a burocracia e os serviços operacionais, transformando a TI em uma área estratégica para as empresas, andando à frente do *time-to-market,* posicionando inovações que transformem os negócios e aumentem as oportunidades.

A nova arquitetura em nuvem integra os conceitos de dados operacionais e analíticos, em ambientes geograficamente distribuídos. Com capacidades elásticas *on-demand*, possibilitando *startups* como Easy Taxi, Uber, Airbnb, Instagram e Netflix, que construíram *cases* de referência, incluindo Big Data sobre a plataforma em Nuvem Amazon AWS.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A seguir, mais um exemplo de evolução baseado em demandas, volumes e complexidade de dados.

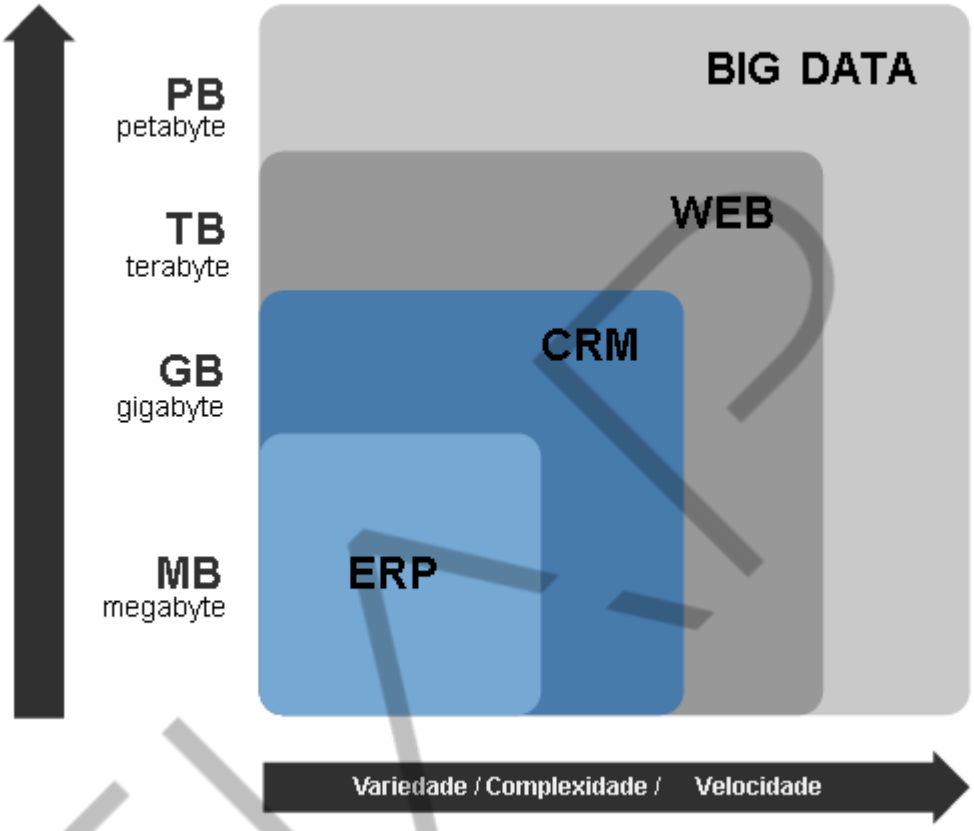

Figura 7 – Volume e complexidade
Fonte: Elaborado pelo autor (2016)

3 OS VS DE BIG DATA

O conceito mais usado para definir os fundamentos de Big Data é baseado em Vs. Inicialmente consideramos os 3Vs – volume, variedade e velocidade − porém podemos considerar 5Vs – adicionando veracidade e valor − e até 7Vs – adicionando variabilidade e visualização. Vamos detalhar alguns destes Vs tão importantes para o entendimento da expressão Big Data.

Abaixo, temos os 3Vs principais e 2Vs complementares.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

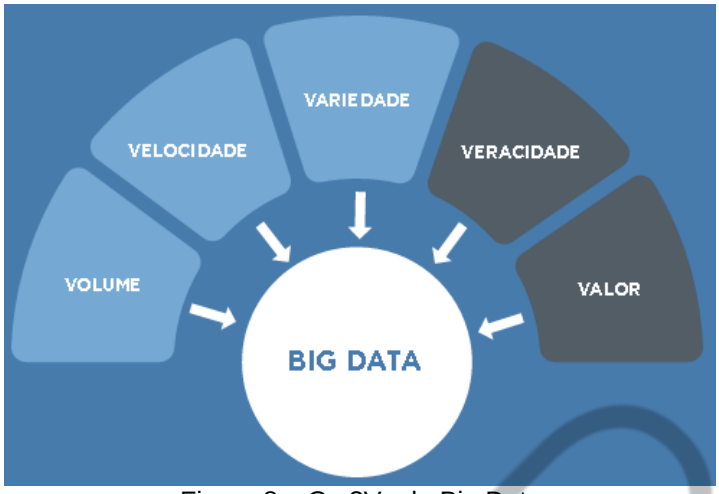

Figura 8 – Os 3Vs de Big Data
Fonte: Elaborado pelo autor (2016)

3.1 Volume

Volume está associado ao armazenamento dos dados, não somente ao tamanho do dado. Imagine o volume associado a um recurso médico (imagem ou filme) ou a um conjunto de dados da sua posição geográfica gerada pelo seu smartphone.

Volume é um conceito relativo, o que é Big Data hoje pode não ser Big Data amanhã. Portanto, precisamos entender essa questão-chave sobre o principal fundamento de Big Data.

Figura 9 – Volume relativo
Fonte: Elaborado pelo autor (2016)

Vamos definir um cenário inicial para identificar qual volume é considerado um Big Data e, nessa definição, utilizaremos o volume em petabytes (que equivale a 1.000 terabytes).

Obs.: Assim como 1 TB, alguns anos atrás, era considerado um grande volume, e havia poucos bancos de dados com essa capacidade, o petabyte será comum para a maioria das organizações, em pouco tempo.

- 10 TB é Big Data?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- 100 TB é Big Data?
- 1 PB é Big Data?

A melhor maneira de responder a essas questões é analisando as tecnologias tradicionais, e, para isso, proponho fazermos a seguinte pergunta:

A solução tradicional (cliente-servidor), seja ela um database, seja uma aplicação ou um *hardware*, está preparada para atender este volume?

Pense sobre:

Custo ($)

Capacidade (por exemplo: Armazenamento, Processamento, I/O)

Arquitetura (por exemplo: Geograficamente Distribuída)

Caso sua resposta seja não, temos aqui a principal motivação para quebrar os paradigmas tradicionais da segunda geração e buscar novas soluções que se enquadrem melhor nas suas necessidades computacionais da terceira geração.

Um database tradicional definitivamente não foi concebido para trabalhar com vários terabytes, sua estrutura foi estressada ao longo da evolução para se adaptar ao crescimento de volumes cada vez maiores. Porém, a partir da nova era da informação, a explosão de dados causou um colapso nas arquiteturas de dados tradicionais e chegamos ao seu limite técnico-financeiro, para a maioria das empresas que operam volumes de dados em petabytes.

Portanto, o V de volume para definição de Big Data está ligado a capacidades que excedem as tecnologias tradicionais.

Uma frase famosa foi usada no Fórum Econômico Mundial de 2011: “Dados são o novo petróleo”.

Esta nova era define que quanto mais dados, “melhor”.

Conforme mencionado no livro *Big Data*, de Cezar Taurion:

“O que o microscópio foi para a medicina e a sociedade, o Big Data também será para as empresas e a própria sociedade.”

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

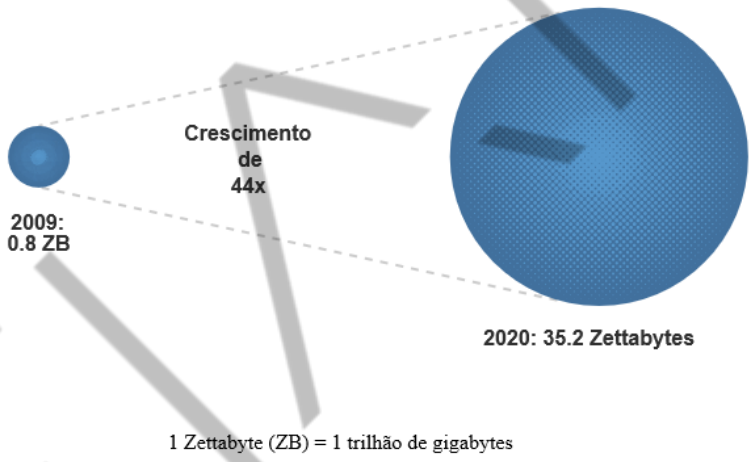

Figura 10 – Analogia entre volume e o microscópio
Fonte: Elaborado pelo autor, adaptado por FIAP (2017)

O microscópio é um instrumento óptico com capacidade de ampliar imagens de objetos muito pequenos graças ao seu poder de resolução. E o que isso tem a ver com o volume de Big Data?

Absolutamente tudo! A capacidade de analisar dados com o máximo de detalhes e a maior granularidade possível permitem análises mais precisas e inteligentes. Trabalhar com Big Data possibilita eliminar processos pesados de filtros e agregações que limitam armazenar todas as variáveis para a tomada de decisão, considerando uma análise mais precisa e complexa. Por isso, entra em cena o próximo V – velocidade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3.2 Velocidade

Velocidade, geralmente, está associada à velocidade de processamento do dado, porém, em Big Data, tem a ver com a velocidade que o processo de negócio precisa daquela informação – *time-to-market*.

A velocidade de negócios requer o dado disponível no momento adequado para tomada de decisão, seja pelo cliente, seja pelo gestor de uma unidade. De nada adianta recomendar um produto após o mesmo já ter sido adquirido pelo cliente. Ou fabricar produtos já em declínio no mercado. Isto requer que a velocidade no tratamento dos dados seja mais rápida do que o processo tradicional.

Vamos analisar o modelo clássico da arquitetura analítica.

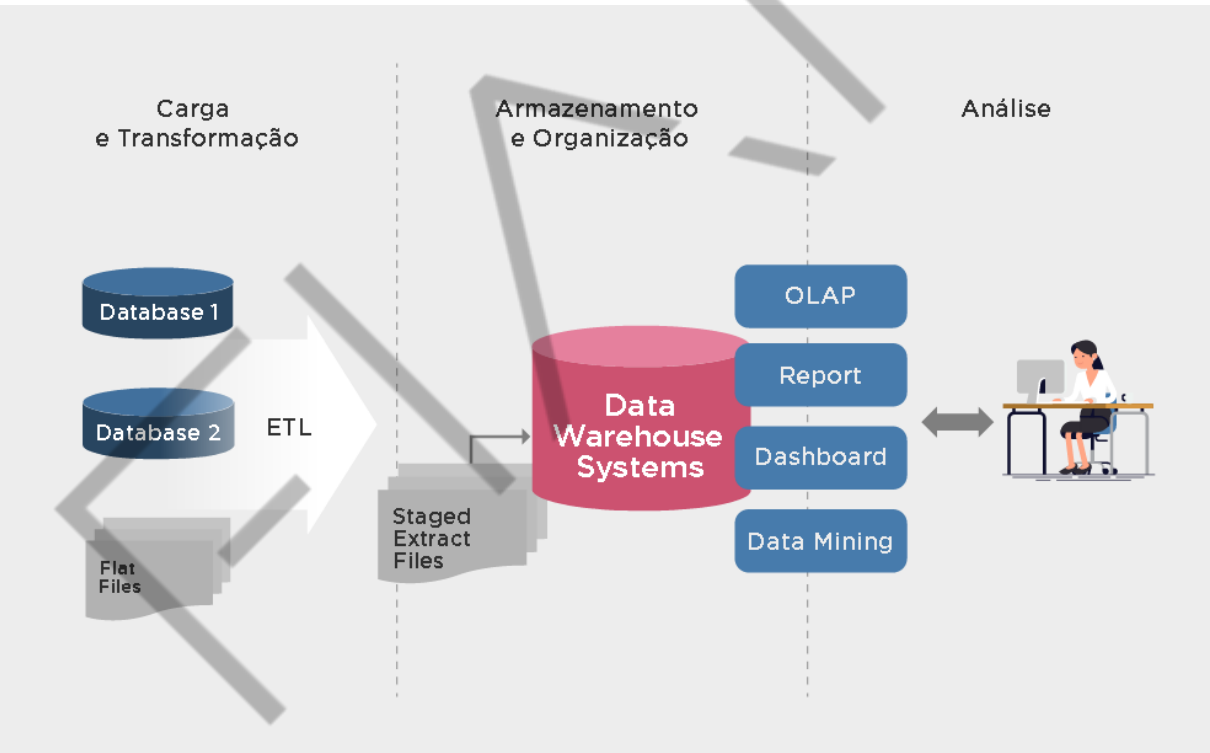

Figura 11 – Arquitetura analítica tradicional
Fonte: Elaborado pelo autor, adaptado por FIAP (2017)

Podemos mencionar sobre os dois principais aspectos relativos à velocidade:

- **Throughput**: a velocidade necessária para processar um grande volume de informações.
- **Latência**: associada ao tempo para aquisição dos dados, para transformação e análise dos dados e para tomada de decisão. Este tempo na arquitetura analítica tradicional era expressa em D-1 (dia anterior), H-1

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

(hora anterior) ou M-1 (mês anterior). A velocidade para análise de informações, ou seja, para chegarmos ao relatório final (D-1 => Data-In-Motion).

O fluxo de dados da arquitetura tradicional acima limita a análise com delta (mês, dia, hora) para a tomada de decisão. As transações que alimentam os bancos de dados operacionais são acumuladas ao longo do período e estão fragmentadas em várias bases, criando silos de informações com visões diferentes. Através de processos ETL (*Extract Transform Load* – Extração, Transformação e Carga), as informações são extraídas dos bancos de dados operacionais, passam por um processo de transformação e são carregadas no Data Warehouse consolidando um modelo de dados dimensional que centraliza os dados com uma visão integrada e consistente na linha do tempo.

Agora vamos analisar um modelo do Google, considerando as necessidades das empresas da era digital.

Para contextualizar, o Google, sem dúvida, é o maior motor de inovação para Big Data, e seu primeiro grande desafio surgiu há mais de uma década, quando encontrou as primeiras barreiras para a evolução do seu algoritmo de PageRank.

> O coração do nosso software é o PageRank(TM), um sistema para dar notas para páginas na web, desenvolvido por nossos fundadores Larry Page e Sergey Brin na Universidade de Stanford. E embora tenhamos dúzias de engenheiros trabalhando para melhorar todos os aspectos do Google no dia a dia, PageRank continua a ser a base para todas nossas ferramentas de busca na web. (POR QUE USAR O GOOGLE, 2011)

O Google faz uso do PageRank e de outros algoritmos com o objetivo de computar (indexar) e otimizar as buscas na web.

Para um exemplo hipotético, considere o cenário abaixo, com o volume de 200 TB e a capacidade de processamento de 50 MB/s (megabytes por segundo).

Qual é o tempo estimado para a análise dos 200 TB de dados?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

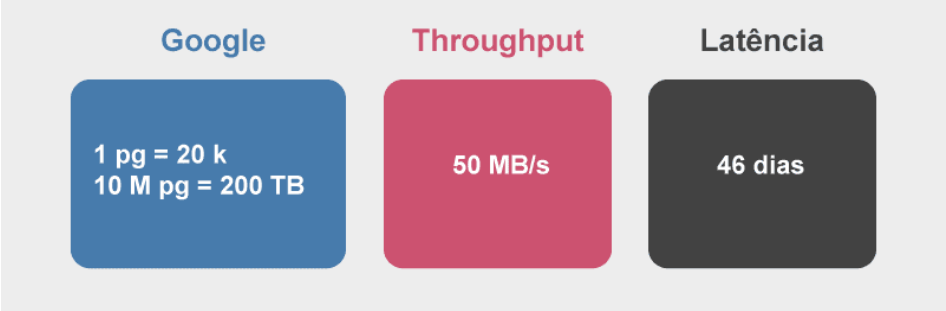

Figura 12 – Exemplo de velocidade – Google
Fonte: Elaborado pelo autor, adaptado por FIAP (2017)

O que deverá ser realizado para otimizar a latência de 46 dias (tempo de processamento)?

Faça uma analogia com uma pessoa que tem o desafio de ler um livro de 1.000 páginas em 1 dia. Se o seu *throughput* é de 1 página a cada 5 minutos, considerando que terá 8 horas para dormir e 16 horas para a leitura, conseguiria atingir no máximo 192 páginas por dia (sem considerar horas de refeições ou possíveis interrupções).

O uso de computação distribuída com capacidades de processamento e armazenamento massivo de dados é o caminho para soluções de Big Data.

As arquiteturas tradicionais tiveram dificuldades para escalar velocidade, assim como seria humanamente impossível ler o livro de 1.000 páginas com baixa latência.

Considere a possibilidade de distribuir as páginas do livro para um grupo de dez pessoas, e em vez de uma pessoa ler o livro sozinha, teremos dez pessoas lendo o livro em paralelo, considerando porções de cem páginas por pessoa. Este é um exemplo clássico de dividir para conquistar e a solução para reduzir a latência e aumentar o *throughput* do todo.

3.3 Variedade

A variedade dos dados está ligada principalmente à maneira como podemos trabalhar a identificação de seu conteúdo. Aqui todas as fontes de dados são consideradas, sejam transações, filmes, fotos ou conexões para obtermos conteúdo como sentimentos, localização, pessoas, entre outros. Algumas fontes já apresentam o conteúdo de forma estruturada, outras semiestruturada e outras não estruturadas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Imagine uma farmácia com diversos medicamentos sem identificação de rótulos nas embalagens e sem etiquetas nas prateleiras. Considere que cada medicamento tem um código único (chave) de identificação que o associa a uma lista com as descrições detalhadas sobre sua composição, processo de fabricação, qualidade e regulamentações de saúde, desde a origem dos laboratórios até as prateleiras das farmácias. Por meio desse novo modo de identificar as propriedades dos medicamentos, podemos consultá-los considerando um número muito maior de atributos.

Dados estruturados (menor parte):	Provenientes de sistemas transacionais tradicionais.
Dados não estruturados (imensa maioria):	Gerados por e-mails, mídias sociais (Facebook, Twitter, YouTube, entre outros), documentos eletrônicos, vídeos e imagens, sensores, RFIDs. Estima-se que mais de 80% dos dados gerados atualmente são não estruturados.
Dados semiestruturados:	Normalmente registros de sensores, máquinas ou logs, por exemplo.

Quadro 1 – Definições de dados estruturados, não estruturados e semiestruturados
Fonte: Elaborado pelo autor (2017)

A Web 2.0 foi um grande *milestone* (marco) para avançarmos com a computação de terceira geração. Novas semânticas de dados foram criadas com o objetivo de aproximar a linguagem humana da linguagem da máquina. Os conceitos de colaboração e interoperabilidade dos dados já são pensados há mais de uma década com esse propósito; e com o auxílio da web semântica, conseguimos evoluir adotando padrões que ajudam a integrar aplicações com o objetivo de compartilhar informações com ampla facilidade.

O infográfico abaixo apresenta uma visualização clara de como estamos produzindo informações com mais volume, velocidade e variedade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 13 – Dados produzidos a cada 60 segundos
Fonte: Doug Austin (2021)

O infográfico para 2021 destaca as empresas digitais, como TikTok e Tinder.

Para facilitar essa definição conceitual de variedade, consideramos que os dados estruturados são aqueles submetidos a processos de modelagens com o objetivo de normalizar e/ou definir um esquema (tabelas, colunas, *data type*, *constraints*) mais rígido, basicamente os dados que armazenamos em um SGBDR (Sistema Gerenciador de Banco de Dados Relacional). De maneira simples, o restante são dados não estruturados.

Big Data não tem o objetivo de tratar apenas os dados não estruturados, muito pelo contrário, sempre haverá uma necessidade de implementar algum tipo de estrutura para evoluir os metadados e facilitar o acesso aos dados. Alguns componentes de soluções Big Data são inclusive projetados para suportar SQL (Structured Query Language), por exemplo, um pouco longe dos conceitos de relacionamento, porém com base na sua estrutura tabular.

Mas um dos grandes diferenciais em relação ao padrão tradicional é a capacidade de manipular os dados não estruturados, considerando que as

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

plataformas de segunda geração da computação (cliente-servidor) não foram projetadas para isso.

3.4 Veracidade

O significado de veracidade está intimamente ligado a tudo o que diz respeito à verdade.

Trabalhando com os dados estruturados ou não estruturados, é importante garantir que os dados são autênticos e fazem sentido, para evitar tomada de decisões com base na análise de dados incertos e imprecisos.

Pode ser prudente atribuir uma pontuação (*score*) de veracidade dos dados e classificação de conjuntos específicos de dados para garantir a qualidade da informação.

Quando analisamos dados de redes sociais, considerando análises de textos, por exemplo, corremos sérios riscos de concluirmos a análise com dados não verídicos, tais como as *fake news* ou dados gerados por robôs. O que acontece com uma mentira reproduzida milhares de vezes na internet? Torna-se verdade, não é mesmo? Se não criarmos um processo de mitigação de cenários como estes, podemos tomar decisões imprecisas e pouco confiáveis.

Sempre foi importante tratar a veracidade dos dados, porém, diferentemente dos modelos analíticos baseados em BI (*Business Intelligence*) tradicional, em que podemos confiar de “olhos vendados” nas fontes de dados comuns (ERP, CRM, Aplicações Corporativas), Big Data deve se preocupar muito mais com a veracidade, considerando as várias fontes de dados e a velocidade que precisamos impor para a análise.

À medida que as empresas avançam na adoção de Big Data, naturalmente o maior volume de dados poderá ser proveniente da nuvem e corresponder a novas semânticas. Assim, a curadoria dos dados será uma disciplina importante para a governança corporativa.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3.5 Valor

Informações são comercializadas há muito tempo, em jornais, revistas, filmes, livros etc. Fontes de dados financeiros são produtos valiosos, e empresas como a Serasa Experian e Boa Vista Serviços lucram vendendo informações para o mercado, que depende delas, seja para crédito, seguros, antifraude, seja para alavancagem de clientes.

Quando trabalhamos com Big Data, os valores que buscamos dos dados devem ser definidos com clareza. Este é o maior motivador para direcionar um *use case* de Big Data.

Não é relevante armazenar um grande volume com possíveis variedades e requisitos de velocidade sem considerar um objetivo claro de extrair valor dos dados. Faça uma analogia com a exploração de uma plataforma de petróleo. Podemos ter valor extraindo dados para cada departamento, ou juntarmos os dados para toda empresa ou ainda compartilharmos os dados com todo ecossistema envolvido.

Como as organizações podem fazer para aumentar receita, reduzir custos, diminuir fraudes e melhorar *compliance*?

A necessidade de gerar valor é o principal objetivo de Big Data. Esse valor pode ocorrer pela agilização da tomada de decisão, aumento da precisão da análise com mais dados sendo correlacionados, redução dos riscos, criação de oportunidades. E assim justificamos um projeto de Big Data.

O valor pode ser muito mais do que uma forma de rentabilizar a receita para a corporação. Considere os avanços nas pesquisas contra o câncer e doenças graves, a evolução nos controles do uso sustentável da água potável, maior transparência na gestão de contas públicas, deste modo somos induzidos naturalmente a usar os dados para resolver problemas e evoluir com mais precisão nas análises complexas, que até pouco tempo atrás eram inviáveis.

3.5.1 Monetização dos dados:

Qual é o valor do seu ativo de dados?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O objetivo de monetizar os dados está relacionado à geração de receitas financeiras a partir de fonte de dados disponíveis ou em tempo real. Em resumo, tratar os dados efetivamente como um produto.

Algumas empresas de software especializadas em dados (com domínio de Big Data) estão criando soluções baseadas em modelos de negócios que propõem um compartilhamento de receita (*revenue share*) e usam o ativo dados das empresas como matéria-prima para alavancar receitas.

Considere o potencial de uma empresa de telecomunicações com enormes volumes de dados e possibilidades de reduzir o custo de campanhas de marketing com propostas mais precisas. Por exemplo, no Brasil, as operadoras têm milhões de clientes, e as campanhas direcionadas para todos eles são pouco precisas e custam um valor altíssimo. Uma empresa fornecedora de soluções de análises baseadas em *revenue share* poderia propor uma abordagem mais precisa para a campanha, usando técnicas de *real time analytics* e reduzindo os custos de uma campanha de marketing com a proposta de atingir o público-alvo, segmentando com grupos de clientes ou até mesmo direcionado a cada cliente com base em eventos específicos. Aqui a diferença para a abordagem tradicional é a possibilidade de individualizar a oferta no momento preciso da necessidade.

Ou uma empresa financeira que pretende baixar os índices de fraudes de 0,1% (que representam milhões de reais mensais) para 0,01%. A empresa fornecedora da solução de análise de dados pode propor 30% do compartilhamento da receita (alguns milhões de reais) em caso de sucesso, referente ao retorno financeiro previsto. A empresa financeira não deverá pagar nada além do resultado comprometido, inclusive considerando a possibilidade de não obter sucesso, a empresa fornecedora da solução não receberá sobre o trabalho. Será um ótimo negócio para ambos, e dessa forma, muitas empresas e consultorias especializadas em monetizar os dados emergirão. Os dados considerados são do ecossistema, não somente os conhecidos pela empresa.

Empresas não consideram a importância do valor de ativo de dados e pouco investem na estratégia para tratar os dados como um produto. O desafio de direcionar os negócios com base em dados mudará essa postura de negligência e, aos poucos, empresas tradicionais serão naturalizadas como empresas digitais.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Como vimos, a computação em nuvem ajuda na evolução de soluções com maior escalabilidade, e os modelos de negócios passaram a ser construídos com base em *social network* (rede), com colaboração e geograficamente distribuídos.

Podemos criar grandes ativos de dados fazendo uso de estratégias baseadas em API (*Application Programming Interface*), um conceito bastante difundido no desenvolvimento de software na era da computação em nuvem e importante para os novos modelos de arquitetura de TI.

A API propõe alguns mecanismos de interfaces para que possamos monetizar bases de dados. Por exemplo: o Google possui uma base de geolocalização com o serviço do Google Maps, porém algumas aplicações podem demandar um número de requisições diárias acima do limite considerado *free* e deverão pagar para usar o serviço. Esse modelo já foi implementado por grande parte dos gigantes da internet e deve ser referência para as empresas que estão buscando oportunidades neste mundo de negócios, cada vez mais baseado em dados.

Basic	1.000 requisições p/ dia R$ 100/mês
Dados não estruturados (imensa maioria)	10.000 requisições p/ dia R$ 250/mês
Dados Semiestruturados	ilimitado R$ 500/mês

Quadro 2 – Um novo modelo de negócios baseado em APIs (*APIs as a Business*)
Fonte: Google Imagens (2017)

Esta pode ser a saída para algumas empresas que estão sendo engolidas por um processo de digitalização e dependem de novos produtos, o fato é que os dados são um ativo importante e devem ser usados para alavancar novos negócios, e isso vai muito além do *core business*. Por exemplo, se considerarmos uma base de referência de geolocalização por usuário de uma operadora de telecom, seria uma

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

grande oportunidade usá-la para monetizar um serviço baseado em APIs e alavancar oportunidades.

Dessa forma, em pouco tempo teremos uma infinidade de novos produtos (serviços) sendo orquestrados por um *grid* baseado em APIs. É evidente a necessidade da governança de dados em todos os processos de estratégia de dados, e quando o assunto é monetização, a ética e a segurança devem ser priorizadas.

Assim podemos definir Big Data como um termo genérico para dados que não podem ser contidos nos repositórios usuais; refere-se a dados volumosos demais para caber em um único servidor; não estruturados demais para se adequar a um banco de dados organizados em linhas e colunas; ou fluidos demais para serem armazenados em um data warehouse estático (DAVENPORT, 2014).

Toda e qualquer informação nestes meios pode ser encontrada, analisada e aproveitada em tempo hábil.

Big Data está diretamente associado à Ciência dos Dados (Data Science) – a ciência das redes que utiliza dados digitais em suas pesquisas, combinando matemática, programação e instinto científico para análise dos dados. A Figura mostra esta combinação.

Figura 14 – Data Science
Fonte: Elaborado pelo autor (2016)

4 TEOREMA CAP

Podemos dizer, então, que Big Data trata de grandes volumes de dados (Volume), com informações vindas de diversas fontes (Variedade) e produzem respostas rápidas (Velocidade). Nesta unidade, consideraremos apenas estes três requisitos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Para abordar os três requisitos que definimos para esta unidade, precisamos nos colocar questões que pertencem a dois aspectos que envolvem Big Data:

Declaração de problema: Como processar Big Data usando o estado-da-arte da tecnologia atual sem “estourar” o limite de tempo e o orçamento?

Onde está o "gargalo" do processamento? A velocidade das CPUs está cada vez maior, mas a velocidade de acesso a disco ou a volumes de discos convencionais, ainda é lenta. O aumento da velocidade de CPU não beneficia muito os programas que têm necessidade de acessar grandes volumes de dados.

Em 2000, Eric Brewer, em sua palestra na Universidade de Berkeley, em São Francisco, nos Estados Unidos, propôs o teorema CAP. Essencialmente, o teorema afirma que em qualquer sistema distribuído *stateful* é preciso escolher entre:

- Consistency (consistência forte). Todos os nós veem os mesmos dados ao mesmo tempo.

- Availability (alta disponibilidade). Toda solicitação recebe uma resposta, seja ela bem-sucedida ou não.

- Network Partition Tolerance (tolerância a particionamento dos dados na rede). O sistema continua funcionando mesmo que mensagens sejam perdidas ou parte do sistema falhe.

Entre essas três propriedades, somente duas podem ser garantidas ao mesmo tempo.

Segundo Hanson (2013), os sistemas de banco de dados tradicionais possuem consistência forte e alta disponibilidade, mas não trabalham muito bem com tolerância a particionamento dos dados na rede. Já o sistema de bancos de dados não-relacionais são sistemas altamente tolerantes a falhas, desde que exista um grande número de servidores suportando o sistema, fornecem disponibilidade, mas apenas consistência eventual.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Em relação à tolerância a particionamento, ela pode ser fornecida pelo Hadoop Distributed File System (HDFS). O Hadoop Distributed File System (HDFS) é um sistema de arquivos altamente tolerante a falhas, projetado para executar em hardware, padrão de baixo custo. O HDFS disponibiliza acesso de alto rendimento para os dados do aplicativo e é adequado para aplicativos com grandes conjuntos de dados.

Segundo Bengford (2016), “Hadoop é um storage confiável e um sistema analítico”, composto por duas partes essenciais:

- Hadoop Distributed Filesystem (HDFS), sistema de arquivos distribuído e confiável, responsável pelo armazenamento dos dados.

- Hadoop MapReduce, responsável pela análise e processamento dos dados.

Uma curiosidade: o nome “Hadoop” veio do elefante de pelúcia que pertencia ao filho do criador, Doug Cutting.

Vamos entender melhor uma dessas duas partes essenciais, o MapReduce.

Segundo a IBM (2009), MapReduce é um “Modelo de programação que permite o processamento de dados massivos em um algoritmo paralelo e distribuído, geralmente em um cluster de computadores”. MapReduce é baseado nas operações de Map e Reduce de linguagens funcionais como o LISP. Ele trata os dados como um conjunto de pares <Key, Value> (chave/valor). As operações de entrada leem os dados e geram os pares <Key, Value> e o usuário fornece duas funções Map e Reduce, que são chamadas em tempo de execução.

Em uma operação típica de Map, o nó principal recebe os dados, divide em partes menores e envia aos outros nós para serem processados. Ao final do processamento, estes nós devolvem o resultado ao nó principal. O nó principal obtêm uma lista de pares <Key, Value>, processa os pares e gera um conjunto de pares <Key, Value> intermediário. O nó principal, então, repassa o valor intermediário para a função Reduce. Cada par é processado em paralelo.

Em uma operação típica de Reduce, o nó principal combina as respostas obtidas pelos outros nós gerando o resultado final do processamento. O nó principal processa todos os valores associados com a mesma <Key> e o nó principal mescla os valores para formar um conjunto de valores possivelmente menor. Geralmente,

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

apenas um valor de saída de 0 ou 1 é produzido a cada chamada Reduce. Os valores intermediários são fornecidos à função Reduce do usuário por um iterador, o que permite identificar listas de valores que são grandes demais para a memória.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

AUSTIN, Doug. **Here is Your 2021 Internet Minute Infographic!: eDiscovery Trends** Disponível em: <https://ediscoverytoday.com/2021/04/16/here-is-your-2021-internet-minute-infographic-ediscovery-trends/>. Acesso em: 18 jan. 2022.

BASSO, Guilherme Mastrichi. **Terceirização e o mundo globalizado**: o encadeamento produtivo e a complementaridade de serviços como potencializadores da formação de contratos. Disponível em: <https://juslaboris.tst.jus.br/bitstream/handle/20.500.12178/5388/005_basso.pdf?sequence=5&isAllowed=y>. Acesso em: 9 out. 2014.

BENGFORT, Benjamin; KIM, Jenny (2016). Data Analytics with Hadoop: An Introduction for Data Scientists. EUA: O'Reilly Media.

DAVENPORT, Thomas H. (2014). Big Data at Work: Dispelling the Myths, Uncovering the Opportunities. Boston: Harvard Business Publishing Corporation, 2014.

HANSON, Jeff. (2013) Uma Introdução ao Hadoop Distributed File System. Disponível em: <https://www.ibm.com/developerworks/br/library/wa-introhdfs/index.html>. Acesso em: 12 jan. 2022.

IBM. Administrando Ambari e componentes. Disponível em: <https://www.ibm.com/support/knowledgecenter/pt-br/SSPT3X_4.1.0/com.ibm.swg.im.infosphere.biginsights.admin.doc/doc/admin_icnav_admin.html>. Acesso em: 12 jan. 2022.

MARZ, Nathan, WARREN, James. **Big Data**: Principles and best practices of scalable realtime data systems. Nova York: Manning Publications, 2015.

POR QUE USAR O GOOGLE. 2011. Disponível em: <https://www.google.com/intl/pt-BR/why_use.html>. Acesso em: 12 dez. 2016.

SATHI, Dr. Arvind, **Big Data Analytics**. IBM Corporation: MC Press Online, 2012.

SCHMIDT, Eric; COHEN, Jared. **A nova era digital**: Como será o futuro das pessoas, das nações e dos negócios. Rio de Janeiro: Intrínseca, 2013.

SCHONBERGER, Viktor Mayer; CUKIER, Kenneth. **Big Data:** como extrair Volume, Variedade, Velocidade e Valor da Avalanche de Informação Cotidiana. São Paulo: Campus, 2013.

TAURION, Cesar. **Big Data**. São Paulo: Brasport, 2013.

TUKEY, W. John. **The Future of Data Analysis**. Disponível em: <http://projecteuclid.org/download/pdf_1/euclid.aoms/1177704711>. Acesso em: 12 dez. 2016.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

GLOSSÁRIO

Application Programming Interface - API	Interface de Programação de Aplicativos, em português, é um conjunto de rotinas e padrões de programação para acesso a um aplicativo de software ou plataforma baseado na Web.
Business Intelligence - BI	Inteligência de Negócios, em português, é o processo de coleta, organização, análise, compartilhamento e monitoramento de informações que oferecem suporte a gestão de negócios.
Compliance	Nos âmbitos institucional e corporativo, *Compliance* é o conjunto de disciplinas para fazer cumprir as normas legais e regulamentares, as políticas e as diretrizes estabelecidas para o negócio e para as atividades da instituição ou empresa, bem como evitar, detectar e tratar qualquer desvio ou inconformidade que possa ocorrer.
Customer Relationship Management - CRM	Gestão de Relacionamento com o Cliente, em português, compreende um conjunto de ferramentas (sistemas e processos) que coloca o cliente no centro do desenho dos processos de negócio.
Client Server	Computação distribuída, muitas soluções de *hardware* e software foram criadas, existem vários fornecedores e opções para compor uma solução, isso implica uma arquitetura cada vez mais complexa. Nas décadas de 1980 e 1990, foi fortemente trabalhado para implementar o ERP e CRM. No fim da década de 1990, se iniciou o “mundo Web”, para transformar os negócios em modelos digitais. O desenvolvimento de software dessa segunda geração foi orientado para a agilidade; devido ao baixo custo de *hardware*, foi perdido um pouco da orientação para a eficiência no desenvolvimento. Com o avanço da computação cliente-servidor, a TI se tornou mais democrática e praticamente todas as empresas e pessoas têm acesso à computação.
Cloud	A computação em nuvem é o modelo de arquitetura para a terceira geração. Não se engane: nuvem não é apenas um provedor remoto de computação, mas sim um novo padrão de arquitetura para a TI, desde a engenharia de software, plataformas até a implementação e, principalmente, a infraestrutura.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

	Os novos modelos são baseados em: agilidade; flexibilidade; elasticidade; escalabilidade; economia em escala. A arquitetura que suporta os grandes *cases* de Big Data foi criada por provedores que adotaram o modelo de arquitetura em nuvem com padrões baseados em *web-scale,* arquitetura *open*, altamente eficientes. Em relação à eficiência, imagine a otimização de um código do Google, consumindo menos de 1 KB de memória por conexão ao aplicativo do Google Maps. Os ganhos em escala são fatores fundamentais para a manutenção dos serviços e garantia da evolução.
Enterprise Resource Planning - ERP	Sistema integrado de gestão empresarial, em português, é um sistema de informação que integra todos os dados e processos de uma organização.
Extract Transform Load – ETL	Extração, Transformação e Carga, em português, as informações são extraídas dos bancos de dados operacionais, passam por um processo de transformação e são carregadas diariamente para o Data Warehouse.
Mainframe	Computação centralizada e monolítica, de implementação relativamente simples. Poucas empresas têm acesso à computação, devido ao alto custo principalmente. Do ponto de vista de desenvolvimento, os programadores são orientados para a eficiência e sabem da importância ($) de otimizar o uso de recursos.
Sistema Gerenciador de Banco de Dados Relacional - SGBDR	Sistema que gerencia dados organizados por tabelas e estas compostas por linhas e colunas.
Stateful	Guardam o estado das conexões iniciadas pelo cliente.
Structured Query Language - SQL	Linguagem de Estrutura de Consulta, em português, é uma linguagem universal de acesso a dados em um banco de dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com