FIAP ON

BIG DATA

MODELOS DIMENSIONAIS

3

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 – Livro “A arte da guerra” 5
Figura 2 – Desafios do Big Data.....5
Figura 3 – Dimensões I 9
Figura 4 – Dimensões II 11
Figura 5 – Cubo.....12
Figura 6 – Slicing, dicing, drill.....13
Figura 7 – Fato 14
Figura 8 – Dimensões 15
Figura 9 – Multidimensionalidade.....16
Figura 10 – Exemplo de níveis hierárquicos de uma dimensão 16
Figura 11 – Exemplo de atributos.....17
Figura 12 – Exemplo de surrogate key.....19

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

MODELOS DIMENSIONAIS 4
1 INTRODUÇÃO 4
2 MODELO PARA INFORMAÇÃO GERENCIAL 4
2.1 Manutenção de Histórico.....6
2.2 Granularidade.....6
2.3 Data Warehouse 7
2.4 Modelos Dimensionais 8
2.5 Cubos.....12
2.6 Drills 12
2.7 Fatos 13
2.8 Dimensões 14
2.9 Hierarquia e Compartilhamento.....15
2.10 Medidas.....17
2.11 Chave substituta.....18
2.12 Slow Changing Dimensions, Modelos e Máscaras.....19
2.13 KPI e BSC 20
2.14 ETL.....21
REFERÊNCIAS.....24

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

MODELOS DIMENSIONAIS

1 INTRODUÇÃO

Os modelos dimensionais são necessários para que possa ser criado um ambiente analítico em um Data Warehouse (DW). Um DW é um banco de dados voltado para análise de dados, e que nos permite obter insights e gerar valor para o negócio analisado.

A lista de benefícios dos modelos dimensionais e dos Data Warehouses é extensa. Entre os benefícios podemos destacar:

- Facilidade na execução de queries complexas;
- Repositório único para os dados gerados pela organização;
- O DW armazena apenas o necessário para gerar valor, o que facilita na tomada de decisão;
- Facilidade de integrar outras áreas de negócio e criar diversos data marts para tomada de decisão;
- Dados limpos e sem ruído, o que facilita a geração de dashboards que aumentarão o valor do negócio.

É importante destacar que a modelagem dimensional não depende de nenhuma ferramenta ou tecnologia e sim da análise e do entendimento do ambiente. O foco deste capítulo é apresentar os conceitos sobre o assunto, sendo assim não nos prenderemos a ferramentas.

2 MODELO PARA INFORMAÇÃO GERENCIAL

Segundo o Gartner:

> Business Intelligence (BI) ou Inteligência de Negócio é um termo abrangente (‘guarda-chuva’) que inclui aplicações, infraestrutura, ferramentas e as melhores práticas que permitem o acesso a análise de informações para melhorar e otimizar decisões.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Está associado com o processo de coleta, organização, análise, compartilhamento e monitoramento de informações que oferecem suporte à gestão de negócios.

Fazendo uma analogia a um cenário de guerra com o uso de algumas técnicas milenares, aprendemos que para vencer na guerra é preciso dominar o conhecimento de suas fraquezas e virtudes, assim como as fraquezas e virtudes do inimigo. Sun Tzu, autor do livro “A Arte da Guerra”, ressalta que a falta deste conhecimento e capacidade de reagir com base nas informações podem resultar em derrota.

Figura 1 – Livro “A arte da guerra”
Fonte: Google Imagens (2017)

Trazendo esta visão para o mundo dos negócios, podemos afirmar que as “ameaças” e oportunidades fazem parte das batalhas diárias das empresas, e quanto maior o domínio do conhecimento, mais chances de vencer as batalhas. Portanto, continuamos com os desafios de:

Figura 2 – Desafios do Big Data
Fonte: Elaborado por Allyne Fiorentino de Oliveira (2016), adaptado por FIAP (2017)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Big Data não é um novo modelo de Business Intelligence, não é especificamente uma tecnologia e não substituirá os conceitos de BI.

Com a adoção de Big Data, as empresas ganham um grande impulso, potencializando a Inteligência de Negócio (BI); são capazes de coletar mais dados, com mais velocidade e organizá-los para agilizar e priorizar a tomada de decisões mais complexas, atender o *time to market* e aumentar a capacidade de reagir aos cenários de análises avançadas com preditividade e ação.

2.1 Manutenção de Histórico

Para (KIMBALL, 2013), eventualmente, em algumas situações, pode ser necessário manter o histórico de atualização e mudanças em tabelas como uma forma histórica da versão atual e para isso é necessário um recurso de versionamento de tabelas para o banco de dados.

Uma estrutura simples, com tabelas de dados históricos em séries temporais, descritos através de tabelas de dimensões, pode permitir que o modelo reflita o processo de análise de negócios da empresa.

2.2 Granularidade

De acordo com Kimball (2013), a granularidade de dados está relacionada ao detalhamento das informações, definindo o menor nível da sumarização dos dados, ou melhor dizendo, qual o menor grão o seu projeto analítico pode chegar.

Um exemplo de fácil visualização são os vários níveis de detalhamento de uma análise temporal. Podemos detalhar as informações, entre outras, por ano, trimestre, bimestre, mês, semana, dia, hora. Para determinadas situações, sumarizar e agrupar as informações por mês pode atender as necessidades do cliente, enquanto, em outros casos, talvez seja necessário agrupar e sumarizar os dados por semana ou, quiçá, por dia ou por hora.

A necessidade do detalhamento deve ser avaliada no momento da modelagem, tendo em vista que, quanto menor a granularidade maior é o nível de detalhes.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

É importante notar que, quanto maior o nível de detalhes, maior o volume de dados armazenado. Grandes volumes de dados podem elevar o tempo de resposta das consultas aos dados e, consequentemente, reduzindo o desempenho do seu ambiente.

É importante entender a necessidade do usuário final para definir corretamente a granularidade de seu modelo.

2.3 Data Warehouse

Para Immon (1995): “Um Data Warehouse é uma coleção de dados, orientado a assuntos, integrado, variável em relação ao tempo e não volátil, para suporte ao gerenciamento dos processos de tomada de decisão”.

Dessa definição são extraídas quatro características de um Data Warehouse (DW):

- Orientado para o assunto: Os dados em um DW são organizados para facilitar a análise, sendo que os aspectos interpretativos se sobrepõem aos transacionais. Os dados são organizados por assuntos e não voltado para aplicações ou funções de negócio operacional. Como exemplo de temas podemos citar vendas, marketing, estoque.
- Integrado: Dados de um DW provém de diversas fontes como planilhas, banco de dados e arquivos textos. Os dados também devem ser padronizados, isto é, códigos, unidades de medida, nomes, gênero e formato de data, entre outro atributos, devem ser consistentes. Os dados também podem ser sumarizados (análise quantitativa) ou eliminados.
- Variável em relação ao tempo: Enquanto em um banco de dados transacional os dados referem-se ao dado atual, em um DW, os dados são relativos a um determinado instante de tempo.
- Não volátil: No data warehouse não volátil, os dados são permanentes, ou seja, quando novos dados são inseridos, os dados anteriores não são substituídos, omitidos ou excluídos. Garante-se que qualquer consulta a um dado relativo a um período de tempo sempre produza o mesmo resultado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Em um data warehouse, os dados são somente leitura e são atualizados apenas em determinados intervalos. As duas operações de dados realizadas no data warehouse são o acesso aos dados e o carregamento dos dados.

Data Warehouse é, ao mesmo tempo, uma tecnologia e uma poderosa plataforma para combinar dados a partir de antigas e novas aplicações, resolvendo problemas relacionados com os negócios e acionando dados em direção a objetivos estratégicos das organizações.

2.4 Modelos Dimensionais

Segundo Kimball (2013), existem três modelos dimensionais principais:

Modelo Estrela (também conhecido como modelo Star Schema);

Modelo Floco de Neve (também conhecido como modelo SnowFlake);

Constelação (também conhecido como Fact Constellation ou Galáxia).

Um modelo **Star Schema** pode ser descrito como uma estrela simples; uma tabela central contém dados de fato, e várias tabelas irradiam dela, conectadas por chaves primárias e estrangeiras do banco de dados. Ao contrário de outras estruturas de banco de dados, um esquema em estrela tem dimensões desnormalizadas. O modelo estrela:

- é fácil de entender pelos usuários porque a estrutura é muito simples e direta;
- fornece resposta rápida a consultas com otimização e redução no número físico de junções necessárias entre as tabelas de fatos e dimensões;
- contém metadados simples;
- é compatível com muitas ferramentas de front end;
- é lento para construir devido ao nível de desnormalização.

O esquema em estrela está emergindo como o modelo predominante para data warehouses ou data marts.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

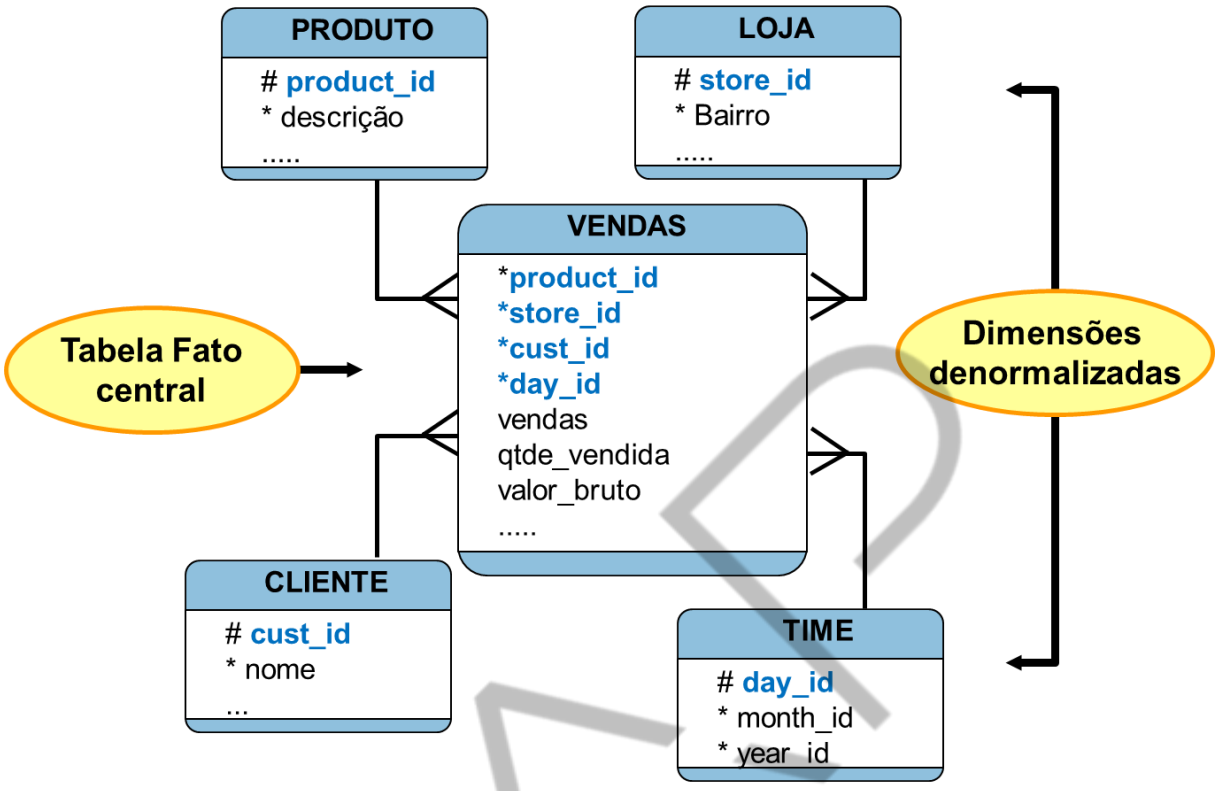

Figura 3 – Dimensões I

Fonte: PAULUCCI (2016)

Principais características:

- Cada coluna de chave estrangeira na tabela de fatos representa uma dimensão.
- As colunas de chave não primária na tabela de fatos são valores que podem ser agregados. As tabelas de fatos não contêm valores de caracteres, estes pertencem às dimensões.
- A estrutura do modelo estrela é semelhante à forma como os usuários entendem as informações.
- O modelo oferece melhor desempenho para consultas analíticas, reduzindo o número de junções.
- Ele permite que consultas complexas sejam expressas pelos usuários finais, porque os dados são organizados de uma maneira fácil de entender e as relações entre as entidades são muito claras.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Ele restringe as medidas numéricas do negócio à tabela de fatos.

Segundo Kimball (2013), diz-se que uma dimensão sofre **flocos de neve** (snowflake) quando os campos de baixa cardinalidade na dimensão são removidos para separar tabelas e vinculados de volta à tabela original com chaves artificiais.

Um modelo floco de neve está mais próximo de um diagrama de relacionamento de entidade do que o modelo clássico em estrela, porque os dados de dimensão são mais normalizados. O desenvolvimento de um modelo floco de neve significa construir hierarquias de classes a partir de cada dimensão (normalizar os dados). Um modelo de floco de neve:

- Resulta em degradação de desempenho severa devido ao seu maior número de junções de tabela.
- Fornece uma estrutura que é mais fácil de alterar conforme os requisitos mudam.
- É mais rápido ao carregar dados em suas tabelas normalizadas menores, em comparação com o carregamento em tabelas desnormalizadas maiores de um esquema em estrela.
- Permite o uso de tabelas de histórico para alteração de dados, em vez de campos de nível (indicadores).
- Tem uma estrutura de metadados complexa, tornando mais difícil a oferta de suporte para o usuário final.
- Um dos principais motivos pelos quais o modelo de esquema em estrela se tornou mais predominante que o modelo em floco de neve é a sua vantagem de desempenho de consulta. Em um ambiente de warehouse, o desempenho de carregamento mais rápido do floco de neve é muito menos importante do que o desempenho de consulta mais lento.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

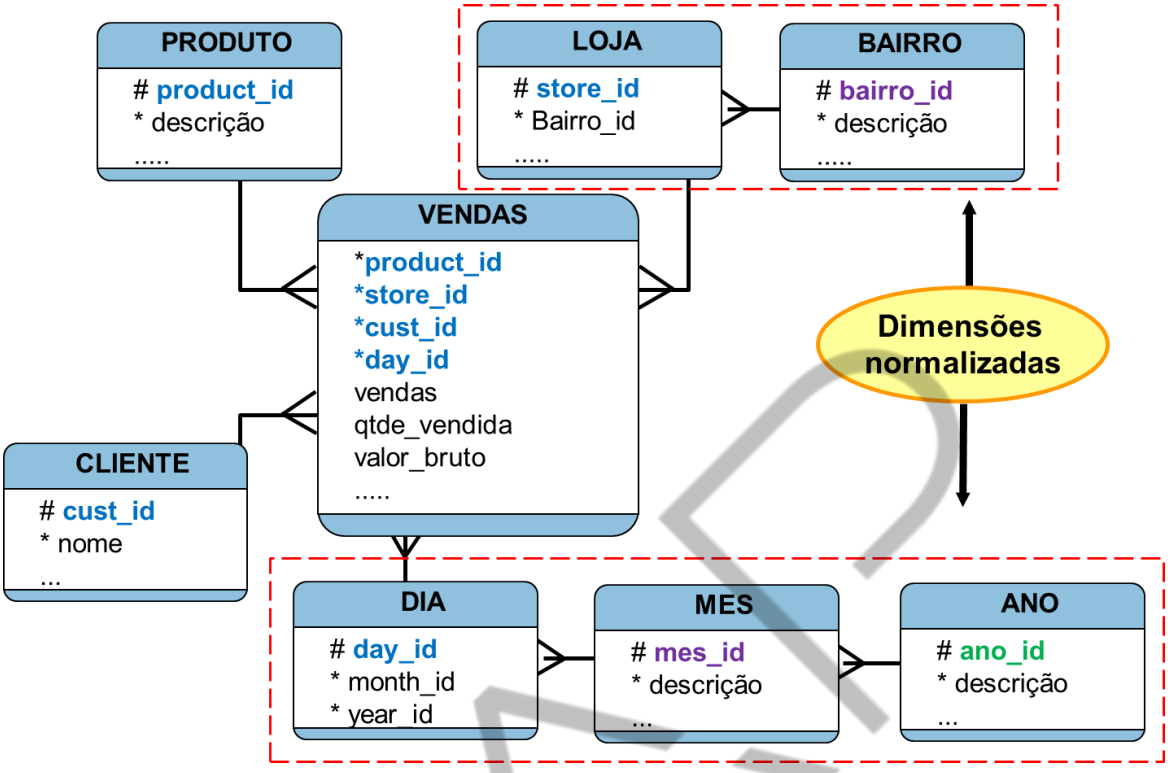

Figura 4 – Dimensões II

Fonte: PAULUCCI (2016)

Suas principais características são:

- Uso direto por algumas ferramentas.
- Mais flexível para mudar.
- Fornece um carregamento de dados mais rápido.
- Pode se tornar grande e incontrolável.
- Degrada o desempenho da consulta.
- Metadados mais complexos.

Um modelo de **constelação** compreende simplesmente uma série de modelos de estrelas. Constelações são um recurso de design útil se você tiver uma tabela de fatos primária e tabelas de resumo de uma dimensionalidade diferente. Ele pode simplificar o design, permitindo que você compartilhe dimensões entre muitas tabelas de fatos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.5 Cubos

Para Kimball (2013), um cubo oferece um local único onde todos os dados relacionados são armazenados para análise. É uma estrutura multidimensional cuja finalidade é conter as informações que são usadas para fins analíticos.

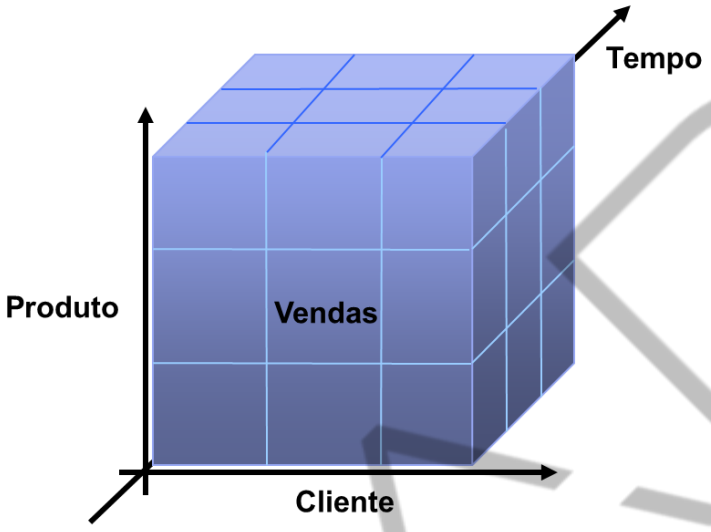

Figura 5 – Cubo

Fonte: PAULUCCI (2016)

A figura 5 mostra um cubo onde é possível analisar as vendas pelas perspectivas de produto, cliente e tempo, ou seja, vendas dimensionadas por produto, cliente e tempo.

2.6 Drills

De acordo com Kimball (2013), a visão multidimensional representada pelo cubo permite executar consultas específicas sobre o modelo de dados, permitindo quatro tipos de operações, considerando-se a granularidade dos dados: Drill Down, Roll Up, Slice e Dice.

As operações drill down e roll up são usadas para fazer movimentos das visões para cima e para baixo ao longo da hierarquia das dimensões. Com o drill down, o usuário é capaz de navegar entre altos níveis de detalhe dos dados, enquanto roll up pode habilitá-lo a aproximar-se ao nível mais sumarizado dos dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Operações como slice e dice promovem a navegação dos dados através da figura do cubo. Slice faz o corte do cubo, de modo que se possa dar enfoque sobre algumas perspectivas específicas. Dice é a operação que permite a rotação sob outras perspectivas, de modo que o usuário possa fazer uma análise mais acurada dos dados apresentados.

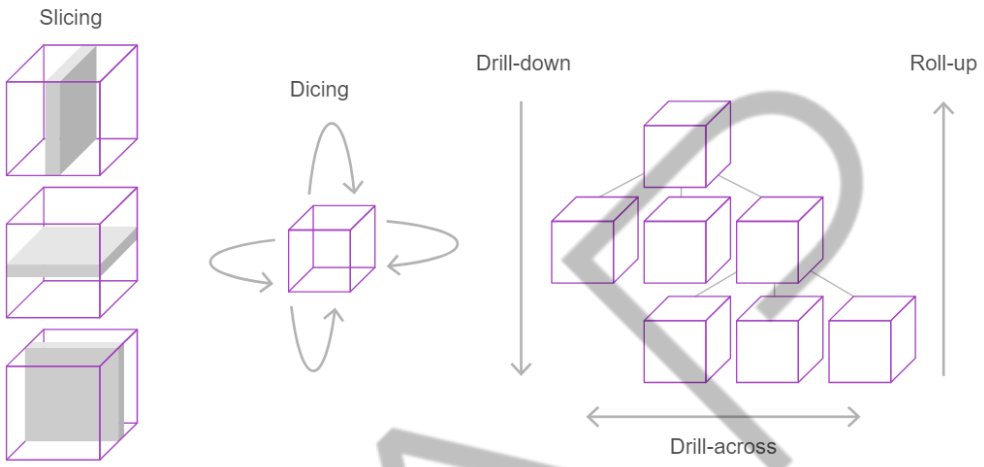

Figura 6 – Slicing, dicing, drill

Fonte: PAULUCCI (2016)

O uso de operações como o drill down, por exemplo, permite ao usuário se movimentar ao longo dos níveis da hierarquia de uma dimensão.

2.7 Fatos

Para Kimball (2013), o modelo dimensional é composto por dois tipos lógicos de tabelas: dimensões e fatos.

A tabela de fatos contém as medidas numéricas (métricas) do negócio, podendo ser quantitativas ou qualitativas. É a maior tabela no esquema em estrela e é composta de grandes volumes de dados, geralmente constituindo 90% ou mais do tamanho total do banco de dados. Pode ser vista em duas partes:

- Chave primária multiparte.
- Métricas de negócios:
  - Numérico.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Aditivo (geralmente).

Frequentemente, uma medida pode ser necessária no depósito, mas pode não parecer aditiva. Estes são conhecidos como fatos sem aditivos. O inventário e a temperatura ambiente são duas dessas medidas numéricas. Não faz sentido adicionar essas medidas ao longo do tempo, mas elas podem ser agregadas usando uma função SQL diferente de soma, por exemplo: média.

Embora um esquema em estrela normalmente contenha uma tabela de fatos, outros esquemas DSS (Decision Support System) podem conter várias tabelas de fatos. Em geral, possuem as seguintes características:

- Contêm métricas numéricas do negócio.
- Podem conter grandes volumes de dados.
- Podem crescer rapidamente.
- Podem conter dados de base, derivados e resumidos.
- São tipicamente aditivos.
- São associadas a tabelas de dimensão através de chaves externas que fazem referência a chaves primárias nas tabelas de dimensão.

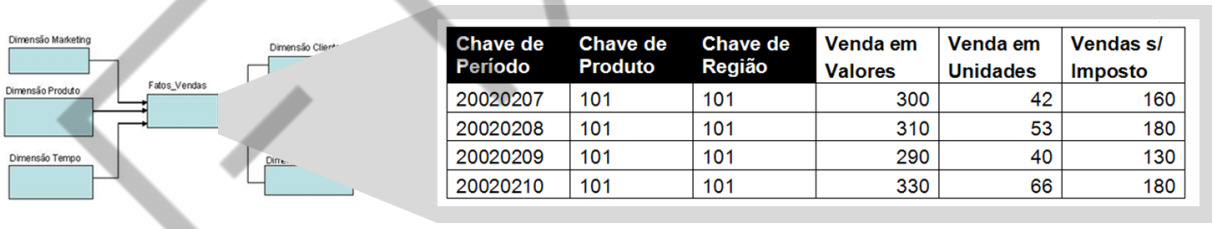

Chave de Período	Chave de Produto	Chave de Região	Venda em Valores	Venda em Unidades	Vendas s/ Imposto
20020207	101	101	300	42	160
20020208	101	101	310	53	180
20020209	101	101	290	40	130
20020210	101	101	330	66	180

Figura 7 – Fato

Fonte: PAULUCCI (2016)

2.8 Dimensões

Segundo Kimball (2013), dimensões são as descrições textuais do negócio. São estruturas de dados responsáveis por classificar, categorizar, descrever, definir e contextualizar os fatos de negócio. Em geral, as dimensões de negócio podem conter configurações específicas e detalhadas, como hierarquias, níveis e atributos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

As tabelas de dimensão são geralmente menores do que as tabelas de fatos e os dados mudam com muito menos frequência. Fornecem uma perspectiva sobre os porquês e como das transações de negócios e elementos. Embora as dimensões geralmente contenham dados relativamente estáticos, as dimensões do cliente são atualizadas com mais frequência.

Dimensões são essenciais para análise. A chave para um modelo dimensional poderoso está na riqueza dos atributos de dimensão, porque eles determinam como os fatos podem ser analisados. As dimensões podem ser consideradas o ponto de entrada no "espaço de fatos".

Sempre nomeie os atributos no vocabulário dos usuários. Dessa forma, a dimensão se documentará e sua força expressiva ficará evidente. As tabelas de dimensão têm as seguintes características:

- Contêm informações textuais que representam os atributos do negócio.
- Contêm dados relativamente estáticos.
- São associados a uma tabela de fatos através de uma referência de chave estrangeira.

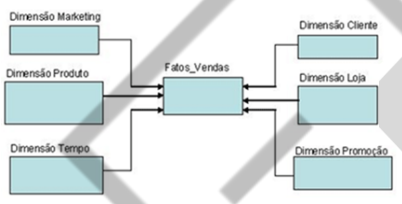

Chave de Região	Descrição da Região	Cidade	Estado	Área	Nível
101	Belo Horizonte	101	201	301	Cidade
102	Porto Alegre	102	202	302	Cidade
201	Minas Gerais	NA	201	301	Estado
202	Rio Grande do Sul	NA	202	302	Estado
301	Região Sudeste	NA	NA	301	Área
302	Região Sul	NA	NA	302	Área

Figura 8 – Dimensões

Fonte: PAULUCCI (2016)

2.9 Hierarquia e Compartilhamento

Segundo Kimball (2013) as dimensões podem possuir hierarquias, na Figura 8 (“Dimensões”) é possível notar que existe uma hierarquia por produto.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

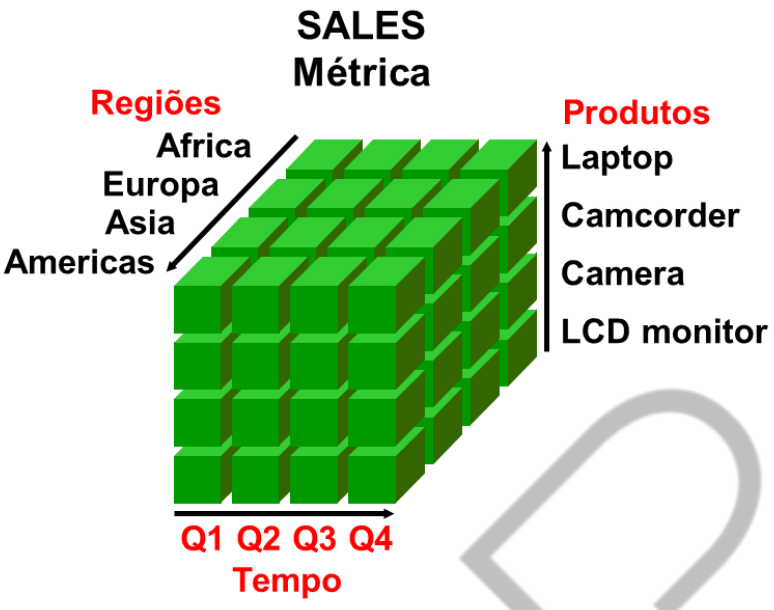

Figura 9 – Multidimensionalidade

Fonte: PAULUCCI (2016)

Uma hierarquia é uma relação pai-filho entre os membros de uma dimensão, que permite agrupamentos lógicos de membros de dimensão para os seguintes fins:

- Navegação de dados.
- Agregação de medidas.
- Atribuição de dados em um aplicativo de orçamento ou planejamento.
- Determinados cálculos, como ações e índices.

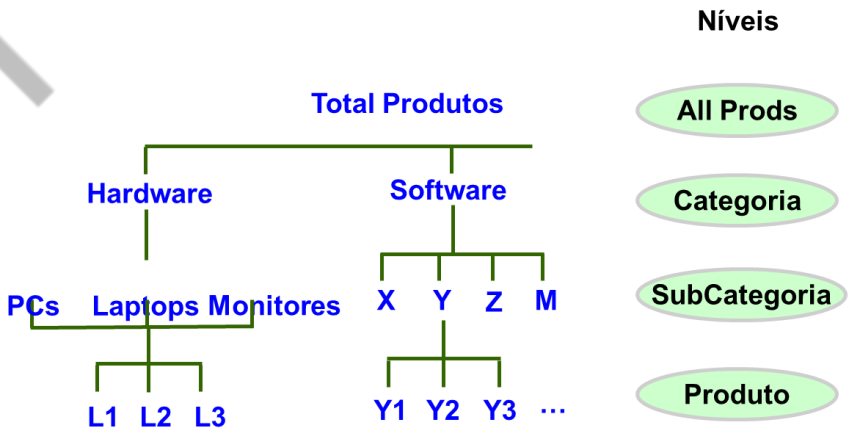

Figura 10 – Exemplo de níveis hierárquicos de uma dimensão

Fonte: PAULUCCI (2016)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

As dimensões podem ter mais de uma hierarquia. Além das hierarquias, as dimensões possuem atributos que fornecem informações descritivas sobre os membros da dimensão. Os atributos também são úteis quando você está selecionando membros de dimensão para análise:

- Selecione os produtos cuja cor (atributo) é “Azul”.
- Selecione os clientes que têm dois filhos.
- Selecione as promoções que são do tipo "Multipack”.
- Selecione todos os períodos de tempo cuja descrição contém “Janeiro”.

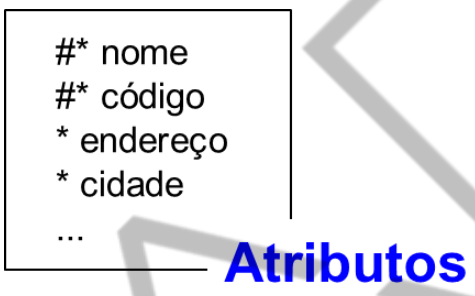

Figura 11 – Exemplo de atributos

Fonte: PAULUCCI (2016)

2.10 Medidas

Para Kimball (2013), medidas são atributos que quantificam um determinado fato, representando o desempenho ou comportamento de um indicador em relação às dimensões que participam do fato.

Da perspectiva de negócio, é mais interessante analisar as medidas como valores agregados, visto que, em aplicações de BI, é muito raro que o usuário precise visualizar um único registro da tabela fato. Dessa forma, é comum que se diga que, uma medida é uma agregação de valores de dados numéricos, como soma, contagem, mínima, máxima, média ou uma função personalizada, mas, todavia, nem toda medida pode ser agregada. As medidas são classificadas, então, como:

- Aditivas: são as medidas que podem ser agregadas em todas as dimensões. Por exemplo, realizar uma análise a respeito de todas as

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

vendas de uma determinada categoria de produto que foram realizadas ao longo dos meses de um ano.

- Semi aditivas: são as medidas que podem ser agregadas em algumas dimensões, mas não podem ser agregadas em outras. A literatura cita como exemplo o saldo das contas contábeis. No caso de uma tabela fato que possuam como grão o saldo de uma conta contábil a cada dia, não devemos somar esta medida ao longo do tempo, já que, contabilmente, não faz sentido somar o saldo de um dia com o saldo do dia seguinte, entretanto, pode fazer sentido somar estes saldos ao longo de outras dimensões para se obter valores totais, como por setor ou por filial.
- Não aditivas: são as medidas que não podem ser agregadas em qualquer dimensão. Um bom exemplo são valores percentuais, não faz sentido somar a alíquota estadual de um imposto de uma determinada unidade da federação (UF) com a alíquota estadual desse mesmo imposto de outra UF. Essa medidas precisam de um tratamento especial para que possam ser agregadas.

2.11 Chave substituta

Para Chan (2009), uma chave substituta, também conhecida como chave warehouse, chave generalizada, chave sintética ou surrogate key, é uma chave gerada pelo sistema DW. A chave em si não tem significado direto e, portanto, não permite determinar nada sobre a dimensão subjacente à qual está associada. De modo geral, é um número inteiro de 4 bytes é suficiente (contendo 232 valores ou mais de dois bilhões de números positivos) ao atribuir atributos para a chave.

Na figura 11, é possível observar que existem os atributos código e nome que formam uma chave primária composta. Como boa prática de desenvolvimento de modelos dimensionais, é sugerida a inclusão de uma chave substituta diferente da chave de negócio (código e nome, no caso) para permitir a independência de origem (sistemas diferentes que irão referenciar o mesmo nome a partir de códigos diferentes), evitar uso de chaves longas, compostas ou strings, preservar contra alterações de negócio como recodificação e migrações de sistema, além do registro

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

evolutivo — mudança de dados que devem ser refletidas na análise ao longo do tempo.

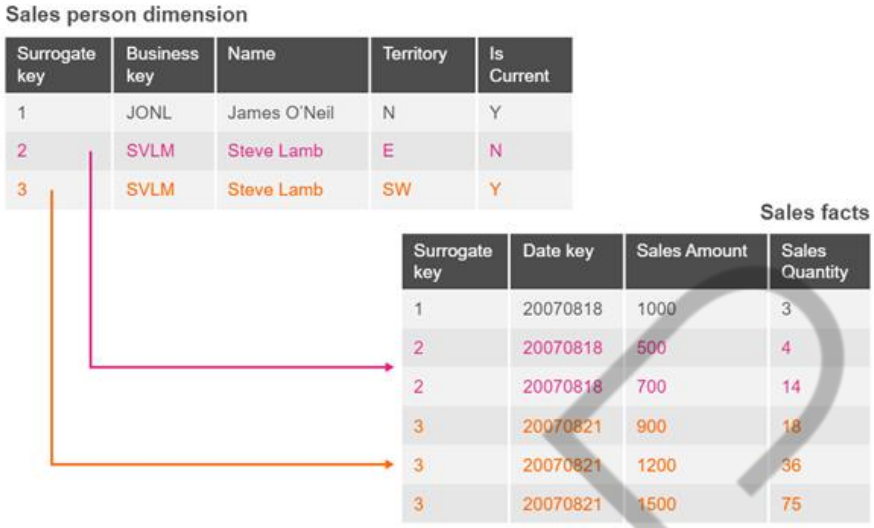

Figura 12 – Exemplo de surrogate key

Fonte: KIMBALL (2013)

Na figura 12, é possível ver que o cliente “Steve Lamb” tem a chave de negócio (business key) “SVLM” e as surrogate key “2” e “3”. O cliente efetuou duas compras na região (territory) “E” e efetuou três compras na região “SW”. Apesar da mudança da região onde foi efetuada a compra, graças a chave substituta, podemos traçar as compras desse mesmo cliente em diferentes regiões.

2.12 Slow Changing Dimensions, Modelos e Máscaras

Segundo Chan (2009), um dos desafios encontrados no modelo dimensional é como manter a veracidade e a fidelidade das informações em relação ao tempo, isto é, como lidar com atributos importantes para nossas análises que sofrem alterações ao longo do tempo.

Uma das características do DW é a capacidade de armazenar dados históricos. Essa característica permite a correspondência dos fatos com suas perspectivas de acordo com o tempo da ocorrência.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A figura 12 traz um exemplo da mudança dos dados, o cliente “Steve Lamb” mudou da região “E” para a região “SW”. Essa informação é importante para um mapa de vendas por região, por exemplo.

O SCD é uma sigla que significa Slowly Changing Dimensions (Dimensões que Mudam Lentamente, em português) e retrata as dimensões que sofrem atualizações em seus campos e os classifica pelo tipo de mudança existente em cada uma delas. Existem vários tipos de SCD, variando de acordo com as características de atualizações das dimensões.

- SCD tipo 0 — Atributo Estável: são dados estáveis, que devem ser mantidos como na origem. São atributos onde não é necessária atualização como data de nascimento, naturalidade, cidade de nascimento, por exemplo.
- SCD tipo 1— Atributo de Histórico Irrelevante: são atributos onde não é mantido um histórico de alteração. Nesse caso, os dados podem ser alterados, mas o histórico de alteração não é relevante para as análises.
- SCD tipo 2 — Atributo com histórico por registro: são atributos relevantes para a análise. Mantêm diferentes versões dos atributos relevantes na forma de registros onde somente um é válido dentro de um período, com nova surrogate key. O fato manterá a referência a sua versão válida ao tempo do registro do fato.

2.13 KPI e BSC

Para Kaplan (1997): “O Balanced Scorecard descreve como a unidade de negócio cria valor para os acionistas[...], impulsionado pela excelência nos processos internos. Os processos são aprimorados continuamente, medindo o alinhamento de pessoas, sistemas e culturas”.

O Balanced Scorecard (BSC) pode ser traduzido como “Indicadores Balanceados de Desempenho”, sua premissa é que uma empresa pode monitorar a execução de suas estratégias acompanhando certos indicadores-chaves.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Segundo Kimball (2013), Key Performance Indicators (KPI) ou indicadores chave de desempenho servem para medir o alcance das metas relacionadas aos objetivos estratégicos da empresa.

Nem sempre os dados necessários para apuração dos KPIs estão disponíveis de forma organizada e centralizada, geralmente estão dispersos em diversas planilhas e sistemas não integrados.

KPIs indicam, de forma percentual ou numérica, o resultado de uma ação e por onde é avaliado o desempenho da organização. Eles são essenciais nos diversos departamentos de uma empresa, pois apontam os resultados reais dos investimentos feitos, seja em gestão de pessoas, na otimização de processos, na redução de gastos, no aumento da produtividade dos colaboradores, entre outros. Dentro de um planejamento estratégico, os KPIs têm como objetivo fornecer informações para o nível tático de uma organização.

2.14 ETL

Para Kimball (2013), Extract, Transform, Load (ETL), ou, Extração, Transformação e Carga, é um conjunto de processos e tecnologias para transformar dados brutos em informações úteis e obter insights a partir deles. Refere-se ao processo de extração de dados de várias fontes, transformando-os em um formato comum apropriado para executarmos consultas ad hoc, geração de relatórios e analytics e, em seguida, carregá-los em um Data Warehouse ou outro repositório de dados centralizado.

A **extração** é um aspecto importante do processo de ETL, pois unifica dados estruturados e não estruturados de várias fontes de dados, incluindo bancos de dados, aplicativos SaaS (Software-as-Service), arquivos, CRMs (Customer Relationship Management), entre outros. No processo de extração, os dados são organizados e convertidos em um formato único, o que torna possível manipulá-los nas próximas etapas. Como os dados são muito diferentes entre si, é necessário adotar essa medida inicial, fazendo a padronização massiva deles. Ao executar o processo de extração de dados, as soluções ETL devem garantir os seguintes critérios:

- Remova os dados redundantes.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Remova dados indesejados.
- Registros e dados de origem diferentes devem ser compatibilizados.
- Os atributos-chave e os tipos de dados devem estar corretos.

A **transformação** é o processo de conversão de dados extraídos em um formato comum para que um Data Warehouse ou uma ferramenta de BI possa manipulá-los facilmente. Na fase de transformação, ocorre a adaptação das informações que foram analisadas e padronizadas no estágio da extração. Nesta etapa os dados são transformados, fazendo o que se chama de higienização. O objetivo é levar para a análise do gestor apenas aquilo que será efetivamente aproveitado.

Nesta etapa também são criados os filtros para agrupar informações de critérios como idade, localização, tempo, cargo, nível hierárquico ou qualquer outro que seja útil para a realização de futuras análises.

Classificar, limpar, remover informações redundantes e verificar dados de fontes de dados são algumas das estratégias de transformação amplamente seguidas em todas as organizações. Alguns dos principais fatores de validação a serem considerados ao transformar dados:

- Filtre os dados de acordo com seus requisitos e carregue apenas as colunas necessárias.
- Técnicas apropriadas de Engenharia de Dados devem ser usadas para preencher os valores ausentes.
- Antes de carregar dados confidenciais no Data Warehouse, certifique-se de que estejam devidamente mascarados.
- Certifique-se de que todas as unidades de medida sejam convertidas em uma única unidade, como converter todas as moedas para R$, comprimento em metros, pesos em kg e assim por diante.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A **carga** é o processo de carregamento de dados transformados para um destino, geralmente um Data Warehouse. A etapa de carga é crítica, pois após esta etapa, os dados do cliente são visualizados usando diferentes ferramentas de BI. Existem 3 tipos de funções de carregamento em um processo típico de ETL:

- Carga inicial: quando é feita a primeira carga de dados por meio do processo. As tabelas são então preenchidas em todo o Data Warehouse.
- Carga Incremental: Os usuários podem carregar dados em tempo real ou em intervalos regulares e atualizar novos dados no Data Warehouse.
- Full Refresh: Este tipo de carga remove os dados existentes na tabela do Data Warehouse e os substitui por novos dados.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

CHAN, B. **Análise de dados: modelagem multivariada para tomada de decisões**. Rio de Janeiro: Editora Campus, 2009.

GARTNER. **Business Intelligence (BI).** Disponível em: <http://www.gartner.com/it-glossary/business-intelligence-bi>. Acesso em: 7 mar. 2017.

INMON, Willian. **What is a Data Warehouse**. New York: Prism Solution Inc. 1995.

KIMBALL, Ralph e ROSS, Margy. **The Data Warehouse Toolkit**. 3.ed. Indianapolis: Wiley, 2013.

KAPLAN, Robert S.; NORTON, David P. **A estratégia em ação: balanced scorecard**. Rio de Janeiro: Campus, 1997.

PAULUCCI, Anderson; RUBIM, Leandro; CANTELE, Regina**. Big Data & Analytics**. São Paulo. FIAP. 2016.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com