FIAP ON

CHATBOTS

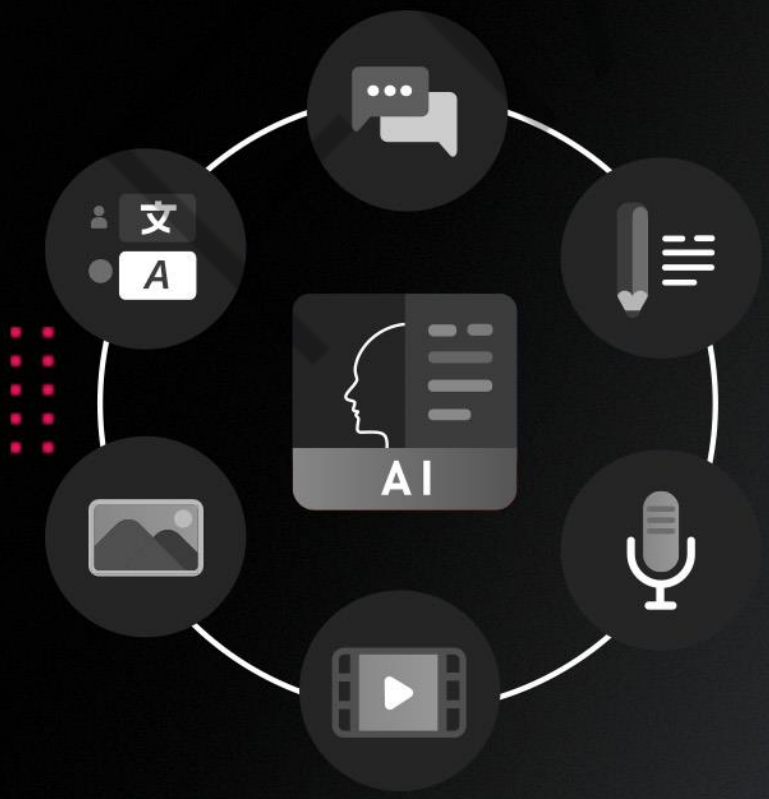

8

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 – Imagem gerada pelo modelo Stable Diffusion XL da Stability AI 4
Figura 2 – Método de ajuste fino (fine-tunning) do ChatGPT para o modelo GPT-3.5 8
Figura 3 – OpenAI Playground para testes com a regulagem de Temperatura e Top_p 22
Figura 4 – ChatGPT com um exemplo básico de prompt.....23
Figura 5 – ChatGPT com um exemplo básico de prompt com comando 24
Figura 6 – Estrutura de um prompt de resposta a perguntas 25
Figura 7 – Estrutura de um Few-Shot Prompting 25
Figura 8 – Estrutura de um Few-Shot Prompting (versão QA).....26
Figura 9 – Exemplo de um Few-Shot Prompting.....26
Figura 10 – Exemplo de prompt para Resumo de Texto.....28
Figura 11 – Exemplo de prompt para resumir ainda mais um texto 28
Figura 12 – Exemplo de prompt para Extração de Informações 29
Figura 13 – Exemplo de prompt para Resposta a Perguntas.....30
Figura 14 – Exemplo de prompt para Classificação de Texto 31
Figura 15 – Exemplo de prompt para Classificação de Texto com formato exato esperado 32
Figura 16 – Exemplo de prompt para Classificação de Texto com um problema inserido.....32
Figura 17 – Exemplo de prompt para Conversação 33
Figura 18 – Exemplo de prompt para Conversação com mais contexto 34
Figura 19 – Exemplo de prompt para Geração de Código 35
Figura 20 – Exemplo de prompt para Geração de Código para query MySQL 35
Figura 21 – Exemplo de prompt para Raciocínio 36
Figura 22 – Exemplo de prompt para Raciocínio com um desafio mais difícil.....37
Figura 23 – Exemplo de prompt para Zero-Shot Prompting.....38
Figura 24 – Exemplo de prompt para Few-Shot Prompting com nova palavra 40
Figura 25 – Exemplo de prompt para Zero-Shot Prompting para classificação 41
Figura 26 – Exemplo de prompt para Zero-Shot Prompting sem padrão 41
Figura 27 – Exemplo de prompt para Chain-of-Thought Prompting 42
Figura 28 – Exemplo de prompt para Chain-of-Thought Prompting com menos exemplos.....43
Figura 29 – Exemplo de prompt para Zero-Shot Chain-of-Thought Prompting 43

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 IA GENERATIVA 4
1.1 Alucinações em IA Generativa 7
2 FOUNDATION MODELS (FMS) 9
2.1 Exemplos de Foundation Models (FMs) 11
2.1.1 BERTO 11
2.1.2 GPT 12
2.1.3 Amazon Titan 12
2.1.4 AI21 Jurassic 13
2.1.5 Claude 13
2.1.6 Cohere 13
2.1.7 Stable Diffusion 13
2.1.8 BLOOM 14
2.1.9 Hugging Face 14
2.2 Desafios com Foundation Models (FMs) 15
3 LARGE-LANGUAGE MODELS (LLMS) 16
4 PROMPT ENGINEERING 21
4.1 Básico de Prompts 22
4.2 Formatação do Prompt 24
4.3 Exemplos de Prompts 27
4.3.1 Resumo de texto 27
4.3.2 Extração de informações 29
4.3.3 Resposta a Perguntas 30
4.3.4 Classificação de texto 30
4.3.5 Conversação 33
4.3.6 Geração de código 34
4.3.7 Raciocínio 36
4.4 Técnicas de Prompting 37
4.4.1 Zero-shot prompting 38
4.4.2 Few-shot prompting 39
4.4.3 Chain-of-thought prompting 42
4.4.4 Retrieval Augmented Generation (RAG) 44
REFERÊNCIAS 46

FIXP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 IA GENERATIVA

A IA Generativa (*Generative AI*, ou GenAI), uma fronteira fascinante na inteligência artificial, tem remodelado o cenário da interação e criatividade humano-computador nos últimos anos. Basicamente, a IA Generativa capacita as máquinas a produzirem de forma autônoma conteúdo novo e original, abrangendo texto, imagens, músicas, vídeos e muito mais. Esta tecnologia, com a sua notável capacidade de gerar conteúdos que muitas vezes imitam a criatividade humana, encontrou uma ligação especialmente profunda com projetos de chatbot, redefinindo a forma como interagimos com sistemas de IA conversacionais. Nesta discussão, exploraremos a relação simbiótica entre a IA generativa e os chatbots, destacando como a IA generativa aprimora as capacidades e as experiências do usuário dos aplicativos de chatbot.

Os chatbots, como programas de computador projetados para iniciar conversas baseadas em texto ou voz com os usuários, evoluíram substancialmente nos últimos anos. Tradicionalmente, os chatbots dependiam de regras predefinidas e correspondência simples de padrões para responder às dúvidas dos usuários. No entanto, com a integração da IA Generativa, estes chatbots transcenderam as suas limitações, tornando-se mais versáteis, conscientes do contexto e capazes de lidar com diálogos complexos.

Figura 1 – Imagem gerada pelo modelo Stable Diffusion XL da Stability AI
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A IA Generativa, especialmente modelos como o GPT-3.5 e seus sucessores, serve como um mecanismo poderoso que capacita os chatbots a gerar respostas semelhantes às humanas. Veja como a IA Generativa aumenta os projetos de chatbot:

- **Compreensão da linguagem natural**: a IA Generativa ajuda os chatbots a compreender e processar as consultas dos usuários de maneira mais eficaz. Permite-lhes compreender nuances da linguagem, incluindo expressões idiomáticas e contexto, resultando em respostas mais precisas e contextualmente relevantes.
- **Fluxo de conversação**: os chatbots com tecnologia de IA Generativa podem manter conversas mais tranquilas e coerentes. Eles podem lembrar e fazer referência a mensagens anteriores, garantindo que as interações sejam mais naturais e envolventes para os usuários.
- **Geração de conteúdo**: IA Generativa auxilia chatbots na geração de conteúdo diversificado e criativo. Os chatbots podem fornecer aos usuários respostas e recomendações personalizadas e até mesmo gerar conteúdo como descrições de produtos, artigos de notícias ou mensagens de marketing personalizadas.
- **Capacidades multimodais**: além do texto, a IA Generativa também pode gerar imagens, que podem ser integradas em interfaces de chatbot para enriquecer as experiências do usuário. Por exemplo, um chatbot em um aplicativo de comércio eletrônico pode usar IA generativa para criar imagens de produtos com base nas descrições dos usuários.
- **Disponibilidade 24 horas por dia, 7 dias por semana**: chatbots generativos alimentados por IA podem operar 24 horas por dia, fornecendo respostas instantâneas e suporte aos usuários sem fadiga, tornando-os uma escolha ideal para aplicações de atendimento ao cliente.
- **Escalabilidade**: à medida que os projetos de chatbot crescem e lidam com mais usuários, a IA generativa pode ajudar a manter a qualidade das interações e respostas sem um aumento linear no esforço manual.

A IA Generativa e os chatbots complementam-se perfeitamente, capacitando os aplicativos de chatbot a oferecer conversas mais inteligentes, naturais e

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

personalizadas. Esta sinergia entre estas tecnologias não só melhora as experiências dos utilizadores, mas também abre novas possibilidades de automação e criatividade em vários domínios, desde o atendimento ao cliente até à geração de conteúdos e muito mais.

Dentro da tecnologia de IA Generativa, existem duas tecnologias que são componentes fundamentais para a construção de um modelo capaz de gerar conteúdos (imagens, vídeos, audios, etc): Foundation Model e Large-Language Model.

Large-Language Model (LLMs) e Foundation Model são componentes integrantes da IA Generativa, particularmente no domínio da compreensão e geração de linguagem natural. Esses modelos servem como blocos de construção sobre os quais vários aplicativos, incluindo chatbots, serviços de tradução e geração de conteúdo, são desenvolvidos.

LLMs são modelos sofisticados baseados em redes neurais projetados para compreender e gerar a linguagem humana. Eles têm a capacidade de processar grandes quantidades de dados de texto e aprender os padrões, a gramática e a semântica subjacentes da linguagem. Exemplos de LLMs proeminentes incluem GPT-3.5 (*Generative Pre-trained Transformer 3.5*) da OpenAI e BERT (*Bidirectional Encoder Representations from Transformers*) da Google.

Os Foundation Models são versões ainda mais extensas e poderosas dos LLMs. Eles servem de base para a criação de vários modelos especializados e são pré-treinados em diversos e extensos conjuntos de dados. Esses modelos são frequentemente chamados de “modelos de base” ou “modelos pais”.

Os Foundation Models servem como ponto de partida para várias aplicações posteriores. Modelos especializados são criados ajustando esses Foundation Models em tarefas específicas. Por exemplo, um modelo de chatbot pode ser criado ajustando um modelo de base em um conjunto de dados de interações conversacionais.

É importante observar que a criação de Foundation Models envolve recursos computacionais, dados e conhecimentos significativos. Considerações éticas, privacidade de dados e uso responsável destes modelos também são fundamentais, pois têm o potencial de influenciar e gerar grandes quantidades de conteúdo em vários domínios.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.1 Alucinações em IA Generativa

No contexto da IA Generativa, “alucinação” refere-se a um fenômeno em que o modelo de IA gera conteúdo incorreto, irreal ou não relacionado à entrada ou ao contexto. Envolve essencialmente a geração de informações que não refletem com precisão os dados nos quais o modelo foi treinado ou a tarefa que deveria executar. A alucinação pode ocorrer de várias formas, dependendo do tipo de dados e do modelo específico de IA em uso. Aqui estão alguns exemplos:

- **Alucinação de texto**: Em tarefas de geração de texto, a alucinação pode envolver a criação de frases ou parágrafos pela IA que contêm fatos fabricados, eventos fictícios ou informações sem sentido. Por exemplo, um modelo de linguagem pode gerar um artigo de notícias com detalhes inventados ou estatísticas incorretas.
- **Alucinação de imagem**: Na geração de imagens, a alucinação pode se manifestar como a IA gerando imagens com objetos ou cenas que não existem na realidade. Pode produzir imagens com combinações bizarras de elementos ou artefatos não relacionados à entrada.
- **Alucinação de áudio**: Em tarefas de geração de áudio, a alucinação pode resultar na criação de sons ou músicas que não estão em conformidade com as normas musicais ou não têm base na realidade. A IA pode produzir melodias discordantes ou amostras de áudio totalmente imaginárias.
- **Alucinação de tradução**: Na tradução automática, a alucinação pode ocorrer quando a IA traduz incorretamente uma palavra ou frase para um idioma, produzindo uma tradução imprecisa ou sem sentido que não se alinha com o significado do texto original.

A alucinação é um problema desafiador em IA generativa, especialmente em LLMs como GPT-3.5 e Transformers. Pode surgir por vários motivos:

- **Overfitting**: O modelo de IA pode ter aprendido a replicar padrões específicos nos dados de treinamento, mesmo que esses padrões não façam sentido lógico.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Falta de compreensão do contexto**: Às vezes, a IA não tem uma compreensão completa do contexto ou não o considera adequadamente ao gerar conteúdo, levando a informações alucinadas.
- **Viés de dados**: Se os dados de treinamento contiverem informações tendenciosas ou imprecisas, a IA poderá produzir conteúdo alucinado que reflita esses preconceitos.
- **Dados de treinamento limitados**: Em alguns casos, o modelo pode não ter visto exemplos diversos o suficiente para discernir com precisão entre conteúdo válido e inválido.

Abordar a alucinação na IA Generativa é um desafio de pesquisa contínuo. Técnicas como ajuste fino (*fine-tunning*), aprendizado por reforço (*reinforcement learning*) e curadoria aprimorada de dados de treinamento são usadas para mitigar esse problema. Além disso, revisores humanos podem ser empregados para filtrar conteúdo alucinado e garantir que o resultado da IA atenda aos padrões de qualidade. As considerações éticas e a utilização responsável da IA são cruciais na gestão dos riscos potenciais associados às alucinações, especialmente na implantação da IA em aplicações do mundo real.

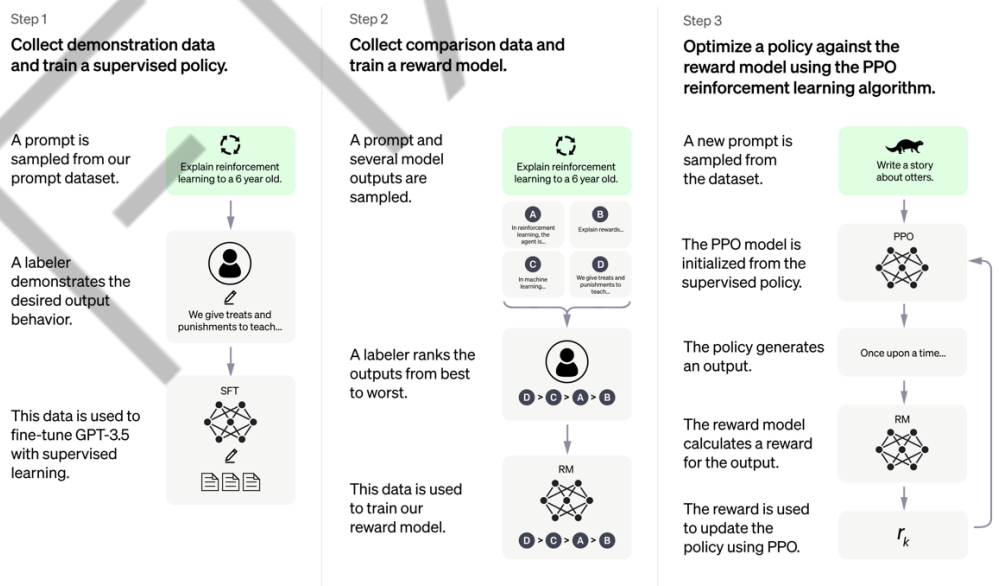

Figura 2 – Método de ajuste fino (fine-tunning) do ChatGPT para o modelo GPT-3.5
Fonte: OpenAI (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 FOUNDATION MODELS (FMS)

Treinados em conjuntos de dados massivos, os Foundation Models (MLs) são grandes redes neurais de Deep Learning que mudaram a forma como os cientistas de dados abordam Machine Learning (ML). Em vez de desenvolver Inteligência Artificial (IA) do zero, os cientistas de dados usam um modelo de base como ponto de partida para desenvolver modelos de ML que potencializem novas aplicações de maneira mais rápida e econômica. O termo modelo de base foi cunhado por pesquisadores para descrever modelos de ML treinados em um amplo espectro de dados generalizados e não rotulados e capazes de realizar uma ampla variedade de tarefas gerais, como compreender a linguagem, gerar texto e imagens e conversar em linguagem natural.

O termo “foundation” implica que estes modelos formam o conhecimento fundamental sobre o qual são construídos modelos de ML mais específicos e orientados para tarefas. Uma característica única dos Foundations Models é a sua adaptabilidade. Esses modelos podem executar uma ampla gama de tarefas distintas com um alto grau de precisão com base em solicitações de entrada. Algumas tarefas incluem processamento de linguagem natural (*Natural Language Processing*, ou NLP), resposta a perguntas e classificação de imagens. O tamanho e a natureza de uso geral dos FMs os tornam diferentes dos modelos tradicionais de ML, que normalmente executam tarefas específicas, como análise de sentimento de texto, classificação de imagens e previsão de tendências.

Você pode usar Foundation Models como modelos de base para desenvolver aplicações mais especializadas. Esses modelos são o resultado de mais de uma década de trabalho que os viu aumentar em tamanho e complexidade.

Por exemplo, o BERT, um dos primeiros Foundation Models bidirecionais, foi lançado em 2018. Foi treinado usando 340 milhões de parâmetros e um conjunto de dados de treinamento de 16 GB. Em 2023, apenas cinco anos depois, a OpenAI treinou o GPT-4 usando 170 trilhões de parâmetros e um conjunto de dados de treinamento de 45 GB. De acordo com a OpenAI, o poder computacional necessário para a modelagem de bases dobrou a cada 3,4 meses desde 2012. Os FMs atuais, como os Large-Language Models (LLMs) Claude 2 e Llama 2, e o modelo de texto

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

para imagem Stable Diffusion da Stability AI, podem realizar uma série de tarefas prontas para uso, abrangendo vários domínios, como escrever postagens em blogs, gerar imagens, resolver problemas matemáticos, dialogar e responder perguntas com base em um documento.

Os Foundation Models estão preparados para mudar significativamente o ciclo de vida do Machine Learning. Embora atualmente custe milhões de dólares desenvolver um modelo básico do zero, eles são úteis no longo prazo. É mais rápido e barato para os cientistas de dados usar FMs pré-treinados para desenvolver novos aplicativos de ML, em vez de treinar modelos exclusivos de ML desde o início.

Os Foundation Models são uma forma de Inteligência Artificial Generativa (IA Generativa). Eles geram resultados a partir de uma ou mais entradas (prompts) na forma de instruções em linguagem humana. Os modelos são baseados em redes neurais complexas, incluindo redes adversárias generativas (GANs), transformadores e codificadores variacionais.

Embora cada tipo de rede funcione de maneira diferente, os princípios por trás de seu funcionamento são semelhantes. Em geral, um FM utiliza padrões e relações aprendidas para prever o próximo item de uma sequência. Por exemplo, com a geração de imagens, o modelo analisa a imagem e cria uma versão mais nítida e claramente definida da imagem. Da mesma forma, com texto, o modelo prevê a próxima palavra em uma sequência de texto com base nas palavras anteriores e em seu contexto. Em seguida, seleciona a próxima palavra usando técnicas de distribuição de probabilidade.

Os Foundation Models usam aprendizagem auto-supervisionada para criar rótulos a partir dos dados de entrada. Isso significa que ninguém instruiu ou treinou o modelo com conjuntos de dados de treinamento rotulados. Este recurso separa os LLMs das arquiteturas de ML anteriores, que usam aprendizagem supervisionada - presente em projetos de chatbot convencionais - ou não supervisionada.

De forma simplificada, o processo de criação de um FM utiliza as seguintes etapas:

- **Coleta de dados**: Os Foundation Models começam coletando extensos dados textuais de diversas fontes na Internet, incluindo livros, artigos, sites

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

e muito mais. Esses dados são essenciais para que o modelo aprenda as nuances da linguagem.

- **Pré-processamento e Tokenização**: O texto coletado é pré-processado para remover ruídos e informações irrelevantes. Em seguida, o texto é tokenizado, dividindo-o em unidades menores, como palavras, subpalavras ou caracteres. A tokenização é crucial para que o modelo compreenda e processe a linguagem de forma eficaz.
- **Treinamento (Pré-treinamento)**: O modelo é pré-treinado usando uma arquitetura de transformador. Durante o pré-treinamento, o modelo aprende a prever a próxima palavra ou token em uma frase com base no contexto fornecido pelas palavras anteriores. Esta fase, conhecida como pré-treinamento não supervisionado, permite ao modelo capturar gramática, contexto e até algumas habilidades de raciocínio.
- **Ajuste fino (fine-tunning)**: após o pré-treinamento, o modelo pode ser ajustado em tarefas específicas usando conjuntos de dados menores e específicos para tarefas. O ajuste fino ajusta os parâmetros do modelo para torná-lo proficiente em tarefas como resumo de texto, tradução ou resposta a perguntas. Esse processo, denominado ajuste fino supervisionado, adapta o modelo básico para aplicações específicas.

2.1 Exemplos de Foundation Models (FMs)

O número e o tamanho dos Foundation Models no mercado têm crescido rapidamente. Existem agora dezenas de modelos disponíveis. Aqui está uma lista de Foundation Models proeminentes lançados desde 2018.

2.1.1 BERTO

Lançado em 2018, o *Bidirecional Encoder Representations from Transformers* (BERT) foi um dos primeiros Foundation Models lançados. BERT é um modelo bidirecional que analisa o contexto de uma sequência completa e depois faz uma previsão. Ele foi treinado em um corpus de texto simples e na Wikipédia usando 3,3

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

bilhões de tokens (palavras) e 340 milhões de parâmetros. O BERT pode responder perguntas, prever frases e traduzir textos.

2.1.2 GPT

O modelo Generative Pre-trained Transformer (GPT) foi desenvolvido pela OpenAI em 2018. Ele usa um decodificador transformador de 12 camadas com mecanismo de autoatenção. E foi treinado no conjunto de dados BookCorpus, que contém mais de 11.000 romances gratuitos. Uma característica notável do GPT-1 é a capacidade de realizar aprendizado imediato.

GPT-2 lançado em 2019. OpenAI o treinou usando 1,5 bilhão de parâmetros (em comparação com os 117 milhões de parâmetros usados no GPT-1). GPT-3 tem uma rede neural de 96 camadas e 175 bilhões de parâmetros e é treinado usando o conjunto de dados Common Crawl de 500 bilhões de palavras. O popular chatbot ChatGPT é baseado em GPT-3.5. E o GPT-4, a versão mais recente, foi lançado no final de 2022 e passou com sucesso no Uniform Bar Examination com uma pontuação de 297 (76%).

2.1.3 AMAZON TITAN

Os FMs do Amazon Titan são pré-treinados em grandes conjuntos de dados, o que os torna modelos poderosos e de uso geral. Eles podem ser usados como estão ou personalizados de forma privada com dados específicos da empresa para uma tarefa específica, sem anotar grandes volumes de dados. Inicialmente, a Titan oferecerá dois modelos. O primeiro é um LLM generativo para tarefas como resumo, geração de texto, classificação, perguntas e respostas abertas e extração de informações. O segundo é um LLM de incorporações que traduz entradas de texto, incluindo palavras, frases e grandes unidades de texto, em representações numéricas (conhecidas como *embeddings*) que contêm o significado semântico do texto. Embora este LLM não gere texto, é útil para aplicações como personalização e pesquisa porque, ao comparar incorporações, o modelo produzirá respostas mais relevantes e contextuais do que a correspondência de palavras. Para continuar apoiando as melhores práticas no uso responsável da IA, os FMs do Titan são construídos para

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

detectar e remover conteúdo prejudicial nos dados, rejeitar conteúdo impróprio na entrada do usuário e filtrar os resultados dos modelos que contêm conteúdo impróprio, como discurso de ódio, palavrões e violência.

2.1.4 AI21 JURASSIC

Lançado em 2021, Jurassic-1 é um modelo de linguagem auto-regressivo de 76 camadas com 178 bilhões de parâmetros. Jurassic-1 gera texto semelhante ao humano e resolve tarefas complexas. Seu desempenho é comparável ao GPT-3.

Em março de 2023, o AI21 Labs lançou o Jurrassic-2, que melhorou o acompanhamento de instruções e os recursos de linguagem.

2.1.5 CLAUDE

Claude 2 é o modelo de última geração da Anthropic que se destaca no diálogo cuidadoso, criação de conteúdo, raciocínio complexo, criatividade e codificação, construído com IA Constitucional. Claude 2 pode receber até 100.000 tokens em cada prompt, o que significa que pode funcionar em centenas de páginas de texto ou até mesmo em um livro inteiro. Claude 2 também pode escrever documentos mais longos – como memorandos e histórias da ordem de alguns milhares de fichas – em comparação com sua versão anterior.

2.1.6 COHERE

Cohere possui dois LLMs: um é um modelo de geração com capacidades semelhantes ao GPT-3 e o outro é um modelo de representação destinado à compreensão de linguagens. Embora o Cohere tenha apenas 52 bilhões de parâmetros, ele supera o GPT-3 em muitos aspectos.

2.1.7 STABLE DIFFUSION

Stable Diffusion é um modelo de texto para imagem que pode gerar imagens de alta definição com aparência realista. Foi lançado em 2022 e possui um modelo de

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

difusão que utiliza tecnologias de ruído e remoção de ruído para aprender a criar imagens.

O modelo é menor que as tecnologias de difusão concorrentes, como o DALL-E 2 da OpenAI, o que significa que não necessita de uma extensa infraestrutura computacional. O Stable Diffusion funcionará em uma placa gráfica normal ou mesmo em um smartphone com plataforma Snapdragon Gen2.

2.1.8 BLOOM

BLOOM é um modelo multilíngue com arquitetura semelhante ao GPT-3. Foi desenvolvido em 2022 como um esforço colaborativo envolvendo mais de mil cientistas e a equipe do Hugging Space. O modelo tem 176 bilhões de parâmetros e o treinamento durou três meses e meio usando 384 GPUs Nvidia A100. Embora o ponto de verificação BLOOM exija 330 GB de armazenamento, ele será executado em um PC independente com 16 GB de RAM. O BLOOM pode criar texto em 46 linguagens e escrever código em 13 linguagens de programação.

2.1.9 HUGGING FACE

Hugging Face é uma plataforma que oferece ferramentas de código aberto para você construir e implantar modelos de Machine Learning. Ele atua como um hub comunitário e os desenvolvedores podem compartilhar e explorar modelos e conjuntos de dados. A adesão para indivíduos é gratuita, embora as assinaturas pagas ofereçam níveis mais elevados de acesso. Você tem acesso público a quase 200 mil modelos e 30 mil conjuntos de dados.

Esses Foundation Models abriram caminho para inúmeras inovações no processamento de linguagem natural, permitindo o desenvolvimento de aplicações avançadas de IA que podem compreender, gerar e manipular a linguagem humana de maneiras diversas e sofisticadas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.2 Desafios com Foundation Models (FMs)

Os Foundation Models podem responder de forma coerente às solicitações sobre assuntos nos quais não foram explicitamente treinados. Mas eles têm certas fraquezas. Aqui estão alguns dos desafios enfrentados pelos modelos de fundação:

- **Requisitos de infraestrutura**: construir um Foundation Model do zero é caro e requer enormes recursos, e o treinamento pode levar meses.
- **Desenvolvimento front-end**: para aplicações práticas, os desenvolvedores precisam integrar Foundation Models em uma pilha (stack) de software, incluindo ferramentas para engenharia imediata, ajuste fino (fine-tunning) e engenharia de pipeline (pipeline engineering).
- **Falta de compreensão**: embora possam fornecer respostas gramatical e factualmente corretas, os Foundation Models têm dificuldade em compreender o contexto de um prompt. E eles não têm consciência social ou psicológica.
- **Respostas não confiáveis**: as respostas a perguntas sobre determinados assuntos podem não ser confiáveis e, às vezes, inadequadas, tóxicas ou incorretas.
- **Viés (Bias)**: o preconceito é uma possibilidade distinta, pois os modelos podem captar discurso de ódio e conotações inadequadas em conjuntos de dados de treinamento. Para evitar isso, os desenvolvedores devem filtrar cuidadosamente os dados de treinamento e codificar normas específicas em seus modelos.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 LARGE-LANGUAGE MODELS (LLMS)

Large-Language Models (LLM) são modelos de Deep Learning muito grandes que são pré-treinados em grandes quantidades de dados. O Transformer, por debaixo dos panos, é um conjunto de redes neurais que consiste em um codificador e um decodificador com capacidade de autoatenção. O codificador e o decodificador extraem significados de uma sequência de texto e compreendem as relações entre palavras e frases nela contidas.

Os LLMs tornaram-se uma pedra angular no campo do Processamento de Linguagem Natural (*Natural Language Processing*, ou NLP) e têm uma ampla gama de aplicações, desde chatbots e tradução de idiomas até geração de texto e resumo de conteúdo.

Os Transformers de LLMs são capazes de treinamento não supervisionado, embora uma explicação mais precisa seja que os Transformers realizam autoaprendizagem. É por meio desse processo que os Transformers aprendem a compreender gramática, idiomas e conhecimentos básicos.

Ao contrário das redes neurais recorrentes (RNN) anteriores que processam entradas sequencialmente, os Transformers processam sequências inteiras em paralelo. Isso permite que os cientistas de dados usem GPUs para treinar LLMs baseados em Transformers, reduzindo significativamente o tempo de treinamento.

A arquitetura de rede neural do Transformer permite o uso de modelos muito grandes, geralmente com centenas de bilhões de parâmetros. Esses Large-Language Models podem ingerir enormes quantidades de dados, muitas vezes provenientes da Internet, mas também de fontes como o Common Crawl, que compreende mais de 50 mil milhões de páginas web, e a Wikipédia, que tem aproximadamente 57 milhões de páginas.

Os Large-Language Models (LLMs) são incrivelmente flexíveis. Um modelo pode realizar tarefas completamente diferentes, como responder perguntas, resumir documentos, traduzir idiomas e completar frases. Os LLMs têm o potencial de perturbar a criação de conteúdo e a forma como as pessoas usam motores de busca e assistentes virtuais.

Características de Large-Language Models:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Escala**: Os LLMs são caracterizados pelo seu enorme tamanho, muitas vezes tendo centenas de milhões ou mesmo bilhões de parâmetros. Essa arquitetura em grande escala permite capturar padrões de linguagem intrincados e gerar texto contextualmente relevante.
- **Conhecimento pré-treinado**: Antes de serem ajustados para tarefas específicas, os LLMs passam por um pré-treinamento em corpora de texto massivo. Durante esta fase, eles aprendem gramática, sintaxe, semântica e conhecimento de mundo de diversas fontes, como livros, sites e artigos.
- **Versatilidade**: Os LLMs são altamente versáteis e podem ser adaptados a uma ampla gama de tarefas de PNL por meio de ajuste fino. Eles podem ser usados para tarefas como classificação de texto, análise de sentimento, resposta a perguntas e muito mais.

Embora não sejam perfeitos, os LLMs estão demonstrando uma capacidade notável de fazer previsões com base em um número relativamente pequeno de prompts ou entradas. LLMs podem ser usados para IA Generativa para produzir conteúdo com base em prompts de entrada em linguagem humana.

LLMs são grandes, muito grandes. Eles podem considerar bilhões de parâmetros e ter muitos usos possíveis. aqui estão alguns exemplos:

- O modelo GPT-3 da Open AI possui 175 bilhões de parâmetros. Seu primo, ChatGPT, pode identificar padrões de dados e gerar resultados naturais e legíveis. Embora não saibamos o tamanho do Claude 2, ele pode receber até 100 mil tokens em cada prompt, o que significa que pode funcionar em centenas de páginas de documentação técnica ou até mesmo em um livro inteiro.
- O modelo Jurassic-1 do AI21 Labs tem 178 bilhões de parâmetros e um vocabulário simbólico de partes de 250.000 palavras e capacidades de conversação semelhantes.
- O modelo Command da Cohere tem recursos semelhantes e pode funcionar em mais de 100 idiomas diferentes.
- O Paradigm da LightOn oferece Foundation Models com capacidades reivindicadas que excedem as do GPT-3. Todos esses LLMs vêm com APIs

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

que permitem aos desenvolvedores criar aplicativos de IA Generativos exclusivos.

Um fator chave na forma como os LLMs funcionam é a forma como representam as palavras. As formas anteriores de Machine Learning (ML) usavam uma tabela numérica para representar cada palavra. Mas, esta forma de representação não poderia reconhecer relações entre palavras como palavras com significados semelhantes. Essa limitação foi superada com o uso de vetores multidimensionais, comumente chamados de *embeddings* de palavras, para representar palavras de modo que palavras com significados contextuais semelhantes ou outras relações fiquem próximas umas das outras no espaço vetorial.

Usando *embeddings* de palavras, os Transformers podem pré-processar texto como representações numéricas por meio do codificador e compreender o contexto de palavras e frases com significados semelhantes, bem como outras relações entre palavras, como classes gramaticais. É então possível que os LLMs apliquem esse conhecimento da linguagem através do decodificador para produzir uma saída única.

As redes neurais baseadas em Transformers são muito grandes. Essas redes contêm vários nós e camadas. Cada nó em uma camada possui conexões com todos os nós da camada seguinte, cada um dos quais possui um peso e uma tendência. Pesos e tendências junto com *embeddings* são conhecidos como parâmetros do modelo. Grandes redes neurais baseadas em *Transformers* podem ter bilhões e bilhões de parâmetros. O tamanho do modelo é geralmente determinado por uma relação empírica entre o tamanho do modelo, o número de parâmetros e o tamanho dos dados de treinamento.

O treinamento é realizado usando um grande corpus de dados de alta qualidade. Durante o treinamento, o modelo ajusta iterativamente os valores dos parâmetros até que o modelo preveja corretamente o próximo token de uma sequência anterior de tokens de entrada. Isso é feito por meio de técnicas de autoaprendizagem que ensinam o modelo a ajustar parâmetros para maximizar a probabilidade dos próximos tokens nos exemplos de treinamento.

Uma vez treinados, os LLMs podem ser facilmente adaptados para executar múltiplas tarefas usando conjuntos relativamente pequenos de dados supervisionados, um processo conhecido como ajuste fino.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Existem três modelos de aprendizagem comuns:

- **Zero-Shot Learning**: os LLMs básicos podem responder a uma ampla gama de prompts sem treinamento explícito, muitas vezes por meio de prompts, embora a precisão das respostas varie.
- **Few-Shot Learning**: ao fornecer alguns exemplos de treinamento relevantes, o desempenho do Foundation Model melhora significativamente nessa área específica.
- **Fine-tunning**: esta é uma extensão do Few-Shot Learning, pois os cientistas de dados treinam um modelo de base para ajustar seus parâmetros com dados adicionais relevantes para a aplicação específica.

A introdução de Large-Language Models como ChatGPT, Claude 2 e Llama 2, que podem responder perguntas e gerar pontos de texto para possibilidades interessantes no futuro. Lentamente, mas com segurança, os LLMs estão se aproximando de um desempenho semelhante ao humano. O sucesso imediato destes LLMs demonstra um grande interesse em LLMs do tipo robótico que emulam e, em alguns contextos, superam o cérebro humano. Aqui estão algumas reflexões sobre o futuro dos LLMs:

- **Capacidades aumentadas**: por mais impressionantes que sejam, o nível atual de tecnologia não é perfeito e os LLMs não são infalíveis. No entanto, as versões mais recentes terão maior precisão e recursos aprimorados à medida que os desenvolvedores aprendem como melhorar seu desempenho e, ao mesmo tempo, reduzir preconceitos e eliminar respostas incorretas.
- **Treinamento audiovisual**: embora os desenvolvedores treinem a maioria dos LLMs usando texto, alguns começaram a treinar modelos usando entrada de vídeo e áudio. Esta forma de formação deverá conduzir a um desenvolvimento mais rápido de modelos e abrir novas possibilidades em termos de utilização de LLMs para veículos autónomos.
- **Transformação do local de trabalho**: LLMs são um fator disruptivo que mudará o local de trabalho. Os LLMs provavelmente reduzirão tarefas monótonas e repetitivas da mesma forma que os robôs fizeram para tarefas

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

repetitivas de fabricação. As possibilidades incluem tarefas administrativas repetitivas, chatbots de atendimento ao cliente e redação automatizada simples.

- **IA conversacional**: os LLMs, sem dúvida, melhorarão o desempenho de assistentes virtuais automatizados como Alexa, Google Assistant e Siri. Eles serão mais capazes de interpretar a intenção do usuário e responder a comandos sofisticados.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4 PROMPT ENGINEERING

Prompt Engineering é uma disciplina que envolve o desenvolvimento e optimização de prompts para usar modelos de linguagem (LMs) de forma eficiente para uma ampla variedade de aplicações e tópicos de pesquisa. Habilidades imediatas de engenharia ajudam a compreender melhor as capacidades e limitações dos grandes modelos de linguagem (*Large-Language Models*, ou LLMs). Os pesquisadores usam engenharia de prompt (*Prompt Engineering*) para melhorar a capacidade dos LLMs em uma ampla gama de tarefas comuns e complexas, como resposta a perguntas e raciocínio aritmético. Os desenvolvedores usam engenharia de prompt para projetar técnicas de prompt robustas e eficazes que fazem interface com LLMs e outras ferramentas.

O *Prompt Engineering* é um conceito fundamental no campo do processamento de linguagem natural (*Natural Language Processing*, ou NLP) e da inteligência artificial (IA). Refere-se ao processo de projetar e elaborar instruções ou consultas específicas, conhecidas como prompts, que são usadas para interagir com modelos de NLP como GPT-3.5 para obter os resultados ou respostas desejadas. O *Prompt Engineering* eficaz é crucial para maximizar a utilidade e a precisão dos modelos de IA, pois influencia diretamente o comportamento do modelo e a qualidade das respostas geradas.

Ao trabalhar com prompts, você interage com o LLM por meio de uma API ou diretamente por uma interface gráfica. Você pode configurar alguns parâmetros para obter resultados diferentes para seus prompts.

- **Temperatura (*Temperature*)** - Em suma, quanto mais baixa a temperatura, mais determinísticos são os resultados, no sentido de que o próximo token mais provável é sempre escolhido. O aumento da temperatura pode levar a mais aleatoriedade, o que incentiva resultados mais diversificados ou criativos. Você está essencialmente aumentando os pesos dos outros tokens possíveis. Em termos de aplicação, você pode querer usar um valor de temperatura mais baixo para tarefas como controle de qualidade baseado em fatos, para encorajar respostas mais factuais e concisas. Para

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

a geração de poemas ou outras tarefas criativas, pode ser benéfico aumentar o valor da temperatura.

- **Top_p (ou *Top P*)** - Da mesma forma, com top_p, uma técnica de amostragem com temperatura chamada amostragem de núcleo, você pode controlar o quão determinístico o modelo é na geração de uma resposta. Se você está procurando respostas exatas e factuais, mantenha esse valor baixo. Se você procura respostas mais diversas, aumente para um valor mais alto.

A recomendação geral é alterar um, não ambos.

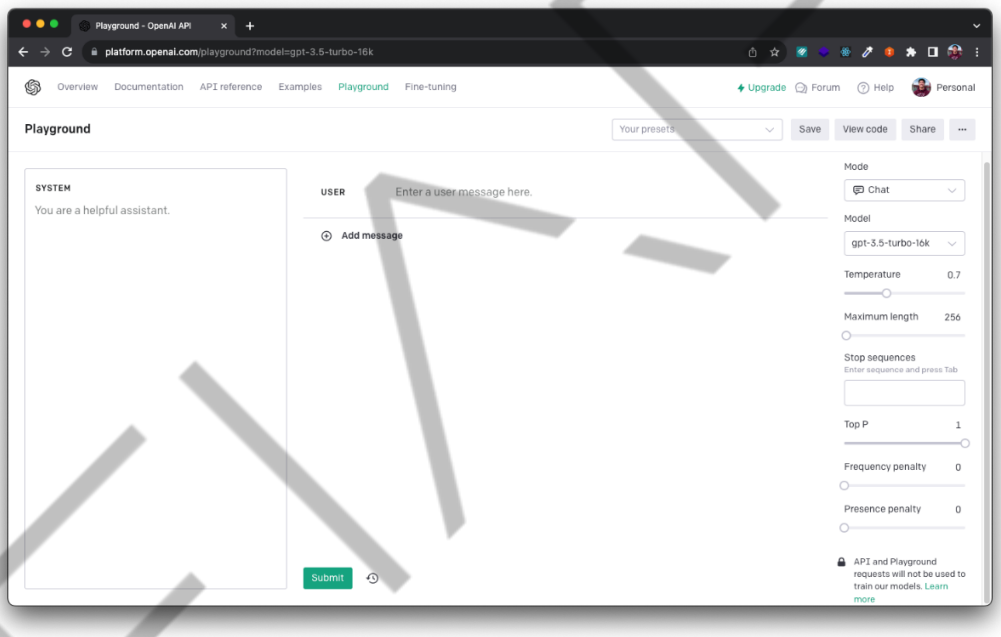

Figura 3 – OpenAI Playground para testes com a regulagem de Temperatura e Top_p
Fonte: Elaborado pelo autor (2023)

4.1 Básico de Prompts

Um prompt contém qualquer um dos seguintes elementos:

- **Instrução** - uma tarefa ou instrução específica que você deseja que o modelo execute.
- **Contexto** - informações externas ou contexto adicional que podem orientar o modelo para melhores respostas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Dados de entrada** - a entrada ou pergunta para a qual estamos interessados em encontrar uma resposta.
- **Indicador de saída** - o tipo ou formato da saída.

Você não precisa de todos os quatro elementos para um prompt e o formato depende da tarefa em questão.

Você pode conseguir atingir ótimos resultados com instruções simples, mas a qualidade dos resultados depende da quantidade de informações que você fornece e de quão bem elaboradas elas são. Um prompt pode conter informações como a instrução ou pergunta que você está passando para o modelo e incluir outros detalhes, como contexto, entradas ou exemplos. Você pode usar esses elementos para instruir melhor o modelo e, como resultado, obter melhores resultados.

Veja um exemplo básico de um simples prompt.

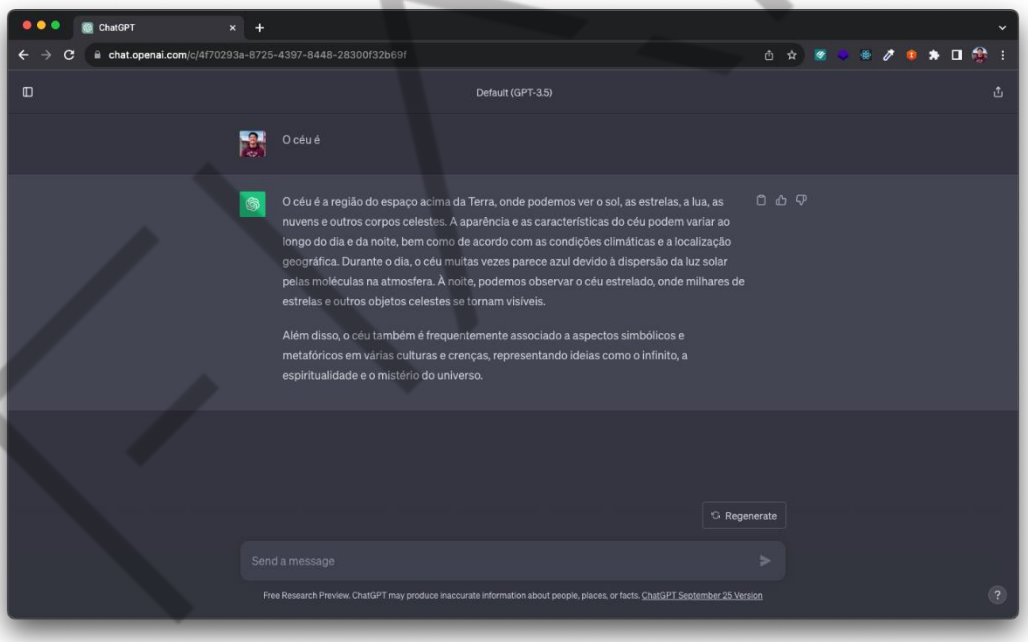

Figura 4 – ChatGPT com um exemplo básico de prompt
Fonte: Elaborado pelo autor (2023)

O modelo de linguagem gera uma continuação de palavras que fazem sentido dado o contexto "O céu é". A saída pode ser inesperada ou distante da tarefa que você deseja realizar.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O exemplo básico também ressalta a necessidade de prover mais contexto ou instruções no que especificamente você quer atingir. Então vamos melhorar um pouco.

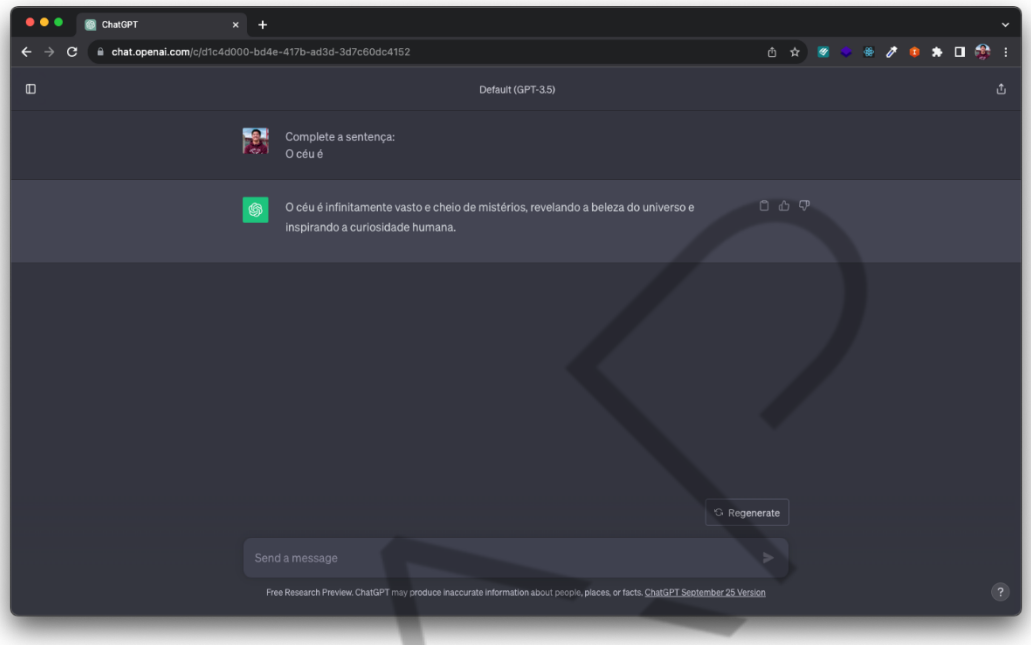

Figura 5 – ChatGPT com um exemplo básico de prompt com comando
Fonte: Elaborado pelo autor (2023)

Isto é melhor? Bem, você disse ao modelo para completar a frase, então o resultado parece muito melhor, pois segue exatamente o que você disse para fazer ("Complete a sentença"). Essa abordagem de projetar prompts ideais para instruir o modelo a executar uma tarefa é chamada de Prompt Engineering.

O exemplo apresentado é uma ilustração básica do que é possível com os LLMs hoje. Os LLMs de hoje são capazes de realizar todos os tipos de tarefas avançadas que vão desde resumo de texto até raciocínio matemático e geração de código.

4.2 Formatação do Prompt

Um padrão do prompt possui o modelo “<Pergunta>?” ou “<Instrução>”. Você pode formatar o prompt em um modelo de resposta a perguntas (Question Answering, ou QA), no qual é o padrão em muitas bases de dados de resposta a perguntas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Formatação do Prompt
Q: <Pergunta>?
A:
```

Figura 6 – Estrutura de um prompt de resposta a perguntas
Fonte: Elaborado pelo autor (2023)

Ao solicitar como o exemplo (veja figura “Estrutura de um prompt de resposta a perguntas"), também é conhecido como **Zero-Shot Prompting**, ou seja, você está solicitando diretamente ao modelo uma resposta, sem quaisquer exemplos ou demonstrações sobre a tarefa que deseja que ele realize. Alguns modelos de linguagem grandes (LLMs) têm a capacidade de executar *Zero-Shot Prompting*, mas isso depende da complexidade e do conhecimento da tarefa em questão.

Dado o formato padrão, uma técnica popular e eficaz de solicitação é chamada de *Few-Shot Prompting*, na qual você fornece exemplos (ou seja, demonstrações).

```
# Formatação de Few-Shot Prompting
<Pergunta>?
<Resposta>
<Pergunta>?
<Resposta>
<Pergunta>?
<Resposta>
<Pergunta>?
```

Figura 7 – Estrutura de um Few-Shot Prompting
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Também é possível utilizar a versão do formato QA para elaborar a estrutura de um *Few-Shot Prompting*.

```
# Formatação de Few-Shot Prompting (versão
QA)
Q: <Pergunta>?
A: <Resposta>
Q: <Pergunta>?
A: <Resposta>
Q: <Pergunta>?
A: <Resposta>
Q: <Pergunta>?
```

Figura 8 – Estrutura de um Few-Shot Prompting (versão QA)
Fonte: Elaborado pelo autor (2023)

Lembre-se de que não é necessário usar o formato QA. O formato do prompt depende da tarefa em questão. Por exemplo, você pode realizar uma tarefa de classificação simples e fornecer exemplos que demonstrem a tarefa de classificação de sentimento.

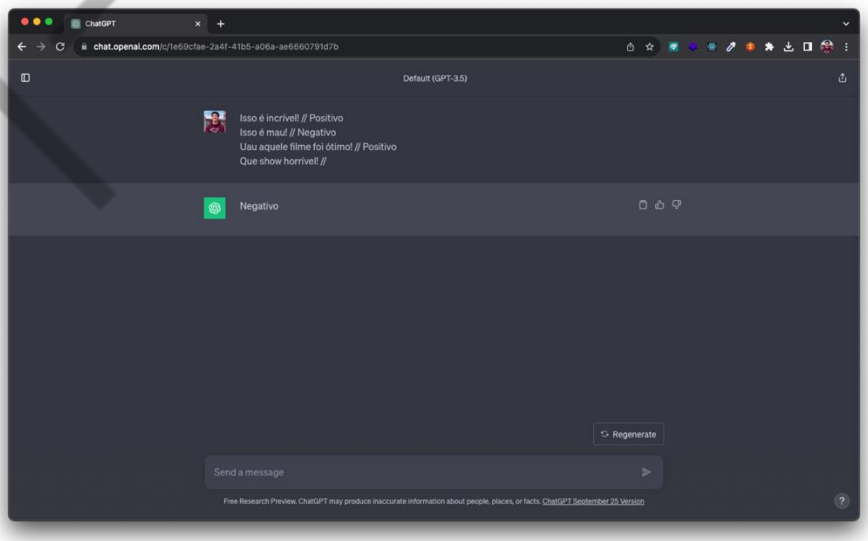

Figura 9 – Exemplo de um Few-Shot Prompting
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O *Few-Shot Prompting* permite o aprendizado dentro do contexto, que é a capacidade dos modelos de linguagem de aprender tarefas após algumas demonstrações.

4.3 Exemplos de Prompts

Os prompts são a porta de entrada para envolver e instruir os grandes modelos de linguagem (*Large-Language Models*, ou LLMs), encapsulando a essência da comunicação entre humanos e máquinas. São as pistas linguísticas que orientam os sistemas de IA moldando as suas respostas e ações. Exemplos de prompts mostram a diversidade de tarefas que podem ser realizadas com modelos de LLMs, desde extrair informações e responder perguntas até gerar histórias imaginativas ou até mesmo redigir código. Ao examinar esses exemplos, obtemos insights sobre a adaptabilidade e versatilidade dos prompts na transformação de capacidades abstratas de IA em aplicações práticas do mundo real.

4.3.1 RESUMO DE TEXTO

Uma das tarefas padrão na geração de linguagem natural é o resumo de texto. O resumo de texto pode incluir muitos sabores e domínios diferentes. Na verdade, uma das aplicações mais promissoras dos modelos de linguagem é a capacidade de resumir artigos e conceitos em resumos rápidos e fáceis de ler. Vamos tentar uma tarefa básica de resumo usando prompts.

Digamos que você esteja interessado em aprender sobre antibióticos. Você pode enviar solicitar uma sugestão (veja figura “Exemplo de prompt para Resumo de Texto”).

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 10 – Exemplo de prompt para Resumo de Texto
Fonte: Elaborado pelo autor (2023)

O "A:" é um formato de prompt explícito que você usa para responder perguntas. Você o usou aqui para dizer ao modelo que há uma resposta esperada posteriormente. Neste exemplo, não está claro como isso é útil ou não o usar, mas deixaremos isso para exemplos posteriores. Vamos apenas supor que isso seja muita informação e você queira resumi-la ainda mais. Na verdade, você pode instruir o modelo a resumir em uma frase (veja figura “Exemplo de prompt para resumir ainda mais um texto”).

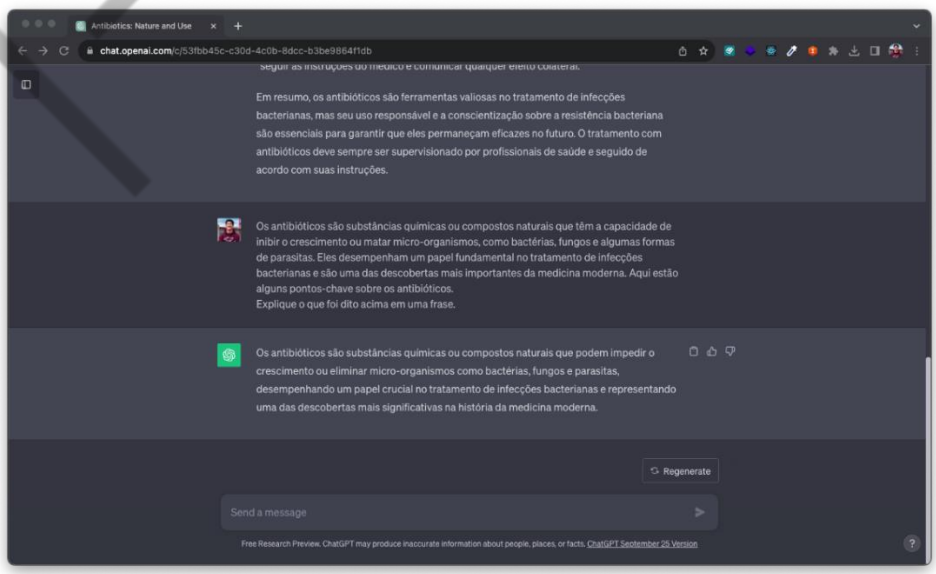

Figura 11 – Exemplo de prompt para resumir ainda mais um texto
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Sem prestar muita atenção à precisão do resultado acima, o modelo tentou resumir o parágrafo em uma frase. Você pode ser esperto com as instruções.

4.3.2 EXTRAÇÃO DE INFORMAÇÕES

Embora os modelos de linguagem sejam treinados para executar a geração de linguagem natural (*Natural Language Generation*, ou NLG) e tarefas relacionadas, eles também são muito capazes de realizar classificação e uma série de outras tarefas de processamento de linguagem natural (*Natural Language Processing*, ou NLP).

Aqui está um exemplo de prompt que extrai informações de um determinado parágrafo.

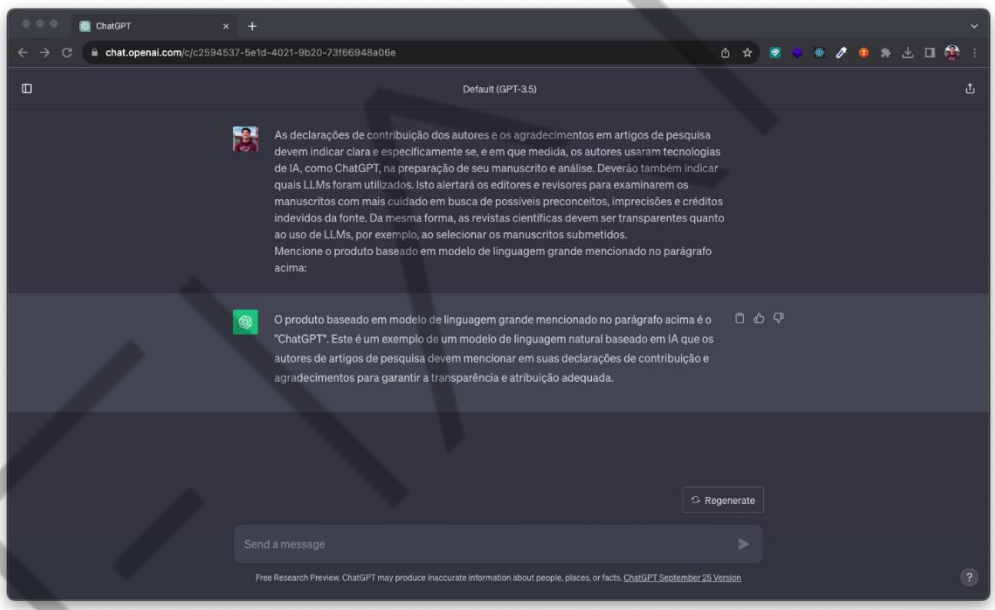

Figura 12 – Exemplo de prompt para Extração de Informações
Fonte: Elaborado pelo autor (2023)

Há muitas maneiras de melhorar os resultados acima, mas isso já é muito útil.

A esta altura, deve estar óbvio que você pode pedir ao modelo para realizar diferentes tarefas, simplesmente instruindo-o sobre o que fazer. Esse é um recurso poderoso que os desenvolvedores de produtos de IA já estão usando para criar produtos e experiências poderosas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4.3.3 RESPOSTA A PERGUNTAS

Uma das melhores maneiras de fazer com que o formato responda a respostas específicas é melhorar o formato do prompt. Conforme abordado anteriormente, um prompt pode combinar instruções, contexto, indicadores de entrada e de saída para obter melhores resultados. Embora esses componentes não sejam obrigatórios, tornam-se uma boa prática, pois quanto mais específico você for nas instruções, melhores resultados obterão. Veja um exemplo de como isso ficaria seguindo um prompt mais estruturado (veja figura "Exemplo de prompt para Resposta a Perguntas").

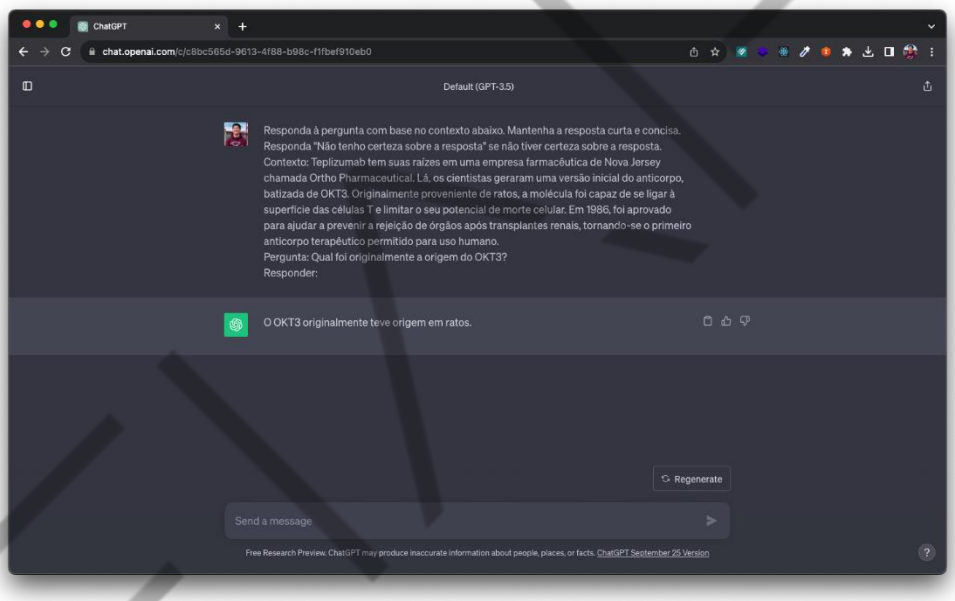

Figura 13 – Exemplo de prompt para Resposta a Perguntas
Fonte: Elaborado pelo autor (2023)

4.3.4 CLASSIFICAÇÃO DE TEXTO

Até agora, você usou instruções simples para executar uma tarefa. Como um Prompt Engineer, você precisa melhorar o fornecimento de instruções melhores. Mas isso não é tudo! Você também descobrirá que, para casos de uso mais difíceis, apenas fornecer instruções não será suficiente. É aqui que você precisa pensar mais sobre o contexto e os diferentes elementos que você pode usar em um prompt. Outros elementos que você pode fornecer são dados de entrada ou exemplos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Vamos tentar demonstrar isso fornecendo um exemplo de classificação de texto.

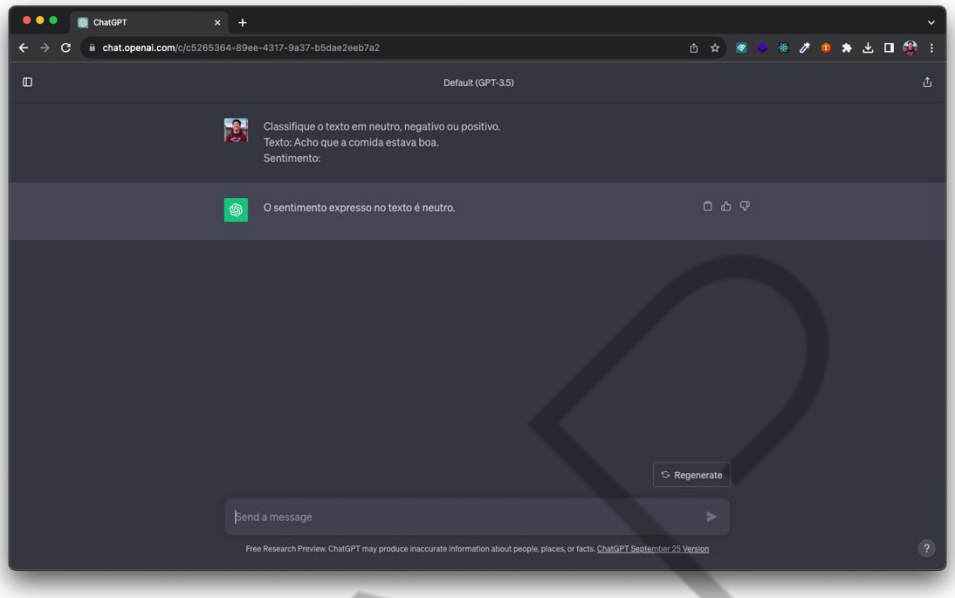

Figura 14 – Exemplo de prompt para Classificação de Texto
Fonte: Elaborado pelo autor (2023)

Você deu a instrução para classificar o texto e a modelo respondeu com 'Neutro', o que está correto. Não há nada de errado com isso, mas digamos que o que você realmente precisa é que o modelo forneça a etiqueta no formato exato que você deseja. Então, em vez de **Neutro**, você deseja que ele retorne **neutro**. Como você consegue isso? Existem diferentes maneiras de fazer isso. Você se preocupa com a especificidade aqui, portanto, quanto mais informações você puder fornecer, melhores resultados. Você pode tentar fornecer exemplos para especificar o comportamento correto.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

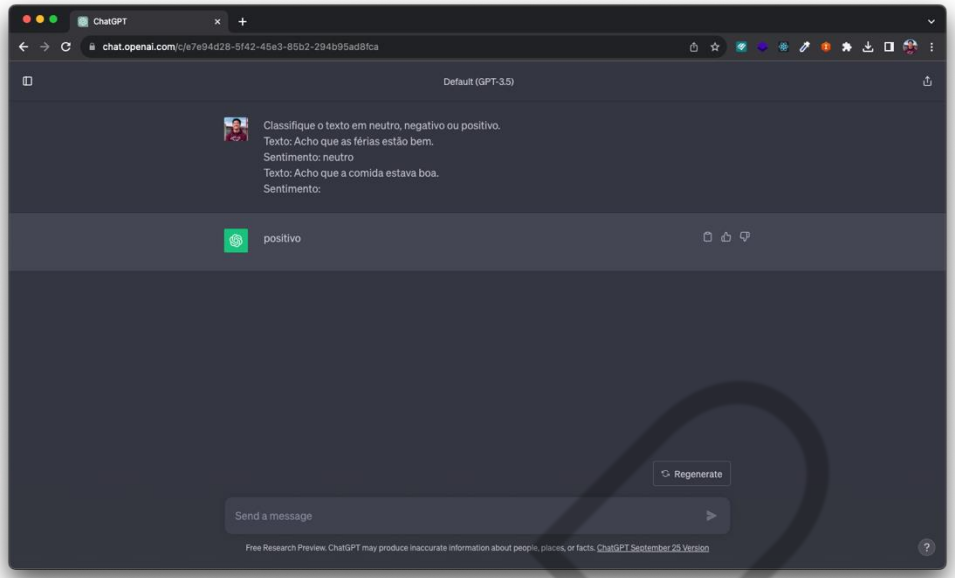

Figura 15 – Exemplo de prompt para Classificação de Texto com formato exato esperado
Fonte: Elaborado pelo autor (2023)

Perfeito! Desta vez o modelo retornou **positivo**, que é o rótulo específico que você procurava. Parece que o exemplo fornecido no prompt ajudou o modelo a ser específico em sua saída.

Para destacar porque às vezes é importante ser específico, veja a figura de exemplo e localize o problema (veja figura “Exemplo de prompt para Classificação de Texto com um problema inserido”).

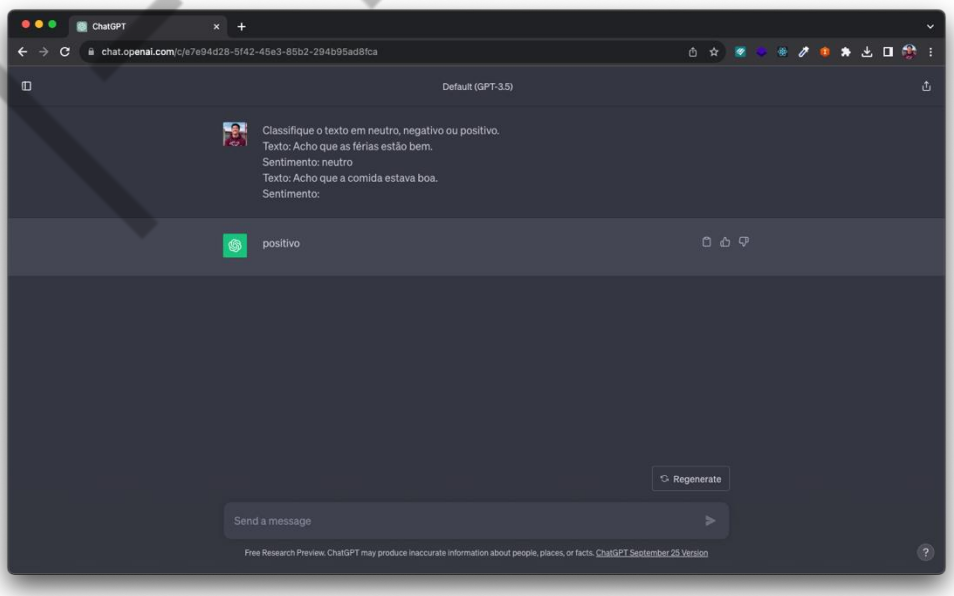

Figura 16 – Exemplo de prompt para Classificação de Texto com um problema inserido
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Qual é o problema aqui? Como dica, o rótulo **nutro** inventado é completamente ignorado pela modelo. Em vez disso, o modelo produz **positivo**, pois tem alguma tendência em relação a esse rótulo. Mas vamos supor que o que você realmente quer é **nutro**. Como você consertaria isso? Talvez você possa tentar adicionar descrições aos rótulos ou adicionar mais exemplos ao prompt?

4.3.5 CONVERSAÇÃO

Talvez uma das coisas mais interessantes que você pode conseguir com a Prompt Engineering seja instruir o sistema LLM sobre como se comportar, sua intenção e sua identidade. Isso é particularmente útil quando você está construindo sistemas de conversação, como chatbots de atendimento ao cliente.

Por exemplo, vamos criar um sistema conversacional capaz de gerar respostas mais técnicas e científicas às perguntas. Observe como você está dizendo explicitamente como se comportar por meio das instruções. Isso às vezes é chamado de função de prompting.

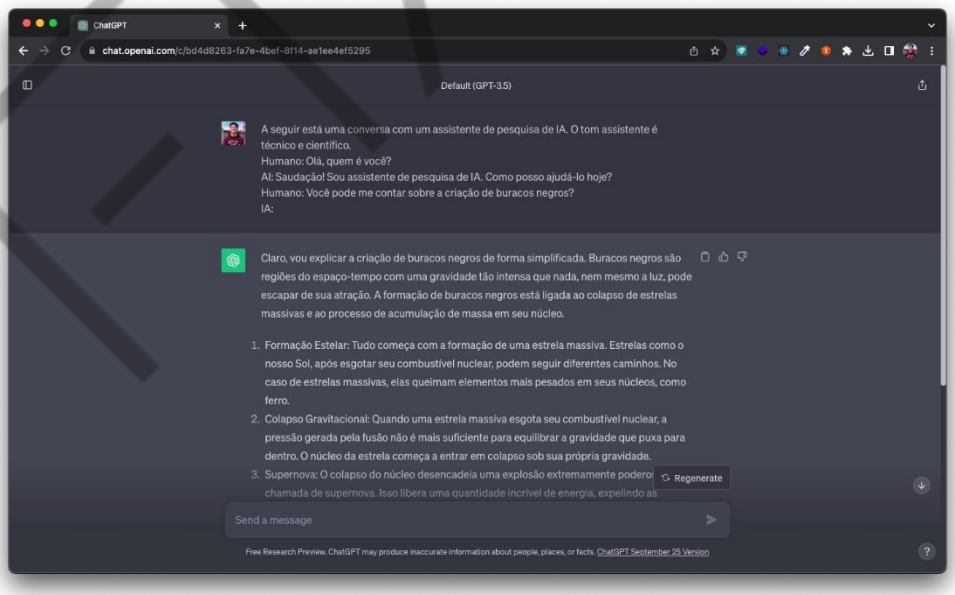

Figura 17 – Exemplo de prompt para Conversação
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Nosso assistente de pesquisa de IA parece um pouco técnico demais, certo? Ok, vamos mudar esse comportamento e instruir o sistema a dar respostas mais acessíveis.

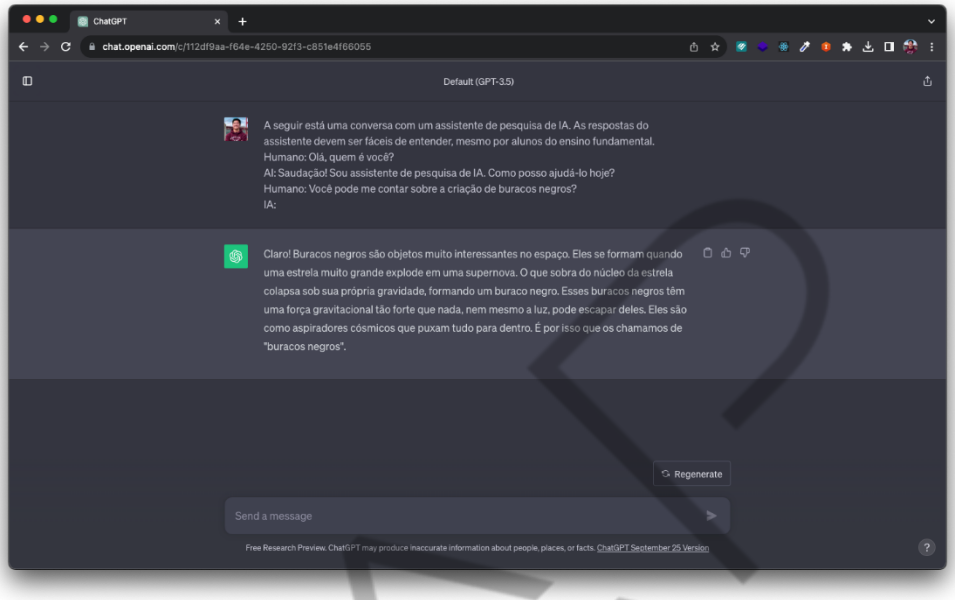

Figura 18 – Exemplo de prompt para Conversação com mais contexto
Fonte: Elaborado pelo autor (2023)

Você fez algum progresso. Você pode continuar melhorando. Se você adicionar mais exemplos, poderá obter resultados ainda melhores.

4.3.6 GERAÇÃO DE CÓDIGO

Uma aplicação em que os LLMs são bastante eficazes é a geração de código. O Amazon CodeWhisperer e o Github Copilot são ótimos exemplos disso. Há um grande número de tarefas de geração de código que você pode executar com instruções inteligentes.

Primeiro, vamos tentar um programa simples que cumprimente o usuário.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

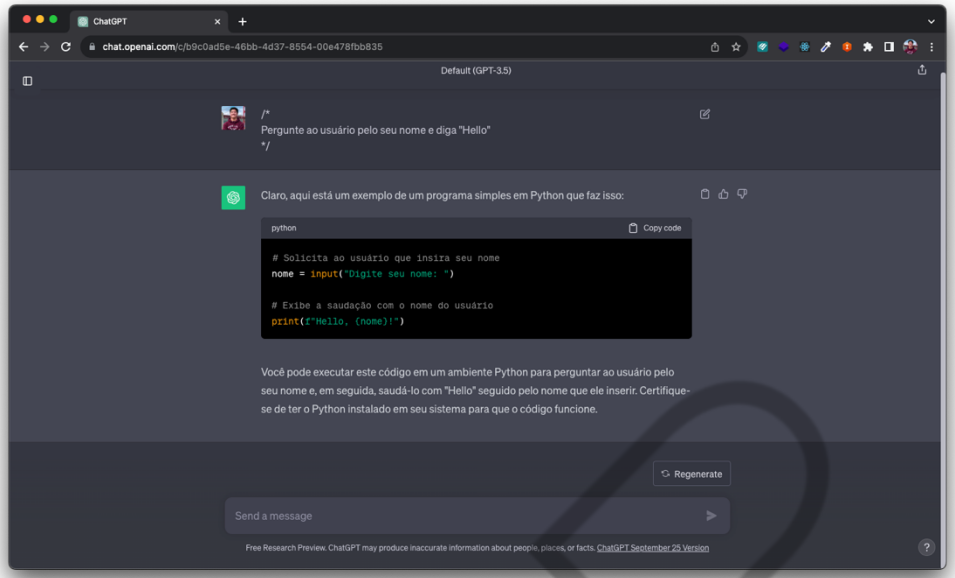

Figura 19 – Exemplo de prompt para Geração de Código
Fonte: Elaborado pelo autor (2023)

Observe que você nem precisou especificar o idioma a ser usado.

Vamos mudar um pouco de nível. O próximo exemplo mostra como os LLMs podem ser poderosos com um pouco mais de esforço no design dos prompts.

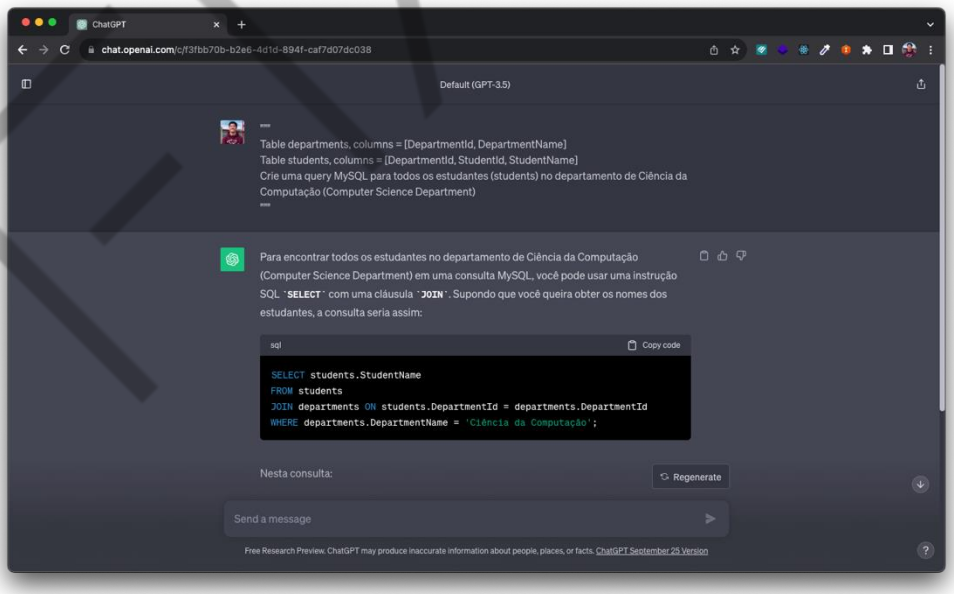

Figura 20 – Exemplo de prompt para Geração de Código para query MySQL
Fonte: Elaborado pelo autor (2023)

Isto é muito impressionante. Nesse caso, você forneceu dados sobre o esquema do banco de dados e solicitou que ele gerasse uma consulta MySQL válida.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4.3.7 RACIOCÍNIO

Talvez uma das tarefas mais difíceis para um LLM hoje seja aquela que requer alguma forma de raciocínio. O raciocínio é uma das áreas mais interessantes devido aos tipos de aplicações complexas que podem surgir dos LLMs.

Houve algumas melhorias em tarefas que envolvem capacidades matemáticas. Dito isto, é importante observar que os LLMs atuais têm dificuldade para realizar tarefas de raciocínio, portanto, isso requer técnicas de Prompt Engineering ainda mais avançadas. De início, cobriremos alguns exemplos básicos para mostrar capacidades aritméticas.

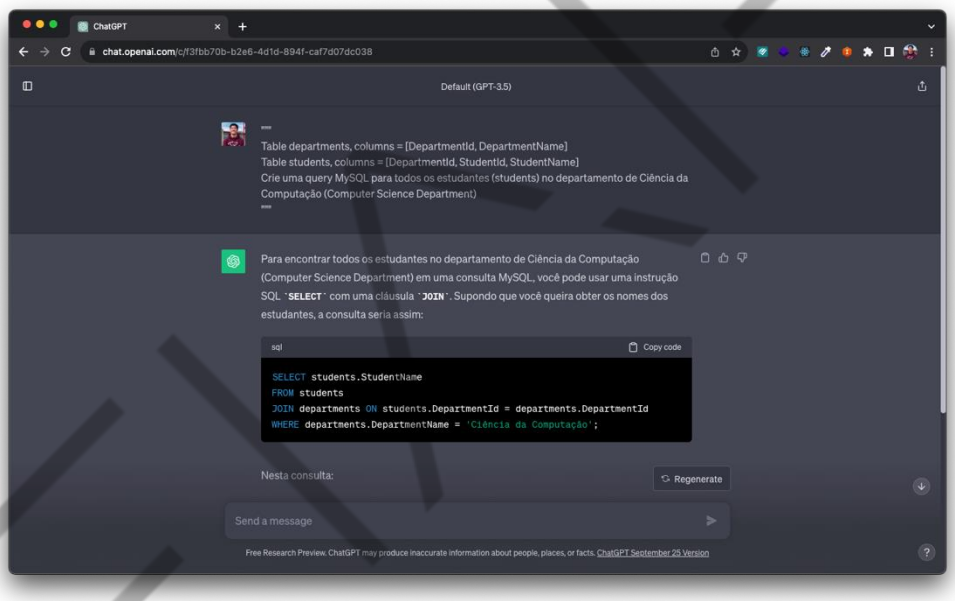

Figura 21 – Exemplo de prompt para Raciocínio
Fonte: Elaborado pelo autor (2023)

Vamos tentar algo mais difícil.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

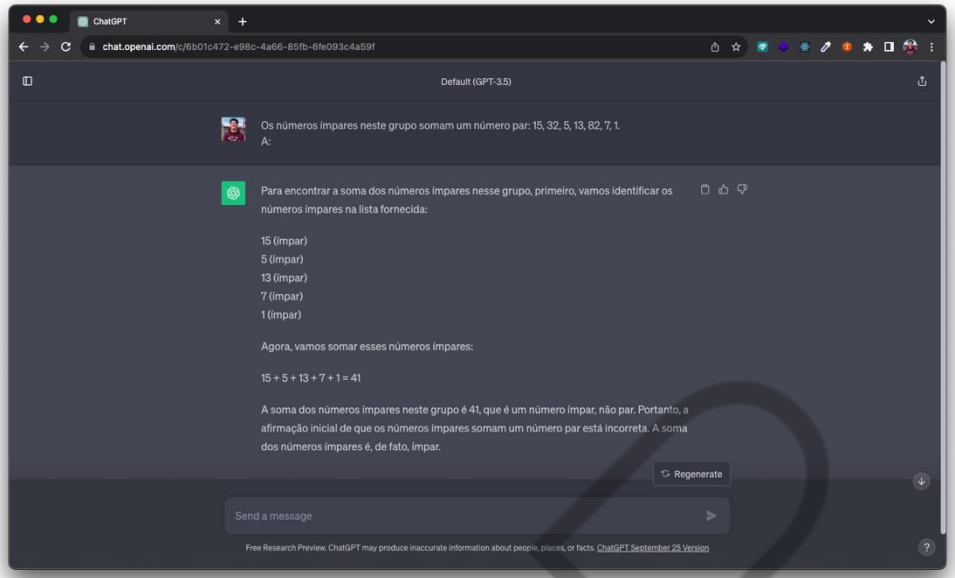

Figura 22 – Exemplo de prompt para Raciocínio com um desafio mais difícil
Fonte: Elaborado pelo autor (2023)

Existem outros exemplos de casos de usos que você pode testar e se aprofundar. Além disso, existem mais conceitos e técnicas avançadas de Prompt Engineering para aprimorar o desempenho dos prompts e para realizar tarefas mais difíceis.

4.4 Técnicas de Prompting

As Técnicas de Prompting são o kit de ferramentas de estratégias e métodos usados para criar instruções eficazes e precisas para interagir com grandes modelos de linguagem (Large-Language Models, ou LLMs). Essas técnicas são a força motriz por trás da obtenção dos resultados desejados e da influência do comportamento dos sistemas de IA. Seja ajustando o parâmetro de temperatura para controlar a aleatoriedade da resposta, incorporando lógica condicional ou usando instruções do sistema para orientar o comportamento do modelo, as técnicas de prompt são essenciais para ajustar o desempenho da IA para tarefas específicas. A exploração dessas técnicas nos permite aprofundar a arte de solicitar e fornece insights valiosos sobre como otimizar as interações com LLMs, tornando-os mais úteis e adaptados às nossas necessidades.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4.4.1 ZERO-SHOT PROMPTING

Grandes LLMs hoje, como o GPT-3.5, são ajustados para seguir instruções e são treinados em grandes quantidades de dados; portanto, eles são capazes de realizar algumas tarefas de "Zero-Shot".

Experimentamos alguns exemplos de Zero-Shot anteriormente.

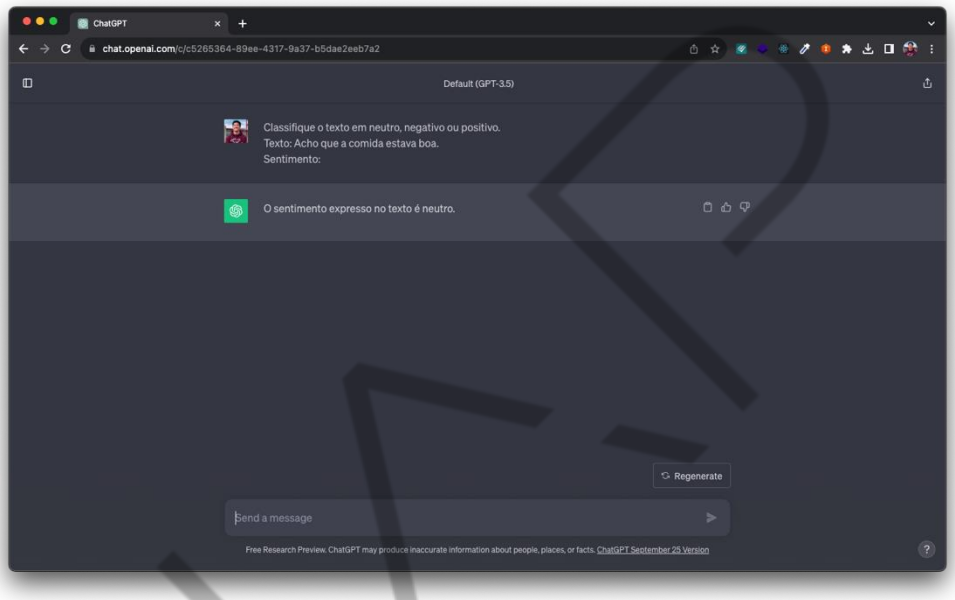

Figura 23 – Exemplo de prompt para Zero-Shot Prompting
Fonte: Elaborado pelo autor (2023)

Observe que no prompt (veja figura “Exemplo de prompt para Zero-Shot Prompting”) não fornecemos ao modelo nenhum exemplo de texto junto com suas classificações, o LLM já entende "sentimento" - são os recursos de Zero-Shot em ação.

O ajuste de instruções demonstrou melhorar o aprendizado Zero-Shot (apresentado no paper “*Finetuned Language Models Are Zero-Shot Learners*” - https://arxiv.org/pdf/2109.01652.pdf). O ajuste de instruções é essencialmente o conceito de ajuste fino de modelos em conjuntos de dados descritos por meio de instruções. Além disso, Aprendizado por Reforço a partir de Feedback Humano (*Reinforcement Learning from Human Feedback*, ou RLHF) foi adotado para dimensionar o ajuste de instruções em que o modelo é alinhado para melhor se adequar às preferências humanas. Este desenvolvimento recente potencializa modelos como ChatGPT.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Quando o Zero-Shot não funciona, é recomendável fornecer demonstrações ou exemplos no prompt que levem ao prompt de few-shot.

4.4.2 FEW-SHOT PROMPTING

Embora os modelos de linguagem grande demonstrem capacidades notáveis de Zero-Shot, eles ainda ficam aquém em tarefas mais complexas quando usam a configuração de Zero-Shot. O Few-Shot Prompting pode ser usado como uma técnica para permitir o aprendizado no contexto, onde fornecemos demonstrações no prompt para orientar o modelo para um melhor desempenho. As demonstrações servem de condicionamento para exemplos subsequentes onde gostaríamos que o modelo gerasse uma resposta.

De acordo com paper "*LLaMA: Open and Efficient Foundation Language Models*" (https://arxiv.org/pdf/2302.13971.pdf) propriedades de Few-Shot apareceram pela primeira vez quando os modelos foram dimensionados para um tamanho suficiente (apresentado também no paper "*Scaling Laws for Neural Language Models*" - https://arxiv.org/abs/2001.08361).

Vamos demonstrar o Few-Shot Prompting por meio de um exemplo apresentado no paper "*Language Models are Few-Shot Learners*" (https://arxiv.org/abs/2005.14165). No exemplo, a tarefa é usar corretamente uma nova palavra em uma frase.

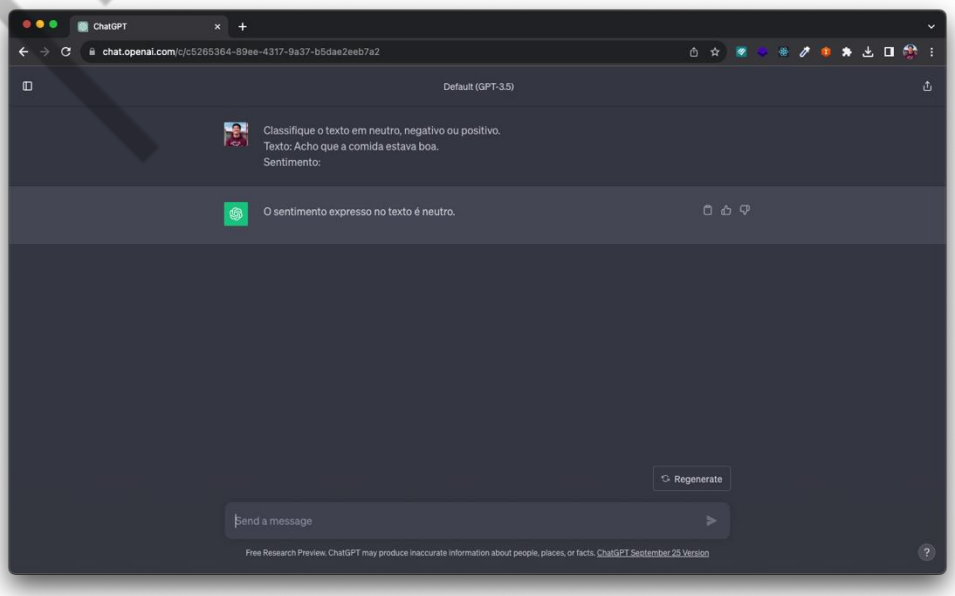

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 24 – Exemplo de prompt para Few-Shot Prompting com nova palavra
Fonte: Elaborado pelo autor (2023)

Podemos observar que o modelo aprendeu de alguma forma como executar a tarefa, fornecendo-lhe apenas um exemplo (ou seja, 1-shot). Para tarefas mais difíceis, podemos experimentar aumentar as demonstrações (por exemplo, 3-shot, 5-shot, 10-shot, etc.).

Seguindo as descobertas do paper "*Rethinking the Role of Demonstrations: What Makes In-Context Learning Work?*" (https://arxiv.org/abs/2202.12837), aqui estão mais algumas dicas sobre demonstrações/exemplos ao fazer poucas fotos:

- O espaço do rótulo e a distribuição do texto de entrada especificado pelas demonstrações são importantes (independentemente de os rótulos estarem corretos para entradas individuais).
- O formato que você usa também desempenha um papel fundamental no desempenho, mesmo se você usar apenas rótulos aleatórios, isso é muito melhor do que nenhum rótulo.
- Resultados adicionais mostram que selecionar rótulos aleatórios de uma distribuição verdadeira de rótulos (em vez de uma distribuição uniforme) também ajuda.

Vamos experimentar alguns exemplos. Vamos primeiro tentar um exemplo com rótulos aleatórios (ou seja, os rótulos Negativo e Positivo são atribuídos aleatoriamente às entradas).

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

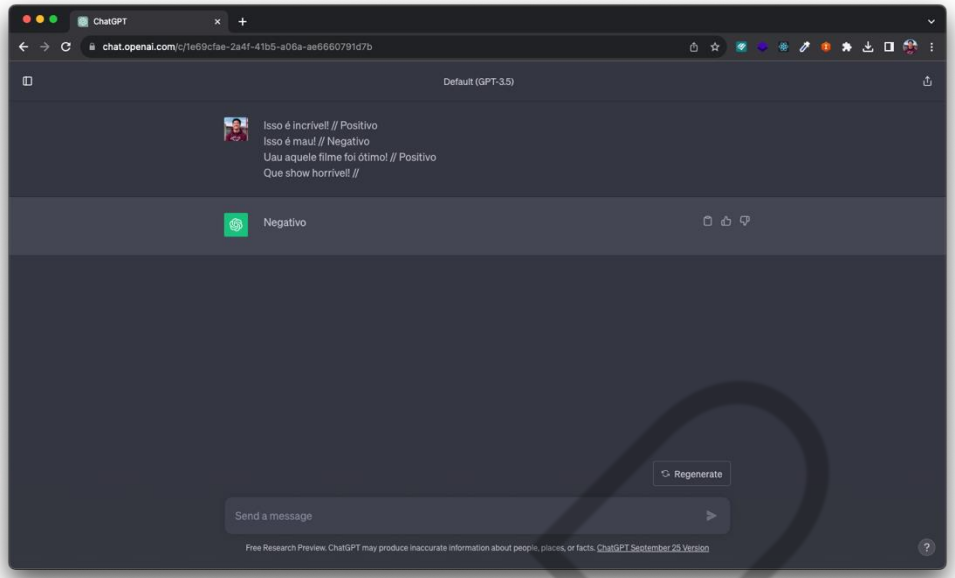

Figura 25 – Exemplo de prompt para Zero-Shot Prompting para classificação
Fonte: Elaborado pelo autor (2023)

Ainda obtemos a resposta correta, embora os rótulos tenham sido randomizados. Observe que também mantivemos o formato, o que também ajuda. Na verdade, com mais experimentações, parece que os modelos GPT mais recentes que estamos experimentando estão se tornando mais robustos até mesmo para formatos aleatórios.

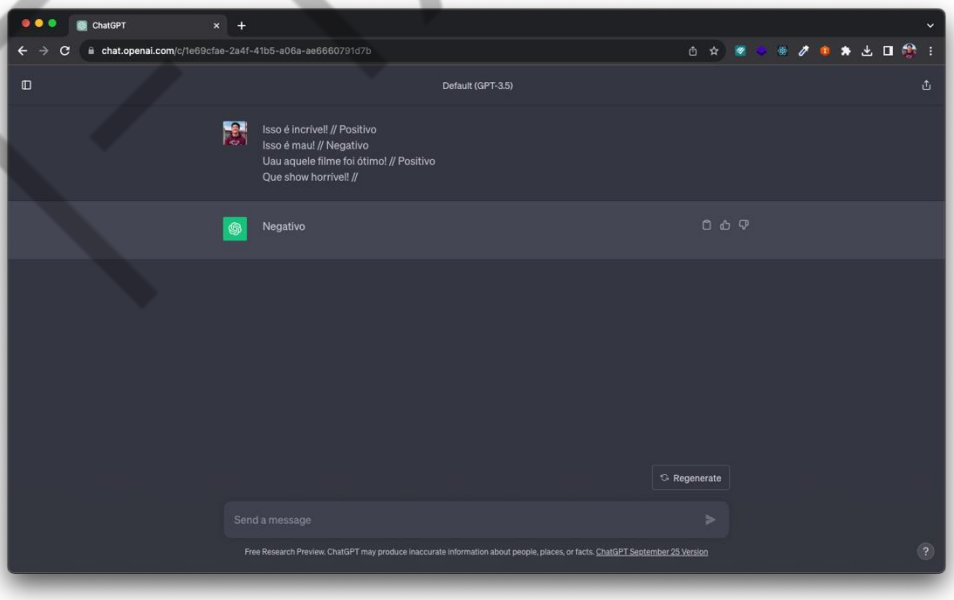

Figura 26 – Exemplo de prompt para Zero-Shot Prompting sem padrão
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Não há consistência no formato acima, mas o modelo ainda previu o rótulo correto. Temos que realizar uma análise mais aprofundada para confirmar se isso se aplica a tarefas diferentes e mais complexas, incluindo diferentes variações de prompts.

4.4.3 CHAIN-OF-THOUGHT PROMPTING

Introduzido no paper "*Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*" (https://arxiv.org/abs/2201.11903), o prompt de Chain-of-Thought (CoT) permite capacidades de raciocínio complexas por meio de etapas intermediárias de raciocínio. Você pode combiná-lo com Few-Shot Prompting para obter melhores resultados em tarefas mais complexas que exigem raciocínio antes de responder.

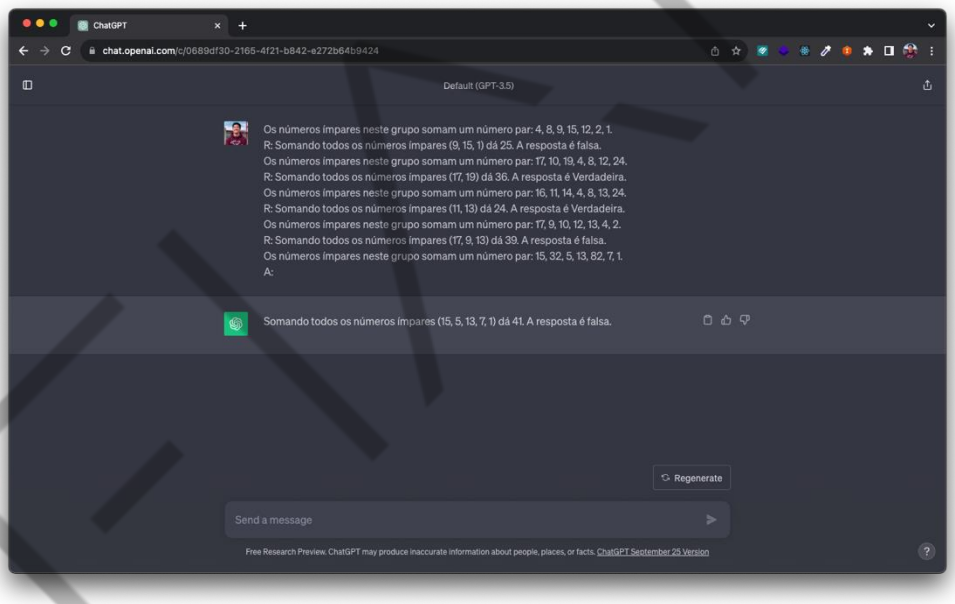

Figura 27 – Exemplo de prompt para Chain-of-Thought Prompting
Fonte: Elaborado pelo autor (2023)

Podemos ver um resultado perfeito quando fornecemos a etapa de raciocínio. Na verdade, podemos resolver esta tarefa fornecendo ainda menos exemplos, ou seja, apenas um exemplo parece suficiente.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

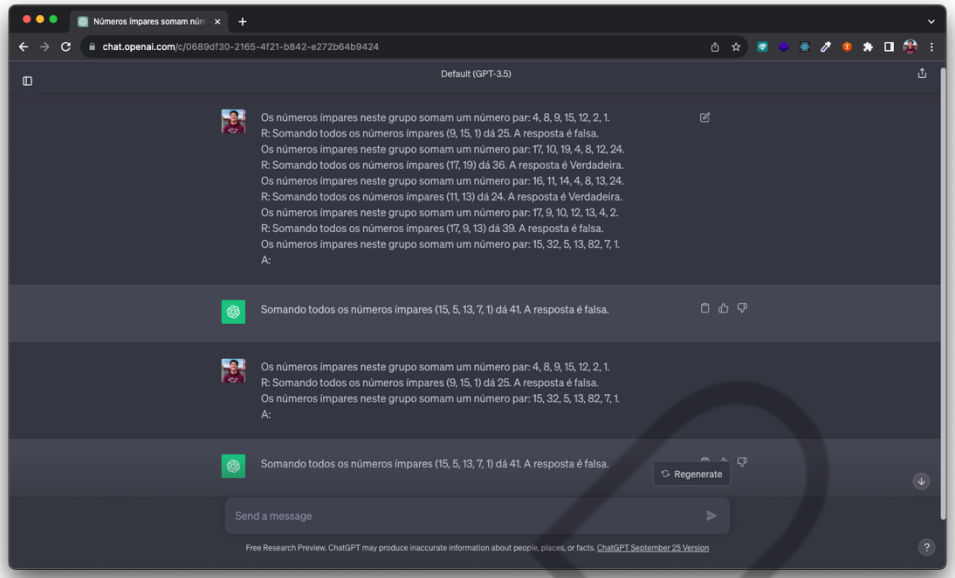

Figura 28 – Exemplo de prompt para Chain-of-Thought Prompting com menos exemplos
Fonte: Elaborado pelo autor (2023)

Tenha em mente que os autores afirmam que esta é uma habilidade emergente que surge com modelos de linguagem suficientemente grandes.

Uma ideia recente que surgiu no final de 2022 é a ideia de Zero-Shot CoT (apresentado no paper "*Large Language Models are Zero-Shot Reasoners*" - https://arxiv.org/abs/2205.11916) que envolve essencialmente adicionar "Vamos pensar passo a passo" ao prompt original. Vamos tentar um problema simples e ver o desempenho do modelo.

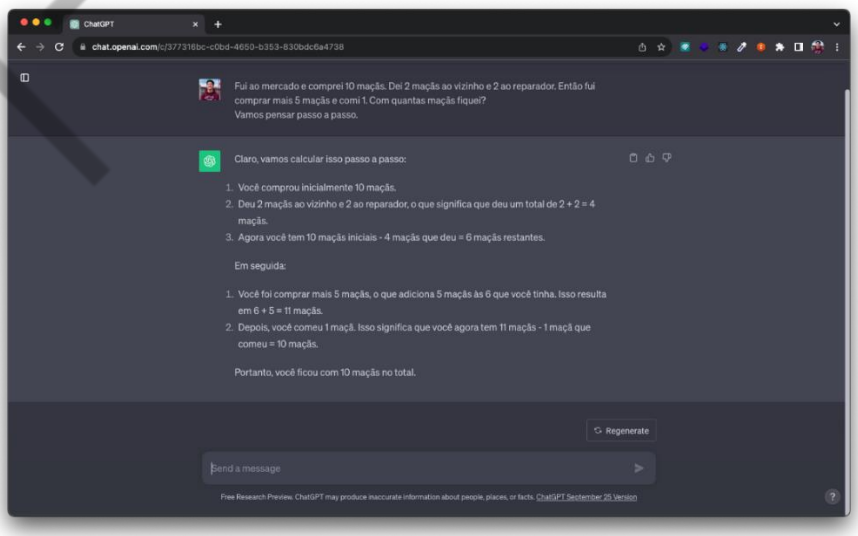

Figura 29 – Exemplo de prompt para Zero-Shot Chain-of-Thought Prompting
Fonte: Elaborado pelo autor (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

É impressionante que este simples prompt seja eficaz nesta tarefa. Isto é particularmente útil quando você não tem muitos exemplos para usar no prompt. Na versão do GPT-3.5, para este exemplo, não há necessidade de incluir a frase “Vamos pensar no passo a passo”. O modelo já executa o prompt num modelo de Zero-Shot CoT.

4.4.4 RETRIEVAL AUGMENTED GENERATION (RAG)

Os modelos de linguagem de uso geral podem ser ajustados para realizar diversas tarefas comuns, como análise de sentimento e reconhecimento de entidade nomeada. Essas tarefas geralmente não requerem conhecimento prévio adicional.

Para tarefas mais complexas e que exigem muito conhecimento, é possível construir um sistema baseado em modelo de linguagem que acesse fontes externas de conhecimento para concluir tarefas. Isto permite uma maior consistência factual, melhora a confiabilidade das respostas geradas e ajuda a mitigar o problema da “alucinação”.

Os pesquisadores da Meta AI introduziram um método chamado Retrieval Augmented Generation (RAG) para lidar com essas tarefas que exigem muito conhecimento. RAG combina um componente de recuperação de informação com um modelo gerador de texto. O RAG pode ser ajustado e seu conhecimento interno modificado de forma eficiente e sem a necessidade de retreinamento de todo o modelo.

O RAG recebe uma entrada e recupera um conjunto de documentos relevantes/de apoio, dada uma fonte (por exemplo, Wikipedia). Os documentos são concatenados como contexto com o prompt de entrada original e alimentados no gerador de texto que produz a saída final. Isto torna o RAG adaptável a situações em que os factos possam evoluir ao longo do tempo. Isto é muito útil porque o conhecimento paramétrico dos LLMs é estático. O RAG permite que os modelos de linguagem contornem o retreinamento, permitindo acesso às informações mais recentes para gerar resultados confiáveis por meio da geração baseada em recuperação.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O paper "*Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*" (https://arxiv.org/pdf/2005.11401.pdf) propôs uma receita de ajuste fino de uso geral para RAG. Um modelo seq2seq pré-treinado é usado como memória paramétrica e um índice vetorial denso da Wikipedia é usado como memória não paramétrica (acessado usando um recuperador neural pré-treinado).

O RAG tem um bom desempenho em vários benchmarks, como Natural Questions, WebQuestions e CuratedTrec. O RAG gera respostas mais factuais, específicas e diversas quando testadas em questões MS-MARCO e Jeopardy. O RAG também melhora os resultados na verificação de fatos do FEVER.

Isto mostra o potencial do RAG como uma opção viável para melhorar os resultados dos modelos linguísticos em tarefas intensivas em conhecimento.

Mais recentemente, essas abordagens baseadas em recuperadores tornaram-se mais populares e são combinadas com LLMs populares como ChatGPT para melhorar as capacidades e a consistência factual.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

CHAIN-of-thought prompting elicits reasoning in large language models. **ArXiv**. 28 jan. 2022. Disponível em: <https://arxiv.org/abs/2201.11903>. Acesso em: 30 set. 2023.

FINETUNED language models are zero-shot learners. **ArXiv**. 08 fev. 2022. Disponível em: <https://arxiv.org/pdf/2109.01652.pdf>. Acesso em: 30 set. 2023.

LLAMA: open and efficient foundation language models. **ArXiv**. 27 fev. 2023. Disponível em: <https://arxiv.org/pdf/2302.13971.pdf>. Acesso em: 30 set. 2023.

LANGUAGE models are few-shot learners. **ArXiv**. 22 maio 2020. Disponível em: <https://arxiv.org/abs/2005.14165>. Acesso em: 30 set. 2023.

LARGE language models are zero-shot reasoners. **ArXiv**. 24 maio 2022. Disponível em: <https://arxiv.org/abs/2205.11916>. Acesso em: 30 set. 2023.

RETRIEVAL-augmented generation for knowledge-intensive nlp tasks. **ArXiv**. 12 abr. 2021. Disponível em: <https://arxiv.org/pdf/2005.11401.pdf>. Acesso em: 30 set. 2023.

RETRIEVAL augmented generation: streamlining the creation of intelligent natural language processing models. **ArXiv**. 28 set. 2020. Disponível em: <https://ai.meta.com/blog/retrieval-augmented-generation-streamlining-the-creation-of-intelligent-natural-language-processing-models/>. Acesso em: 30 set. 2023.

RETHINKING the role of demonstrations: what makes in-context learning work?. **ArXiv**. 25 fev. 2022. Disponível em: <https://arxiv.org/abs/2202.12837>. Acesso em: 30 set. 2023.

SCALING laws for neural language models. **ArXiv**. 30 jan. 2020. Disponível em: <https://arxiv.org/abs/2001.08361>. Acesso em: 30 set. 2023.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com