



WBA0457_v2.0

Cloud computing



Aplicações e serviços de nuvem

Big Data e machine learning na nuvem

Bloco 1

Vinícius Climaco



Vamos refletir?

A evolução da computação em nuvem não só transformou a forma como armazenamos dados, mas também a forma como aplicamos esses dados para gerar valor.

Como o *Big Data* e o *machine learning*, quando combinados com a nuvem, podem mudar o cenário empresarial nos próximos anos?





O que é *Big Data* e *machine learning*?

Big Data se refere ao grande volume de dados, estruturados e não estruturados, gerado continuamente por várias fontes. A capacidade de processar e analisar esses dados em larga escala é o que possibilita a inovação.

Machine learning (ML) é um campo da Inteligência Artificial (IA), que permite que os sistemas aprendam e melhorem automaticamente a partir de experiências, sem serem explicitamente programados para isso. Na nuvem, o ML pode ser escalado de forma eficiente.




Casos de uso do *Big Data* em nuvem

O *Big Data* é utilizado em setores como saúde, marketing e finanças, a fim de identificar padrões, prever comportamentos e tomar decisões baseadas em dados.

Exemplos incluem a análise de grandes volumes de dados de pacientes para prever surtos de doenças ou a utilização de dados de consumo para personalizar ofertas em tempo real.

AWS data pipeline



Fonte:

<https://d2908q01vomqb2.cloudfront.net/fc074d501302eb2b93e2554793fc50b3bf7291/2023/01/19/Figure1.png>.



Machine learning e cloud computing

Com a escalabilidade oferecida pela nuvem, o *machine learning* pode processar vastos volumes de dados e entregar insights em tempo real. Isso permite às empresas construir modelos mais precisos e inovar mais rapidamente.

Serviços como **Amazon SageMaker**, **Azure Machine Learning** e **Google Cloud AI** facilitam a criação, o treinamento e a implementação de modelos ML de forma eficiente.




Empresas usando ML para análise de dados


Empresas de tecnologia, como Netflix e Amazon, usam *machine learning* para analisar os comportamentos dos usuários e oferecer recomendações personalizadas. Esse tipo de aplicação melhora a experiência do cliente e impulsiona as vendas.

A área de finanças e os bancos utilizam *machine learning* para detectar fraudes em tempo real, analisando padrões de transações suspeitas.

Azure data pipeline



Fonte: <https://learn.microsoft.com/api/attachments/102438-image.png?platform=QnA>.



Reflexão sobre *Big Data* e ML nas empresas

- Como *Big Data* e *machine learning* podem ser integrados para ajudar as empresas a tomar decisões mais estratégicas?
- Quais são os maiores desafios enfrentados ao aplicar essas tecnologias no dia a dia corporativo, especialmente em um ambiente em constante mudança, como a nuvem?




Aplicações e serviços de nuvem

Internet das coisas e *cloud computing*

Bloco 2

Vinícius Climaco



Introdução às ferramentas de processamento e análise

Ferramentas de processamento de dados em nuvem são essenciais para lidar com grandes volumes de dados. Além disso, permitem transformar dados brutos em informações valiosas e prontas para análise.

Entre as principais ferramentas, destacam-se o Amazon EMR e o Azure Data Lake Analytics, ambos amplamente utilizados para o processamento de grandes volumes de dados em diferentes setores.






Amazon EMR: processamento de grandes volumes de dados

O Amazon EMR (*Elastic MapReduce*) é uma plataforma na nuvem que facilita o processamento massivo de dados, usando *frameworks* como Apache Hadoop e Spark. Além disso, permite que grandes volumes de dados sejam processados de maneira distribuída.


Seu uso é comum em tarefas como classificação de dados, mineração de dados e análises complexas em escala.

Fluxo de ETL com AWS Glue e integração de dados



Fonte:

<https://d2908q01vomqb2.cloudfront.net/d435a6cdd786300dff204ee7c2ef942d3e9034e2/2019/09/09/Figure5-1024x500.jpg>.



Azure Data Lake e processamento de dados em escala

O Azure Data Lake Analytics é uma solução escalável de processamento de dados, que permite executar trabalhos de análise de grandes volumes de dados. É altamente eficiente para processar dados não estruturados e semiestruturados.

A integração com outras ferramentas da Azure, como o Azure Synapse, possibilita uma análise completa e unificada dos dados armazenados em Data Lakes.




Serviços AWS para análise de dados

O Amazon Redshift é uma das soluções mais poderosas da AWS para análise de dados em grande escala. Permite que empresas realizem consultas em grandes volumes de dados, com performance otimizada.

Além disso, o AWS Glue facilita a preparação e transformação de dados, integrando-se facilmente com o Redshift para análises avançadas.

Arquitetura de dados na AWS



Fonte:

<https://d2908q01vomqb2.cloudfront.net/b6692ea5df920cad691c20319a6fffd7a4a766b8/2018/02/09/Cerberus3.png>

Comparação entre AWS e Azure

O Amazon EMR é uma solução robusta para processamento distribuído, com foco em *frameworks* como Apache Spark e Hadoop. Por outro lado, o Azure Data Lake Analytics oferece uma abordagem mais integrada ao ecossistema Microsoft, focada em processamento de dados não estruturados.

A escolha entre essas ferramentas depende do ecossistema já utilizado pela empresa e dos requisitos de processamento de dados.




Aplicações e serviços de nuvem

Serviços de armazenamento e processamento de dados distribuídos

Bloco 3

Vinícius Climaco



Introdução ao armazenamento em nuvem

O armazenamento na nuvem revolucionou a forma como lidamos com grandes volumes de dados, permitindo o acesso remoto, escalabilidade e segurança.


Os principais provedores de nuvem, como AWS e Azure, oferecem diferentes tipos de armazenamento adequados a várias necessidades, desde objetos até arquivos e blocos. Exploraremos as opções de armazenamento em ambas as plataformas, a fim de entender suas aplicações.




Processamento distribuído em nuvem

Com o aumento exponencial de dados, o processamento distribuído se tornou uma peça-chave em arquiteturas modernas. Ferramentas como *AWS Elastic MapReduce (EMR)* e *Azure HDInsight* facilitam a execução de grandes volumes de dados em *cluster*. Esse tipo de processamento é essencial para *Big Data* e *machine learning*, onde a execução paralela de tarefas reduz o tempo de análise.

Microsoft Azure HDInsight



Fonte: <https://learn.microsoft.com/pt-br/azure/hdinsight/spark/media/apache-spark-streaming-overview/hdinsight-spark-streaming.png>.



Computação *serverless*, com AWS Lambda e Azure Functions

A computação sem servidor, ou *serverless*, permite que os desenvolvedores criem funções executadas sob demanda, sem gerenciar a infraestrutura subjacente.

AWS Lambda e Azure Functions são serviços que oferecem essa funcionalidade, possibilitando que as aplicações cresçam automaticamente, de acordo com a carga de trabalho, e reduzam os custos operacionais.




Casos de uso: *data pipelines* e *machine learning*

A construção de *pipelines* de dados é um dos casos de uso mais comuns para armazenamento e processamento em nuvem. Ferramentas como AWS Glue e Azure Data Factory são essenciais para transformar e mover grandes volumes de dados entre diferentes fontes. Outro caso de uso relevante é a integração com *machine learning*, onde serviços, como AWS SageMaker e Azure ML, facilitam a análise preditiva.

ETL sem código na AWS



Fonte: https://encrypted-tbn2.gstatic.com/images?q=tbn:ANd9GcQvFrM742lt5_XRw_Xw52jWkRVraDQ7BPVX2JyeYtjuviw0OuI9.



Conclusão

O uso de armazenamento e processamento distribuído em nuvem permite que empresas lidem com dados em grande escala, de maneira eficiente e escalável.

Tanto AWS quanto Azure oferecem uma ampla gama de serviços que facilitam a análise, transformação e armazenamento de dados, preparando as organizações para desafios futuros.



Aplicações e serviços de nuvem

Teoria em prática

Bloco 4

Vinícius Climaco




Refleta sobre a seguinte situação

Situação do problema: ingestão de dados em tempo real.

Uma empresa de varejo global precisa processar dados de transações em tempo real, capturados de milhares de pontos de venda ao redor do mundo, para gerar insights operacionais e tomar decisões rápidas.

Os dados são enviados em diferentes formatos e volumes. A infraestrutura atual não é escalável e enfrenta problemas de latência ao lidar com o crescente volume de dados.






Norte para a resolução

Por onde começar?

- Identifique os principais requisitos da solução: suporte à ingestão em tempo real, baixa latência e escalabilidade horizontal.
- Considere o uso de serviços, como AWS Kinesis ou Azure Event Hubs, para ingestão em tempo real e análise contínua.






Norte para a resolução

Propostas de solução:

- Mapeie os gargalos atuais no fluxo de ingestão de dados, como falta de escalabilidade ou ineficiência na transformação dos dados recebidos.
- Avalie o custo e o desempenho das soluções atuais, identificando os pontos críticos que exigem melhorias.






Norte para a resolução

Propostas de solução:

- Utilizar uma arquitetura baseada em microsserviços, com serviços, como AWS Lambda ou Azure Functions, para lidar com a transformação dos dados.
- Empregar uma arquitetura de *streaming*, com Spark ou Flink, para processar dados em tempo real.





Norte para a resolução

Execução e revisão contínua:

- Implementar a solução em um ambiente de teste e monitorar o desempenho em tempo real, utilizando ferramentas como AWS CloudWatch ou Azure Monitor.
- Realizar ajustes contínuos, revisando a escalabilidade e a capacidade de resposta do sistema, conforme os volumes de dados aumentam.




Aplicações e serviços de nuvem

Consolidando o aprendizado

Bloco 5

Vinícius Climaco



Consolidando o aprendizado

- Discutimos sobre a ingestão de dados em tempo real, utilizando ferramentas de *cloud computing*, como AWS Kinesis e Azure Event Hubs, e a importância de arquiteturas escaláveis.
- Revisamos as soluções para microsserviços e *streaming* de dados e como podem ser aplicadas para gerar insights operacionais rápidos e eficientes.





Quiz



Qual das alternativas abaixo descreve a melhor abordagem para ingestão de dados em tempo real, em um ambiente altamente escalável?

A

Utilizar uma base de dados relacional centralizada para processar os dados em tempo real.

B

Implementar um *pipeline* de ingestão, com microsserviços baseados em AWS Lambda e AWS Kinesis, para processar grandes volumes de dados com baixa latência.

C

Utilizar um servidor de aplicação monolítico, com várias camadas para processamento de dados.

D

Armazenar todos os dados em planilhas Excel e processá-los manualmente ao final do dia.

Quiz



Qual das alternativas abaixo descreve a melhor abordagem para ingestão de dados em tempo real, em um ambiente altamente escalável?

A

Utilizar uma base de dados relacional centralizada para processar os dados em tempo real.

B


Implementar um *pipeline* de ingestão, com microsserviços baseados em AWS Lambda e AWS Kinesis, para processar grandes volumes de dados com baixa latência.

C

Utilizar um servidor de aplicação monolítico, com várias camadas para processamento de dados.

D

Armazenar todos os dados em planilhas Excel e processá-los manualmente ao final do dia.




Quiz – Resolução

Resposta correta: **b) Implementar um *pipeline* de ingestão, com microsserviços baseados em AWS Lambda e AWS Kinesis, para processar grandes volumes de dados com baixa latência.**

Essa alternativa é a mais adequada porque combina o uso de microsserviços, AWS Lambda e AWS Kinesis, que são ferramentas ideais para processar grandes volumes de dados em tempo real com baixa latência. Os microsserviços permitem que o sistema seja modular e escalável, dividindo as tarefas em componentes independentes, o que facilita a manutenção e escalonamento. AWS Lambda, por ser *serverless*, ajusta automaticamente a capacidade conforme a demanda, processando dados em tempo real sem a necessidade de gerenciar servidores, enquanto o Kinesis Streams possibilita a captura e o processamento contínuo de dados, garantindo baixa latência e alta capacidade de ingestão.






Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!






Indicação de leitura 1

Este livro aborda como gerenciar dados em ambientes de *cloud computing*, cobrindo desde arquiteturas distribuídas até escalabilidade e performance em sistemas de dados.

Referência:

ELMASRI, R.; NAVATHE, S. B. **Sistemas de gerenciamento de banco de dados**. 7. ed. São Paulo: Pearson, 2019.






Indicação de leitura 2

Esta leitura foca em como construir aplicações de dados intensivos, com ênfase em escalabilidade, arquitetura distribuída e processamento de grandes volumes de dados em tempo real.

Referência:

KLEPPMANN, M. **Designing data-intensive applications:** the big ideas behind reliable, scalable, and maintainable systems. 1. ed. Sebastopol: O'Reilly Media, 2017.





Referências

AMAZON. Visão geral. **Amazon**, 2024. Disponível em: <https://aws.amazon.com>. Acesso em: 9 out. 2024.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de gerenciamento de banco de dados**. 7. ed. São Paulo: Pearson, 2019.

GOOGLE. Produtos em destaque. **Google**, 2024. Disponível em: <https://cloud.google.com/?hl=pt-BR>. Acesso em: 9 out. 2024.

KLEPPMANN, M. **Designing data-intensive applications: the big ideas behind reliable, scalable, and maintainable systems**. 1. ed. Sebastopol: O'Reilly Media, 2017.

MICROSOFT. Azure gratuito. **Microsoft**, 2024. Disponível em: https://azure.microsoft.com/pt-br/free/search/?ef_id=__k_Cj0KCQjwmOm3BhC8ARIsAOSbapWUjFv6lNXCklu3VYddnmvBLXG9QNw2Oj_yvIPDxCgt8M0RF0lg_rQaAr7XEALw_wcB_k_&OCID=AIDcmmzmn0182_SEM__k_Cj0KCQjwmOm3BhC8ARIsAOSbapWUjFv6lNXCklu3VYddnmvBLXG9QNw2Oj_yvIPDxCgt8M0RF0lg_rQaAr7XEALw_wcB_k_&gad_source=1&gclid=Cj0KCQjwmOm3BhC8ARIsAOSbapWUjFv6lNXCklu3VYddnmvBLXG9QNw2Oj_yvIPDxCgt8M0RF0lg_rQaAr7XEALw_wcB. Acesso em: 9 out. 2024.





Bons estudos!