COLHEITA DE DADOS E INSIGHTS - DADOS VALIOSOS E MADUROS

O BIG DATA POR TRÁS DA IA

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Áreas que compõem a Ciência de Dados 7
Figura 2 - O que impulsiona a Ciência de Dados? 8
Figura 3 - Relação entre os conceitos de Inteligência Artificial, Machine Learning e Deep Learning 9
Figura 4 - Pilares da Ciência de Dados 11
Figura 5 - Perfis que compõem times da Ciência de Dados 12
Figura 6 - Exemplos de tipos de estruturas de dados 17
Figura 7 - Os 5 V's do Big Data 19
Figura 8 - Formas de modelagem de dados 20
Figura 9 - Formas de modelagem de dados em Machine Learning 22
Figura 10 - Formas de modelagem de dados em Machine Learning (detalhe) 24
Figura 11 - Ciclo de vida de soluções baseadas em Ciência de Dados 25
Figura 12 - Separação de dados em treino e teste 28
Figura 13 - Separação de dados em treino, validação e teste 29
Figura 14 - Fragmento de uma base de dados real 34
Figura 15 - Exemplo de mamografia com destaque para dois nódulos 35
Figura 16 - Exemplos lúdicos de overfitting 37
Figura 17 - Definição de modelo ideal 38
Figura 18 - Resultado do código-fonte 1 41
Figura 19 - Resultado do código-fonte 2 42
Figura 20 - Resultado do código-fonte 3 43
Figura 21 - Resultado do código-fonte 4 43
Figura 22 - Resultado do código-fonte 5 44
Figura 23 - Resultado dos códigos-fontes 6 e 7 45
Figura 24 - Resultado do código-fonte 8 47
Figura 25 - Resultado do código-fonte 9 48
Figura 26 - Resultado do código-fonte 10 49
Figura 27 - Resultado do código-fonte 12 50
Figura 28 - Resultado do código-fonte 13 51
Figura 29 - Exibição de novos arquivos criados no ambiente Google Colaboratory 52

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE QUADROS

Quadro 1 - Perguntas direcionadoras da análise exploratória de dados.....31
Quadro 2 - Estratégias típicas da limpeza de dados.....32
Quadro 3 - Desafios de trabalhar com dados.....36

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 - Leitura de um arquivo de dados com Pandas.....40
Código-fonte 2 - Exibição de 5 linhas aleatórias 41
Código-fonte 3 - Obtendo informações das variáveis do DataFrame Pandas.....42
Código-fonte 4 - Visualizando dados faltantes com a biblioteca missingno 43
Código-fonte 5 - Obtendo análises estatísticas básicas do Pandas.....44
Código-fonte 6 - Obtendo análises estatísticas básicas do Pandas.....44
Código-fonte 7 - Limpeza de dados com Pandas.....45
Código-fonte 8 - Tratando dados categóricos ordinais.....46
Código-fonte 9 - Tratando dados categóricos nominais 47
Código-fonte 10 - Como eliminar colunas via Pandas.....48
Código-fonte 11 - Trazendo dados para a mesma escala.....49
Código-fonte 12 - Criando um DataFrame com os dados Padronizados 50
Código-fonte 13 - Criando um DataFrame com os dados Normalizados 50
Código-fonte 14 - Exportando o resultado das transformações aplicadas 51

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 O BIG DATA POR TRÁS DA IA 6
1.1 Introdução 6
1.2 O que impulsiona a evolução da Ciência de Dados? 7
1.3 Inteligência Artificial e Machine Learning é tudo igual? 8
2 PILARES DA CIÊNCIA DE DADOS 11
2.1 Universo das pessoas 12
2.1.1 Conhecendo o Cientista de Dados 14
2.2 Universo dos dados 15
2.2.1 Classificação de dados de acordo com sua fonte 16
2.2.2 Classificação de dados de acordo com sua granularidade 16
2.2.3 Classificação de dados de acordo com sua estrutura 17
2.2.4 Classificação de dados de acordo com seu tipo 17
2.2.5 Organização dos dados 18
2.3 Universo das técnicas 19
2.3.1 Formas de modelagem 20
2.3.2 Formas de modelagem de Machine Learning 22
3 PIPELINE DE CIÊNCIA DE DADOS 25
4 TRABALHANDO COM DADOS 28
4.1 Como utilizar a base de dados em Machine Learning? 28
4.2 Técnicas de amostragem para conjuntos de treino/teste 30
4.3 Pré-processamento de dados 31
4.4 Engenharia de features (feature engineering) 32
5 DESAFIOS DA CONSTRUÇÃO DE MODELOS PREDITOS 34
5.1 Desafios gerais sobre a base 34
5.2 Overfitting 36
5.3 Underfitting 37
5.4 Definição de “modelo ideal” 38
6 HANDS ON: ANÁLISE DE DADOS PARA MACHINE LEARNING 40
6.1 Explorando e limpando dados com Pandas 40
6.2 Engenharia de features com Pandas e Scikit-Learn 46
CONCLUSÃO 53
REFERÊNCIAS 54
GLOSSÁRIO 55

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 O BIG DATA POR TRÁS DA IA

1.1 Introdução

Bem-vindo(a) à disciplina **Machine Learning & Modelling**! Serão abordados temas que complementarão sua formação como Cientista de Dados, como novos conceitos e ferramentas importantes sobre Inteligência Artificial (IA). Você perceberá que esta disciplina tem relações estreitas com **Redes Neurais Artificiais** (RNAs), pois as RNAs são uma família de algoritmos de Machine Learning (ML). No entanto, antes de nos aprofundarmos em qualquer modelo complexo ou mesmo técnicas clássicas de modelagem de dados, é importante compreender o que é a Ciência de Dados e quais aspectos influenciam esta área tão relevante e fascinante!

Estamos em uma era onde os dados permeiam quase todos os aspectos de nossas vidas, influenciando desde decisões triviais até as mais complexas. Por exemplo, ao escolher em qual restaurante jantar, você avalia várias questões, como: localização, preço, reputação do local, entre outros fatores; e para abrir aquele restaurante, o investidor deve considerar: localização, público-alvo, concorrentes e vários outros requisitos.

Na tomada de decisões empresariais os dados ajudam a definir estratégias, otimizar operações e prever tendências futuras. A quantidade de dados disponíveis e a velocidade com que são gerados têm transformado a maneira como entendemos e interagimos com o mundo ao nosso redor.

A **inteligência artificial** tem se tornado onipresente, com aplicações que abrangem: a área da saúde, onde algoritmos de Machine Learning ajudam a diagnosticar doenças; no comércio, em que sistemas de recomendação personalizam ofertas para consumidores; o setor industrial, no qual a IA otimiza processos de manufatura; e transportes, onde veículos autônomos já são realidade. Essas inovações, todas alimentadas por dados, ilustram o imenso potencial que o processamento e a análise de informações possuem para revolucionar diferentes setores.

Nesse contexto, surge a **Ciência de Dados**, uma área interdisciplinar que combina estatística, ciência da computação e conhecimento de domínio para extrair

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

valor a partir de grandes volumes de dados, como exemplificado na figura “Áreas que compõem a Ciência de Dados”.

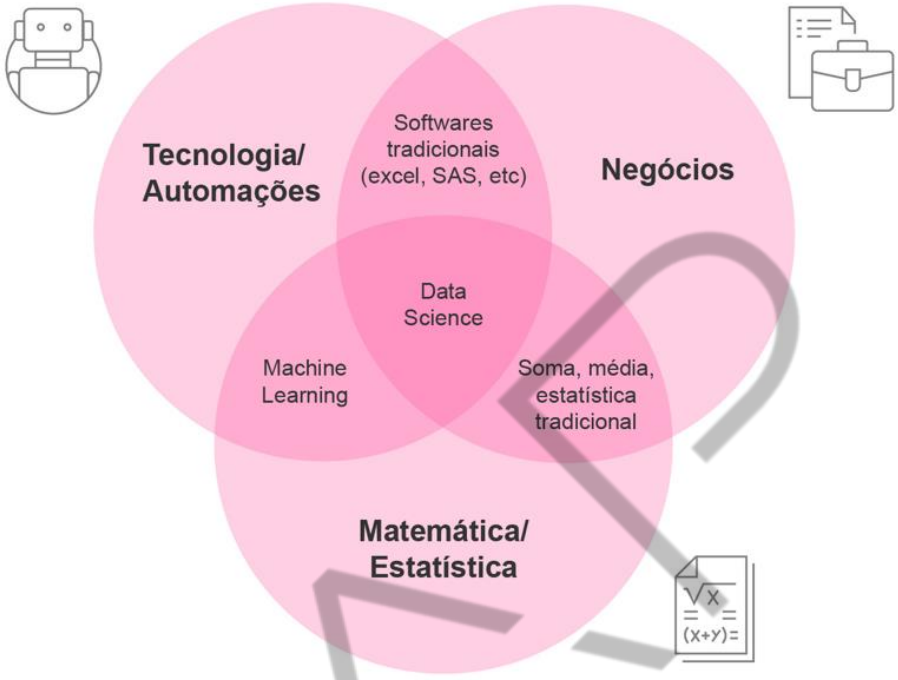

Figura 1 - Áreas que compõem a Ciência de Dados
Fonte: Hashtag treinamentos (2022)

A importância da Ciência de Dados no mercado de trabalho é crescente, pois ela capacita profissionais a transformar dados brutos em *insights* acionáveis, proporcionando uma vantagem competitiva para empresas e organizações. Além de ser uma disciplina técnica, a Ciência de Dados se tornou essencial para o sucesso e a inovação em um ambiente cada vez mais orientado por dados.

Neste contexto, o **conhecimento do negócio**, ou seja, de onde provêm os dados e onde as decisões devem ser implantadas, ajuda muito a construir análises relevantes e com alto poder de impacto.

1.2 O que impulsiona a evolução da Ciência de Dados?

A utilização intensiva de dados tem sido impulsionada por diversos fatores. Entre eles, três são essenciais para explicar o fenômeno da ampliação da Ciência de Dados e da IA em diversos setores do mercado, como ilustrado na figura “O que impulsiona a evolução da Ciência de Dados?”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 2 - O que impulsiona a Ciência de Dados?
Fonte: Elaborado pelo autor (2024)

O fenômeno do **Big Data**, caracterizado pela explosão no volume, na variedade e na velocidade dos dados, desafia as abordagens tradicionais de processamento e análise. Simultaneamente, o **avanço no poder computacional**, com a popularização de unidades de processamento gráficos (GPUs, do inglês Graphic Processing Unit) e *cloud computing*, possibilitou a execução de modelos complexos de maneira eficiente. Além disso, o desenvolvimento de **técnicas mais avançadas**, como **Deep Learning** (DL), ampliou ainda mais o leque de possibilidades para a aplicação de dados em soluções inovadoras.

Em conjunto, esses impulsionadores têm solidificado a posição dos dados como um dos ativos empresariais mais relevantes do século XXI. No entanto, ao contrário de outros ativos corporativos (como um carro ou um computador), que se desvalorizam com o uso, os dados são desvalorizados quando não os usamos. Logo, vamos conhecer as técnicas para analisar e extrair conhecimento das diversas bases de dados!

1.3 Inteligência Artificial e Machine Learning é tudo igual?

Embora muitas vezes utilizados de forma intercambiável, os termos “IA” e “ML” representam conceitos distintos dentro do campo da computação.

A inteligência artificial é um campo amplo que abrange a criação de sistemas capazes de realizar tarefas que, se realizadas por humanos, exigiriam inteligência.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Isso inclui desde jogos de xadrez até assistentes virtuais e carros autônomos. A IA é uma área abrangente que engloba diversas subdisciplinas, das quais o Machine Learning é uma das mais proeminentes. Sua relação é dada conforme a figura “Relação entre os conceitos de Inteligência Artificial, Machine Learning e Deep Learning”.

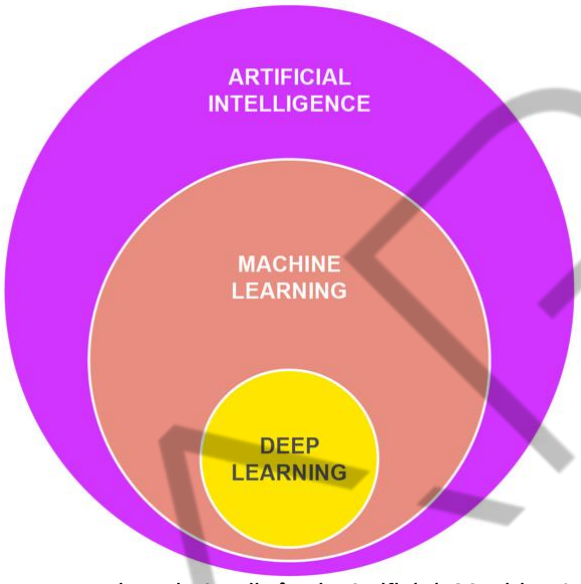

Figura 3 - Relação entre os conceitos de Inteligência Artificial, Machine Learning e Deep Learning
Fonte: Advancing analytics (2021)

Os **sistemas especialistas** são uma das formas mais antigas de IA. Esses sistemas utilizam regras pré-definidas, criadas por especialistas humanos, para tomar decisões ou resolver problemas em domínios específicos. Um exemplo clássico é um sistema de diagnóstico médico que aplica uma série de regras lógicas para identificar uma doença com base nos sintomas apresentados pelo paciente. Embora eficazes em domínios bem definidos, os sistemas especialistas são limitados por causa da rigidez de suas regras e pela dificuldade de escalabilidade para problemas mais complexos.

O Machine Learning, por outro lado, é uma abordagem dentro da IA que permite o sistema aprender com dados em vez de depender de regras fixas. Dessa forma, os desenvolvedores não precisam programar explicitamente como resolver um problema, mas sim criar algoritmos que permitam ao sistema reconhecer padrões e tomar decisões com base em grandes volumes de dados. A capacidade de aprendizado e adaptação é o que diferencia o ML dos sistemas especialistas. Por exemplo, se quisermos construir um modelo preditivo de doenças e outro de fraudes bancárias,

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

dependemos de dois especialistas, gerando regras típicas de cada setor. Entretanto, com o Machine Learning, podemos aplicar o mesmo algoritmo para predizer ambos os cenários, pois a diferenciação está nos exemplos usados para treinamento (ou seja, nos dados).

Dentro do Machine Learning, o **Deep Learning** é um subconjunto que utiliza RNAs profundas, compostas por múltiplas camadas, para modelar dados complexos. Essa abordagem tem sido responsável por avanços significativos em áreas como visão computacional, processamento de linguagem natural e reconhecimento de fala. Enquanto a criação de modelos preditivos com ML possa exigir maior intervenção humana, o DL é capaz de descobrir automaticamente relações sofisticadas e complexas entre os dados, o que o torna especialmente poderoso em tarefas que envolvem grandes volumes de dados complexos como imagens e textos.

Não há uma única solução para todos os problemas: cada uma dessas abordagens tem suas próprias forças e fraquezas, e a escolha da técnica depende do tipo de problema que se deseja resolver e do cenário de dados disponíveis no momento da construção das análises.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 PILARES DA CIÊNCIA DE DADOS

A Ciência de Dados se apoia em quatro pilares fundamentais e suas relações: **dados**, **técnicas**, **pessoas** e **processos de negócio** (como ilustrado na figura "Pilares da Ciência de Dados"). Caso um destes quatro pilares faltar, qualquer iniciativa de Ciência de Dados fracassará.

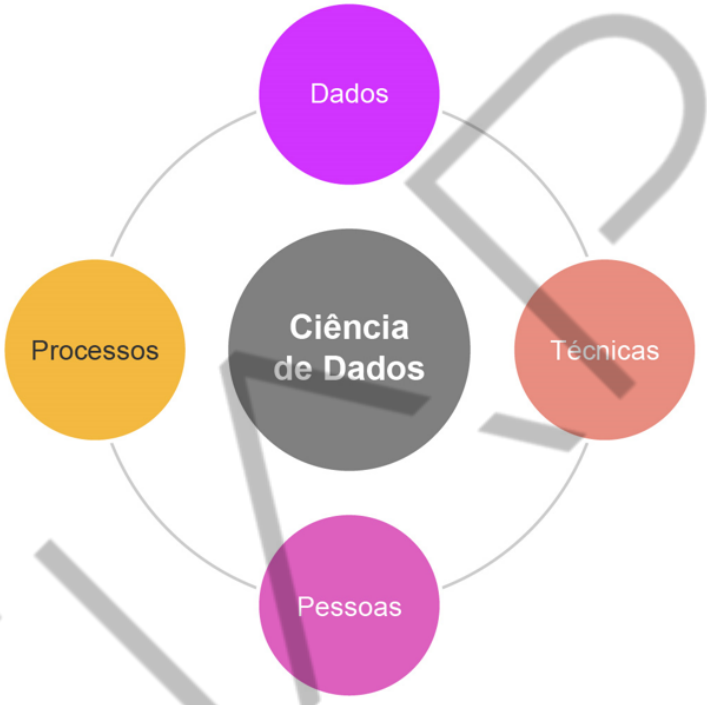

Figura 4 - Pilares da Ciência de Dados
Fonte: Elaborado pelo autor (2024)

Os **dados** são a matéria-prima da Ciência de Dados. Isto é, sem eles, não há o que analisar ou modelar. É importante lembrar que os dados podem vir de diversas fontes, como transações comerciais, sensores ou interações em redes sociais, e sua qualidade e relevância são cruciais para o sucesso de qualquer projeto de Data Science. As **técnicas**, por sua vez, referem-se aos métodos e algoritmos utilizados para extrair *insights* dos dados, incluindo Estatística, Machine Learning e Visualização de Dados. Essas técnicas são consideradas o coração da análise de dados, pois permitem transformar informações brutas em conhecimento valioso.

No entanto, os dados e as técnicas sozinhos não bastam, é igualmente necessário a participação de **pessoas** e **processos de negócio**. As **pessoas**, que incluem cientistas de dados, analistas e *stakeholders*, são responsáveis por interpretar

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

os resultados das análises e tomar decisões informadas com base nesses *insights*. A combinação de habilidades técnicas e de conhecimento de domínio é fundamental para garantir que as análises sejam relevantes e acionáveis. Em relação aos **processos de negócio**, eles conectam a Ciência de Dados às necessidades reais da organização. Além disso, garantem que as soluções desenvolvidas estejam alinhadas com os objetivos estratégicos e operacionais, maximizando o impacto dos projetos de Data Science no desempenho empresarial.

A seguir descreveremos os principais aspectos de cada pilar. Vamos deixar os "processos de negócio" de lado, pois eles são próprios de cada setor e/ou empresa. No momento iremos nos concentrar nos aspectos técnicos e de formação de pessoas.

2.1 Universo das pessoas

O pilar de **pessoas** é composto por uma variedade de perfis profissionais que, juntos, garantem o sucesso dos projetos de Data Science. Esses perfis incluem desde os gestores de dados até os cientistas de dados, passando por analistas de dados, engenheiros de dados e especialistas em negócios. Cada um desempenha uma função crucial na coleta, processamento, análise e interpretação dos dados, garantindo que o conhecimento adquirido seja relevante e aplicável ao contexto de negócio. Podemos ver um panorama geral na figura a seguir.

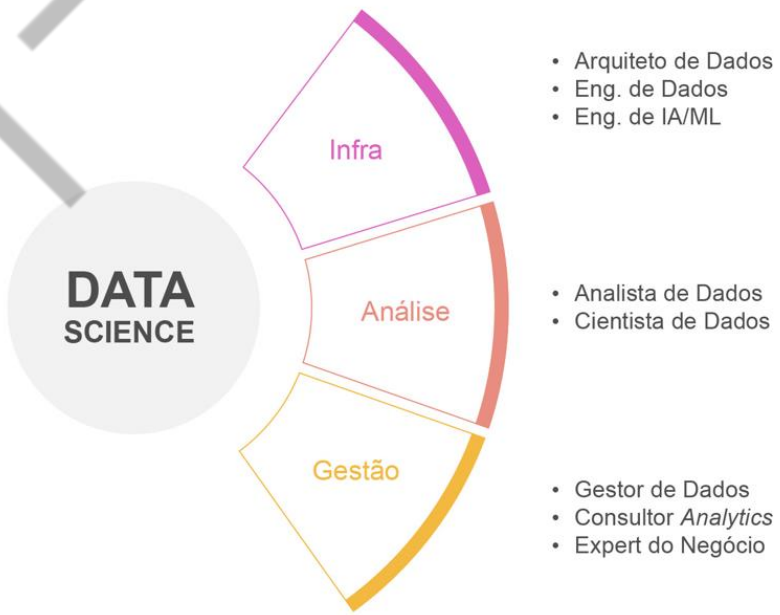

Figura 5 - Perfis que compõem times da Ciência de Dados
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Como mostra a figura “Perfis que compõem os times da Ciência de Dados”, podemos classificar os perfis de dados em três frentes:

- **Infraestrutura de dados:** nesta frente, temos as pessoas que constroem e gerenciam a infraestrutura de armazenamento e processamento de dados. Os principais são:
  - **Arquiteto de dados:** projeta a infraestrutura, geralmente em plataformas cloud ou ambientes locais nas empresas. Além de projetar a infraestrutura, ele garante a consistência dos dados e aspectos de segurança da informação.
  - **Engenheiro de dados:** atua na ingestão de bases de dados da origem até o ambiente analítico projetado pelo arquiteto. Além disso, é responsável por investigar os bancos de dados, projetar rotinas de vinculação e realizar o tratamento e a limpeza massiva de dados, gerando um conjunto de dados mais adequado para análise.
  - **Engenheiro de IA/ML:** é responsável por desenvolver, implementar e otimizar os modelos de IA e ML, criando a infraestrutura necessária para que esses modelos possam ser utilizados em escala. Ele garante que os modelos implementados funcionem eficientemente na produção.
- **Análise de dados:** nesta etapa, agregamos as pessoas que realizam a interpretação e a inteligência sobre os dados, que pode ser feita por:
  - **Analista de dados:** utiliza os dados para entender o passado e descrever o presente (fazem análises mais simples).
  - **Cientista de dados:** usa os dados para descobrir padrões e realizar análises preditivas que norteiam decisões sobre o futuro (fazem análises mais complexas e sofisticadas).
- **Gestão de projetos/processos:** na gestão, lidamos com processos de trabalho das equipes de dados. Geralmente são envolvidos:
  - **Expert do negócio:** profissional que atua na sua área específica como os enfermeiros na Saúde e os agrônomos no Agronegócio. É um profissional que conhece os dados, sabe como interpretá-los e toma

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

decisões sobre o negócio. Além disso, determina as demandas ou processos que podem ser aprimorados utilizando a Ciência de Dados.

- **Consultor *analytics*:** profissional com experiência híbrida que atua como um tradutor fazendo a ponte entre time técnico e experts de negócio. Também pode ser o guardião de processos de ideação para priorização de demandas, ou de desenvolvimento ágil.
- **Gestor de dados:** profissional responsável por zelar pela boa condução dos projetos de dados do ponto de vista de gestão de expectativas de cliente, esforços do time, cumprimento de cronograma e aspectos financeiros. Também é responsável por cuidar do time do ponto de vista de carreira.

Com tantos perfis é comum ter dúvidas sobre como montar uma boa equipe de dados. Não necessariamente um time de dados precisa ter todos os perfis listados. Precisamos apenas garantir a multidisciplinaridade dos times, trazendo tanto perfis técnicos quanto de negócios.

Além dos perfis listados existem outros e provavelmente novos surgirão devido ao dinamismo da área. Alguns perfis também “mudam de nome” com o tempo. Por exemplo, o atual “analista de dados” já foi chamado de “analista de Business Intelligence (BI)”.

2.1.1 Conhecendo o Cientista de Dados

Esta disciplina fornece as bases de conhecimento do Cientista de Dados, por isso é importante compreendermos com mais detalhes sua formação e habilidades. O Cientista de Dados, também conhecido como *Data Scientist*, é o perfil mais multidisciplinar e, frequentemente, o mais valorizado dentro da equipe de Ciência de Dados.

Esse profissional combina habilidades em Programação, Estatística, Machine Learning e conhecimento de domínio para extrair *insights* significativos a partir de dados complexos. Um Cientista de Dados deve ser proficiente em linguagens de programação como Python e R, familiarizado com técnicas de Machine Learning e Deep Learning, e capaz de trabalhar com grandes volumes de dados utilizando

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

ferramentas como SQL, Hadoop ou Spark. Além das habilidades técnicas, um Cientista de Dados de destaque possui uma forte capacidade analítica e de resolução de problemas, assim como excelentes habilidades de comunicação para traduzir descobertas técnicas em recomendações acionáveis para os *stakeholders* de negócios.

O que torna um bom Cientista de Dados valorizado pelo mercado é a combinação de competências técnicas avançadas com uma compreensão profunda dos problemas de negócios que ele está tentando resolver. Este profissional deve ser capaz de identificar as perguntas certas, formular hipóteses, experimentar com diferentes abordagens e comunicar os resultados de forma clara e persuasiva.

Além disso, a capacidade de trabalhar de forma colaborativa em equipes multidisciplinares e de aprender continuamente em um campo em constante evolução também são características essenciais para um Cientista de Dados ser bem-sucedido e altamente valorizado pelo mercado.

2.2 Universo dos dados

Os dados são o combustível essencial para a Ciência de Dados e para as formas mais modernas de IA. Neste capítulo, exploraremos as características dos dados e suas formas de armazenamento.

Mas, afinal, o que é um **dado**? Enquanto muitas pessoas associam “dado” à “informação”, é mais preciso defini-lo como “**um valor coletado e armazenado**”. Um dado, quando relacionado a uma variável, tem o potencial de revelar uma informação.

Por exemplo, ao coletarmos as idades dos alunos, valores como 17, 18 ou 19 só ganham significado quando sabemos que estão associados à variável “idade”. Sem esse contexto, um número como “23” é apenas um valor isolado. Portanto, quanto mais variáveis tivermos sobre um contexto, maior será a quantidade de informações disponíveis para a tomada de decisões. A seguir, exploraremos as diferentes dimensões dos dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.2.1 Classificação de dados de acordo com sua fonte

De onde os dados provêm? Podemos reconhecer três tipos de fontes de dados:

- **Dados primários:** referem-se aos dados em que temos controle direto sobre a origem. São geralmente exemplos de dados internos e confidenciais de uma empresa, como receita, número de itens produzidos e lucro por produto. A fonte dessas informações é própria e, em geral, não é compartilhada em sua forma bruta.
- **Dados secundários:** são dados primários de outra organização que foram disponibilizados para nossa análise. Por exemplo, a empresa A define o preço de venda de seu produto com base em diversos fatores, incluindo os componentes adquiridos das empresas B e C. As empresas B e C possuem seus próprios dados primários sobre "valor de venda", mas esses dados são conhecidos pela empresa A para calcular o valor final de seu produto.
- **Dados terciários:** são informações de uma empresa ou organização que já estão disponíveis publicamente, acessíveis a qualquer pessoa. O foco aqui não está em quem gerou o dado, mas no próprio dado em si.

2.2.2 Classificação de dados de acordo com sua granularidade

Em qual nível os dados foram cedidos?

- **Dados agregados:** referem-se a dados originais que foram previamente consolidados ou agrupados com base em algum critério específico. Por exemplo, qual é a idade média dos estudantes matriculados na disciplina de "Machine Learning & Modelling"? Ou qual foi a média final desses alunos na disciplina? Em geral, os dados agregados não permitem a identificação individual, pois já passaram por um tratamento antes de serem disponibilizados.
- **Dados desagregados:** são dados em sua forma mais bruta, exatamente como foram coletados. Por exemplo, informações detalhadas de cada estudante que cursou "Machine Learning & Modelling", onde é possível identificar quem são, suas idades e suas notas finais.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.2.3 Classificação de dados de acordo com sua estrutura

De qual forma os dados são apresentados?

- **Dados estruturados:** neste formato, os dados são organizados em tabelas com linhas e colunas, onde cada coluna representa uma variável e cada linha uma entrada. Por exemplo, em um cadastro de clientes, as variáveis podem incluir nome, sobrenome, e-mail e celular, com cada cliente representando uma linha na tabela.
- **Dados semiestruturados:** possuem uma estrutura parcial, não tão rígida como uma tabela, mas seguem um formato específico, geralmente usando tags ou pares de chave-valor. Alguns exemplos comuns incluem páginas HTML e arquivos JSON.
- **Dados não estruturados:** são informações que não seguem um formato predefinido, como as tabelas ou esquemas de chave-valor, o que os torna mais difíceis de interpretar e analisar seu conteúdo utilizando métodos tradicionais. Exemplos incluem imagens, vídeos, textos, áudios e postagens em redes sociais.

Observe a figura a seguir para conhecer os três tipos de estrutura de dados.

Figura 6 - Exemplos de tipos de estruturas de dados
Fonte: Elaborado pelo autor (2024)

2.2.4 Classificação de dados de acordo com seu tipo

Que tipo de informação os dados trazem?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Dados numéricos:** este tipo de variável carrega uma informação **quantitativa**, ou seja, que expressa uma quantidade. Podemos ter **valores discretos** (números inteiros. Exemplos: quantidade de filhos, número de banheiros em uma residência) ou **valores contínuos** (números reais. Exemplos: salário, altura).
- **Dados categóricos:** este tipo de variável carrega uma informação **qualitativa**, ou seja, que expressa uma característica. Podemos ter **valores nominais** (quando não há uma relação de ordem entre as possibilidades de resposta. Exemplos: sexo biológico, profissão) ou **valores ordinais** (quando há uma relação de ordem entre as possibilidades de resposta. Exemplos: posição em um ranking, nível de escolaridade).

Observação: nesta disciplina trabalharemos com **dados estruturados** (que podem ser **numéricos** ou **categóricos**) caracterizados como **dados terciários e desagregados**.

2.2.5 Organização dos dados

Os dados são organizados e armazenados em bancos de dados, que são coleções estruturadas de informações inter-relacionadas, geralmente mantidas digitalmente em um Sistema de Gerenciamento de Banco de Dados (SGBD). Essas informações são dispostas em tabelas, onde cada uma representa uma entidade específica e as interconexões entre elas. Os bancos de dados permitem o armazenamento, recuperação, gerenciamento e manipulação de dados de maneira eficiente, servindo como uma base robusta para aplicativos e sistemas que necessitam de acesso rápido e confiável às informações. Eles são amplamente empregados em diversas áreas, como negócios, ciência, governo e tecnologia.

Além disso, existem bancos de dados especialmente projetados para o armazenamento e a busca de dados não estruturados. A discussão sobre bancos de dados para dados estruturados ou não estruturados está além do escopo desta disciplina. O foco aqui é que a “evolução” dos bancos de dados culminou no conceito de “Big Data”. O Big Data se refere a um enorme conjunto de dados caracterizado por cinco aspectos essenciais, como ilustrado na figura “Os 5 V’s do Big Data”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

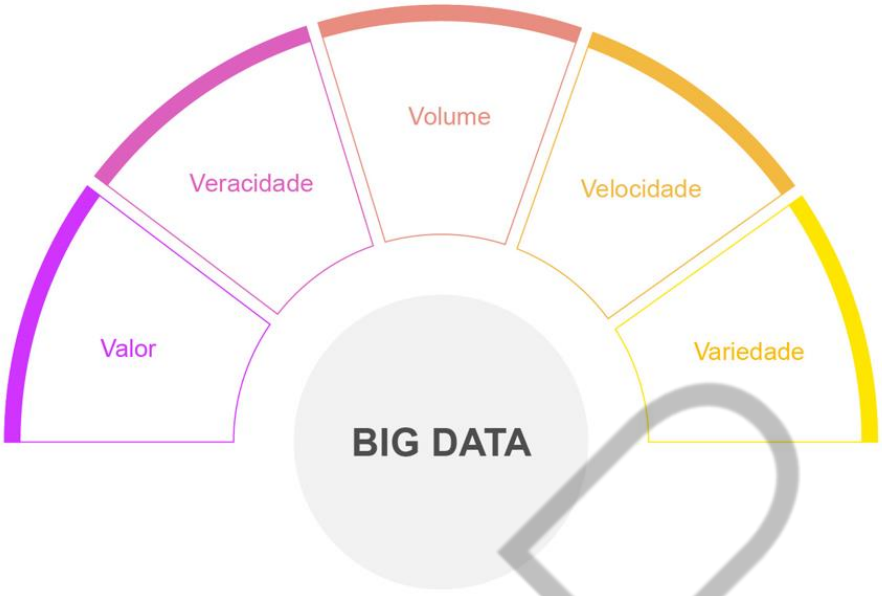

Figura 7 - Os 5 V's do Big Data
Fonte: Elaborado pelo autor (2024)

Esses repositórios de Big Data se distinguem por causa do seu vasto **volume** de informações, sua **variedade** — abrangendo dados estruturados, semiestruturados e não estruturados — e pela **velocidade** com que são gerados e armazenados. Além disso, esses dados têm grande **valor** para a obtenção de *insights* e devem ser preservados sob o princípio da **veracidade**, buscando sempre armazenar dados com a maior precisão possível, apesar dos inevitáveis desafios de qualidade.

No domínio da Ciência de Dados, o Big Data tornou-se a principal fonte para análises, representando um vasto e abrangente conjunto de informações. Este conceito assume uma importância ainda maior no contexto de Deep Learning, onde a quantidade de dados necessária para treinar modelos de IA baseados nos preceitos de ML é significativamente maior.

2.3 Universo das técnicas

Este será o pilar da Ciência de Dados que veremos com mais detalhes, pois aqui residem as estratégias para trabalhar com dados, bem como os algoritmos para aprender a partir de dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Primeiramente, iremos aprender quais são as formas de modelagem típicas. Em seguida, nos concentraremos nas estratégias comuns de Machine Learning. Vamos nessa?

2.3.1 Formas de modelagem

A modelagem em Ciência de Dados pode ser categorizada em quatro formas principais: **descritiva**, **diagnóstica**, **preditiva** e **prescritiva**. Cada uma dessas abordagens possui objetivos específicos e oferece diferentes *insights*, variando em complexidade e exigindo diferentes níveis de maturidade analítica por parte das organizações. O resumo está na figura “Formas de modelagem de dados”.

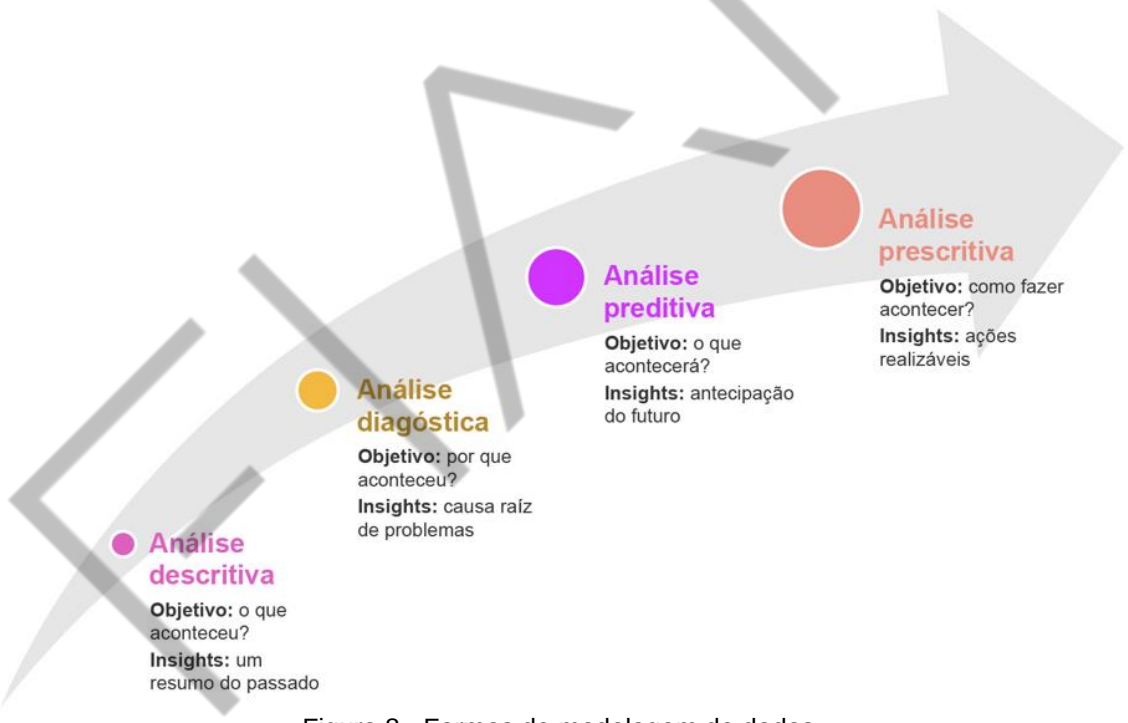

Figura 8 - Formas de modelagem de dados
Fonte: Elaborado pelo autor (2024)

- **Modelagem Descritiva:** é a forma mais básica de análise, focando em resumir e interpretar os dados históricos para entender o que aconteceu no passado. Essa abordagem utiliza métodos estatísticos simples, como médias, distribuições e correlações para transformar dados brutos em informações significativas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Um exemplo típico de modelagem descritiva é a criação de relatórios de vendas mensais ou anuais, que mostram tendências e padrões de desempenho. Embora seja a menos complexa, a modelagem descritiva é essencial para qualquer empresa, pois estabelece as bases para análises mais sofisticadas. Empresas em estágios iniciais de maturidade analítica geralmente começam por aqui.

- **Modelagem Diagnóstica:** vai além da descrição e busca identificar as causas por trás dos eventos passados. Ao invés de apenas mostrar o que aconteceu, a modelagem diagnóstica tenta responder por que aquilo aconteceu. Isso é feito através da análise de variáveis causais e de relações de correlação ou causalidade entre diferentes fatores.
  - Por exemplo, uma empresa pode utilizar a modelagem diagnóstica para entender por que as vendas caíram em um determinado período, analisando fatores como mudanças no comportamento do consumidor, ações de concorrentes ou alterações no mercado. Este tipo de modelagem é mais complexo do que a descritiva e exige um nível intermediário de maturidade analítica, pois requer uma compreensão mais profunda dos dados e das interações entre as variáveis.
- **Modelagem Preditiva**: utiliza técnicas avançadas de Estatística, Machine Learning e Data Mining para prever o que provavelmente acontecerá no futuro com base em padrões identificados nos dados históricos.
  - Exemplos de modelagem preditiva incluem a previsão de demanda de produtos, o risco de inadimplência de um cliente ou o *churn* em serviços de assinatura. Este tipo de modelagem é mais complexo, pois envolve a construção de modelos matemáticos que extrapolam tendências passadas para o futuro. Para trabalhar efetivamente com modelagem preditiva, as empresas precisam ter muita maturidade analítica, incluindo infraestrutura tecnológica robusta e equipes capacitadas para lidar com algoritmos complexos e grandes volumes de dados.
- **Modelagem Prescritiva:** é a forma mais avançada de modelagem analítica, que não apenas prevê futuros resultados, mas também recomenda ações específicas para otimizar esses resultados. Ela combina a modelagem

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

preditiva com técnicas de otimização e de simulação para sugerir os melhores cursos de ação em cenários complexos. Por exemplo, uma empresa pode utilizar a modelagem prescritiva para definir a melhor estratégia de preços em um mercado competitivo, levando em consideração fatores como custos, demanda, comportamento do consumidor e ações da concorrência. Este tipo de modelagem é altamente complexo e requer o nível mais alto de maturidade analítica, pois envolve a integração de diversas fontes de dados, algoritmos sofisticados e a capacidade de simular múltiplos cenários.

Em resumo, à medida que as organizações progridem em sua jornada analítica, elas transitam de modelagens mais simples, como a descritiva, para abordagens mais complexas e sofisticadas, como a prescritiva, que oferecem um valor estratégico mais significativo.

2.3.2 Formas de modelagem de Machine Learning

Nesta disciplina nosso foco está na análise preditiva. No contexto de Machine Learning, existem três formas de modelagem de dados.

Observe a figura:

Figura 9 - Formas de modelagem de dados em Machine Learning
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Aprendizado supervisionado (*supervised learning*):** nesse método, o modelo é treinado em um conjunto de dados rotulado (seus *labels*), onde cada exemplo de entrada está associado a uma saída conhecida.
  - **Objetivo:** o modelo aprende a mapear relações entre entradas e saídas, permitindo prever saídas para novas entradas não vistas durante o treinamento.
  - **Exemplos de aplicações:** classificação (identificar a categoria de uma entrada) e regressão (prever um valor contínuo).
- **Aprendizado não supervisionado (*unsupervised learning*):** neste caso, o modelo é treinado em um conjunto de dados não rotulado, onde o algoritmo busca identificar padrões, estruturas ou relações intrínsecas nos dados.
  - **Objetivo:** o modelo aprende a estrutura subjacente dos dados sem a orientação explícita de rótulos, explorando características e agrupamentos naturais.
  - **Exemplos de aplicações:** agrupamento (organizar dados em grupos) e redução de dimensionalidade.
- **Aprendizado por reforço (*reinforcement learning*):** neste paradigma, o modelo, chamado agente, interage com um ambiente dinâmico e recebe feedback na forma de recompensas ou penalidades com base nas ações realizadas.
  - **Objetivo:** o agente aprende a realizar ações que maximizam a recompensa ao longo do tempo, ajustando seu comportamento com base nas interações com o ambiente.
  - **Exemplos de aplicações:** em jogos (como xadrez ou Go), robótica autônoma ou sistemas de controle.

Concluindo, a figura “Formas de modelagem de dados em Machine Learning (detalhe)” apresenta as formas de modelagem típicas de Machine Learning, com a intuição da aplicabilidade de seus subtipos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 10 - Formas de modelagem de dados em Machine Learning (detalhe)
Fonte: Elaborado pelo autor (2024)

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 PIPELINE DE CIÊNCIA DE DADOS

Agora aprenderemos como os pilares da Ciência de Dados atuam em conjunto. A pergunta central é: como as soluções baseadas em Ciência de Dados são desenvolvidas? Para responder esta questão, vamos nos basear no ciclo de vida das soluções de Ciência de Dados conforme a seguinte figura.

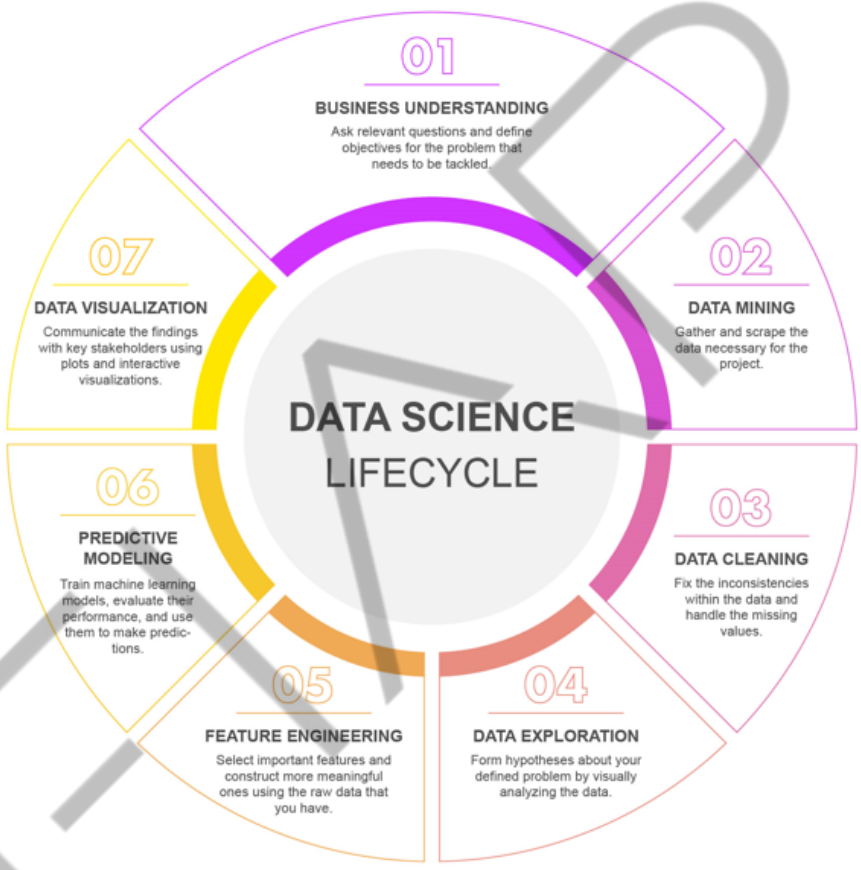

Figura 11 - Ciclo de vida de soluções baseadas em Ciência de Dados
Fonte: Medium (2020)

As etapas do ciclo são:

1. ***Business understanding*** **(entendimento do negócio):** nesta etapa inicial, é crucial definir o objetivo da análise de dados e determinar o tipo de resultado que buscamos alcançar: será um relatório, um painel interativo ou um modelo preditivo?
2. ***Data mining*** **(obtenção dos dados):** com o objetivo definido, é hora de reunir os dados que sustentarão nossa análise. Esta fase envolve a seleção dos dados que formarão a base a ser utilizada no processo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3. ***Data cleaning* (limpeza dos dados):** é comum que os dados apresentem problemas, como informações ausentes ou valores imprecisos. Nesta etapa, realizamos a limpeza dos dados, eliminando valores inconsistentes ou divergentes do esperado.
4. ***Data exploration* (exploração dos dados):** a exploração dos dados é uma fase crucial para aprofundar nossa compreensão do tema em análise. Nesta etapa, identificamos padrões básicos, correlacionamos variáveis e analisamos valores médios e medianos. Utilizando estatísticas básicas e criando gráficos, conseguimos ampliar nosso entendimento sobre o assunto em questão.
5. ***Feature engineering* (engenharia de features):** esta fase está mais associada à construção de modelos preditivos, onde padronizamos variáveis, removemos aquelas que são desnecessárias ou pouco informativas e, em seguida, criamos novas variáveis a partir das existentes. O objetivo é refinar o conjunto de variáveis para que a máquina possa aprender a fazer previsões de maneira mais eficaz.
6. ***Predictive modeling* (modelagem preditiva):** embora nem toda análise de dados exija a criação de modelos preditivos, quando o entendimento do negócio demanda esse tipo de resultado, é nesta fase que treinamos e avaliamos o modelo. Nas soluções de Machine Learning, a modelagem preditiva é o foco principal. Será discutido com mais detalhes sobre esta etapa posteriormente.
7. ***Data visualization* (visualização de dados/comunicação):** seja após a construção de um modelo preditivo ou de um relatório baseado em dados, a etapa final do processo é apresentar a solução a quem a solicitou. Nesta fase, verificamos se os requisitos foram atendidos, identificamos possíveis melhorias ou simplesmente validamos a entrega como concluída, garantindo que ela já possui o potencial de gerar um impacto positivo no negócio.

É importante ressaltar que o ciclo de vida das soluções em Ciência de Dados é iterativo. Podemos avançar para a próxima etapa ou retornar à anterior, conforme necessário. Por exemplo, após a limpeza dos dados, podemos perceber que as

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

informações disponíveis não são suficientemente confiáveis para construir um modelo preditivo, exigindo um retorno à fase de coleta de dados. Além disso, é comum que as soluções passem por vários ciclos dessas etapas até atingirem a maturidade necessária para serem utilizadas.

Essa iteração durante o desenvolvimento é extremamente positiva, pois aproxima os solicitantes das soluções (geralmente especialistas em negócios, mas com pouco conhecimento técnico) da equipe de Ciência de Dados (geralmente com profundo conhecimento técnico, mas pouca familiaridade com o domínio de origem dos dados).

As próximas seções deste capítulo apresentarão os **aspectos técnicos** de cada etapa. Iremos assumir que o entendimento de negócio já foi feito e que os dados já foram coletados, portanto, vamos nos atentar às etapas de **limpeza de dados**, **exploração de dados** e **engenharia de features**. Primeiramente, compreenderemos as motivações e os passos de cada etapa. A parte prática deste capítulo será a implementação em Python de cada passo listado.

Nesta disciplina, nosso projeto de modelagem será sempre modelos preditivos, portanto, focaremos nesta forma de modelagem.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4 TRABALHANDO COM DADOS

Machine Learning é essencialmente aprender com os dados. Utilizamos dados previamente coletados para treinar um modelo capaz de aprender regras, padrões e variações dos dados mais ligados ao fenômeno modelado. Por exemplo, podemos analisar várias transações no cartão de crédito, algumas fraudulentas e outras não, para tentar encontrar alguma “pista” nos dados que indique quando uma compra é uma fraude. O objetivo do modelo preditivo é, portanto, aprender a generalizar um conceito a partir de exemplos, tentando acertar predições em novos exemplos que nunca viu anteriormente.

4.1 Como utilizar a base de dados em Machine Learning?

Será que basta ter os dados em mãos para trabalharmos com Machine Learning? Não! Inicialmente, precisamos aprender **como** utilizar as bases de dados, especialmente para criarmos modelos preditivos.

Precisamos separar nossos dados em dois conjuntos disjuntos: o **treinamento** e o **teste**. Eles são separados porque os exemplos que estão no treinamento não podem estar no teste e vice-versa — isso comprometeria a avaliação da efetividade da modelagem preditiva.

Normalmente essa separação é feita de forma aleatória, separando 80% dos dados para treinar e 20% para teste, mas outras combinações podem ser aplicadas (como 70% e 30%). Observe a figura “Separação de dados em treino e teste”.

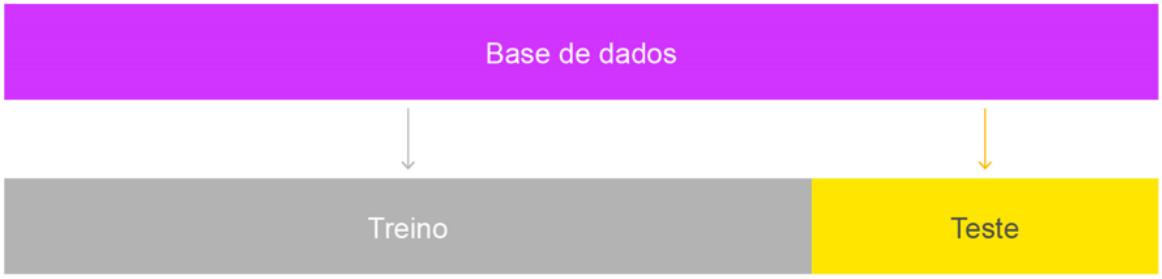

Figura 12 - Separação de dados em treino e teste
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Os dados do subconjunto de **treino** são utilizados para o algoritmo de Machine Learning ou Deep Learning investigar padrões, identificar correlações e aprender a mapear relações nos dados de acordo com a tarefa que está sendo aprendida. Por exemplo, a máquina pode analisar diversas imagens de lesões de pele para aprender a reconhecer quais são as lesões malignas e quais são as lesões comuns. Os dados de treino são acessados quantas vezes e de qual forma a máquina precisar durante o treinamento do algoritmo.

Em relação aos dados de **teste**, eles são utilizados para avaliar o poder preditivo do algoritmo de ML ou DL naquela tarefa em questão. Por exemplo, após treinar a máquina a reconhecer melanomas (um tipo de câncer de pele) em lesões de pele, queremos investigar qual a capacidade preditiva real deste modelo, fazendo-o gerar predições para dados que nunca foram vistos anteriormente (o subconjunto de teste). Percebeu por que devemos separar completamente os subconjuntos de treino/teste?

Você pode estar se perguntando: “mas como a máquina sabe, em tempo de treinamento, que ela está aprendendo algo de verdade?”. Boa pergunta! Além da divisão entre treino e teste, é comum subdividir o conjunto de treino em duas partes: o **treino** propriamente dito e a **validação**, como ilustrado na figura a seguir.

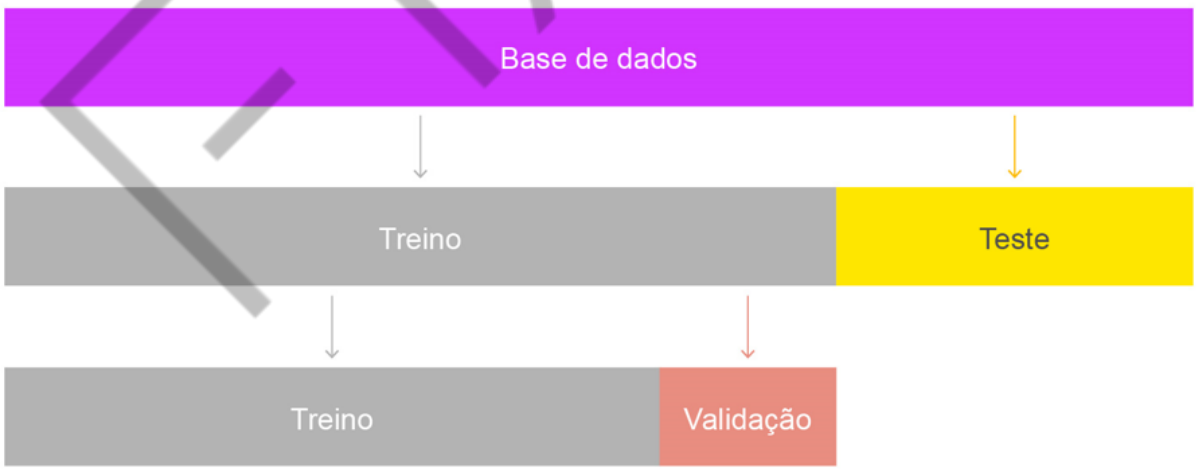

Figura 13 - Separação de dados em treino, validação e teste
Fonte: Elaborado pelo autor (2024)

A proporção mais utilizada é 60% da base de dados para treino, 20% para validação e 20% para teste. O conceito de separação disjunta continua válido nesta

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

nova subdivisão: o exemplo que está em um dos conjuntos NÃO pode estar presente nos demais.

A importância do subconjunto de validação é para a máquina ter uma amostra separada de dados para “brincar” de fazer testes em tempo de treinamento, o intuito é identificar se os padrões aprendidos realmente estão resolvendo a tarefa ou se não está ocorrendo de fato um aprendizado real. Na prática, o treinamento encerra quando não há mais como melhorar os acertos de predição no subconjunto de validação. Na prática, ainda, o próprio algoritmo de ML ou DL subdivide o treino em treino e validação, ou seja, é nossa responsabilidade lembrar de separar treino e teste.

4.2 Técnicas de amostragem para conjuntos de treino/teste

Existem diversas técnicas de amostragem para conjuntos de treino, validação e teste:

- **Amostragem aleatória simples:** seleção aleatória de exemplos do conjunto de dados, garantindo que cada exemplo tenha a mesma probabilidade de ser escolhido.
- **Amostragem estratificada:** garante que a proporção de cada classe no conjunto de treinamento, validação e teste seja representativa da proporção geral do conjunto de dados.
- **Amostragem cruzada (*cross-validation*):** divide o conjunto de dados em k partições (*folds*) e executa o treinamento e validação k vezes, utilizando cada partição como conjunto de teste em uma iteração diferente.
- **Amostragem por *bootstrap*:** cria múltiplas amostras de treinamento aleatórias, com reposição, a partir do conjunto de dados original para treinar modelos em diferentes conjuntos de treinamento.
- **Amostragem por *minibatch*:** divide o conjunto de treinamento em pequenos lotes (*minibatches*) para treinar o modelo de forma mais eficiente, especialmente quando o conjunto de dados é grande demais para caber na memória.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Amostragem por tempo:** em séries temporais, utilizam-se dados passados para treinamento e dados futuros para teste, simulando a previsão do comportamento do modelo em situações reais.

Essas técnicas de amostragem são essenciais para garantir que os modelos de Machine Learning sejam bem treinados e se generalizem bem para novos dados. Cada uma delas tem suas vantagens e pode ser utilizada de acordo com a natureza do problema e o tamanho do conjunto de dados disponível. Posteriormente, vamos detalhar cada uma delas.

4.3 Pré-processamento de dados

Considerando que toda base de dados possui problemas de qualidade, a etapa de pré-processamento de dados engloba **limpeza dos dados** e **exploração da base**, para o Cientista de Dados conhecer cada vez mais o desafio a ser modelado.

É comum que a exploração da base siga junto com sua limpeza pois, conforme nós aprendemos mais sobre os dados (exploramos aquela base), nos deparamos com problemas a serem ajustados. E conforme os problemas vão sendo corrigidos, vamos conhecendo sobre o que cada variável tem para nos dizer.

A **exploração da base** costuma ser embasada em uma série de perguntas que colocamos sobre os dados, tais como algumas exemplificadas no quadro “Perguntas direcionadoras da análise exploratória de dados”.

Perguntas direcionadoras da ANÁLISE EXPLORATÓRIA DE DADOS
• Qual é o tamanho desta base de dados? • Quantos exemplos (linhas) e variáveis (colunas) nós temos? • Quais variáveis são numéricas e quais são categóricas? • Quais são discretas e quais são contínuas? • Quais são nominais e quais são ordinais? • Existem outliers nos dados? • Como estão distribuídas as classes em um problema de classificação? • Há correlações significativas entre variáveis? • Quais são as estatísticas descritivas básicas das variáveis numéricas? • Quais são os tipos de dados e quantidades de valores nulos? • Quantas ocorrências de cada valor único das variáveis categóricas?

Quadro 1 - Perguntas direcionadoras da análise exploratória de dados
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Vale lembrar que existem questões específicas do domínio dos dados. Por exemplo, o que gostaríamos de saber sobre dados de exames clínicos de pacientes? Quais perguntas são pertinentes ao analisar dados da última safra de cana-de-açúcar na região Sudeste?

Por outro lado, a **limpeza da base** consiste em sanar problemas descobertos diretamente na exploração da base, tais como aqueles listados no quadro “Estratégias típicas da limpeza de dados”.

Estratégias típicas da LIMPEZA DE DADOS
• Identificação e remoção de valores nulos; • Preenchimento de valores nulos evitando a remoção; • Identificação e remoção de outliers.

Quadro 2 - Estratégias típicas da limpeza de dados
Fonte: Elaborado pelo autor (2024)

4.4 Engenharia de features (feature engineering)

A engenharia de features consiste em uma série de transformações de dados mais elaboradas, e que muitas vezes exige conhecimento sobre o domínio de geração dos dados. São exemplos de tais transformações:

- **Seleção de features:** dadas as variáveis existentes, nesta etapa selecionamos quais serão levadas adiante nas modelagens e quais serão excluídas, além de constatar o porquê de elas não serem interessantes ao negócio ou o porquê de gerarem implicações éticas.
- **Criação de features:** dadas as variáveis existentes, quais outras podem ser criadas a partir delas? E esta combinação de features faz sentido? Por exemplo: calcular o IMC a partir de altura e peso; ou calcular idade a partir da data de nascimento; ou a partir da data, descobrir se é um dia útil ou não.
- **Redução de dimensionalidade:** cada variável representa uma dimensão a ser avaliada. Se tivermos 30 variáveis em um dataset, lidaremos com 30 dimensões. Quanto mais dimensões nos dados, mais complexa fica sua modelagem preditiva. Portanto, uma etapa a ser considerada na limpeza/engenharia de recursos é a eliminação de variáveis de baixo valor preditivo ou baixa relação com o problema analisado. Isso diminui a dimensionalidade do problema.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Normalização de dados:** é comum termos em uma mesma base variáveis expressas em escalas diferentes. Por exemplo, a diferença entre idades pode ser expressa em unidades ou dezenas, mas a diferença entre salários pode ser expressa em milhares ou dezenas de milhares. No universo de modelos preditivos, é importante levar todas as variáveis para a mesma escala, para que o modelo aprenda as relações entre elas no mesmo pé de igualdade. Sem isso, uma diferença expressa em alta dimensão pode passar a impressão falsa que aquela variável é mais relevante que as demais para uma predição qualquer.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

5 DESAFIOS DA CONSTRUÇÃO DE MODELOS PREDITOS

5.1 Desafios gerais sobre a base

Trabalhar com dados é fascinante! À medida que mergulhamos em uma base de dados, aprendemos mais sobre aquele domínio e nos apaixonamos ainda mais pelo tema. No entanto, nem tudo são flores: existem diversos desafios para se trabalhar com dados. Observe a figura a seguir:

diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave_points_mean	symmetry_mean	fractal_dimension_mean
B	13,54	14,36	87,46	566,3	0,09779	0,08129	0,06664	0,04781	0,1885	0,05766
B	13,08	15,71	85,63	520	0,1075	127	0,04568	0,0311	0,1967	0,06811
B	8196	16,84	51,71	201,9	86	0,05943	0,01588	0,005917	0,1769	0,06503
B	6981	13,43	43,79	143,5	117	0,07568	0	0	193	0,07818
B	12,18	20,52	77,22	458,7	0,08013	0,04038	0,02383	0,0177	0,1739	0,05677
M	25,22	24,91	171,5	1878	0,1063	0,2665	0,3339	0,1845	0,1829	0,06782
M	19,1	26,29	129,1	1132	0,1215	0,1791	0,1937	0,1469	0,1634	0,07224
M	18,46	18,52	121,1	1075	0,09874	0,1053	0,1335	0,08795	0,2132	0,06022
M	14,48	21,46	94,25	648,2	0,09444	0,09947	0,1204	0,04938	0,2075	0,05636
M	19,02	24,59	122	1076	0,09029	0,1206	0,1468	0,08271	0,1953	0,05629

Figura 14 - Fragmento de uma base de dados real
Fonte: Elaborado pelo autor (2024)

A figura “Fragmento de uma base de dados real” ilustra um fragmento de uma base de dados real. Certamente existem mais linhas nesta planilha, mas este pequeno fragmento já nos instiga a descobrirmos os principais desafios. Sabemos que cada linha é um exemplo de dado, e cada coluna é uma variável, mas:

- **Que dados são estes:** o primeiro desafio é em relação ao entendimento de negócio. De qual domínio eles derivam? O que significa, por exemplo, área média? Para abrir o jogo, estas são linhas de uma base de dados disponível no Kaggle com informações sobre câncer de mama. Cada linha contém

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

dados numéricos que caracterizam nódulos do seio, a partir da análise de imagens médicas de mamografias.

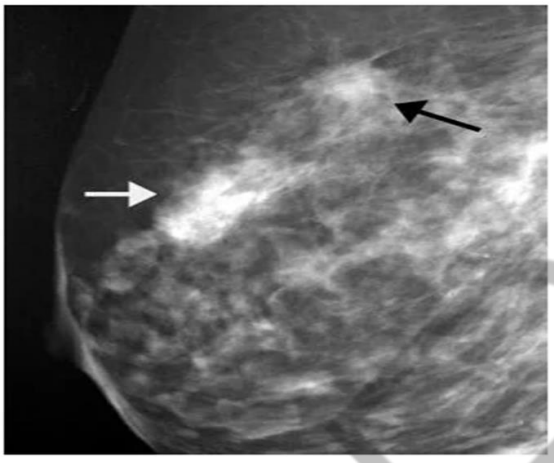

Figura 15 - Exemplo de mamografia com destaque para dois nódulos
Fonte: Medscape Drugs and Disease (2017)

Ou seja, a partir da mamografia, pegamos a imagem médica, identificamos os nódulos e para cada um descrevemos seu raio, sua textura em escala de cinza, seu perímetro, sua área, entre tantas outras variáveis que são expressas de forma numérica. A letra “B” significa um diagnóstico benigno, e a letra “M” um diagnóstico maligno. Com isso, conseguimos entender a origem dos dados e ter uma melhor ideia do que representa cada variável apresentada.

- **Conhecer a distribuição dos dados:** podemos nos perguntar como está a distribuição destes dados, qual é o valor mínimo e máximo de cada variável, se os dados estão desbalanceados (proporção desigual entre exemplos “B” e “M”), se existem dados faltantes e outliers etc.
- **Preparar os dados para uso:** antes de colocar o algoritmo para treinar, precisamos preparar a base, que é a etapa de limpeza de dados e engenharia de features. Isto é, será que todas as variáveis são necessárias? O que fazer com dados faltantes? Os campos com “zero” são dados reais ou valores faltantes? Como reconhecer e eliminar outliers?

Quando trabalhamos com dados, enfrentamos também outros desafios que podem ser causados por **dados ruins** ou **algoritmos ruins**. Observe o quadro:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Problemas causados por DADOS RUINS	Problemas causados por ALGORITMOS RUINS
Dados insuficientes para treinar os modelos Dados com baixa qualidade Features irrelevantes	Overfitting do modelo Underfitting do modelo

Quadro 3 - Desafios de trabalhar com dados
Fonte: Elaborado pelo autor (2024)

Quando o problema está no domínio dos dados, devemos trabalhar na base de dados para resolvê-lo. Porém, se a nossa base de dados for pequena, não há o que fazer, precisamos coletar novos exemplos. Quando nossos dados possuem baixa qualidade, devemos investir ainda mais tempo na limpeza de dados. E se as features são irrelevantes, podemos ignorar algumas delas ou tentar criar features mais poderosas. Por exemplo, podemos criar o IMC a partir do peso e altura de uma pessoa.

Quando o problema está no algoritmo, devemos trocá-lo ou refinar o processo de treinamento do modelo de ML. Vamos reconhecer estes problemas agora!

5.2 Overfitting

O **overfitting**, também conhecido como sobreajuste, acontece quando o algoritmo preditivo é complexo demais para diferenciar as variações dos dados. Ou seja, o modelo se adapta excessivamente aos dados de treinamento. Isso acontece quando o modelo aprende detalhes e ruídos específicos dos dados de treinamento ao invés de aprender padrões gerais que possam ser aplicados a novos dados.

Em outras palavras, o modelo memoriza os dados de treinamento ao invés de aprender a generalizar e capturar a relação subjacente entre os recursos e a variável alvo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 16 - Exemplos lúdicos de overfitting
Fonte: X (2022)

Considere os exemplos da figura “Exemplos lúdicos de overfitting”, eles representam de forma lúdica o que é sobreajuste. No primeiro caso, queremos construir uma casinha de cachorro, e o resultado é uma casinha de cachorro que só serve para **aquele** cachorro **naquela** posição. Qualquer outra tentativa de usar esta casinha em outra situação ela seria completamente inútil. No segundo exemplo, é apresentada uma cama que serve para alguém que dorme **exatamente** naquela posição, pois não falta nem sobra nada. Para qualquer outra pessoa, esta cama seria uma péssima escolha. Dessa forma, é como se o modelo tivesse “decorado” o que é esperado para o dado que foi apresentado durante sua construção (decorou os dados do treino).

Overfitting pode ocorrer quando o modelo é muito complexo em relação ao tamanho do conjunto de treinamento ou quando o conjunto de treinamento é insuficiente. Para combater o overfitting, são utilizadas técnicas de regularização, como *dropout*, L1 e L2, assim como a validação cruzada para avaliar o desempenho do modelo em dados não vistos. Veremos estas técnicas adiante!

5.3 Underfitting

Underfitting, também conhecido como subajuste, é outro fenômeno indesejável que pode ocorrer em modelos de Aprendizado de Máquina, incluindo

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

redes neurais em Deep Learning. Ao contrário do overfitting, o underfitting ocorre quando o modelo não é capaz de capturar adequadamente os padrões e a relação subjacente nos dados de treinamento (imagine tentar matar um dragão com um mata-moscas).

Quando um modelo sofre de underfitting ele é muito simples para lidar com a complexidade dos dados de treinamento. Como resultado, o modelo não consegue aprender nem representar adequadamente os padrões e relacionamentos nos dados, levando a uma baixa capacidade de generalização. O desempenho do modelo no conjunto de treinamento também pode ser insatisfatório.

As principais causas do underfitting incluem o uso de um modelo muito simples, com poucos parâmetros, ou o treinamento insuficiente do modelo. Além disso, um conjunto de dados pequeno ou de baixa qualidade pode contribuir para o subajuste.

5.4 Definição de “modelo ideal”

Então o que é um modelo ideal? É importante encontrar um equilíbrio entre um modelo que é suficientemente complexo para aprender os padrões relevantes e não tão complexo a ponto de memorizar os dados de treinamento.

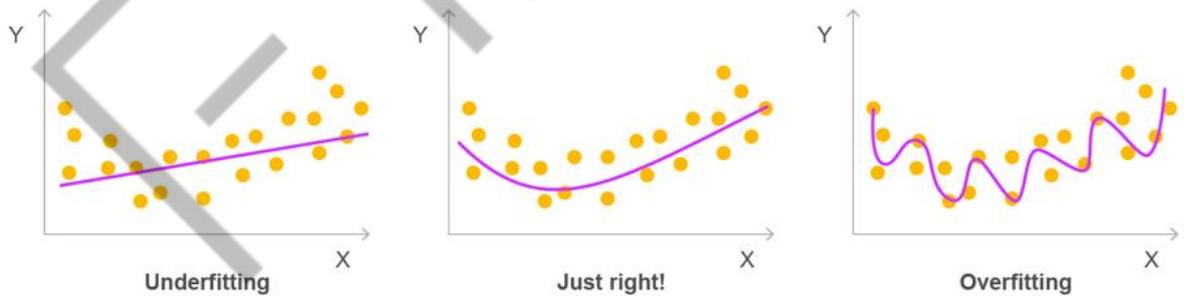

Figura 17 - Definição de modelo ideal
Fonte: Analytics Vidhya (2021)

A figura “Definição de modelo ideal” ilustra o modelo ideal (central) ao lado de exemplos de underfitting e overfitting. Em todos os casos, os pontos em laranja indicam os dados de treinamento e a curva em rosa indica o modelo preditivo que ilustra o comportamento de tais dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

No overfitting, o modelo em rosa é muito complexo, representando **exatamente** todos os dados, sem captar suas tendências e características gerais. Portanto, o modelo falha na generalização do aprendizado pois não houve aprendizado, visto que apenas decorou os exemplos.

Em relação ao underfitting, o modelo em rosa é muito simples, sendo incapaz de reconhecer as variações nos dados. Neste caso, o modelo forçou uma representação linear da distribuição dos dados, quando naturalmente a distribuição é um pouco mais sofisticada.

Por fim, o modelo ideal (figura central) é perfeito. Ou seja, não é nem simples demais, nem complexo demais, pois modela bem o comportamento dos dados, mas possui certa tolerância a novos dados.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

6 HANDS ON: ANÁLISE DE DADOS PARA MACHINE LEARNING

Agora que passamos pelos principais conceitos da nossa jornada de trabalho com dados, rumo à criação de modelos preditivos, está na hora de conhecermos as principais bibliotecas em Python que implementam as etapas listadas acima.

Toda nossa prática será feita em um jupyter notebook no ambiente do Google Colaboratory (Colab).

Dica: veja o material HOW TO para acessar o ambiente do Colab.

Uma vez no Colab, crie um novo notebook, dê um nome como preferir (sugestão: aula 1), e faça cada bloco de código fonte em uma célula. Após inserir o código na célula do notebook, execute-a e veja a saída gerada.

Dica: utilize o arquivo de apoio “exemplos_limpeza_dados.csv”.

6.1 Explorando e limpando dados com Pandas

Explorar e limpar dados são fases críticas na análise, e a biblioteca Pandas destaca-se nessas tarefas. Mergulharemos na exploração de um conjunto de dados simples, mas que ilustra os passos de exploração e limpeza de dados.

O código a seguir carrega para a memória um DataFrame Pandas contendo os dados do arquivo “exemplos_limpeza_dados.csv”. Na sequência, pedimos o formato deste DataFrame, bem como sua exibição.

```
import pandas as pd
import numpy as np

df = pd.read_csv("exemplos_limpeza_dados.csv")
print(df.shape)
print()
df
```

Código-fonte 1 - Leitura de um arquivo de dados com Pandas
Fonte: Elaborado pelo autor (2024)

A saída do comando “shape” é uma tupla, indicando a quantidade de linhas e colunas do arquivo (12 linhas e 5 colunas). Após pularmos uma linha, vemos o

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

conteúdo do DataFrame. É importante notar que somente conseguimos ver o DataFrame inteiro porque ele é pequeno. Para dimensões maiores, a visualização seria restrita.

```
(12, 5)
```

	Country	Age	Salary	Grade	Purchased
0	France	44.0	72000.0	1st	No
1	France	44.0	72000.0	1st	No
2	Spain	27.0	48000.0	1st	Yes
3	Germany	30.0	54000.0	3th	No
4	Spain	38.0	61000.0	1st	No
5	Germany	40.0	NaN	2nd	Yes
6	Germany	40.0	NaN	2nd	Yes
7	France	35.0	58000.0	2nd	Yes
8	Spain	NaN	52000.0	1st	No
9	France	48.0	79000.0	3th	Yes
10	Germany	50.0	83000.0	2nd	No
11	France	37.0	67000.0	3th	Yes

Figura 18 - Resultado do código-fonte 1
Fonte: Elaborado pelo autor (2024)

Inclusive, nos casos que possuímos muitas linhas, podemos alterar a visualização puxando apenas as primeiras linhas — com o head() — ou as últimas — com o tail(). Geralmente, a melhor representação é feita pelo sample(N), que puxa uma amostra de N linhas aleatórias. Esta é uma representação mais fiel da distribuição de dados do DataFrame inteiro. No código a seguir vamos exibir 5 linhas aleatórias. Sua saída provavelmente será diferente. Aproveite e explore outros valores para N.

```
# Pegando uma amostra de 5 linhas aleatórias
df.sample(5)
```

Código-fonte 2 - Exibição de 5 linhas aleatórias
Fonte: Elaborado pelo autor (2024)

A saída do comando “shape” é uma tupla, indicando a quantidade de linhas e colunas do arquivo (12 linhas e 5 colunas). Após pularmos uma linha, vemos o

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

conteúdo do DataFrame. É importante notar que somente conseguimos ver o DataFrame inteiro porque ele é pequeno. Para dimensões maiores, a visualização seria restrita.

	Country	Age	Salary	Grade	Purchased
3	Germany	30.0	54000.0	3th	No
11	France	37.0	67000.0	3th	Yes
7	France	35.0	58000.0	2nd	Yes
9	France	48.0	79000.0	3th	Yes
0	France	44.0	72000.0	1st	No

Figura 19 - Resultado do código-fonte 2
Fonte: Elaborado pelo autor (2024)

Uma parte relevante da exploração da base é compreender quais variáveis existem, quais são seus tipos e a existência de dados nulos. Tudo isso pode ser obtido por meio do seguinte comando:

```
# Explorando a base
df.info()
```

Código-fonte 3 - Obtendo informações das variáveis do DataFrame Pandas
Fonte: Elaborado pelo autor (2024)

A saída do comando info() é muito completa. Ela aponta que estamos diante de um DataFrame Pandas, que ocupa ~608 bytes na memória, temos 5 variáveis, sendo que duas variáveis (Age e Salary) são numéricas do tipo *float* e as demais são *strings*. Também conseguimos notar que o DataFrame possui 12 entradas (linhas), numeradas de 0 a 11. Inclusive, a maior parte das variáveis está completa, havendo valores nulos apenas nas colunas “Age”, “Salary” e “Grade”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12 entries, 0 to 11
Data columns (total 5 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   Country    12 non-null     object
 1   Age        11 non-null     float64
 2   Salary     10 non-null     float64
 3   Grade      12 non-null     object
 4   Purchased  12 non-null     object
dtypes: float64(2), object(3)
memory usage: 608.0+ bytes
```

Figura 20 - Resultado do código-fonte 3
Fonte: Elaborado pelo autor (2024)

Inclusive, uma outra forma mais visual de verificar se há dados faltantes é por meio da biblioteca “missingno”. Experimente seu uso com os seguintes comandos:

```
import missingno as msno
msno.matrix(df);
```

Código-fonte 4 - Visualizando dados faltantes com a biblioteca missingno
Fonte: Elaborado pelo autor (2024)

Esta visualização nos permite afirmar que há dados faltantes apenas nas colunas “Age” e “Salary”, e que as ausências não ocorrem nas mesmas linhas.

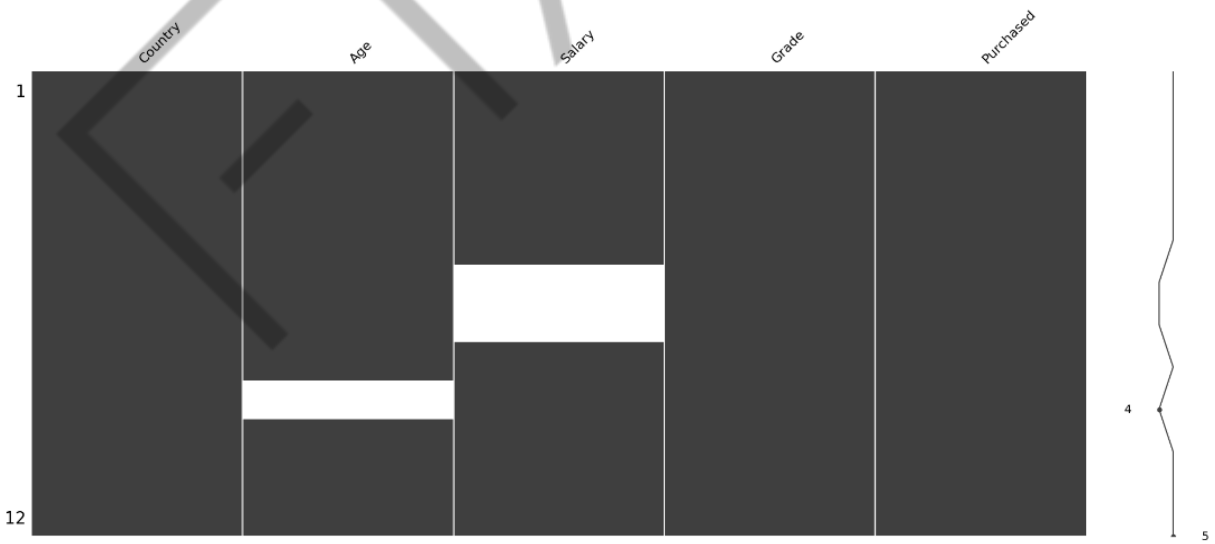

Figura 21 - Resultado do código-fonte 4
Fonte: Elaborado pelo autor (2024)

Outra análise exploratória relevante é obtermos estatísticas básicas das variáveis numéricas. Podemos fazer isso manualmente com poucas linhas de código, porém, o Pandas já facilita este cálculo por meio do comando describe():

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Exibe estatísticas básicas do dataframe
df.describe()
```

Código-fonte 5 - Obtendo análises estatísticas básicas do Pandas
Fonte: Elaborado pelo autor (2024)

Esta análise nos mostra, para cada variável numérica, a contagem de linhas não nulas, além de apresentar a média (mean), o desvio padrão (std), os valores mínimos (min) e máximo (max) e os quartis (25%, 50% e 75%). Observe a média da idade (Age) e a mediana do salário (Salary). Usaremos estes valores em breve!

	Age	Salary
count	11.000000	10.000000
mean	39.363636	64600.000000
std	7.060775	11852.800888
min	27.000000	48000.000000
25%	36.000000	55000.000000
50%	40.000000	64000.000000
75%	44.000000	72000.000000
max	50.000000	83000.000000

Figura 22 - Resultado do código-fonte 5
Fonte: Elaborado pelo autor (2024)

Agora chegou o momento de começarmos a limpar os dados. Uma análise essencial para Machine Learning é evitar dados duplicados no dataset. Podemos remover linhas duplicadas de forma simples com os seguintes comandos:

```
# Remover dados duplicados em nova variável
df_unicos = df.drop_duplicates()

# Remover dados duplicados na MESMA variável
df.drop_duplicates(inplace=True)
```

Código-fonte 6 - Obtendo análises estatísticas básicas do Pandas
Fonte: Elaborado pelo autor (2024)

Ambos os comandos mencionados fazem essencialmente a mesma coisa. O drop_duplicates() sempre retorna uma cópia do DataFrame sem as cópias extras das linhas que aparecem mais de uma vez. A diferença é que o primeiro comando armazena esta cópia na variável “df_unicos”, portanto, a variável “df” fica exatamente

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

como está. Em relação ao comando que utiliza o parâmetro “inplace=True”, ele altera a própria variável “df”.

Podemos seguir com a variável “df_unicos” para mostrar como podemos tratar dados nulos com a exclusão das linhas problemáticas. O primeiro comando mostrado a seguir apaga as linhas com nulos na própria variável “df_unicos”.

Além disso, outra estratégia é preencher os valores nulos com valores pertinentes. Por exemplo, preenchemos a coluna “Age” com seu valor médio e a coluna “Salary” com a mediana.

```
# Apagar dados faltantes na MESMA variável
df_unicos.dropna(inplace=True)

# Preencher dados faltantes
# - coloca o valor médio da idade na coluna Age
df["Age"].fillna( df["Age"].mean() , inplace=True)

# - coloca o valor mediano do salário na coluna Salary
df["Salary"].fillna( df["Salary"].median() , inplace=True
)
```

Código-fonte 7 - Limpeza de dados com Pandas
Fonte: Elaborado pelo autor (2024)

Reveja os valores obtidos no “describe()” e compare com os valores que apareceram no DataFrame da variável “df”. Em seguida, compare os estados atuais de “df_unicos” e “df”.

df_unicos

	Country	Age	Salary	Grade	Purchased
0	France	44.0	72000.0	1st	No
2	Spain	27.0	48000.0	1st	Yes
3	Germany	30.0	54000.0	3th	No
4	Spain	38.0	61000.0	1st	No
7	France	35.0	58000.0	2nd	Yes
9	France	48.0	79000.0	3th	Yes
10	Germany	50.0	83000.0	2nd	No
11	France	37.0	67000.0	3th	Yes

df

	Country	Age	Salary	Grade	Purchased
0	France	44.000000	72000.0	1st	No
2	Spain	27.000000	48000.0	1st	Yes
3	Germany	30.000000	54000.0	3th	No
4	Spain	38.000000	61000.0	1st	No
5	Germany	40.000000	61000.0	2nd	Yes
7	France	35.000000	58000.0	2nd	Yes
8	Spain	38.777778	52000.0	1st	No
9	France	48.000000	79000.0	3th	Yes
10	Germany	50.000000	83000.0	2nd	No
11	France	37.000000	67000.0	3th	Yes

Figura 23 - Resultado dos códigos-fontes 6 e 7
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

6.2 Engenharia de features com Pandas e Scikit-Learn

A engenharia de features é essencial na construção de modelos de aprendizado de máquina robustos, e a combinação do Scikit-Learn e Pandas oferece uma abordagem poderosa nesse processo.

O Scikit-Learn é crucial para Ciência de Dados e Machine Learning, pois ele proporciona uma ampla gama de ferramentas e algoritmos de aprendizado de máquina. Sua biblioteca abrangente simplifica a implementação de modelos, oferecendo suporte desde a pré-processamento dos dados até a avaliação do desempenho do modelo. Veremos usos mais sofisticados desta biblioteca adiante.

Dica: continuaremos utilizando o arquivo de apoio "exemplos_limpeza_dados.csv". Certifique-se que as variáveis "df" e "df_unicos" estejam conforme ilustrados na figura "Resultado dos códigos-fontes 6 e 7".

Por enquanto, utilizaremos a parte de pré-processamento do Scikit-learn para transformar dados categóricos nominais e ordinais, bem como escalar valores numéricos.

```
from sklearn.preprocessing import StandardScaler, MinMaxScaler
from sklearn.preprocessing import LabelEncoder

# Tratando dados categóricos - ORDINAIS
print( df["Purchased"].unique() ) # valores únicos

le = LabelEncoder()

df["Purchased_encoder"] = le.fit_transform( df["Purchased"] )
df["Grade_encoder"] = le.fit_transform( df["Grade"] )
df
```

Código-fonte 8 - Tratando dados categóricos ordinais
Fonte: Elaborado pelo autor (2024)

A figura "Resultado dos código-fonte 8" mostra que os valores únicos de "Purchased" são "No" e "Yes". Claramente, trata-se de um dado categórico. Da mesma forma, os valores únicos de "Grade" são "1st", "2nd" e "3th". Existe uma relação de ordem entre os dados, portanto, utilizamos o LabelEncoder() do Scikit-Learn. O

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

fit_transform() primeiro cria uma relação entre cada categoria e um valor numérico de 0 em diante, e depois aplica tal relação. Veja a saída na figura a seguir:

	Country	Age	Salary	Grade	Purchased	Purchased_encoder	Grade_encoder
0	France	44.000000	72000.0	1st	No	0	0
2	Spain	27.000000	48000.0	1st	Yes	1	0
3	Germany	30.000000	54000.0	3th	No	0	2
4	Spain	38.000000	61000.0	1st	No	0	0
5	Germany	40.000000	61000.0	2nd	Yes	1	1
7	France	35.000000	58000.0	2nd	Yes	1	1
8	Spain	38.777778	52000.0	1st	No	0	0
9	France	48.000000	79000.0	3th	Yes	1	2
10	Germany	50.000000	83000.0	2nd	No	0	1
11	France	37.000000	67000.0	3th	Yes	1	2

Figura 24 - Resultado do código-fonte 8
Fonte: Elaborado pelo autor (2024)

Agora vamos tratar as variáveis categóricas nominais, ou seja, aquelas que não possuem relação de ordem entre cada categoria. Neste caso usamos a técnica de *One Hot Encoder*, que é implementada, por exemplo, pelo método get_dummies() do Pandas.

```
# Tratando dados categóricos - NOMINAIS
aux = pd.get_dummies( df["Country"] )
final = pd.concat( [df, aux], axis=1 )
final
```

Código-fonte 9 - Tratando dados categóricos nominais
Fonte: Elaborado pelo autor (2024)

Observe que agora nosso novo DataFrame “final” está bem mais amplo, pois novas features foram criadas automaticamente.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

	Country	Age	Salary	Grade	Purchased	Purchased_encoder	Grade_encoder	France	Germany	Spain
0	France	44.000000	72000.0	1st	No	0	0	1	0	0
2	Spain	27.000000	48000.0	1st	Yes	1	0	0	0	1
3	Germany	30.000000	54000.0	3th	No	0	2	0	1	0
4	Spain	38.000000	61000.0	1st	No	0	0	0	0	1
5	Germany	40.000000	61000.0	2nd	Yes	1	1	0	1	0
7	France	35.000000	58000.0	2nd	Yes	1	1	1	0	0
8	Spain	38.777778	52000.0	1st	No	0	0	0	0	1
9	France	48.000000	79000.0	3th	Yes	1	2	1	0	0
10	Germany	50.000000	83000.0	2nd	No	0	1	0	1	0
11	France	37.000000	67000.0	3th	Yes	1	2	1	0	0

Figura 25 - Resultado do código-fonte 9
Fonte: Elaborado pelo autor (2024)

No entanto, claramente não precisamos de todas estas features, pois muitas são cópias transformadas das colunas originais. Então, vamos fazer outra limpeza, removendo colunas que não são mais necessárias. O comando a seguir pode ser feito com qualquer feature que julgamos irrelevante na nossa análise:

```
     # Filtrar colunas relevantes
     final.drop( columns=["Country", "Grade", "Purchased"] ,
inplace=True )
     final
```

Código-fonte 10 - Como eliminar colunas via Pandas
Fonte: Elaborado pelo autor (2024)

Ao usarmos o parâmetro “inplace=True”, alteramos a própria variável “final”. Ao exibir o resultado, temos:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

	Age	Salary	Purchased_encoder	Grade_encoder	France	Germany	Spain
0	44.000000	72000.0	0	0	1	0	0
2	27.000000	48000.0	1	0	0	0	1
3	30.000000	54000.0	0	2	0	1	0
4	38.000000	61000.0	0	0	0	0	1
5	40.000000	61000.0	1	1	0	1	0
7	35.000000	58000.0	1	1	1	0	0
8	38.777778	52000.0	0	0	0	0	1
9	48.000000	79000.0	1	2	1	0	0
10	50.000000	83000.0	0	1	0	1	0
11	37.000000	67000.0	1	2	1	0	0

Figura 26 - Resultado do código-fonte 10
Fonte: Elaborado pelo autor (2024)

Finalmente, nossas features estão completamente numéricas, o que é uma exigência dos modelos de Machine Learning e Deep Learning. No entanto, elas se apresentam em escalas bem diferentes. Nosso próximo comando transformará os dados por meio de Padronização e Normalização.

A Padronização “StandardScaler()” é mais voltada para dados que seguem a distribuição normal, ou seja, centrados na média. A Normalização “MinMaxScaler()” apenas leva a distribuição dos dados para outro intervalo de valores (no nosso caso, entre 10 e 20).

```
# Transforma os dados com Padronização/Normalização
sc = StandardScaler()
final_padronizado = sc.fit_transform(final)

mm = MinMaxScaler(feature_range=(10, 20))
final_normalizado = mm.fit_transform(final)
```

Código-fonte 11 - Trazendo dados para a mesma escala
Fonte: Elaborado pelo autor (2024)

Para melhor exibir os dados, criaremos novos DataFrames Pandas. Primeiramente, para os dados Padronizados:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Salvar os dados padronizados em outro dataframe
df_final_padronizado = pd.DataFrame(final_padronizado,
                                    columns=final.columns)
df_final_padronizado
```

Código-fonte 12 - Criando um DataFrame com os dados Padronizados
Fonte: Elaborado pelo autor (2024)

E vejamos o resultado:

	Age	Salary	Purchased_encoder	Grade_encoder	France	Germany	Spain
0	0.758874	0.772568	-1.0	-1.083473	1.224745	-0.654654	-0.654654
1	-1.711504	-1.408800	1.0	-1.083473	-0.816497	-0.654654	1.527525
2	-1.275555	-0.863458	-1.0	1.324244	-0.816497	1.527525	-0.654654
3	-0.113024	-0.227226	-1.0	-1.083473	-0.816497	-0.654654	1.527525
4	0.177609	-0.227226	1.0	0.120386	-0.816497	1.527525	-0.654654
5	-0.548973	-0.499897	1.0	0.120386	1.224745	-0.654654	-0.654654
6	0.000000	-1.045239	-1.0	-1.083473	-0.816497	-0.654654	1.527525
7	1.340140	1.408800	1.0	1.324244	1.224745	-0.654654	-0.654654
8	1.630773	1.772361	-1.0	0.120386	-0.816497	1.527525	-0.654654
9	-0.258340	0.318116	1.0	1.324244	1.224745	-0.654654	-0.654654

Figura 27 - Resultado do código-fonte 12
Fonte: Elaborado pelo autor (2024)

Agora iremos fazer o mesmo com os dados Normalizados:

```
# Salvar os dados normalizados em outro dataframe
df_final_normalizado = pd.DataFrame(final_normalizado,
                                    columns=final.columns)
df_final_normalizado
```

Código-fonte 13 - Criando um DataFrame com os dados Normalizados
Fonte: Elaborado pelo autor (2024)

E vejamos o resultado:

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

	Age	Salary	Purchased_encoder	Grade_encoder	France	Germany	Spain
0	17.391304	16.857143	10.0	10.0	20.0	10.0	10.0
1	10.000000	10.000000	20.0	10.0	10.0	10.0	20.0
2	11.304348	11.714286	10.0	20.0	10.0	20.0	10.0
3	14.782609	13.714286	10.0	10.0	10.0	10.0	20.0
4	15.652174	13.714286	20.0	15.0	10.0	20.0	10.0
5	13.478261	12.857143	20.0	15.0	20.0	10.0	10.0
6	15.120773	11.142857	10.0	10.0	10.0	10.0	20.0
7	19.130435	18.857143	20.0	20.0	20.0	10.0	10.0
8	20.000000	20.000000	10.0	15.0	10.0	20.0	10.0
9	14.347826	15.428571	20.0	20.0	20.0	10.0	10.0

Figura 28 - Resultado do código-fonte 13
Fonte: Elaborado pelo autor (2024)

Pronto! Agora sim os dados estão todos no formato esperado pela máquina para aprender a encontrar padrões nos dados e treinar algoritmos de Machine Learning. Observe que todos os dados são numéricos e estão na mesma escala. Os DataFrames finais “df_final_padronizado” ou “df_final_normalizado” podem ser utilizados para alimentar algoritmos de Machine Learning.

A título de curiosidade, podemos, ainda, exportar os dados salvos em arquivos CSV pelos seguintes comandos:

```
# Exporta os dados para arquivos
df_final_padronizado.to_csv("dados_padronizados.csv")
df_final_normalizado.to_csv("dados_normalizados.csv")
```

Código-fonte 14 - Exportando o resultado das transformações aplicadas
Fonte: Elaborado pelo autor (2024)

Após executá-los, note a criação de dois novos arquivos no seu ambiente de execução do Google Colaboratory, ilustrado na figura “Exibição de novos arquivos criados no ambiente Google Colaboratory”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

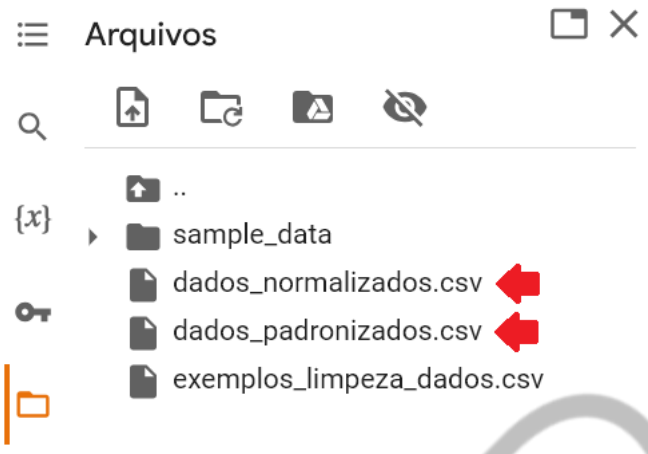

Figura 29 - Exibição de novos arquivos criados no ambiente Google Colaboratory
Fonte: Elaborado pelo autor (2024)

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

CONCLUSÃO

Ao longo deste capítulo, exploramos as diversas dimensões do universo dos dados, desde a classificação baseada em fonte, granularidade, estrutura e tipo até sua organização em bancos de dados (e no Big data).

Adentramos no fascinante domínio da Ciência de Dados e do Aprendizado de Máquina, abordando a manipulação de variáveis, técnicas de amostragem e as etapas cruciais de pré-processamento e engenharia de features. Descobrimos e compreendemos os desafios inerentes ao trabalho com dados e Machine Learning, como overfitting e underfitting, contrastando-os com o perfil do “modelo ideal”.

Na parte prática, implementamos técnicas de exploração e limpeza de dados, além da engenharia de features com Pandas e Scikit-Learn, capacitando vocês a não apenas compreender, mas também aplicar as habilidades fundamentais de Ciência de Dados em projetos do mundo real. Essa atividade prática reforça o aprendizado teórico, fornecendo uma base sólida para explorar os vastos horizontes da modelagem de dados na era da informação.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

CATUNDA, Heitor. Introdução a Ciência de Dados – Primeiros Passos. **Hashtag treinamentos**, 07 de março de 2022. Disponível em: <https://www.hashtagtreinamentos.com/introducao-a-ciencia-de-dados-cd>. Acesso em: 16 de ago. 2024.

CIELEN, Davy; MEYSMAN, Arno; ALI, Mohamed. **Introducing data science: Big Data, Machine Learning, and more, using Python tools**. 1st ed. Manning, 2016.

GOEL, Vanshika. Data Science Life Cycle in 5 Steps. **Medium**, 4 july 2020. Disponível em: <https://medium.com/@vanshikagoel/data-science-life-cycle-in-5-steps-3fe720b2a2fe>. Acesso em: 16 ago. 2024.

GOYAL, Chirag. Complete Guide to Prevent Overfitting in Neural Networks (Part-1). **Analytics Vidhya**, 12 june 2021, Disponível em: <https://www.analyticsvidhya.com/blog/2021/06/complete-guide-to-prevent-overfitting-in-neural-networks-part-1/>. Acesso em: 16 de ago. de 2024.

IZBICKI, Rafael; DOS SANTOS, Tiago Mendonça. **Aprendizado de máquina: uma abordagem estatística**. Editora: UICLAP, 2020.

MILLER, Ac. Breast Abscess and Masses. **Medscape Drugs and Diseases**. Medscape Drugs and Disease, April 13 2017. Disponível em: <https://www.researchgate.net/publication/316120957_Breast_Abscess_and_Masses>. Acesso em: 16 de ago. de 2024.

PROVOST, Foster. **Data Science para Negócios by Tom Fawcett Foster Provost** [Fawcett, Tom](z-lib.org).

Regunath, Gavita. Understanding The Difference Between AI, ML, And DL: Using An Incredibly Simple Example. **Advancing analytics**, 15 dec. 2021. Disponível em: <https://www.advancinganalytics.co.uk/blog/2021/12/15/understanding-the-difference-between-ai-ml-and-dl-using-an-incredibly-simple-example>. Acesso em: 16 de ago. 2024.

RUSSELL, Stuart J.; NORVIG, Peter. **Inteligencia Artificial: un enfoque modern**, 2004.

SMEDEN, Van Maarten (MaartenvSmeden). “There are never enough overfitting memes. Please share your own favorite”. 5 de maio de 2022, 12:05. **X**. Disponível em: https://x.com/MaartenvSmeden/status/1522230905468862464. Acesso em: 19 ago. 2024.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

GLOSSÁRIO

Termo	Explicação
BI	Business Intelligence.
DL	Deep Learning.
IA	Inteligência Artificial.
ML	Machine Learning.
RNAs	Redes Neurais Artificiais.
SGBD	Sistema de Gerenciamento de Banco de Dados.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com