FIAP ON

SAFRA DO CONHECIMENTO
CIBERNÉTICO - PRAGAS VIRTUAIS

ÉTICA E RESPONSABILIDADE NA IA GENERATIVA

2

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Chimpanzé bebê gerado por uma IA 4
Figura 2 - Garry Kasparov vs Deep Blue, da IBM (essa imagem correu o mundo em 1997) 6
Figura 3 - Exemplo de chatbot 8
Figura 4 - Fachada do jornal New York Times 11
Figura 5 - Geração de imagem usando o primeiro prompt 17
Figura 6 - Geração de imagem usando o segundo prompt 18
Figura 7 - Geração de imagem usando o terceiro prompt 19
Figura 8 - Geração de imagem usando o quarto prompt.....19

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 ÉTICA E RESPONSABILIDADE NA IA GENERATIVA 4
1.1 Introdução 4
1.2 As origens da IA Simbólica e Conexionista 5
1.3 O modelo computacional da mente 7
1.4 A evolução do Conexionismo e da Aprendizagem Profunda 8
1.5 A necessidade de ética no uso da IAG 9
1.6 Algumas provocações na área da educação 10
1.7 Em busca da ética e não do viés 12
2 QUAL A DIFERENÇA ENTRE A IA GENERATIVA E A PREDITIVA? 15
2.1 Alguns modelos de IAG 15
2.2 Exemplo de alucinação 17
3 AS LEIS DA ROBÓTICA E DA IA CRIADAS 22
3.1 Compilado das normatizações 24
3.2 IAG consegue sentir? 27
3.3 IAG consegue mentir? 27
3.4 As IAs podem ser racistas? 28
CONCLUSÃO 30
REFERÊNCIAS 32

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 ÉTICA E RESPONSABILIDADE NA IA GENERATIVA

1.1 Introdução

Nesse capítulo vamos aprofundar nas reflexões sobre a ética de um sistema de Inteligência Artificial (IA), em especial, relacionada à Inteligência Artificial Generativa (IAG). Essa reflexão é importante já que você e todos da turma estão aqui não apenas para codificar os modelos e resolver problemas da sociedade com a ajuda da IA, mas também, ter pensamento crítico sobre como programar as IAs.

Quando você se aprofunda nos resultados dos frameworks em Python, o destino é uma reflexão humana do que está acontecendo, já que o resultado esperado é uma característica especialmente humana: a inteligência, mesmo que artificial.

Os chimpanzés não são seres humanos por causa de apenas dois cromossomos a mais que eles possuem. Ou seja, nós e eles temos aproximadamente 99% de semelhança no DNA.

Figura 1 - Chimpanzé bebê gerado por uma IA
Fonte: FreeP!k (2023)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Desde o lançamento do ChatGPT, em meados de dezembro de 2022, a IAG causou uma revolução ainda não mensurada, impactando diversas áreas e transformando a maneira como a sociedade lida com a criação e comunicação digital.

A IAG se diferencia da Inteligência Artificial Preditiva (IAP) pois tem um alcance mais amplo e acessível, permitindo que qualquer pessoa consiga gerar conteúdo sofisticado com comandos simples, sem a necessidade de conhecimentos técnicos aprofundados.

Explicando melhor, a IAP é a IA comum que tínhamos como a revolução, isto é, uma categoria de IA que se concentra em usar dados históricos para fazer previsões sobre eventos futuros. Ela funciona ao analisar grandes volumes de dados, identificar padrões, tendências e relações entre variáveis e, com base nisso, fazer previsões precisas sobre o que pode acontecer.

A IAG não apenas cria formas de interação digital, mas também facilita tarefas que anteriormente exigiam maior esforço e criatividade humana, como redação de textos, geração de imagens e auxílio em processos de aprendizado. No entanto, com essa facilidade, surgem desafios éticos e educacionais, especialmente ao considerar que essa tecnologia pode ser utilizada tanto de forma honesta quanto para realizar práticas fraudulentas.

1.2 As origens da IA Simbólica e Conexionista

Para relembrar, a história da IA começou na década de 1950, quando especialistas em ciência da computação se reuniram na Conferência de Dartmouth para definir os fundamentos da ciência da mente a partir do modelo do computador digital. Esse encontro deu origem à “IA Simbólica”, que focava na simulação de habilidades humanas por meio da manipulação de símbolos.

Isso significa que, assim como usamos palavras, números ou sinais para nos comunicar e resolver problemas, os computadores poderiam ser programados para usar símbolos e regras lógicas para fazer a mesma coisa. Por exemplo, a IA Simbólica foi aplicada em programas que jogavam xadrez. Esses programas “pensavam” sobre o jogo considerando as regras predefinidas e processando as informações do

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

tabuleiro como símbolos que representavam peças de xadrez. Com isso, a máquina conseguia simular a tomada de decisões durante uma partida.

Você se recorda da primeira vitória significativa de uma IA contra um jogador humano de xadrez? Ocorreu em 1997, quando o supercomputador Deep Blue, desenvolvido pela IBM, derrotou o campeão mundial Garry Kasparov em uma partida histórica. Um representante da IBM repassava as posições das peças para o computador ao lado, e o Deep Blue combinava milhões de possibilidades e avançava uma peça na tela, que por sua vez, o operador colocava manualmente no tabuleiro.

Figura 2 - Garry Kasparov vs Deep Blue, da IBM (essa imagem correu o mundo em 1997)
Fonte: AI Business (2022)

Em 1980 surgiu uma nova abordagem chamada “Conexionismo”, que foi desenvolvida com o intuito de simular a inteligência humana através de redes neurais artificiais, replicando a estrutura e o funcionamento do cérebro.

Enquanto a IA Simbólica modelava a mente como uma série de processos lógicos e regras sintáticas, o Conexionismo buscava emular o funcionamento do cérebro como uma rede massiva de neurônios interconectados. Essas duas abordagens — IA Simbólica e Conexionista — coexistem até hoje, embora o sucesso recente da aprendizagem profunda tenha dado maior visibilidade ao Conexionismo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Para a sua profissão, é interessante saber que no início a IA Simbólica fez um grande sucesso. Alguns anos depois, a IA Conexionista veio para evoluir.

1.3 O modelo computacional da mente

A IA Simbólica se baseava em dois pressupostos principais:

- Autonomia entre hardware e software, o que permitia simular a inteligência sem depender do tipo de estrutura física;
- A concepção da mente como um sistema de representações simbólicas governadas por regras lógicas.

Essa abordagem (IA Simbólica) entendia o pensamento como o resultado da manipulação de símbolos, e não como algo necessariamente ligado ao cérebro físico. Essa concepção influenciou profundamente as ciências cognitivas e estabeleceu o paradigma computacional da mente, conhecido como funcionalismo.

E o que é funcionalismo? No contexto da IA e das ciências cognitivas, o funcionalismo é uma teoria que explica a mente e os processos mentais em termos de funções, sem se concentrar em como esses processos são realizados fisicamente e sem entender as sinapses, visto que a mente é um dos grandes mistérios até hoje. Ou seja, o funcionalismo sugere que os estados mentais, como pensamentos, crenças e desejos são definidos não pelo que eles são fisicamente (se são neurônios no cérebro ou circuitos em um computador), mas pelas funções que desempenham e pelas relações que têm entre si. Isso parece ser mais fácil de ser explicado que os circuitos dos neurônios.

Por outro lado, o Conexionismo, ao focar em redes neurais artificiais, aproximou-se mais do estudo da biologia do cérebro. Essa abordagem considera a mente como um sistema dinâmico composto por padrões de conectividade que se formam entre unidades semelhantes aos neurônios.

Essa perspectiva alinhou o Conexionismo com filosofias materialistas da mente, e suas pesquisas contribuíram para o desenvolvimento da neurociência cognitiva e da robótica.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.4 A evolução do Conexionismo e da Aprendizagem Profunda

Na década de 1980, pesquisadores como Hinton, Rumelhart e McClelland retomaram o estudo das redes neurais artificiais. Esse trabalho, que inicialmente teve pouca repercussão, ganhou força nas décadas seguintes graças ao crescimento exponencial da capacidade computacional e ao acesso a grandes volumes de dados.

Foi nesse contexto que o Aprendizado Profundo (*Deep Learning*) surgiu como a tecnologia dominante em IA utilizando redes neurais para treinar modelos complexos capazes de aprender padrões e realizar tarefas específicas.

É de conhecimento geral que o Aprendizado Profundo e o Aprendizado de Máquina se tornaram fundamentais em aplicações como visão computacional, processamento de linguagem natural, sistemas de recomendação e automação de processos. Esses avanços possibilitaram a criação de assistentes virtuais e chatbots cada vez mais sofisticados, como o próprio ChatGPT, que se tornou amplamente utilizado em diversas esferas da vida cotidiana.

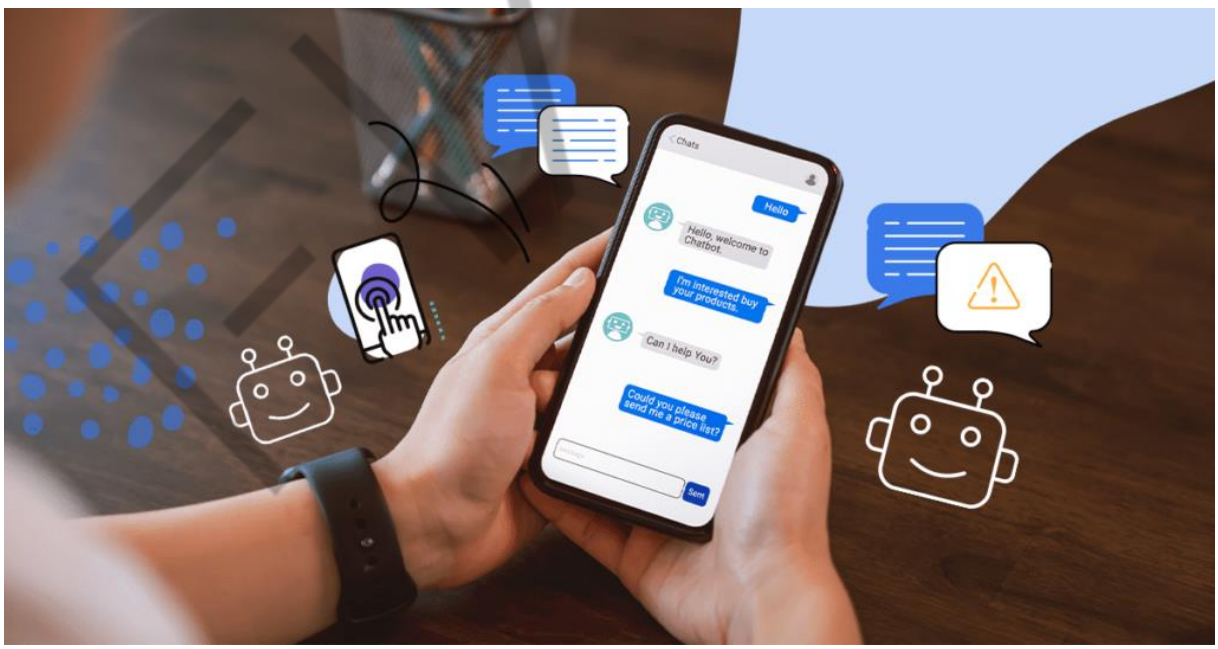

Figura 3 - Exemplo de chatbot
Fonte: Rock Content (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.5 A necessidade de ética no uso da IAG

A disseminação da IAG levantou e continua levantando questões éticas e desafios significativos. A facilidade com que o ChatGPT pode ser utilizado para criar textos e respostas traz consigo o risco de fraude acadêmica, em que estudantes podem usar a ferramenta para produzir trabalhos sem qualquer esforço próprio. Isso representa uma ameaça direta à integridade educacional, à formação profissional e levanta a necessidade de um debate sobre ética e regulamentação da tecnologia.

Por exemplo, em um trabalho acadêmico no qual se deseja avaliar o alcance técnico autoral individual ou em grupo, se discute até que ponto o código-fonte está sob domínio técnico do(s) envolvido(s). O que foi integral ou parcialmente copiado ou ajustado para concluir um projeto? Até que ponto é possível propor soluções inteligentes com base no conhecimento sólido e nas experiências vivenciadas (e fazer centenas de buscas não é necessariamente uma vivência sólida) sem depender das IAGs? Com o advento das IAGs, o problema agora não é somente resolver uma dor específica de um trabalho ou de uma empresa, e sim, decidir de quem é a Propriedade Intelectual (PI) da solução.

Para elucidar um pouco mais, PI é o conjunto de direitos legais que protege as criações do intelecto humano. Isso inclui inovações, obras artísticas e literárias, símbolos, nomes, imagens e designs utilizados no comércio, código-fonte, patentes, e segredos industriais. A propriedade intelectual permite que os criadores tenham o controle sobre o uso de suas criações e recebam compensação financeira ou reconhecimento em público pelo uso de suas ideias ou produtos.

Outro ponto a se refletir é que a IAG pode ser usada para manipular a opinião pública, gerar desinformação e reforçar preconceitos, devido aos vieses presentes nos dados de treinamento dos modelos.

Para lidar com esses riscos, é importante que sejam estabelecidas diretrizes claras e um manual ético para orientar o uso responsável da IAG. Esse manual deve incluir orientações sobre transparência, regulamentação e uso educacional seguro, garantindo que a tecnologia seja utilizada de forma justa e benéfica para todos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.6 Algumas provocações na área da educação

Na FIAP, não é proibido usar a IAG para desenvolver os trabalhos acadêmicos, desde que haja alguma restrição direta dos avaliadores. Porém, nem sempre todos os trabalhos poderão ter consultas em todas as ocasiões. Isto é, em algum momento, haverá um teste individual do seu conhecimento adquirido ao longo da sua jornada.

Portanto, utilize a IAG como ferramenta de apoio, e não como substituto e o centro da discussão. Seja qual for a ferramenta, como o ChatGPT ou Gemini, o uso dela para a pesquisa, organização de ideias e esclarecimento de conceitos ajuda muito, mas não depender exclusivamente da IAG para gerar o conteúdo principal do trabalho é o mais importante. O objetivo da educação é desenvolver suas próprias habilidades de pensamento crítico e escrita.

É fundamental lembrar que, assim como citamos livros, artigos ou sites utilizados na elaboração de um trabalho, devemos também citar o uso da IAG, caso utilizada para gerar informações ou sugestões. Isso pode ser feito mencionando o uso da ferramenta, como “conteúdo sugerido pelo ChatGPT” ou algo semelhante. Isso demonstra transparência no uso da tecnologia.

Copiar e colar diretamente o que a IAG gerou sem realizar edições ou sem dar o devido crédito é um dos atos mais corriqueiros e falhos. O plágio é considerado uma violação ética grave, e a IAG pode criar textos semelhantes a outros existentes. Ao usar as ideias ou trechos gerados, reformule o conteúdo e adicione sua própria análise ou opinião.

Um exemplo concreto é o processo judicial aberto pelo jornal The New York Times contra a startup OpenIA (criadora do ChatGPT) e a Microsoft por violação de direitos autorais por utilizar seus artigos para alimentar seus modelos de IA.

Esse processo é a definição mais profunda do que é “plágio” e vai muito além de simplesmente copiar um texto e reutilizá-lo, pois estamos falando de uma entidade computacional que foi ensinada ou treinada com a propriedade intelectual de outrem disponível na Internet.

Esse cenário agrava ainda mais quando envolve prestação de serviços, cobrança de assinaturas, lucros e dividendos a partir desse treinamento não

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

autorizado, que é o que ChatGPT faz, sem recompensar o jornal. Esse é o objeto de acusação do processo.

Figura 4 - Fachada do jornal New York Times
Fonte: G1 (2023)

O uso ético da IAG requer usá-la para aprender e entender melhor um assunto, e não para criar respostas automáticas para avaliações ou testes. A tecnologia deve ser um apoio ao seu aprendizado, não um atalho para evitar o esforço necessário para desenvolver suas próprias habilidades.

A IAG pode fornecer informações incorretas ou desatualizadas. Sempre verifique a precisão e a confiabilidade das informações geradas pela IA cruzando com fontes acadêmicas e confiáveis. Isso é essencial para garantir que você está produzindo um trabalho de qualidade. Uma fonte segura de informação é o Google Acadêmico, que abrange apenas artigos e livros em suas pesquisas.

Em geral, deve-se verificar as políticas da escola ou universidade sobre o uso de IAG em trabalhos acadêmicos. Algumas instituições podem ter diretrizes específicas sobre como e quando a IA pode ser utilizada.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O uso da IAG deve complementar o seu processo de pensamento e ajudar a expandir suas ideias, e não as substituir. A certeza de que o seu trabalho final reflete sua própria compreensão e análise forjada do tema, mostra o seu desenvolvimento como estudante.

Em atividades como provas ou trabalhos que exigem exclusivamente seu conhecimento e esforço, não se deve utilizar a IAG sem a permissão explícita, porque isso pode ser considerado fraude e pode prejudicar sua integridade acadêmica.

Entender que a IAG não substitui o raciocínio humano é um ponto muito importante. Ela pode oferecer sugestões e direções, mas não substitui a criatividade, a originalidade e a capacidade de reflexão que o processo educacional espera de você.

Por fim, no contexto educacional, a proibição deve ser evitada, pois pode estimular o uso velado, o qual, apesar das ferramentas existentes, ainda é difícil de detectar com precisão. Ignorar o problema é se afastar de uma questão que requer atenção e soluções práticas. A principal questão a ser considerada é a ética, e isso exige, inicialmente, buscar informações, adquirir conhecimento, testar e refletir para tomar decisões mais adequadas.

1.7 Em busca da ética e não do viés

Para lidar tecnicamente com a base de dados e evitar vieses em sistemas de IAG, é necessário adotar uma série de medidas práticas e rigorosas no tratamento de dados, desenvolvimento de modelos e sua validação. É importante reforçar alguns pontos:

- Sempre busque variedade de fontes. A base de dados deve ser composta por dados de diversas fontes que representem diferentes contextos, populações, culturas, gêneros, raças e condições socioeconômicas. Isso reduz o risco de enviesamento em relação a grupos sub-representados.
- Cuide para que os dados estejam balanceados. Deve-se evitar que a base de dados contenha muito mais exemplos de uma categoria específica. Por exemplo, se um modelo de IA for treinado com muito mais dados de uma

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

população específica (como homens em comparação com mulheres), o modelo pode desenvolver viés em relação àquela população.

- Remova as informações irrelevantes ou sensíveis. Elimine informações que não são relevantes para a tarefa de IA, como atributos relacionados à raça, ao gênero, à etnia ou à religião, a menos que sejam estritamente necessários para a aplicação. Isso ajuda a prevenir decisões enviesadas baseadas nessas características.
- Tente passar um detector automático de viés. Ferramentas de Aprendizado de Máquina podem ser utilizadas para detectar padrões de viés em diferentes fases do pipeline de IA. Existem bibliotecas, como Fairlearn e IBM AI Fairness 360, que ajudam a identificar e mitigar vieses nos dados.
- Subamostragem e superamostragem são um problema. Caso o conjunto de dados seja desbalanceado, técnicas como subamostragem (reduzir a quantidade de dados de classes dominantes) ou superamostragem (aumentar os dados de classes minoritárias) podem ser usadas para equilibrar o dataset.
- Adote quando necessário a geração de dados sintéticos. Para complementar dados sub-representados, técnicas como SMOTE (Synthetic Minority Over-sampling Technique) podem ser utilizadas para gerar exemplos sintéticos e balancear o conjunto de dados.
- Validação contínua. Após o treinamento, realizar testes contínuos para verificar o desempenho do modelo em diferentes subgrupos da população. O desempenho consistente entre esses grupos é um indicador de que o modelo está menos enviesado.
- Tenha um conjunto de dados de teste representativos. Além de um conjunto de dados de treinamento diversificado, também é essencial ter um conjunto de teste diversificado para garantir que o modelo se comporte de maneira justa com todos os grupos.
- Elabore uma documentação clara sobre o seu sistema de IA. Deve-se manter uma documentação clara e detalhada sobre como os dados foram coletados, quais técnicas de balanceamento foram aplicadas e como o

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

modelo foi treinado. Isso aumenta a transparência e permite que outros revisem o processo para identificar possíveis pontos de melhoria.

- Tente usar métodos de explicabilidade como SHAP (Shapley Additive Explanations) ou LIME (Local Interpretable Model-agnostic Explanations) para garantir que as decisões do modelo possam ser interpretadas, ajudando a identificar se algum atributo está causando resultados enviesados.
- Garanta que a sua equipe de desenvolvimento e validação de IA seja diversificada em termos de origens e perspectivas, o que pode ajudar a identificar e mitigar vieses que talvez passassem despercebidos por um grupo homogêneo.
- Use feedback de usuários humanos para identificar possíveis problemas de viés que não foram detectados no estágio de desenvolvimento. Esse feedback pode ser valioso para ajustar o modelo e corrigir vieses.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 QUAL A DIFERENÇA ENTRE A IA GENERATIVA E A PREDITIVA?

Por que é importante saber a diferença entre elas? Primeiro porque muda a forma de criá-las, segundo, muda as aplicações. Em terceiro, muda a base de dados. E em quarto, muda o hardware necessário.

A IA Preditiva utiliza grandes volumes de dados históricos para prever resultados futuros. Ela trabalha com análise de tendências, padrões e modelagem de dados, usando métodos como regressão, redes neurais e árvores de decisão.

Após o treinamento, o modelo preditivo é validado e refinado até alcançar a precisão adequada, sendo implantado em ambientes de produção. A IA Preditiva ajuda corporações a tomarem decisões baseadas em dados, melhorando processos e gerando insights mais inteligentes ao longo do tempo.

Por outro lado, a IA Generativa é voltada para a criação de novos conteúdos, como imagens, textos e músicas. Ela utiliza modelos de aprendizado profundo e redes neurais para gerar dados originais, aprendendo com padrões em dados existentes. Isso a torna uma ferramenta poderosa em campos criativos e inovadores, auxiliando na resolução de novos problemas.

Embora distintas, as duas abordagens podem ser combinadas. Por exemplo, a IA Generativa pode criar dados para treinar modelos preditivos mais robustos, enquanto a IA Preditiva pode ajudar a projetar produtos com base em previsões de demanda.

2.1 Alguns modelos de IAG

Os modelos de IAG são treinados para gerar novos dados que imitam dados reais existentes, utilizando o aprendizado não supervisionado, isto é, como se fosse uma criança aprendendo agora, simulando a criatividade humana. Entre os modelos gerativos mais comuns estão:

- **Autoencodificadores Variacionais (VAEs):** são modelos de aprendizado profundo que codificam dados em um espaço comprimido e depois os

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

decodificam para gerar novas amostras, mantendo a similaridade com os dados originais. São utilizados para geração de imagens e dados sintéticos.

- **Redes Adversariais Gerativas (GANs):** consistem em dois modelos que competem entre si — um gerador cria dados (imagens, por exemplo), enquanto um discriminador tenta distinguir os dados gerados dos reais. São utilizados para criar imagens realistas, vídeos e até músicas.
- **Máquinas de Boltzmann Limitadas (RBMs):** são redes neurais estocásticas usadas para redução de dimensionalidade, classificação e geração de dados. Elas funcionam aprendendo padrões em dados não supervisionados e são utilizadas em sistemas de recomendação e filtragem colaborativa.
- **Modelos de Linguagem Baseados em Transformadores (Transformers):** são modelos de aprendizado profundo que utilizam mecanismos de atenção para processar grandes sequências de dados de texto de forma eficiente, gerando textos semelhantes aos humanos. Exemplos incluem o GPT, que é usado no ChatGPT.

O Processamento de Linguagem Natural (PLN), uma subárea da IA, está fortemente conectado aos Grandes Modelos de Linguagem (LLMs, do inglês Large Language Models). Esses modelos de IA são treinados com grandes volumes de texto e utilizam redes neurais avançadas para gerar ou prever conteúdos textuais. Eles são capazes de entender e processar a linguagem humana, identificando contexto e nuances de sentimento.

Vale ressaltar que os melhores modelos do mundo entendem mais o idioma inglês. Ou seja, quando tentamos utilizar esses modelos utilizando o português brasileiro, percebe-se falhas nas respostas e alucinações (respostas sem correlações com a pergunta enviada). Por isso, não se culpe pelas falhas do seu projeto, porque esse problema é seu e de todo o restante do mundo que não fala em inglês.

Os LLMs são uma evolução dos modelos de PLN, focados em prever a probabilidade de palavras ou frases e gerar textos coerentes e relevantes. Exemplos

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

de aplicações incluem assistentes virtuais, traduções automáticas, análises de sentimentos e recomendações personalizadas.

Além de gerar textos, a IAG também engloba sistemas de geração de imagens, como o famoso MidJourney, que utiliza um modelo de difusão para criar imagens realistas a partir de comandos textuais. O DALL-E é outro exemplo de aplicativo treinado para gerar imagens com base em descrições verbais.

2.2 Exemplo de alucinação

Um exemplo de geração de imagens que pode gerar alucinações, isto é, a IA devolve como resultado algo inesperado e errado. Foi dado o seguinte prompt ao ChatGPT:

- **Primeiro prompt:** *"Crie uma imagem de um telhado inundado usando água barrenta de chuva. A vista do telhado inundado precisa ser superior. Mostre dois lados do telhado. A resolução deve ser 1920 por 1080."*

  Resultado:

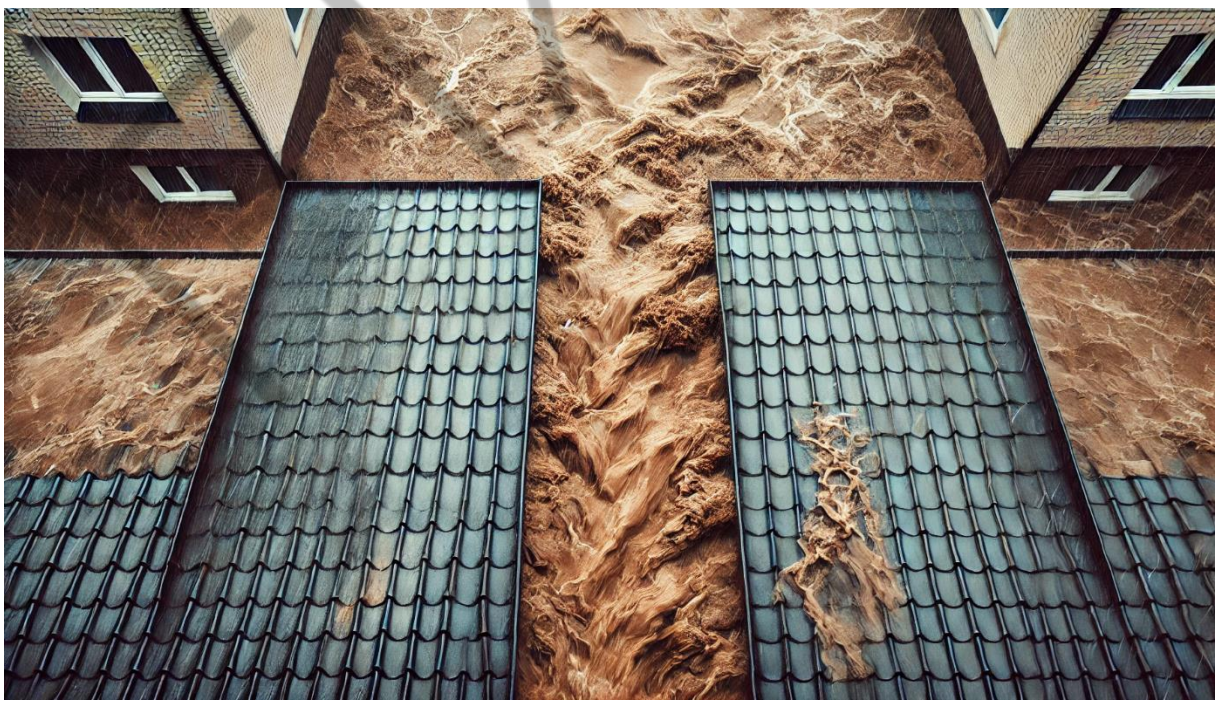

Figura 5 - Geração de imagem usando o primeiro prompt
Fonte: ChatGPT da OpenAI (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Segundo prompt:** *"Crie outra imagem de telhado inundado usando água barrenta de chuva. A vista do telhado inundado precisa ser superior de ângulo reto. Mostre um telhado usando telha romana do Brasil. A resolução deve ser 1920 por 1080. O telhado precisa ter uma cumeeira no centro e 2,40m de telha para cada lado. A água só pode estar no arredor do telhado. O telhado possui apenas 2 lados, direito e esquerdo."*

  Resultado:

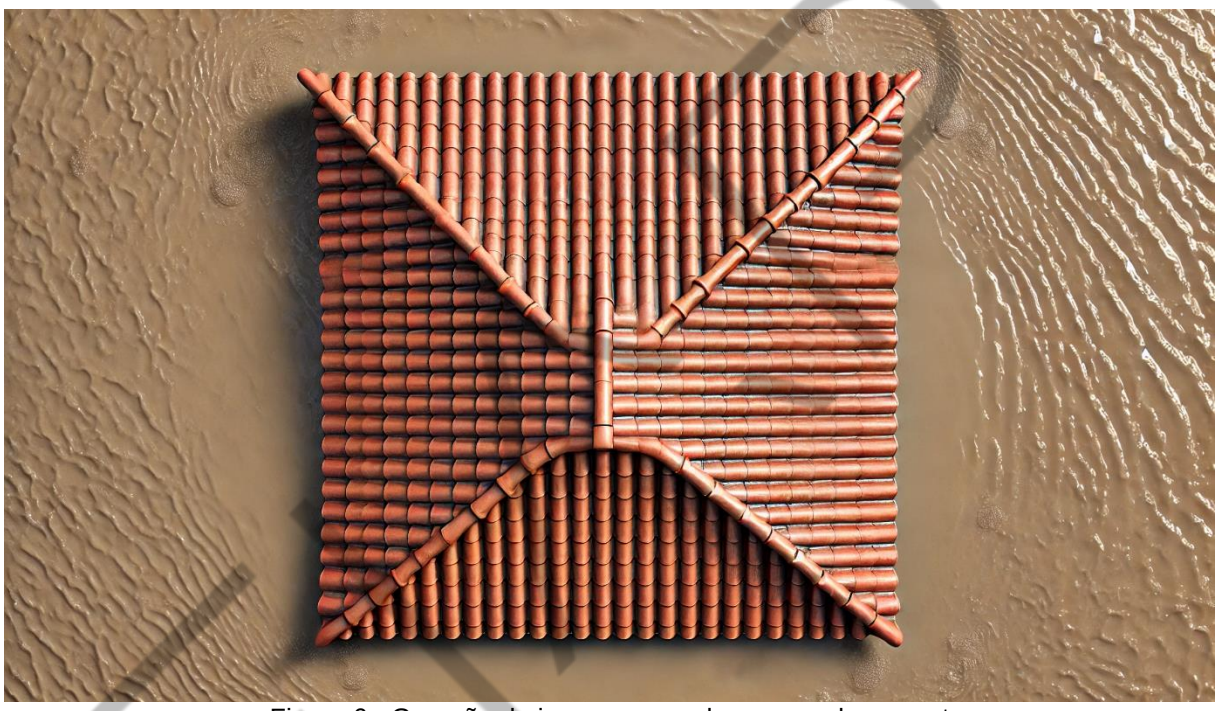

Figura 6 - Geração de imagem usando o segundo prompt
Fonte: ChatGPT da OpenAI (2024)

- **Terceiro prompt:** *"Usando essa mesma imagem, reduza a área do telhado e aumente a área da água."*

  Resultado:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Figura 7 - Geração de imagem usando o terceiro prompt
Fonte: ChatGPT da OpenAI (2024)

- **Quarto prompt:** *"Usando a mesma imagem, coloque apenas a água nos arredores do telhado do centro."*

  Resultado:

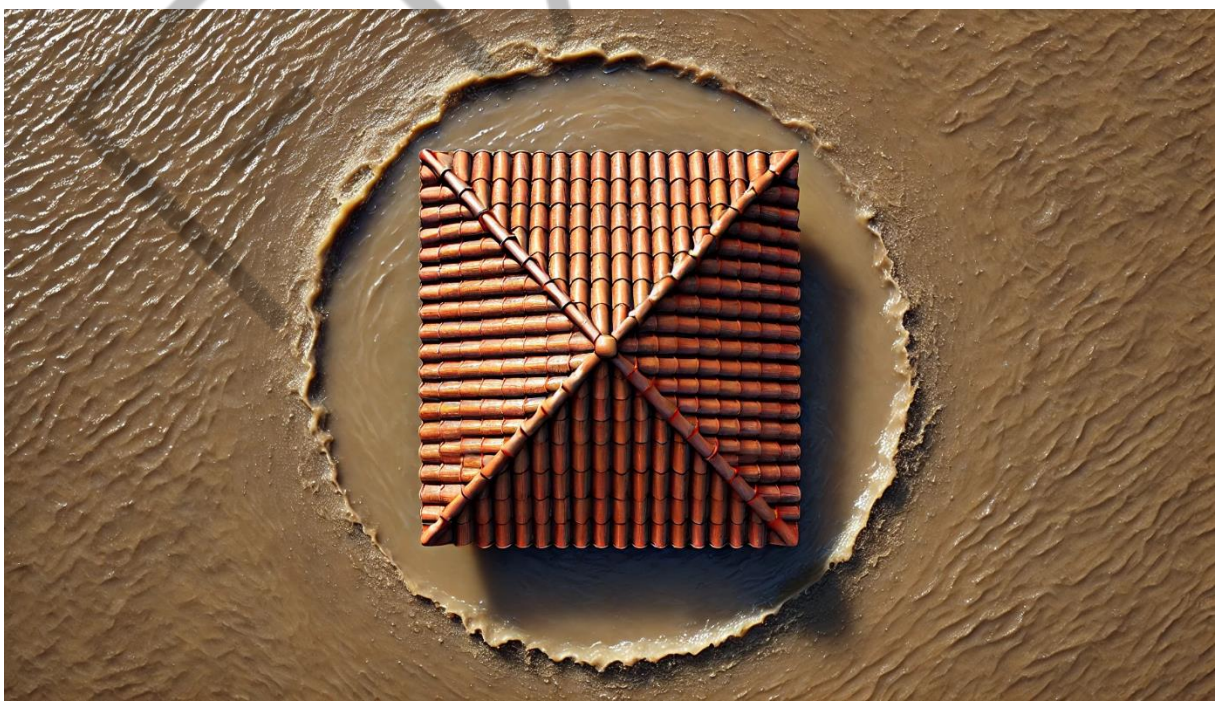

Figura 8 - Geração de imagem usando o quarto prompt
Fonte: ChatGPT da OpenAI (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Observe que houve uma alucinação na figura “Geração de imagem usando o quarto prompt”.

Portanto, pela evolução das imagens nota-se que os modelos de IAG, como o ChatGPT, podem alucinar em suas respostas e em resultados devido à forma como são treinados e operam. Essas alucinações ocorrem quando a IA gera informações incorretas ou inventa fatos que parecem plausíveis, mas não são verdadeiros.

Isso acontece por algumas razões principais:

- Os modelos IAG são treinados com enormes volumes de dados textuais disponíveis na Internet, que contêm informações corretas e incorretas. Eles aprendem padrões e associações entre palavras e frases, mas não têm a capacidade de verificar a veracidade dos dados. Como resultado, podem combinar informações de forma incorreta, gerando respostas que parecem precisas, mas não são.
- Esses modelos funcionam com base na probabilidade de sequência de palavras, ou seja, eles tentam prever a próxima palavra ou frase com base no que foi digitado até então. Quando a IA não tem informações suficientes ou exatas sobre o assunto, ela ainda gera uma resposta para continuar a conversa, e pode acabar “inventando” algo que parece lógico, mas não é baseado em fatos reais.
- Embora os modelos de IAG sejam muito avançados em gerar respostas que parecem compreensivas, eles não possuem compreensão real do conteúdo que estão gerando, isto é, eles (ainda) não “entendem” o mundo como os humanos. O modelo pode fazer conexões entre conceitos que não têm relação lógica ou factual, levando a respostas incoerentes ou falsas.
- Modelos de IAG são projetados para generalizar informações a partir dos dados com que foram treinados. Isso significa que, em situações específicas ou menos comuns, podem tentar aplicar regras gerais ou padrões observados em outros contextos, resultando em respostas imprecisas ou alucinações.
- Para mitigar as alucinações, é importante verificar as informações geradas pelo modelo com fontes confiáveis, além de treinar o modelo com dados de

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

alta qualidade e supervisionar o uso em contextos críticos. E o mais importante: integrar mecanismos que permitam ao modelo admitir incerteza quando a resposta não é clara e nem responder.

As alucinações são um desafio inerente à forma como os modelos de IAG operam. Por esta razão, o uso responsável e supervisionado desses modelos é essencial, especialmente em aplicações que exigem alta precisão.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 AS LEIS DA ROBÓTICA E DA IA CRIADAS

Para fomentar este cenário complexo discutido até aqui, existe uma quantidade de iniciativas normativas considerável que propõe regulamentações para a IA. Infelizmente, essas propostas geram uma sensação de insegurança jurídica, uma certa instabilidade e até sobreposições das próprias tentativas de normatização, pois parece que tais normatizações são criadas considerando apenas o prazer dos criadores ou empresas, visto que mudam as metodologias de normatização a cada novo lançamento.

Contudo, os princípios possuem um ponto em comum: quase todos se voltam à proteção dos humanos para evitar consequências nefastas do uso da tecnologia. E ao mesmo tempo, tentam maximizar os benefícios de seu uso e garantir que a tecnologia proporcionará melhoramentos e comodidade à condição humana.

Em Joon Moon (2023), foi feito um levantamento identificando que tais iniciativas de normatização datam desde 1942:

- As três leis da robótica, de Isaac Asimov (1942, EUA);
- Dez leis de Osamu Tezuka (1988, Japão);
- Declaração Mundial de Robôs Feira Internacional de Robôs de Fukuoka (2004, Japão);
- Carta de Ética para Robôs (2007, Coreia do Sul);
- As três leis da robótica responsável — do IEEE [Instituto de engenheiros elétricos e eletrônicos] (2009, Mundial);
- Cinco princípios éticos para a robótica do Conselho de Pesquisas em Engenharia e Ciências Físicas (EPSRC) e o Conselho de Pesquisa em Artes e Humanidades (AHRC, 2011, Reino Unido);
- Carta de Ética de Robôs (2012, Coreia do Sul);
- Oito leis da robótica de Shinpo Fumio — Keio University (2015, Japão);
- As Leis de Satya Nadella (2016, EUA);
- Princípios de Parceria em IA (2016, EUA);

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Três princípios para criar IA segura (ou IA compatível com humanos), de Stuart Russell (2017, EUA);
- Três Regras para Sistemas de Inteligência Artificial — do diretor executivo do Allen Institute for Artificial Intelligence (2017, EUA);
- Regras de Direito Civil sobre Robótica (2017, UE);
- 23 Princípios de Asilomar (2017, EUA);
- Os Princípios Gerais do Design Eticamente Alinhado — IEEE versão 2 (2017, Mundial);
- Princípios para transparência algorítmica e responsabilidade — USACM (2017, EUA);
- Diretrizes Éticas da Sociedade Japonesa para IA — da Japanese Society for Artificial Intelligence [JSAI] (2017, Japão);
- Princípios para a Governança da IA da The Future Society (2017, EUA e UE);
- Os dez principais princípios para a IA ética da UNI Global Union (2017, Mundial);
- Princípios da Política de IA do Instituto de Tecnológico de Informática [ITI] (2017, Mundial);
- Princípios de pesquisa e desenvolvimento (P&D) de IA — MIC (2017, Japão/G7);
- Princípios para a Era Cognitiva da IBM (2017, EUA);
- Desenvolvendo IA para Negócios com Cinco Princípios Fundamentais, da editora Sage (2017, Reino Unido);
- Código IA da Câmara dos Lordes (2017, Reino Unido);
- Três ideias da Iniciativa de IA centrada no ser humano de Stanford Human-Centered AI [HAI] (2018, EUA);
- Princípios Harmoniosos de IA — HAIP (2018, China);
- Diretrizes Universais para IA da Coalizão The Public Voice (2018, Mundial);

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Rascunho dos Princípios de Utilização de IA do MIC (2018, Japão);
- Princípios éticos e pré-requisitos democráticos, Grupo Europeu de Ética em Ciência e Novas Tecnologias [EGE] (2018, UE);
- Carta aberta à Comissão Europeia de IA e Robótica (2018, Europa);
- OpenAI Charter da OpenAI (2018, EUA);
- Práticas gerais recomendadas para IA da Google (2018, EUA);
- Microsoft responsible AI principles (2018, EUA); (xxxiv)
- Princípios para Confiança e Transparência IBM (2018, EUA);
- Princípios orientadores da empresa SAP para inteligência artificial (2018, Alemanha);
- Diretrizes de Ética de IA do Grupo Sony (2018, Japão);
- Declaração de Montreal pelo desenvolvimento responsável da IA (2018, Canadá);
- Princípios de IA da Organização para a Cooperação e Desenvolvimento Econômico (OCDE) (2019, Mundial);
- Recomendações sobre a inclusão da África subsaariana na ética global da IA (2019, África);
- Os oito princípios de ética da inteligência artificial (IA) da Austrália (2019, Austrália).

3.1 Compilado das normatizações

Fazendo um compilado de todas essas iniciativas de normatização dos sistemas de IA, verificamos que ao somar todos os documentos, chegamos nos seguintes tópicos e os respectivos subtópicos, além do percentual de citação de cada um deles:

- Privacidade (presente em 97% das iniciativas), e as suas variantes:
    - Consentimento (25%);

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Controle sobre uso de dados (42%);
- Restrição ao processamento de dados (11%);
- Direito de retificação (8%);
- Direito ao esquecimento (6%);
- Proteção de dados (17%);
- Outros princípios de privacidade (92%).

- Responsabilidade (97% dos documentos):
  - Verificabilidade e replicabilidade (36%);
  - Avaliações de impacto (53%);
  - Responsabilidade ambiental (17%);
  - Avaliação e fiscalização de resultados (47%);
  - Criação de corpo de monitoramento (17%);
  - Capacidade de apelação (22%);
  - Remediação de decisões automatizadas (11%);
  - Responsabilidade civil/legal (31%);
  - Recomendações para novas regulações (53%).

- Segurança e proteção (81% dos documentos):
  - Segurança (61%);
  - Proteção (67%).

- Transparência e explicabilidade (94% dos documentos):
  - Transparência (72%);
  - Explicabilidade (78%);
  - Código aberto e algoritmos (28%);

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Direito à informação (11%);
- Notificação de decisões de IA sobre indivíduos (19%);
- Notificação de interação com IA (25%);
- Relatórios periódicos (17%).

- Justiça e não discriminação (100% dos documentos):
  - Prevenção de vieses e não discriminação (89%);
  - Representatividade e dados de alta qualidade (36%);
  - Justiça (56%);
  - Equidade (25%);
  - Inclusividade no impacto (42%).

- Controle humano sobre a tecnologia (69% dos documentos):
  - Revisão humana de decisões automatizadas (33%);
  - Autoexclusão de decisões automatizadas (8%);
  - Controle humano sobre a tecnologia (64%).

- Responsabilidade profissional (78% dos documentos):
  - Acurácia (19%);
  - Design responsável (44%);
  - Consideração de efeitos a longo prazo (33%);
  - Colaboração multissetorial (64%);
  - Integridade científica (6%).

- Promoção de valores humanos (69% dos documentos):
  - Valores humanos e prosperidade (44%);

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Acesso à tecnologia (31%);
- Benefício para a sociedade (64%).

3.2 IAG consegue sentir?

A tecnologia apresenta tendência (ou pelos tenta) de antropomorfizar as IAs, ou seja, atribuir a elas características humanas, como emoções, moralidade e a capacidade de raciocínio ético.

Essa confusão surge principalmente após o avanço da IAG, que responde a comandos com uma prontidão e gentileza semelhantes às interações humanas, levando muitos a acreditar que as IAs podem “sentir” ou “pensar” como seres humanos.

Segundo os autores Li e Suh (2021) e Salles (2020), a antropomorfização das IAs distorce a compreensão de suas capacidades reais.

As IAs não possuem consciência ou intencionalidade; elas apenas simulam reações humanas com base em algoritmos e estatísticas, sem realmente entender o significado das respostas geradas.

Isso cria desafios significativos para a ética no uso de IA, especialmente em ambientes como a educação, onde a presença de IA pode enganar os usuários sobre suas reais limitações.

A reflexão aqui é: quais os impactos de tratar as IAs como entidades cognitivamente humanas?

3.3 IAG consegue mentir?

As IAGs podem ser acusadas de apresentar comportamentos similares ao ato de mentir. Afirma-se que elas podem iludir, desinformar e até mesmo enganar para concluir suas tarefas, o que se aproxima do comportamento humano de mentir.

Esse comportamento levanta preocupações éticas significativas. Segundo Santaella (2021), a mentira tem uma semântica complexa e precisa ser diferenciada de erros ou lapsos. A mentira envolve intencionalidade, com o objetivo de enganar, o

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

que a IAG não possui, pois carece de consciência e seu algoritmo matemático não possui essa natureza (ainda).

É fundamental distinguir entre propósito e intencionalidade. O propósito refere-se a uma ação dirigida a um fim, algo que até as IAGs podem ter. Porém, a intencionalidade requer uma dimensão psicológica, ligada à consciência, algo que a IA não tem.

Assim, enquanto as IAGs possuem um propósito, elas não podem ser intencionais, pois não têm autoconsciência. A IA pode ser utilizada por humanos de maneira ética ou antiética, mas sua matemática interna não lhe permite o comportamento deliberado de enganar, como no caso humano.

No entanto, falhas em seus bancos de dados ou algoritmos podem levar a resultados imprecisos, conhecidos como “alucinações”, o que muitas vezes se manifesta como respostas incorretas.

Embora a IA pareça responder de forma afetiva e rápida, como no caso do ChatGPT, essa afetividade é simulada. Ela não tem noção do que é verdade ou mentira, apenas gera respostas a partir dos dados com que foi treinada.

Portanto, a IA não está programada para dizer a verdade, mas sim para produzir conteúdo coerente baseado em seu treinamento. Isso não isenta os humanos de responsabilidade no uso dessas tecnologias para mentir ou enganar. Além disso, é possível que vieses nos dados e negligências dos desenvolvedores afetem os resultados da IA podendo, assim, atender a interesses duvidosos.

3.4 As IAs podem ser racistas?

Em 1990, Bayat Friedman e Helen Nissenbaum, citadas por Kaufman, Junquilho e Reis (2023, p. 44), foram pioneiras em apontar os riscos dos sistemas de computação tendenciosos e os possíveis impactos que eles poderiam causar na sociedade e nos direitos humanos.

Elas identificaram três tipos de vieses nesses sistemas: o preexistente, que surge das “instituições, práticas e atitudes sociais”, e não necessariamente da tecnologia propriamente dita; o técnico, que deriva das limitações operacionais dos

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

próprios sistemas; e o emergente, que aparece em situações ou contextos específicos durante o uso da nova tecnologia.

Um dos grandes desafios das IAs está justamente nesses vieses, muitos dos quais já existiam antes das próprias tecnologias. Isso ocorre porque os dados não são neutros e, portanto, podem carregar vieses.

Quando são utilizados para treinar algoritmos, esses dados podem refletir desigualdades, especialmente se forem predominantes entre públicos masculinos e de pele clara, como apontado por Kaufman, Junquilho e Reis (2023, p. 44-45), sem a devida diversidade em termos de raça, gênero, classe social ou região.

Um exemplo famoso de um viés problemático é o do algoritmo do Google Fotos que identificou erroneamente pessoas negras como gorilas. Quando o erro foi “corrigido”, o Google resolveu remover esse *label* da base do Google Fotos e passou a não identificar os gorilas (Garcia, 2016) até hoje, o que destaca o problema de dados mal higienizados, que, ao serem processados, acabam exacerbando o racismo estrutural presente na sociedade.

Com o avanço das IAGs, que automatizam a criação de textos e imagens cada vez mais realistas, esses problemas se intensificam, criando uma dissociação entre a fantasia e a realidade.

Além disso, grande parte dos dados utilizados para treinar essas IAs é gerada em países como os Estados Unidos e nações da União Europeia, regiões mais ricas e influentes. Os países do Sul Global, incluindo o Brasil, possuem menos recursos humanos e tecnológicos para competir com essas potências. Ao tentar adotar esses modelos sem realizar os ajustes adequados, pode resultar em problemas estrangeiros e fomentar preconceitos e estereótipos existentes na sociedade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

CONCLUSÃO

A IAG trouxe e continua trazendo um impacto profundo para a sociedade, oferecendo novas maneiras de criar conteúdo, automatizar processos e melhorar a eficiência em diversas áreas.

No entanto, a rapidez com que a tecnologia evoluiu também levantou uma série de questões éticas que precisam ser urgentemente discutidas e tratadas com seriedade.

O uso indiscriminado e sem regulamentação adequada da IAG pode gerar graves implicações, desde a criação de vieses até a desinformação, com efeitos que podem comprometer a integridade social e educacional.

A antropomorfização das IAs, que leva muitos a acreditar que elas possuem características humanas como emoções e intencionalidade, é uma distorção que pode dificultar a compreensão de suas capacidades e limitações.

Ao tratarmos a IAG como uma ferramenta, é essencial que entendamos suas restrições, como a falta de autoconsciência e a incapacidade de realmente compreender o mundo, impedindo que ela tenha responsabilidade moral em suas ações.

No entanto, as IAGs podem ser manipuladas por humanos para fins prejudiciais, como enganar, manipular ou desinformar.

A ética no uso da IAG é essencial, especialmente no contexto educacional, no qual o risco de fraude acadêmica aumenta consideravelmente com o uso dessas ferramentas.

Estudantes podem utilizar as IAs como o ChatGPT para gerar trabalhos sem esforço próprio, o que prejudica o processo de aprendizado e levanta dúvidas sobre a propriedade intelectual de suas criações.

Dessa forma, a implementação de diretrizes claras e de políticas que garantam o uso justo e responsável da IAG é essencial para evitar que sua adoção cause danos irreversíveis ao ambiente acadêmico.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Outro desafio fundamental é a presença de vieses nos sistemas de IAG, que muitas vezes refletem as desigualdades presentes nos dados utilizados para o treinamento dessas tecnologias.

A falta de diversidade nos dados, principalmente em termos de raça, gênero e classe social, pode resultar em algoritmos tendenciosos que reforçam preconceitos existentes. Isso se torna ainda mais preocupante quando esses sistemas são utilizados para tomar decisões em contextos críticos, como contratações, justiça e saúde.

Para mitigar esses problemas, é necessário adotar práticas rigorosas no tratamento de dados e no desenvolvimento de modelos de IAG. A validação contínua, o monitoramento de vieses e a utilização de dados representativos e balanceados são etapas essenciais para garantir que as IAs sejam justas e inclusivas.

Além disso, o treinamento de modelos com dados de alta qualidade, aliado ao uso de ferramentas de explicabilidade, pode ajudar a identificar e corrigir eventuais falhas no sistema.

Por fim, a IAG pode ser uma ferramenta poderosa para a inovação, desde que seja utilizada com responsabilidade. A transparência no desenvolvimento de algoritmos, o respeito à privacidade e à proteção de dados, bem como a responsabilidade profissional, são aspectos essenciais para garantir que os benefícios da tecnologia superem os riscos. A criação de regulamentações eficazes e a promoção de valores humanos são essenciais para que a IAG possa contribuir para o progresso social de maneira ética e sustentável.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

BENATTI, Mayara. Como utilizar chatbots para melhorar a interação dos usuários com seu site. **Rock Content**, 15 de janeiro de 2024. Disponível em: <https://rockcontent.com/br/blog/como-utilizar-chatbots-para-melhorar-a-interacao-dos-usuarios/>. Acesso em: 09 out. 2024.

DE OLIVEIRA, Laize Almeida *et al.* Inteligência artificial na educação: uma revisão integrativa da literatura. **Peer Review**, v. 5, n. 24, p. 248-268, 2023.

FIRAT, Mehmet. **How chat GPT can transform autodidactic experiences and open education?**. 2023.

GARCIA, Megan. Racist in the Machine. **World Policy Journal**, v. 33, n. 4, p. 111-117, 2016.

KAUFMAN, Dora; JUNQUILHO, Tainá; REIS, Priscila. Externalidades negativas da inteligência artificial: conflitos entre limites da técnica e direitos humanos. **Revista de Direitos e Garantias Fundamentais**, v. 24, n. 3, p. 43-71, 2023.

LI, Mengjun; SUH, Ayoung. Machinelike or humanlike? A literature review of anthropomorphism in AI-enabled technology. In: **54th Hawaii international conference on system sciences (HICSS 2021)**. 2021. p. 4053-4062.

MOON, Joon. **As regras das leis para humanos, não humanos e transhumanos (Código de Ur-Nammu, Três leis da Robótica e Princípios de Asilomar)**. Tese (Dissertação de Mestrado) – Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo. São Paulo, p. 206. 2023.

OPENAI. Crie uma imagem de um telhado inundado usando água barrenta de chuva. A vista do telhado inundado precisa ser superior. Mostre dois lados do telhado. A resolução deve ser 1920 por 1080. **GPT-4**, 2024. Inteligência Artificial. Disponível em: <https://chatgpt.com/>. Acesso em: 10 out. 2024.

OPENAI. Crie outra imagem de telhado inundado usando água barrenta de chuva. A vista do telhado inundado precisa ser superior de ângulo reto. Mostre um telhado usando telha romana do Brasil. A resolução deve ser 1920 por 1080. O telhado precisa ter uma cumeeira no centro e 2,40m de telha para cada lado. A água só pode estar no arredor do telhado. O telhado possui apenas 2 lados, direito e esquerdo. **GPT-4**, 2024. Inteligência Artificial. Disponível em: <https://chatgpt.com/>. Acesso em: 10 out. 2024.

OPENAI. Usando essa mesma imagem, reduza a área do telhado e aumente a área da água. **GPT-4**, 2024. Inteligência Artificial. Disponível em: <https://chatgpt.com/>. Acesso em: 10 out. 2024.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

OPENAI. Usando a mesma imagem, coloque apenas a água nos arredores do telhado do centro. **GPT-4**, 2024. Inteligência Artificial. Disponível em: <https://chatgpt.com/>. Acesso em: 10 out. 2024.

PINKER, Steven; PRINCE, Alan. On language and connectionism: Analysis of a parallel distributed processing model of language acquisition. **Cognition**, v. 28, n. 1-2, p. 73-193, 1988.

PRESSE, France. The New York Times processa OpenIA, criadora do ChatGPT, e Microsoft por violação de direitos autorais. **G1**, 27 dezembro de 2023. Disponível em: <https://g1.globo.com/tecnologia/noticia/2023/12/27/the-new-york-times-processa-openai-e-microsoft-por-violacao-de-direitos-autorais.ghtml>. Acesso em: 10 out. 2024.

SALLES, Arleen; EVERS, Kathinka; FARISCO, Michele. Anthropomorphism in AI. **AJOB neuroscience**, v. 11, n. 2, p. 88-95, 2020.

SANTAELLA, Lucia (Ed.). **Inteligência artificial & redes sociais**. São Paulo: EDUC – Editora da PUC-SP, 2021.

STUDIO wildlight. Um bebê chimpanzé com fundo branco. **Freep!k**, 12 de julho de 2023. Disponível em: <https://br.freepik.com/imagem-ia-premium/um-bebe-chimpanze-com-fundo-branco_48408344.htm>. Acesso em: 09 out. 2024.

YAO, Deborah. 25 Years Ago Today: How Deep Blue vs. Kasparov Changed AI Forever. **AI Business**, 11 de maio de 2022. Disponível em: <https://aibusiness.com/ml/25-years-ago-today-how-deep-blue-vs-kasparov-changed-ai-forever>. Acesso em: 09 out. 2024.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com