SAFRA DO CONHECIMENTO
CIBERNÉTICO - PRAGAS VIRTUAIS

DESVENDANDO INSIGHTS PREDITIVOS COM SÉRIES TEMPORAIS E DADOS ESPACIAIS

5

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 DESVENDANDO INSIGHTS PREDITIVOS COM SÉRIES TEMPORAIS E DADOS ESPACIAIS 3
1.1 Fundamentos estatísticos 4
1.2 Modelo Autorregressivo Espacial (SAR) 5
1.3 Regressão Geograficamente Ponderada (GWR) 6
2 SÉRIES TEMPORAIS 12
2.1 Estrutura de séries temporais 12
2.2 Aplicações das séries temporais no dia a dia 13
2.3 Séries temporais e sua relevância na Inteligência Artificial 14
2.4 Aplicação em R 16
REFERÊNCIAS 18

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 DESVENDANDO INSIGHTS PREDITIVOS COM SÉRIES TEMPORAIS E DADOS ESPACIAIS

A história dos modelos espaciais remonta à década de 1970, quando os estudos de econometria espacial começaram a ganhar destaque. Inicialmente desenvolvidos para lidar com dados econômicos e sociais que exibiam padrões espaciais, esses modelos evoluíram para enfrentar a complexidade dos dados geoespaciais e suas relações. Desde então, houve avanços significativos em termos de métodos computacionais, disponibilidade de dados e técnicas de modelagem. Os modelos atuais são capazes de lidar com conjuntos de dados maiores e mais complexos, além de oferecerem maior flexibilidade na modelagem de relações espaciais não lineares e heterogeneidade espacial.

Com o avanço da tecnologia e a disponibilidade de dados geoespaciais, a aplicação desses modelos se expandiu para diversas áreas como a Ciência da Computação, Engenharia de Software e Inteligência Artificial (IA). O uso crescente de sistemas de informação baseados em localização, redes e aplicativos móveis demanda uma compreensão aprofundada dos padrões espaciais para otimizar a alocação de recursos e melhorar a experiência do usuário. Essas melhorias permitem uma análise mais precisa e detalhada dos fenômenos espaciais, possibilitando uma aplicação mais ampla e sofisticada em diversas áreas.

Na inteligência artificial, os modelos espaciais desempenham um papel fundamental na análise e otimização de sistemas baseados em localização. O Modelo Autorregressivo Espacial (SAR) surgiu como uma extensão do modelo autorregressivo comum, visando lidar especificamente com a autocorrelação espacial. Por exemplo, a aplicação de modelos SAR e GWR em sistemas de GPS pode melhorar a precisão das previsões de tráfego, contribuindo para a roteirização eficiente de veículos de entrega. Da mesma forma, na análise de dados de redes sociais baseadas em localização, esses modelos podem ajudar a identificar comunidades geograficamente próximas e melhorar a personalização de conteúdo.

Ao longo deste capítulo, exploraremos em detalhes como esses modelos podem ser aplicados atualmente, destacando suas contribuições e implicações na análise e previsão de fenômenos espaciais em sistemas e aplicativos inteligentes.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.1 Fundamentos estatísticos

Na inteligência artificial, os fundamentos estatísticos desempenham um papel fundamental em várias áreas, desde o desenvolvimento e teste de sistemas até a otimização de sua eficiência e desempenho. Um dos conceitos estatísticos mais utilizados é a regressão linear, que permite modelar e entender as relações entre diferentes variáveis. Por exemplo, ao analisar o desempenho de um aplicativo inteligente, os profissionais de IA podem utilizar a regressão linear para prever como mudanças na capacidade do servidor ou no tamanho do banco de dados afetarão o tempo de resposta do sistema, sendo essencial para garantir que o aplicativo funcione de forma eficaz e atenda às expectativas dos usuários.

Os modelos lineares e espaciais são ferramentas distintas na análise estatística, cada uma com suas próprias características e pressupostos (Limongi, *et al*., 2023). Enquanto os modelos lineares tradicionais assumem independência entre as observações e não consideram a influência da localização geográfica, os modelos espaciais levam em conta a autocorrelação espacial, reconhecendo que valores semelhantes tendem a estar mais próximos no espaço. Os modelos lineares são adequados quando não há necessidade de considerar a proximidade geográfica entre os dados, sendo mais apropriados para análises onde a localização não desempenha um papel significativo. Por outro lado, os modelos espaciais são essenciais quando a proximidade geográfica é relevante, como em estudos ambientais, socioeconômicos ou de saúde pública, permitindo capturar padrões espaciais e realizar previsões mais precisas. A inclusão de informações de localização nos modelos espaciais não apenas aprimora a capacidade de previsão, mas também pode revelar *insights* sobre processos espaciais e tendências geográficas. Portanto, a escolha entre modelos lineares e espaciais depende da natureza dos dados e dos objetivos da análise, com cada abordagem oferecendo vantagens distintas na modelagem e interpretação de fenômenos complexos.

Um conceito importante é a autocorrelação espacial, que se refere à tendência de valores semelhantes estarem mais próximos no espaço geográfico. Na IA, este aspecto pode ser observado ao analisar a distribuição geográfica de erros de software

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

em uma rede de computadores. Por exemplo, em sistemas de manutenção preditiva, algoritmos de IA podem identificar padrões de falhas em diferentes regiões, levando em consideração tanto as variáveis temporais quanto espaciais. A utilização de modelos como o SAR e GWR pode auxiliar na detecção de áreas com maior propensão a falhas, enquanto métodos de séries temporais, como ARIMA (Modelo Autorregressivo Integrado de Médias Móveis), podem prever quando essas falhas provavelmente ocorrerão. Esse tipo de análise integrada é fundamental para otimizar a alocação de recursos e melhorar a eficiência operacional em redes complexas e distribuídas. Compreender a autocorrelação espacial é relevante para identificar padrões e tendências nos dados, o que pode ajudar os profissionais de IA a diagnosticar problemas e tomar medidas corretivas de forma mais eficaz. A localização geográfica dos dados pode fornecer *insights* valiosos sobre o comportamento dos usuários, padrões de uso de aplicativos e demanda por recursos computacionais em diferentes regiões. Por exemplo, ao projetar sistemas de entrega de alimentos ou transporte, é essencial considerar a localização dos usuários para otimizar rotas e garantir uma entrega eficiente.

Ao integrar esses fundamentos estatísticos na inteligência artificial, os profissionais podem tomar decisões mais informadas e projetar sistemas mais adaptáveis e eficientes. Afinal, não melhora apenas a experiência do usuário, mas também contribui para o desenvolvimento de soluções de softwares e aplicativos inteligentes mais robustos e eficazes em uma ampla gama de contextos geográficos e de uso.

1.2 Modelo Autorregressivo Espacial (SAR)

O Modelo Autorregressivo Espacial (SAR) é uma técnica estatística utilizada para modelar a relação entre uma variável dependente e suas variáveis independentes, levando em consideração a autocorrelação espacial (Limongi, *et al*., 2023). É formulado como uma extensão do modelo autorregressivo comum, incorporando termos de autocorrelação espacial para capturar a dependência entre observações em locais geograficamente próximos. Esta abordagem permite uma análise mais precisa e abrangente de dados espaciais, especialmente em contextos em que a localização geográfica desempenha um papel significativo. O SAR tem suas

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

raízes na econometria espacial, onde foi desenvolvido para lidar com a dependência espacial nos dados econômicos e sua formulação matemática envolve a incorporação de termos de autocorrelação espacial, levando em consideração a influência dos valores vizinhos ao prever uma variável dependente.

A interpretação dos parâmetros do SAR é fundamental para compreender como cada variável afeta o valor da variável dependente dentro do contexto espacial (Ignacio, 2016). Pode ser utilizado, ainda, para prever padrões de demanda de aplicativos em diferentes regiões geográficas, auxiliando no dimensionamento de servidores e na otimização de recursos.

O modelo SAR é definido como: $[Y = \backslash rho\, WY + X\backslash beta + \backslash varepsilon]$ onde:

- (Y) é a variável dependente;
- (\rho) é o coeficiente espacial autorregressivo (medida de correlação espacial);
- (W) é a matriz de vizinhança espacial;
- (X) são as variáveis independentes;
- (\beta) são os coeficientes de regressão;
- (\varepsilon) é o termo de erro.

1.3 Regressão Geograficamente Ponderada (GWR)

A Regressão Geograficamente Ponderada (GWR) é uma técnica estatística que visa modelar a relação entre uma variável dependente e suas variáveis independentes, considerando a variação espacial das relações. Similar ao SAR, a GWR é formulada como uma extensão da regressão linear comum, porém, incorpora uma ponderação espacial localizada para capturar a variação nos efeitos das variáveis independentes sobre a variável dependente em diferentes locais geográficos. Essa abordagem permite uma análise mais detalhada e sensível às nuances espaciais dos dados, sendo particularmente útil em contextos em que a localização geográfica desempenha relevância preditiva.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A GWR tem suas raízes na mesma tradição da econometria espacial, onde foi desenvolvida para lidar com a variação espacial nos dados econômicos e sociais. Sua formulação matemática incorpora uma função de ponderação espacial que atribui pesos diferentes às observações com base em sua proximidade geográfica, levando em consideração a influência das características locais ao modelar a variável dependente.

A interpretação dos parâmetros da GWR é essencial para compreender como cada variável independente afeta a variável dependente de forma diferenciada em diferentes locais geográficos. Além disso, a GWR pode ser aplicada para prever padrões locais de comportamento ou demanda, como o consumo de produtos em diferentes regiões, auxiliando na tomada de decisões e estratégias de negócios adaptadas a cada localidade.

O modelo GWR é definido como: $Yi = \beta 0(ui, vi) + \sum j = 1k\beta j(ui, vi)Xij + \varepsilon i$, em que Y representa a variável dependente de uma localidade “i”; β0 representa os coeficientes de regressão para interceptação e cada variável independente, respectivamente na localidade “i”; X_{ij} representa o valor da variável independente “j” na localidade “i”; e εi representa o termo do erro na localidade “i”. A formulação permite que os coeficientes de regressão variem espacialmente, adaptando-se às condições locais e capturando melhor a complexidade dos dados espaciais.

A aplicação da GWR no contexto da IA pode ser relevante para entender e prever padrões de demanda por aplicativos ou serviços em diferentes regiões geográficas. Ao considerar a variação espacial das relações entre as variáveis independentes e a variável dependente, a GWR pode fornecer *insights* sobre como as características locais, como infraestrutura de rede, densidade populacional e preferências culturais, influenciam o uso e a adoção de aplicativos específicos (Ignacio, 2016). Permite uma alocação mais eficiente de recursos, como servidores e equipes de suporte, bem como uma adaptação mais precisa das estratégias de desenvolvimento e marketing para atender às necessidades específicas de cada região.

Tanto o modelo autorregressivo espacial quanto a regressão geograficamente ponderada são técnicas estatísticas para lidar com dados espaciais e capturar a variação espacial nas relações entre variáveis. Enquanto o SAR se concentra em

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

modelar a autocorrelação espacial globalmente, considerando a dependência entre todas as observações geograficamente próximas, a GWR leva em conta a variação espacial localizada, permitindo que os coeficientes de regressão variem de acordo com a localidade. Em outras palavras, o SAR assume que a relação espacial é uniforme em todo o conjunto de dados, enquanto a GWR reconhece que essa relação pode variar de acordo com o local geográfico. Portanto, a escolha entre esses modelos depende da natureza dos dados e do objetivo da análise. O SAR é mais apropriado quando se deseja capturar a autocorrelação espacial de forma geral, enquanto a GWR é mais adequada para analisar padrões espaciais locais e heterogeneidade nas relações entre variáveis. Ambos os modelos possuem suas aplicações e podem fornecer *insights* valiosos em diferentes contextos analíticos e de pesquisa.

Os vizinhos mais próximos desempenham um papel fundamental nos modelos SAR e GWR ao capturar a estrutura espacial dos dados. No contexto do SAR, a matriz de pesos espaciais, derivada dos vizinhos mais próximos, permite modelar a autocorrelação espacial, considerando a dependência entre observações em locais geograficamente próximos. Isso é essencial para analisar e prever fenômenos que exibem padrões espaciais, como distribuição de doenças ou crimes urbanos, onde a influência de observações vizinhas é significativa. Da mesma forma, no GWR, os vizinhos mais próximos são utilizados para calcular ponderações locais, permitindo que o modelo capture variações espaciais nas relações entre variáveis dependentes e independentes. Essas ponderações locais refletem a heterogeneidade espacial dos dados, possibilitando previsões mais precisas e contextuais em diferentes regiões geográficas. Portanto, a seleção adequada dos vizinhos mais próximos é importante para a eficácia e interpretabilidade desses modelos, pois influencia diretamente na captura da estrutura espacial dos dados e na qualidade das previsões realizadas.

Agora, vamos a uma aplicação na Linguagem R envolvendo os modelos discutidos:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```R
# Carregar bibliotecas
library(spdep)
library(spgwr)
library(VIM)  # (opcional)

# Carregar dados
data("columbus")

# Selecionar variáveis
crime <- columbus$CRIME
inc <- columbus$INC
hoval <- columbus$HOVAL

# Assumir coordenadas nas primeiras duas colunas
coords <- columbus[, 1:2]

# Verificar e tratar valores ausentes (opcional)
if (any(is.na(coords))) {
  # Imputar valores ausentes usando knnImpute (considere métodos alternativos)
  coords <- knnImpute(coords)
  # Como alternativa, remova as linhas com coordenadas ausentes:
  # coords <- na.omit(coords)
}

# Calcular k-vizinhos mais próximos (k = 5)
nn <- dnearneigh(coords, k = 5, longlat = FALSE, d1 = 0, d2 = max(dist(coords)))

# Calcular k-vizinhos mais próximos (k = 5)
nn <- knn2nb(knearneigh(coords, k = 5, longlat = FALSE))

# Criar lista de vizinhos
nb <- nb2listw(nn)
```

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Modelo SAR
sar_model <- lagsarlm(crime ~ inc + hoval, data = columbus, listw = nb)

# Adicionar coordenadas ao conjunto de dados
coordinates(columbus) <- c("X", "Y")

# Modelo GWR
gwr_model <- gwr(crime ~ inc + hoval, data = columbus, bandwidth = 0.5)

# Resumo do modelo SAR
summary(sar_model)

# Resumo do modelo GWR
summary(gwr_model)
```

Este script demonstra como realizar regressões espaciais em R usando os pacotes spdep, spgwr e VIM. As principais etapas do script são:

1. Carregar bibliotecas:

- **spdep:** fornece funções para análise espacial em R.
- **spgwr:** fornece funções para regressão ponderada geograficamente (GWR).
- **VIM:** fornece funções para imputação de valores ausentes (opcional).

2. Carregar dados:

   O conjunto de dados columbus é usado para ilustrar as regressões espaciais. Este conjunto de dados contém informações sobre crimes, renda e valor de imóveis em Columbus, Ohio.

3. Selecionar variáveis:

   As variáveis crime (taxa de criminalidade), inc (renda familiar) e hoval (valor de imóveis) são selecionadas para a análise.

4. Assumir coordenadas:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

As primeiras duas colunas do conjunto de dados são assumidas como coordenadas espaciais.

5. Verificar e tratar valores ausentes (opcional):

   Se houver valores ausentes nas coordenadas, eles podem ser imputados usando a função knnImpute do pacote VIM. Como alternativa, as linhas com coordenadas ausentes podem ser removidas.

6. Calcular vizinhos mais próximos:

   A função dnearneigh do pacote spdep é utilizada para calcular os k-vizinhos mais próximos (k = 5) para cada ponto espacial.

7. Criar lista de vizinhos:

   A função knn2nb do pacote spdep é útil quando desejamos converter a lista de k-vizinhos mais próximos em uma lista de pesos espaciais.

8. Modelo SAR (Regressão Autorregressiva Espacial):

   A função lagsarlm do pacote spdep é usada para ajustar um modelo SAR com a variável crime como variável dependente e as variáveis inc e hoval como variáveis explicativas.

9. Modelo GWR (Regressão Ponderada Geograficamente):

   A função gwr do pacote spgwr é usada para ajustar um modelo GWR com a variável crime como variável dependente e as variáveis inc e hoval como variáveis explicativas. A largura de banda do modelo GWR é definida como 0.5.

10. Resumo dos modelos:

    As funções summary são utilizadas para apresentar os resultados dos modelos SAR e GWR.

Observações:

Este script é um guia básico para regressões espaciais em R. Para análises mais complexas, consulte a documentação dos pacotes spdep, spgwr e VIM. A escolha do modelo de regressão espacial mais adequado depende da natureza dos dados e dos objetivos da análise.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 SÉRIES TEMPORAIS

Séries temporais são um conjunto de dados sequenciais coletados ou registrados ao longo do tempo, geralmente em intervalos regulares, ou seja, os dados são observados em instantes ordenados do tempo (Bussab; Morettin, 2017). Esses dados são utilizados para analisar e prever padrões ou tendências, e podem ser utilizados em diversas áreas como economia, finanças, meteorologia, engenharia, saúde, entre outras. A característica fundamental das séries temporais é a dependência dos dados no tempo, isso significa que observações passadas podem fornecer informações valiosas para prever eventos futuros.

2.1 Estrutura de séries temporais

Uma série temporal pode ser analisada em quatro componentes principais:

- **Tendência (trend):** é a direção geral que a série temporal segue ao longo de um período mais extenso. Pode ser crescente, decrescente ou estacionária.
- **Sazonalidade (seasonality):** refere-se aos padrões que se repetem periodicamente, como flutuações anuais ou mensais. Por exemplo, o aumento das vendas de brinquedos em dezembro.
- **Ciclo (cycle):** padrões cíclicos que ocorrem ao longo de períodos irregulares, como flutuações econômicas ou crises financeiras.
- **Ruído (noise):** variabilidade aleatória que não pode ser explicada pelos outros componentes.

Ao identificar essas características, é possível construir modelos matemáticos e computacionais para prever futuros comportamentos com base no histórico de dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.2 Aplicações das séries temporais no dia a dia

O uso de séries temporais é vasto e impacta diretamente vários setores da economia e do mercado de trabalho. Entre as principais aplicações, destacam-se:

- **Previsão de demanda:** um dos usos mais comuns é prever a demanda por produtos e serviços. Por exemplo, no varejo, as empresas utilizam séries temporais para prever a demanda futura com base em dados de vendas passadas, ajustando estoques e otimizando a logística. Isso evita tanto o excesso de estoque quanto a falta de produtos.
- **Mercado financeiro:** no mundo financeiro, séries temporais são usadas para analisar e prever o comportamento de preços de ações, taxas de câmbio, juros e outros indicadores econômicos. Modelos como o ARIMA são amplamente utilizados para prever movimentos no mercado, ajudando investidores a tomar decisões estratégicas.
- **Controle de processos industriais:** em fábricas e indústrias, dados coletados ao longo do tempo em máquinas e processos podem ser usados para monitorar o desempenho e prever falhas. O monitoramento de séries temporais permite que engenheiros identifiquem padrões anômalos e realizem manutenção preditiva, reduzindo tempo de inatividade e custos de manutenção.
- **Meteorologia e climatologia:** a previsão do tempo é baseada em grandes volumes de dados históricos, como temperatura, precipitação e pressão atmosférica. A análise de séries temporais é fundamental para prever condições climáticas futuras, o que é essencial para setores como agricultura, energia e transporte.
- **Saúde:** na área da saúde, séries temporais são usadas para monitorar a evolução de pacientes, analisar a propagação de doenças e prever surtos futuros. Durante a pandemia de COVID-19, por exemplo, modelos de séries temporais foram amplamente utilizados para prever o número de casos e orientar políticas de saúde pública.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

No mercado de trabalho atual, a habilidade de trabalhar com séries temporais tornou-se cada vez mais valiosa, especialmente com o crescente uso de dados nas empresas. Profissionais com capacidade de analisar e modelar dados temporais são altamente demandados em várias áreas:

- **Analistas de dados e cientistas de dados:** empresas que dependem de grandes volumes de dados para tomada de decisão buscam especialistas que possam analisar e prever tendências utilizando séries temporais. Isso é essencial para otimizar processos, entender comportamentos de consumidores e ajustar estratégias de marketing.
- **Economistas e consultores financeiros:** compreender o comportamento de mercados ao longo do tempo e prever mudanças futuras é uma habilidade fundamental para economistas e consultores. A análise de séries temporais permite modelar a evolução de variáveis econômicas e financeiras, ajudando a prever crises e oportunidades.
- **Engenheiros de manutenção e operação:** profissionais que trabalham com sistemas industriais complexos precisam prever falhas de equipamentos e otimizar o tempo de operação. O uso de séries temporais permite a criação de sistemas de manutenção preditiva, que melhoram a eficiência e reduzem custos operacionais.
- **Especialistas em logística e cadeia de suprimentos:** a análise de dados de demanda ao longo do tempo é vital para gerenciar estoques, planejar rotas de entrega e prever necessidades futuras. Empresas de transporte e varejo, por exemplo, precisam de especialistas que possam prever picos de demanda e ajustar suas operações de acordo.

2.3 Séries temporais e sua relevância na Inteligência Artificial

Na área de IA, as séries temporais desempenham um papel crucial, especialmente no desenvolvimento de sistemas preditivos e de tomada de decisão. A integração de IA com modelos de séries temporais possibilita uma análise mais precisa e automatizada de grandes volumes de dados ao longo do tempo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Previsão de modelos financeiros automatizados:** a IA, em conjunto com modelos de séries temporais, pode automatizar a análise de dados financeiros, aprendendo padrões complexos e fazendo previsões mais precisas. Redes neurais recorrentes (RNNs), como Long Short-Term Memory (LSTM), são úteis para lidar com dependências temporais, capturando relações não lineares nos dados.
- **Detecção de anomalias em tempo real:** os sistemas de IA podem monitorar continuamente fluxos de dados temporais para identificar anomalias e eventos incomuns. Em áreas como segurança cibernética e monitoramento industrial, essa capacidade é fundamental para detectar falhas ou ataques antes que eles causem danos significativos.
- **Reconhecimento de padrões em sinais biomédicos:** na área da saúde, algoritmos de IA que analisam séries temporais de sinais biomédicos (como eletrocardiogramas ou monitoramento de glicose) podem prever crises de saúde iminentes e alertar pacientes ou médicos com antecedência.
- **Previsão de tráfego e mobilidade urbana:** os modelos de IA que integram dados de séries temporais ajudam a prever o fluxo de tráfego em cidades, ajustando semáforos e otimizando rotas de transporte público. Esses sistemas tornam-se cada vez mais eficientes à medida que aprendem com dados históricos e em tempo real.

Séries temporais são ferramentas poderosas para análise e previsão, sendo aplicadas em uma ampla gama de setores, desde o financeiro até o industrial e o de saúde. A capacidade de identificar padrões e prever eventos futuros a partir de dados históricos é crucial para o mercado de trabalho moderno, que valoriza profissionais capazes de usar dados de maneira estratégica. Com o avanço da inteligência artificial, as aplicações de séries temporais se expandem, tornando-se ainda mais precisas e impactantes. Por isso, o conhecimento e a expertise em trabalhar com séries temporais são habilidades essenciais para aqueles que buscam se destacar no campo da análise de dados e da inteligência artificial.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.4 Aplicação em R

Para entendermos os componentes que formam a Série Temporal (Z), utilizamos um procedimento estatístico chamado de Decomposição.

A decomposição pode ser:

- Aditiva: Z = T + S + E
- Multiplicativa: Z = T . S . E (Componentes ≠ 0)

Em que:

- T = Componente Tendência.
- S = Componente Sazonal.
- E = Componente Ruído Branco (erro).

Entre os objetivos da decomposição podemos citar:

- Reduzir a série temporal em componentes que sejam simples de serem modelados.
- Obter a série sem a tendência ou sem a sazonalidade (dessazonalizada).
- Utilizando o dataset AirPassengers do R, analise a série temporal por:
  a) Decomposição aditiva.
  b) Decomposição multiplicativa.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Puxando o dataset:

data("AirPassengers")

# Para saber mais sobre este dataset, digite:

?AirPassengers

# Colocando o dataset dentro de um objeto X:

X <- AirPassengers

# a) Fazendo a Decomposição Aditiva:

dec <- decompose(X, type = "a")

plot(dec)

# b) Fazendo a Decomposição Multiplicativa:

dec <- decompose(X, type = "m")

plot(dec)
```

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

LIMONGI, R., RONQUI, R. M., Coelho, P. P., & de Rezende Francisco, E. (2023). No public surveys, no data? A proposal for income forecast in brazilian municipalities. **Revista Ibero-Americana de Estratégia**, 22(1), e22993-e22993.

MORETTIN, P. A.; DE O. BUSSAB, W. **Estatística básica**. 9. ed. [*s.l.*] Saraiva Uni, 11 julho 2017.

NIELSEN, A. **Análise Prática de Séries Temporais:** Predição com Estatística e Aprendizado de Máquina. 1. ed. [*s.l.*] Alta Books, 27 outubro 2021.

SARMIENTO-BARBIERI, Ignacio. An introduction to Spatial Econometrics in R. University of Illinois. **Econ.uiuc**. Disponível em: <http://www.econ.uiuc.edu/~lab/workshop/Spatial_in_R.html>. Acesso em: 19 set. 2024.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com