FIAP ON

SAFRA DO CONHECIMENTO
CIBERNÉTICO - PRAGAS VIRTUAIS

MODELAGEM DE DADOS COM REGRESSÃO SUPERVISIONADA

13

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Diferença ilustrada de classificação e regressão 6
Figura 2 - Exemplo de regressão 7
Figura 3 - Exemplo de regressão 9
Figura 4 - Fórmula do MAE 14
Figura 5 - Fórmula do MSE 14
Figura 6 - Fórmula do RMSE.....15
Figura 7 - Fórmula do R^2 Score.....15
Figura 8 - Comparação da qualidade do ajuste da reta (R^2) 16
Figura 9 - Regressão linear simples.....19
Figura 10 - Método hold-out 26
Figura 11 - Método K-fold.....27
Figura 12 - Método leave-one-out 28
Figura 13 - Método K-fold estratificado 28
Figura 14 - Combinação de Hold-out com K-fold 30
Figura 15 - Exemplo de uso de Pipelines do Sklearn.....32
Figura 16 - Saída do código-fonte 1 34
Figura 17 - Saída do código-fonte 2 35
Figura 18 - Saída do código-fonte 3 36
Figura 19 - Saída do código-fonte 4 37
Figura 20 - Saída do código-fonte 5 37
Figura 21 - Saída do código-fonte 6 38
Figura 22 - Saída do código-fonte 7 39

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE QUADROS

Quadro 1 - Vantagens e desvantagens do XGBoost.....22

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 - Imports e leitura do dataset 34
Código-fonte 2 - Informações gerais da base.....34
Código-fonte 3 - Informações gerais da base.....35
Código-fonte 4 - Construindo modelo de regressão simples.....36
Código-fonte 5 - Construindo o gráfico da regressão linear simples 37
Código-fonte 6 - Construindo um modelo da regressão linear múltipla.....38
Código-fonte 7 - Imprimindo coeficientes e intercept da regressão múltipla 39

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 MODELAGEM DE DADOS COM REGRESSÃO SUPERVISIONADA.....6
1.1 Introdução 6
1.1.1 Intuição da regressão.....6
1.1.2 Relação entre regressão e classificação.....8
2 APLICAÇÕES 10
2.1 Educação: Prevendo o desempenho acadêmico 10
2.2 Financeiro: Prevendo riscos de crédito 10
2.3 Agronegócio: Estimando a produção agrícola.....11
2.4 Saúde: Predição de progressão de doenças.....11
2.5 Imobiliário: Estimativa de preços de propriedades 11
2.6 Transportes: Previsão de demanda e tempo de viagem 12
3 AVALIAÇÃO DE DESEMPENHO.....13
3.1 Métricas de avaliação.....13
3.1.1 Erro Absoluto Médio.....14
3.1.2 Erro Quadrático Médio 14
3.1.3 Raiz Quadrada do Erro Quadrático Médio 15
3.1.4 R^2 Score 15
3.1.5 Outras métricas 16
3.2 Escolhendo a métrica ideal para o problema 16
4 PRINCIPAIS ALGORITMOS 18
4.1 Regressão Linear 18
4.2 Regressão Linear Múltipla.....19
4.3 XGBoost (caso de regressão) 21
4.3.1 Funcionamento do algoritmo.....21
4.3.2 Vantagens e desvantagens do método 21
4.3.3 Parametrização e influência no resultado.....22
4.4 Demais algoritmos.....23
5 CONSTRUINDO MODELOS PREDITIVOS MAIS ROBUSTOS 25
5.1 Validação cruzada.....25
5.1.1 Método Hold-Out 26
5.1.2 Método K-Fold.....26
5.1.3 Método Leave-One-Out.....27
5.1.4 Método K-Fold Estratificado 28
5.2 Uso da validação cruzada 29
5.3 Implementando pipelines.....30
6 HANDS ON: ANÁLISES PREDITIVAS DE REGRESSÃO 33
6.1 Sobre a base de dados 33
6.2 Implementando nossa análise.....33
REFERÊNCIAS.....40
GLOSSÁRIO 42

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 MODELAGEM DE DADOS COM REGRESSÃO SUPERVISIONADA

1.1 Introdução

Nem todo problema preditivo pode ser resolvido com respostas binárias ou categóricas. Em muitos casos, precisamos prever um **valor contínuo**, como a temperatura do dia, o preço de uma casa ou a demanda futura de um produto. Considerando esses casos, os modelos de classificação não são suficientes. É neste momento que entra a regressão, uma abordagem que prevê valores numéricos a partir das features.

1.1.1 Intuição da regressão

A intuição por trás de um modelo de regressão é encontrar uma relação matemática entre as variáveis de entrada e a saída contínua. Enquanto os modelos de classificação se concentram em atribuir um rótulo a um conjunto de características (representada por uma região do espaço das features), os modelos de regressão buscam identificar padrões que permitam prever uma quantidade específica. Em vez de dizer se um cliente comprará ou não um produto, um modelo de regressão estima, por exemplo, quanto ele gastará.

Observe a figura:

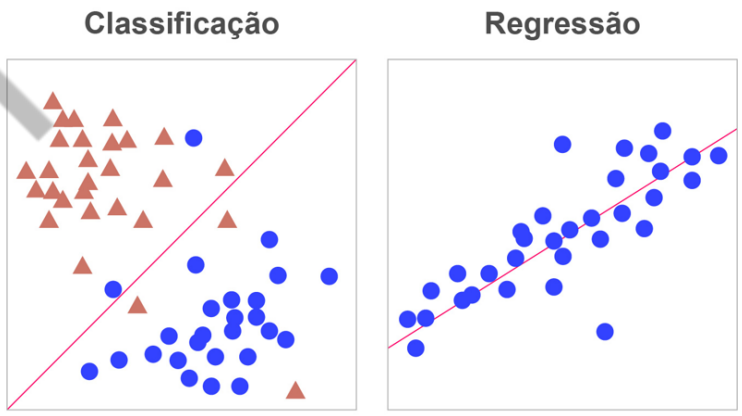

Figura 1 - Diferença ilustrada de classificação e regressão
Fonte: Lean Saúde (2022), adaptado por FIAP (2024)

Criar um modelo de regressão é, essencialmente, encontrar uma tendência na dispersão dos pontos em um conjunto de dados. Imagine um gráfico onde cada ponto

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

representa uma combinação de características e seu valor numérico associado, a tarefa da regressão é traçar uma linha ou curva que melhor representa essa tendência geral. Na figura “Exemplo de regressão”, o modelo preditivo mostra a relação entre a variável independente “Propaganda” (eixo X), e a variável dependente “Vendas” (eixo Y). Os pontos são os exemplos que a máquina usa para aprender, e o modelo, no caso, é uma reta.

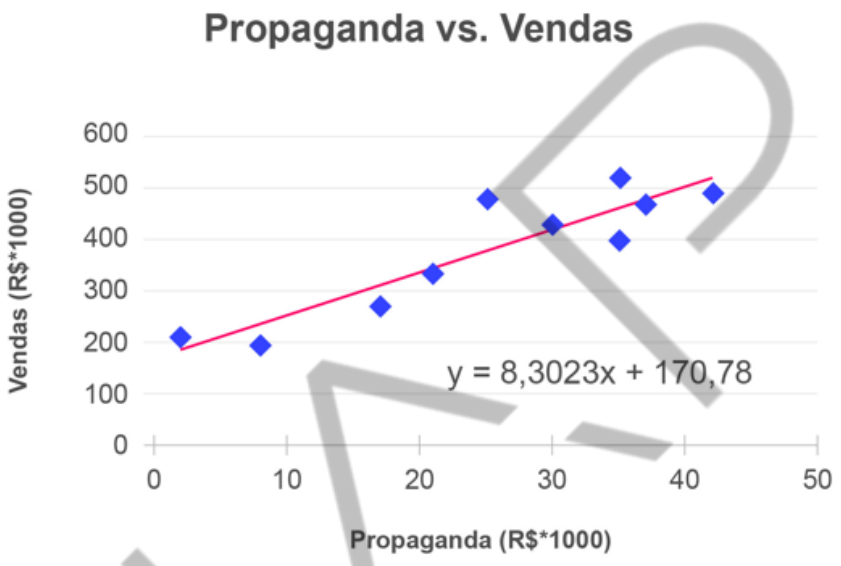

Figura 2 - Exemplo de regressão
Fonte: Blogspot (2016), adaptado por FIAP (2024)

No entanto, um bom modelo de regressão precisa ir além de apenas se ajustar aos dados que possui. Ele deve ser capaz de **aprender os padrões presentes**, capturando as relações entre as variáveis, mas também ser generalizável, ou seja, funcionar bem com novos dados que não foram utilizados durante o treinamento. Encontrar esse equilíbrio entre aprender com os dados e ser robusto a novas situações é a chave para um modelo preditivo de sucesso em regressão.

Portanto, um bom modelo de regressão precisa encontrar o equilíbrio entre aprender com os dados e **ser capaz de generalizar**. Isso significa evitar dois extremos: **overfitting** e **underfitting**. O overfitting ocorre quando o modelo se ajusta demais aos detalhes e ruídos do conjunto de treinamento, tornando-se inflexível para dados novos. Por outro lado, o underfitting acontece quando o modelo é excessivamente simples, falhando em capturar as tendências básicas dos dados. O objetivo é construir um modelo que se ajuste bem aos dados de treinamento, mas que também mantenha a capacidade de fazer previsões precisas em dados inéditos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.1.2 Relação entre regressão e classificação

Embora sejam problemas distintos, a regressão e a classificação guardam uma relação entre si. Um exemplo comum envolve transformar um problema de regressão (contínuo) em um problema de classificação (categórico) quando se deseja prever uma variável contínua, porém, a interpretação final requer uma decisão categórica. Por exemplo, ao prever a pontuação de crédito de um cliente, que originalmente seria um valor contínuo, pode-se posteriormente categorizá-lo em classes como “baixo risco”, “médio risco” ou “alto risco”. Para fazer essa conversão, é necessário definir intervalos ou limites que traduzam os valores previstos em categorias.

Da mesma forma, é possível abordar alguns problemas de classificação como se fossem de regressão. Um exemplo é a classificação binária com a regressão logística, onde o modelo prevê a probabilidade de um evento (um valor contínuo entre 0 e 1), e essa probabilidade é então convertida em uma decisão categórica com base em um limiar, como 0,5. Além disso, existem técnicas como a “regressão ordinal”, que lidam com variáveis categóricas ordenadas, combinando características de classificação e regressão.

No entanto, a passagem entre os dois tipos de problema nem sempre é trivial. A abordagem escolhida depende da natureza do dado, dos objetivos do projeto e da interpretação necessária. Se um problema requer previsões precisas de valores numéricos, como a quantidade de vendas futuras, tratá-lo como uma classificação pode resultar em perda de nuances importantes. Portanto, é essencial analisar a especificidade do problema antes de optar por convertê-lo de regressão para classificação ou vice-versa.

Grande parte da conversão da regressão em classificação é feita pela escolha de *threshold* (limiares), delimitando faixas que caracterizam uma categoria. Não conhecer este *threshold* limita a conversão da classificação em uma regressão. Por exemplo, após 84 ºF (~29 ºC) está quente, e abaixo disso está frio. Um modelo de regressão pode prever a temperatura média amanhã, e a partir disso você classifica se está quente ou frio. Entretanto, saber se está quente ou frio não é o suficiente para afirmar a temperatura média do dia seguinte.

Observe a figura “Exemplo de regressão”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

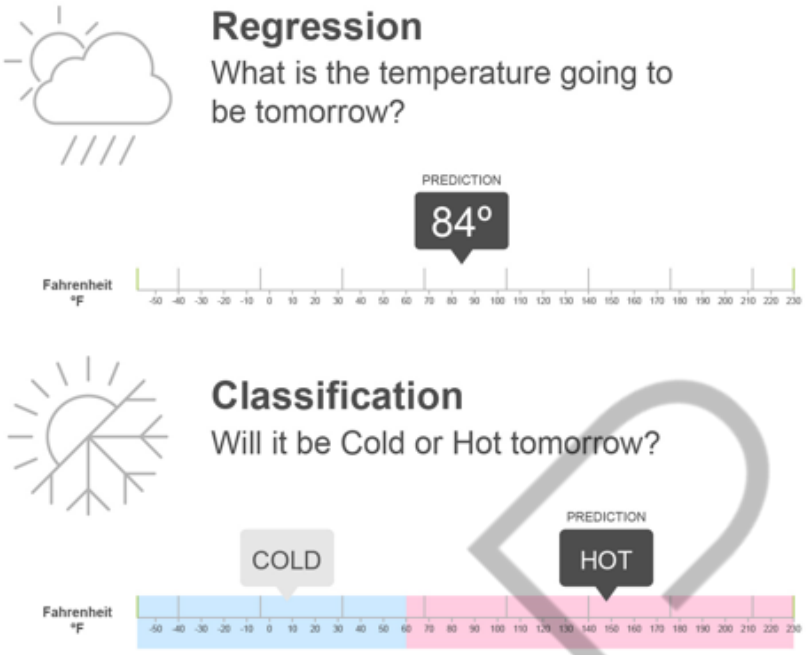

Figura 3 - Exemplo de regressão
Fonte: Medium (2019), adaptado por FIAP (2024)

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 APLICAÇÕES

O aprendizado supervisionado de regressão é fundamental quando precisamos prever valores contínuos com base em variáveis de entrada. Ao contrário da classificação, onde cada exemplo é associado a um rótulo categórico, na regressão, cada exemplo no conjunto de dados corresponde a um valor numérico específico. Isso permite abordar problemas complexos, como prever o faturamento de uma empresa ou a temperatura em um dia futuro, capturando as sutis relações entre as variáveis e os resultados. A habilidade de prever um valor contínuo faz da regressão uma ferramenta poderosa em análises preditivas e tomada de decisões estratégicas.

2.1 Educação: Prevendo o desempenho acadêmico

Na educação, a regressão pode ser utilizada para prever o desempenho futuro dos alunos com base em características como frequência, notas em disciplinas anteriores, tempo dedicado ao estudo e engajamento em atividades extracurriculares. Por exemplo, um modelo de regressão linear pode ser treinado com dados históricos para prever a média final de um aluno ao final do semestre. Isso ajuda as instituições de ensino a identificar estudantes que estão em risco de baixo desempenho, permitindo a implementação de intervenções de maneira personalizada, como tutorias ou programas de mentoria.

2.2 Financeiro: Prevendo riscos de crédito

No setor financeiro, prever o risco de crédito é uma tarefa crítica, e os modelos de regressão desempenham um papel central nesse processo. Instituições financeiras, como bancos e empresas de crédito, utilizam regressão para prever a probabilidade de um cliente não pagar um empréstimo, estimando uma “pontuação de crédito”. Os modelos de regressão multivariada, por exemplo, são usados para calcular a probabilidade de inadimplência com base em variáveis como histórico financeiro do cliente, renda, idade, padrões de gasto e comportamento de pagamento anterior. Esse tipo de análise é vital para ajustar taxas de juros, definir limites de crédito e identificar a necessidade de medidas preventivas para mitigar riscos.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.3 Agronegócio: Estimando a produção agrícola

O agronegócio se beneficia amplamente dos modelos de regressão, especialmente para estimar a produção de culturas agrícolas. Variáveis como dados meteorológicos, qualidade do solo, quantidade de fertilizantes utilizados, variedade de sementes e histórico de safras podem ser utilizados para prever a produção agrícola esperada. Por exemplo, uma empresa pode optar pela regressão múltipla para estimar a produção de milho em uma determinada safra, levando em consideração variáveis climáticas como temperatura e precipitação, bem como fatores do solo e práticas de cultivo. Essas previsões são cruciais para gerenciar estoques, planejar a logística e definir estratégias de venda no mercado futuro.

2.4 Saúde: Predição de progressão de doenças

Na área da saúde, a regressão é empregada para prever a progressão de doenças e auxiliar no planejamento de tratamentos. Um caso comum é a predição do tempo de sobrevivência de pacientes com doenças crônicas, como câncer. Modelos de regressão linear podem utilizar variáveis como idade, estágio da doença, resultados de exames laboratoriais e hábitos de vida para estimar a expectativa de sobrevivência do paciente. Além disso, em outras áreas da medicina, modelos de regressão são usados para prever indicadores como a pressão arterial ou níveis de glicose no sangue, com base em fatores como dieta, atividade física, medicação e histórico de saúde do paciente. Esses *insights* permitem que os médicos e equipes de saúde possam personalizar tratamentos e acompanhar a eficácia das intervenções.

2.5 Imobiliário: Estimativa de preços de propriedades

No mercado imobiliário, os modelos de regressão são amplamente aplicados para estimar os preços das propriedades. Variáveis como localização, tamanho do imóvel, número de quartos, idade da construção e amenidades podem ser utilizadas em um modelo de regressão múltipla para prever o preço de venda de uma casa ou apartamento. Isso auxilia corretores e investidores a definir preços competitivos e identificar oportunidades de investimento. Além disso, os modelos de regressão

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

podem ser usados para analisar a influência de diferentes fatores no valor do imóvel, como a proximidade de escolas, hospitais e centros comerciais.

2.6 Transportes: Previsão de demanda e tempo de viagem

O setor de transportes também se beneficia do uso de regressão para previsão de demanda e tempo de viagem. Por exemplo, empresas de logística utilizam modelos de regressão para prever o tempo estimado de entrega de mercadorias com base em variáveis como condições climáticas, horário do dia, congestionamento e rotas escolhidas. Da mesma forma, serviços de transporte como táxis e aplicativos de carona usam regressão para prever a demanda de veículos em determinadas regiões e horários, otimizando a distribuição da frota e ajustando preços dinâmicos de acordo com a demanda.

Esses exemplos ilustram como os modelos de regressão são ferramentas poderosas em uma ampla gama de setores. Eles permitem prever e quantificar resultados contínuos, auxiliando na tomada de decisões baseadas em dados. A capacidade de prever valores numéricos com precisão oferece uma vantagem estratégica, ajudando as organizações a se anteciparem aos problemas, otimizarem processos e ajustarem estratégias conforme as tendências do mercado e o comportamento dos consumidores.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 AVALIAÇÃO DE DESEMPENHO

Avaliar o desempenho de modelos preditivos de regressão é uma etapa fundamental para garantir que as previsões feitas sejam confiáveis e úteis na prática. Ao construir um modelo de regressão, nosso objetivo é prever valores contínuos, como o preço de um imóvel, a temperatura de amanhã ou o faturamento de uma empresa. No entanto, as previsões só terão valor se forem precisas e se o modelo for capaz de generalizar bem para dados novos e desconhecidos. Sem uma avaliação adequada, não há como saber se o modelo está realmente aprendendo padrões relevantes nos dados ou apenas se ajustando a ruídos ou peculiaridades do conjunto de treinamento.

Além disso, a avaliação de desempenho permite identificar as limitações do modelo e orientar melhorias. Por exemplo, se um modelo de regressão apresenta desempenho ruim, podemos investigar se isso se deve a variáveis inadequadas, ao tratamento insuficiente de outliers ou à necessidade de ajustes nos parâmetros do modelo. Possuir uma medida clara do erro das previsões ajuda a entender se o modelo é adequado para o problema em questão e se ele está pronto para ser utilizado em um ambiente real. Dessa forma, a avaliação não só valida a qualidade do modelo, mas também direciona esforços para aprimorar a capacidade preditiva e garantir que ele possa apoiar efetivamente a tomada de decisões.

3.1 Métricas de avaliação

Uma métrica de avaliação é uma ferramenta quantitativa utilizada para medir a performance de um modelo preditivo, permitindo uma análise objetiva de quão bem o modelo está atingindo seus objetivos. No contexto do aprendizado supervisionado de regressão, as métricas de avaliação têm um papel fundamental, pois nos ajudam a entender a precisão das previsões feitas pelo modelo em relação aos valores reais.

Enquanto um modelo de classificação prevê categorias, um modelo de regressão prevê valores contínuos, como preços, temperaturas ou vendas. Portanto, as métricas de avaliação em regressão focam em quantificar a diferença entre os valores previstos e os reais. Elas nos oferecem uma visão sobre a qualidade das

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

previsões, identificando se o modelo está, por exemplo, consistentemente subestimando ou superestimando os resultados. Em última análise, a escolha da métrica de avaliação adequada permite ajustar e aprimorar o modelo para que ele forneça previsões úteis e confiáveis em situações do mundo real.

3.1.1 Erro Absoluto Médio

O Erro Absoluto Médio (MAE – Mean Absolute Error) é uma métrica que mede a média das diferenças absolutas entre os valores previstos pelo modelo e os valores reais. Ele é calculado somando as diferenças absolutas entre cada valor previsto (y) e o valor real correspondente (y^) e, em seguida, é dividido pelo número total de observações (n):

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Figura 4 - Fórmula do MAE
Fonte: Elaborado pelo autor (2024)

A interpretação do MAE é direta: ele indica, em média, o quão distante as previsões estão dos valores reais. Por estar em unidades da variável de saída, o MAE é fácil de entender, representando o erro médio esperado do modelo. Quanto menor o MAE, mais precisas são as previsões do modelo.

3.1.2 Erro Quadrático Médio

O Erro Quadrático Médio (MSE – Mean Squared Error) é outra métrica que mede a média dos quadrados das diferenças entre os valores previstos e os reais. Sua fórmula é dada por:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \tilde{y}_i)^2$$

Figura 5 - Fórmula do MSE
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Diferentemente do MAE, o MSE dá mais peso a erros maiores devido à elevação ao quadrado. Isso significa que um modelo que comete grandes erros será penalizado mais severamente. Portanto, o MSE é útil quando se deseja enfatizar grandes desvios nas previsões. Entretanto, sua interpretação pode ser menos intuitiva, já que o resultado está em unidades quadradas da variável de saída.

3.1.3 Raiz Quadrada do Erro Quadrático Médio

A Raiz Quadrada do Erro Quadrático Médio (RMSE – Root Mean Squared Error) é a raiz quadrada do MSE:

$$RMSE = \sqrt{\sum_{i=1}^{n} \frac{(\hat{y}_i - y_i)^2}{n}}$$

Figura 6 - Fórmula do RMSE
Fonte: Elaborado pelo autor (2024)

O RMSE traz o erro médio de volta para as mesmas unidades da variável alvo, tornando a métrica mais interpretável. Ele ainda mantém a penalização para grandes erros, pois é baseado no MSE. Um RMSE mais baixo indica um modelo preditivo mais preciso, sendo especialmente útil quando se quer dar maior atenção para desvios significativos nas previsões.

3.1.4 R² Score

O R² Score (Coeficiente de Determinação) mede a proporção da variabilidade dos dados que é explicada pelo modelo. Ele é calculado como:

$$R2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})}, \quad \bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$$

Figura 7 - Fórmula do R² Score
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O R^2 varia de 0 a 1, onde 1 indica que o modelo explica perfeitamente a variabilidade dos dados, enquanto 0 indica que ele não explica nenhuma variabilidade em relação à média. Em alguns casos, o R^2 pode ser negativo, sugerindo que o modelo é pior do que simplesmente usar a média como previsão. Em resumo, o R^2 fornece uma medida da qualidade do ajuste do modelo, indicando quão bem as previsões se aproximam dos valores reais.

Veja a figura:

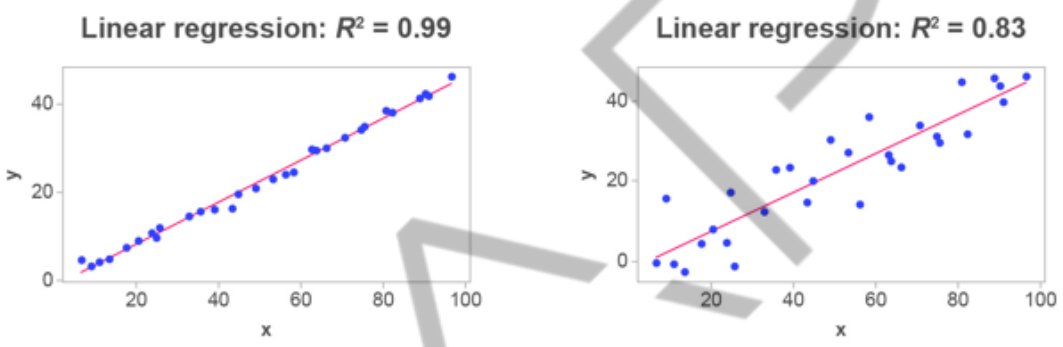

Figura 8 - Comparação da qualidade do ajuste da reta (R^2)
Fonte: Medium (2020)

3.1.5 Outras métricas

Além das métricas discutidas, existem outras formas de avaliar a performance de um modelo de regressão, como o Erro Percentual Absoluto Médio (MAPE) e o Mean Bias Deviation (MBD). Cada métrica oferece uma perspectiva diferente sobre a qualidade das previsões, e pode ser mais adequada dependendo do contexto do problema e das características dos dados. Escolher a métrica certa é crucial para garantir uma avaliação justa e alinhada com os objetivos do projeto.

Importante: não deixe de conhecer e explorar outras métricas, como aquelas implementadas e disponibilizadas no Sklearn: <https://scikit-learn.org/stable/modules/model_evaluation.html>.

3.2 Escolhendo a métrica ideal para o problema

Escolher a métrica de avaliação ideal para um problema de regressão é uma etapa fundamental, que influencia diretamente a interpretação e o sucesso do modelo

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

preditivo. A decisão deve ser baseada nas características dos dados, no contexto do problema e no tipo de erro que se deseja minimizar. Não existe uma única métrica que seja adequada para todos os casos, por isso é importante conhecer as diferenças e os impactos de cada uma.

Se o objetivo é ter uma ideia clara do erro médio esperado nas mesmas unidades da variável alvo, o Erro Absoluto Médio (MAE) pode ser a melhor escolha. Ele fornece uma visão direta e fácil de entender do quanto as previsões, em média, estão distantes dos valores reais. Além disso, o MAE é especialmente útil quando todos os erros devem ser tratados com igual importância, sem dar peso maior para desvios maiores.

Por outro lado, se o problema em questão é sensível a grandes desvios, o Erro Quadrático Médio (MSE) ou a Raiz Quadrada do Erro Quadrático Médio (RMSE) são as opções mais indicadas. Ambos penalizam mais fortemente os erros maiores devido ao fato de elevar as diferenças ao quadrado. Isso significa que, se erros grandes forem mais prejudiciais ou críticos, o MSE e o RMSE podem ser mais adequados, fornecendo um ajuste do modelo que se concentra em minimizar esses desvios.

Em casos em que o objetivo é entender quão bem o modelo explica a variabilidade dos dados, o R^2 Score é uma escolha relevante. Ele não apenas mede o quão próximo o modelo está dos valores reais, mas também indica a eficiência do modelo em relação a simplesmente usar a média dos dados. No entanto, é importante ter cautela, pois um alto R^2 não significa necessariamente que o modelo realiza boas previsões individuais, visto que ele pode ser influenciado por outliers e isso não é ideal quando o conjunto de dados apresenta comportamento não linear ou ruído.

Além dessas métricas, existem outras, como o Erro Percentual Absoluto Médio (MAPE), que é útil quando a escala dos dados varia muito, ou quando se deseja expressar o erro em termos percentuais. A escolha da métrica deve ser feita considerando os objetivos específicos do projeto, os impactos de erros nas previsões e a natureza dos dados envolvidos. Em alguns casos, a análise combinada de várias métricas é a melhor abordagem, fornecendo uma visão mais completa do desempenho do modelo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4 PRINCIPAIS ALGORITMOS

Agora que sabemos o que é **Machine Learning (ML)**, do que se trata o **aprendizado supervisionado**, quais são os problemas típicos modelados pela **regressão** e como **avaliar** os modelos treinados, chegou o momento **de conhecermos os principais algoritmos** que aprendem valores contínuos a partir dos dados.

A lista de algoritmos é vasta e nossa intenção não é passar todos eles, mas dar destaques aos principais. Assim, a partir destes você poderá conhecer outros e contrastar seus benefícios e limitações. Vamos lá?

4.1 Regressão Linear

A regressão linear é um dos algoritmos mais simples e amplamente utilizados em aprendizado supervisionado para prever valores contínuos. Em casos básicos, podemos chamar de regressão linear simples, pois temos apenas uma variável independente (ou preditora) e uma variável dependente (ou alvo). O objetivo da regressão linear é encontrar a melhor linha reta que descreva a relação entre essas duas variáveis.

Imagine que queremos prever a altura de uma pessoa (variável dependente) com base na idade (variável independente). A regressão linear simples vai traçar uma linha reta que melhor se ajusta aos dados, representando a tendência geral de como a altura muda conforme a idade varia. A fórmula dessa linha é:

$$y = \beta 0 + \beta 1 x$$

Aqui, **y** é a variável dependente (altura), **x** é a variável independente (idade), $\beta 0$ é o intercepto (o ponto onde a linha cruza o eixo y), e ***β1*** é o coeficiente angular, também chamado de inclinação. O coeficiente $\beta 1$ indica o quanto a variável dependente muda, em média, para cada unidade de variação na variável independente. Por exemplo, se β1=2 isso significa que a altura aumenta, em média, 2 unidades para cada unidade de aumento na idade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O algoritmo de regressão linear encontra a melhor linha ajustando os valores de $\beta 0$ e $\beta 1$ de forma que a soma das diferenças quadradas entre os valores reais e os valores previstos seja minimizada. Essa técnica é conhecida como “mínimos quadrados”. Em outras palavras, o modelo tenta minimizar o erro total das previsões, encontrando a linha que fica mais próxima possível de todos os pontos de dados, como ilustrado na figura “Regressão linear simples”.

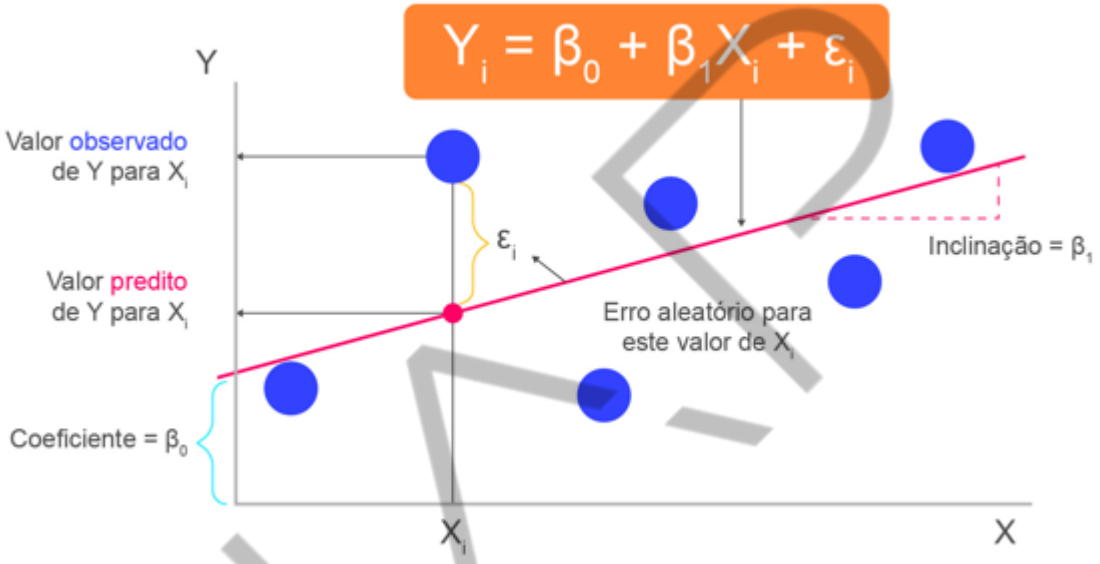

Figura 9 - Regressão linear simples
Fonte: Medium (2020), adaptado por FIAP (2024)

Uma vez que a linha é definida, podemos usar o modelo para fazer previsões. Por exemplo, se queremos prever a altura de uma pessoa de 10 anos, substituímos **x=10** na fórmula da linha. A simplicidade da regressão linear a torna uma ferramenta poderosa para capturar tendências em dados quando há uma relação linear entre as variáveis. No entanto, ela é limitada em casos nos quais a relação entre as variáveis é mais complexa e não pode ser bem representada por uma linha reta.

4.2 Regressão Linear Múltipla

A regressão linear múltipla é uma extensão da regressão linear simples. Ela é útil em situações onde temos mais de uma **variável independente** (ou preditora) para prever a **variável dependente** (ou alvo). Enquanto a regressão linear simples tenta encontrar uma linha que melhor representa a relação entre duas variáveis, a regressão linear múltipla busca um “plano” ou um “hiperplano” em um espaço

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

multidimensional para representar as relações entre várias variáveis preditoras e a variável de interesse.

A fórmula da regressão linear múltipla é expressa da seguinte forma:

$$y = \beta 0 + \beta 1x1 + \beta 2x2 + \beta 3x3 + \cdots + \beta nxn$$

Neste caso, **y** é a variável dependente (o valor que queremos prever), **x1, ..., xn** são as variáveis independentes (as características ou fatores que podem influenciar **y**), $\beta 0$ é o intercepto (o valor de **y**) quando todas as variáveis independentes são zero, e $\beta 1, \ldots \beta n$ são os coeficientes que representam a influência de cada variável independente em y.

Cada coeficiente βi indica o quanto a variável dependente **y** mudará, em média, para uma unidade de aumento na variável independente xi, assumindo que todas as outras variáveis independentes permaneçam constantes. Por exemplo, em um modelo que tenta prever o preço de uma casa, as variáveis independentes poderiam incluir o número de quartos, a metragem quadrada, a idade do imóvel, entre outros. O coeficiente associado à metragem quadrada indicaria o quanto o preço da casa muda para cada aumento de uma unidade na metragem, mantendo todas as outras variáveis fixas.

O objetivo da regressão linear múltipla é encontrar os valores dos coeficientes $\beta 1, \ldots \beta N$ que minimizam a soma dos quadrados das diferenças entre os valores previstos e os valores reais. Isso é feito usando a técnica de “mínimos quadrados”, que calcula a melhor combinação linear das variáveis preditoras para ajustar os dados.

Uma das grandes vantagens da regressão linear múltipla é que ela pode modelar cenários mais complexos onde a variável dependente é influenciada por múltiplos fatores. No entanto, ela também traz desafios, como a necessidade de se atentar à multicolinearidade, que ocorre quando as variáveis independentes são altamente correlacionadas entre si. Isso pode afetar a precisão das estimativas dos coeficientes e, consequentemente, a confiabilidade das previsões. Portanto, é importante analisar cuidadosamente as variáveis utilizadas no modelo e verificar a qualidade do ajuste, geralmente por meio de métricas como o **R²** ajustado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4.3 XGBoost (caso de regressão)

XGBoost (eXtreme Gradient Boosting) é um algoritmo de aprendizado supervisionado baseado em técnicas de Ensemble Learning, mais especificamente o "*gradient boosting*". Ele é amplamente utilizado tanto em problemas de classificação quanto em regressão, sendo conhecido por sua eficiência e alta capacidade preditiva. No contexto da regressão, o XGBoost constrói um modelo composto por uma série de árvores de decisão, onde cada nova árvore é adicionada para corrigir os erros das previsões das árvores anteriores, melhorando assim a precisão do modelo de forma iterativa.

4.3.1 Funcionamento do algoritmo

O XGBoost começa treinando uma árvore de decisão inicial com os dados. Essa primeira árvore tenta fazer previsões, mas inevitavelmente comete alguns erros. Em seguida, o algoritmo calcula o gradiente (basicamente, a direção dos erros) e usa essas informações para treinar uma nova árvore que se concentra em corrigir os erros cometidos pela anterior. Este processo é repetido para um número especificado de árvores, onde cada nova árvore é ajustada aos "resíduos" das previsões anteriores. A combinação dessas árvores resulta em um modelo final com maior precisão.

O XGBoost introduz várias melhorias em relação ao tradicional gradient boosting, como a regularização (para prevenir overfitting), a construção de árvores paralelas (para acelerar o treinamento) e o uso de uma técnica chamada "pruning" (poda) para reduzir o tamanho das árvores e evitar modelos excessivamente complexos.

4.3.2 Vantagens e desvantagens do método

Como todo algoritmo preditivo, o XGBoost possui vantagens e desvantagens, como apresentadas no quadro "Vantagens e desvantagens do XGBoost". Não há como saber se o algoritmo funcionará bem ou mal no seu conjunto de dados, portanto, é sempre recomendado experimentar.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Vantagens	Desvantagens
Alto desempenho preditivo: o XGBoost costuma ter excelente desempenho em problemas complexos, sendo uma escolha comum em competições de Machine Learning.	Complexidade de parametrização: o XGBoost possui muitos parâmetros que podem ser ajustados, tornando a otimização do modelo uma tarefa complexa e demorada.
Regularização embutida: o algoritmo inclui parâmetros de regularização (L1 e L2) para reduzir o overfitting, o que contribui para a criação de modelos mais generalizáveis.	Risco de overfitting: se não for configurado corretamente, especialmente os parâmetros de regularização, o XGBoost pode sofrer overfitting, ajustando-se demais aos dados de treinamento.
Eficiência computacional: o XGBoost é otimizado para aproveitar ao máximo os recursos computacionais, com suporte a processamento paralelo, tornando-o muito rápido mesmo em grandes conjuntos de dados.	Custo computacional: apesar das otimizações, para grandes conjuntos de dados e modelos muito complexos, o treinamento pode ser intensivo em termos de recursos computacionais.
Trabalho com valores faltantes: ele lida automaticamente com dados missing, facilitando o pré-processamento.	-

Quadro 1 - Vantagens e desvantagens do XGBoost
Fonte: Elaborado pelo autor (2024)

4.3.3 Parametrização e influência no resultado

Em relação aos hiperparâmetros do XGBoost, ou seja, as fontes de configuração do algoritmo, temos as mesmas alternativas de configuração de métodos baseados em Árvores de Decisão. Para compreender melhor:

- **n_estimators:** número de árvores que o modelo irá construir. Valores mais altos geralmente aumentam a precisão, mas também aumentam o risco de overfitting.
- **learning_rate:** controla a taxa de aprendizado, ou seja, o impacto de cada nova árvore no modelo final. Valores mais baixos tornam o processo de aprendizado mais lento, mas podem resultar em um modelo mais robusto.
- **max_depth:** profundidade máxima das árvores. Profundidades maiores permitem capturar padrões complexos, mas também aumentam o risco de overfitting.
- **subsample:** proporção dos dados de entrada a serem usados para construir cada árvore. Valores menores que 1 podem ajudar a prevenir o overfitting, criando árvores mais diversificadas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **colsample_bytree:** proporção de características selecionadas aleatoriamente para treinar cada árvore. Assim como o subsample, ajuda a prevenir o overfitting ao criar árvores diferentes.
- **gamma:** controle da redução mínima necessária na função de custo para dividir um nó. Valores mais altos tornam o modelo mais conservador, reduzindo a complexidade das árvores.
- **reg_alpha (L1 regularization) e reg_lambda (L2 regularization):** controlam a regularização do modelo. Valores mais altos impõem uma penalização maior, evitando que o modelo se ajuste excessivamente aos dados de treinamento.

Alterar qualquer configuração pode mudar significativamente os resultados do modelo. Por esta razão, é essencial realizar experimentos com diferentes configurações para encontrar a configuração ideal para o problema em questão.

4.4 Demais algoritmos

Além do algoritmo de regressão linear e do XGBoost, outros algoritmos que normalmente associamos a problemas de classificação, como KNN, Árvore de Decisão, Floresta Aleatória e Support Vector Machine (SVM), também podem ser adaptados e utilizados para resolver problemas de regressão. Esses algoritmos, quando aplicados ao contexto de regressão, sofrem algumas alterações em seu funcionamento e nos critérios de avaliação.

No caso do **KNN** para regressão, em vez de prever uma classe com base na maioria dos vizinhos mais próximos, ele calcula a média dos valores das variáveis dependentes dos K vizinhos mais próximos. Isso resulta em um valor contínuo ao invés de uma categoria. A principal alteração é que, ao invés de “votação” para classificar, o KNN faz uma média ou uma ponderação dos valores contínuos.

Para a **Árvore de Decisão** em regressão, a principal diferença é o critério usado para dividir os nós. Em vez de buscar a pureza das classes (como ocorre na classificação), a Árvore de Decisão de regressão divide os nós para minimizar o erro

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

de previsão em termos de variância ou erro quadrático médio. Cada nó final (folha) da árvore passa a representar uma média dos valores das amostras presentes naquele grupo, fornecendo uma previsão numérica ao invés de uma categoria.

A **Floresta Aleatória** também pode ser utilizada em regressão, com algumas mudanças. Em vez de “votar” na classe mais frequente como na classificação, cada árvore na floresta produz um valor de regressão (normalmente a média das amostras em cada folha). A previsão final da Floresta Aleatória de regressão é a média das previsões feitas por todas as árvores. Assim, ela mantém sua capacidade de reduzir variabilidade e melhorar a robustez do modelo, mas agora em termos de valores contínuos.

Já o **SVM** pode ser adaptado para problemas de regressão por meio de uma técnica chamada Support Vector Regression (SVR). Em vez de encontrar um hiperplano que separa as classes, a SVR tenta encontrar uma linha ou hiperplano que se ajuste aos dados, ao mesmo tempo que tenta manter todos os pontos de dados dentro de uma margem de erro especificada. Assim, o foco muda de maximizar a margem entre classes para minimizar o erro das previsões em um intervalo especificado.

Em todos esses algoritmos, **a principal mudança é o critério de avaliação e otimização** e que, ao invés de medir a acurácia ou a pureza das classes, eles **buscam minimizar o erro contínuo** (como erro absoluto médio, erro quadrático médio, entre outros). Além disso, os parâmetros que influenciam o ajuste do modelo, como a profundidade das árvores em Árvores de Decisão e Florestas Aleatórias ou o valor de K no KNN, continuam sendo fundamentais, mas agora precisam ser otimizados para fornecer previsões numéricas precisas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

5 CONSTRUINDO MODELOS PREDITIVOS MAIS ROBUSTOS

A validação cruzada e os pipelines do Scikit-learn são ferramentas essenciais na construção de modelos preditivos, tanto de regressão quanto de classificação. A **validação cruzada** permite avaliar a performance do modelo de forma consistente, evitando vieses ao garantir que todas as observações sejam utilizadas tanto para treinamento quanto para validação, proporcionando uma estimativa confiável da capacidade de generalização do modelo. Em relação aos **pipelines do Scikit-learn**, eles facilitam o processo de modelagem ao automatizar etapas como pré-processamento, seleção de características e ajuste de hiperparâmetros em um fluxo único. Isso não apenas reduz o risco de erros ao aplicar diferentes técnicas, mas também garante que as transformações aplicadas aos dados de treino sejam idênticas às usadas nos dados de validação ou teste, resultando em um modelo mais robusto e eficiente.

5.1 Validação cruzada

Validação cruzada é uma técnica que consiste em dividir os dados de treinamento em várias partes (subconjuntos) para testar o modelo em diferentes segmentos dos dados. A ideia é que, ao invés de treinar o modelo em todo o conjunto de dados de uma só vez, ele é treinado múltiplas vezes, cada vez com um subconjunto ligeiramente diferente dos dados. Isso fornece uma visão mais completa do desempenho do modelo, evitando resultados excessivamente otimistas ou pessimistas que poderiam surgir caso avaliássemos o modelo utilizando um único conjunto de validação.

Assim, a validação cruzada permite avaliar o desempenho do modelo de maneira mais confiável, fornecendo uma estimativa precisa de como ele deve se comportar em dados desconhecidos. Existem diversas formas de implementar validação cruzada. Vamos conhecê-las!

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

5.1.1 Método Hold-Out

O método **hold-out** é uma técnica de validação mais comum, em que o conjunto de dados é dividido em duas ou três partes: um conjunto de **treinamento** e um conjunto de **teste** (às vezes também um conjunto de **validação**). Normalmente, uma porcentagem maior dos dados, como 70-80%, é destinada ao treinamento do modelo, enquanto o restante, 20-30%, é reservado para teste. O modelo é treinado apenas com os dados de treinamento e, em seguida, avaliado em seu desempenho usando o conjunto de teste, que simula dados novos e desconhecidos.

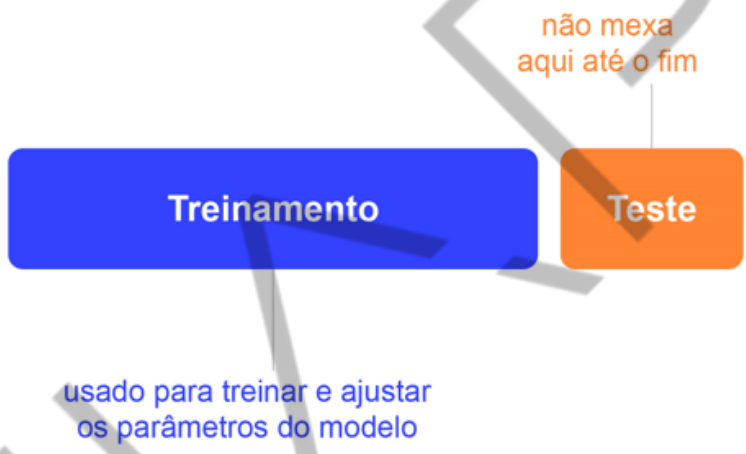

Figura 10 - Método hold-out
Fonte: Máquinas que aprendem (2020), adaptado por FIAP (2024)

A vantagem do hold-out é sua **simplicidade e rapidez**, mas ele pode ser influenciado pela maneira como os dados foram divididos, podendo levar a uma avaliação não tão precisa se os dados não forem representativos ou se houver uma divisão desbalanceada entre os conjuntos.

5.1.2 Método K-Fold

O **K-Fold Cross-Validation** é o tipo mais comum de validação cruzada. Nele, o conjunto de dados é dividido em K subconjuntos ou “folds”. O modelo é treinado K vezes, cada vez usando K-1 folds para treino e 1 fold diferente para validação. No final, a performance do modelo é avaliada como a média do desempenho em todos os K folds. A figura “Método K-fold” exemplifica a validação 5-fold, na qual os dados são divididos em 5 partes. O modelo é treinado 5 vezes, usando cada vez 4 partes

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

para treinamento e 1 para validação. Esse processo garante que cada observação no conjunto de dados seja utilizada para validação exatamente uma vez, o que reduz a variabilidade e fornece uma estimativa mais estável do erro do modelo.

Figura 11 - Método K-fold
Fonte: Medium (2019), adaptado por FIAP (2024)

5.1.3 Método Leave-One-Out

O **Leave-One-Out Cross-Validation** (LOOCV) é um caso extremo do K-Fold Cross-Validation, onde K é igual ao número total de observações no conjunto de dados. Isso significa que o modelo é treinado **n** vezes, cada vez deixando uma única observação de fora para validação. Embora seja uma técnica muito completa, é computacionalmente cara para grandes conjuntos de dados, pois envolve o treinamento do modelo um grande número de vezes. Observe a figura:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

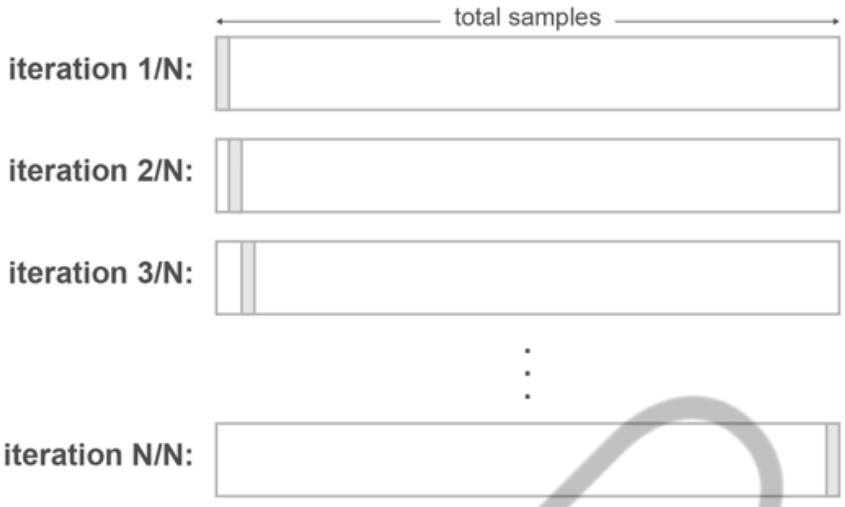

Figura 12 - Método leave-one-out
Fonte: Comparison of Statistical Methods for Genomic Signature Extraction (2013), adaptado por FIAP (2024)

5.1.4 Método K-Fold Estratificado

O **Stratified K-Fold Cross-Validation** (K-fold estratificado) é uma variante do K-Fold em que os folds são criados de forma a manter a distribuição das variáveis dependentes semelhante em cada fold. A figura “Método K-fold estratificado” mostra a dinâmica de separação para K=5; em cada fold a distribuição entre as classes (M e F) é mantida.

Figura 13 - Método K-fold estratificado
Fonte: Medium (2023), adaptado por FIAP (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O K-fold estratificado é especialmente útil quando se trabalha com problemas onde há desbalanceamento nas variáveis, garantindo que a proporção de valores em cada fold seja consistente com o conjunto de dados original.

Portanto, **a validação cruzada é uma técnica poderosa que, ao avaliar o desempenho do modelo em múltiplos subconjuntos, fornece uma visão mais completa da robustez do modelo**. Isso resulta em modelos preditivos mais confiáveis e capazes de generalizar melhor quando aplicados a novos dados, seja em problemas de regressão ou classificação.

5.2 Uso da validação cruzada

Uma abordagem comum na construção de modelos preditivos é combinar o método hold-out com a validação cruzada K-Fold, geralmente em uma configuração de 5-Fold Cross-Validation. Neste processo, o conjunto de dados original é primeiro dividido utilizando o método hold-out em dois subconjuntos: um conjunto de treinamento e um conjunto de teste. A divisão típica é 70-80% dos dados para o conjunto de treinamento e 20-30% para o conjunto de teste. O conjunto de teste é separado e só será utilizado ao final, para uma avaliação final do modelo.

Com o conjunto de treinamento em mãos, o próximo passo é aplicar a validação cruzada 5-Fold. Isso significa dividir o conjunto de treinamento em cinco partes (ou “folds”), onde em cada iteração quatro partes são usadas para treinar o modelo e a parte restante é usada para validação. Esse processo é repetido cinco vezes, garantindo que cada fold seja utilizado como conjunto de validação uma vez. A média das métricas obtidas em cada uma dessas cinco iterações fornece uma avaliação confiável do desempenho do modelo durante a fase de ajuste e seleção de hiperparâmetros, como a profundidade das árvores ou a taxa de aprendizado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

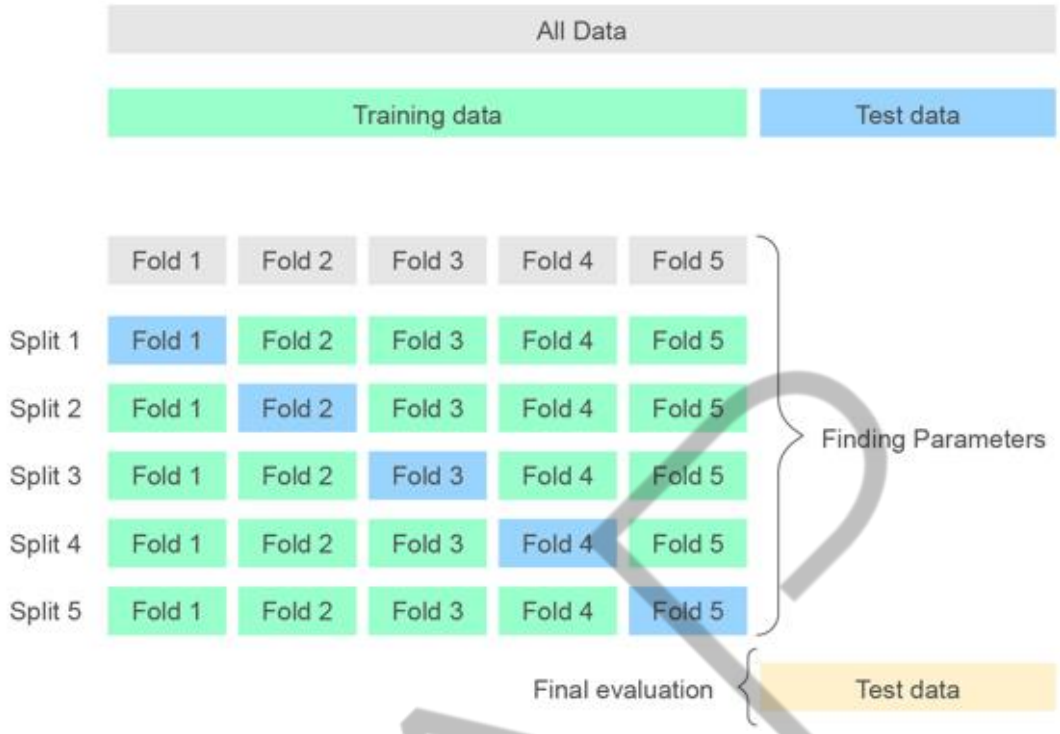

Figura 14 - Combinação de Hold-out com K-fold
Fonte: Scikit-learn (2024), adaptado por FIAP (2024)

Após encontrar a melhor configuração de modelo usando a validação cruzada, o modelo final é treinado com todos os dados do conjunto de treinamento, incorporando os hiperparâmetros ajustados. Finalmente, ele é testado no conjunto de teste original (mantido separado desde o início com o método hold-out) para avaliar seu desempenho em dados totalmente novos.

Essa combinação de hold-out e 5-Fold Cross-Validation oferece uma visão robusta da capacidade de generalização do modelo, minimizando riscos de overfitting e fornecendo uma avaliação precisa do seu desempenho real.

5.3 Implementando pipelines

Os pipelines do Scikit-learn são uma ferramenta poderosa para simplificar e estruturar o processo de construção de modelos de aprendizado de máquina. Em um projeto típico, várias etapas precisam ser realizadas, como pré-processamento de dados, seleção de características, ajuste do modelo e avaliação. O pipeline permite integrar todas essas etapas em um fluxo de trabalho sequencial, garantindo que elas sejam executadas na ordem correta e de forma consistente em todo o conjunto de dados. Isso é especialmente útil quando se deseja aplicar as mesmas transformações

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

tanto aos dados de treinamento quanto aos dados de teste, garantindo que os procedimentos de pré-processamento, como normalização ou codificação de variáveis categóricas, sejam aplicados de forma idêntica.

Um pipeline é criado combinando uma sequência de passos, onde cada passo pode ser uma transformação (como “StandardScaler” para normalizar os dados) ou um modelo de aprendizado (como uma regressão linear ou uma árvore de decisão). Por exemplo, se estamos construindo um modelo de regressão, o pipeline pode incluir uma etapa de normalização seguida pelo ajuste de um modelo de regressão. Isso torna o código mais limpo, reduzindo a possibilidade de erros e facilitando a manutenção do projeto.

Além disso, os pipelines permitem realizar validações cruzadas e ajustes de hiperparâmetros de forma mais eficiente. Durante a validação cruzada, o pipeline aplica todas as transformações de pré-processamento dentro de cada fold, evitando o vazamento de informações entre os conjuntos de treinamento e validação. Ao utilizar técnicas como “GridSearchCV” ou “RandomizedSearchCV” com pipelines, é possível ajustar os hiperparâmetros das etapas do pipeline, incluindo tanto os parâmetros do pré-processamento quanto do modelo, em uma única operação. Essa abordagem integrada não apenas otimiza o fluxo de trabalho, mas também assegura que o modelo final seja treinado de maneira correta e consistente em todas as fases do processo de modelagem.

A figura “Exemplo de uso de Pipelines do Sklearn” representa um pipeline completo construído com Scikit-learn para processamento de dados e modelagem. No pré-processamento, utiliza-se um “ColumnTransformer” para aplicar diferentes transformações a variáveis numéricas e categóricas. Para as variáveis numéricas, um “SimpleImputer” preenche os valores ausentes com a mediana, seguido pelo “StandardScaler” que padroniza os dados. Para as variáveis categóricas, os valores ausentes são preenchidos com uma constante usando outro “SimpleImputer”, e o “OneHotEncoder” transforma essas variáveis em formato binário, ignorando categorias desconhecidas. Após o pré-processamento, a Análise de Componentes Principais (PCA) é aplicada para reduzir a dimensionalidade a 10 componentes. Por fim, o modelo de Regressão Logística é treinado com parâmetros específicos, como `C=0.1` e `solver='newton-cg'`. Esse pipeline garante que todas as etapas de preparação e modelagem sejam realizadas de forma integrada e consistente.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

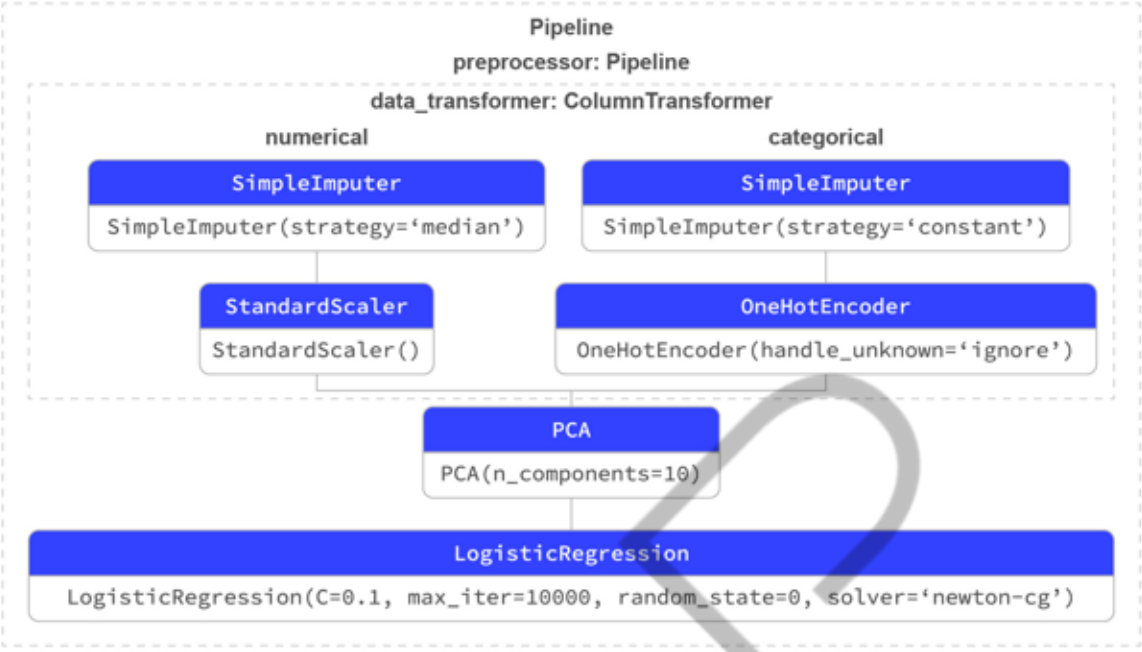

Figura 15 - Exemplo de uso de Pipelines do Sklearn
Fonte: Medium (2020), adaptado por FIAP (2024)

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

6 HANDS ON: ANÁLISES PREDITIVAS DE REGRESSÃO

Agora que passamos pelos principais algoritmos de aprendizado supervisionado de regressão, chegou a hora de aprendermos como os implementar sobre um dataset real.

Toda nossa prática será feita em um jupyter notebook no ambiente do Google Colaboratory (Colab).

Sugestão: veja o material HOW TO para acessar o ambiente do Colab.

Uma vez no Colab, crie um novo notebook, dê um nome como preferir (sugestão: Aula 3), e faça cada bloco de código fonte em uma célula. Após inserir o código na célula do notebook, execute-a e veja a saída gerada.

Atenção: utilize o arquivo de apoio “galton.csv”.

6.1 Sobre a base de dados

A base de dados “galton.csv” é um conjunto clássico em estatística que contém informações sobre a altura de pais e seus filhos, coletadas pelo cientista Francis Galton. Cada registro na base representa uma família, e inclui variáveis como a altura média dos pais (em geral, uma média ponderada das alturas do pai e da mãe) e a altura de seus filhos. Essa base é comumente utilizada para realizar estudos de regressão e análise da hereditariedade, especialmente quando é necessário ilustrar a relação e a tendência de regressão à média na altura de diferentes gerações.

6.2 Implementando nossa análise

O primeiro passo é a importação do código necessário, leitura e exibição dos dados (ou de uma parte deles).

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Imports
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error,
mean_absolute_error, r2_score

# Ler o dataset
df = pd.read_csv("galton.csv")
df.head(5)
```

Código-fonte 1 - Imports e leitura do dataset
Fonte: Elaborado pelo autor (2024)

A figura “Saída do código-fonte 1” mostra uma visão dos dados:

	family	father	mother	midparentHeight	children	childNum	gender	childHeight
0	1	78.5	67.0	75.43	4	1	male	73.2
1	1	78.5	67.0	75.43	4	2	female	69.2
2	1	78.5	67.0	75.43	4	3	female	69.0
3	1	78.5	67.0	75.43	4	4	female	69.0
4	2	75.5	66.5	73.66	4	1	male	73.5

Figura 16 - Saída do código-fonte 1
Fonte: Elaborado pelo autor (2024)

Vamos obter informações gerais sobre a base:

```
# Infos do dataset
df.info()
```

Código-fonte 2 - Informações gerais da base
Fonte: Elaborado pelo autor (2024)

A figura “Saída do código-fonte 2” mostra que não há dados faltantes:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 934 entries, 0 to 933
Data columns (total 8 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   family           934 non-null    object
 1   father           934 non-null    float64
 2   mother           934 non-null    float64
 3   midparentHeight  934 non-null    float64
 4   children         934 non-null    int64
 5   childNum         934 non-null    int64
 6   gender           934 non-null    object
 7   childHeight      934 non-null    float64
dtypes: float64(4), int64(2), object(2)
memory usage: 58.5+ KB
```

Figura 17 - Saída do código-fonte 2
Fonte: Elaborado pelo autor (2024)

Agora podemos fazer a limpeza da base, removendo duplicados, colunas inúteis, convertendo inchs para metros e tratando as variáveis que são strings:

```
# Removendo linhas duplicadas
df.drop_duplicates(inplace=True)

# Tratamento de dados - REMOVENDO COLUNAS INÚTEIS PARA O PROBLEMA
df.drop(columns=["family", "children", "childNum"], inplace=True)

# Tratamento de dados - PASSANDO DE INCHES PARA METROS
def inch2m(inch):
  return inch*2.54/100

for coluna in ["father", "mother", "midparentHeight", "childHeight"]:
  df[coluna] = df[coluna].apply( inch2m )

# Tratamento de dados - PASSANDO "GENDER" DE STRING PARA NÚMERO
df["gender"] = df["gender"].apply( lambda x: 0 if x=="male" else 1 )

# Tratamento de dados - CRIAR UMA COLUNA COM A MÉDIA DA ALTURA DOS PAIS
df["media"] = (df["father"] + df["mother"]) / 2

# Exibe o resultado
df.sample(5)
```

Código-fonte 3 - Informações gerais da base
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A figura “Saída do código-fonte 3” mostra cinco linhas aleatórias, então sua saída pode ser diferente, mas deve seguir a mesma estrutura da resposta:

	father	mother	midparentHeight	gender	childHeight	media
106	1.8415	1.6129	1.791716	1	1.71450	1.7272
804	1.6764	1.6764	1.743456	0	1.72720	1.6764
43	1.8542	1.7018	1.846072	1	1.57480	1.7780
560	1.7526	1.5494	1.712976	1	1.57480	1.6510
431	1.7526	1.6764	1.781556	0	1.80848	1.7145

Figura 18 - Saída do código-fonte 3
Fonte: Elaborado pelo autor (2024)

Podemos fazer o primeiro modelo, que será uma **regressão linear simples** (uma variável independente), baseada apenas na média da altura dos pais:

```
# Dados e labels
X = np.array( df["media"] ).reshape(-1, 1) # Só fiz o
reshape pq estou usando apenas 1 coluna do df
y = df["childHeight"]

# Treino e teste
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.3,
    random_state=42
)

# Treinar o modelo
reta = LinearRegression()
reta.fit(X_train, y_train)
y_pred = reta.predict(X_test)

# Avaliar o modelo
mse = mean_squared_error(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"MSE = {mse}")
print(f"MAE = {mae}")
print(f"R² = {r2}")
```

Código-fonte 4 - Construindo modelo de regressão simples
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A figura “Saída do código-fonte 4” mostra as métricas resultantes:

```
MSE = 0.0076515087487540635
MAE = 0.07409180708927149
R² = 0.1283802341245447
```

Figura 19 - Saída do código-fonte 4
Fonte: Elaborado pelo autor (2024)

Por ser uma regressão simples, é possível construir o gráfico do modelo:

```
# Gráfico da regressão simples
import matplotlib.pyplot as plt

plt.scatter(X_test, y_test)
plt.plot(X_test, y_pred, color="red")
plt.title("Regressão da altura média dos pais e dos filhos")
plt.xlabel("Altura média dos pais (m)")
plt.ylabel("Altura dos filhos (m)")
plt.show()
```

Código-fonte 5 - Construindo o gráfico da regressão linear simples
Fonte: Elaborado pelo autor (2024)

A figura “Saída do código-fonte 5” apresenta o gráfico:

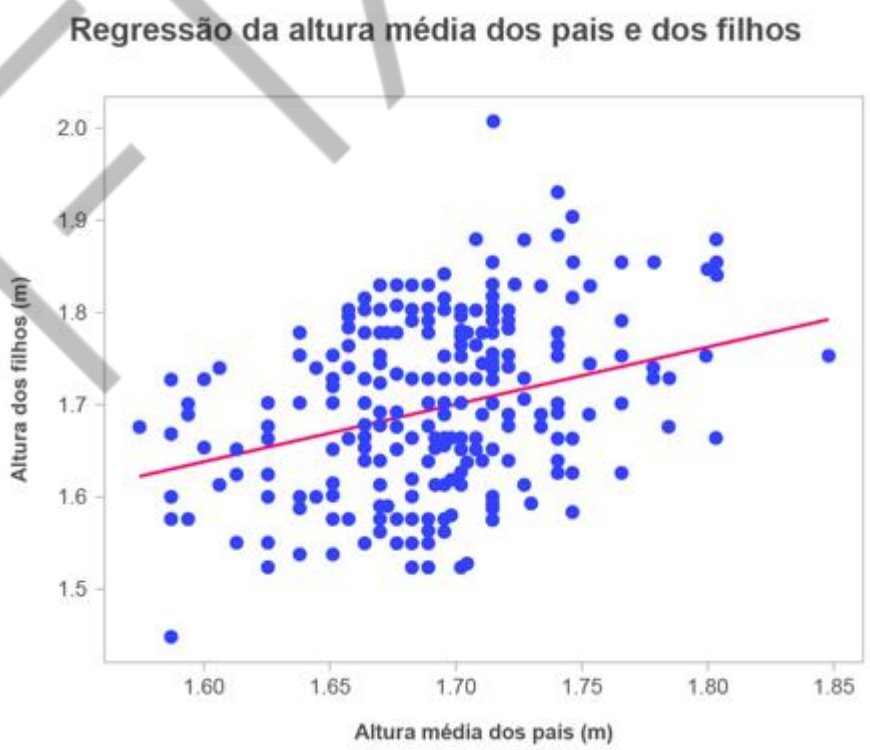

Figura 20 - Saída do código-fonte 5
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Será que podemos fazer melhor? Vamos ver como um modelo de regressão multivariada performaria neste dataset:

```
# Dados e labels
X = df.drop(columns=["childHeight", "midparentHeight"])
y = df["childHeight"]

# Treino e teste
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.3,
    random_state=42
)

# Padronização dos dados
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Treinar o modelo
reta2 = LinearRegression()
reta2.fit(X_train_scaled, y_train)
y_pred = reta2.predict(X_test_scaled)

# Avaliar o modelo (só copiei da célula da regressão
simples)
mse = mean_squared_error(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"MSE = {mse}")
print(f"MAE = {mae}")
print(f"R² = {r2}")
```

Código-fonte 6 - Construindo um modelo da regressão linear múltipla
Fonte: Elaborado pelo autor (2024)

A figura “Saída do código-fonte 6” mostra as métricas resultantes:

```
MSE = 0.003050348288408433
MAE = 0.043282428624405976
R² = 0.6525203135376285
```

Figura 21 - Saída do código-fonte 6
Fonte: Elaborado pelo autor (2024)

Podemos perceber uma melhora nos resultados! Inclusive, podemos verificar os coeficientes e o intercept deste modelo mais robusto:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Intercept
display("Intercept: ", reta2.intercept_)

# Coeficientes
pd.DataFrame( {"features": X_train.columns,
               "coeficientes": reta2.coef_})
```

Código-fonte 7 - Imprimindo coeficientes e intercept da regressão múltipla
Fonte: Elaborado pelo autor (2024)

Que são exibidos na figura “Saída do código-fonte 7”:

```
'Intercept: '
1.7003034798884957
```

	features	coeficientes
0	father	-1.703672e+12
1	mother	-1.609760e+12
2	gender	-6.568146e-02
3	media	2.383889e+12

Figura 22 - Saída do código-fonte 7
Fonte: Elaborado pelo autor (2024)

Agora é com você! Para treinar, faça outros modelos baseados em outros algoritmos de regressão e compare com os resultados obtidos até aqui, e observe se algum dos seus modelos superou o resultado obtido até o momento.

Bons estudos!

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

APRENDIZADO Supervisionado vs. Aprendizado Não-Supervisionado em machine learning. **Lean Saúde**, 2022. Disponível em: <https://www.leansaude.com.br/aprendizado-supervisionado-vs-aprendizado-nao-supervisionado-em-machine-learning/>. Acesso em: 27 set. 2024.

AZANK, Felipe. Como avaliar seu modelo de regressão. **Medium**, 03 de agosto de 2020. Disponível em: <https://medium.com/turing-talks/como-avaliar-seu-modelo-de-regress%C3%A3o-c2c8d73dab96>. Acesso em: 27 set. 2024.

CHLIS, Nikolaos-Kosmas. **Comparison of Statistical Methods for Genomic Signature Extraction**. 2013. 88 f. Tese (Diploma in Electronic and Computer Engineering) - Technical University of Crete, Crete, 2023. Disponível em: <https://www.researchgate.net/figure/Leave-One-Out-Cross-Validation_fig11_266617511>. Acesso em: 27 set. 2024.

CIELEN, Davy; MEYSMAN, Arno. **Introducing data science:** big data, machine learning, and more, using Python tools. Simon and Schuster, 2016.

CROSS-VALIDATION: evaluating estimator performance. **Scikit-learn**, 2024. Disponível em: <https://scikit-learn.org/stable/modules/cross_validation.html>. Acesso em: 27 set. 2024.

DARMITON. Overfitting. **Máquinas que aprendem**, 11 de maio de 2020. Disponível em: <https://maquinasqueaprendem.com/category/overfitting/>. Acesso em: 27 set. 2024.

GABRIEL. Analise de Regressão - Linear. **Blogspot**, 16 de maio de 2016. Disponível em: <https://mercado-gestao-empeend.blogspot.com/2016/05/analise-de-regressao-linear.html>. Acesso em: 27 set. 2024.

GOEL, Ankit. Are you using Pipeline in Scikit-Learn? **Medium**, 20 de junho de 2020. Disponível em: <https://towardsdatascience.com/are-you-using-pipeline-in-scikit-learn-ac4cd85cb27f>. Acesso em: 27 set. 2024.

IZBICKI, Rafael; DOS SANTOS, Tiago Mendonça. **Aprendizado de máquina:** uma abordagem estatística. Rafael Izbicki, 2020.

LIU, Patrick Langechuan. Multimodal Regression — Beyond L1 and L2 Loss. **Medium**, 30 de setembro de 2019. Disponível em: <https://towardsdatascience.com/anchors-and-multi-bin-loss-for-multi-modal-target-regression-647ea1974617>. Acesso em: 27 set. 2024.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

PRAMOND, Om. Cross Validation. **Medium**, 21 de janeiro de 2023. Disponível em: <https://medium.com/@ompramod9921/cross-validation-623620ff84c2>. Acesso em: 27 set. 2024.

PROVOST, Foster. **Data Science para Negócios** by Tom Fawcett Foster Provost [Fawcett, Tom](z-lib. org).

RABELLO, Eduardo Braz. Cross Validation: Avaliando seu modelo de Machine Learning. **Medium**, 07 de julho de 2019. <https://medium.com/@edubrazrabello/cross-validation-avaliando-seu-modelo-de-machine-learning-1fb70df15b78>. Acesso em: 27 set. 2024.

RAJBANGSHI, Anju. Types of regression in Machine learning. **Medium**, 22 de maio de 2020. Disponível em: <https://miro.medium.com/max/628/1*GnoMPH4FsH6CTzqCmAj6bA.png>. Acesso em: 27 set. 2024.

RUSSELL, Stuart J.; NORVIG, Peter. **Inteligencia Artificial:** un enfoque moderno. 2004.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

GLOSSÁRIO

Termo	Explicação
XGBoost	eXtreme Gradient Boosting.
LOOCV	Leave-One-Out Cross-Validation.
MAE	Mean Absolute Error.
MSE	Mean Squared Error.
RMSE	Root Mean Squared Error.
SVM	Support Vector Machine.
SVR	Support Vector Regression.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com