FIAP ON

COLHEITA DE SOLUÇÕES INTELIGENTES - TRANSFORMANDO DADOS EM AÇÕES

DO LOCAL À NUVEM: REPLICANDO INFRAESTRUTURAS NA AWS

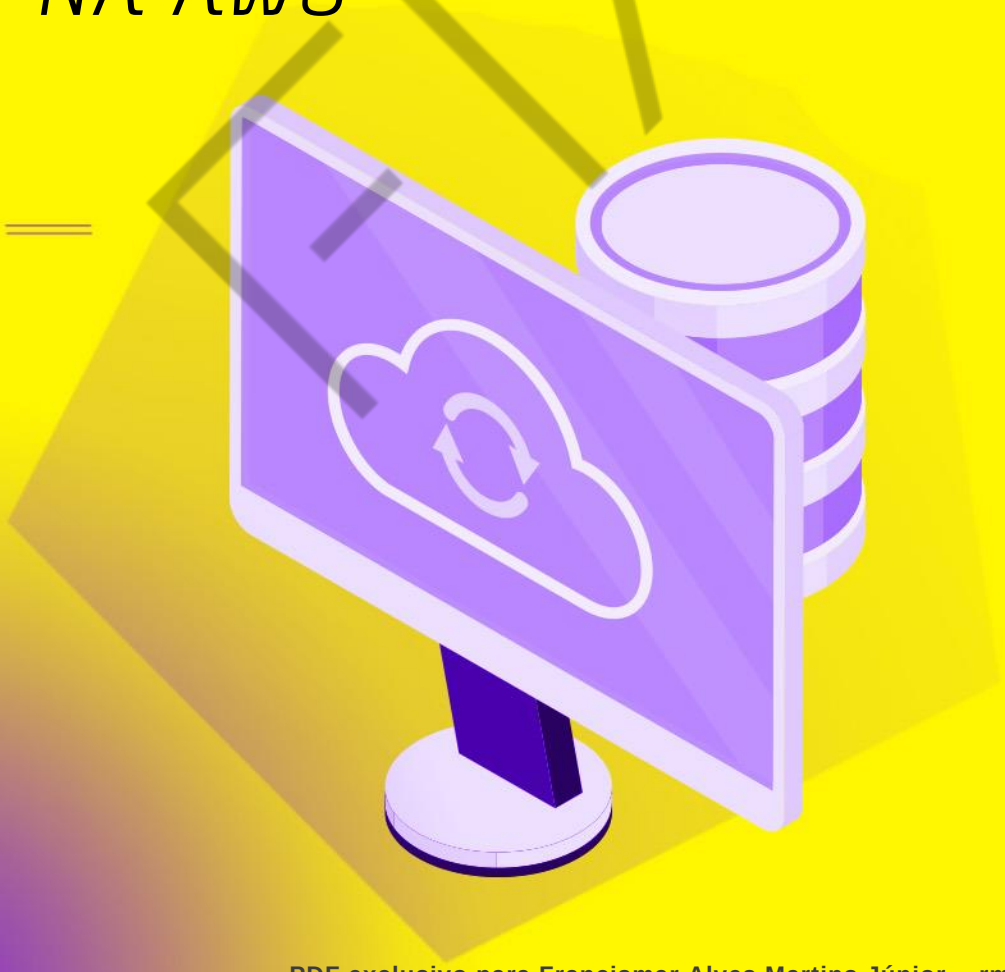

11

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Regiões e Zonas de Disponibilidade 5
Figura 2 - VPC dentro de uma região 8
Figura 3 - Endereçamento IP 8
Figura 4 - Máscara de sub-rede 9
Figura 5 - VPC com 4 sub-redes 9
Figura 6 - VPC com 2 sub-redes 10
Figura 7 - *Security Group* 11
Figura 8 - Instâncias da AWS 13
Figura 9 - Armazenamento em Volumes EBS 15
Figura 10 - EFS 16
Figura 11 - Site Estático com Bucket S3 17
Figura 12 - Bucket S3 Criado 18
Figura 13 - Arquivo em um bucket S3 18
Figura 14 - URL para um objeto no bucket 19
Figura 15 - Página estática disponível na web 19
Figura 16 - Criar Instância no RDS 21
Figura 17 - Instância do RDS criada 21
Figura 18 - Endpoint de uma instância RDS 22
Figura 19 - Conexão remota ao RDS 22
Figura 20 - ETL x ELT 23
Figura 21 - Ingestão, Armazenamento e Consumo 25
Figura 22 - AWS Athena 25

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE QUADROS

Quadro 1 - Famílias de instâncias.....14

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 DO LOCAL À NUVEM: REPLICANDO INFRAESTRUTURAS NA AWS.....5
1.1 Regiões, Zonas de Disponibilidade e VPCs.....5
1.2 Nuvem privada virtual (VPC).....7
1.3 Grupos de Segurança (*Security Groups*) 11
2 MÁQUINAS VIRTUAIS E TIPOS DE ARMAZENAMENTO.....13
2.1 Máquinas Virtuais (EC2).....13
2.2 Elastic Block Storage (EBS).....14
2.3 Elastic File System (EFS).....16
2.4 Simple Storage Service (S3) 17
3 BANCO DE DADOS NA NUVEM.....20
3.1 Base de dados Relacionais (RDS).....20
3.2 Ingestão de Dados 23
3.3 Consumo de Dados.....24
REFERÊNCIAS.....26
GLOSSÁRIO 27

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 DO LOCAL À NUVEM: REPLICANDO INFRAESTRUTURAS NA AWS

1.1 Regiões, Zonas de Disponibilidade e VPCs

Para disponibilizar serviços de computação em nuvem, a AWS mantém centenas de milhares de servidores em **datacenters** geograficamente distribuídos. Somente em um data center, existem aproximadamente entre 50 a 80 mil servidores.

Para manter o ambiente seguro, evitando falhas e garantindo a recuperabilidade, a AWS usa no mínimo dois conjuntos de datacenters, podendo chegar até 10 datacenters. Este agrupamento de datacenters é denominado de **Zona de Disponibilidade** (Avaiability Zone — AZ). Estes datacenters são conectados por redes de alta performance para garantir espelhamento dos dados, por exemplo.

Ainda, para garantir a latência e disponibilidade em diferentes locais, a AWS agrupa estas AZs em **regiões**. Por esta razão, existem regiões em vários locais do mundo, inclusive em São Paulo (sa-east-1).

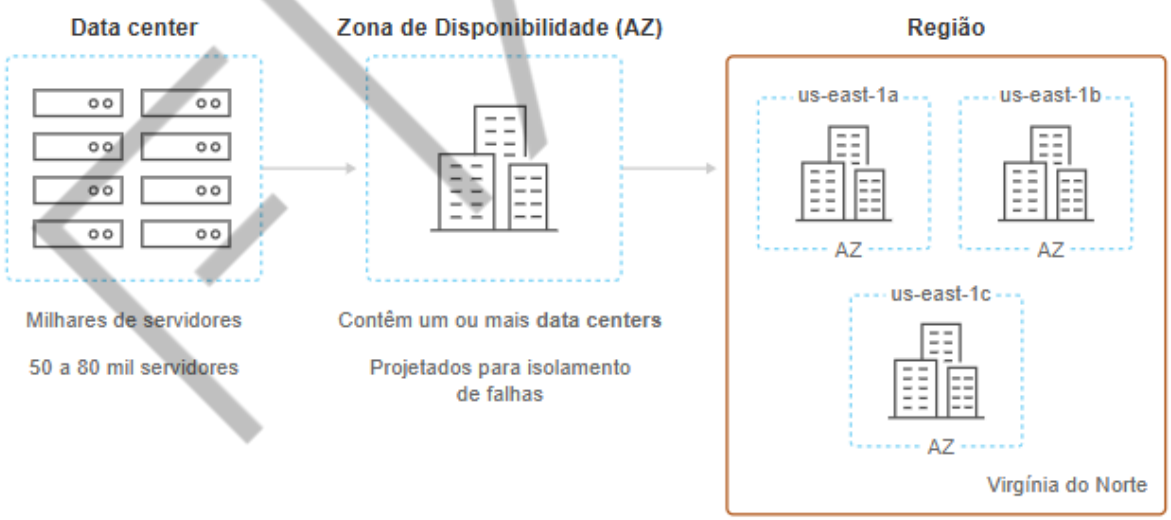

Figura 1 - Regiões e Zonas de Disponibilidade
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

É importante ressaltar que nem todos os serviços da AWS estão disponíveis em todas as regiões. Alguns serviços são lançados em regiões de países com maior demanda e, para prova de conceito, são incorporados gradativamente nas demais regiões.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Ainda existem subdivisões desta infraestrutura, como zonas locais, AWS Outposts e zonas de Wavelenght.

Em resumo, segue a descrição de cada agrupamento:

- Cada Região é uma área geográfica separada. Exemplo:
  - us-east-1 (North Virginia);
  - sa-east-1 (São Paulo).
- As zonas de disponibilidade (AZs) são vários locais isolados dentro de cada região. Exemplo:
  - us-east-1a.
- As zonas locais fornecem a capacidade de colocar recursos, como computação e armazenamento, em vários locais mais próximos dos usuários finais.
  - O código da zona local é o código da região pai, seguido do identificador da zona local. Exemplo: zona local us-west-2-lax-1 em Los Angeles e dentro da região us-west-2.
- O AWS Outposts leva serviços, infraestrutura e modelos operacionais nativos da AWS e, local do cliente. Este serviço é conhecido como ***colocation.*** A AWS gerencia a capacidade de computação como parte de uma região da AWS. Ou seja, os recursos computacionais ficam no ambiente do cliente (*on-premises*).
- As zonas do Wavelength permitem que os desenvolvedores criem aplicações que oferecem baixíssimas latências para dispositivos 5G e usuários finais. O Wavelength implanta os serviços de armazenamento e computação padrão da AWS até a borda das redes 5G de operadoras de telecomunicação.

Vale ressaltar que as zonas locais e as Wavelength zones não estão disponíveis em todas as regiões.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Observação: é possível consultar a disponibilidade de regiões no site: <https://aws.amazon.com/pt/about-aws/global-infrastructure/>, já as zonas locais e Wavelengths podem ser consultadas na página de documentação da AWS: <https://docs.aws.amazon.com/>.

Para decidir em qual região devemos alocar nossa nuvem privada, devemos considerar alguns critérios como:

- **Proximidade:** regiões mais próximas possuem menor latência, ou seja, o tempo de acesso a um servidor mais próximo é menor.
- **Compliance:** verifique as normas de armazenamento de dados da empresa e se as normas de proteção de dados do país (exemplo: LGPD) são compatíveis com as normas da região a ser escolhida.
- **Custo:** os custos variam de acordo com região. Em alguns casos, devido a uma maior infraestrutura, regiões mais distantes têm custos menores.

Agora que já sabemos como funcionam as regiões e as suas agregações, iremos abordar o conceito de nuvem privada virtual.

1.2 Nuvem privada virtual (VPC)

Uma nuvem privada virtual (Virtual Private Cloud — VPC) é uma rede virtual dedicada à sua conta na AWS. Utilizando essa rede, é possível provisionar recursos da AWS, como máquinas virtuais, instâncias de banco de dados, entre outros. É uma seção **isolada logicamente** de outros clientes da AWS. Ao criarmos uma conta na AWS, já temos uma VPC padrão criada para nós.

Dentro da VPC, podemos criar sub-redes públicas ou privadas. Uma VPC pode existir em apenas uma região, mas pode ter sub-redes em outras AZs na mesma região, conforme mostra a figura a seguir.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

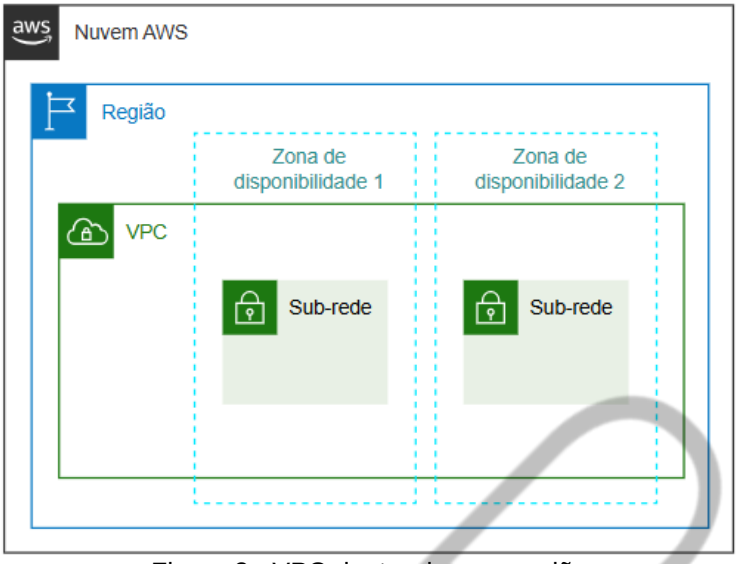

Figura 2 - VPC dentro de uma região
Fonte: AWS (2024)

Para criar uma VPC, é importante lembrar que podemos escolher a quantidade de sub-redes, além da quantidade de máquinas em cada sub-rede. Para isso, vamos observar o padrão do IPv4, que utiliza o sistema binário de 32 bits para definir um endereço de IP (Internet Protocolo).

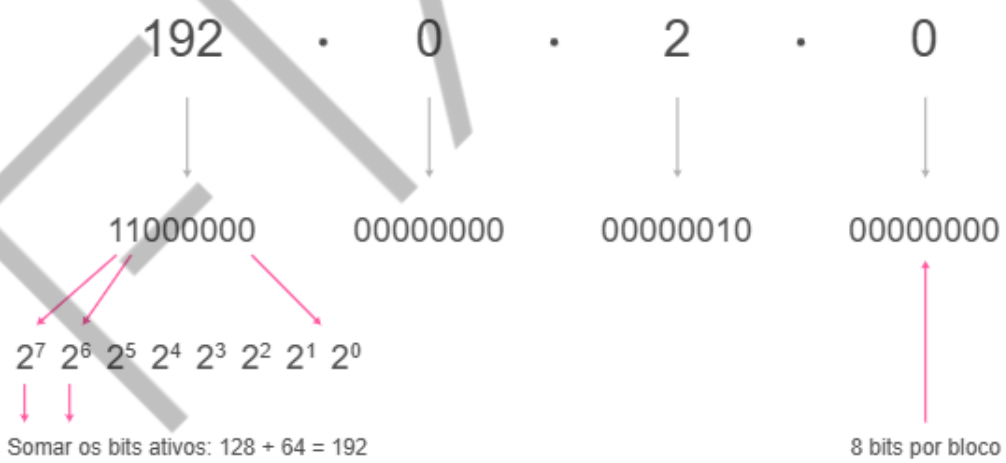

Figura 3 - Endereçamento IP
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

Podemos usar uma parte do bloco de IP para definir os bits usados para a rede e os bits usados para os equipamentos, utilizando uma **máscara de sub-rede**. Para isso, podemos usar uma notação conhecida como Class Inter-Domain Routing (CIDR), que permite definir os bits usados para a rede e os bits usados para os equipamentos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

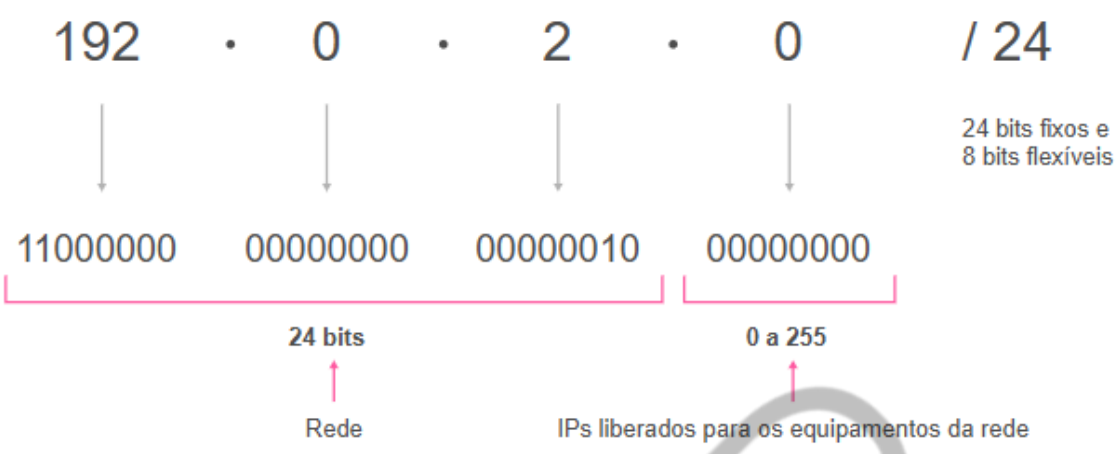

Figura 4 - Máscara de sub-rede
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

Considere o exemplo a seguir, onde definimos um bloco CIDR IPv4 de **10.0**.0.0/16. Neste caso, 16 bits são alocados para a rede (em negrito). Além disso, podemos criar diferentes sub-redes, podendo alocar equipamentos de departamentos distintos, por exemplo.

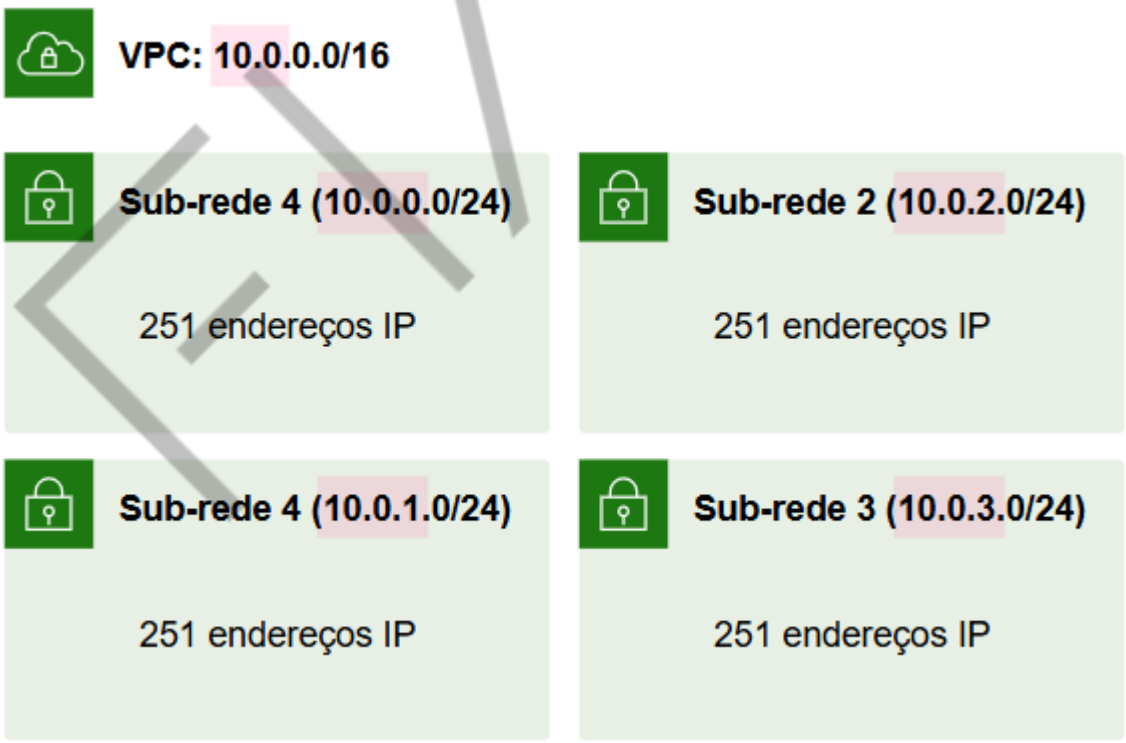

Figura 5 - VPC com 4 sub-redes
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

Na figura anterior, temos 4 sub-redes. A sub-rede 1 está definida com o endereço de rede 10.0.0. O último bloco de 8 bits do IP é destinado para alocação de

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

equipamentos, podendo chegar a 251 endereços IPs, sendo que alguns IPs são reservados:

- 10.0.0.0 — Endereço de rede;
- 10.0.0.1 — Comunicação Interna;
- 10.0.0.2 — DNS;
- 10.0.0.3 — Uso futuro;
- 10.0.0.255 — Endereço de transmissão de rede (***broadcast***).

A AWS também suporta o conceito mais moderno de atribuição de IPs (IPv6) que define 128 bits para endereçamento. Focaremos apenas no IPv4.

Vejamos um diagrama simples em que temos um servidor web e um servidor de banco de dados, ambos implantados na nuvem.

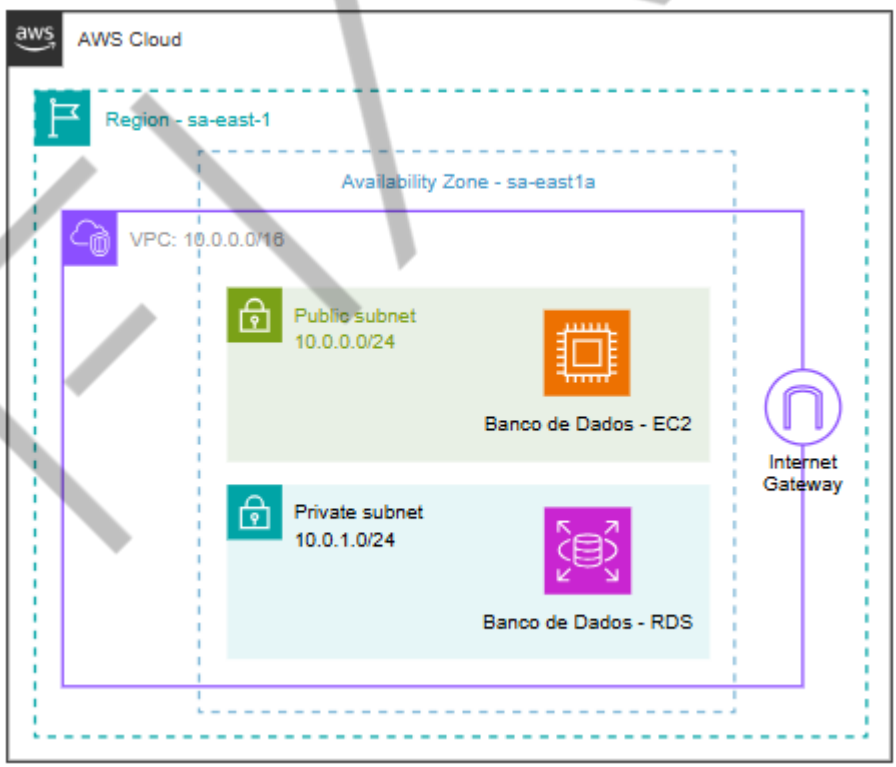

Figura 6 - VPC com 2 sub-redes
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

Na figura anterior, podemos observar um diagrama para a implantação de uma VPC (10.0.0.0/16) na região de São Paulo (sa-east-1), em uma única zona de

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

disponibilidade (sa-east-1a). Existe uma sub-rede pública (10.0.0.0/24) que contém um servidor web e uma sub-rede privada que contém uma sub-rede privada com uma instância de um banco de dados. Além disso, podemos observar uma saída para a internet da VPC, o chamado Internet Gateway.

Este é um cenário simples que pode ser implementado nas empresas. Entretanto, existem outros serviços de rede que podem ser incluídos com o intuito de garantir a disponibilidade e o balanceamento de carga, ou até mesmo para proteger o tráfego de entrada e saída da rede, por meio de um firewall.

Vejamos agora o conceito de **Security Group** no próximo tópico.

1.3 Grupos de Segurança (*Security Groups*)

Um grupo de segurança (*Security Group* — SG) atua como um firewall virtual que controla o tráfego de entrada e saída para os dispositivos definidos em uma VPC, como máquinas virtuais. No *Security Group*, podemos definir regras para permitir ou negar tráfego com base em portas e protocolos específicos.

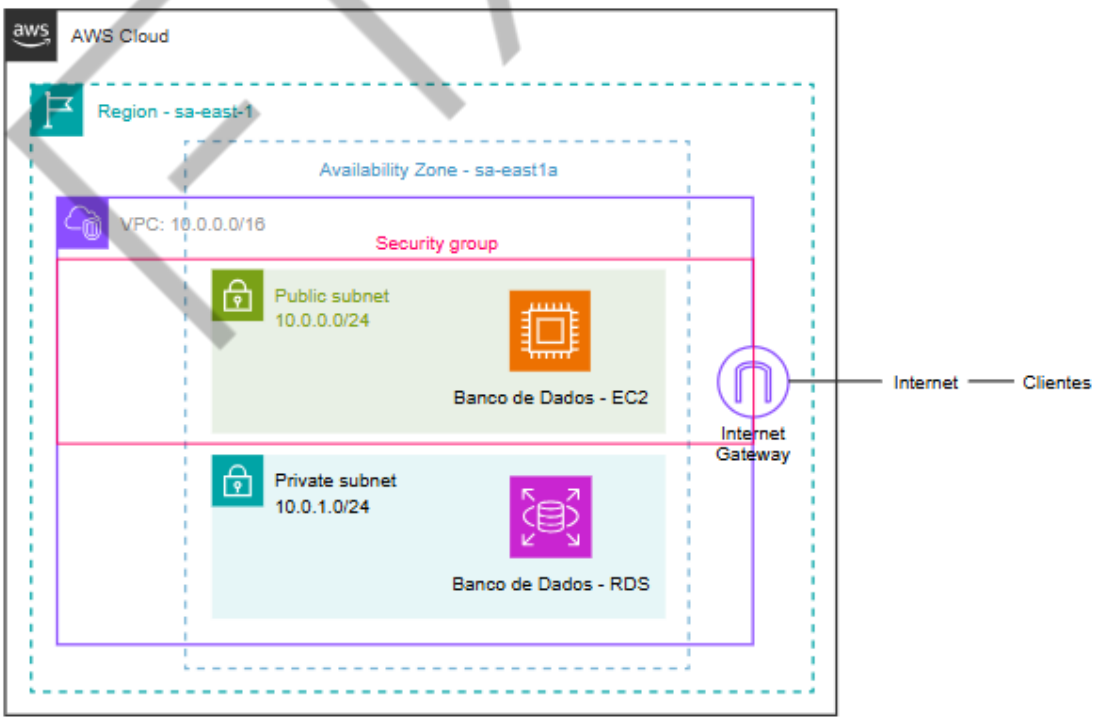

Figura 7 - *Security Group*
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Na figura anterior, podemos observar em vermelho um *Security Group* que protege todo o tráfego, limitando somente as portas específicas para acesso à VPC. No *Security Group*, é possível definir quais portas são liberadas tanto para a entrada de dados quanto para a saída de dados. Por padrão, ao criar um grupo de segurança, todos os acessos são limitados, fazendo com que seja necessário configurar explicitamente as portas que precisamos liberar.

Por exemplo, podemos liberar a porta 80 ou a porta 8080 para acesso de qualquer IP em casos nos quais expomos um servidor web para a internet. Assim, podemos “subir” um servidor web para a nuvem da AWS, permitindo que seja acessível somente pelas portas específicas. Veremos agora como gerenciar máquinas virtuais na AWS.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 MÁQUINAS VIRTUAIS E TIPOS DE ARMAZENAMENTO

2.1 Máquinas Virtuais (EC2)

O Elastic Compute Cloud (EC2) é um serviço de computação em nuvem que permite criar instâncias de máquinas virtuais. Neste serviço, podemos escolher diversas configurações de máquinas e de sistemas operacionais, escolhendo imagens prontas da AWS (Amazon Machine Images — AMI). Também é possível criarmos nossas próprias imagens para serem reutilizadas diversas vezes.

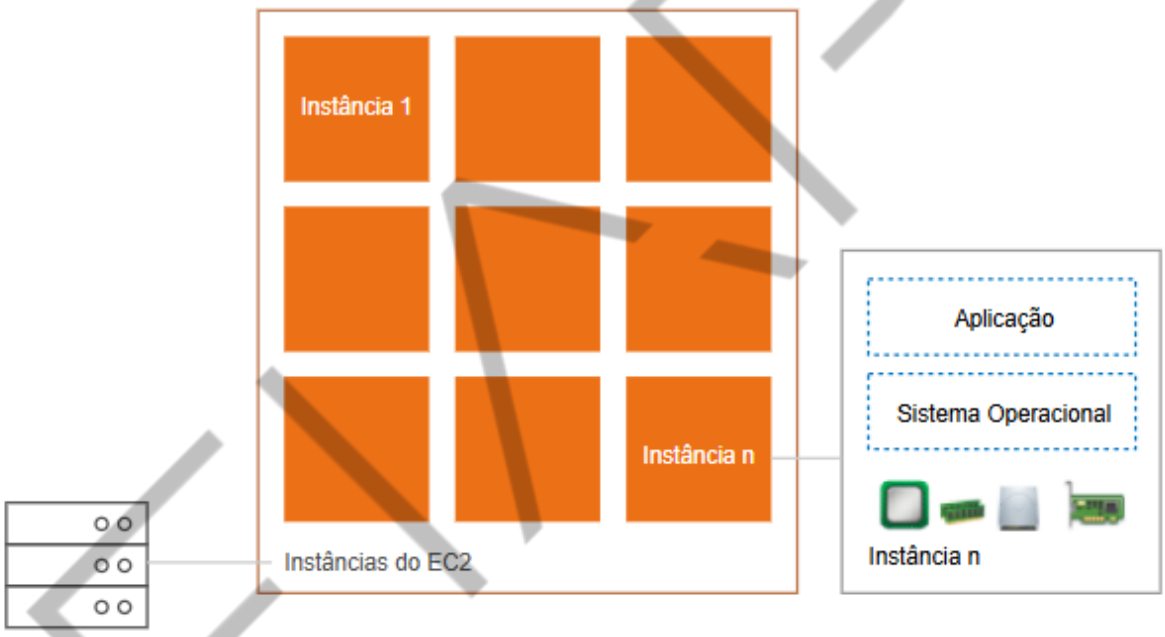

Figura 8 - Instâncias da AWS
Fonte: Elaborado pelo autor (2024), adaptado por FIAP (2025)

Na figura “Instâncias da AWS”, podemos observar que um grupo de servidores pode ter várias instâncias (máquinas virtuais). Cada instância tem sua própria configuração, como memória, CPU, HD, rede e sistema operacional.

A AWS oferece diversos tipos de famílias de instâncias, como por exemplo:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Famílias de instâncias	Exemplo de uso
Propósito Geral (*General purpose*) A1, T3, T3a, T2, M6g, M5	Sites web de baixo tráfego; pequenas e médias bases de dados.
Otimizado para processamento (*Compute Optimized*) C5, C5n, C4, C7g	Sites web de alta performance; processamento de vídeo.
Otimizado para memória (*Memory Optimized*) R5, R5n, X1e, X1, z1d	Bancos de dados na memória (exemplo: redis).
Otimizado para armazenamento (*Storage Optimized*) I3, I3en, D2, H1	Data warehousing; aplicações que processam dados e logs.
Computação acelerada (*Accelerated computing*) P3, P2, Inf1, G4, G3, F1	Machine Learning; visualizações 3D.

Quadro 1 - Famílias de instâncias
Fonte: Elaborado pelo autor (2024)

Existem instâncias para propósito geral, como pequenos websites, até instâncias otimizadas para execução de trabalhos de Machine Learning.

Ao criar uma instância, os endereços IPs são atribuídos dinamicamente, inclusive um IP público para acesso à internet e outro para comunicação na sub-rede privada. No entanto, o IP é renovado quando a instância é renovada. É possível adquirir um serviço adicional para manter sempre o mesmo IP, chamado de Elastic IP, podendo mover o IP entre as instâncias existentes.

Ao criar instâncias, definimos o espaço de armazenamento para o sistema operacional e para discos externos. Estes espaços são chamados de **Elastic Block Storage**.

2.2 Elastic Block Storage (EBS)

O Elastic Block Storage é um tipo de HD (Hard Disk) virtual. Por padrão, há um HD destinado para o sistema operacional, como por exemplo, o disco C: em máquinas com o sistema operacional Windows, com pelo menos 10 GB e no máximo 64TB. Os dados armazenados neste volume (C:) são efêmeros e se perdem toda vez que a instância é reiniciada. É possível ainda criar outro volume do EBS que pode ser

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

anexado a qualquer instância, criando outra partição (exemplo: disco D:) e que mantém os dados após reiniciar. Este volume adicional pode ser mantido mesmo após a exclusão da instância e anexado futuramente em outras instâncias.

Por exemplo, podemos criar um volume EBS extra (D:) para armazenar dados de um servidor web, enquanto o volume principal (C:) fica sendo utilizado apenas para armazenar dados do sistema operacional.

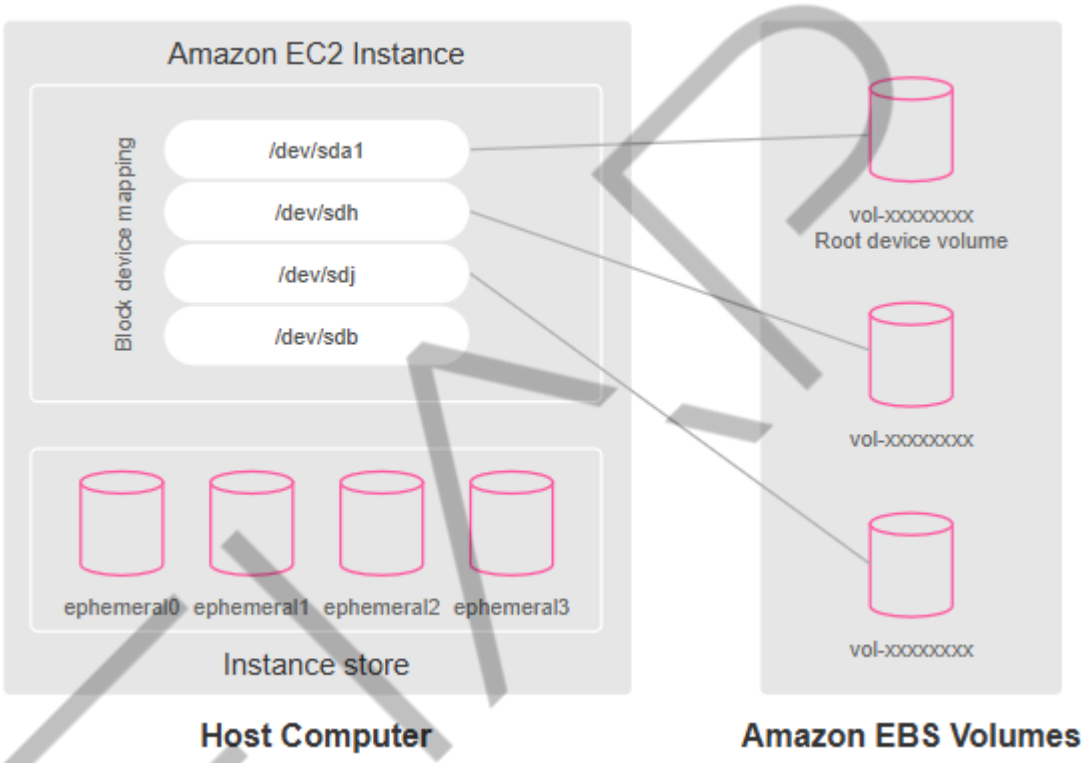

Figura 9 - Armazenamento em Volumes EBS
Fonte: AWS (2024),adaptado por FIAP (2025)

É possível escolher, além da capacidade de armazenamento do HD, o tipo de HD, sendo Hard Disk Drives (HDD) ou Solid State Drives (SSD), e variações entre estas opções (exemplo: SSD NVMe).

É possível ainda realizar backups dos HDs da AWS, criando uma fotografia (*snapshot*) no tempo que pode eventualmente ser restaurada quando necessário. Estes backups ficam armazenados em um repositório de dados conhecido como S3.

Portanto, podemos armazenar e alterar arquivos no volume EBS sempre que necessário. Além do EBS, existem outros tipos de armazenamento compatível apenas com sistemas Linux, que é o Elastic File System (EFS), basicamente um *drive* de rede

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

que pode ser acessado simultaneamente por várias instâncias, e o Amazon Simple Storage Service (S3).

2.3 Elastic File System (EFS)

O Elastic File System (EFS) é um sistema de arquivos exclusivo para instâncias EC2 com Linux. Ele funciona como um "*drive*" de rede, podendo ser acessado tanto pelas máquinas virtuais da AWS quanto para máquinas *on-premises* do cliente. Algumas características são:

- Usa o protocolo NFS;
- Auto-dimensionável (aumenta o tamanho conforme demanda);
- Permite editar arquivos em tempo real.

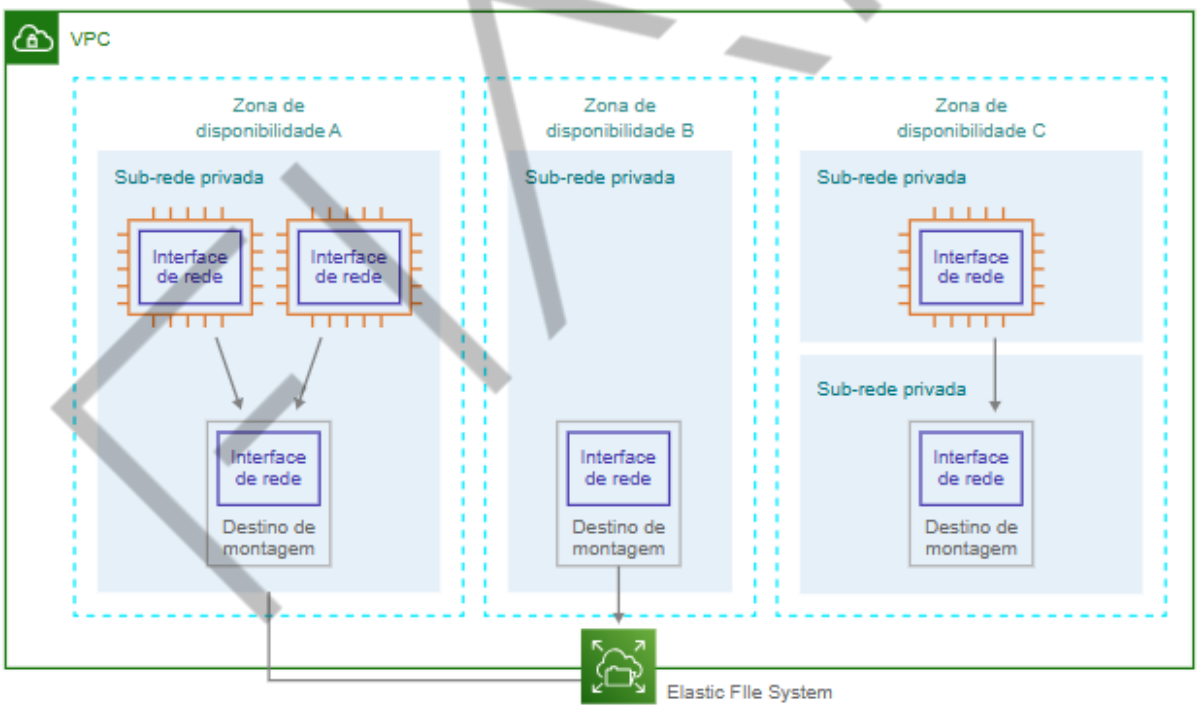

Figura 10 - EFS
Fonte: AWS (2024), adaptado por FIAP (2025)

Na figura "EFS", podemos observar o EFS servindo como um drive de rede para instâncias do EC2 distribuídas em diferentes zonas de disponibilidade, como se fosse um repositório central.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Além do NFS, é possível armazenar diferentes tipos de arquivos, sejam imagens, textos, entre outros, em outro serviço da AWS, conhecido como Amazon S3.

2.4 Simple Storage Service (S3)

O Amazon Simple Storage Service (S3) foi um dos primeiros serviços lançados pela AWS e permite o armazenamento de diferentes tipos de arquivos, como imagens, textos e demais formatos. Ele utiliza o conceito de *bucket*, onde cada arquivo armazenado é chamado de objeto. No S3, diferentemente do EBS, não é possível alterar objetos. Ou seja, cada alteração substitui completamente o objeto.

Podemos armazenar, por exemplo, arquivos de aplicações, log, vídeos, imagens e arquivos separados por vírgula (CSV) para que sejam processados e depois incluídos em um banco de dados. O custo de armazenamento no S3 é muito mais barato, possuindo versões para uso recorrente, como o **S3 Standard,** e versões específicas para armazenamento de longo prazo para uso em auditorias, com o **S3 Glacier**. Podemos usar o S3 para a construção de um *data lake*, servindo como um repositório central de dados, para que depois sejam rodados algoritmos de Machine Learning e Computação Distribuída.

É possível ainda criar um site estático utilizando o serviço do S3. Para isso, basta subir um arquivo HTML em um bucket S3 e expor o acesso ao bucket de forma pública pela internet, configurando a política de acesso ao bucket.

Figura 11 - Site Estático com Bucket S3
Fonte: Elaborado pelo autor (2024)

Após a criação de um bucket, é possível armazenar diferentes tipos de arquivos diretamente ao bucket ou programaticamente, por meio do SDK.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

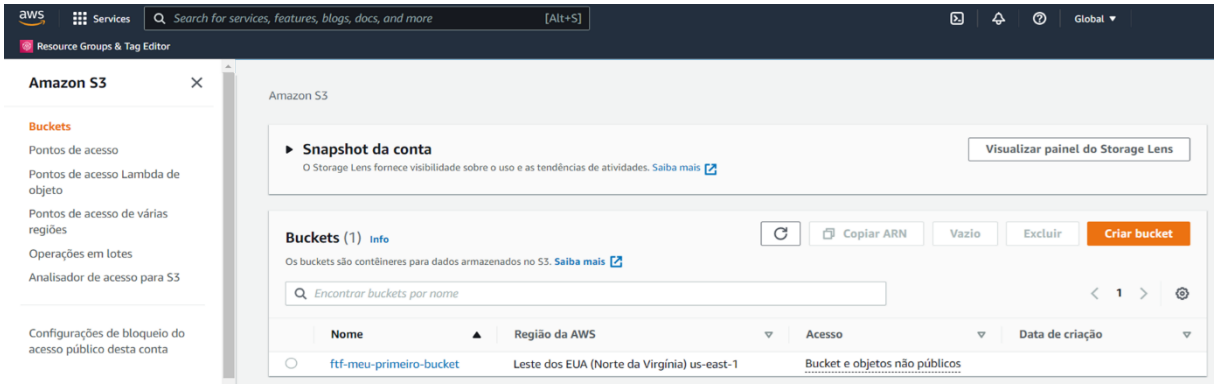

Figura 12 - Bucket S3 Criado
Fonte: Elaborado pelo autor (2024)

Na figura “Bucket S3 Criado”, podemos observar um bucket criado denominado “ftf-meu-primeiro-bucket”. O bucket é gerado em uma região específica. Neste caso, ele foi criado na região da Virgínia do Norte, nos EUA, conhecida pela sigla us-east-1.

Após a criação do bucket, se torna possível adicionar arquivos ao mesmo, inclusive páginas estáticas HTML, para servir de site institucional, por exemplo.

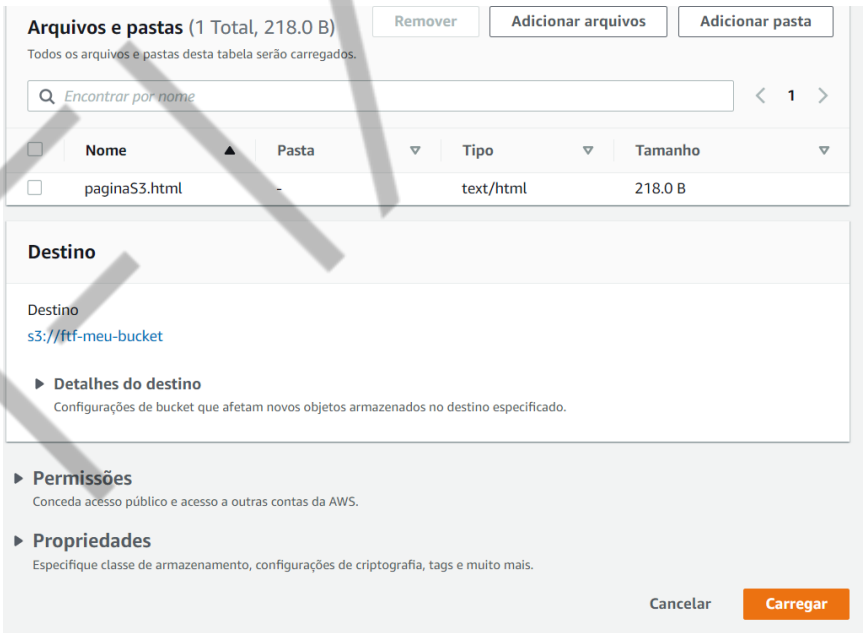

Figura 13 - Arquivo em um bucket S3
Fonte: Elaborado pelo autor (2024)

Na figura “Arquivo em um bucket S3”, podemos observar uma página HTML (paginaS3.html) dentro de um bucket S3.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Quando adicionamos qualquer objeto como arquivo, página html, imagem, entre outros, é criada uma URL para acesso direto ao objeto.

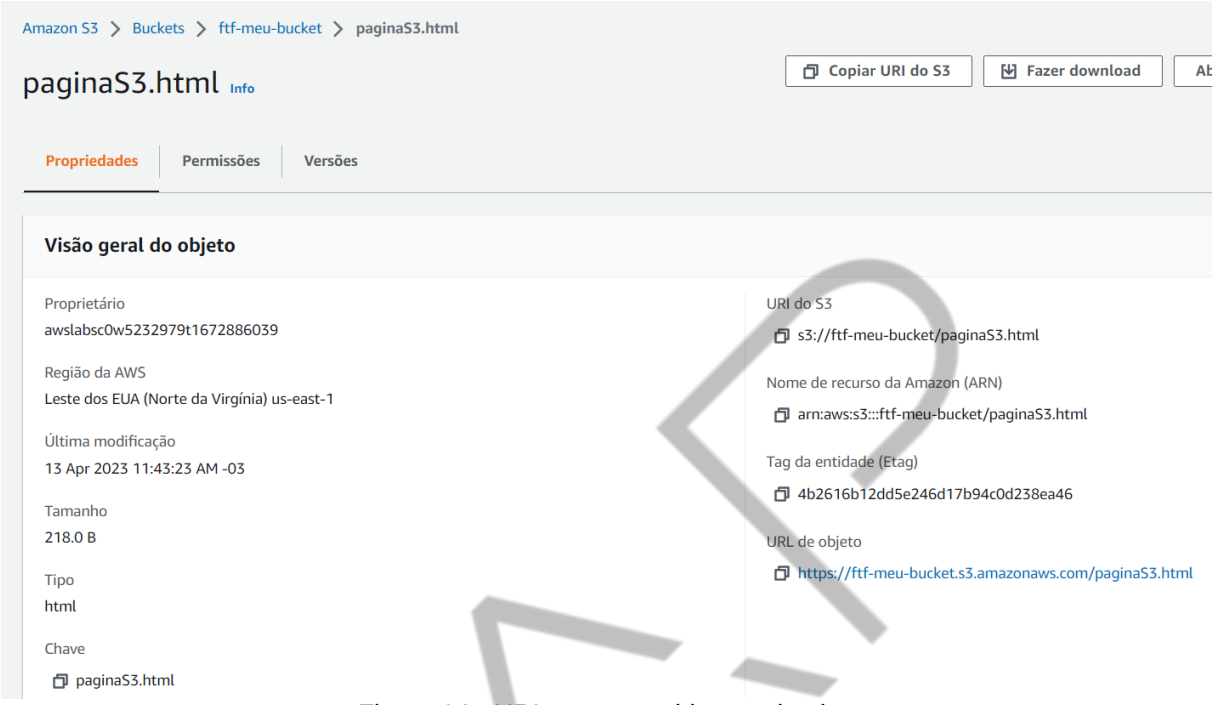

Figura 14 - URL para um objeto no bucket
Fonte: Elaborado pelo autor (2024)

Na figura “URL para um objeto no bucket”, podemos observar uma URL (<https://ftf-meu-bucket.s3.amazonaws.com/paginaS3.html>). A partir desta URL e fornecidas as devidas permissões de acesso público (editada a política de segurança), podemos acessar de qualquer lugar do mundo nosso site estático.

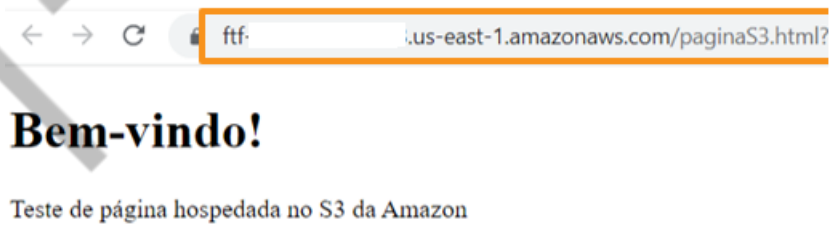

Figura 15 - Página estática disponível na web
Fonte: Elaborado pelo autor (2024)

Como podemos observar na figura “Página estática disponível na web”, é possível visualizar uma página HTML em um navegador da internet.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 BANCO DE DADOS NA NUVEM

A AWS oferece diversos tipos de bancos de dados na nuvem, desde instâncias de base de dados relacionais, com suporte ao MySQL, SQL Server e outros, até bases de dados NoSQL, como o DynamoDB, o AWS Neptune, e entre outros. Vamos explorar algumas das opções disponíveis.

3.1 Base de dados Relacionais (RDS)

Nas bases de dados relacionais, os dados são armazenados em tabelas e usam apontamentos como chaves primárias e estrangeiras em um modelo de dados relacional, de maneira a minimizar redundâncias, garantir que as operações sejam executadas integralmente, a consistência dos dados, isolamento de transações e durabilidade dos dados. Estas características são conhecidas como ACID (Atomicidade, Consistência, Isolamento e Durabilidade).

- **Atomicidade:** as operações em um banco de dados são executadas completamente ou não são executadas.
- **Consistência:** a execução de uma transação deve levar de um estado consistente a um outro estado consistente.
- **Isolamento:** cada transação é executada isoladamente da outra, mesmo quando há concorrência.
- **Durabilidade:** após as transações, os dados são persistentes, mesmo em caso de falhas.

O Amazon Relational Database Services (RDS) oferece toda a estrutura para armazenar bases de dados relacionais. Há suporte para sistemas gerenciadores de bases de dados tradicionais (SGBDs), como o MySQL, o MariaDB, o MS SQL Server, o Oracle e o PostgreSQL. Além disso, a AWS conta com um SGDB customizado chamado Aurora, facilitando a escalabilidade e disponibilidade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Ao criar uma instância de banco de dados, você não precisa se preocupar em alocar uma máquina virtual e nem o sistema operacional por trás do banco de dados pois a AWS já cria automaticamente.

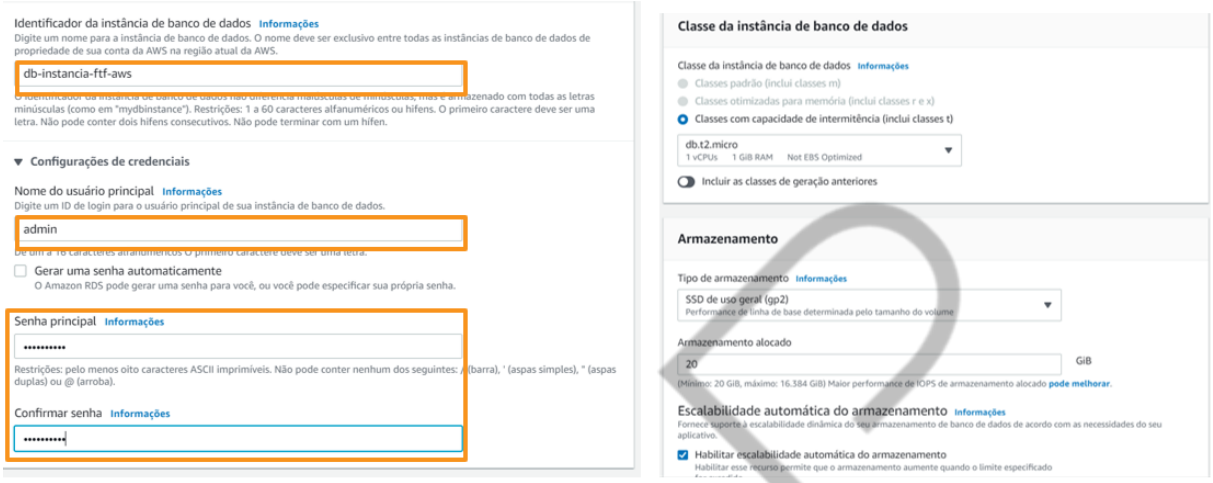

Figura 16 - Criar Instância no RDS
Fonte: Elaborado pelo autor (2024)

A figura “Criar Instâncias no RDS” mostra as opções selecionadas para criação de uma instância no RDS. Basta selecionar o tipo da instância, o nome do usuário principal e senha, e a família de instância que irá armazenar a base de dados, assim como o tamanho alocado para armazenamento. Além das configurações básicas, precisamos definir uma VPC onde a instância será instalada e um *Security Group* protegendo a instância, e, opcionalmente, o nome de uma base de dados. A partir deste *setup*, é possível acessar a base de dados remotamente ou direto pela AWS.

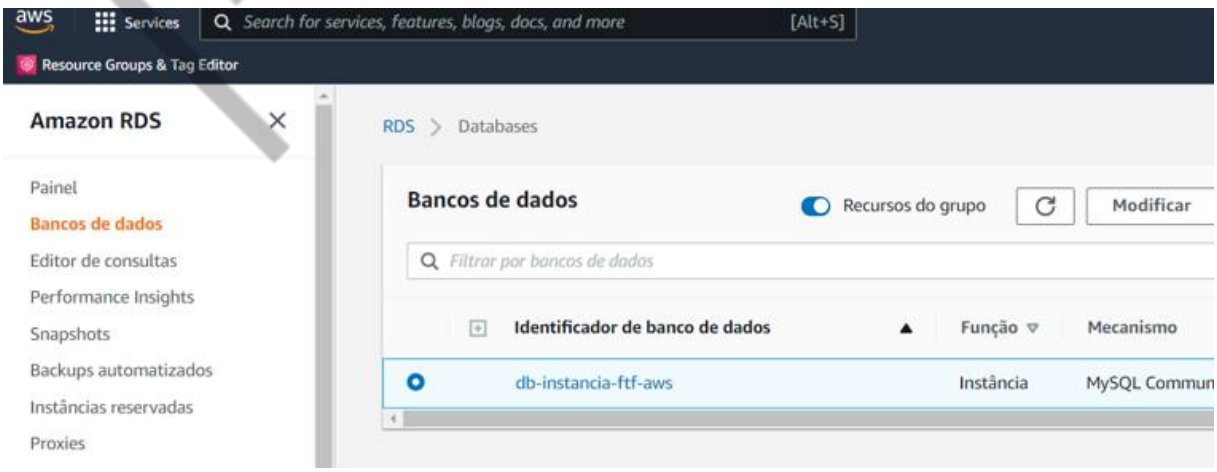

Figura 17 - Instância do RDS criada
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Na figura “Instância do RDS criada”, podemos observar uma instância criada no painel da Amazon RDS.

O Editor de consultas do RDS permite acessar diretamente somente as bases de dados do Amazon Aurora. Para consultar bases de dados, como do MySQL, é possível a conexão remota por meio do endereço da instância ou programaticamente, por meio de funções ou códigos em Python, por exemplo.

Ao clicar na instância, podemos obter detalhes de como acessar remotamente.

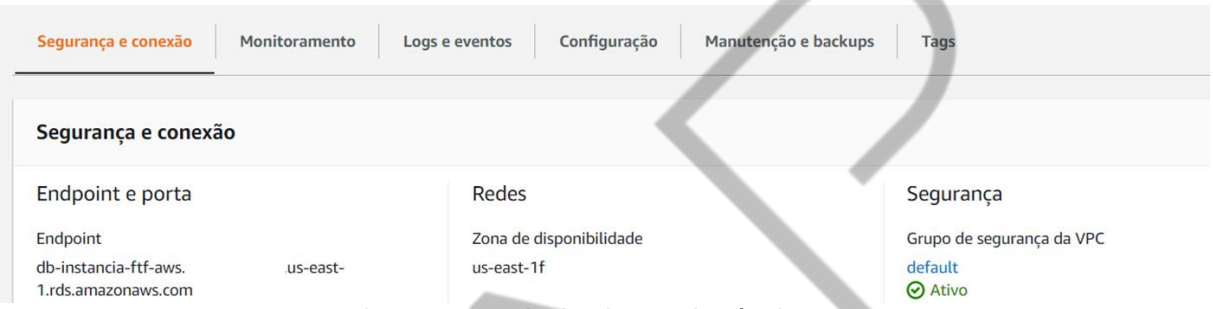

Figura 18 - Endpoint de uma instância RDS
Fonte: Elaborado pelo autor (2024)

Na figura a seguir, podemos observar a conexão realizada a partir de uma máquina on-premises, ao qual utilizamos o MySQL Workbench como interface e consultas e execução de queries.

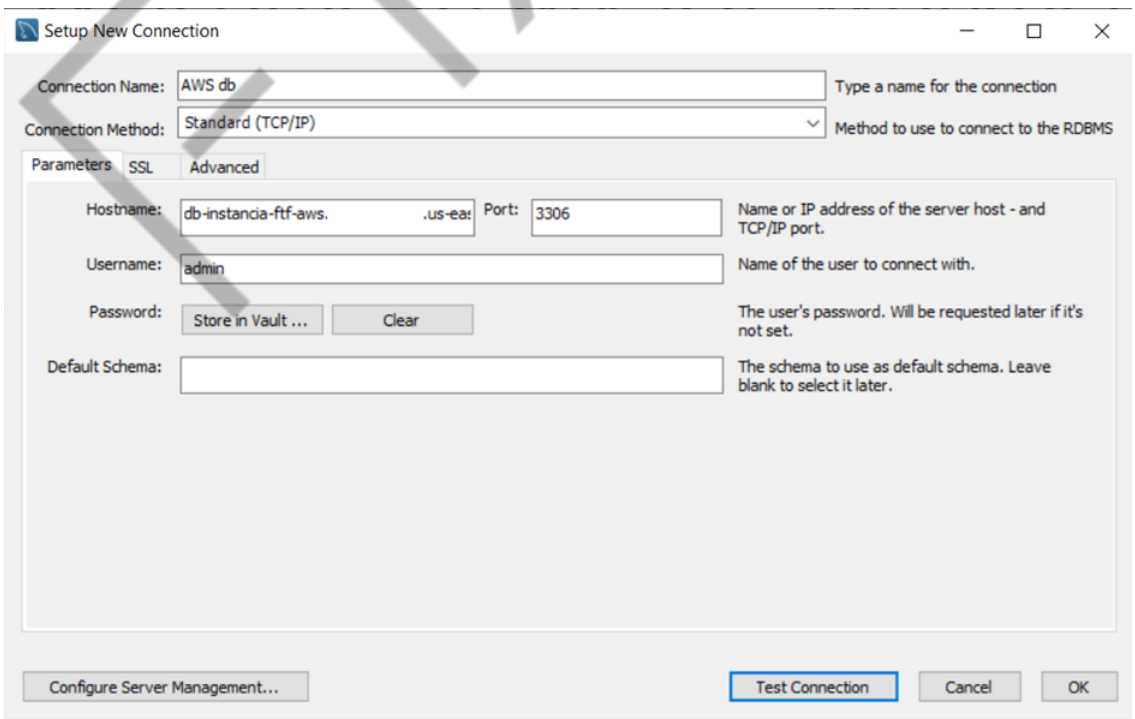

Figura 19 - Conexão remota ao RDS
Fonte: Elaborada pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Na figura “Conexão remota ao RDS”, podemos observar parte do endpoint digitado no campo Hostname, assim como a porta padrão para conexão a instâncias do MySQL.

3.2 Ingestão de Dados

O processo de ingestão de dados, seja em uma base de dados, seja em um repositório de objetos, como o S3, pode ser efetuado de diferentes maneiras, sendo:

- ETL — Extract, Transform and Load;
- ELT — Extract, Load and Transform.

O processo tradicional, conhecido como extração, transformação e carga (Extract, Transform, Load — ETL), pode ser usado, por exemplo, para ler um arquivo CSV, realizar uma transformação simples, como exclusão de algumas colunas e seguir para uma carga em uma base de dados relacional como o Amazon RDS ou até mesmo em um DataWarehouse, como o Amazon Redshift.

Além deste processo, podemos realizar o processo de extração, carga e transformação (Extract, Transform, Load – ETL), quando lidamos com grandes volumes de dados, para garantir a carga dos dados brutos e depois transformar os dados de acordo com os cenários de análise.

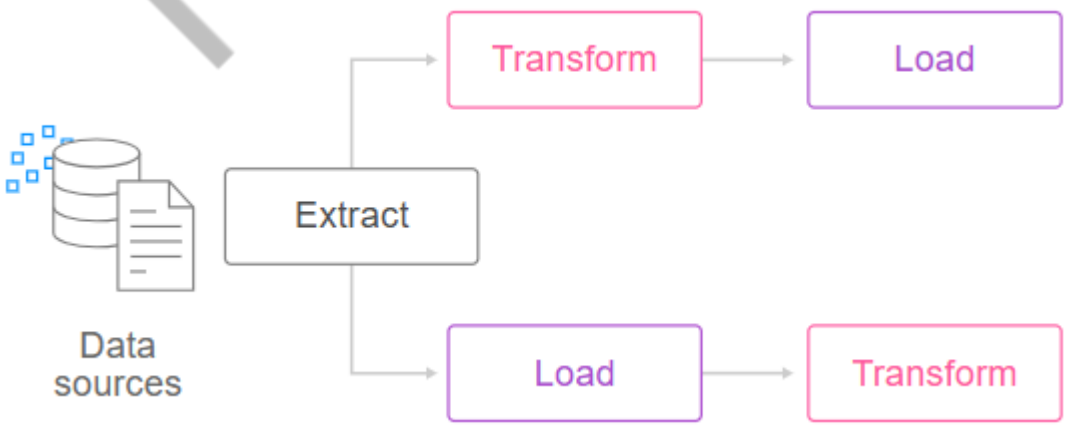

Figura 20 - ETL x ELT
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Portanto, o volume dos dados impacta no processo de carga dos dados em um banco de dados e até mesmo na escolha do banco de dados a ser armazenado. O **Amazon Redshift**, por exemplo, é uma **base de dados colunar**, otimizada para armazenar grandes volumes de dados e facilitando a consulta e agregação de dados, pois usa paralelismo para ingestão e consulta.

Em vários cenários de análises de dados, os dados podem ser armazenados em um DataLake, composto por buckets S3 e bases de dados, em que se mantém os dados brutos em um repositório S3. Após um primeiro processamento, os dados podem ser filtrados, limpos e padronizados, salvando-os em outro repositório, chamado de dados confiáveis e, em seguida, podem ser enriquecidos com novas colunas para projetos específicos, conhecidos como dados curados. Esta arquitetura é conhecida como "**Arquitetura Medalhão**", em que os dados brutos estão na camada bronze, os dados confiáveis na camada prata e os dados enriquecidos na cama ouro.

3.3 Consumo de Dados

O consumo de dados por aplicações ou por analistas de dados pode ser feito também por diversos serviços. O Amazon Athena permite rodar consultas SQL diretamente em arquivos armazenados em um bucket S3 ou a partir do Amazon Redshift. Para isso, torna-se necessário catalogar as bases existentes em um data lake usando o serviço do AWS Glue, que é um *crawler* que busca em diferentes locais na nuvem da AWS. O *crawler* pode ser disparado sob demanda ou programado para ser executado em um horário específico.

O AWS Glue permite identificar o *schema* da base de dados, auto-inferindo as colunas e armazenando os metadados em um catálogo para consulta posterior.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

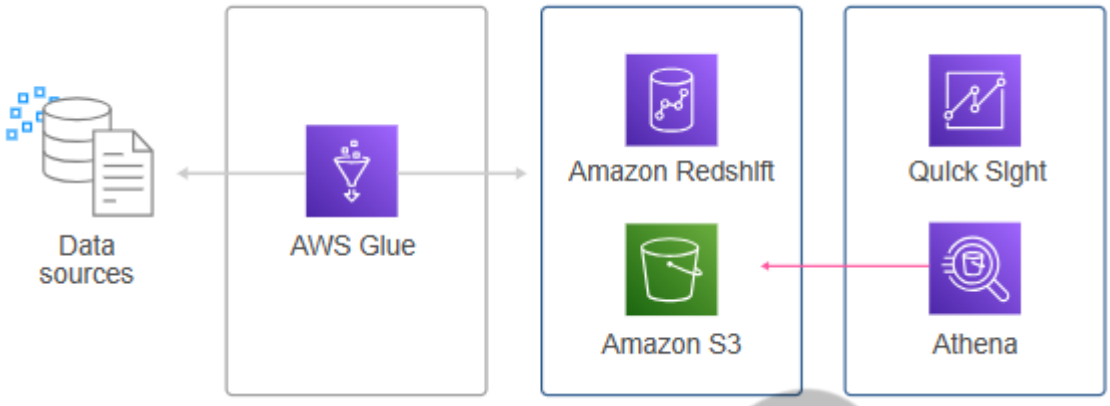

Figura 21 - Ingestão, Armazenamento e Consumo
Fonte: Elaborado pelo autor (2024)

Podemos agendar um *crawler* no AWS Glue para identificar e catalogar diferentes fontes de dados, fazer e executar o ETL para depois deixar os dados pesquisáveis por serviços, como o AWS Athena ou o Amazon Quick Sight.

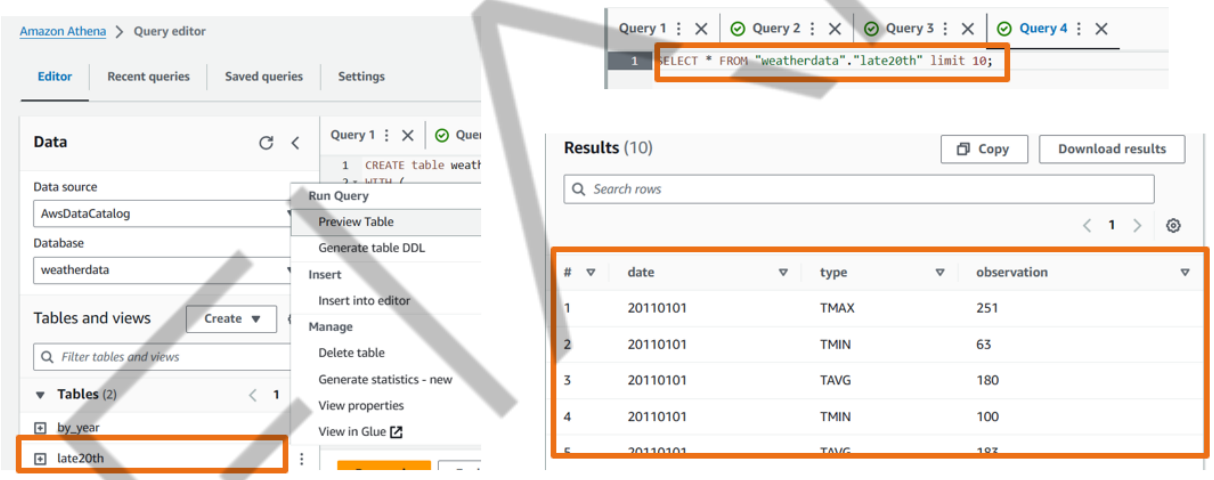

Figura 22 - AWS Athena
Fonte: Elaborado pelo autor (2024)

Na figura “AWS Athena”, é possível observar algumas tabelas catalogadas pelo AWS Glue (chamadas de late20th e by_year). Na figura à direita, podemos ver uma consulta SQL que retorna os primeiros 10 registros da tabela.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

ARQUITETURA Medalhão. **DataBricks**. Disponível em: <https://www.databricks.com/br/glossary/medallion-architecture>. Acesso em: 30 jan. de 2024.

AWS Academy. **AWS Academy**. Disponível em: <https://awsacademy.instructure.com/>. Acesso em: 30 jan. de 2024.

EAGAR, G. **Data Engineering with AWS .** Birmingham, UK: Packt Publishing, 2021.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de Banco de Dados.** 7º Ed.; São Paulo: Pearson Education do Brasil, 2018.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

GLOSSÁRIO

AWS	Amazon Web Services.
CLI	Command Line Interface.
EBS	Elastic Block Storage.
EC2	Elastic Compute Cloud.
EFS	Elastic File System.
RDS	Relational Database Service.
ELT	Extração, Carga e Transformação.
ETL	Extração, Transformação e Carga.
S3	Amazon Simple Storage Sevice.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com