FIAP ON

COLHEITA DE SOLUÇÕES INTELIGENTES - TRANSFORMANDO DADOS EM AÇÕES

DECIFRANDO O ALGORITMO: SISTEMAS DE RECOMENDAÇÃO INTELIGENTES

13

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Exemplo de recomendação de produtos no site da Amazon 7
Figura 2 - Pipeline tradicional de Ciência de Dados.....9
Figura 3 - Ilustração de um teste A/B 14
Figura 4 - Intuição da filtragem baseada em conteúdo 16
Figura 5 - Exemplo de Filtragem Colaborativa usando intuições baseada em conteúdo 18
Figura 6 - Intuição da análise de cestas de mercado “98% das pessoas que compraram os itens A e B também compraram o item C”.....21
Figura 7 - Exemplos de modelos híbridos de recomendação na Netflix.....27
Figura 8 - Resultado da execução do código-fonte 1 35
Figura 9 - Resultado parcial da execução do código-fonte 2 36
Figura 10 - Resultado parcial da execução do código-fonte 3.....37
Figura 11 - Resultado da execução do código-fonte 5 38
Figura 12 - Resultado parcial da execução do código-fonte 5.....39
Figura 13 - Primeiras linhas dos arquivos da base MovieLens 41
Figura 14 - Resultado da execução do código-fonte 8 42
Figura 15 - Resultado da execução do código-fonte 9 42
Figura 16 - Resultado parcial da execução do código-fonte 10 - Parte 1.....43
Figura 17 - Resultado parcial da execução do código-fonte 10 - Parte 2.....44
Figura 18 - Exemplo de uso do sistema de recomendação de filme - Parte 1 46
Figura 19 - Exemplo de uso do sistema de recomendação de filme - Parte 2 46
Figura 20 - Exemplo de uso do sistema de recomendação de filme - Parte 3 47

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE QUADROS

Quadro 1 - Vantagens e desvantagens da filtragem por conteúdo 17
Quadro 2 - Vantagens e desvantagens da filtragem colaborativa 20
Quadro 3 - Vantagens e desvantagens do método Apriori.....23
Quadro 4 - Vantagens e desvantagens do método híbrido 27

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 - Instalação da biblioteca apyori.....35
Código-fonte 2 - Imports e leitura dos dados 35
Código-fonte 3 - Reorganizando os dados.....36
Código-fonte 4 - Criando regras de associação 37
Código-fonte 5 - Analisando a primeira regra.....38
Código-fonte 6 - Imprimindo as regras de associação geradas 38
Código-fonte 7 - Imports e leitura dos dados 40
Código-fonte 8 - Alterando a estrutura dos dados.....41
Código-fonte 9 - Limpando valores vazios 42
Código-fonte 10 - Limpando os dados 43
Código-fonte 11 - Tratando dados esparsos e construindo o motor de recomendação 44
Código-fonte 12 - Método de obtenção das recomendações.....45

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 DECIFRANDO O ALGORITMO: SISTEMAS DE RECOMENDAÇÃO INTELIGENTES 6
1.1 Conceitos 6
1.2 Importância....7
2 AVALIANDO O DESEMPENHO....9
2.1 Métricas clássicas 10
2.1.1 Precisão 11
2.1.2 Recall 11
2.1.3 F1-Score....12
2.2 Métricas específicas....12
2.2.1 Diversidade 12
2.2.2 Novidade 13
2.2.3 Serendipidade 13
2.3 Dificuldades da avaliação dos motores de recomendação....13
3 PRINCIPAIS ABORDAGENS....16
3.1 Filtragem por conteúdo....16
3.1.1 Funcionamento do método....16
3.1.2 Vantagens e desvantagens....17
3.2 Filtragem colaborativa 18
3.2.1 Funcionamento do método....19
3.2.2 Vantagens e desvantagens....19
3.3 Regras de associação....20
3.3.1 Funcionamento do método....21
3.3.2 Vantagens e desvantagens....22
3.4 Híbridas....23
3.4.1 Funcionamento do método....24
3.4.2 Vantagens e desvantagens....27
4 PRINCIPAIS DESAFIOS....28
4.1 Cold start....28
4.1.1 Contornando o cold start 29
4.2 Escalabilidade e Esparsidade 30
4.3 Vieses e bolhas....31
4.4 Privacidade e segurança de dados 32
5 HANDS ON: CONSTRUINDO SISTEMAS DE RECOMENDAÇÃO....34
5.1 Regras de associação....34
5.1.1 Sobre a base de dados 34
5.1.2 Implementando o método....35
5.2 Filtragem item-item....39
5.2.1 Sobre a base de dados 40
5.2.2 Implementando o método....40
5.3 Sobre outras técnicas....47
CONCLUSÃO....48
REFERÊNCIAS....49
GLOSSÁRIO 50

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 DECIFRANDO O ALGORITMO: SISTEMAS DE RECOMENDAÇÃO INTELIGENTES

1.1 Conceitos

Os sistemas de recomendação são ferramentas de Machine Learning projetadas para sugerir itens relevantes a usuários com base em seus **interesses**, **comportamentos passados** ou **características semelhantes** a outros usuários. Eles desempenham um papel crucial em ajudar os usuários a navegarem por grandes volumes de informações e encontrar o que é mais relevante para eles, tornando-se uma parte indispensável de plataformas digitais modernas. Desde indicar o próximo filme em uma plataforma de streaming até sugerir produtos em um e-commerce, esses sistemas transformaram a forma como consumimos informações e tomamos decisões, tanto de forma online quanto offline (se pensarmos na disposição de produtos em uma loja física).

No entanto, os sistemas de recomendação não são apenas sobre “o que exibir”, mas também sobre “o que não exibir”. Eles filtram o excesso de informações que poderia sobrecarregar o usuário, ajudando-o a se concentrar em opções mais relevantes. Esse papel de “curador” é especialmente valioso em tempos de abundância de dados, onde a quantidade de escolhas pode gerar indecisão. Nesse contexto, sistemas de recomendação atuam como **facilitadores**, guiando os usuários em um mar de informações.

A figura a seguir ilustra o conceito: dada a busca pelo livro “Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow”, o site da Amazon exibe o resultado principal e uma lista de produtos recomendados vinculados ao produto em questão. Podemos ver a sugestão de itens comprados em conjunto, bem como outros livros comprados por quem comprou o livro em questão ou apenas visualizados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

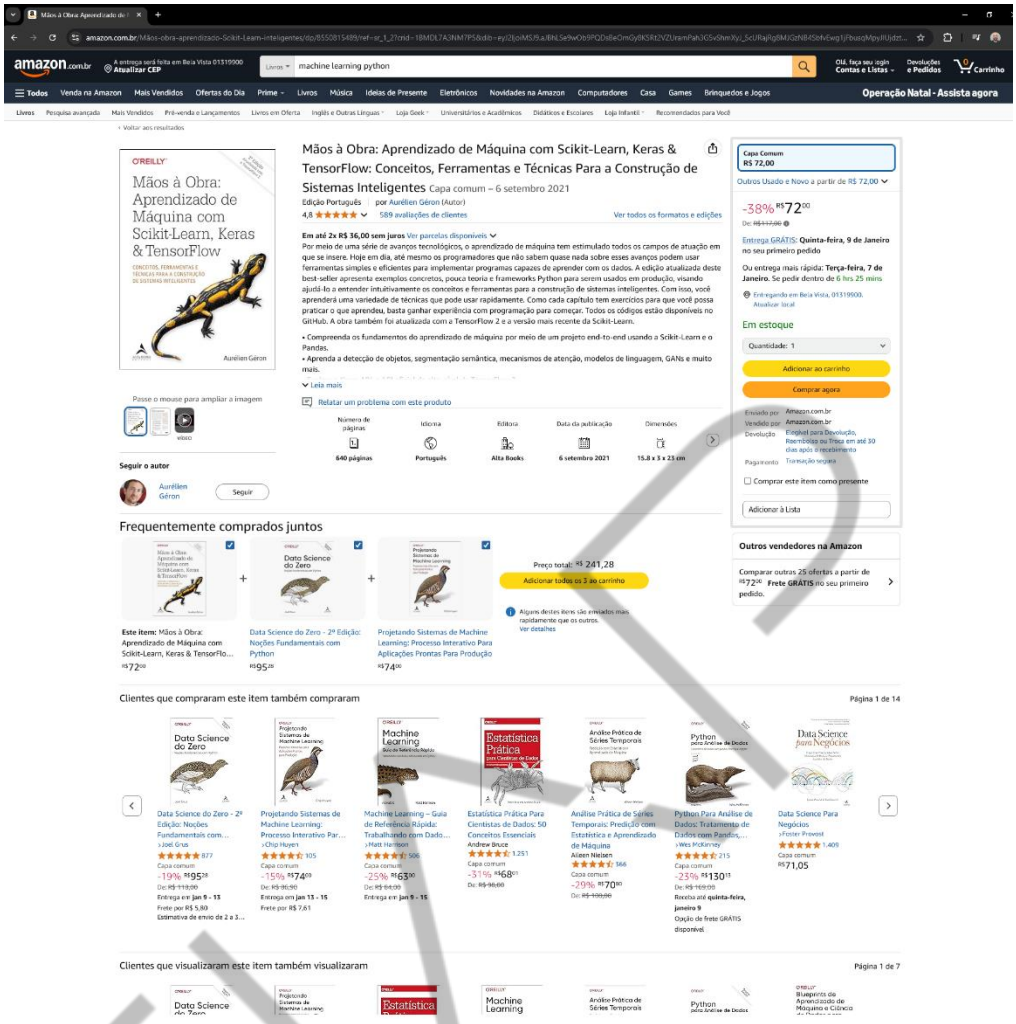

Figura 1 - Exemplo de recomendação de produtos no site da Amazon
Fonte: Elaborado pelo autor (2024)

Portanto, os sistemas de recomendação são mais do que algoritmos; eles são **componentes essenciais da experiência digital moderna**. Eles não apenas impulsionam o sucesso comercial das empresas, mas também melhoram a experiência do usuário, conectando pessoas a produtos, serviços ou informações que realmente importam. Ao longo deste capítulo, mergulharemos nas abordagens, métricas e desafios desses sistemas, entendendo por que eles são tão relevantes no mundo conectado de hoje.

1.2 Importância

A importância dos sistemas de recomendação se destaca em diversos setores. No **e-commerce**, sistemas de recomendação ajudam a melhorar as vendas ao sugerir produtos relacionados ou personalizar a vitrine de acordo com o perfil do usuário. Em

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

plataformas de streaming, como Netflix e Spotify, eles garantem que o conteúdo exibido seja relevante, aumentando o engajamento e o tempo de uso. Já em **redes sociais**, como Instagram ou TikTok, os sistemas de recomendação alimentam os algoritmos que decidem o que o usuário verá no feed, promovendo conteúdos que maximizam a interação.

Esse impacto vai além do lucro para as empresas; ele também beneficia diretamente os usuários. Ao personalizar a experiência, **os sistemas de recomendação economizam tempo e esforço dos usuários**, apresentando opções ajustadas às suas preferências. Por exemplo, em um serviço de streaming, um usuário pode rapidamente descobrir um novo filme favorito baseado em seus hábitos anteriores, sem precisar navegar por milhares de opções. Isso aumenta a satisfação e a fidelidade dos usuários, incentivando o retorno contínuo às plataformas.

A **personalização** proporcionada por esses sistemas também melhora a qualidade da interação entre usuário e plataforma. Quando os usuários percebem que suas preferências estão sendo reconhecidas e valorizadas, a sensação de confiança e envolvimento cresce. Além disso, a capacidade de oferecer recomendações exclusivas pode criar um **senso de novidade e surpresa**, aumentando a satisfação e a probabilidade de engajamento. Por exemplo, a descoberta de um produto inesperado em uma loja online pode ser vista como um “momento de encantamento”, fortalecendo o vínculo com o usuário.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2 AVALIANDO O DESEMPENHO

A construção de sistemas de recomendação também segue o pipeline tradicional de ciência de dados ilustrado na figura “Pipeline tradicional de Ciência de Dados”. Além de entender qual o principal objetivo de negócio (por exemplo: vender mais, reter o usuário, surpreender o usuário, entre outros), também devemos coletar dados e construir features relevantes. Adiante veremos as principais modelagens, mas já podemos refletir sobre sua **avaliação**.

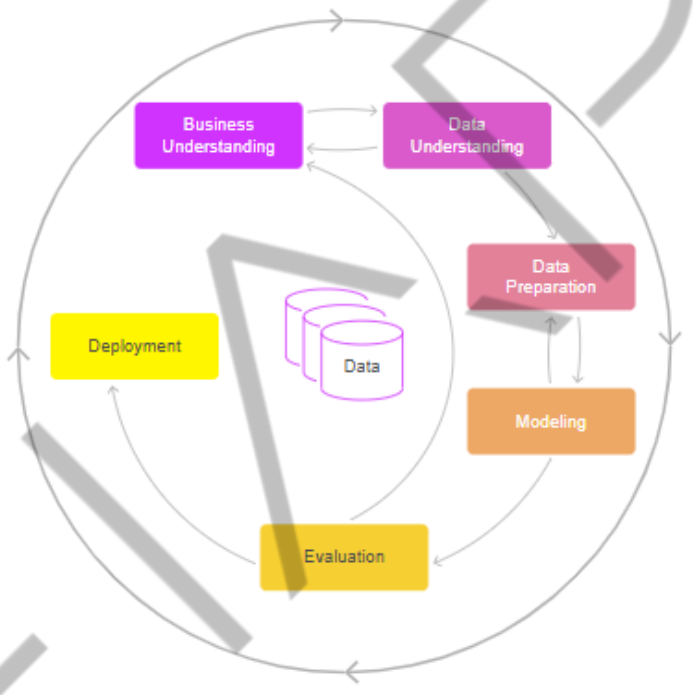

Figura 2 - Pipeline tradicional de Ciência de Dados
Fonte: Wikipédia (2012), adaptado por FIAP (2025)

Avaliar o desempenho de sistemas de recomendação é uma etapa fundamental para garantir que eles realmente entreguem valor tanto para o usuário quanto para o negócio. Diferentemente de modelos tradicionais de Machine Learning, onde geralmente avaliamos a precisão ou o erro de previsões numéricas ou categóricas, a avaliação de sistemas de recomendação é mais complexa. Não basta saber se o sistema está correto ao recomendar um item; **é necessário avaliar se as recomendações são relevantes, diversificadas, úteis e, principalmente, alinhadas ao objetivo da plataforma**, seja ele aumentar a conversão de vendas, o tempo de engajamento ou a satisfação do usuário.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A principal diferença em relação ao aprendizado supervisionado clássico reside no fato de que, em sistemas de recomendação, **não há necessariamente um "rótulo correto" para cada interação**. Por exemplo, em um sistema de e-commerce, não sabemos de antemão qual produto o usuário deseja comprar ou explorar, apenas inferimos isso com base em dados de interações passadas. Essa característica faz com que as métricas de avaliação de recomendação muitas vezes dependam de dados implícitos, como cliques ou visualizações, ao invés de dados explícitos, como classificações ou escolhas binárias, introduzindo um grau maior de incerteza.

Além disso, a avaliação de desempenho vai além do modelo em si e precisa considerar a experiência do usuário de maneira holística. Aspectos como diversidade e novidade das recomendações, equilíbrio entre personalização e exploração de novos conteúdos, e até mesmo preocupações éticas, como evitar vieses ou bolhas de filtro, entram em jogo. **Avaliar um sistema de recomendação, portanto, não é apenas uma questão de analisar acertos e erros, mas sim de medir como as recomendações contribuem para o objetivo final da aplicação, garantindo que atendam tanto às expectativas dos usuários quanto às metas estratégicas do negócio**. Essa avaliação ampla permite que o sistema evolua continuamente, ajustando-se às demandas de um ambiente dinâmico e competitivo.

Ainda assim, não podemos construir um modelo de recomendação e colocá-lo em produção sem testá-lo. Em breve, iremos discutir algumas formas de avaliar sistemas de recomendação.

2.1 Métricas clássicas

As métricas de Precisão, Recall e F1-Score são amplamente utilizadas para avaliar sistemas de recomendação, especialmente em situações em que é possível medir diretamente o acerto ou relevância das recomendações. Embora essas métricas sejam originalmente associadas ao aprendizado supervisionado, elas também têm aplicações úteis em sistemas de recomendação, permitindo medir a qualidade das previsões feitas pelo modelo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.1.1 Precisão

A precisão mede a proporção de itens recomendados que são, de fato, relevantes para o usuário. Em outras palavras, **avalia o quanto o sistema evita recomendar itens irrelevantes**. Sua fórmula é:

$$Precisão = \frac{Itens\ Relevantes\ Recomendados}{Total\ de\ Itens\ Recomendados}$$

No contexto de um e-commerce, imagine que o sistema recomende 10 produtos para um determinado usuário, porém, apenas quatro desses produtos sejam realmente comprados ou clicados (considerados “relevantes”). A precisão nesse caso seria 4 / 10 = 0.4 ou 40%. Uma precisão alta significa que o sistema é eficiente em recomendar itens que os usuários realmente valorizam, evitando “ruído” nas recomendações. No entanto, sozinha, a precisão não considera quantos itens relevantes não foram recomendados, o que pode ser uma limitação em certos contextos.

2.1.2 Recall

O recall mede a proporção de todos os itens relevantes disponíveis que foram corretamente recomendados pelo sistema. Sua fórmula é:

$$Recall = \frac{Itens\ Relevantes\ Recomendados}{Total\ de\ Itens\ Relevantes}$$

Ainda no exemplo de e-commerce, considere que existam oito produtos relevantes no catálogo para o usuário, mas o sistema recomendou apenas quatro desses oito itens. O recall seria 4 / 8 = 0.5 ou 50%. **Uma métrica de recall alta indica que o sistema consegue capturar a maior parte dos itens relevantes para o usuário, o que é essencial em cenários onde é importante não perder oportunidades**, como em plataformas que priorizam engajamento.

Contudo, um recall alto pode ser alcançado recomendando muitos itens, mesmo que vários sejam irrelevantes, o que impacta negativamente a precisão.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2.1.3 F1-Score

O F1-Score é a média harmônica entre precisão e recall, equilibrando as duas métricas. Sua fórmula é:

$$F1\ Score = 2 * \frac{Precisão * Recall}{Precisão + Recall}$$

Esse indicador é útil quando precisamos de um equilíbrio entre precisão e recall. Por exemplo, em um e-commerce que valoriza tanto a relevância das recomendações (precisão) quanto a abrangência de itens sugeridos (recall), o F1-Score fornece uma medida consolidada de desempenho. Se a precisão for 40% e o recall for 50%, o F1-Score seria: 2 * (0.4 * 0.5) / (0.4 + 0.5) = 0.4444

Um F1-Score alto representa um equilíbrio saudável entre precisão e recall, sendo especialmente útil em e-commerces que precisam balancear relevância e abrangência para melhorar a experiência do usuário.

Importante: no geral, a escolha da métrica depende do objetivo do sistema. Por exemplo, em um e-commerce focado em conversões rápidas, a precisão pode ser mais importante. Já em plataformas que valorizam a descoberta de novos itens, como streamings, o recall pode ser priorizado. O F1-Score, por sua vez, é útil em contextos em que é necessário equilibrar os dois aspectos.

2.2 Métricas específicas

Embora métricas clássicas sejam úteis para medir a precisão dos sistemas de recomendação, mensurar aspectos qualitativos das recomendações também é relevante, pois promovem experiências mais ricas e satisfatórias aos usuários.

2.2.1 Diversidade

A métrica de diversidade avalia **o quão variado é o conjunto de itens recomendados a um usuário**. Ela considera a **similaridade** entre os itens sugeridos, buscando **reduzir redundâncias**. Um sistema com alta diversidade evita recomendar produtos muito semelhantes entre si, como sugerir apenas diferentes cores de um

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

mesmo modelo de camiseta. Diversidade é essencial em contextos como streaming musical, onde o usuário espera explorar artistas ou gêneros variados.

2.2.2 Novidade

A novidade mede **o quanto os itens recomendados são desconhecidos para o usuário**. Por exemplo, sugerir um filme que o usuário nunca assistiu ou um produto que ele não explorou antes. A novidade é importante **para manter o engajamento contínuo**, evitando a saturação do usuário com os mesmos itens. No e-commerce, por exemplo, isso pode ajudar a introduzir novos produtos ao mercado.

2.2.3 Serendipidade

A serendipidade mede **o quanto uma recomendação é inesperada, mas ainda assim relevante para o usuário**. Diferente da novidade, que foca no desconhecido, a serendipidade **busca surpreender positivamente o usuário**, sugerindo itens fora de seu comportamento habitual, mas que podem ser de seu interesse. Por exemplo, recomendar um livro de ficção científica para alguém que geralmente lê romances históricos, mas que ainda possui características que podem agradar.

2.3 Dificuldades da avaliação dos motores de recomendação

Avaliar motores de recomendação é um desafio intrínseco, pois envolve uma série de questões técnicas e práticas que vão além da precisão de previsões. A dificuldade começa na **separação entre treino e teste**, que é essencial em qualquer sistema preditivo. Em sistemas de recomendação, essa divisão não é trivial, já que as interações entre usuários e itens estão em constante mudança, e os dados históricos podem não refletir as preferências futuras dos usuários. Além disso, a avaliação offline com conjuntos de treino e teste pode não capturar a experiência real do usuário ao interagir com as recomendações, limitando a capacidade de prever o impacto real no negócio.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Outro ponto importante é que as **recomendações "perfeitas" nem sempre são acionáveis**. Mesmo que um sistema consiga identificar com precisão os itens que o usuário provavelmente escolherá, isso pode não levar a uma experiência satisfatória. Por exemplo, recomendar sempre itens que o usuário já conhece ou deseja pode reforçar padrões previsíveis, limitando a descoberta de novos itens e a exploração de outros interesses. Isso destaca a importância de métricas complementares, como diversidade, novidade e serendipidade, que buscam equilibrar relevância com exploração. Além disso, a recomendação do produto pode ser perfeita como, por exemplo, um curso, mas se o usuário não tiver tempo e dinheiro para adquirir o produto, a recomendação não será acionada. Isso não necessariamente é uma falha do sistema de recomendação.

Uma das melhores maneiras de avaliar o impacto de um sistema de recomendação em um cenário real é por meio de **testes A/B**, como ilustrado na figura a seguir. Testes A/B são essenciais porque fornecem uma avaliação no mundo real, capturando as reações autênticas dos usuários ao invés de se basear apenas em análises offline.

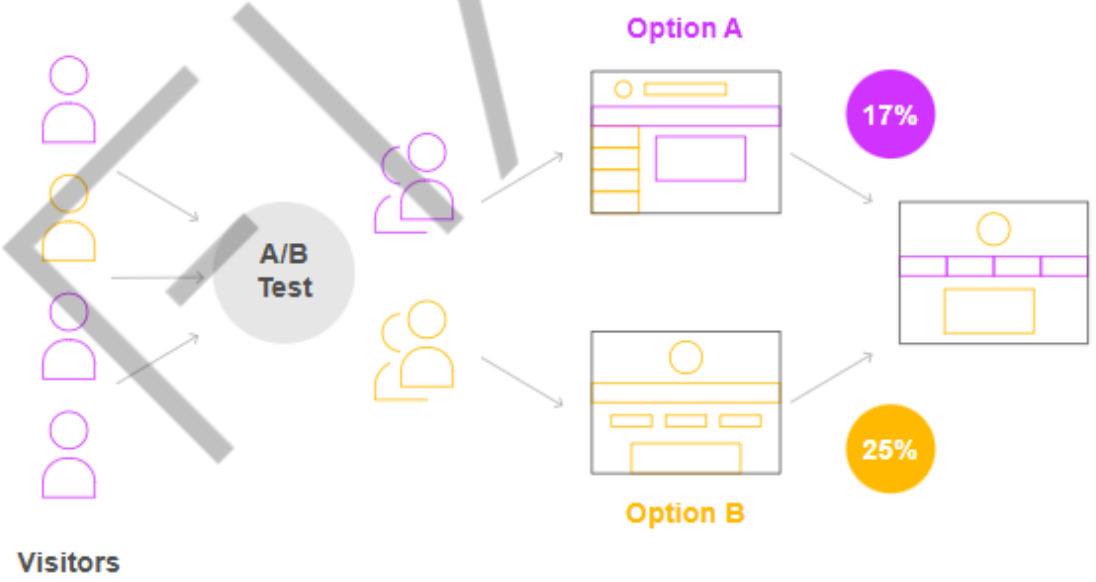

Figura 3 - Ilustração de um teste A/B
Fonte: Blitzpay (2023), adaptado por FIAP (2025)

Um teste A/B é um experimento controlado onde dois (ou mais) grupos de usuários são expostos a diferentes versões do sistema para comparar os resultados. Um grupo, chamado de "grupo de controle", utiliza uma versão antiga ou um sistema

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

base, enquanto o outro, o “grupo experimental”, interage com a nova versão do motor de recomendação. O desempenho dos dois grupos é então comparado com base em métricas relevantes, como taxa de cliques, conversão ou engajamento.

Apesar de sua eficácia, testes A/B também têm desafios. Eles exigem planejamento cuidadoso para garantir que os grupos sejam balanceados, e que os resultados sejam estatisticamente significativos. Além disso, podem ser demorados, pois precisam de uma base de usuários suficientemente grande e um tempo adequado para a coleta de dados. Mesmo assim, eles continuam sendo uma das estratégias mais confiáveis para validar sistemas de recomendação, especialmente quando se busca entender não apenas a precisão, mas também o impacto real no comportamento do usuário e nos objetivos do negócio.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3 PRINCIPAIS ABORDAGENS

3.1 Filtragem por conteúdo

A filtragem por conteúdo é uma abordagem de sistemas de recomendação que **utiliza informações sobre os itens e as preferências do usuário para gerar recomendações personalizadas**. A ideia central é comparar as características de itens já consumidos ou bem avaliados por um usuário com as características de outros itens ainda não consumidos, identificando aqueles que são mais similares. O processo está ilustrado na figura “Intuição da filtragem baseada em conteúdo”.

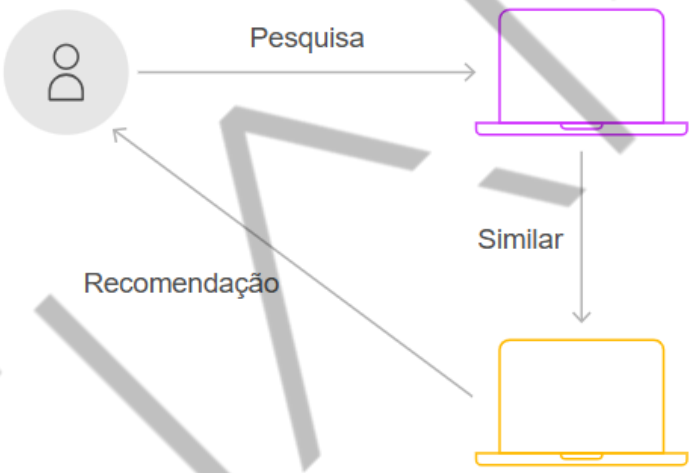

Figura 4 - Intuição da filtragem baseada em conteúdo
Fonte: Didática.tech (2024), adaptado por FIAP (2025)

3.1.1 Funcionamento do método

O processo funciona em etapas:

1. **Perfil do usuário:** um perfil é construído com base no histórico do usuário, analisando os itens com os quais ele interagiu (como livros, filmes ou produtos). Esse perfil pode ser definido por palavras-chave, categorias ou atributos específicos dos itens.
2. **Extração de features:** os itens são descritos por um conjunto de features, como, por exemplo: gênero de um filme, autor de um livro ou especificações técnicas de um produto.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3. **Medição de similaridade:** o sistema compara o perfil do usuário com as características dos itens não consumidos, usando métricas como *cosine similarity* ou Jaccard index, para determinar o quão similar um item é em relação ao perfil.
4. **Recomendações:** com base nas similaridades calculadas, o sistema recomenda os itens mais alinhados ao perfil do usuário. Por exemplo, se um usuário gosta de livros de ficção científica, o sistema recomendará outros livros com essa mesma característica, usando atributos como gênero literário, autor ou palavras-chave associadas.

3.1.2 Vantagens e desvantagens

Como todo método, a filtragem por conteúdo possui vantagens e limitações, não devendo ser o único motor de geração de recomendações. O quadro a seguir resume os principais pontos ao considerar para implementar a filtragem por conteúdo.

Vantagens	Desvantagens
Personalização: as recomendações são altamente personalizadas, baseando-se nas preferências únicas de cada usuário.	**Novos usuários:** o sistema tem dificuldade em construir um perfil inicial para gerar recomendações a usuários sem histórico.
Independência de outros usuários: não depende do comportamento de outros usuários, tornando-o eficaz mesmo em plataformas com poucos usuários ativos.	**Recomendações restritas:** o sistema só sugere itens similares aos já consumidos, limitando a diversidade e a descoberta de novos interesses.
Interpretação clara: as recomendações são explicáveis, pois se baseiam em características específicas dos itens.	**Dependência de features bem definidas:** se os dados forem escassos ou mal organizados, a eficácia diminui.
Sem problemas para itens novos: itens novos com descrições detalhadas podem ser recomendados imediatamente, pois a abordagem não depende de histórico de interações com outros usuários.	**Sobrefitting ao usuário:** pode ocorrer um foco excessivo nas preferências passadas do usuário, restringindo as possibilidades de recomendações inesperadas ou serendipidade.
Autossuficiência: foca apenas nos dados do próprio usuário, dispensando dependências complexas de redes de interação.	**Complexidade:** em certos domínios, como imagens ou músicas, extrair características significativas pode ser desafiador, exigindo técnicas avançadas como Deep Learning.

Quadro 1 - Vantagens e desvantagens da filtragem por conteúdo
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

A filtragem por conteúdo é uma abordagem poderosa, mas **funciona melhor combinada com outras técnicas, como a filtragem colaborativa, em sistemas híbridos**. Dessa forma, é possível superar as limitações de cada método individual, proporcionando recomendações mais robustas e diversificadas.

3.2 Filtragem colaborativa

A filtragem colaborativa é uma abordagem de sistemas de recomendação que se baseia nos comportamentos e preferências de múltiplos usuários para gerar sugestões. Ao invés de analisar as características dos itens diretamente, **a filtragem colaborativa identifica padrões nas interações entre usuários e itens para prever o que um usuário pode gostar, baseando-se no comportamento de outros usuários com gostos semelhantes**. O processo está ilustrado na figura “Exemplo de Filtragem Colaborativa usando intuições baseada em conteúdo”.

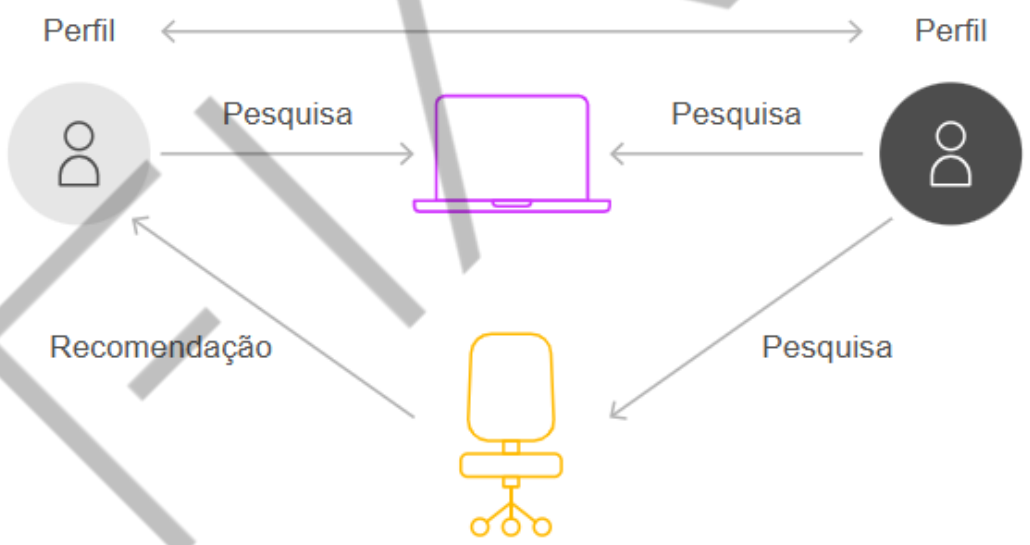

Figura 5 - Exemplo de Filtragem Colaborativa usando intuições baseada em conteúdo
Fonte: Didática.tech (2024), adaptado por FIAP (2025)

Por exemplo, em uma plataforma de streaming, se dois usuários assistirem e gostarem de filmes de ação, o sistema pode sugerir ao usuário A um filme que o usuário B assistiu, mas que ainda não está no histórico de A.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3.2.1 Funcionamento do método

Existem duas principais formas de filtragem colaborativa:

1. **Baseada em usuários:** o sistema identifica usuários com comportamentos semelhantes ao do usuário alvo. Por exemplo, pessoas que avaliaram positivamente os mesmos filmes e recomenda itens que esses usuários similares consumiram, mas que o usuário alvo ainda não experimentou.
2. **Baseada em itens:** o sistema encontra itens que foram avaliados ou consumidos de maneira semelhante por outros usuários. Por exemplo, se dois filmes foram avaliados positivamente pelos mesmos usuários são considerados semelhantes, a filtragem sugere itens que combinam com o histórico do usuário alvo.

3.2.2 Vantagens e desvantagens

A filtragem colaborativa também possui vantagens e limitações, descritos no quadro a seguir.

Vantagens	Desvantagens
Independência das features dos itens: não exige características explícitas dos itens, apenas dados de interação, como avaliações, cliques ou compras.	**Início dificultoso:** depende de um volume mínimo de interações para ser eficaz. Itens novos ou usuários sem histórico dificultam a geração de recomendações.
Capacidade de capturar preferências implícitas: pode identificar padrões sutis de comportamento que não são evidentes apenas com base nas características dos itens.	**Esparsidade dos dados:** em sistemas grandes, as matrizes de interação (usuários x itens) são frequentemente esparsas, tornando difícil encontrar padrões significativos.
Recomendações dinâmicas: as sugestões evoluem à medida que os usuários interagem com novos itens, adaptando-se rapidamente ao comportamento do público.	**Escalabilidade:** à medida que a quantidade de usuários e itens cresce, os cálculos de similaridade se tornam mais complexos e computacionalmente caros.
Efetividade em domínios variados: funciona bem em contextos em que os itens não possuem descrições detalhadas ou onde as características dos itens são difíceis de capturar, como música ou filmes.	**Bolha de filtro:** pode reforçar comportamentos existentes, recomendando apenas itens que se alinham aos gostos históricos, limitando a descoberta de novos interesses.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Exploração de novos itens: a filtragem colaborativa pode surpreender o usuário com recomendações inesperadas, já que se baseia no comportamento coletivo e não apenas no histórico pessoal.	**Falta de explicabilidade:** como é baseado em interações, muitas vezes é difícil explicar por que um item específico foi recomendado, especialmente para o usuário final.

Quadro 2 - Vantagens e desvantagens da filtragem colaborativa
Fonte: Elaborado pelo autor (2024)

A filtragem colaborativa é uma técnica amplamente utilizada em sistemas de recomendação modernos devido à sua flexibilidade e eficácia em capturar padrões de comportamento. Contudo, seus desafios a tornam ideal para ser combinada com outras abordagens, como a filtragem por conteúdo, em sistemas híbridos que podem oferecer recomendações mais completas e equilibradas.

3.3 Regras de associação

As regras de associação são utilizadas para descobrir padrões de ocorrência em grandes bases de dados, especialmente em transações. **A abordagem identifica relações entre itens frequentemente comprados ou utilizados juntos**, ajudando a responder perguntas como: se o cliente compra X, qual é a probabilidade de também comprar Y?

Essa abordagem é amplamente aplicada em análise de cestas de mercado (*market basket analysis*), onde, por exemplo, é possível detectar que compradores de pão têm alta probabilidade de comprar manteiga. Observe a figura:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

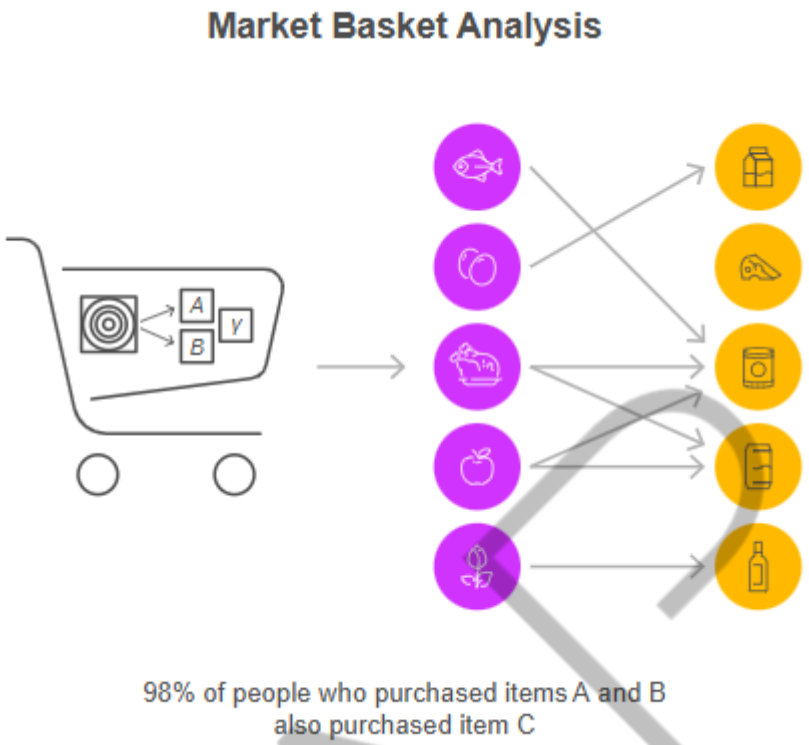

Figura 6 - Intuição da análise de cestas de mercado “98% das pessoas que compraram os itens A e B também compraram o item C”
Fonte: Medium (2021), adaptado por FIAP (2025)

3.3.1 Funcionamento do método

O **método Apriori** é uma técnica clássica para gerar regras de associação. Ele trabalha com base na ideia de que se um conjunto de itens é frequente, então todos os seus subconjuntos também são frequentes. Isso reduz o espaço de busca ao eliminar combinações de itens que não atendem a um limite mínimo de frequência, chamado de suporte mínimo.

Etapas do Algoritmo Apriori:

1. **Cálculo de suporte para itens individuais:** identifica os itens que satisfazem o suporte mínimo, ou seja, aqueles que aparecem com frequência suficiente nas transações.
2. **Geração de conjuntos de itens frequentes:** com base nos itens que atendem ao suporte mínimo, o algoritmo gera combinações de itens (2, 3, 4... itens) e calcula o suporte de cada combinação.
3. **Eliminação de combinações infrequentes:** descarta subconjuntos de itens que não atendem ao suporte mínimo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4. **Criação de regras de associação:** para cada conjunto de itens frequentes, o algoritmo gera regras da forma X → Y, onde X e Y são subconjuntos dos itens, calculando métricas de suporte, confiança e lift.

Para compreensão do método, é importante conhecermos e entendermos as principais métricas envolvidas! São elas:

- Suporte (*Support*): mede a frequência com que um conjunto de itens aparece no dataset. Por exemplo: se "leite e pão" aparecem em 40 de 200 transações, o suporte é 0,2 (20%).

$$Suporte(X) = \frac{Número\ de\ transações\ contendo\ X}{Total\ de\ transações}$$

- Confiança (*Confidence*): mede a probabilidade de que o item Y seja comprado dado que X já foi comprado. Exemplo: se 30 de 40 pessoas que compraram "leite" também compraram "pão", a confiança é 0,75 (75%).

$$Confiança(X \text{à} Y) = \frac{Suporte(X\ e\ Y)}{Suporte(X)}$$

- Lift: avalia a força da regra comparando a probabilidade de Y ocorrer dado X com a probabilidade de Y ocorrer independentemente. Um lift **maior que 1 indica que X e Y têm uma associação positiva. Quanto maior, melhor!**

$$Lift(X \text{à} Y) = \frac{Confiança(X \text{à} Y)}{Suporte(Y)}$$

3.3.2 Vantagens e desvantagens

A método Apriori possui vantagens e limitações, descritos no quadro a seguir.

Vantagens	Desvantagens
Facilidade de interpretação: as regras geradas são simples e compreensíveis, permitindo insights claros sobre os dados.	**Alto custo computacional:** em bases de dados grandes, o algoritmo pode gerar uma explosão combinatória de subconjuntos, tornando o processo lento.
Eficiência em bases pequenas: funciona bem para bases de dados com um número moderado de itens e transações.	**Sensibilidade ao suporte mínimo:** valores baixos geram regras irrelevantes; valores altos podem ignorar associações úteis.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Relevância prática: amplamente aplicável em comércio eletrônico, varejo e marketing para entender padrões de comportamento.	**Foco exclusivo em frequência:** não leva em conta outros fatores, como o valor financeiro das associações descobertas.

Quadro 3 - Vantagens e desvantagens do método Apriori
Fonte: Elaborado pelo autor (2024)

O método Apriori é uma abordagem poderosa e versátil para descobrir padrões em dados transacionais, mas exige cuidados na configuração para ser eficiente e relevante.

Um ponto importante de destacar é que o funcionamento do método depende de dados transacionais, requerendo uma base de dados estruturada em transações, o que limita sua aplicação em domínios com dados menos organizados, ou sem tal histórico.

Em cenários modernos, o método Apriori pode ser complementado por técnicas mais avançadas, como aprendizado profundo ou algoritmos otimizados, para lidar com desafios de escalabilidade e de complexidade.

3.4 Híbridas

Modelos híbridos combinam duas ou mais abordagens de sistemas de recomendação para superar as limitações de métodos individuais, proporcionando uma experiência mais robusta e eficiente. Eles são projetados para alavancar as forças de diferentes estratégias enquanto minimizam suas fraquezas. No contexto de um e-commerce, modelos híbridos podem aumentar a precisão das recomendações, melhorar a diversidade de itens sugeridos e atender a diferentes tipos de usuários, como novos clientes ou aqueles com histórico estabelecido. As estratégias mais comuns combinadas em sistemas híbridos incluem:

- Filtragem colaborativa e baseada em conteúdo:
  - A filtragem colaborativa recomenda itens com base em comportamentos de usuários semelhantes, enquanto a abordagem baseada em conteúdo utiliza as características dos itens consumidos pelo usuário.
  - Exemplo: em um e-commerce, a combinação permite recomendar roupas similares ao estilo das peças que o cliente comprou (baseado em

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

conteúdo) e peças populares entre clientes com gostos semelhantes (filtragem colaborativa).

- Filtragem colaborativa e regras de associação:
  - As regras de associação detectam padrões em transações (como “clientes que compraram X também compraram Y”), complementando a filtragem colaborativa em encontrar recomendações menos óbvias.
  - Exemplo: quando um cliente compra um smartphone, o sistema pode recomendar não apenas os acessórios mais frequentemente comprados com o telefone (regras de associação), mas também produtos escolhidos por outros usuários com histórico de compra semelhante (filtragem colaborativa).
- Baseada em conteúdo e regras de associação:
  - Combinar características dos itens com padrões de ocorrência nas compras aumenta a relevância das recomendações.
  - Exemplo: um cliente que comprou um livro de ficção científica pode receber recomendações de outros livros do mesmo gênero (baseado em conteúdo) e de outros produtos frequentemente comprados junto, como marcadores de páginas ou luminárias de leitura (regras de associação).
- Deep Learning e modelos tradicionais:
  - Redes neurais podem ser utilizadas para extrair padrões complexos em dados de interação e, em seguida, combinar essas previsões com métodos tradicionais para maior precisão.
  - Exemplo: o sistema usa um modelo de rede neural para prever categorias de produtos com maior probabilidade de interesse e complementa isso com uma abordagem de filtragem colaborativa para recomendar itens específicos dentro dessas categorias.

3.4.1 Funcionamento do método

A combinação de estratégias em modelos híbridos pode ser realizada de várias maneiras, dependendo da aplicação e dos objetivos do sistema:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Ponderação simples:** cada abordagem contribui para a recomendação com um peso pré-definido.
  - Exemplo: as recomendações baseadas em conteúdo têm peso de 70%, enquanto as colaborativas têm peso de 30%.
- **Modelos sequenciais:** um método é aplicado primeiro, e suas recomendações são refinadas ou filtradas por outro método.
  - Exemplo: primeiro, o sistema aplica regras de associação para sugerir produtos relevantes e, em seguida, filtra esses itens com base no histórico do cliente.
- **Integração em nível de feature:** combina as features derivadas de diferentes métodos em um único modelo.
  - Exemplo: um modelo de aprendizado supervisionado usa como entrada as similaridades calculadas por filtragem colaborativa e baseada em conteúdo.
- **Meta-modelagem:** um modelo de alto nível (meta-modelo) aprende a combinar as previsões de vários métodos para produzir a recomendação final.
  - Exemplo: um algoritmo de stacking utiliza as saídas de filtragem colaborativa, baseada em conteúdo e regras de associação como features para treinar um modelo final.
- **Seleção baseada no contexto:** o sistema escolhe a abordagem mais adequada com base no perfil do usuário ou nas características do cenário.
  - Exemplo: para novos usuários, utiliza-se uma abordagem baseada em conteúdo; para usuários recorrentes, aplica-se a filtragem colaborativa.
  - **Exemplo no contexto de e-commerce:** imagine um e-commerce de moda que deseja melhorar suas recomendações. Existem várias formas de combinar estratégias de recomendação. Elas podem ser:
    1. **Filtragem colaborativa baseada em usuários:** para recomendar roupas populares entre clientes com comportamentos semelhantes.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2. **Baseada em conteúdo:** para sugerir peças de vestuário semelhantes às compradas pelo cliente, analisando características como cor, tecido e estilo.
3. **Regras de associação:** para identificar itens frequentemente comprados juntos, como sapatos com bolsas ou camisas com gravatas.
4. **Rede neural:** para detectar padrões mais sutis no comportamento de navegação e compras, como combinações de categorias frequentemente vistas em uma única sessão.

- O sistema pode, por exemplo, sugerir para um cliente que comprou um terno, gravatas de cor complementar (baseado em conteúdo), sapatos frequentemente comprados com ternos (regras de associação) e itens populares entre usuários com perfil semelhante (filtragem colaborativa). Para garantir relevância, o sistema pode ponderar as contribuições de cada abordagem ou priorizar métodos específicos dependendo do histórico do cliente.
- A própria Netflix trabalha com múltiplos níveis de recomendação para cada usuário, de modo a diversificar a oferta de conteúdo. Cada fileira oferece um “tema” que reúne títulos naquele contexto. Observe a figura:

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

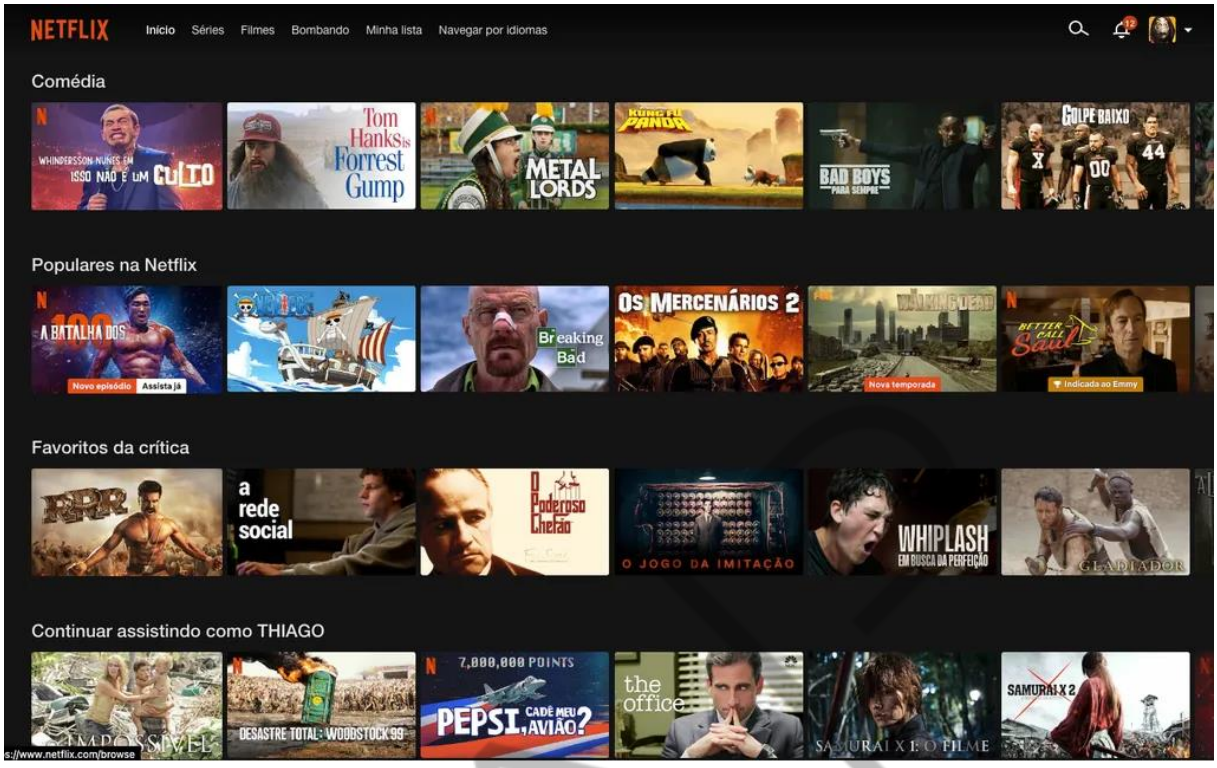

Figura 7 - Exemplos de modelos híbridos de recomendação na Netflix
Fonte: Netflix (2024)

3.4.2 Vantagens e desvantagens

É importante mencionar que a combinação de métodos pode apresentar tanto vantagens quanto desvantagens, como mostra o quadro a seguir.

Vantagens	Desvantagens
Superam as limitações individuais de cada abordagem.	Maior complexidade na implementação e na manutenção.
Oferecem recomendações mais precisas e diversificadas.	Exigem maior poder computacional para integrar e processar múltiplos métodos.
Adaptam-se melhor a diferentes perfis de usuários.	Necessitam de estratégias para equilibrar as contribuições de cada abordagem.

Quadro 4 - Vantagens e desvantagens do método híbrido
Fonte: Elaborado pelo autor (2024)

Os modelos híbridos representam o estado da arte em sistemas de recomendação, unindo força técnica e flexibilidade prática para atender às demandas cada vez mais sofisticadas do mercado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

4 PRINCIPAIS DESAFIOS

A preparação de dados é uma das etapas mais desafiadoras na construção de sistemas de recomendação. Esses sistemas dependem de grandes volumes de informações para gerar recomendações úteis e precisas, mas o processo de transformar dados brutos em uma base pronta para análise é complexo e exige atenção a diversos aspectos.

Uma das dificuldades mais comuns é a **qualidade dos dados**. Sistemas de recomendação frequentemente lidam com dados provenientes de interações de usuários, como cliques, compras ou avaliações. Esses dados podem ser ruidosos, incompletos ou ambíguos. Por exemplo, em uma plataforma de e-commerce, cliques podem não significar necessariamente interesse genuíno, enquanto a ausência de cliques em um item pode não significar desinteresse, mas sim falta de visibilidade. **A limpeza e o pré-processamento são essenciais para separar sinais úteis de ruídos**.

É importante mencionar que a preparação de dados para sistemas de recomendação não é apenas um desafio técnico, mas também ético. Decisões sobre quais dados incluir e como tratá-los podem introduzir ou amplificar vieses, afetando negativamente a qualidade e a justiça das recomendações. Portanto, o cuidado com os dados vai além da análise técnica, abrangendo também considerações éticas e sociais, fundamentais para o sucesso e a confiabilidade do sistema.

4.1 Cold start

Um dos maiores desafios do cold start é a sua dificuldade inerente aos sistemas de recomendação, que **ocorre quando não há dados suficientes para gerar recomendações precisas**. Esse problema pode se manifestar em três cenários principais: **novos usuários**, **novos itens** ou um **sistema recém-implantado sem histórico suficiente**. Em todos esses casos, a falta de informações iniciais torna desafiador personalizar recomendações.

Os métodos baseados em popularidade são simples, eficazes e amplamente usados para lidar com o problema de cold start. Eles se baseiam na premissa de que

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

itens populares entre a base de usuários têm maior probabilidade de agradar novos usuários ou atrair interesse para novos itens. Por exemplo:

- Em um e-commerce, os produtos mais vendidos podem ser recomendados a novos usuários, mesmo sem um histórico individual.
- Em uma plataforma de streaming, os filmes ou músicas mais assistidas globalmente podem ser destacados.

Embora eficientes no curto prazo, essas abordagens têm limitações. Elas tendem a priorizar itens convencionais e amplamente aceitos, o que pode reduzir a personalização e diversidade das recomendações. Assim, conforme o sistema coleta mais dados, é importante transitar para abordagens mais sofisticadas, como filtragem colaborativa ou métodos híbridos, para oferecer recomendações mais personalizadas e impactantes.

4.1.1 Contornando o cold start

Além da aplicação de métodos baseados em popularidade, podemos explorar técnicas mais expressas e contextualizadas para cada cenário de partida a frio:

- **Cold start para novos usuários:** quando não há histórico de interações que permita ao sistema entender suas preferências. Esse cenário é comum em e-commerces, serviços de streaming e plataformas de redes sociais. Para mitigar esse problema, algumas estratégias incluem:
  - Perguntas de preferência inicial: solicitar que o usuário selecione categorias, gêneros ou produtos de interesse durante o cadastro, criando um perfil inicial.
  - Basear-se em dados demográficos: usar informações como idade, localização ou gênero para comparar o novo usuário com perfis similares já existentes.
- **Cold start para novos itens:** o desafio está em recomendar itens novos quando não há interações associadas. Por exemplo, um produto recém-

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

adicionado a um catálogo não terá avaliações ou histórico de vendas. Algumas soluções incluem:

- Basear-se em metadados: usar informações descritivas do item, como categoria, marca ou especificações técnicas, para compará-lo a itens já conhecidos.
- Promoção inicial: destacar novos itens em seções de “novidades” ou “lançamentos” para aumentar sua visibilidade e coletar dados iniciais.

- **Cold start para o sistema:** quando o sistema está em sua fase inicial de operação, sem interações de usuários ou dados históricos, torna-se difícil fornecer recomendações personalizadas. Nesse caso, soluções baseadas em popularidade são amplamente usadas:
  - Itens populares globais: recomendação de produtos ou conteúdos com base em sua popularidade geral, como os produtos mais vendidos ou os filmes mais assistidos.
  - Tendências atuais: explorar itens em alta ou conteúdos em destaque, que podem atrair novos usuários enquanto os dados são coletados.
  - Promoções e destaques: destacar ofertas, descontos ou conteúdos exclusivos para aumentar a interação inicial.

4.2 Escalabilidade e Esparsidade

A **heterogeneidade das fontes de dados** também aumenta a complexidade. Sistemas modernos combinam diferentes tipos de dados, como histórico de navegação, avaliações explícitas, transações e até mesmo dados demográficos ou de redes sociais. Cada tipo de dado requer um tratamento específico, incluindo padronização, normalização e combinação de diferentes formatos, para garantir que sejam integrados de forma coerente no sistema.

Outro ponto crítico é a **atualização em tempo real dos dados**. Em sistemas dinâmicos, como plataformas de streaming ou e-commerce, as interações dos usuários mudam constantemente, exigindo que os modelos sejam treinados e atualizados com dados mais recentes. Essa necessidade de processamento contínuo

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

adiciona uma camada de complexidade à infraestrutura do sistema, exigindo pipelines robustos que equilibrem eficiência e qualidade.

Além disso, a **esparsidade** dos dados representa um desafio significativo. Em sistemas com muitos usuários e itens, a matriz de interações é frequentemente esparsa, com a maioria das células vazias. Isso significa que muitos usuários interagem com apenas uma pequena fração do catálogo disponível, dificultando a identificação de padrões confiáveis. Técnicas como preenchimento de matrizes, fatoração ou integração de dados auxiliares são frequentemente necessárias para lidar com esse problema.

4.3 Vieses e bolhas

Os sistemas de recomendação enfrentam desafios éticos e técnicos relacionados a vieses e bolhas de filtro, que podem impactar negativamente tanto os usuários quanto os negócios.

Os vieses surgem quando os dados usados para treinar os modelos ou as próprias estratégias algorítmicas refletem desigualdades ou padrões distorcidos. Por exemplo, um sistema de recomendação em e-commerce pode priorizar produtos mais populares ou de grandes marcas, negligenciando itens de vendedores menores. Isso cria um ciclo onde os itens recomendados continuam sendo os mais consumidos, reforçando padrões preexistentes. Esse problema pode afetar também a diversidade cultural, econômica ou de conteúdo em plataformas como redes sociais ou serviços de streaming.

As bolhas de filtro ocorrem quando os sistemas de recomendação reforçam as preferências existentes dos usuários, limitando a exposição de conteúdo ou produto fora de seu histórico. Por exemplo, em uma plataforma de streaming onde um usuário que consome apenas um gênero específico pode receber recomendações exclusivamente desse gênero, reduzindo a oportunidade de explorar novas opções. Isso pode levar à monotonia nas recomendações e à perda de serendipidade.

Para lidar com esses problemas, é essencial introduzir mecanismos que incentivem a diversidade e a exploração, como métricas de serendipidade, limites de repetição em recomendações e estratégias para incorporar itens menos populares ao

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

ranking. Além disso, análises cuidadosas dos dados e transparência nos algoritmos ajudam a minimizar o impacto de vieses, garantindo uma experiência mais justa e equilibrada para todos os usuários.

4.4 Privacidade e segurança de dados

Os sistemas de recomendação, por sua natureza, dependem de grandes volumes de dados de usuários para oferecer sugestões personalizadas. Contudo, o uso desses dados levanta preocupações sobre privacidade, segurança e conformidade com legislações como a Lei Geral de Proteção de Dados (LGPD) no Brasil, o GDPR na Europa e outras regulamentações internacionais.

De acordo com a LGPD, o processamento de dados pessoais para fins de sistemas de recomendação deve ser justificado por uma base legal, sendo o consentimento do usuário uma das justificativas mais comuns. Isso significa que as plataformas precisam informar claramente como os dados serão usados e obter aprovação explícita antes de processá-los. Por exemplo, em um e-commerce, o cliente deve estar ciente de que seu histórico de compras será utilizado para personalizar recomendações.

Além disso, os usuários têm o direito de acessar, corrigir ou excluir seus dados e até de recusar o uso desses dados para recomendações, o que representa um desafio técnico para manter a eficácia dos sistemas sem comprometer a conformidade legal.

Os sistemas de recomendação frequentemente armazenam dados sensíveis, como histórico de compras, preferências pessoais ou localização. Vazamentos de dados podem expor essas informações, causando prejuízos financeiros, danos à reputação da empresa e perda de confiança dos usuários. Um exemplo marcante foi o vazamento de dados de usuários de plataformas de streaming, onde históricos de visualização foram expostos, comprometendo a privacidade.

Para mitigar esses riscos, é essencial implementar práticas robustas de segurança cibernética, como criptografia dos dados em trânsito e em repouso, autenticação forte e monitoramento contínuo de vulnerabilidades.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Além de atender à legislação, as empresas devem priorizar a transparência no uso de dados. Isso inclui explicar como as recomendações são geradas e garantir que os dados sejam utilizados de forma ética. Por exemplo, a coleta de dados para personalização não deve ser explorada para manipular decisões dos usuários de maneira abusiva, como induzir compras desnecessárias ou enviesar recomendações para fins comerciais não explícitos.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

5 HANDS ON: CONSTRUINDO SISTEMAS DE RECOMENDAÇÃO

Agora que conhecemos as principais técnicas de recomendação, está na hora de implementar algumas delas. Toda nossa prática será feita em um jupyter notebook no ambiente do Google Colaboratory (Colab).

Dica: veja o material HOW TO para acessar o ambiente do Colab.

Uma vez no Colab, crie um novo notebook, dê um nome como preferir (sugestão: Aula 6), e faça cada bloco de código-fonte em uma célula. Após inserir o código na célula do notebook, execute-a e veja a saída gerada.

5.1 Regras de associação

5.1.1 Sobre a base de dados

Nesta prática, precisamos de um conjunto de dados que mostre a relação de produtos que foram comprados em conjunto. Isso é equivalente a abrir, por exemplo, o histórico de cada compra realizada em uma loja, para verificar o que as pessoas tendem a comprar em conjunto.

Assim será possível criar regras do tipo “quem viu comprou”. Neste exemplo, trabalharemos com dados hipotéticos de vendas de um supermercado, da seguinte forma:

- No arquivo CVS, cada linha representa uma cesta de compras.
- Cada linha lista os itens adquiridos em conjunto, separados por vírgula.

Ainda que seja um arquivo CSV, a leitura e interpretação não é exatamente de um DataFrame clássico do Pandas.

Dica: utilize o arquivo de apoio “store_data.csv”.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

5.1.2 Implementando o método

O primeiro passo é instalar a biblioteca *apyori*, que implementa o método Apriori em Python. O comando está abaixo e a figura “Resultado da execução do código-fonte 1” ilustra a saída esperada no Colab:

```
!pip install apyori
```

Código-fonte 1 - Instalação da biblioteca apyori
Fonte: Elaborado pelo autor (2024)

```
Collecting apyori
  Downloading apyori-1.1.2.tar.gz (8.6 kB)
  Preparing metadata (setup.py) ... done
Building wheels for collected packages: apyori
  Building wheel for apyori (setup.py) ... done
  Created wheel for apyori: filename=apyori-1.1.2-py3-none-any.whl
  Stored in directory: /root/.cache/pip/wheels/c4/1a/79/20f55c470a5
Successfully built apyori
Installing collected packages: apyori
Successfully installed apyori-1.1.2
```

Figura 8 - Resultado da execução do código-fonte 1
Fonte: Elaborado pelo autor (2024)

Feito isso partimos para os imports e a leitura da base:

```
# Imports
import pandas as pd
import numpy as np
from apyori import apriori

# Ler o dataset
store_data = pd.read_csv("store_data.csv", header=None)
store_data
```

Código-fonte 2 - Imports e leitura dos dados
Fonte: Elaborado pelo autor (2024)

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

	0	1	2	3	4	5	6	7	8	9
0	shrimp	almonds	avocado	vegetables mix	green grapes	whole weat flour	yams	cottage cheese	energy drink	tomato juice
1	burgers	meatballs	eggs	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	chutney	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	turkey	avocado	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	mineral water	milk	energy bar	whole wheat rice	green tea	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...
7496	butter	light mayo	fresh bread	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7497	burgers	frozen vegetables	eggs	french fries	magazines	green tea	NaN	NaN	NaN	NaN
7498	chicken	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

Figura 9 - Resultado parcial da execução do código-fonte 2
Fonte: Elaborado pelo autor (2024)

Note que não se trata de uma tabela de fato, então prepararemos os dados como uma lista de listas (excluindo os “nans”), sendo que cada lista interna é a sequência dos produtos. Adotamos tal estrutura de dados porque o *apyori* espera tal formato nos dados:

```
records = []
for i in range(0, 7501):
  records.append( [ str(store_data.values[i, j]) for j in range(20) \
                    if str(store_data.values[i, j]) != "nan"] )

records
```

Código-fonte 3 - Reorganizando os dados
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
[['shrimp',
  'almonds',
  'avocado',
  'vegetables mix',
  'green grapes',
  'whole weat flour',
  'yams',
  'cottage cheese',
  'energy drink',
  'tomato juice',
  'low fat yogurt',
  'green tea',
  'honey',
  'salad',
  'mineral water',
  'salmon',
  'antioxydant juice',
  'frozen smoothie',
  'spinach',
  'olive oil'],
 ['burgers', 'meatballs', 'eggs'],
 ['chutney'],
```

Figura 10 - Resultado parcial da execução do código-fonte 3
Fonte: Elaborado pelo autor (2024)

Esta base dispensa processamentos mais robustos, então podemos partir para a construção das regras de associação:

```
association_rules = apriori(
    records,
    min_support=0.0045,
    min_confidence=0.2,
    min_lift=3,
    min_lenght=2
)

association_rules = list(association_rules)

print(len(association_rules))
```

Código-fonte 4 - Criando regras de associação
Fonte: Elaborado pelo autor (2024)

O código anterior mostra a criação automática de 24 regras, com uma confiança mínima de 0.2 e um suporte mínimo de 0.0045. O lift mínimo é 3 e o tamanho mínimo das regras é de 2.

A geração de regras parte de regras simples (tamanho mínimo 2) selecionando as que atendem aos requisitos mínimos, e vão sendo mineradas e combinadas com

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

novos ciclos de atualização. Ao final do processo apenas 24 combinações se mostraram minimamente viáveis. Parte essencial desta limitação é a pouca quantidade de exemplos (linhas) no arquivo de entrada.

Agora podemos começar a entender o formato de apresentação das regras:

```
# Puxa a primeira regra
association_rules[0]
```

Código-fonte 5 - Analisando a primeira regra
Fonte: Elaborado pelo autor (2024)

```
RelationRecord(items=frozenset({'chicken', 'light cream'}), support=0.004532728969470737, ordered_statistics=
[OrderedStatistic(items_base=frozenset({'light cream'}), items_add=frozenset({'chicken'}), confidence=0.29059829059829057,
lift=4.84395061728395)])
```

Figura 11 - Resultado da execução do código-fonte 5
Fonte: Elaborado pelo autor (2024)

Se quisermos, podemos imprimir todas as regras geradas:

```
# Agora, imprimindo a lista de recomendações
for cesta in association_rules:
  itens = [x for x in cesta[0]]
  print("Produtos da cesta: " + str(itens))
  print("Suporte: " + str(cesta[1]))

  # Lista as regras desta cesta
  idRegra = 1
  for regra in cesta[2]:
    print(f"- Regra #{idRegra}: {regra[0]} -> {regra[1]}")
    print("    - Confiança: " + str(regra[2]))
    print("    - Lift: " + str(regra[3]))
    print(regra)
    idRegra += 1

  print("=" * 15)
```

Código-fonte 6 - Imprimindo as regras de associação geradas
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
Produtos da cesta: ['chicken', 'light cream']
Suporte: 0.004532728969470737
- Regra #1: frozenset({'light cream'}) -> frozenset({'chicken'})
   - Confiança: 0.29059829059829057
   - Lift: 4.84395061728395
OrderedStatistic(items_base=frozenset({'light cream'}), items_add=frozenset({'chicken'}),
===============
Produtos da cesta: ['escalope', 'mushroom cream sauce']
Suporte: 0.005732568990801226
- Regra #1: frozenset({'mushroom cream sauce'}) -> frozenset({'escalope'})
   - Confiança: 0.3006993006993007
   - Lift: 3.790832696715049
OrderedStatistic(items_base=frozenset({'mushroom cream sauce'}), items_add=frozenset({'es
===============
Produtos da cesta: ['escalope', 'pasta']
Suporte: 0.005865884548726837
- Regra #1: frozenset({'pasta'}) -> frozenset({'escalope'})
   - Confiança: 0.3728813559322034
   - Lift: 4.700811850163794
OrderedStatistic(items_base=frozenset({'pasta'}), items_add=frozenset({'escalope'}), conf
===============
Produtos da cesta: ['ground beef', 'herb & pepper']
Suporte: 0.015997866951073192
- Regra #1: frozenset({'herb & pepper'}) -> frozenset({'ground beef'})
   - Confiança: 0.3234501347708895
```

Figura 12 - Resultado parcial da execução do código-fonte 5
Fonte: Elaborado pelo autor (2024)

Possuindo tais regras, o supermercado pode implementá-las em diversos canais de venda. Por exemplo:

- Oferecer produtos em compras virtuais;
- Oferecer promoções exclusivas no seu aplicativo para compras associadas;
- Deixar próximos produtos relacionados nas lojas físicas.

5.2 Filtragem item-item

A técnica de recomendação baseada em item-item foi popularizada pela Amazon em 1998. Essa abordagem surgiu para resolver problemas de escalabilidade e precisão em sistemas de recomendação de grande escala. Em vez de encontrar usuários semelhantes ao usuário alvo (como na filtragem colaborativa baseada em usuários), o método foca em identificar itens similares com base nos padrões de interação de todos os usuários. Por exemplo, se muitos usuários compraram “Livro A” e “Livro B” juntos, esses itens serão considerados semelhantes, e “Livro B” pode ser recomendado a um usuário que comprou “Livro A”.

As principais vantagens dessa técnica incluem maior estabilidade (pois itens são menos propensos a mudar com frequência do que os comportamentos dos usuários) e sua eficácia em cenários com muitos usuários e poucos itens. No entanto,

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

uma desvantagem é que o cálculo da similaridade entre itens pode ser computacionalmente intensivo em catálogos muito grandes. Além disso, a técnica depende fortemente de dados de interações, o que pode ser um problema em cenários de cold start para novos itens. Mesmo assim, sua robustez e simplicidade a tornam amplamente utilizada em sistemas de recomendação modernos.

5.2.1 Sobre a base de dados

Trata-se de uma versão reduzida do conjunto de dados MovieLens, amplamente utilizado para pesquisas e desenvolvimento de sistemas de recomendação de filmes. Esta versão contém informações sobre filmes, avaliações de usuários e possivelmente metadados adicionais, permitindo análises de preferências e padrões de comportamento dos usuários. Devido ao seu tamanho compacto, é ideal para experimentações iniciais e desenvolvimento de protótipos em Machine Learning e Análise de Dados. Aqui não vamos usar todos os arquivos, apenas o que descreve os filmes e as avaliações.

Dica: utilize os arquivos de apoio “movies.csv” e “ratings.csv”.

5.2.2 Implementando o método

O primeiro passo é realizar os *imports* necessários e ler os arquivos de dados:

```
import pandas as pd
import numpy as np

from scipy.sparse import csr_matrix
from sklearn.neighbors import NearestNeighbors

import matplotlib.pyplot as plt
import seaborn as sns

movies = pd.read_csv("movies.csv")
ratings = pd.read_csv("ratings.csv")
```

Código-fonte 7 - Imports e leitura dos dados
Fonte: Elaborado pelo autor (2024)

Você pode explorar os arquivos listando algumas linhas, como ilustra a figura a seguir:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
ratings.head()
```

	userId	movieId	rating	timestamp
0	1	1	4.0	964982703
1	1	3	4.0	964981247
2	1	6	4.0	964982224
3	1	47	5.0	964983815
4	1	50	5.0	964982931

```
[ ] movies.head()
```

	movieId	title	genres
0	1	Toy Story (1995)	Adventure|Animation|Children|Comedy|Fantasy
1	2	Jumanji (1995)	Adventure|Children|Fantasy
2	3	Grumpier Old Men (1995)	Comedy|Romance
3	4	Waiting to Exhale (1995)	Comedy|Drama|Romance
4	5	Father of the Bride Part II (1995)	Comedy

Figura 13 - Primeiras linhas dos arquivos da base MovieLens
Fonte: Elaborado pelo autor (2024)

O conjunto de dados de filmes possui a informação de gênero, a qual não usaremos nesta análise. **O que nos interessa é construir uma matriz de usuários por filmes, indicando qual usuário interagiu com qual filme, quantificando esta interação pela nota (*rating*)**. Para isso vamos construir uma *pivot table* da seguinte forma:

```
final_dataset = ratings.pivot(index='movieId',columns='userId',values='rating')
final_dataset.head()
```

Código-fonte 8 - Alterando a estrutura dos dados
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

userId	1	2	3	4	5	6	7	8	9	10	...	601	602	603	604	605	606	607	608	609	610
movieId																					
1	4.0	NaN	NaN	NaN	4.0	NaN	4.5	NaN	NaN	NaN	...	4.0	NaN	4.0	3.0	4.0	2.5	4.0	2.5	3.0	5.0
2	NaN	NaN	NaN	NaN	NaN	4.0	NaN	4.0	NaN	NaN	...	NaN	4.0	NaN	5.0	3.5	NaN	NaN	2.0	NaN	NaN
3	4.0	NaN	NaN	NaN	NaN	5.0	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2.0	NaN	NaN
4	NaN	NaN	NaN	NaN	NaN	3.0	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
5	NaN	NaN	NaN	NaN	NaN	5.0	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	3.0	NaN	NaN	NaN	NaN	NaN	NaN

5 rows × 610 columns

Figura 14 - Resultado da execução do código-fonte 8
Fonte: Elaborado pelo autor (2024)

Como temos muitos valores “nans”, devemos substituí-los por zeros. Também podemos agregar as informações tomando por base os filmes votados e os votos de cada usuário, chegando na seguinte distribuição:

```
final_dataset.fillna(0,inplace=True)

no_user_voted                                                    =
ratings.groupby('movieId')['rating'].agg('count')
no_movies_voted                                                  =
ratings.groupby('userId')['rating'].agg('count')

f,ax = plt.subplots(1,1,figsize=(16,4))
plt.scatter(no_user_voted.index,no_user_voted,color='med
iumseagreen')
plt.axhline(y=10,color='r')
plt.xlabel('MovieId')
plt.ylabel('No. of users voted')
plt.show()
```

Código-fonte 9 - Limpando valores vazios
Fonte: Elaborado pelo autor (2024)

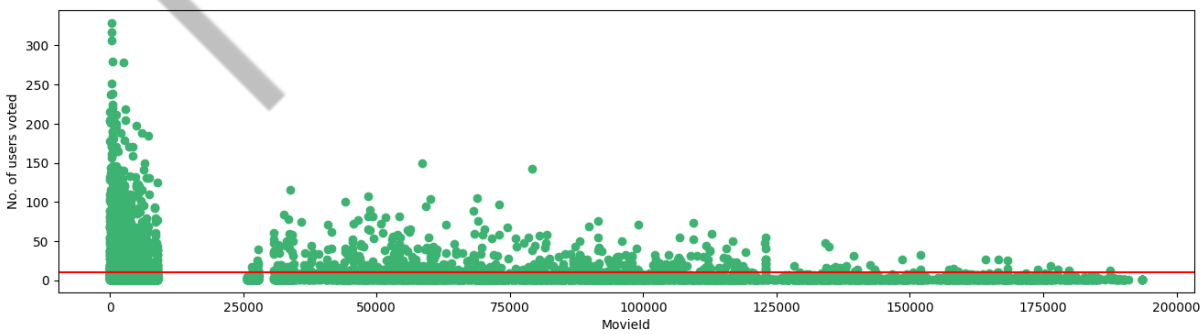

Figura 15 - Resultado da execução do código-fonte 9
Fonte: Elaborado pelo autor (2024)

Feito isso, **é importante focarmos as recomendações em produtos e usuários que atendem critérios mínimos**, tais como:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Para qualificar um filme, no mínimo 10 usuários devem ter votado nele.
- Para qualificar um usuário, ele deve ter votado em no mínimo 50 filmes.

Fazemos isso utilizando o comando a seguir, e as saídas nas figuras “Resultado parcial da execução do código-fonte 10 - Parte 1” e “Resultado parcial da execução do código-fonte 10 - Parte 2”:

```
     final_dataset                                                    =
final_dataset.loc[no_user_voted[no_user_voted > 10].index,:]

     f,ax = plt.subplots(1,1,figsize=(16,4))
     plt.scatter(no_movies_voted.index,no_movies_voted,color=
'mediumseagreen')
     plt.axhline(y=50,color='r')
     plt.xlabel('UserId')
     plt.ylabel('No. of votes by user')
     plt.show()

     final_dataset=final_dataset.loc[:,no_movies_voted[no_mov
ies_voted > 50].index]
     final_dataset
```

Código-fonte 10 - Limpando os dados
Fonte: Elaborado pelo autor (2024)

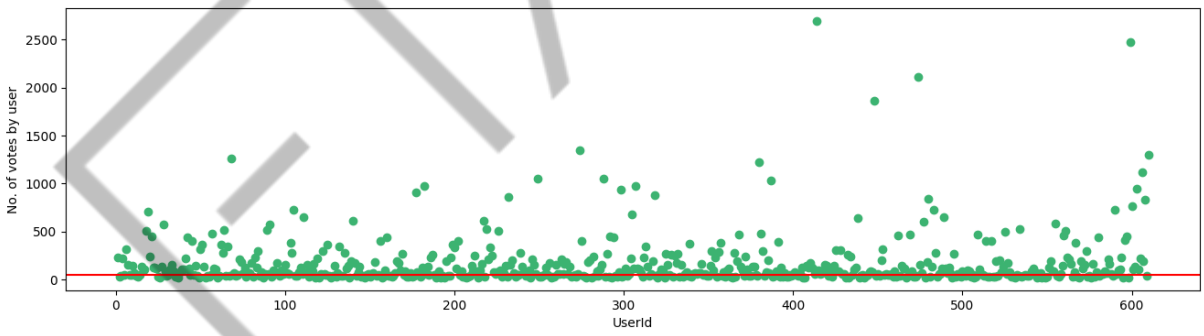

Figura 16 - Resultado parcial da execução do código-fonte 10 - Parte 1
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

userId	1	4	6	7	10	11	15	16	17	18	...	600	601	602	603	604	605	606	607	608	610
movieId																					
1	4.0	0.0	0.0	4.5	0.0	0.0	2.5	0.0	4.5	3.5	...	2.5	4.0	0.0	4.0	3.0	4.0	2.5	4.0	2.5	5.0
2	0.0	0.0	4.0	0.0	0.0	0.0	0.0	0.0	0.0	3.0	...	4.0	0.0	4.0	0.0	5.0	3.5	0.0	0.0	2.0	0.0
3	4.0	0.0	5.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0	0.0
5	0.0	0.0	5.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	2.5	0.0	0.0	0.0	3.0	0.0	0.0	0.0	0.0	0.0
6	4.0	0.0	4.0	0.0	0.0	5.0	0.0	0.0	0.0	4.0	...	0.0	0.0	3.0	4.0	3.0	0.0	0.0	0.0	0.0	5.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
174055	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	4.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
176371	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	4.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
177765	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	4.5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
179819	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
187593	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Figura 17 - Resultado parcial da execução do código-fonte 10 - Parte 2
Fonte: Elaborado pelo autor (2024)

Nosso `final_dataset` tem dimensões de 2121 * 378 onde a maioria dos valores são esparsos. Aqui estamos trabalhando com um pequeno subconjunto de dados, mas para o dataset completo teríamos mais de 100.000 features. Isso certamente travaria nosso código.

Para reduzir a dispersão, usamos `csr_matric` da scipy lib. Na sequência, vamos identificar os filmes mais parecidos (mais próximos do espaço de features), pela aplicação do KNN. O código a seguir não tem saída.

```
csr_data = csr_matrix(final_dataset.values)
final_dataset.reset_index(inplace=True)

knn = NearestNeighbors(metric='cosine',
algorithm='brute', n_neighbors=20, n_jobs=-1)
knn.fit(csr_data)
```

Código-fonte 11 - Tratando dados esparsos e construindo o motor de recomendação
Fonte: Elaborado pelo autor (2024)

Para interagirmos de forma mais fácil com o modelo, iremos construir um método que retorna os 10 filmes mais parecidos de acordo com o filme de entrada. O código busca o título do filme no catálogo e retorna seu ID, em seguida obtém os IDs dos filmes mais próximos deste ID selecionado, e, por fim, realiza uma engenharia reversa para dado o ID do filme retornar seu nome. Isso constrói uma lista de recomendação com a distância do filme buscado a cada filme elencado, retornando a consulta ao usuário:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
def get_movie_recommendation(movie_name):
    n_movies_to_reccomend = 10
    movie_list = movies[movies['title'].str.contains(movie_name)]
    if len(movie_list):
        movie_idx= movie_list.iloc[0]['movieId']
        movie_idx = final_dataset[final_dataset['movieId'] == movie_idx].index[0]

        distances , indices = knn.kneighbors(csr_data[movie_idx],n_neighbors=n_movies_to_reccomend+1)
        rec_movie_indices = sorted(list(zip(indices.squeeze().tolist(),distances.squeeze().tolist())),\
        key=lambda x: x[1])[:0:-1]

        recommend_frame = []

        for val in rec_movie_indices:
            movie_idx = final_dataset.iloc[val[0]]['movieId']
            idx = movies[movies['movieId'] == movie_idx].index
            recommend_frame.append({'Title':movies.iloc[idx]['title'].values[0],'Distance':val[1]})
        df = pd.DataFrame(recommend_frame,index=range(1,n_movies_to_reccomend+1))
        return df

    else:

        return "No movies found. Please check your input"
```

Código-fonte 12 - Método de obtenção das recomendações
Fonte: Elaborado pelo autor (2024)

Podemos interagir com o método do código-fonte “Método de obtenção das recomendações” por meio da seguinte chamada:

```
get_movie_recommendation('insira aqui o nome do filme')
```

Veja nas próximas figuras alguns exemplos! Você concorda com os resultados?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
get_movie_recommendation('Iron Man')
```

	Title	Distance
1	Up (2009)	0.368857
2	Guardians of the Galaxy (2014)	0.368758
3	Watchmen (2009)	0.368558
4	Star Trek (2009)	0.366029
5	Batman Begins (2005)	0.362759
6	Avatar (2009)	0.310893
7	Iron Man 2 (2010)	0.307492
8	WALL·E (2008)	0.298138
9	Dark Knight, The (2008)	0.285835
10	Avengers, The (2012)	0.285319

Figura 18 - Exemplo de uso do sistema de recomendação de filme - Parte 1
Fonte: Elaborado pelo autor (2024)

```
get_movie_recommendation('Titanic')
```

	Title	Distance
1	Good Will Hunting (1997)	0.460759
2	Truman Show, The (1998)	0.460628
3	Catch Me If You Can (2002)	0.460281
4	Sixth Sense, The (1999)	0.452878
5	Saving Private Ryan (1998)	0.437196
6	Shrek (2001)	0.433120
7	Finding Nemo (2003)	0.432400
8	Star Wars: Episode I - The Phantom Menace (1999)	0.427623
9	Forrest Gump (1994)	0.427187
10	Men in Black (a.k.a. MIB) (1997)	0.420254

Figura 19 - Exemplo de uso do sistema de recomendação de filme - Parte 2
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
get_movie_recommendation('Harry Potter')
```

	Title	Distance
1	Lord of the Rings: The Two Towers, The (2002)	0.391128
2	Incredibles, The (2004)	0.386104
3	Spider-Man (2002)	0.379973
4	Star Wars: Episode II - Attack of the Clones (...	0.377116
5	Pirates of the Caribbean: The Curse of the Bla...	0.367811
6	Monsters, Inc. (2001)	0.363530
7	Shrek (2001)	0.342930
8	Harry Potter and the Goblet of Fire (2005)	0.284509
9	Harry Potter and the Prisoner of Azkaban (2004)	0.271120
10	Harry Potter and the Chamber of Secrets (2002)	0.196221

Figura 20 - Exemplo de uso do sistema de recomendação de filme - Parte 3
Fonte: Elaborado pelo autor (2024)

5.3 Sobre outras técnicas

Métodos de Machine Learning são amplamente utilizados em sistemas de recomendação para personalizar experiências dos usuários. Na filtragem colaborativa, algoritmos como K-Nearest Neighbors (KNN) e Deep Learning identificam padrões entre usuários e itens. Na abordagem baseada em conteúdo, são usados TF-IDF, Cosine Similarity, e redes neurais para recomendar itens similares aos preferidos pelo usuário. Já na popularidade, análises estatísticas, contagens e rankings ponderados destacam itens mais consumidos. Essas abordagens podem ser combinadas em sistemas híbridos para maximizar a precisão das recomendações.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

CONCLUSÃO

Neste capítulo, exploramos o vasto universo dos sistemas de recomendação, compreendendo suas bases teóricas, métodos de avaliação, abordagens práticas e os desafios éticos e técnicos que os envolvem. Entendemos como diferentes técnicas, como filtragem colaborativa, baseada em conteúdo e híbrida, são aplicadas para personalizar experiências em contextos como e-commerce, streaming e redes sociais, destacando suas vantagens e limitações. Além disso, abordamos questões fundamentais, como o tratamento de dados, os problemas de cold start, os vieses e bolhas, e a importância de privacidade e segurança no uso de dados.

Aprendemos também que a avaliação de sistemas de recomendação vai muito além de métricas tradicionais, exigindo considerações como diversidade, novidade e serendipidade para oferecer uma experiência significativa aos usuários. Complementarmente, discutimos como métodos avançados, como o algoritmo Apriori e os modelos híbridos, podem criar soluções mais robustas e eficazes. Por fim, refletimos sobre a necessidade de um equilíbrio entre a inovação técnica e as responsabilidades éticas para garantir que as recomendações gerem valor tanto para os negócios quanto para os usuários.

Os sistemas de recomendação representam um dos pilares mais impactantes da personalização em plataformas digitais, moldando a maneira como consumimos informações e tomamos decisões. Apesar dos desafios, as oportunidades são imensas, e o futuro desses sistemas depende de sua capacidade de evoluir para se tornarem mais inteligentes, éticos e orientados ao usuário. Que este capítulo inspire novas ideias e direcione aplicações práticas em sistemas que conectem as pessoas ao que realmente importa para elas.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

AMADOR, Daniel Sousa. Regras de Associação. **Medium**, 25 de fevereiro de 2021. Disponível em: <https://daniel-s-amador.medium.com/regras-de-associa%C3%A7%C3%A3o-b02bb9ce6ea3>. Acesso em: 03 fev. 2025.

BANIK, Rounak. **Hands-on recommendation systems with Python:** start building powerful and personalized, recommendation engines with Python. Packt Publishing Ltd, 2018.

CHARU, C. Aggarwal. **Recommender systems:** The textbook. 2016.

JENSEN, Kenneth. A diagram showing the relationship between the different phases of CRISP-DM and illustrates the recursive nature of a data mining project. **Wikipédia**, 26 de abril de 2012. Disponível em: <https://pt.m.wikipedia.org/wiki/Ficheiro:CRISP-DM_Process_Diagram.png>. Acesso em: 03 fev. 2025.

PROVOST, Foster; FAWCETT, Tom. **Data Science for Business: What you need to know about data mining and data-analytic thinking**. O'Reilly Media, Inc., 2013.

SCHRAGE, Michael. **Recommendation engines**. MIT press, 2020.

SISTEMAS de recomendação. **Didática.tech**, 2024. Dispónivel em: <https://didatica.tech/sistemas-de-recomendacao/>. Acesso em: 03 fev. 2025.

TUDO que você precisa saber sobre teste A/B. **Blitzpay**, 22 de setembro de 2023. Disponível em: <https://blog.blitzpay.com.br/tudo-que-voce-precisa-saber-sobre-teste-a-b/>. Acesso em: 03 fev. 2025.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

GLOSSÁRIO

Termo	Explicação
KNN	K-Nearest Neighbors.
LGPD	Lei Geral de Proteção de Dados.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com