

Podcast

Disciplina: Análise e Modelagem Preditiva

Título do tema: Avaliação de Modelos Preditivos

Autoria: Orlando da Silva Junior

Leitura crítica: Amanda Souza da Silva

Abertura:

Olá, tudo bem? Aqui é o professor Orlando Junior e, no podcast de hoje, vamos falar sobre avaliação de modelos preditivos e em como você pode ter mais segurança com os modelos que você está programando.

Antes de tudo, você deve ter em mente alguns conceitos básicos da avaliação de modelos preditivos e a sua importância para Analytics, modelagem estatística e Machine Learning.

É bem verdade que, por causa da grande quantidade de dados que temos hoje (o Big Data) e de técnicas super avançadas (como redes neurais e Deep Learning), acabamos deixando de lado o rigor metodológico da ciência de dados.

Ficamos esperando que os dados ou os algoritmos resolvam todos os problemas pra nós.

Porém, até mesmo a falta de uma avaliação adequada pode trazer problemas para aplicações de Big Data e Deep Learning.

Pense que nós não estamos apenas querendo resultados ótimos a todo custo, mas garantir que esses resultados permanecerão ótimos também a longo prazo.

Assim, vamos direto ao ponto!

Pra começar, vamos pensar no processo de construção do nosso modelo preditivo, sendo ele de classificação ou regressão.

A primeira coisa que a gente faz é determinar qual métrica nós usaremos. Pode ser acurácia, erro quadrático médio, precisão, etc. O mais importante nessa primeira etapa é decidir qual medida usar. Na dúvida, podemos usar mais de uma. Podem ser duas, três, quatro.... desde que elas sejam consistentes com o problema que estamos querendo resolver. Depois de vários experimentos você poderá se concentrar em apenas uma para reportar ao cliente, até para que ele entenda mais facilmente.

Ok?

A segunda coisa que a gente vai fazer é preparar os experimentos. E como a gente vai fazer isso? Particionando os dados em subconjuntos de treinamento, avaliação e teste.

Se a gente tiver muitos dados, vamos de *holdout*. Por quê? Porque é rápido de fazer, fácil de manipular, fácil de entender. Além de tudo isso, com muitos dados à disposição, nossas estimativas serão mais confiáveis.

Para o *holdout*, eu gosto de começar em 80/20, ou seja 80% para treinamento e 20% para teste. Desses 80%, eu ainda tiro 20% para validação. Esse é o padrão que eu adoto e muito colegas profissionais da área também seguem.

Se os resultados iniciais ficarem muito ruins, eu vou mudando: 70/30, 60/40 e 90/10. Se a gente tiver a oportunidade de fazer isso, vale a pena.

Agora... se eu tenho muito poucos dados, eu faço a validação cruzada com 10 partições. Além de ser mais confiável, o processo é rápido. E raramente eu mexo na quantidade de partições. Na maior parte das vezes, vale a pena manter o número 10.

Ok?

Por fim, a terceira coisa que a gente vai fazer é executar os algoritmos (previamente já escolhidos) no conjunto de treinamento e avaliar nos conjuntos de avaliação e teste.

Quando avaliamos no conjunto de validação, nosso propósito é aproveitar os dados ainda não vistos pelo algoritmo para melhorar o desempenho desse mesmo algoritmo. Assim, ao mesmo tempo em que ele não vê os dados, ele vê e melhora o resultado.

Agora, quando avaliamos no conjunto de teste, temos certeza que o nosso modelo está adequado para ser colocado em produção. É claro, se os resultados forem bons.

Fechamento:

E aí, o que você achou do nosso *podcast* de hoje? Fique ligado no próximo assunto e até mais!