



INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINAS

Marcelo Henrique dos Santos

Marcelo Tavares de Lima

INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINAS

1ª edição

São Paulo

Platos Soluções Educacionais S.A

2022

© 2022 por Platos Soluções Educacionais S.A.

Todos os direitos reservados. Nenhuma parte desta publicação poderá ser reproduzida ou transmitida de qualquer modo ou por qualquer outro meio, eletrônico ou mecânico, incluindo fotocópia, gravação ou qualquer outro tipo de sistema de armazenamento e transmissão de informação, sem prévia autorização, por escrito, da Platos Soluções Educacionais S.A.

Head de Platos Soluções Educacionais S.A

Silvia Rodrigues Cima Bizatto

Conselho Acadêmico

Alessandra Cristina Fahl
Ana Carolina Gulelmo Staut
Camila Braga de Oliveira Higa
Camila Turchetti Bacan Gabiatti
Giani Vendramel de Oliveira
Gislaine Denisale Ferreira
Henrique Salustiano Silva
Mariana Gerardi Mello
Nirse Ruscheinsky Breternitz
Priscila Pereira Silva

Coordenador

Nirse Ruscheinsky Breternitz

Editorial

Beatriz Meloni Montefusco
Carolina Yaly
Márcia Regina Silva
Paola Andressa Machado Leal

Dados Internacionais de Catalogação na Publicação (CIP)

S237i Santos, Marcelo Henrique dos
Inteligência artificial e aprendizado de máquinas /
Marcelo Henrique dos Santos, Marcelo Tavares de Lima. –
São Paulo: Platos Soluções Educacionais S.A., 2022.
44 p.

ISBN 978-65-5356-269-1

1. Inteligência artificial. 2. Modelos preditivos. 3. Machine learning. I. Lima, Marcelo Tavares de. II. Título.

CDD 006.3

Evelyn Moraes – CRB: 010289/O

INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINAS

SUMÁRIO

A História da inteligência artificial	05
Implementando a inteligência artificial	22
Ambiente Favorável a aplicação de tecnologias de Analytics e IA	37
Introdução ao machine learning: como funciona a aprendizagem de máquina	52
Algoritmos de machine learning: modelos preditivos	72

A História da inteligência artificial

Autoria: Marcelo Henrique dos Santos

Leitura crítica: Paula Faragó Vieira Barbosa



Objetivos

- Compreender os conceitos sobre a Inteligência Artificial.
- Compreender sobre o Teste de Turing e a sua importância no desenvolvimento e nos avanços da Inteligência Artificial.
- Refletir sobre a integração da Inteligência Artificial no desenvolvimento de projetos e aplicações.

1. A Inteligência Artificial

A Inteligência Artificial (IA) é uma denominação comumente empregada para se referir ao campo da ciência destinado a fornecer máquinas com a capacidade de realizar funções como lógica, raciocínio, planejamento, aprendizagem e percepção. Apesar da referência a “máquinas” nessa definição, o último poderia ser aplicado a “qualquer tipo de inteligência viva”. Da mesma forma, o significado de inteligência, como é encontrado em primatas e outros animais excepcionais, por exemplo, pode ser estendido nesse contexto e inclui um conjunto intercalado de capacidades, como a criatividade, o conhecimento emocional e a autoconsciência.

O termo IA foi intimamente associado ao campo da “**IA simbólica**”, popular até o final dos anos 1980. Para superar algumas das limitações desta, foram implementadas algumas metodologias subsimbólicas, como redes neurais, sistema *fuzzy*, computação evolutiva e outros modelos, levando ao termo “**Inteligência computacional**”, que emerge como um subcampo da IA.

Hoje em dia, o termo IA abrange toda a conceitualização de uma máquina que é inteligente em termos e consequências operacionais e sociais. Uma definição prática é a proposta por Russell e Norvig (2009), que apontam que a IA é o estudo da inteligência humana e das ações replicadas artificialmente, de modo que o resultado tem em seu desenho um nível razoável de racionalidade. Essa definição pode ser mais refinada ao estipular que o nível da racionalidade pode até substituir os humanos, por questões específicas e tarefas bem definidas, vide Figura 1.

Figura 1 – Representação dos conceitos da IA



Fonte: iStock – ipopba / iStock.com.

A perspectiva de criar computadores inteligentes fascina muitas pessoas desde os primórdios dos computadores, e, como veremos no panorama histórico, as primeiras dicas na direção da IA datam antes mesmo disso. Mas o que queremos dizer com IA, se até o próprio termo inteligência é difícil de definir?

A definição e o significado precisos da palavra inteligência, e ainda mais de Inteligência Artificial, é um assunto de muita discussão e tem causado muita confusão. A Inteligência Artificial pode ser vista como sendo:

1. Uma área de estudo no campo da ciência da computação, preocupada com o desenvolvimento de computadores capazes de se envolver em processos de pensamento, como aprendizagem, raciocínio e autocorreção.
2. O conceito de que as máquinas podem ser aprimoradas para assumir algumas capacidades, sendo normalmente pensadas para funcionar como a inteligência humana, como aprendizagem, adaptação, autocorreção etc.
3. A extensão da inteligência humana por meio do uso de computadores (com o uso de ferramentas mecânicas).

4. Em um sentido restrito, o estudo de técnicas para usar computadores de forma mais eficaz a partir de técnicas de programação aprimoradas.

De acordo com Negnevitsky (2002), as definições também mudaram ao longo do tempo, devido aos desenvolvimentos rápidos. Há algum tempo, a comunidade de IA vem tentando imitar o comportamento inteligente com programas de computador; porém, essa não é uma tarefa fácil, porque este deve ser capaz de fazer muitas coisas diferentes para ser chamado de inteligente.

Em vez de olhar para uma definição geral de Inteligência Artificial, podemos também restringir à definição de sistemas artificialmente inteligentes. Existem muitas definições ao redor, mas a maioria delas pode ser classificada nas quatro categorias a seguir:

1. Sistemas que pensam como humanos.
2. Sistemas que agem como humanos.
3. Sistemas que pensam racionalmente.
4. Sistemas que agem racionalmente.

1.1 O Teste de Turing

Se temos um sistema, como podemos verificar se ele é (artificialmente) inteligente? Existe uma diferença entre humanos e computadores no que diz respeito à inteligência?

Alan Turing (HODGES, 2012) propôs um jogo a fim de responder à pergunta **“As máquinas podem pensar?”**. Esse jogo de imitação¹ agora é conhecido como Teste de Turing, e o próprio Turing o descreve da seguinte forma:

¹ Sugerimos a leitura do livro *Alan Turing: The Enigma*, de Andrew Hodges.

É jogado com três pessoas, um homem (A), uma mulher (B) e um interrogador (C), que pode ser de qualquer sexo. O interrogador fica em uma sala separada dos outros dois. O objetivo para o interrogador é determinar qual dos dois é o homem e qual é a mulher. Ele os conhece pelos rótulos X e Y, e no final do jogo ele diz que “X é A e Y é B” ou “X é B e Y é A”.

Agora fazemos a pergunta: o que acontecerá quando uma máquina assumir a parte de A nesse jogo? O interrogador decidirá erroneamente com a frequência quando o jogo é jogado, assim como ele faz quando o jogo é disputado entre um homem e uma mulher? Essas questões substituiriam a pergunta original: “As máquinas podem pensar?”.

Claro, a configuração do teste deve tornar impossível decidir quem é quem, por medir o tempo de resposta, as características de voz ou critérios semelhantes. O teste de Turing é polêmico porque muitos acreditam que é possível enganar (C) sem ter um programa inteligente, mas pelo menos nos fornece alguns critérios.

Para passar no teste de Turing, um computador precisaria pelo menos das seguintes habilidades:

1. **Processamento de linguagem natural:** precisa ser capaz de se comunicar de forma natural com o idioma em questão (como o inglês).
2. **Representação do conhecimento:** precisa ser capaz de ter conhecimento e armazená-lo em algum lugar.
3. **Raciocínio automatizado:** precisa ser capaz de fazer raciocínio com base no armazenado do conhecimento.
4. **Aprendizado de máquina:** precisa ser capaz de aprender com o seu ambiente.

De acordo com Negnevitsky (2002), as formas tradicionais de projetar os sistemas inteligentes, como sistemas baseados em regras, nunca alcançaram os resultados esperados na época em que as pessoas começaram a perceber que os computadores podem ser usados além de simplesmente calcular. Até agora, não foi possível construir um conjunto de regras capaz de mostrar um comportamento realmente inteligente. Existem alguns sistemas especialistas capazes de competir em um nível de especialista em áreas estreitas, mas ainda não existe um programa geral de IA que seja capaz de funcionar em situações cotidianas.

Negnevitsky (2002) afirma que “os sistemas especialistas sabem tudo sobre quase nada”, o que significa, entre outras coisas, que eles são bastante diferentes dos especialistas humanos. No entanto, na prática, muitos sistemas usam técnicas de IA e, nesse sentido, a comunidade de IA trouxe um impacto bastante grande sem atingir os objetivos originais (por enquanto). Além disso, temos que observar o fato de que uma pessoa que consegue jogar xadrez em alto nível é geralmente considerada muito inteligente, independentemente de suas outras realizações.

A IA sempre teve suas vitrines e jogar jogos, xadrez em particular, sempre foi um grande destaque. Outra vitrine é o campo da robótica, no qual estão envolvidos vários algoritmos de IA, como em robôs de direção que jogam futebol.

1.2 O que é um agente?


De acordo com Hewitt (1977), a forma mais geral em que o termo **agente** é usado, seja para denotar um hardware ou, mais comumente, um sistema de computador baseado em software, possui as seguintes propriedades:

- **Autonomia:** os agentes operam sem a intervenção direta de humanos, ou outros, e têm algum tipo de controle sobre suas ações e seu estado interno.

- **Habilidade social:** os agentes interagem com outros agentes (e possivelmente humanos) por meio de algum tipo de linguagem de sua comunicação.
- **Reatividade:** os agentes percebem seu ambiente – que pode ser o mundo físico, um usuário por meio de uma interface gráfica, uma coleção de outros agentes, a internet ou talvez todos esses elementos combinados – e respondem em tempo hábil às mudanças que ocorrem nele.
- **Proatividade:** os agentes não agem simplesmente em resposta ao seu ambiente; eles são capazes de exibir um comportamento direcionado a um objetivo, tomando a iniciativa.

A seguir temos uma imagem que representa a criação de um agente inteligente.

Figura 2 – Representação da criação de um agente inteligente



Fonte: iStock – Andy / iStock.com.

Uma maneira simples de conceituar um agente é, portanto, como um tipo de processo de software semelhante ao UNIX, que exhibe essas propriedades. Por exemplo, na ciência da computação convencional, a noção de um agente como um processo de software autossuficiente, executando simultaneamente, que encapsula algum estado e é capaz de se comunicar com outros agentes por meio da passagem de mensagens, é vista como um desenvolvimento natural do paradigma de programação simultânea baseada em objeto (AGHA; WEGNER; YONEZAWA, 1993).

Essa noção também é usada na disciplina emergente baseada em agente da Engenharia de software: os agentes se comunicam com seus pares trocando mensagens de uma forma expressiva (linguagem de comunicação do agente). Embora os agentes possam ser tão simples quanto sub-rotinas, normalmente são entidades maiores com algum tipo de controle persistente (GENESERETH; KETCHPEL, 1994).

As tecnologias atuais de IA são usadas em publicidade on-line, imagem de direção, aviação, medicina e reconhecimento de assistência pessoal. O recente sucesso da IA conquistou a imaginação da comunidade científica e do público. Um exemplo disso são os veículos equipados com um sistema automático de direção, também conhecidos como carros autônomos. Cada veículo é equipado com uma série de sensores e câmeras que permitem o reconhecimento de seus ambientes tridimensionais e fornecem a capacidade de tornar inteligentes as decisões sobre manobras em estradas e as condições do tráfego real variável.

Outro exemplo é o Alpha-Go, desenvolvido pela Google Deepmind para jogar o jogo de tabuleiro Go. O número de jogos possíveis em Go é estimado em 10^{170} , e, dada a extrema complexidade do jogo, a maioria dos pesquisadores de IA acreditava que seriam necessários anos antes que isso pudesse acontecer, o que levou ao entusiasmo e ao medo em muitos de que a IA superaria os humanos em todos os campos da ciência. No entanto, as tecnologias atuais de IA são limitadas

a formulários, sendo uma de suas limitações, por exemplo, a falta do “senso comum”, a capacidade de julgar as informações além do seu conhecimento adquirido.

Outro exemplo é a IA que foi empregada na construção do robô Tay, desenvolvido pela Microsoft e projetado para responder a conversas em redes sociais. Teve que ser desconectado logo após seu lançamento, porque não foi capaz de distinguir entre interação humana positiva e negativa. A IA também é limitada em termos de inteligência emocional; ela só pode detectar os estados emocionais humanos básicos, como raiva, alegria, tristeza, medo, dor, estresse e neutralidade. A inteligência emocional é uma das fronteiras de níveis mais elevados de personalização.

O *chatbots* pode ser visto como sendo um novo canal de informação, comunicação e transação que permite que as empresas atinjam seu público-alvo por meio de aplicativos de mensagens, como Facebook, WhatsApp, entre outros. Comparados com os chats tradicionais, não são controlados por pessoas, mas pelo software, que conduz as conversas. Os últimos desenvolvimentos de chatbots em serviços e vendas ao cliente são notáveis.

A IA verdadeira e completa ainda não existe. Nesse nível, ela busca o processo de imitar a cognição humana a ponto de adquirir alguma habilidade específica, pensar, sentir emoções e ter objetivos próprios. Apesar de não haver evidências de que esse tipo de IA poderá existir nos próximos meses, os princípios da ciência da computação que orientam a IA para o futuro estão avançando rapidamente e é importante avaliar seu impacto, não apenas do ponto de vista tecnológico, mas também de uma perspectiva social, ética e legal.

1.2.1 Uma abordagem sistemática para agentes inteligentes

Os agentes são ferramentas avançadas que as pessoas usam para atingir diferentes objetivos e para solucionar vários problemas. A

principal diferença entre ferramentas e agentes comuns é que estes podem funcionar mais ou menos independentemente daqueles que os delegaram. Por muito tempo, as pessoas usavam apenas outras pessoas e às vezes animais como seus agentes.

Os desenvolvimentos em tecnologia de processamento de informação, os computadores e suas redes tornaram possível construir e usar agentes artificiais, e agora a abordagem mais popular na IA artificial é baseada em agentes. Os agentes inteligentes formam a base para muitos tipos de sistemas de software avançados que incorporam metodologias variadas, diversas fontes de conhecimento de domínio e uma variedade de tipos de dados. A abordagem de agente inteligente foi amplamente aplicada em sistemas de negócios, de apoio à decisão médica, atrelados à ecologia e várias outras áreas.

No paradigma geral, o tomador de decisão humano é considerado um ser agente e está incorporado no processo de decisão. Essa decisão geral é facilitada por um gerenciador de tarefas que atribui subtarefas ao agente apropriado e combina as conclusões alcançadas pelos agentes para formar a decisão final.

Um agente autônomo é um sistema situado dentro e parte de um ambiente que sente aquele ambiente e age sobre ele, ao longo do tempo, em busca de sua própria agenda, de modo a efetuar o que sente no futuro (FRANKLIN; GRAESSER, 1996). No entanto, também existem aspectos naturais e sociais sobre os agentes. Por exemplo, o termo agente no contexto de negócios ou econômicos refere-se a objetos naturais do mundo real, como organizações, empresas ou pessoas. Esses objetos são capazes de exibir um comportamento autônomo, como reagir a eventos externos, e iniciar atividades e interação com outros objetos.

Assim, é razoável supor que um agente é qualquer coisa (ou qualquer pessoa) que pode ser visto como percebendo seu ambiente por meio

de sensores e agindo sobre esse ambiente por meio de efetores. Um agente humano tem olhos, ouvidos e outros órgãos para a realização dos sensores e mãos, pernas, boca e outras partes do corpo para efetores; um agente robótico utiliza câmeras, telêmetros infravermelhos e outros dispositivos de detecção como sensores e várias partes do corpo como efetores; e um agente de software possui canais de comunicação para os sensores e efetores.

De acordo com Jansen (1997), podemos definir os agentes inteligentes a partir dos seguintes elementos:

1. Agentes são programas de computador semiautônomos que auxiliam de forma inteligente o usuário com aplicativos de computador, empregando técnicas de IA para auxiliar os usuários com a realização de tarefas diárias de computador, como ler um e-mail, manter o calendário e as informações de arquivamento. Eles aprendem por meio do raciocínio baseado em exemplos e são capazes de melhorar seu desempenho ao longo do tempo.
2. Agentes são sistemas computacionais que habitam alguns complexos e dinâmicos ambientes e sentem e agem autonomamente para realizar um conjunto de objetivos ou tarefas.
3. Agentes são robôs de software que pensam e agem em nome de um usuário para realizar tarefas. Eles ajudam a atender à necessidade crescente de recursos mais funcionais, flexíveis e pessoais (sistemas de computação e telecomunicações). Seus usos incluem as tarefas autônomas, operando de forma semiautônoma, e a comunicação entre os recursos do usuário e do sistema.
4. Agentes são programas de software que implementam a delegação de usuários.

Franklin e Graesser (1996) coletaram e analisaram uma lista mais extensa de definições. Segundo eles, um agente é qualquer coisa que

pode ser vista como a dinâmica de perceber seu ambiente por meio de sensores e agir sobre esse ambiente por meio de efetores.

Os agentes podem ser definidos como sendo uma entidade de software persistente dedicada a um propósito específico. A persistência distingue agentes de sub-rotinas; eles têm suas próprias ideias sobre como realizar tarefas (possuem suas próprias agendas). Eles desempenham continuamente três funções: percepção de dinâmica das condições do meio ambiente; ação para afetar as condições no meio ambiente; e raciocínio para interpretar percepções, resolver problemas, fazer inferências e determinar as suas ações (HAYES-ROTH, 1995).

Os agentes são entidades de software que realizam algum conjunto de operações em nome de um usuário ou outro programa, com algum grau de independência ou autonomia, e, ao fazê-lo, empregam algum conhecimento ou realizam algum objetivo esperado.

1.3 O impacto da IA

Dado o aumento exponencial do interesse em IA, os especialistas estão desenvolvendo estudos importantes sobre seu impacto em nossa sociedade, não apenas na área tecnológica, mas também jurídica, ética e socioeconômica. Essa resposta também inclui a especulação de que um dia ela poderá substituir as capacidades cognitivas dos humanos. Esse cenário futuro geralmente é conhecido em fóruns sobre o tema como “singularidade de IA”, sendo comumente definido como a capacidade das máquinas de construir máquinas melhores por conta própria.

Esse cenário futurista foi questionado e é recebido com ceticismo por muitos especialistas. Os pesquisadores de IA de hoje estão mais focados em desenvolver sistemas que sejam muito bons em tarefas em uma gama estreita de aplicações, foco que está em desacordo com a ideia da busca por um sistema de IA supergenérico que possa imitar todas as

diferentes habilidades cognitivas relacionadas à inteligência humana, como autoconsciência e conhecimento emocional.

Por exemplo, o AI100 (*One Hundred Year Study on Artificial Intelligence*) é um comitê liderado pela Universidade de Stanford e definiu 18 tópicos de importância para IA (HORVITZ, 2014), que, embora não sejam elementos definitivos, estabelecem a gama de tópicos que precisam ser estudados para o potencial impacto da IA, bem como salientam que há uma série de questões a serem abordadas. Muitas avaliações semelhantes foram realizadas e cada uma descreve preocupações semelhantes relacionadas à adoção mais ampla da tecnologia de IA.

1.3.1 Os 18 tópicos cobertos pelo AI100

1. **Tendências técnicas e surpresas:** visa prever os avanços futuros e as competências da IA e das tecnologias que irão ocorrer em um futuro próximo. São observatórios da tendência do impacto da IA, ajudando a planejar a definição de IA em setores específicos e preparando as regulamentações necessárias para facilitar sua introdução.
2. **Oportunidades principais para IA:** mostra como os avanços em IA podem ajudar a transformar a qualidade dos serviços sociais, como saúde, educação, gestão e governo, abrangendo não apenas os benefícios econômicos, mas também as vantagens sociais e os seus impactos.
3. **Atrasos na tradução dos avanços da IA em valores do mundo real:** o ritmo de traduzir IA em aplicações do mundo real é impulsionado atualmente pelas perspectivas econômicas potenciais. Isso é necessário para tomar medidas para promover uma tradução rápida das aplicações potenciais de IA que podem melhorar ou resolver uma necessidade crítica de nossa sociedade, como aquelas que podem salvar vidas ou melhorar

muito a organização dos serviços sociais, embora sua exploração econômica ainda não esteja assegurada.

4. **Privacidade e inteligência de máquina:** os dados pessoais e a privacidade são uma questão importante para se considerar e prever, além de preparar a regulamentação legal e política das estruturas relacionadas ao compartilhamento de dados pessoais em desenvolvimento de sistemas de IA.
5. **Democracia e liberdade:** além da privacidade, perguntas relacionadas à ética quanto ao uso furtivo de IA para aplicativos sem escrúpulos devem ser consideradas. O uso de IA não deve ser feito à custa de limitar ou influenciar a democracia e a liberdade das pessoas.
6. **Lei:** considera as implicações das leis relevantes e seus regulamentos, para identificar quais aspectos da IA exigem avaliação legal e quais ações devem ser realizadas para garantir a aplicação da lei nesses serviços. Também é preciso fornecer estruturas e diretrizes sobre como aderir a leis e políticas aprovadas.
7. **Ética:** no momento em que a IA é implantada no mundo real, há questões éticas referentes à interação com o mundo. Quais usos da IA devem ser considerados antiéticos? Como isso deve ser divulgado?
8. **Economia:** as implicações econômicas da IA nos empregos devem ser monitoradas e previstas de forma que as políticas possam ser implementadas para direcionar nossa geração futura para eles. O uso de IA sofisticada nos mercados financeiros poderia potencialmente causar volatilidades, sendo necessário avaliar a influência de seus sistemas nos mercados financeiros.

9. **IA e guerra:** a IA tem sido empregada pelos aplicativos e sistemas militares por mais de uma década. Robôs de franco-atiradores e torres foram desenvolvidos para fins militares. Armas inteligentes têm níveis crescentes de autonomia, havendo a necessidade de desenvolver novas convenções e acordos internacionais para definir um conjunto de fronteiras seguras do uso de IA em armamento e guerra.
10. **Usos criminosos de IA:** implementações de IA em *malware* estão se tornando mais sofisticadas e, com isso, as chances de roubos de informações pessoais de dispositivos infectados estão cada vez maiores. O *malware* pode ser mais difícil de detectar, pois as técnicas de evasão por vírus e *worms* de computador podem alavancar as técnicas de IA altamente sofisticadas. Outro exemplo é o uso de drones e seu potencial para cair nas mãos de terroristas, cuja consequência seria devastadora.
11. **Colaboração com máquinas:** humanos e robôs precisam trabalhar juntos e é pertinente prever como será a colaboração de cenários de forma segura. Acidentes por robôs trabalhando lado a lado com pessoas aconteceram no início do processo de integração, e, por isso, o desenvolvimento de sistemas autônomos deve se concentrar não apenas na precisão da tarefa aprimorada, mas também na capacidade de compreender o meio ambiente e a intenção humana.
12. **IA e cognição humana:** a IA tem potencial para melhorar as habilidades cognitivas humanas, e, entre as disciplinas de pesquisa relevantes com esse objetivo está a informática de sensores e interfaces homem-computador. Além de aplicações para reabilitação e vida assistida, há o uso em cirurgias e no controle de tráfego aéreo.
13. **Segurança e autonomia:** para a operação segura de sistemas inteligentes, os sistemas autônomos devem conter ferramentas

de verificação formal para avaliar sua operação de segurança. A validação pode estar focada no processo de raciocínio e verificar se a base de conhecimento de um sistema inteligente está correta, certificando-se de que a formulação do comportamento inteligente estará dentro dos limites de segurança.

14. **Perda de controle dos sistemas de IA:** o potencial de a IA ser independente do controle humano é uma grande preocupação. Nesse sentido, devem ser promovidos estudos tanto do ponto de vista tecnológico quanto da estrutura relevante, a fim de haja um desenvolvimento responsável da IA.
15. **Psicologia de pessoas e máquinas inteligentes:** mais pesquisas devem ser realizadas para obter um conhecimento detalhado sobre as opiniões e as preocupações que as pessoas têm, no uso mais amplo de máquinas inteligentes nas sociedades. Além disso, no design de sistemas inteligentes, entender as preferências das pessoas é importante para melhorar sua aceitabilidade.
16. **Comunicação, compreensão e divulgação:** as estratégias de comunicação e educação devem ser desenvolvidas para abraçar tecnologias de IA em nossa sociedade. Essas estratégias devem ser formuladas a fim de que sejam compreensíveis e acessíveis por não especialistas e pelo público em geral.
17. **Neurociência e IA:** podem se desenvolver de forma sincronizada. A neurociência desempenha um papel importante para orientar a pesquisa em IA e, com os novos avanços em alto desempenho da computação, também existem novas oportunidades para estudar o cérebro por meio de modelos computacionais e simulações para investigar novas hipóteses.
18. **IA e filosofia da mente:** quando a IA experimentar um nível de consciência e autoconsciência, haverá a necessidade de entender

o mundo interno da psicologia e das máquinas, além de sua subjetividade de consciência.

Referências

- AGHA, G.; WEGNER, P.; YONEZAWA, A. (ed.). **Research Directions in Concurrent Object-Oriented Programming**. Cambridge, MA: The MIT Press, 1993.
- COPPIN, B. **Inteligência artificial**. Rio de Janeiro: Grupo Gen-LTC, 2015.
- FRANKLIN, S.; GRAESSER, A. **Is it an Agent, or just a Program?: A Taxonomy for Autonomous Agents**. 1996. Disponível em: <https://link.springer.com/chapter/10.1007/BFb0013570>. Acesso em: 10 mar. 2021.
- GENESERETH, M. R.; KETCHPEL, S. P. Software agents. **Communications of the ACM**, [s.l.], v. 37, n. 7, 1994.
- HAYES-ROTH, B. An Architecture for Adaptive Intelligent Systems. **Artificial Intelligence**, [s.l.], v. 72, n. 1-2, p. 329-365, 1995.
- HEWITT, C. Viewing control structures as patterns of passing messages. **Artificial Intelligence**, [s.l.], v. 8, n. 3, p. 323-364, 1977.
- HODGES, A. **Alan Turing: The Enigma**. London: Vintage Books, 2012.
- HORVITZ, E. **One Hundred Year Study on Artificial Intelligence: Reflections and Framing**. EUA: Stanford University, 2014.
- JANSEN, J. **Using Intelligent Agents to Enhance Search Engine Performance**. 1997. Disponível em: <https://firstmonday.org/ojs/index.php/fm/article/view/517>. Acesso em: 14 dez. 2020.
- NEGNEVITSKY, M. **Artificial Intelligence: A Guide to Intelligent Systems**. Londres: Pearson, 2002.
- RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 3. ed. Rio de Janeiro: Campus, 2013.
- RUSSELL, S. J.; NORVIG, P. **Artificial intelligence: a modern approach**. 3. ed. EUA: Prentice Hall, 2009.

Implementando a inteligência artificial

Autoria: Marcelo Henrique dos Santos

Leitura crítica: Paula Faragó Vieira Barbosa



Objetivos

- Compreender os princípios e os conceitos de espaço e estados de busca.
- Aprender a aplicar as estratégias e os algoritmos de busca.
- Desenvolver algoritmos para a resolução de problemas.



1. Resolução de problemas utilizando as técnicas de IA

A Inteligência Artificial (IA) pode ser vista como sendo a parte da Ciência da Computação preocupada em projetar sistemas de computador inteligentes, que exibam as características que associamos ao comportamento humano inteligente. Observamos sua importância quando consideramos que grande parte da Pesquisa Operacional está preocupada com as atividades de planejamento ou com as ações necessárias para resolver problemas.

A pesquisa na área de IA esteve envolvida com a dinâmica da busca por soluções para problemas que não se prestam a uma abordagem algorítmica. Além disso, em muitos casos, o conhecimento ou as informações sobre um domínio de problema são difíceis ou não naturais para a representação em estruturas de dados, como matrizes ou conjuntos de números. Frequentemente, é mais “natural” representar um problema como um conjunto de sentenças ou declarações em inglês que descrevem seu domínio.

De acordo com Graham (1979), existem duas dificuldades associadas à abordagem algorítmica (passo a passo) para resolver uma classe de problemas:

- a. Muitas vezes não existe um algoritmo que irá resolver todos os problemas em uma determinada classe.
- b. Mesmo se houver um algoritmo para resolver todos os problemas em determinada classe, ele pode ser tão ineficiente a ponto de ser inadequado para os problemas práticos (programas que rodam em tempo exponencial são considerados impraticáveis).

No entanto, os humanos muitas vezes enfrentam uma classe de problemas para a qual não existe nenhum algoritmo abrangente e, se existir, é executado em tempo exponencial. Isso é feito apesar de

as técnicas de resolução de problemas serem consideradas falíveis, aproximadas e com base em métodos rápidos e sujos.

Em vez de tentar construir algoritmos para resolver problemas, os pesquisadores de IA têm se concentrado nos métodos mais bem-sucedidos usados por humanos. Como os humanos podem compreender e expressar conhecimento de resolução de problemas mais facilmente usando símbolos e linguagem natural, as linguagens de programação simbólica foram desenvolvidas para a programação de IA que tende a se basear no processamento de símbolos em vez do processamento de números.

1.1 Representação do problema

De acordo com Winston (1984), existem dois métodos bem usados para representar um problema. O primeiro trata o problema como uma rede de estados inerentemente ordenados, enquanto o segundo vê o problema como uma série de subproblemas que, por sua vez, têm problemas de subitens (elementos) e assim por diante, até que uma solução imediata seja alcançada. Formalmente, esses dois métodos são conhecidos como a representação do espaço de estado e a representação da redução do problema.

A escolha de qual representação usar para um problema particular é comentada por Winston (1984). Segundo ele, algumas representações enfatizam coisas mais importantes para resolver uma classe de problemas. Dessa forma, um esquema é mais poderoso do que outro porque oferece mais comodidade ao usuário, embora, teoricamente, ambos possam fazer o mesmo trabalho.

Ainda de acordo com Winston (1984), uma representação do problema de espaço de estado consiste em condições congeladas de um problema em cada estágio de sua solução. Essa representação deve ser usada para problemas cujas soluções são caracterizadas por uma sucessão de

estados. Um exemplo é o problema do “caminho mais curto”, cujo objetivo é encontrar a rota mais curta possível. Porém, ao procurar uma solução nas redes, é possível ficar preso em um *loop* cíclico, o que pode ser detectado e interrompido por mecanismos extras programados. No entanto, por ser mais fácil eliminar os caminhos cíclicos da rede, a estrutura resultante é então chamada de gráfico ou árvore de espaço de estado.

Embora isso aumente o tamanho da estrutura de dados representacionais do problema, reduz a quantidade de dificuldade do código necessário para verificar os *loops* cíclicos. As redes são feitas em árvores, traçando todos os caminhos possíveis até o ponto em que eles entram novamente nos nós visitados anteriormente ou chegam a um nó sem saída. Por convenção, a árvore tem nós conectado por ramos, e as ramificações conectam diretamente os nós pais com os filhos. O nó superior, aquele que não tem pai, é chamado de nó raiz (WINSTON, 1984).

Usando o método de redução de problemas (ou redução de metas), o problema é estruturado como um conjunto de subproblemas (ou subobjetivos). Sua solução é vista como sendo a obtenção de subobjetivos, ao ir do objetivo inicial ao final.

2. Conceitos de espaço e estados de busca

Os últimos anos de pesquisa testemunharam o desenvolvimento de muitas ferramentas de IA para resolver os problemas mais difíceis na Ciência da Computação e da Engenharia. Essas ferramentas são: pesquisa e otimização; lógica; métodos probabilísticos para raciocínio incerto; classificadores e métodos estatísticos de aprendizagem; redes neurais; teoria de controle e linguagens etc.

Muitos problemas em IA podem ser resolvidos em teoria de forma inteligente, procurando por várias soluções possíveis. Por exemplo, os algoritmos de planejamento pesquisam árvores com objetivos e

subobjetivos, a fim de encontrar um caminho para atingir o objetivo, um processo denominado ***means-end analysis*** (POOLE, 1998).

Os algoritmos robóticos podem ser usados para mover membros e agarrar objetos; para implementar tal estrutura, podemos utilizar as pesquisas que abordam sobre espaço de configuração. Muitos algoritmos de aprendizagem utilizam as pesquisas dos algoritmos baseados em otimização, e a solução, para muitos problemas, é usar “heurísticas” que eliminam as escolhas que provavelmente não levarão à meta (chamado de poda da árvore de pesquisa). A heurística fornece ao programa um “melhor palpite” para a solução (RUSSELL; NORVING, 2003).

Para muitos problemas, é possível iniciar a pesquisa com alguma forma de suposição e então redefinir a estimativa incrementalmente até que nenhum refinamento possa ser feito. Esses algoritmos podem ser visualizados como escalada às cegas, ou seja, começamos a busca em um ponto aleatório da paisagem e então, por saltos ou passos, continuamos movendo nossa suposição até chegarmos ao topo. Outros algoritmos de otimização são o reconhecimento simulado e a otimização aleatória (RUSSELL; NORVING, 2003).

A pesquisa é um mecanismo universal de solução de problemas em IA, nos quais a sequência de etapas necessárias para a solução não é conhecida a priori, mas muitas vezes deve ser determinada por uma exploração de tentativa e erro de alternativas. Os problemas que foram resolvidos por IA com algoritmos de pesquisa dividem-se em três classes gerais: *single-agent path-finding problems*; *game playing*; e *constraint-satisfaction problems*. Exemplos clássicos na literatura de IA de *single-agent path-finding problems* são os blocos deslizantes de quebra-cabeças (puzzles), incluindo os de 3×3, 4×4 e 5×5. Eles são testes comuns para pesquisas em algoritmos de pesquisa de IA porque são muito simples de representar e manipular (RATNER; WARMUTH, 1986).

Um exemplo conhecido de um problema de *single-agent pathfinding problems* é o cubo de Rubik. Exemplos do mundo real incluem a prova de teorema, o problema do viajante e a navegação do veículo. Em cada caso, a tarefa é encontrar uma sequência de operações que mapeiam um estado inicial para um estado de objetivo. Uma segunda classe de problemas de pesquisa inclui jogos, como xadrez, damas, Othello, gamão, bridge, pôquer e Go.

A terceira categoria são os problemas *constraint-satisfaction problems*, como os do Sudoku, cuja tarefa é preencher cada célula vazia em uma matriz 9×9 com um dígito de zero a nove, de modo que cada linha, coluna e nove submatrizes 3×3 contenham todos os dígitos de zero a nove. Exemplos do mundo real são onipresentes, incluindo, por exemplo, o planejamento e a programação de formulários.

Figura 1 – Representação do jogo Sudoku



Fonte: iStock – GA161076 / iStock.com.

2.1 Modelo de Espaço de Problemas

Um espaço de problema é o ambiente no qual uma pesquisa ocorre e consiste em um conjunto de estados do problema e um conjunto de

operadores que alteram esse estado. Por exemplo, no quebra-cabeça 3x3, os estados são as diferentes permutações possíveis das peças, e os operadores deslizam uma peça na posição em branco. Uma instância de problema é um espaço de problema junto com um estado inicial e um estado objetivo, e, no caso do quebra-cabeça 3x3, o estado inicial seria qualquer permutação inicial. A tarefa é encontrar uma sequência de operadores que mapeiam o estado inicial para um estado objetivo (NEWELL; SIMON, 1972).

Os estados do espaço são representados por nós do grafo e os operadores por arestas entre nós. A tarefa em um problema de localização de caminho de um agente único é encontrar um caminho no gráfico a partir do nó inicial para um nó de objetivo. Embora a maioria dos espaços correspondam a gráficos com mais de um caminho entre um par de nós, para simplificar, eles são frequentemente representados como árvores, sendo o estado inicial sua raiz. O custo dessa simplificação é qualquer estado que possa ser alcançado por dois caminhos diferentes poder ser representado por nós duplicados na árvore, aumentando seu tamanho. O benefício de uma árvore é que a ausência de vários caminhos para o mesmo estado simplifica muito os algoritmos de pesquisa.

Um recurso que distingue os algoritmos de pesquisa de IA de outros algoritmos de pesquisa de gráfico é o tamanho dos gráficos envolvidos. Por exemplo, estima-se que todo o gráfico do xadrez contenha mais de 1.040 nós. Como resultado, os gráficos de espaço de problema de IA nunca são representados explicitamente listando cada estado, mas, em vez disso, são implicitamente representados especificando um estado inicial e um conjunto de operadores para gerar novos estados (que estão relacionados com os já existentes). Além disso, o tamanho de um problema de IA raramente é expresso como o número de nós em seu gráfico de espaço de problema. Em vez disso, os dois parâmetros de uma árvore de pesquisa que determinam a eficiência de vários algoritmos de pesquisa são seu fator de ramificação e sua profundidade de solução.

Figura 2 – Representação do jogo de xadrez



Fonte: iStock – marchmeena29 / iStock.com.

2.2 Pesquisa de força bruta (*Brute-Force Search*)

Os algoritmos de pesquisa mais gerais são de força bruta, uma vez que não requerem nenhum conhecimento específico do domínio. Nesse caso, são necessários apenas uma descrição do estado, um conjunto de operadores legais, um estado inicial e uma descrição do estado de objetivo. As técnicas de força bruta mais importantes são **custo uniforme**, **profundidade**, **bidirecional** e **pesquisa de fronteira** (POHL, 1971).

2.2.1 Pesquisa de Custo Uniforme

Em vez de expandir os nós em ordem de profundidade a partir da raiz, a pesquisa de custo uniforme os expande na ordem de seu custo. Em cada etapa, o próximo nó n a ser expandido é aquele cujo custo $g(n)$ é o mais baixo, sendo $g(n)$ a soma dos custos das arestas da raiz ao nó n . Nesse método, os nós são armazenados em uma fila de prioridade. Esse algoritmo é semelhante ao algoritmo do caminho mais curto de fonte única de Dijkstra (1959).

A principal diferença é que a pesquisa de custo uniforme é executada até que um nó de meta seja escolhido para a sua expansão, enquanto o algoritmo de Dijkstra é executado até que cada nó em um gráfico finito seja escolhido para a sua expansão. Sempre que um nó é escolhido, um caminho de menor custo deve ser encontrado.

2.2.2 Pesquisa em profundidade

A pesquisa em profundidade remove a limitação de espaço da pesquisa de custo uniforme pela dinâmica de gerar um filho do nó não expandido mais profundo em seguida. No geral, ela é implementada recursivamente, com a pilha de recursão levando o lugar de uma pilha de nós explícita.

Sua vantagem é seu requisito de espaço ser apenas linear, em oposição ao exponencial para a pesquisa em amplitude. A razão é que o algoritmo precisa apenas armazenar uma pilha de nós no caminho da raiz ao nó atual. Assim, como uma questão prática, ela é limitada no tempo em vez de no espaço.

Já sua principal desvantagem é não poder terminar em uma árvore infinita, mas simplesmente ir pelo caminho mais à esquerda. A solução para esse problema é impor uma profundidade de corte na pesquisa. Embora o corte ideal seja a profundidade da solução, esse valor raramente é conhecido antes de realmente resolver o problema (POHL, 1971).

2.2.3 Pesquisa bidirecional

A pesquisa bidirecional é um algoritmo de força bruta que requer um estado objetivo explícito em vez de simplesmente um teste para uma condição de objetivo (POHL, 1971). A ideia principal é pesquisar simultaneamente para a frente a partir do estado inicial e para trás a partir do estado objetivo, até que as duas fronteiras de busca se

encontrem. O caminho inicial do estado é então concatenado com o caminho inverso do estado objetivo para formar o caminho da solução.

A pesquisa bidirecional ainda garante soluções ideais, ao assumir que as comparações para identificar um estado comum entre as duas fronteiras podem ser feitas em tempo constante por nó.

2.2.4 Pesquisa de Fronteira

As melhores pesquisas iniciais, como pesquisa abrangente, custo uniforme e bidirecional, armazenam uma lista de nós expandidos e uma lista aberta de nós que foram gerados, mas ainda não foram expandidos. Outra abordagem para a limitação de memória desses algoritmos, chamada de pesquisa de fronteira, é armazenar apenas a lista aberta e excluir os nós, uma vez que eles são expandidos (KORF; ZHANG, 2005). Para evitar regenerar o “pai” de um nó, ela armazena cada nó em um bit para cada operador que geraria um nó expandido, o que reduz a complexidade do espaço de uma pesquisa abrangente, como do tamanho do espaço do problema para a largura do espaço do problema, ou o número máximo de nós em qualquer profundidade. Por exemplo, o tamanho de um gráfico de alça bidimensional é quadrático no raio, enquanto sua largura é apenas linear; alternativamente, os pais imediatos desses nós podem ser armazenados em uma lista aberta.

Sua principal desvantagem é que, uma vez que a pesquisa é concluída, o caminho da solução não ficará mais disponível, pois os nós expandidos foram excluídos. Uma maneira de reconstruir o caminho da solução é realizar uma pesquisa de fronteira bidirecional, tanto do estado inicial quanto do objetivo. Quando as duas fronteiras de pesquisa se encontram, temos um nó do meio aproximadamente; então, podemos dividir e conquistar a pesquisa de fronteira para gerar recursivamente um caminho do estado inicial para o estado intermediário, e do estado intermediário para o estado objetivo. Ela também pode ser usada para reduzir a memória das melhores pesquisas heurísticas.

3. Algoritmos de Busca

De acordo com ProfessionalAI (2020), a IA é o estudo de agentes racionais e, em sua essência, busca solucionar problemas de enorme complexidade combinatória, com o auxílio de agentes. Como pode haver mais de uma solução para um problema, esses agentes buscam espaço para todas as combinações e usam abordagens para encontrar o caminho mais curto ou adequado para atingir o objetivo final. Portanto, a pesquisa, juntamente com os agentes, desempenha um papel fundamental na IA. Desde fornecer um *backbone* conceitual a várias estratégias de busca e algoritmos para realizar a exploração sistemática de alternativas, a pesquisa garante que a máquina/ sistema de IA funcione com precisão.

Porém, o conceito da pesquisa em IA não se limita a isso. É composto por vários algoritmos de busca, que são utilizados no processo de resolução de problemas e de busca de solução, uma vez que os agentes percebem o mundo e fazem suposições.

Os algoritmos de busca, seja em IA ou em geral, são um processo passo a passo de resolução de um problema de busca, em um determinado espaço. Eles fazem isso passando por vários fatores do problema de pesquisa, que são:

1. **Espaço de busca:** representa todos os conjuntos possíveis de soluções que um sistema pode ter.
2. **Estado inicial:** é a partir desse estado que os agentes iniciam o processo de pesquisa.
3. **Teste de meta:** é o estado final do problema de pesquisa; ele observa o estado atual do espaço do problema e verifica se o estado de meta foi alcançado ou não.

Quando esses fatores são completados, a solução para os problemas de busca é fornecida em uma sequência de ações, conhecida como um plano, que transforma o estado inicial em estado objetivo. É aqui que começa o papel dos algoritmos de busca, os quais ajudam a atingir o plano.

3.1 O que são algoritmos de busca?

Ao longo do texto, mencionamos a importância da pesquisa em IA e como ela ajuda os agentes a realizar suas tarefas básicas e atingir o objetivo final. Porém, é importante compreender que sem algoritmos de busca, as máquinas de IA, sejam elas um assistente virtual ou um carro autônomo, não podem realizar a busca e encontrar a solução ou a rota mais adequada. Esses algoritmos são usados para avaliar o espaço do problema e várias sequências de ações.

Em IA, a importância dos algoritmos de busca é imensa, pois eles funcionam em segundo plano e ajudam os agentes a atingirem o objetivo final após avaliarem vários cenários e alternativas. Porém, o que os torna eficientes para esse processo? Existem quatro propriedades essenciais que garantem sua eficiência:

1. **Completo:** um algoritmo de pesquisa é denominado completo porque garante o retorno da solução, mesmo nos casos em que haja pelo menos qualquer solução existente para qualquer entrada aleatória.
2. **Ótimo:** ajuda a entregar soluções ótimas, pois fornece a melhor solução entre todas as alternativas disponíveis.
3. **Complexidade de tempo:** é a medida do tempo que leva para completar uma tarefa por um algoritmo de busca, bem como o número máximo de nós criados.
4. **Complexidade do espaço:** indica o espaço máximo de armazenamento necessário durante a pesquisa, dependendo da complexidade do problema.

3.2 Tipos de algoritmos de pesquisa em IA

Em IA, há muitos tipos de algoritmos de busca, os quais são divididos em duas categorias, que variam excessivamente entre si. Enquanto

alguns são implementados usando uma fila de prioridade ou nota raiz, outros possuem uma lista fechada ou uma lista aberta de nós (PROFESSIONALAI, 2020).

Esses diferentes tipos de algoritmos de pesquisa são:

a. Uninformed Search

A *Uninformed Search*, também conhecida como Pesquisa Cega ou Pesquisa de Força Bruta, não possui nenhuma informação adicional ou conhecimento de domínio que possa ajudá-la a atingir o objetivo, além do fornecido na definição do problema. Esse tipo de algoritmo está focado apenas em atingir a meta e obter sucesso e pode ser aplicado a uma variedade de algoritmos de busca, já que não se preocupam com o problema-alvo. Esse método é dividido nos seguintes tipos:

- *Breadth-First Search.*
- *Uniform Cost Search.*
- *Depth First Search.*
- *Iterative Deepening Search.*
- *Bidirectional Search.*

b. Informed Search

Também conhecido como Busca Heurística, esse tipo de algoritmo usa o conhecimento do domínio e segue uma função heurística que estima o custo do caminho ótimo entre dois estados, bem como a proximidade de um estado do objetivo. Esse método é dividido em três tipos:

- *Greedy Search.*
- *A* Tree Search.*
- *A* Graph Search.*

As técnicas de resolução de problemas de IA fornecem uma gama de ferramentas que podem ser combinadas em qualquer número de elementos para construir programas a fim de resolver problemas que não se prestam a soluções algorítmicas. A maioria dos problemas do mundo real se enquadram nessa categoria. A parte mais difícil de aplicar essas técnicas é escolher qual usar para resolver um problema específico.

Inicialmente, uma representação do problema – espaço de estados ou redução do problema – deve ser escolhida para torná-los explícitos, e diversos fatores podem influenciar nessa escolha. Para pequenos problemas, é suficiente usar um conhecimento simples de representação (não necessariamente com base simbólica) com uma estratégia de controle guiada heurísticamente que irá eficientemente procurar o gráfico do problema. Quanto maior e mais complexo for o problema, será necessária uma sofisticada representação do conhecimento.

A maioria das estratégias de resolução de problemas de IA evoluiu por ser projetada para resolver problemas específicos que têm surgido em domínios específicos. Como resultado, seria altamente improvável que um tipo de representação do conhecimento e uma estratégia de controle fossem adequados a qualquer outro grande problema do mundo real. É mais apropriado procurar semelhanças entre solucionadores de problemas bem estabelecidos e o problema a ser resolvido e, em seguida, adaptar as técnicas de acordo com as demandas e as necessidades.

Muitas combinações de estratégias podem se adequar a um problema a ser resolvido. No entanto, para o objetivo dos pesquisadores de IA, é necessário buscar aquela combinação que irá produzir a solução mais eficiente em termos de tempo e recursos computacionais.



Referências

DIJKSTRA, E. W. A note on two problems in connexion with graphs. **Numerische Mathematik**, [s.l.], v. 1, 269-271, 1959.

GRAHAM, N. **Artificial Intelligence. Making Machines Think**. EUA: Tab Books Inc., 1979.

KORF, R. E, W.; ZHANG, I. T. Frontier search. **Journal of the Association for Computing Machinery**, [s.l.], v. 52, n. 5, p. 715-748, 2005.

NEWELL, A.; SIMON, H. A. **Human Problem Solving**. Englewood Cliffs, NJ: Prentice-Hall, 1972.

POHL, I. **Bi-directional search, in Machine Intelligence 6**. New York: American Elsevier, 1971. p. 127-140.

POOLE, A. D. **Mackworth and R. Goebel, Randy, Computational Intelligence: A logical Approach**. New York: Oxford University Press, 1998.

PROFESSIONALAI. **Search Algorithms**. 2020. Disponível em: <https://www.professional-ai.com/search-algorithms.html>. Acesso em: 26 dez. 2020.

RATNER, D.; WARMUTH M. **Finding a shortest solution for the NxN extension of the 15-puzzle is intractable**. 1986. p. 168-172. Disponível em: <https://www.aaai.org/Papers/AAAI/1986/AAAI86-027.pdf>. Acesso em: 10 mar. 2021.

RUSSELL, S.; NORVING, P. **Artificial Intelligence: A Modern Approach**. 2. ed. New Jersey: Prentice Hall, 2003.

WINSTON P. H. **Artificial Intelligence**. 2. ed. EUA: Addison-Wesley Publishing Company, 1984.

Ambiente Favorável a aplicação de tecnologias de Analytics e IA

Autoria: Marcelo Tavares de Lima

Leitura crítica: Lucas dos Santos Araujo Claudino



Objetivos

- Apresentar conceitos básicos e fundamentais da Inteligência Artificial.
- Apresentar conceitos básicos e fundamentais de *Analytics*.
- Descrever ambientes favoráveis para aplicação de tecnologias de *Analytics* e Inteligência Artificial.



1. Introdução

Seja bem-vindo ao mundo do *analytics* e da inteligência artificial (IA). Vamos ingressar em um terreno do conhecimento vasto e com muita coisa a ser explorada. Serão abordadas nomenclaturas relativamente novas, mas que possuem como embasamento conceitos consolidados e importantes.

Este texto apresentará conceitos fundamentais de *analytics* e de Inteligência Artificial para, em seguida, descrever ambientes favoráveis para a implementação dessas tecnologias de forma proveitosa e otimizada. Fique atento ao que virá! Bons estudos!



2. Inteligência Artificial

Antes de apresentar do que trata a Inteligência Artificial e os conceitos associados, vale a pena introduzir conceitos relacionados a uma característica muito desejada por todos os seres humanos, a inteligência. Esta, segundo Oliveira (2018, p. 9) é “um dos conceitos mais fascinantes para a ciência”.

Desde o início da história da humanidade, busca-se compreender o que caracteriza um ser inteligente, entender o que é inteligência e quais as maneiras como pode se manifestar nos seres humanos e nos animais. Esses questionamentos se expandiram para as máquinas quando os sistemas computacionais começaram a ser desenvolvidos e a evoluir significativamente.

Nós, seres humanos, somos pertencentes à classe de seres *Homo sapiens*, ou seja, somos parte do gênero humano (*Homo*) e da espécie que é considerada sábia (*sapiens*). Tal classificação foi atribuída porque somos a única espécie do planeta Terra capaz de raciocinar logicamente e apresentar conhecimento com base em processos de aprendizado,

permitindo, assim, que nós, seres humanos, tenhamos a capacidade de tomar decisões. No entanto, a característica de inteligência não é exclusividade da espécie humana.

Questionamentos sobre a possibilidade de uma máquina criada pelo homem poder apresentar a característica de inteligência humana passaram a fazer parte da rotina de pesquisadores da área de inteligência, mesmo sabendo, é claro, que a inteligência imputada em uma máquina não seria nata, mas, só pelo fato de existir a possibilidade de implementação, iniciou-se uma corrida nas pesquisas associadas.

Para dar um pontapé inicial sobre essa imensidão que é a IA, vale a pena definir conceitos básicos associados, como inteligência, definir como um sistema pode ser classificado como inteligente, levantar características, possibilidades e limitações de um sistema computacional considerado inteligente, de acordo com Oliveira (2018).

Do ponto de vista da inteligência, pode acontecer de, num contexto do senso comum, parecer que somente o ser humano é detentor desta característica. No entanto, isso não é verdade. Por exemplo, os animais mamíferos, também são capazes de apresentar inteligência de alguma forma. É claro que, se considerarmos em medidas de quantificação, o homem é o único capaz de atingir altos níveis de inteligência, segundo Santos e Arruda (2019).

O conceito de inteligência pode parecer nebuloso e extremamente polêmico, embora possamos argumentar que há uma possibilidade de afirmar que um comportamento inteligente diz respeito a aprender lidar com o mundo por meio de estratégias direcionadas para a busca de soluções a determinados problemas (SANVITTO, 1995 *apud* SANTOS e ARRUDA, 2019, p. 727).

Com os avanços tecnológicos crescendo de forma exponencial, em particular na área computacional, algumas correntes da ciência chegam a afirmar que uma máquina pode pensar e, portanto, possui comportamento

inteligente. É claro que esse é um assunto longe de ser consensual entre os estudiosos do ramo, mas, pode ser considerado uma provocação para o debate sobre ele, segundo Santos e Arruda (2019).

Sanvitto (1995 *apud* Santos e Arruda, 2019) chegou a utilizar o termo *Homo sapiens* versus *Machine sapiens* como forma de representar a dicotomia do homem versus a máquina, em relação à apresentação do atributo ou característica de inteligência. De certo, o autor teve um contexto próprio para introduzir o assunto dessa maneira, o que, ao longo dos anos, deixou de ser um confronto e passou a ser muito mais uma parceria ou complementação do homem pela máquina e vice-versa.

O termo inteligência artificial surgiu por volta da década de 1950. No seu surgimento, tinha-se como intenção o desenvolvimento de sistemas que fossem capazes de realizar tarefas que ainda seriam mais bem realizadas pelos seres humanos, segundo Machado (2017).

Oficialmente, a IA surgiu em 1956, em uma conferência realizada no Dartmouth College, nos Estados Unidos. Alguns participantes desse evento submeteram à Fundação Rockfeller uma proposta de pesquisa a ser desenvolvida em um período de dois meses, que seria composta por dez homens e associada ao termo inteligência artificial, segundo Machado (2017).

De acordo com Machado (2017, p. 17), define-se inteligência artificial como “área de pesquisa da ciência da computação que busca métodos ou dispositivos computacionais que simulam a capacidade humana de resolver problemas”. Desde o seu surgimento, pesquisadores tentam implementar, de forma computacional, sistemas que possam agir racionalmente, semelhante aos seres humanos.

Desde seu surgimento, a IA gera discussões polêmicas, começando pelo seu próprio nome, considerado um tanto presunçoso por muitos contemporâneos de sua criação, segundo Machado (2017). A justificativa

dada por essa sensação ou sentimento em relação ao termo, ou definição, tem base no desconhecimento dos conceitos associados à inteligência e, por outro lado, relação com a capacidade prática do processamento dos computadores, que, ainda complementam, terem ocorrido promessas exageradas com o surgimento da IA.

A linha de tempo do desenvolvimento da IA é um tanto ampla, mas, considerando os principais momentos de seu desenvolvimento, podemos citar os anos 1990, onde as pesquisas relacionadas ao tema extrapolaram os muros das universidades e passaram a ser também exploradas por empresas de tecnologia. Trata-se de um marco na história da IA, pois, a partir de então, seu desenvolvimento deu um grande salto em quantidade de produção de tecnologias.

A definição de inteligência artificial apresentada por Lima, Pinheiro e Santos (2014, *apud* Oliveira, 2018, p. 10) afirma que “I.A. é o conjunto de ações que, se fossem realizadas por um ser humano, seriam consideradas inteligentes”. De certa maneira, remete à dicotomia levantada por Sanvitto (1995 *apud* Santos e Arruda, 2019), pois cria um comparativo das ações de uma máquina com as ações dos seres humanos para, então, definir se o comportamento ou ação realizada é ou não inteligente.

Uma definição mais abrangente, apresentada por Russell e Norvig (2013 *apud* Oliveira, 2018, p. 11) declara que:

Inteligência artificial é a capacidade de sistemas cibernéticos (formados por computadores, softwares, sensores e atuadores) de imitar funções cognitivas dos seres humanos, funções estas que podemos resumir na resolução de problemas por meio de aprendizado apoiado na percepção. (RUSSELL; NORVIG, (2013 *apud* OLIVEIRA, 2018, p. 11)

Oliveira (2018), a partir da definição de Russell e Norvig (2013), apresentada para IA, detalha um pouco melhor os três termos

chaves apresentados na definição descrita: resolução de problemas, aprendizado e percepção.

A resolução de problemas é compreendida como “a capacidade de realizar tarefas julgadas corretas por algum critério de avaliação”, segundo Oliveira (2018, p. 11). De forma prática, pensando em um problema a ser resolvido por uma máquina, com uso de algoritmos e regras, trata-se da obtenção do resultado esperado para solucionar um problema. Essa característica não representa de fato um sistema inteligente, pois, como dito, as soluções são obtidas por procedimentos implementados ou por execução mecânica, fazendo, assim, a resolução de problemas como uma característica essencial, mas, não suficiente para identificar sistemas inteligentes.

Em IA, o aprendizado “é a característica dos algoritmos que têm a capacidade de melhorar seu desempenho por meio da experiência” (RUSSELL; NORVIG, 2013 *apud* OLIVEIRA, 2018, p. 12). Trata-se da reparametrização dos algoritmos a cada iteração realizado pela máquina, situação conhecida como aprendizado de máquina.

A percepção, no contexto humano, tem relação com dois tipos de fenômenos: físico e mental. Percepção física tem relação direta com a capacidade da coleta de informações/dados sobre o ambiente em nossa volta, segundo Oliveira (2018). A coleta é realizada com o uso dos sentidos de percepção humana: olfato, paladar, visão, audição e tato. O âmbito mental, ou fenômeno mental, está relacionado à capacidade de deduzir as situações que ocorrem ao nosso redor e extrair informações das mesmas para uma tomada de decisão apropriada.

Em relação aos sistemas cibernéticos, a capacidade de percepção está baseada nos sensores implementados e instalados para coletar dados e informações, que são diversos e podem fazer desde a simples leitura de dados até a coleta de informações por meio dos sensores físicos, como, por exemplo, medidores de velocidade e aceleração, termômetros etc.

Inúmeros jogos computacionais e outros dispositivos têm sido criados com base em inteligência artificial, como, por exemplo, o jogo *República: a revolução*, lançado em 2003 e usado como exemplo por Coppin (2013). O autor afirma que a construção deste jogo conteve um milhão de inteligências artificiais individuais, sendo que, cada uma delas era capaz de interagir com o mundo e com o jogador e ser manipulada por este.

Com a evolução tecnológica cada vez mais veloz e atuante, é possível que a inteligência artificial se torne predominante na sociedade de forma cada vez mais intensa. Mesmo que sejam criados dispositivos tecnológicos realmente inteligentes, cada vez mais, do ponto de vista de tendência, serão encontrados computadores, máquinas e outros dispositivos mais, mesmo que aparentemente, inteligentes, segundo Coppin (2013).

3. Conceitos fundamentais de *analytics*

O termo *analytics* é muito amplo e engloba processos e tecnologias. Na literatura, *analytics*, também é conhecido como *Business Intelligence*, *Big Data*, *Business Analytics* e outros termos, de acordo com Ruggiero (2017).

O *analytics* é o processo de extração e criação de informações a partir de dados brutos por filtragem, processamento, categorização, condensação e contextualização dos dados, segundo Bahga e Madiseti (2019).

Analytics é o tratamento aplicado no dado com intenção de transformá-lo em informação útil para ser aproveitada nos processos de tomada de decisão e para divulgação de resultados.

Segundo Ruggiero (2017), o termo *Business Intelligence* (BI) surgiu na literatura no ano de 1958, por meio de Hans Peter Luhn, pesquisador da área de ciência da computação. Nesse momento, BI era considerado um sistema automático para definição de ações reais aos seus usuários. No entanto, em 1986, passou a ser considerado um processo, onde sua

entrada se daria com dados brutos e sua saída, a inteligência para a tomada de decisão.

Na prática, de acordo com muitos estudiosos do assunto, o conceito de BI está relacionado a um processo onde há utilização de “informações operacionais e ferramentas analíticas para melhorar os processos de tomada de decisão das empresas” (NEGASH, 2004 *apud* RUGGIERO, 2017).

Quando considerado um processo, BI é composto por métodos apropriados para o tratamento de dados, a fim de transformá-los em informações para serem utilizadas pelas empresas para que se tornem competitivas. O produto deste tratamento será o resultado que permitirá a possibilidade da tomada de decisão realizada por meio das informações disponíveis para a execução de predição de comportamentos dos concorrentes, clientes, fornecedores etc.

Ao longo do desenvolvimento do BI, surgiu, no meio acadêmico, o termo inteligência analítica (IA), como um substituto. Continuamente, também surgiu o termo *Big data*, como um sinônimo para BI e IA. No entanto, este último, ao longo do desenvolvimento de trabalhos e pesquisas associados, passou a ter conceito próprio, como, segundo Ruggiero (2017, p. 28), sendo “o fenômeno do aumento da oferta e demanda de dados e de ferramentas para manejá-los, o que parece bastante relacionado com IA”.

No período de seu desenvolvimento, o conceito de inteligência analítica, associado ao conceito de *Big data*, teve um termo acrescido à sua denominação. Trata-se do termo *analytics*, tornando assim, o termo conhecido como *Big data analytics*, que passou a significar “conjuntos de dados e técnicas analíticas para aplicações muito grandes e complexas, que requerem soluções, avançadas de armazenagem, gerenciamento, análise e ferramentas de visualização”, segundo Ruggiero (2017, p. 28).

É comum que os estudiosos do assunto se refiram apenas ao termo *analytics* quando estiverem se referindo ao *Business Intelligence and*

Analytics. O termo *analytics*, segundo Ruggiero (2017, p. 29) “é um termo genérico que significa aplicar várias técnicas analíticas em dados para responder ou resolver problemas, algo que facilita a realização de objetivos de negócio”.

Por fim, *Analytics* concentra-se em conhecimento e inteligência, reunindo ferramentas de visualização, exploração, explanação e predição, de acordo com Ruggiero (2017). Sendo assim, *Analytics* reúne técnicas de estatística, econometria, *Machine learning*, otimização e simulação. Então, falar de *Analytics*, é falar de técnicas já conhecidas, mas, com o enfoque em negócios e na tomada de decisão gerencial, dando a ideia de que *Business Intelligence* e *Analytics* trata-se de ciência de dados no contexto de negócios.

Com uso de técnicas diversas dentro do contexto de *Analytics*, as informações obtidas são organizadas e estruturadas para inferir conhecimento sobre sistemas e/ou seus usuários, seus ambientes e suas operações, assim como a evolução dos seus objetivos, tornando os sistemas envolvidos mais inteligentes e mais eficientes.

Ruggiero (2017) em sua pesquisa, afirma que a inteligência analítica, desde 2002, passou a ser usada em *e-commerce*, vendas, *marketing*, *suplly chain*, detecção de fraudes e gestão de performance corporativa. Além disso, o autor, também identificou aplicações de IA em áreas como otimização de relacionamento com clientes, monitoramento de atividades de negócio e suporte à decisão.


Mesmo não sendo a ferramenta principal, ou o principal conceito no desenvolvimento de uma atividade, a IA também pode ser suporte para a geração de relatórios gerenciais, para um aumento de conhecimento em práticas de marketing, dentre outras situações.

A escolha de técnicas de *Analytics* dependerá diretamente dos objetivos de aplicação. Por exemplo, prever algo como se uma transação bancária é ou não uma fraude, se choverá ou não em um dia específico, ou se um

tumor é ou não maligno. Pode-se também utilizar técnicas de *Analytics* para obtenção de padrões nos dados, como, observar os dias mais frios do ano, identificar assuntos mais visitados em uma página de Internet ou, ainda, identificar assuntos mais pesquisados em um determinado período do ano. Outras possibilidades são ligadas à busca de relações nos dados, como, por exemplo, comportamento de consumo de alimentos em relação ao período do ano etc.

A Figura 1 apresenta a relação entre *Analytics* e algumas ferramentas quantitativas e computacionais mais utilizadas para a tomada de decisão. É claro que não se trata de uma receita de bolo, podendo uma metodologia ser usada em contexto distinto ao que está sendo mostrado, tratando-se apenas de uma proposta de metodologia quantitativa e computacional para cada situação dentro do *Analytics*.

Figura 1 – Relação entre *Analytics* e métodos quantitativos e computacionais



Fonte: elaborado pelo autor.

O *Analytics* descritivo compreende a análise de dados existentes, oriundos de tempos passados e analisados no presente de forma resumida para serem facilmente interpretados. O *Analytics* descritivo ajuda a responder a seguinte pergunta: o que aconteceu? Grande parte do *Analytics* realizado é descritivo com o uso de funções estatísticas, como contagem, soma, mínimo, máximo, médias, porcentagens etc. Essas estatísticas ajudam a descrever padrões nos dados. Por exemplo, a contagem do número de *likes* de uma particular postagem em uma rede social; média de acessos a uma determinada página da Internet etc.

O *Analytics* diagnóstico compreende a análise de dados passados para diagnosticar as razões da ocorrência de determinados eventos. Ajuda a responder perguntas como: por quê aconteceu? Por exemplo, um sistema que coleta e analisa sensores de equipamentos que monitoram um sinal vital humano. Enquanto o descritivo pode ser útil no resumo dos dados por meio do cálculo de diversas estatísticas, o diagnóstico pode fornecer informações que permitam saber por que ocorreu alguma falha no sistema.

O *Analytics* preditivo corresponde à previsão da ocorrência de um evento ou a chance de sua ocorrência, assim como a previsão de valores futuros com uso de modelos preditivos. O *Analytics* preditivo ajuda a responder perguntas como: qual a chance de acontecer? Por exemplo, pode-se desejar prever quando uma máquina falhará em prever se um tumor é maligno ou benigno. O *Analytics* preditivo é realizado com o uso de modelos preditivos que utilizam dados existentes. Esses modelos identificam padrões e tendências a partir dos dados e fazem a previsão da ocorrência de um ou mais eventos. A acurácia dos modelos de previsão depende da qualidade e do volume de dados existentes disponíveis para o seu treinamento. Antes de ser utilizado para previsão, o modelo deve ser validado com dados existentes. Um procedimento padrão utilizado para o desenvolvimento de modelos de previsão divide os dados existentes em duas partes, uma para treinamento e, outra para

teste ou validação. Em geral, utiliza-se 75% dos dados para treinamento e, 25% para teste ou validação, segundo Bahga e Madisetti (2019).

Enquanto o *Analytics* preditivo utiliza modelos de previsão para prever prováveis resultados de um evento, o *Analytics* prescritivo utiliza modelos de predição múltipla para prever diversos resultados e o melhor curso de ação para cada resultado, segundo Bahga e Madisetti (2019). O *Analytics* prescritivo ajuda a responder perguntas como: o que podemos fazer para que isso aconteça? O *Analytics* prescritivo pode prever os possíveis resultados com base na atual escolha de ações e pode ser considerado como um tipo de *Analytics* que utiliza diferentes modelo de previsão para diferentes entradas (*inputs*). Prescreve ações ou as melhores opções a serem seguidas dentre as possíveis. Por exemplo, pode-se utilizar uma técnica de *Analytics* prescritivo para prescrever o melhor tratamento médico para um paciente com base nos resultados de outros pacientes. Outro exemplo: seria possível sugerir o melhor plano de dados para celular com base nos padrões de navegação do cliente.

Os possíveis ambientes de aplicação de técnicas de *Analytics* são diversos, como dito antes, assim como a seleção das técnicas apropriadas para cada um deles. Pode-se utilizar todas as técnicas existentes ou pode-se recorrer a apenas uma delas. A quantidade a ser implementada estará diretamente relacionada com a complexidade dos problemas ou ambientes em que serão implementadas.

Em cadeias de suprimentos, por exemplo, pode-se utilizar *Analytics* para otimizar fluxos e diminuir os estoques, enquanto que, no relacionamento com o cliente, pode-se utilizar para a identificação de oportunidades de negócios e potenciais relações empresariais. Ruggiero (2017, p. 31) exemplifica ainda a possibilidade de utilizar no “uso inteligente do capital humano interno; no ganho de qualidade a partir de processos internos; de performance financeira; e para pesquisa e desenvolvimento”.

Muitas empresas utilizam o *Analytics* em suas diversas áreas e, a depender destas, faz-se uso de um conjunto de técnicas apropriadas dentre as apresentadas na Figura 1. O ideal é que toda a empresa faça uso de inteligência analítica em seus diversos setores. No entanto, esta não é a realidade encontrada.

O *Analytics* ou Inteligência Analítica, pode também ser utilizado em análise de mídias sociais com a intenção de extração de opinião de usuários de redes sociais, de consumidores de determinado produto, clientes de um serviço de televisão, dentre outros. Muitas empresas prestam esse tipo de serviço, e estas têm se consolidado neste mercado cada vez mais.

É certo que o uso de IA extrapola o campo do mundo corporativo, muitos setores do serviço público fazem uso de técnicas de *Analytics* para manter, por exemplo, a transparência e a participação pública em suas atividades. Muitos centros de pesquisas acadêmicas também fazem uso de IA para o desenvolvimento de suas pesquisas em diversas áreas.

Ruggiero (2017) apresenta vantagens no uso de IA:

Na área de ciência e tecnologia, com amplo ganho de informações através de sensores e instrumentos (exemplo oceanografia, astrofísica, etc.); na saúde, com ganho nas frentes de genoma e no bom uso dos dados gerados pelos pacientes; e na segurança pública, com o uso de dados de múltiplas fontes e o uso de sistemas de inteligência. (RUGGIERO, 2017, p. 32)

Com a produção maciça de dados por meio do uso intensivo da Internet, diversas empresas como Google, Amazon, Microsoft, entre outras, têm aumentado o uso de IA e capacitado seus colaboradores a lidar com técnicas que podem extrair informações importantes para seus negócios e orientações na produção de serviços e aplicativos, sendo a Google, Amazon e Facebook consideradas as pioneiras no uso de IA em suas atividades, segundo Ruggiero (2017).

No geral, o termo *Analytics* tem associação a alguma área ou contexto, como, por exemplo, *Business Analytics*, *Health Analytics*, *Safe Analytics* etc. O uso do termo associado a algum contexto ou área permite, segundo Ruggiero (2017), criar uma diferenciação do uso ou do propósito do uso das técnicas de IA, a fim de clarear para seus usuários quais as habilidades e tecnologias necessárias para a sua implementação.

Mesmo com o uso diferenciado e termos distintos, as várias áreas e empresas que utilizam conceitos e técnicas de IA têm em comum o uso de dados para extração de valor e informações que possam direcionar para a tomada de decisão dentro dos melhores cenários possíveis.

Ao voltar a falar em dados, é praticamente inevitável falar em *Big data*, pois a IA é que sustenta ou fornece embasamento para este conceito, o qual recorre, como já dito, ao uso de diversas técnicas quantitativas de estatística, raciocínio matemático e lógico, além de recursos computacionais.

Uma rápida consulta na internet sobre *Analytics* ou Inteligência Analítica permite que se tenha uma breve noção do quanto as empresas fazem uso de seus conceitos e técnicas. Está diretamente relacionado com a corrida para se atingir os melhores resultados dentro de suas áreas de atuação.

O uso de IA permite que as empresas obtenham uma série de benefícios, sendo muitos já descritos neste texto, mas vários outros podem ser elencados, como a possibilidade de permitir que as empresas desenvolvam projetos e campanhas de forma eficiente, permitindo que os esforços direcionados possam ser mensurados e ajustados, quando necessário.

Falar em *Analytics* ou Inteligência Artificial, como feito neste texto, é falar de um amplo mundo cheio de recursos tecnológicos e de termos que se associam e ao mesmo tempo se diferenciam em relação a área de atuação e, quanto ao uso das ferramentas metodológicas. Portanto, é um mundo que se abre diante de você, o qual não poderá de ser explorado.

Este texto apresentou, de forma breve e resumida, conceitos de inteligência artificial, conceitos de *Analytics* e, descreveu de forma breve os ambientes favoráveis à aplicação desses conceitos e suas tecnologias associadas. Não houve a pretensão de esgotar o assunto, mas houve a intenção de instigar o aluno a buscar e a conhecer mais do que aqui foi apresentado.

Referências Bibliográficas

BAHGA, Arshdeep; MADISETTI, Vijay. **Big data science & analytics: a hands-on approach**. Arshdeep Bahga & Vijay Madisetti, 2019. ISBN: 978-1-949978-00-1.

COPPIN, B. **Inteligência artificial**. Tradução e revisão técnica Jorge Duarte Pires Valério. Reimpr. Rio de Janeiro: LTC, 2013. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/978-85-216-2936-8/cfi/6/2!/4/2@0.00:0>. Acesso em: 23 jul 2020.

MACHADO, V. P. **Inteligência artificial**. Fortaleza. Notas de aula, 2017. Disponível em: http://www.uece.br/computacaoead/index.php/downloads/doc_download/2177-inteligencia-artificial. Acesso em: 23 jul 2020.

OLIVEIRA, R. F. **Inteligência artificial**. Londrina: Editora e Distribuidora Educacional S.A., 2018.

RUGGIERO, P.H.G. **Inteligência analítica: competências para atuação**. 2017. Dissertação (Mestrado em Administração de Empresas), Escola de Administração de Empresas de São Paulo, Fundação Getúlio Vargas, São Paulo, 2017. Disponível em: <https://bibliotecadigital.fgv.br/dspace/bitstream/handle/10438/18031/Pedro%20Ruggiero%20-%20Intelig%C3%Aancia%20Anal%C3%ADtica.pdf?sequence=1&isAllowed=y>. Acesso em: 23 jul 2020.

SANTOS, B.L.; ARRUDA, E.P. Dimensões da inteligência artificial no contexto da educação contemporânea. **Educação Unisinos**, [s. l.], v. 23, n. 4, p. 725-741, 2019. Disponível em: <http://search.ebscohost.com/login.aspx?direct=true&db=foh&AN=140968652&lang=pt-br&site=ehost-live>. Acesso em: 23 jul 2020.

SOARES, J. Uma breve viagem pela inteligência artificial. **Revista de Ciências da Computação**, [s. l.], v. 14, p. 1-34, 2019. Disponível em: <http://search.ebscohost.com/login.aspx?direct=true&db=foh&AN=141373309&lang=pt-br&site=ehost-live>. Acesso em: 23 jul 2020.

Introdução ao *machine learning*: como funciona a aprendizagem de máquina

Autor: Lucas Claudino



Objetivos

- Aprender como funciona a dinâmica do aprendizado de máquina: se o algoritmo escolhido necessita ou não de uma etapa de treinamento.
- Classificar corretamente o aprendizado de máquina para então saber qual algoritmo é mais adequado para cada situação a ser resolvida.
- Estudar as principais topologias de problemas que utilizam a aprendizagem de máquina como ferramenta de resolução.



1. Introdução

O termo *machine learning*, em português, significa aprendizado de máquina. O principal objetivo desse aprendizado é buscar a maneira de entender a estrutura dos dados de interesse para poder ajustá-los a modelos já conhecidos, para então facilitar a interpretação desses dados, fornecendo meios para analisar, inferir e prever informações a partir desses modelos. Mesmo sendo um campo da ciência da computação, o aprendizado de máquina possui características bastante diferentes da computação tradicional.

Machine learning, como o próprio nome já diz, é capaz de aprender com os dados fornecidos. Os algoritmos aplicados nessa área proporcionam aos computadores técnicas para que eles sejam capazes de treinar sua inteligência por meio de dados de entrada, para então criar modelos que conseguem tomar decisões inteligentes baseadas nos resultados obtidos por meio do treinamento.

Neste estudo, serão abordados os principais fatores do aprendizado de máquina para mostrar seu funcionamento básico, quais vantagens ele pode trazer e suas principais aplicações.



Para saber mais


Antes mesmo de se ter o conceito de *machine learning* formulado, Alan Turing, em 1950, publicou um artigo intitulado “Computing Machinery and Intelligence”. Nesse trabalho, Turing questionava, dentro de todas as limitações da época, se as máquinas podiam realmente pensar. Alan Turing propôs uma espécie de pensamento baseado na cópia de atividades humanas (TURING, 1950).

2. Entendendo a aplicação de *machine learning*

Segundo Sá (1995, p. 27): “[...] por meio da mesma ‘arte de conversação’ que abrange tão extensa e significativa parte da nossa existência cotidiana [...]”, o aprendizado de máquina (AM) é dito como sendo a capacidade que a máquina possui de melhorar seu desempenho na realização de algum processo por meio da experiência obtida com treinamentos (MITCHELL, 1997).

Para entender melhor como pode ser esse aprendizado e como ele pode ajudar na tomada de decisões, considere o caso de João, que é uma pessoa que gosta de músicas rápidas e com volume alto. Colocando essas informações em um gráfico, é possível identificar duas regiões: A é a região de músicas que João gosta e B é a região de músicas que ele não gosta, assim como mostra a Figura 1. Qualquer música nova reproduzida por João, se estiver dentro das regiões A ou B, poderá ser facilmente classificada de acordo com o gosto musical.


Figura 1 – Exemplo de músicas classificadas graficamente



Fonte: elaborada pelo autor.

O problema aparece quando João escutar uma música nova e ela não puder ser diretamente classificada em nenhuma das regiões. Um exemplo disso é o ponto **y** no gráfico da Figura 2. Para fazer a classificação correta da música **y**, é preciso traçar uma região ao redor do ponto, identificando que há mais músicas pertencentes a A do que a B perto do ponto **y**, assim como ilustra a Figura 2. Logo, pode-se afirmar que **y** é pertencente ao grupo A.

Figura 2 – Exemplo de músicas classificadas graficamente e uma música nova inserida no gráfico



Fonte: elaborada pelo autor.

Você observou que, para fazer essa classificação correta, primeiro houve um treinamento relacionando os grupos A e B. É dessa forma que os algoritmos de aprendizado de máquina funcionam. Mais especificamente, essa metodologia de classificação apresentada é como funciona o algoritmo KNN (*K nearest neighbors*), que identifica os K vizinhos mais próximos.

O exemplo das músicas de João fornece mais uma característica do funcionamento do aprendizado de máquina. O modelo a ser criado a partir do estudo da disposição gráfica das músicas tem o objetivo de

prever se uma nova música a ser escutada por João estará ou não de acordo com seu gosto musical. Sendo assim, você já sabe então a primeira classificação do AM quanto ao seu objetivo: ele pode ser **preditivo** ou **descritivo**. Sendo assim, estas e outras definições serão abordadas ao longo do texto.

2.1 Classificação do aprendizado de máquina

A partir do exemplo, você viu que o aprendizado de máquina pode ser classificado como preditivo ou descritivo. As tarefas de previsão usam os dados fornecidos durante a etapa de treinamento para criar funções capazes de prever um rótulo que caracterize o novo dado inserido (assim como o ato de prever a música no exemplo do João). Para que isso aconteça corretamente, cada dado fornecido durante o treinamento deve possuir rótulos de entrada e saída (FACELI; LORENA; GAMA, 2011). No exemplo, os rótulos de entrada eram o ritmo e o volume, e a saída era se João gostava ou não da música.

As tarefas de descrição, como o próprio nome já diz, tem como objetivo analisar um conjunto de dados e descrevê-lo de alguma maneira. Essa descrição pode ser, por exemplo, encontrar grupos de dados semelhantes, e então descrever os dados a partir desses grupos. Ou então, a tarefa descritiva pode ser também “encontrar regras de associação que relacionam um grupo de atributos a outro grupo de atributos” (FACELI; LORENA; GAMA, 2011, p. 6).


Além da classificação em preditivo e descritivo, pode-se também classificar o aprendizado de máquina como **supervisionado** e **não supervisionado**. O aprendizado supervisionado é aquele em que os dados utilizados para treinar o algoritmo contêm a resposta desejada. Ou seja, você fornece os dados já sabendo qual é o rótulo certo, então consegue treinar seu algoritmo para fornecer a resposta desejada. Isso é o que acontece no exemplo do João, em que você fornece todos

os dados sobre as músicas da etapa de treinamento e sabe se ela está de acordo ou não com o gosto musical dele. Dessa maneira, você supervisiona seu algoritmo durante o treinamento para que ele possa criar a função que será responsável por gerar a resposta desejada para qualquer dado novo que seja inserido.

Em diversos casos, não é possível obter dados já rotulados para fornecer à máquina, de maneira que ela possa criar funções relacionando entradas e saídas desejadas. Um exemplo clássico é um algoritmo criado para mostrar os perfis de compradores de uma determinada loja. Neste caso, o computador não tem uma classificação específica a fazer dos indivíduos, ele apenas vai separar os compradores de acordo com suas semelhanças. Uma opção é observar o histórico de compras e então verificar se existem padrões ou repetições que permitam a inferência do perfil dos clientes. Sendo assim, é possível identificar que o computador não será supervisionado, pois não há uma resposta esperada. O que acontece nos casos de aprendizado não supervisionado é que os resultados obtidos serão úteis para guiar a análise dos dados.

Para melhor entender a classificação do AM, observe a Figura 3.

Figura 3 – Classificação do aprendizado de máquina



Fonte: elaborada pelo autor.


A partir da Figura 3, é possível observar que o AM supervisionado pode ser também subdividido. O AM de classificação irá classificar todo dado novo recebido, sendo que os critérios de classificação são fornecidos durante a etapa de treinamento. O trabalho da máquina é, a partir do treinamento, elaborar a maneira mais eficaz de fazer a classificação correta. Já o AM de regressão vai utilizar os dados do treinamento para gerar uma função responsável por ditar como uma variável se comporta, ao passo que outra variável é modificada.

O AM não supervisionado, assim como visto na Figura 3, pode ser ainda subdividido em agrupamento, associação e sumarização, sendo que essas três classificações significam:

As tarefas descritivas são genericamente divididas em: agrupamento, em que os dados são agrupados de acordo com sua similaridade; sumarização, cujo objetivo é encontrar uma descrição simples e compacta para um conjunto de dados; e associação, que consiste em encontrar padrões frequentes de associações entre os atributos de um conjunto de dados. (FACELI; LORENA; GAMA, 2011, p. 6)

Para melhor entender essa divisão, observe a Figura 4.

Figura 4 – Síntese da divisão do AM de descrição



Fonte: elaborada pelo autor.

Uma terceira abordagem para o aprendizado de máquina também pode ser estudada: a aprendizagem por **reforço**. Essa metodologia se baseia no princípio de que nenhum problema a ser resolvido é estático, pois

ele pode mudar ao longo do caminho. Nessa técnica, a máquina escolhe, dentro de um leque de possibilidades a ela fornecido, um caminho a tomar para a solução do problema proposto, e ao final observa qual foi o resultado obtido. Cada vez que o resultado não é satisfatório, a máquina busca modificar a estratégia de solução do problema.

Essa metodologia é baseada em estudos da psicologia, que utiliza uma estratégia de dar alguma forma de recompensa ou punição a alguém como consequência de seus atos. Um exemplo clássico disso é o adestramento de cães, em que o adestrador pede para o animal se sentar e, caso ele realmente sente, oferece uma recompensa (geralmente um biscoito).

Observe que essa metodologia não é tão simples quanto parece. Um grande desafio é fazer com que o algoritmo não pare em uma “zona de conforto”, onde ele sempre receberá uma recompensa, pois nesses casos não haverá uma exploração de estratégias mais eficientes para a resolução do problema. Isso é conhecido como o compromisso entre *exploration* e *exploitation*. *Exploration* refere-se à exploração, que é o estado de buscar estratégias mais eficientes; já *exploitation* refere-se ao estado de percorrer o caminho no qual se tem certeza do sucesso.

Essa estratégia é muito utilizada em algoritmos aplicados a instituições financeiras e/ou investidores, pois é um cenário no qual se pode optar por um investimento mais arriscado e com chances de gerar um lucro muito maior do que investimentos seguros com rentabilidade menor.



Assimile

O aprendizado de máquina é muito amplo e com inúmeras aplicações, mas pode ser basicamente subdividido em três grandes categorias: aprendizado **supervisionado**, **não supervisionado** e de **reforço**.

2.2 Aplicações da aprendizagem de máquina

O aprendizado de máquina está intimamente ligado com diversas atividades de seu cotidiano, desde atividade simples, como uma pesquisa na internet, até tarefas complexas, como o reconhecimento da voz. Você, com certeza, já utilizou sites de pesquisa, como, por exemplo, o Google.com, para buscar algum assunto de seu interesse. Ao fazer esse tipo de pesquisa, você, com certeza, irá se deparar com um conceito chamado **ranqueamento de páginas**. Para fazer esse ranqueamento, a máquina recebe um dado de entrada, a palavra a ser pesquisada, e encontra as páginas mais relevantes ao assunto. A Figura 5 ilustra o ranqueamento que acontece ao digitar “aprendizado de máquina”.

Figura 5 – Ranqueamento para “aprendizado de máquina”



Fonte: https://scholar.google.com.br/scholar?hl=pt-BR&as_sdt=0%2C5&q=aprendizado+de+m%C3%A1quina&btnG=. Acesso em: 22 jul. 2019.

Para fazer o ranqueamento ilustrado na Figura 5, a máquina precisa, baseada no texto digitado, varrer o banco de dados, fazer uma seleção

dos websites disponíveis e, a partir da popularidade de cada um deles, classificar por ordem de relevância.

Outro cenário de aplicação é a filtragem colaborativa. Muitas lojas virtuais, como Amazon e Netflix, usam essa técnica para influenciar seus clientes a comprarem produtos adicionais, além daquele principal que era alvo de interesse. Você, com certeza, já pesquisou algum produto na internet e, ao final da página de compra, viu uma janela indicando algo como “Quem comprou este item também comprou...”, e depois disso havia uma lista com produtos que você também gostaria de comprar.

Ao tratar de filtragem colaborativa, o problema a ser resolvido pela máquina é similar ao caso do ranqueamento, pois o objetivo é conseguir uma lista de produtos. A diferença principal é que, no caso da filtragem colaborativa, não há uma entrada de dados específica, como a linha de pesquisa do exemplo anterior. Nesse caso, a máquina deve usar estatísticas de outros compradores e, baseado em compras similares, fazer uma lista de sugestão de possíveis produtos adicionais a serem comprados.

Existe também outra aplicação muito importante para o aprendizado de máquina, o reconhecimento facial aplicado à solução de crimes. O número de câmeras de vigilância tem aumentado muito e isso é um grande auxílio para a identificação de criminosos. Mas do que adianta a aquisição de muitas imagens sem a tecnologia certa para fazer o reconhecimento de padrões?

Algoritmos de *deep learning* e redes neurais são muito recomendados para o trabalho com reconhecimento facial. As redes neurais são feitas para simular o funcionamento do cérebro humano e, por isso, indicadas para a identificação de padrões em imagens. Esses algoritmos conseguem digitalizar a imagem e retirar partes que não ajudam no reconhecimento. Os elementos mais importantes para identificar a identidade de uma pessoa são os olhos, nariz, boca e cicatrizes. Por

meio da coleta de milhões de dados, podem-se identificar padrões repetidos em imagens diferentes, auxiliando na busca pela identidade. Um exemplo muito interessante de aplicação é o processo utilizado por diversos aplicativos de celular que deixam as pessoas com aparência mais velha; alguns desses aplicativos, como o FaceApp, utilizam redes neurais convolucionais para realizar essa tarefa.

Mas como isso pode ajudar na solução de crimes? A coleta de dados de crimes já resolvidos serve para treinamento dos algoritmos, facilitando a identificação de pessoas quando um novo fato ocorre. Devido à infinidade de câmeras coletando imagens de pessoas conhecidas e desconhecidas, as redes neurais podem ser muito bem treinadas, possuindo um enorme banco de dados para fazer o reconhecimento dos padrões (HURWITZ, 2018, p. 25).



3. Problemas clássicos no aprendizado de máquina

Claramente existem inúmeros problemas nos quais você pode aplicar o aprendizado de máquina, porém a grande maioria deles pode ser classificada de acordo com algumas topologias clássicas: classificação binária, classificação multiclasse, regressão, *clustering*, recomendação.

3.1 Classificação binária

Esse tipo de classificação é um dos problemas mais estudados em AM, e foi base teórica para o desenvolvimento de inúmeros algoritmos muito utilizados. Basicamente, pode-se reduzir o algoritmo a responder à seguinte questão: dado um padrão x contido em um domínio X , estime qual valor uma variável aleatória binária $y \in \{\pm 1\}$ irá assumir. Como exemplo, imagine um algoritmo que deseja falar se um novo e-mail chegou em sua caixa é *spam* ou não.


Mesmo sendo um problema aparentemente simples, observe como é possível criar situações mais complicadas:

- Pode haver uma sequência de pares (x_i, y_i) a serem instantaneamente estimados. Isso é conhecido como estimativa on-line.
- Você pode observar uma coleção $X := \{x_1, \dots, x_m\}$ e $Y := \{y_1, \dots, y_m\}$ de pares (x_i, y_i) que serão utilizados para estimar y para um conjunto não conhecido $X' := \{x'_1, \dots, x'_m\}$. Isso pode ser conhecido como aprendizado em lote.
- Você pode ser permitido a escolher o conjunto X para construir o modelo. Isso é conhecido como aprendizado ativo.
- Pode haver casos em que não há informação completa sobre X , levando a um problema de estimativa com variáveis desconhecidas.
- Os conjuntos X e X' podem vir de fontes diferentes, levando a um problema de correção de deslocamento por covariância.

3.2 Classificação multiclasse

Pode ser entendida como a extensão da classificação binária. A diferença é que aqui o valor da variável y não assume mais valores binários. Agora se deve considerar que $y \in \{1, \dots, n\}$ assume n valores diferentes. Imagine que o algoritmo queira classificar um documento de acordo com a língua na qual ele foi escrito. Portanto, y pode assumir $y \in \{\text{inglês}, \text{português}, \text{espanhol}, \text{chinês} \dots\}$. Para entender melhor a diferença entre classificação binária e multiclasse, observe a Figura 6.

Figura 6 – Classificações a) binária e b) multiclasse



Fonte: Smola e Nishwanathan (2008, p. 10).


A Figura 6 ilustra o objetivo das classificações binária e multiclasse. No item a, você observa que o algoritmo busca identificar as regiões de separação entre duas classes; já no item b, o propósito é classificar o grupo de dado de acordo com o conjunto de três itens distintos apresentados.

3.3 Regressão

A regressão é utilizada para criar uma metodologia capaz de prever algum tipo de rótulo do dado inserido. Algoritmos de regressão utilizam a etapa de treinamento para criar modelos que relacionam as características dos dados, tendo como resultado uma função matemática. A partir dessa função, você pode, então, inserir qualquer informação dos novos dados e prever o rótulo desejado.

Para entender melhor a regressão, observe a Figura 7, que mostra a relação entre peso, potência e consumo de automóveis. Os pontos representam os dados utilizados para treinamento e, a partir da análise dessas informações, o algoritmo criou uma função tridimensional capaz de estimar qual será o consumo de veículos automotivos.

Figura 7 – Regressão a partir de dados de entrada



Fonte: elaborada pelo autor.

3.4 Clustering

O *clustering*, ou clusterização, é uma tarefa do aprendizado de máquina não supervisionado e seu objetivo é agrupar os dados fornecidos em clusters que possuam características iguais ou semelhantes. Todos os objetos que estejam dentro de um cluster resultante possuem mais similaridade entre si do que com qualquer objeto que esteja fora desse cluster.

3.5 Recomendação

O algoritmo de recomendação é amplamente utilizado por lojas virtuais. O propósito dessa técnica é produzir uma lista de objetos recomendados

a partir de algum tipo de entrada de dados, como, por exemplo, as palavras digitadas na busca por produtos a serem comprados.

Os algoritmos de recomendação buscam cruzar informações do perfil usuário com a lista de produtos disponíveis para compra, e assim conseguem criar uma lista de recomendações. Essa técnica não é utilizada somente em lojas. Você pode fazer proveito de uma lista de recomendações para estimular um usuário de revistas digitais a ler novas matérias. O algoritmo de recomendação só precisa elaborar a lista com temas que sejam de interesse do usuário. Um exemplo é o trabalho feito por aplicativos musicais, que criam *playlists* com músicas que provavelmente serão de interesse do usuário.

Nesta Leitura Fundamental, foram primeiramente abordadas as principais características do aprendizado de máquina, em que você foi apresentado aos termos e suas aplicações atuais. Com o exemplo de João e seu gosto musical, você observou como a máquina trabalha e como ela pode “aprender”. Além disso, foram apresentadas algumas das principais aplicações do AM, e foi nessa etapa que você foi também apresentado a algumas aplicações do AM e sua importância para a evolução de todos os sistemas tecnológicos. Finalmente, você estudou as topologias clássicas de problemas resolvidos pelo aprendizado de máquina: classificação binária, classificação multiclasse, regressão, *clustering* e recomendação. Logicamente, o AM não se restringe a essas topologias. Existem inúmeros problemas nos quais você pode aplicar seus estudos, o seu trabalho é estudar todos os algoritmos e técnicas e utilizar o conhecimento adquirido para encontrar novas situações a serem resolvidas.



Teoria em prática

Considere que você é um profissional que trabalha no setor de tecnologia de uma locadora online de filmes, a Filmeflix. A empresa implementou um sistema no qual os usuários podem dar notas de 1 a 10 para os filmes assistidos. Porém, as pessoas que estão buscando filmes para assistir acharam que notas com 10 níveis não são muito boas; elas preferem somente saber se o filme é “bom”, “médio” ou “ruim”. Como você é o responsável por fazer essa nova etapa do projeto, tem a liberdade para utilizar a tecnologia que julgar mais adequada.

Em seus estudos para essa tarefa, você viu que será possível criar um algoritmo de aprendizado de máquina capaz de separar os filmes com notas de 1 a 10. O seu algoritmo deverá realizar o seguinte agrupamento:

- Notas de 1 a 3: filme ruim.
- Notas de 4 a 7: filme médio.
- Notas de 8 a 10: filme bom.

O conteúdo estudado até agora já lhe proporcionou bastante conhecimento sobre as principais características e aplicações da aprendizagem de máquina. A partir dos tópicos estudados, descreva em qual problema clássico do AM a situação da Filmeflix se encaixa. Após identificar o problema, descreva as principais características dessa modalidade de AM, pesquise quais os principais algoritmos já existentes são normalmente utilizados nesse caso e, finalmente, escolha um deles para ser utilizado pela empresa. É importante você descrever o algoritmo escolhido e citar suas principais vantagens.


Verificação de leitura

1. O aprendizado de máquina (AM) pode ser utilizado em inúmeros cenários. Considere as afirmações a seguir sobre possíveis aplicações do AM:
 - () É possível utilizar algoritmos de AM para detectar quais e-mails são *spam* e quais não.
 - () É possível utilizar AM para fazer identificação de imagens e classificar os objetos nela contidos.
 - () É possível utilizar algoritmos de AM para identificar o perfil de clientes de uma loja.
 - () Não é possível utilizar algoritmos de AM para fazer a identificação de emoções por meio da voz.

Qual das sequências a seguir indica, respectivamente, quais afirmações são verdadeiras (V) ou falsas (F)?

- a. F – F – V – V.
 - b. V – V – F – F.
 - c. V – V – V – F.
 - d. V – F – V – V.
 - e. V – V – V – V.
2. O aprendizado de máquina é amplamente utilizado na indústria automobilística para fazer a identificação de anomalias e proposição de otimizações. A seguir, é apresentado um gráfico que apresenta dados de vários carros e também um resultado obtido com aprendizado de máquina:

Figura 8 – Dados de aprendizado de máquina



Fonte: Prates (2019).

Qual das topologias a seguir corresponde corretamente à topologia de aprendizado de máquina ilustrada na figura?

- a. Classificação binária.
- b. Classificação multiclasse.
- c. Regressão.
- d. Identificação de anomalias.
- e. *Clustering*.

3. O aprendizado de máquina pode ser subdividido em duas grandes categorias: aprendizado supervisionado e não supervisionado. Assinale a alternativa que contém um algoritmo de aprendizado de máquina supervisionado.
- a. Regressão e classificação.
 - b. *Clustering* e *K-means*.
 - c. Regressão e *clustering*.
 - d. Classificação e *clustering*.
 - e. Regressão e decomposição em valores singulares.

Referências bibliográficas

BURGER, S. **Introduction to machine learning with R: rigorous mathematical analysis**. Sebastopol, CA: O'Reilly, 2018.

FACELI, K.; LORENA, A. C.; GAMA, J.; CARVALHO, A. C. P. L. F. **Inteligência artificial: uma abordagem de aprendizado de máquina**. São Paulo: LTC Editora, 2011.

HURWITZ, J.; KIRSCH, D. **Machine learning for dummies**. Hoboken, NJ: John Wiley & Sons, Inc., 2018. 70 p.

MITCHEL, M. B. **Machine Learning**. New York: McGraw-Hill Science/Engineering/Math, 1997. 432 p.

PRATES, W. R. **Aprendizado de máquina: supervisionado e não supervisionado**. 2018. Disponível em: https://www.wrprates.com/aprendizado-de-maquina-supervisionado-e-nao-supervisionado/#Modelo_supervisionado_1_Regressao. Acesso em: 25 jul. 2019.

SMOLA, A.; VISHWANATHAN, S. V. N. **Introduction to machine learning**. New York, NY: Cambridge University Press, 2008. 226 p.

TURING, A. M. Computing machinery and intelligence. **Mind: New Series**, Oxford, v. 59, n. 236, p. 433-460, out. 1950.



Gabarito

Questão 1 – Resposta C

Resolução: O aprendizado de máquina pode ser aplicado em inúmeras situações. Inclusive no reconhecimento de emoções por meio da análise de áudios. Por meio da identificação do tom e da intensidade da fala, os algoritmos podem, sim, fazer esse tipo de reconhecimento. Por isso a sequência correta de afirmações é V – V – V – F.

Questão 2 – Resposta C

Resolução: O resultado mostrado na figura é a utilização de um algoritmo de regressão, que cria uma função matemática baseada nos dados da etapa de treinamento.

Questão 3 – Resposta A

Resolução: Dos algoritmos apresentados, somente a regressão e a classificação são supervisionadas. Logo, a alternativa A é a correta.

Algoritmos de *machine learning*: modelos preditivos

Autor: Lucas Claudino



Objetivos

- Compreender a principal função dos algoritmos de *machine learning* preditivos, observando suas características básicas e finalidades.
- Conhecer os principais métodos de aprendizado de máquina preditivos e os algoritmos clássicos de cada um dos métodos.
- Conhecer as principais aplicações de *machine learning* preditivo e saber identificar qual técnica é a mais indicada para o problema a ser resolvido.



1. Introdução

O aprendizado de máquina pode ser classificado de diversas maneiras, e não existe uma delas que é considerada a forma mais correta de classificação. Você já estudou a divisão do AM em supervisionado, não supervisionado e de reforço. Outra forma de classificar o AM é a partir da finalidade do algoritmo utilizado. Para isso, a classificação mais comum é dividir o AM em modelos **preditivos** ou **descritivos**.

São aqueles que, a partir de um conjunto de dados rotulados fornecidos como entrada, conseguem elaborar estratégias para construir um estimador capaz de apresentar valores de saída de acordo com novos dados de entrada fornecidos. Já os modelos descritivos são aqueles capazes de avaliar os dados disponíveis e identificar informações relevantes e similares entre os objetos fornecidos para estudo. O resultado é alguma forma de classificação ou separação dos dados por meio dessas informações extraídas.



2. Introdução aos modelos preditivos

De acordo com Faceli *et al.* (2011), o algoritmo de aprendizado de máquina preditivo é aquele que, a partir de um conjunto de dados conhecidos, cria um estimador. Todo dado desse conjunto conhecido possui rótulos também conhecidos. Se os dados contidos nesse domínio conhecido forem finitos e tiverem valores nominais, o problema então é de classificação, e o estimador resultante do treinamento é o classificador. Se o domínio desse conjunto de dados for infinito, o problema é, então, de regressão, e o estimador é um regressor.

É possível também criar uma definição matemática formal para esse modelo de AM. Considere o conjunto de pares de dados como $D = \{(x_i, f(x_i)), i = 1, \dots, n\}$, sendo que $f(x_i)$ é uma função desconhecida. O algoritmo

de AM preditivo analisa então esse conjunto para criar uma aproximação $\hat{f}$ de f . Com essa aproximação, o algoritmo consegue então estimar os rótulos para qualquer nova entrada x . O AM preditivo é, então, dividido entre classificação e regressão, de acordo com o domínio da função original $f(x_i)$ como:

- Classificação: $y_i = f(x_i) \in \{c_1, \dots, c_m\}$. Nesse caso, $f(x_i)$ assume somente valores discretos contidos em seu domínio.
- Regressão: $y_i = f(x_i) \in R$. Nesse caso, $f(x_i)$ assume valores contidos no domínio infinito R .

Para melhor entender essa distinção entre classificação e regressão, vamos considerar dois problemas conhecidos na área de aprendizado de máquina: o problema da Iris e o problema Swiss. O problema da Iris consiste em classificar flores em três espécies com base em alguns atributos físicos referentes a tamanho e largura das pétalas e sépalas das flores. Já o problema Swiss fornece dados para criar soluções capazes de relacionar a taxa de mortalidade a quatro parâmetros: fertilidade, agricultura, educação e renda.

Em ambos os casos, são consideradas como variáveis de entrada do problema as características que as diferenciam em suas classificações. Esses dados estão organizados no Quadro 1 e no Quadro 2.

Quadro 1 – Parte do conjunto de dados Iris

Tamanho (P)	Largura (P)	Tamanho (S)	Largura (S)	Espécie
5,1	3,5	1,4	0,2	Setosa
4,9	3,0	1,4	0,2	Setosa
7,0	3,2	4,7	1,4	Versicolor
6,4	3,2	4,5	1,5	Versicolor
6,3	3,3	6,0	2,5	Virgínica
5,8	2,7	5,1	1,9	Virgínica

Fonte: elaborada pelo autor.

Quadro 2 – Parte do conjunto de dados Swiss

Fertilidade	Agricultura	Educação	Renda	Mortalidade
80,2	17,0	12	9,9	22,2
83,1	45,1	9	84,8	22,2
92,5	39,7	5	83,4	20,2
85,8	36,5	7	33,7	20,3
76,9	43,5	15	5,2	20,6

Fonte: elaborada pelo autor.

Ambos os quadros, ou conjuntos de dados, cada linha é uma observação diferente. A última coluna é o rótulo de cada observação, ou atributo-alvo, que é o valor da função $f(x_i)$; ou seja, é a variável dependente, pois depende dos valores das outras colunas. Os outros dados são os atributos de entrada, ou variável independente.

No problema da Iris, parcialmente contido no Quadro 1, o conjunto de dados de diversas flores divididas em três grupos: setosa, versicolor e virgínica. Nesse caso, os atributos de entrada são características (tamanho e largura) das pétalas e sépalas das flores. A partir desses atributos, é possível separar as plantas em três rótulos, ou classes, que são as espécies da planta: setosa, versicolor e virgínica.

O problema da Iris é largamente utilizado para o ensino do AM de classificação devido à característica das três classes. A espécie setosa é bastante separada das outras duas; porém, as espécies versicolor e virgínica possuem características muito semelhantes, por isso é mais difícil separá-las. Você pode observar essa diferença por meio da largura da sépala, por exemplo.

Os dados contidos no Quadro 2, referentes ao problema Swiss, relacionam a taxa de mortalidade a diversas características da população. Nesse caso, as variáveis independentes são fertilidade, agricultura, educação e renda, enquanto a variável dependente é a taxa de mortalidade.

Em ambos os casos, o objetivo do algoritmo é aprender por meio desses dados de treinamento para criar uma função $\hat{f}(x_i)$ que seja capaz de mapear novos dados inseridos. No caso do problema Iris, a função terá que classificar novas plantas em alguma das três espécies. Já no caso do problema Swiss, a função $\hat{f}(x_i)$ deverá estimar qual o valor da taxa de mortalidade.


A função $\hat{f}(x_i)$ é uma estimativa, ou seja, mesmo sendo uma excelente aproximação, pode haver alguns casos em que $\hat{f}(x_i) \neq f(x_i)$. Por isso que o modelo tem que ser criado corretamente. Para medir a qualidade da estimativa, existem as chamadas funções custo, e para cada tipo de problema há uma função custo mais indicada. Para problemas de classificação, é utilizada a função binária 0 – 1: quando a estimativa for correta ($\hat{f}(x_i) = f(x_i)$), o custo é 0, já quando a estimativa é incorreta ($\hat{f}(x_i) \neq f(x_i)$), o custo é 1. Para os problemas do tipo regressão, costuma-se utilizar o custo chamado erro quadrático médio (MSE – *mean squared error*) $MSE = E [\hat{f}(x_i) - f(x_i)]^2$.

Os algoritmos de aprendizado de máquina preditivos podem ser subclassificados em métodos baseados em distância, otimização, procura e métodos probabilísticos. A seguir, você verá as principais características de cada um desses métodos e os algoritmos mais populares das subcategorias do AM preditivo.

2.1 Métodos baseados em distância

Segundo Faceli *et al.* (2011), o AM preditivo baseado em distância busca calcular a distância entre os pontos em análise. Esse método se baseia na hipótese de que dados semelhantes ficam dispostos de maneira concentrada no domínio do conjunto da função. Para melhor entender como funciona um método baseado em distâncias, observe a Figura 1, que é a representação gráfica dos dados obtidos com a base de dados Iris.

Figura 1 – Diagrama planificado da classificação do problema Iris



Fonte: elaborada pelo autor.

A Figura 1 possui diferentes gráficos, cada um relacionando duas das quatro variáveis independentes do Quadro 1. Em todos os gráficos, é possível observar que a classe setosa está geograficamente separada da versicolor e da virgínica. Então, o algoritmo consegue facilmente ser treinado a identificar qual é a região que representa a flor da espécie setosa. Porém, as classes virgínica e versicolor possuem vários elementos que se confundem, e o desafio maior do algoritmo é conseguir identificar pontos pertencentes a essas classes.

Os algoritmos baseados em distâncias irão, a cada novo ponto recebido para análise, calcular a distância entre ele e os pontos mais próximos. Com isso, saberão qual é a classe que está mais próxima ao ponto. Esses algoritmos são rotulados como “preguiçosos” (*lazy*), pois não aprendem ou criam um modelo baseados nos dados do treinamento, eles apenas memorizam os dados e criam um plano n-dimensional para possibilitar a análise das distâncias.

O algoritmo mais conhecido que se enquadra no método baseado em distâncias é o k -NN (*k nearest neighbors*). Basicamente, esse algoritmo identifica os k vizinhos mais próximos do ponto a ser analisado, para então verificar em qual classe o novo dado se enquadra.



3. Métodos probabilísticos

Métodos probabilísticos são muito utilizados quando não há informação completa sobre os dados utilizados. Nesses casos, as previsões são feitas com o auxílio do teorema de Bayes, que diz o seguinte:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Sendo $P(A|B)$ a probabilidade de o evento A acontecer, dada a situação B ; $P(B|A)$ é a verossimilhança entre A e B ; $P(B)$ e $P(A)$ são as probabilidades *a priori*.

O teorema de Bayes mostra que a probabilidade do evento B ocorrer, dado o conjunto ou evento A , depende da relação entre esses dois objetos, mas também depende da probabilidade das observações individuais de A e B .

Para encontrar as probabilidades *a priori*, você pode observar os dados e analisar com qual frequência os eventos A ou B ocorrem. Então, dado o conjunto total de observações, é possível extrair as probabilidades $P(A)$ e $P(B)$. Pode-se também observar a ocorrência de B para cada evento A que ocorreu. Mas como você vai observar a probabilidade de A ocorrer, para cada evento B , sendo que todos os eventos do tipo A já ocorreram? Para isso, você utiliza o Teorema de Bayes.

Assim como dito anteriormente, métodos probabilísticos podem ser utilizados, por exemplo, quando não há informação completa sobre

os fatos, ou também quando os dados obtidos forem muito ruidosos. Para entender melhor como esse método é utilizado, pense no caso de prever se uma pessoa terá algum problema cardíaco, sendo que os atributos preditivos mensuráveis disponíveis são: peso e frequência cardíaca. Nesse caso, informações muito importantes estão sendo ignoradas, como, por exemplo, a hereditariedade, consumo de bebidas alcoólicas ou o estresse. Por isso, utiliza-se, por exemplo, a probabilidade de pessoas que consomem bebidas alcoólicas terem problemas cardíacos. Essa seria a verossimilhança observada do Teorema de Bayes.

Algumas definições básicas de teoria das probabilidades são essenciais para a compreensão dos métodos probabilísticos. O espaço amostral Ω é a definição do conjunto composto por todos os resultados que podem acontecer em um dado experimento. A probabilidade de um evento E , pertencente ao espaço amostral Ω , ocorrer é $P(E)$ e satisfaz os conhecidos axiomas de Kolmogorof (PESTANA; VELOSA, 2002):

- $P(E) \leq 1$.
- Se o espaço amostral é Ω , então $P(\Omega) = 1$.
- Se F e G são eventos distintos, então a união entre eles é $P(F \cup G) = P(F) + P(G)$.

Esses axiomas são ferramentas necessárias para o cálculo da lei da probabilidade total: se $G_1, G_2, \dots, G_n \in \Omega$ então, para qualquer F , a seguinte probabilidade é verdadeira:

$$P(A) = \sum_{i=1}^n P(A|B_i) \times P(B_i)$$

Para encontrar o Teorema de Bayes, que é a base para os modelos probabilísticos, observe a probabilidade de ocorrência simultânea dos eventos A e B:

$$P(A \cap B) = P(A|B) \cdot P(B)$$

$$P(B \cap A) = P(B|A) \cdot P(A)$$

Igualando as equações:

$$P(A \cap B) = P(B \cap A) \therefore P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Portanto:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

O algoritmo mais popular que é baseado em métodos probabilístico que é o Naive Bayes, também conhecido como Bayes Ingênuo ou Bayes simples.

4. Métodos baseados em procura


Outra abordagem para o aprendizado de máquina é tratar o problema como uma procura no espaço de soluções disponíveis, até que a solução desejada seja alcançada. Segundo Russel e Norvig (2010), um problema de procura é basicamente constituído por:

- Espaço de estados: o conjunto com todos os estados possíveis nos quais o problema pode se encontrar.
- Um estado de início: o estado por onde a busca deve começar.

- Teste de objetivo: uma função capaz de observar o estado atual e retornar se é ou não o estado final.
- A solução para um problema de busca é uma sequência de atos, também chamada de plano, que transforma o estado inicial de tal maneira até chegar ao estado final.
- O plano é concretizado por meio do algoritmo de busca.

Existem diversos algoritmos de busca e cada um tem seus nichos de aplicação. Os métodos baseados em procura podem ser divididos da seguinte maneira:

Figura 2 – Divisão dos métodos baseados em procura



Fonte: elaborada pelo autor.

Os algoritmos de busca não informada não possuem informações adicionais sobre o estado final, eles só sabem se esse estado foi atingido ou não. O plano para chegar ao estado final a partir do estado inicial defere somente pela ordem e/ou tamanho das buscas tomadas por cada algoritmo. Devido a essas características, os algoritmos não informados são também conhecidos como algoritmos de “busca cega”, pois não enxergam onde estão, e só sabem se chegaram ou não ao destino (RUSSEL; NORVIG, 2010).

Observando a Figura 2, você pode identificar alguns exemplos de busca não informada. A busca em largura é um método que varre um ramo da árvore de procura até encontrar um nó em que não consiga mais prosseguir, mesmo que esse ramo esteja levando a busca para longe do estado final desejado.

Os algoritmos de busca informada utilizam conhecimento sobre o domínio do problema. Eles possuem informação sobre o estado final, o que ajuda na construção de buscas mais eficientes. Geralmente, esse tipo de algoritmo utiliza alguma função heurística para estimar quão perto a busca está do estado final. Essa heurística estima então o custo necessário para passar de um estado ao outro. Caso o algoritmo detecte que está ficando mais distante da solução ótima, ele é capaz de retroceder a busca e procurar um caminho mais adequado (RUSSEL; NORVIG, 2010).

Um exemplo de busca informada é o algoritmo Greedy Search, que busca expandir o nó mais próximo da solução desejada, e para saber qual é esse nó, o algoritmo utiliza uma função heurística de estimação $h(x)$. Basicamente, $h(x)$ estima a distância entre o nó x e o estado final.

Outro exemplo é o algoritmo A* Search, que minimiza o custo total estimado para atingir a solução. O custo é também estimado por meio de funções heurísticas, e a estratégia de otimização varia para cada algoritmo utilizado, sendo ela otimização linear ou não.



Para saber mais

Algoritmos de busca são amplamente utilizados em problemas de localização de rotas ótimas, em que o aplicativo tem que fornecer a direção para o usuário chegar ao destino. Outra aplicação é a montagem automática de produtos, na qual o robô precisa estabelecer um plano de montagem que otimize alguma função custo, como, por exemplo, a energia gasta durante o processo.


5. Métodos baseados em otimização

Existem estratégias de aprendizado de máquina que chegam à solução do problema por meio de estratégias de otimização de uma função. Nesses métodos, o problema é criado de tal forma que seu objetivo é otimizar (maximizar ou minimizar) uma função custo (ou função objetivo).

Pense no caso de otimização da produção, um problema bastante atual e no qual inúmeras indústrias estão prestando atenção. A otimização pode ser de diversos fatores, como redução de custos, redução de tempo, redução de poluição, aumento de produtividade. Você consegue perceber que todos esses problemas buscam minimizar ou reduzir alguma função? O objetivo é conseguir dados suficientes para descrever essas funções.

A Figura 3 ilustra uma função custo qualquer, que é dependente das variáveis 1 e 2. Claramente, é possível observar pontos de máximo e mínimo globais a partir da inspeção visual.

Figura 3 – Exemplo de função custo com duas variáveis independentes



Fonte: elaborada pelo autor.

Suponha que o custo ilustrado na Figura 3 é a quantidade relativa de itens produzidos por uma determinada indústria. Custo positivo significa que a produção está acima da meta e custo negativo significa que está abaixo do desejado. Com esses dados, um algoritmo de otimização tem que conseguir encontrar qual o ponto máximo da função custo, pois isso significa que a produção está em seu máximo.

Observe que a solução não é tão simples como parece, pois a função custo ilustrada não possui somente o ponto máximo global. Ela apresenta também os chamados máximos locais, que são aqueles pontos em que há um pico no valor da função, porém existem picos ainda maiores. São esses pontos que o algoritmo de otimização precisa evitar, pois eles são conhecidos com “falsos ótimos”.



Assimile


Para os algoritmos de otimização poderem maximizar (ou minimizar) uma função, ela precisa realmente apresentar pontos de máximo ou mínimo. Ou seja, a função custo precisa ser côncava ou convexa, pois isso significa que ela realmente apresentará os pontos ótimos desejados.

Duas técnicas bastante conhecidas de aprendizado de máquina baseado em métodos de otimização são as redes neurais artificiais (RNA) e as SVM (*support vector machine* ou máquinas de vetor de suporte) (BRAGA *et al.*, 2007; HAYKIN, 1999; CRISTIANINI; SHAW-ETAYLOR, 2000). As RNAs são inspiradas no funcionamento das redes neurais biológicas que formam o cérebro humano. Esses sistemas são capazes de aprender para executar tarefas sem terem que ser programados para nenhuma tarefa específica. Esse tipo de algoritmo interpreta os dados por meio

de um tipo de percepção de máquina, identificando, rotulando e classificando os dados disponíveis.

As SVM são algoritmos que buscam encontrar algum hiperplano em um espaço N-dimensional capaz de fazer a separação ótima entre os dados. Para entender melhor a ideia de hiperplano, observe a Figura 4, que ilustra um hiperplano em um sistema de duas variáveis. Nesse caso, o hiperplano é uma reta. Se fosse um sistema com três variáveis, o hiperplano seria uma superfície.

Figura 4 – Ilustração de um hiperplano 2D



Fonte: elaborada pelo autor.

Observe a Figura 4, que ilustra o hiperplano 2D. Só é possível considerar que esse hiperplano é ótimo pois ele está localizado exatamente no ponto que oferece a margem máxima de separação entre as duas classes dos dados.

Nesta Leitura Fundamental, você pôde compreender que o aprendizado de máquina possui uma abordagem bastante dinâmica e pode ser utilizado para a resolução de inúmeros problemas.

Os modelos preditivos de AM podem ser classificados em métodos baseados em otimização, procura, distância e métodos probabilísticos. Cada uma dessas técnicas possui seus algoritmos mais conhecidos, e é importante que você conheça uma grande variedade deles, pois

só assim será capaz de julgar qual algoritmo é mais indicado para o problema que for resolver.

Teoria em prática

Um problema clássico no AM é o *8-puzzle*, que é uma espécie de jogo em uma placa de 3x3 peças, sendo que 8 peças são numeradas e uma posição está em branco. As peças que estão ao lado do espaço livre podem deslizar para ocupar seu lugar. O objetivo é sair de um estado inicial e chegar até um estado final predeterminado. Observe a figura abaixo, que ilustra uma possibilidade do jogo *8-puzzle* e seus estados inicial e final:

Figura 5 – Jogo 8-puzzle

7	2	4
5		6
8	3	1
Início		

	1	2
3	4	5
6	7	8
Fim		

Fonte: elaborada pelo autor.

Diversas técnicas aprendidas nesta Leitura Fundamental podem ser utilizadas para resolver o problema acima. O *8-puzzle* pertence à família de problemas de blocos deslizantes, possui $9!/2=181.440$ estados possíveis e pode ser facilmente resolvido utilizando técnicas de AM (a solução pode ser encontrada em alguns milésimos de segundo). O seu desafio agora é escolher uma das técnicas e descrever

como seria a resolução do 8-*puzzle* com o uso da técnica escolhida. O problema não precisa ser totalmente resolvido, ou seja, você não precisa descrever todos os estados pelos quais o problema deverá passar para sair do estado inicial e chegar ao estado final. Porém, você precisa compreender o problema, escolher uma técnica que julga ser a melhor para esse caso e descrever de que forma você tentaria resolvê-lo.



Verificação de leitura

1. O problema Iris é uma situação clássica no estudo de *machine learning*. Nesse problema, o algoritmo deve ser capaz de distinguir os objetos entre três espécies de planta: versicolor, virgínica ou setosa.

Assinale a alternativa que afirma corretamente que tipo de problema de aprendizado de máquina preditivo é o problema Iris.

- a. Regressão.
 - b. Otimização.
 - c. Classificação.
 - d. Busca informada.
 - e. Busca não informada.
2. Assinale a alternativa que contém corretamente o nome do método de aprendizado de máquina que se baseia no princípio de que dados semelhantes ficam organizados de maneira concentrada no domínio do conjunto de dados do problema, para então poder classificar corretamente os dados.

- a. Regressão.
 - b. Método de busca.
 - c. Método de otimização.
 - d. Método das distâncias.
 - e. Método probabilístico.
3. Existe uma metodologia de aprendizado de máquina que é mais indicada para ser utilizada em casos nos quais não há informação completa sobre os fatos, ou também quando os dados obtidos forem muito ruidosos.
- Assinale a alternativa que afirma corretamente qual método de *machine learning* é mais indicado para esse caso.
- a. Método probabilístico.
 - b. Método baseado em busca.
 - c. Método baseado em distância.
 - d. Método baseado em otimização.
 - e. Método baseado em aproximação linear.



Referências bibliográficas

- FACELI, K.; LORENA, A. C.; GAMA, J.; CARVALHO, A. C. P. L. F. **Inteligência artificial: uma abordagem de aprendizado de máquina**. São Paulo: LTC Editora, 2011.
- GANDHI, R. **Support vector machine: introduction to machine learning algorithms**. 2018. Disponível em: <https://towardsdatascience.com/support-vector-machine-introduction-to-machine-learning-algorithms-934a444fca47>. Acesso em: 31 jul. 2019.
- GRIVA, I.; NASH, S. G.; SOFER, A. **Linear and nonlinear optimization**. 2. ed. Fairfax: George Mason University, 2009. 742 p.
- PESTANA, D. D.; VELOSA, S. F. **Introdução à probabilidade e à estatística**. 4. ed. Lisboa: Fundação Calouste Gulbenkian, 2008. 1.164 p.

RUSSEL, S.; NORVIG, P. **Artificial Intelligence: a modern approach**. 3. ed. New Jersey: Pearson Education Inc., 2010. 1.132 p.

SMOLA, A.; VISHWANATHAN, S. V. N. **Introduction to machine learning**. New York, NY: Cambridge University Press, 2008. 226 p.



Gabarito

Questão 1 – Resposta C

Resolução: O problema Iris é do tipo classificação, em que o algoritmo deve classificar corretamente qualquer nova planta entre as três classes já conhecidas.

Questão 2 – Resposta D

Resolução: O método das distâncias se baseia na hipótese de que dados semelhantes ficam dispostos de maneira concentrada no domínio do conjunto da função.

Questão 3 – Resposta A

Resolução: Métodos probabilísticos podem ser utilizados, por exemplo, quando não há informação completa sobre os fatos, ou também quando os dados obtidos forem muito ruidosos.



BONS ESTUDOS!