



WBA0752_v2.0

Técnicas estatísticas: teoria e prática (R Programming)



Manipulação de dados: banco de dados e sumarização estatística usando R

Curiosidades sobre banco de dados

Bloco 1


Anderson Emidio de Macedo Gonçalves




Vamos refletir?

A possibilidade de conectar diretamente as bases de dados, extrair informações relevantes e aplicar técnicas estatísticas avançadas em R, sem a necessidade de alternar entre diferentes ferramentas, representa um grande avanço para profissionais de diversas áreas. Esse avanço no manejo dos dados redefine a forma como as empresas abordam a análise de informações. Agora, é possível transformar grandes quantidades de dados brutos em informações concisas que suportam a tomada de decisões.

Diante desse cenário, é inevitável perguntar: como a adoção dessas técnicas de manipulação e sumarização de dados em R pode continuar a moldar a estratégia de negócios, permitindo uma abordagem mais precisa, ágil e baseada em dados na gestão empresarial? A resposta a essa pergunta pode ser a chave para o sucesso organizacional nos próximos anos.





A base da era digital

Bancos de dados são sistemas estruturados para armazenar e gerenciar grandes volumes de informações. O primeiro banco de dados digital foi criado na década de 1960 para gerenciar reservas de voos.

Banco conectado a vários dispositivos



Fonte: https://cdn.pixabay.com/photo/2017/10/29/14/48/data-2899902_1280.jpg.

Como os dados são armazenados?

Tipos e estruturas:
tabelas, índices etc.


Modelos de banco de
dados: relacional,
NoSQL e orientado a
objetos.

Tabela do banco de dados

	ID_Jogador	Nome	Email	Data_Criacao
▶	1	Alice	alice@example.com	2024-01-01
	2	Bob	bob@example.com	2024-01-02
	3	Anderson	anderson@gmail.com	2024-08-08
	NULL	NULL	NULL	NULL

Fonte: elaborada pelo autor por meio da
ferramenta MySQL Workbench.


Curiosidade: a linguagem SQL, usada em bancos de
dados relacionais, foi desenvolvida na IBM nos anos
1970 e ainda é amplamente utilizada.



Banco de dados relacionais

- **Características:** baseado em tabelas, utiliza chaves primárias e estrangeiras para relacionamentos.
- **Bancos:** MySQL, PostgreSQL e Oracle Database.
- **Curiosidade:** introduzido por Edgar Codd em 1970, revolucionando a forma como dados são armazenados e acessados.


Modelagem de dados




Fonte: elaborada pelo autor por meio da ferramenta MySQL Workbench.

Além do relacional: o mundo NoSQL

- **O que é NoSQL?:** bancos de dados que não seguem o modelo relacional tradicional, ideal para grandes volumes de dados não estruturados.
- **Tipos de NoSQL:** documentos (MongoDB), chave-valor (Redis) e colunas (Cassandra).
- **Curiosidade:** empresas como Facebook e Google usam bancos de dados NoSQL para lidar com petabytes de dados de usuários.




Fonte: https://images.datacamp.com/image/upload/v1656083462/No_SQL_Databases_Explained_1_ace7d34fdf.png.



O futuro dos banco de dados

Tendências: maior integração com IA e machine learning, bancos de dados distribuídos e aumento da segurança de dados.




Fonte: https://www.convergenciadigital.com.br/media/2024/TIC-Empresas-2023_Empresas-que-pagaram-por-capacidade-de-processamento-em-nuvem.jpg.

Manipulação de dados: banco de dados e sumarização estatística usando R

Banco de dados: criação e manipulação de dados
em uma base de dados

Bloco 2

Anderson Emidio de Macedo Gonçalves




Ferramentas essenciais no mundo moderno


A visualização de dados em uma organização é fundamental por diversos fatores. Entre eles, se encontram:

Crescimento exponencial de informações

Pilares da gestão da informação

Exemplo prático: um supermercado utilizando um banco de dados para rastrear seus produtos, preços e vendas.






Conceitos fundamentais

- **Definição:** um banco de dados é uma coleção organizada de dados com significado inerente, projetada para uma finalidade específica.
- **Propósito e uso:** criado para um grupo definido de usuários com aplicações específicas.
- **Citação:** “um banco de dados é uma coleção logicamente coerente de dados com algum significado inerente.” (Elmasri; Navathe, 2011).

DER Diagrama Entidade-Relacionamento




Fonte: elaborada pelo autor por meio da ferramenta MySQL Workbench.

Manipulação de dados com SQL

- **O papel da SQL:** Structured Query Language (SQL) é a linguagem padrão para realizar operações em bancos de dados.
- **Operações CRUD:** criação, leitura, atualização e exclusão de dados.
- **Exemplo prático:** gestão de um banco de dados de uma biblioteca usando SQL.


Comando select



The screenshot shows the MySQL Workbench interface. At the top, there's a tab labeled 'Query 1' and another labeled 'Jogador'. Below the tabs is a toolbar with various icons, including a lightning bolt, a magnifying glass, and a refresh button. To the right of the toolbar is a 'Limit to 1000' button. The main area displays the SQL query: `1 • SELECT * FROM jogo.Jogador;`. Below the query is a progress bar and a zoom level of '100%'. Underneath the query is a 'Result Grid' section with a 'Filter Rows' search bar and an 'Edit' button. The result grid contains a table with the following data:

	ID_Jogador	Nome	Email	Data_Criacao
▶	1	Alice	alice@example.com	2024-01-01
	2	Bob	bob@example.com	2024-01-02
	3	Anderson	anderson@gmail.com	2024-08-08
	NULL	NULL	NULL	NULL

Fonte: elaborada pelo autor por meio da ferramenta MySQL Workbench.



Entendendo as diferenças


- **Bancos de dados relacionais (RDBMS):** organizam dados em tabelas relacionadas por chaves. Exemplo: MySQL.
- **Bancos de dados não relacionais (NoSQL):** armazenam dados em formatos como documentos, grafos ou colunas. Exemplo: MongoDB.
- **Exemplos práticos:** tabela de livros em MySQL versus documentos de usuários em MongoDB.

Relacional versus NoSQL

id	titulo	autor
1	Dom Casmurro	Machado de Assis
2	O Alquimista	Paulo Coelho
3	Grande Sertão: Veredas	João Guimarães Rosa

```
{
  "_id": "1",
  "titulo": "Dom Casmurro",
  "autor": "Machado de Assis",
  "ano_publicacao": 1899
}
```

Fonte: elaborada pelo autor por meio da ferramenta SQL Client.



Funções do banco de dados

O que são Stored Procedures (SPs)?

- **Definição:** são blocos de código SQL armazenados e executados no servidor de banco de dados.
- **Vantagem:** executadas no servidor, evitando a necessidade de enviar múltiplas instruções SQL do cliente, o que melhora a eficiência e segurança.

Stored Procedure

```
3 DELIMITER //  
4  
5 • CREATE PROCEDURE BuscaJogador(IN searchDate DATE)  
6 BEGIN  
7     SELECT id_Jogador, nome, email, data_criacao  
8     FROM Jogador  
9     WHERE data_criacao = searchDate;  
10 END //  
11  
12 DELIMITER ;  
13
```


Fonte: elaborada pelo autor por meio da ferramenta MySQL Workbench.

Manipulação de dados: banco de dados e sumarização estatística usando R

Sumarização estatística na análise de dados usando R

Bloco 3


Anderson Emidio de Macedo Gonçalves



O poder da sumarização estatística em R

- O que é sumarização estatística?
- Transformação de grandes volumes de dados em informações compreensíveis.
- Uso de medidas descritivas como média, mediana, variância e desvio-padrão.
- **Importância:**
- Essencial para entender as principais características de um conjunto de dados.
- Facilita a tomada de decisões informadas.

Sumarização



Fonte: elaborada pelo autor no RStudio na Linguagem R.

Introdução

Na Estatística Descritiva, as medidas de tendência central são ferramentas importantes para resumir um conjunto de dados em um único número. As principais medidas de tendência central são:


Moda

Média

Mediana


Desvio-padrão

Histograma



Fonte:

https://upload.wikimedia.org/wikipedia/commons/thumb/8/8e/Histogram_example.svg/1920px-Histogram_example.svg.png




Compreendendo a variabilidade dos dados

Variância: mede o quanto os dados variam em torno da média.

Desvio-padrão: a raiz quadrada da variância, indicando a dispersão dos dados.

Gráfico de dispersão



Fonte: elaborada pelo autor no RStudio na Linguagem R.

Dados para o gráfico

```
horas_estudo <- c(2, 3, 5, 7, 9, 10, 4, 6, 8, 3, 5).
```

```
notas <- c(70, 75, 80, 85, 88, 90, 78, 82, 86, 76, 84).
```

Visualizando a sumarização com ggplot2


Importância da visualização:

Facilita a identificação de padrões e tendências.

Torna os dados mais acessíveis e compreensíveis.

Scatter Plots

```
library(ggplot2)
ggplot(data = data.frame(notas), aes(x = notas)) +
  geom_histogram(binwidth = 5, fill = "blue", color = "black") +
  theme_minimal()
```



Fonte: elaborada pelo autor no RStudio na Linguagem R.

Aplicando sumarização estatística no dia a dia

Aplicações reais:

- Em empresas para análise de desempenho.
- Em pesquisas para resumo de resultados.

Conclusão:

- A sumarização estatística em R é uma habilidade essencial para transformar dados em conhecimentos significativos.
- Aprenda a calcular e interpretar estatísticas descritivas, além de criar gráficos informativos para tomar decisões melhores e mais rápidas.

Preparação do ambiente

Conjunto de dados

Instalação do pacote

Dados e gráfico



Manipulação de dados: banco de dados e sumarização estatística usando R

Teoria em prática

Bloco 4

Anderson Emidio de Macedo Gonçalves




Refleta sobre a seguinte situação

Você é um analista de dados contratado por uma empresa de varejo on-line que está buscando maneiras de otimizar a gestão de estoques e melhorar a experiência do cliente. A empresa utiliza um banco de dados que armazena informações sobre pedidos, devoluções, tempo de entrega, avaliações dos clientes e inventário em tempo real. Recentemente, a empresa começou a explorar novas estratégias baseadas em análise de dados para prever demandas, gerenciar estoques e personalizar ofertas para os clientes.

Desafio:

- Identificar os dias e horários com maior volume de pedidos, ajudando a prever demandas e otimizar o estoque.
- Usar sumarização estatística para comparar o tempo médio de entrega dos pedidos em diferentes regiões antes e depois da implementação de uma nova estratégia logística.
- Investigar as avaliações dos clientes para entender a relação entre o tempo de entrega e a satisfação, utilizando R para criar gráficos que visualizem essa relação.
- Comparar os custos associados às diferentes estratégias de entrega e estoque.





Norte para a resolução

Por onde começar?

Passo 1: Coleta e organização dos dados

- Primeiro, você precisará acessar e organizar os dados relevantes, como históricos de pedidos, tempos de entrega, avaliações dos clientes e custos logísticos. Organize esses dados em um formato estruturado, utilizando um banco de dados ou tabelas em R para facilitar a análise.

Passo 2: Análise descritiva e sumarização estatística


- Utilize técnicas de sumarização estatística para calcular medidas descritivas (média, mediana, desvio-padrão) que ajudem a entender padrões nos dados, como identificar os dias e horários com maior volume de pedidos e comparar tempos médios de entrega antes e depois de mudanças logísticas.

Passo 3: Visualização dos dados


- Crie gráficos utilizando R, como histogramas para visualizar a distribuição dos tempos de entrega e scatter plots para analisar a relação entre tempo de entrega e satisfação do cliente. Essas visualizações ajudarão a identificar padrões e comunicar os resultados de forma clara.


Passo 4: Avaliação de custos e benefícios

- Compare os custos associados às estratégias logísticas antes e depois da implementação das novas técnicas. Avalie se as mudanças geraram uma economia significativa ou melhoria na satisfação do cliente, utilizando análises de custo-benefício para tomar decisões informadas sobre as práticas a serem adotadas.




Norte para a resolução






Norte para a resolução


Desafios que poderão surgir:




Qualidade e integração dos dados: dificuldade em consolidar dados de diferentes fontes com precisão e consistência.



Precisão nas previsões de demanda: complexidade em prever a demanda corretamente devido a fatores externos e imprevisíveis.



Resistência à mudança: possível resistência de funcionários e fornecedores ao adotar novas estratégias logísticas.



Custo-benefício das novas estratégias: desafio em garantir que os investimentos iniciais em novas práticas logísticas sejam economicamente viáveis.

Bons estudos!




Manipulação de dados: banco de dados e sumarização estatística usando R

Consolidando o aprendizado

Bloco 5

Anderson Emidio de Macedo Gonçalves



Consolidando o aprendizado

Durante este conteúdo programático, abordamos os seguintes assuntos:

- Curiosidades sobre banco de dados.
- Banco de dados: criação e manipulação de dados em uma base de dados.
- Sumarização estatística na análise de dados usando R.
- Situação-problema: otimização do processo de gestão de estoque para uma empresa de varejo on-line.



Quiz



No estudo da sumarização estatística, especialmente ao utilizar a linguagem R, é essencial compreender as diferentes formas de resumir e interpretar um conjunto de dados. Sendo assim, responda qual das seguintes opções NÃO é uma medida de tendência central utilizada na sumarização estatística em R?

Assinale a alternativa correta.

A

Média.

B

Moda.

C

Mediana.

D

Desvio-padrão.

Quiz



No estudo da sumarização estatística, especialmente ao utilizar a linguagem R, é essencial compreender as diferentes formas de resumir e interpretar um conjunto de dados. Sendo assim, responda qual das seguintes opções NÃO é uma medida de tendência central utilizada na sumarização estatística em R?

Assinale a alternativa correta.

A

Média.

B


Moda.

C

Mediana.

D

Desvio-padrão.




Quiz – Resolução

(D) Desvio-padrão.

A média, mediana e moda são todas medidas de tendência central que resumem o valor típico de um conjunto de dados. O desvio-padrão, por outro lado, é uma medida de dispersão que indica o grau de variação ou dispersão dos valores em relação à média. Portanto, a alternativa D é a correta.






Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!






Indicação de leitura 1

Esta obra, intitulada como: "Utilizando a Linguagem R", aborda vários assuntos determinantes para aprofundar seu aprendizado em sumarização estatística. O capítulo 9 - "Análise descritiva dos dados" demonstra uma análise descritiva dos dados por meio da tabulação das variáveis e cálculo de medidas descritivas como média, desvio-padrão, entre outras. No final do capítulo faça também os exercícios de fixação.

Referência

ALCOFORADO, Luciane F. **Utilizando a Linguagem R**. Rio de Janeiro: Alta Books, 2021.







Indicação de leitura 2

O livro: "Estatística Básica" aborda o conteúdo de medidas-resumo no capítulo 3. Conteúdos como: médias de dispersão, box plots, gráficos de simetria, quantis empíricos e transformações são abordados durante o capítulo. Não deixe de conferir e compreender um pouco mais sobre este conteúdo por meio desta indicação de leitura.

Referência

MORETTIN, Pedro A.; BUSSAB, Wilton de O. **Estatística básica**. 9.ed. São Paulo: Saraiva, 2017.





Referências

ANDRADE, E. L. **Introdução à pesquisa operacional:** métodos e modelos para análise de decisões. 4. ed. Rio de Janeiro: LTC, 2009.

ALCOFORADO, Luciane F. **Utilizando a Linguagem R.** Rio de Janeiro: Alta Books, 2021. [Minha Biblioteca].

ELMASRI, R.; NAVATHE, S. B. **Sistemas de banco de dados.** 6. ed. São Paulo: Pearson Addison Wesley, 2011.

FÁVERO, Luiz P. **Análise de Dados.** Rio de Janeiro: Elsevier, 2015. [Minha Biblioteca].

MORETTIN, Pedro A.; BUSSAB, Wilton de O. **Estatística básica.** 9. ed. São Paulo: Saraiva, 2017.

NETO, Pedro Luiz de Oliveira C. **Estatística.** 2. ed. São Paulo: Blucher, 2006.

SICSÚ, Abraham L.; DANA, Samy. **Estatística aplicada:** análise exploratória de dados. São Paulo: Saraiva, 2012.

VIEIRA, S. **Estatística básica.** 2. ed. São Paulo: Cengage Learning, 2018.





Bons estudos!