



TÉCNICAS ESTATÍSTICAS: TEORIA E PRÁTICA (R PROGRAMMING)

Anderson Emidio de Macedo Gonçalves

TÉCNICAS ESTATÍSTICAS: TEORIA E PRÁTICA (R PROGRAMMING)

1ª edição

Londrina
Editora e Distribuidora Educacional S.A.
2024

© 2024 por Editora e Distribuidora Educacional S.A.

Todos os direitos reservados. Nenhuma parte desta publicação poderá ser reproduzida ou transmitida de qualquer modo ou por qualquer outro meio, eletrônico ou mecânico, incluindo fotocópia, gravação ou qualquer outro tipo de sistema de armazenamento e transmissão de informação, sem prévia autorização, por escrito, da Editora e Distribuidora Educacional S.A.

Diretora Sr. de Pós-graduação & OPM

Silvia Rodrigues Cima Bizatto

Conselho Acadêmico

Alessandra Cristina Fahl

Ana Carolina Gulelmo Staut

Camila Braga de Oliveira Higa

Camila Turchetti Bacan Gabiatti

Giani Vendramel de Oliveira

Gislaine Denisale Ferreira

Henrique Salustiano Silva

Juliana Schiavetto Dauricio

Juliane Raniro Hehl

Mariana Gerardi Mello

Nirse Ruscheinsky Breternitz

Coordenador

Camila Turchetti Bacan Gabiatti

Revisor

Edneuci Denise Audacio

Editorial

Beatriz Meloni Montefusco

Márcia Regina Silva

Paola Andressa Machado Leal

Rosana Silverio Siqueira

Dados Internacionais de Catalogação na Publicação (CIP)

G635r Gonçalves, Anderson Emidio de Macedo
Técnicas estatísticas: teoria e prática (R Programming)/
Anderson Emidio de Macedo Gonçalves, – Londrina:
Editora e Distribuidora Educacional S.A., 2024.
32 p.

ISBN 978-65-5903-728-5

1. Classificação de resíduos. 2. Logística reversa. 3.
Reciclagem. I. Título.

CDU 628.4

Raquel Torres – CRB 8/10534

2024

Editora e Distribuidora Educacional S.A.
Avenida Paris, 675 – Parque Residencial João Piza
CEP: 86041-100 — Londrina — PR
Homepage: <https://www.cogna.com.br/>



TÉCNICAS ESTATÍSTICAS: TEORIA E PRÁTICA (R PROGRAMMING)

SUMÁRIO

Apresentação da disciplina	05
Histórico, Conceitos e Estrutura da Linguagem R	07
Estatística Descritiva, Hipóteses, Correlação e Causalidade e Regressões lineares	19
Visualização de Dados: Gráficos para análise de dados com a linguagem R e análise exploratória.	39
Manipulação de Dados: Banco de dados e sumarização estatística usando R.	56

Apresentação da disciplina

A disciplina de *Técnicas Estatísticas: Teoria e Prática (R Programming)* oferece uma oportunidade única de desenvolver competências essenciais na análise de dados utilizando uma das ferramentas mais poderosas e versáteis disponíveis: a linguagem R. Ao longo deste conteúdo, você será introduzido aos conceitos fundamentais de estatística e às aplicações práticas dessas técnicas em cenários reais.

Assim, um de nossos principais objetivos é capacitar os alunos para compreenderem a teoria estatística subjacente às análises quantitativas, além de aplicar esses conhecimentos em situações práticas.

Neste conteúdo também enfatizamos a importância da sumarização estatística, uma técnica que transforma dados brutos em informações claras e compreensíveis. Por meio da linguagem R, você aprenderá como calcular medidas descritivas, visualizar dados de maneira eficaz e comunicar resultados de forma que até mesmo pessoas sem especialização possam compreendê-las. Essa prática é essencial em um mundo no qual a habilidade de interpretar e apresentar dados de forma precisa e acessível é cada vez mais valorizada.

Além disso, os estudantes serão encorajados a explorar a visualização de dados como uma forma de identificar padrões, tendências e inovações significativas. Com a utilização de pacotes como ggplot2, você poderá criar gráficos que ilustram os dados de maneira clara e que ajudam a contar histórias por trás dos números, facilitando a comunicação dos resultados de uma análise estatística.

Por fim, destacaremos a importância de selecionar as ferramentas e os métodos adequados para cada situação de análise. A linguagem R, com sua vasta gama de pacotes e recursos, será apresentada como uma escolha ideal para conduzir análises estatísticas de ponta, possibilitando que você adquira a capacidade de abordar desafios complexos de maneira eficiente e precisa.

Ao concluir esta disciplina, você estará preparado para enfrentar os desafios da análise de dados no mundo moderno. Então, convidamos você a embarcar nesta jornada de descoberta e aprendizado, explorando o fascinante universo das técnicas estatísticas com “R”. Venha se preparar para o futuro, onde a capacidade de analisar e interpretar dados será uma habilidade indispensável.

Bons estudos!



Histórico, Conceitos e Estrutura da Linguagem R

Autoria: Anderson Emidio de Macedo Gonçalves

Leitura crítica: Edneuci Denise Audacio

Objetivos

- Apresentar a evolução histórica da estatística e da linguagem R e os seus principais conceitos teóricos e suas aplicações práticas.
- Ensinar a estrutura básica da linguagem R.
- Desenvolver habilidades práticas para realizar análises estatísticas e manipulação de dados usando R.

1. Introdução

A estatística é uma área fundamental para a análise e interpretação de dados, sendo aplicada também em diversas áreas do conhecimento, desde as ciências sociais até as ciências exatas. Com o crescimento exponencial da quantidade de dados gerados diariamente, a habilidade de analisar e extrair informações valiosas a partir desses dados se tornou indispensável. Neste Tema, vamos introduzir os conceitos básicos e os históricos da estatística, com foco em compreender como essa ciência evoluiu ao longo do tempo e como suas ferramentas podem ser aplicadas para resolver problemas reais.

Além da teoria estatística, é importante saber dominar ferramentas que facilitam a aplicação desses conceitos na prática, como a linguagem R, uma das ferramentas mais poderosas para análise estatística e manipulação de dados. Ao longo deste material, você conhecerá a estrutura da linguagem R, explorando seus principais comandos e como eles podem ser utilizados para realizar análises estatísticas complexas de maneira eficiente.

Ao final deste estudo, você não apenas terá conhecimento teórico, mas também as habilidades práticas necessárias para aplicar a estatística e a linguagem R em diversos contextos. Preparado para prosseguir e enriquecer o seu aprendizado? Então, vamos lá!

2. Estatística e linguagem R: apresentação, histórico e principais conceitos

A estatística surgiu da necessidade de coletar e analisar dados para tomar decisões informadas. As raízes dessa ciência remontam à Antiguidade, mas foi no século XVII que ela começou a se desenvolver de

maneira mais sistemática, com contribuições significativas de estudiosos como John Graunt e William Petty. Com o avanço da matemática no século XVIII, a estatística passou a incorporar técnicas mais sofisticadas, evoluindo continuamente até os dias atuais, onde o seu uso é indispensável em inúmeras áreas.

Segundo Vieira (2013, p. 1), a estatística é “a ciência que fornece os princípios e a metodologia para coleta, organização, apresentação, resumo, análise e interpretação de dados”. Ademais, os principais conceitos da estatística incluem a coleta, a organização, a análise, a interpretação e a apresentação de dados. A coleta de dados envolve a obtenção de informações relevantes para o estudo, enquanto a organização se refere ao processo de estruturar esses dados de maneira lógica e coerente. A análise de dados utiliza métodos estatísticos para identificar padrões e tendências, e a interpretação é a etapa na qual os resultados são avaliados para tirar conclusões significativas. Por fim, a apresentação de dados diz respeito à comunicação dos resultados de maneira clara e eficaz.

Nesse sentido, a estatística faz parte da área de estudo de pesquisa operacional, que oferece ferramentas para identificar problemas por meio de seus sintomas e procurar solucioná-los para tomar a decisão correta (Andrade, 2009).

Aplicada na programação, a estatística é uma ferramenta fundamental para realizar análises detalhadas, criar visualizações informativas e desenvolver modelos de *machine learning*. A seguir, vamos explorar como a estatística pode ser usada em cada um desses tópicos:

- **Análise de Dados**

Descrição estatística: é usada para resumir e organizar dados. As ferramentas como média, mediana, moda, desvio padrão e quartis

ajudam a entender a distribuição e as características principais dos dados. Isso permite identificar padrões, tendências e *outliers*, fornecendo uma visão geral dos dados antes de realizar análises mais complexas.

Inferência estatística: possibilita tirar conclusões sobre uma população com base em uma amostra. As técnicas como testes de hipóteses, intervalos de confiança e análise de variância (ANOVA) são usadas para avaliar se os padrões observados nos dados são significativos ou se poderiam ter ocorrido por acaso. Esse processo é crucial para validar suposições e tomar decisões baseadas em dados.

Análise de correlação: mede a força e a direção da relação linear entre duas variáveis. Nesse caso, identificar correlações ajuda a entender como as variáveis estão relacionadas e pode guiar a construção de modelos preditivos ou o reconhecimento de relações causais potenciais.

• Visualização de Dados

Gráficos estatísticos: visualizações como histogramas, *box plots*, *scatter plots* e gráficos de barras são essenciais para entendermos a distribuição dos dados e identificarmos padrões. Por meio desses gráficos, é possível comunicar informações complexas de maneira clara e intuitiva, facilitando a interpretação dos dados.

Análise exploratória de dados (EDA): utiliza visualizações para explorar dados de forma não formalizada, ajudando a descobrir estruturas subjacentes, detectar *outliers* e testar hipóteses. Por meio de gráficos interativos e estáticos, os analistas podem iterar rapidamente sobre diferentes aspectos dos dados para gerar insights valiosos.

Gráficos de séries temporais: são usados para visualizar dados ao longo do tempo, como tendências e sazonalidades. Eles nos ajudam a identificar padrões temporais que podem ser cruciais para previsões

futuras e para a compreensão do comportamento dos dados ao longo do tempo.

- ***Machine Learning***

Preparação dos dados: a estatística é usada para preparar os dados para o treinamento de modelos de *machine learning*. Isso inclui a normalização, que ajusta as escalas das variáveis, o tratamento de valores ausentes e a criação de variáveis dummy para variáveis categóricas. Essas etapas são essenciais para garantir que os dados estejam em um formato adequado para os algoritmos de *machine learning*.

Modelagem preditiva: modelos estatísticos como regressão linear e regressão logística são frequentemente usados em *machine learning* para prever valores e classificar dados. A estatística fornece a base matemática para esses modelos, permitindo que os algoritmos aprendam a partir dos dados e façam previsões precisas.

Avaliação de modelos: estatísticas como precisão, recall, F1-score e AUC-ROC são usadas para avaliar a performance de modelos de *machine learning*. Essas métricas ajudam a determinar o quão bem um modelo está performando e a identificar áreas de melhoria. A avaliação de modelos de forma estatística é crucial para garantir que as previsões sejam confiáveis e úteis.

Em resumo, a estatística oferece um forte conjunto de ferramentas para coletar, analisar e interpretar dados. Assim, entender esses conceitos e saber aplicá-los na prática é essencial para tomar decisões informadas e baseadas em evidências em diversas áreas.

A linguagem R foi desenvolvida na década de 1990 por Ross Ihaka e Robert Gentleman na Universidade de Auckland, na Nova Zelândia.

Inspirada no ambiente estatístico S, criado por John Chambers na Bell Laboratories, R foi projetada para ser uma ferramenta de software livre, permitindo a colaboração e contribuição de uma vasta comunidade de usuários. Desde então, R se tornou uma das linguagens mais populares para a análise estatística e ciência de dados, devido à sua flexibilidade, capacidade de expansão e a grande quantidade de pacotes disponíveis para diferentes tipos de análise.

Na linguagem R, esses conceitos são aplicados por meio de uma série de comandos e funções específicas. Essa linguagem permite a importação e a manipulação de grandes conjuntos de dados, a realização de análises estatísticas complexas e a criação de visualizações gráficas de alta qualidade. Nesse contexto, comandos como `"read.csv"` para leitura de arquivos, `"summary"` para obter resumos estatísticos e `"plot"` para gerar gráficos são alguns exemplos das funcionalidades básicas que R oferece aos usuários.

A combinação da estatística com a linguagem R gera uma ferramenta poderosa para a análise de dados, permitindo que usuários de diversas áreas do conhecimento extraiam informações importantes de seus dados. Contudo, entender o histórico e os principais conceitos dessas ferramentas é fundamental para utilizá-las de maneira eficaz. Com o domínio da teoria estatística e da prática com a linguagem R, é possível realizar análises detalhadas e precisas, contribuindo para a tomada de decisões informadas e a geração de novos conhecimentos.

3. Principais comandos e estrutura da linguagem R

A linguagem R é uma das ferramentas mais poderosas, sendo amplamente utilizadas no campo da estatística e da análise de dados.

Desenvolvida inicialmente por estatísticos para análise estatística e gráficos, R evoluiu para uma linguagem de programação completa, oferecendo uma vasta gama de funcionalidades para manipulação, visualização e modelagem de dados. Neste texto, exploraremos os principais comandos e a estrutura básica da linguagem R.

Estrutura Básica da Linguagem R

R é uma linguagem interpretada e interativa, o que significa que os comandos são executados à medida que são digitados e podem ser modificados e reexecutados conforme necessário. A estrutura básica de um script em R inclui:

1. Comentários: começam com o símbolo # e são ignorados pelo interpretador. Eles são úteis para documentar o código e explicar seu funcionamento.

Exemplo:

```
# Este é um comentário em R
```

2. Atribuição de variáveis: variáveis em R são atribuídas usando o operador <- ou =. O nome da variável à esquerda recebe o valor à direita.

Exemplo:

```
idade <- 30
```

3. Funções: funções em R são chamadas usando o nome da função seguido por parênteses (), que podem conter argumentos para a função.

Exemplo:

```
média <- mean(dados)
```

4. Estruturas de controle: R suporta estruturas de controle como *if*, *else*, *for*, *while* e *repeat*, que permitem controlar o fluxo de execução do programa com base em condições ou iterações.

Exemplo:

```
if (idade >= 18) {  
  mensagem <- "É maior de idade."  
} else {  
  mensagem <- "É menor de idade."  
}
```

5. Instalação de pacotes: no exemplo, é baixado e instalado o pacote "ggplot2" a partir do repositório de pacotes, o que vai permitir o uso de funções para a visualização de dados no R.

Exemplo de instalação de pacote:

```
install.packages("ggplot2")
```

Exemplo de carregamento de pacote:

```
library(ggplot2)
```

Conforme os exemplos anteriores, podemos perceber que a estrutura básica da linguagem R proporciona uma boa base para realizar análises estatísticas ricas em detalhes. Com comandos intuitivos para a manipulação de dados, funções estatísticas completas e capacidades avançadas de visualização, R permite que os usuários transformem dados rasos em informações completas. A flexibilidade da linguagem, combinada com a grande possibilidade de pacotes disponíveis, torna R uma ferramenta indispensável para estatísticos, cientistas de dados e profissionais em áreas afins, facilitando desde tarefas simples, como atribuição de variáveis, até modelagens estatísticas complexas.

Principais comandos em R

1. Manipulação de dados:

- `c()`: cria vetores combinando seus argumentos.
- `data.frame()`: cria um *data frame* a partir de vetores ou listas.
- `subset()`: filtra linhas ou colunas de um *data frame* com base em condições.

2. Estatísticas descritivas:

- `mean()`: calcula a média dos valores.
- `median()`: calcula a mediana dos valores.
- `summary()`: produz um resumo estatístico dos dados.
- `sd()`: calcula o desvio padrão dos valores.

3. Gráficos e visualizações:

- `plot()`: cria gráficos básicos.
- `hist()`: cria histogramas.
- `boxplot()`: cria *box plots*.
- `ggplot2`: pacote para criar gráficos elegantes e personalizados.

4. Modelagem estatística:

- `lm()`: ajusta modelos de regressão linear.
- `glm()`: ajusta modelos de regressão generalizados.
- `anova()`: realiza análise de variância.
- `cor()` e `cor.test()`: calcula correlações entre variáveis.

Agora, veremos um exemplo de como a estrutura e o comando da linguagem R podem ser utilizadas na análise de dados. Suponha que temos um conjunto de dados `dados.csv` com informações sobre salários e anos de experiência de funcionários. Podemos utilizar R para carregar, analisar e visualizar esses dados, além de ajustar um modelo de regressão para prever salários com base na experiência. Observe:

Figura 1 - Modelo de aplicação de imagens

```
1  dados <- read.csv("dados.csv")
2
3  # Resumo estatístico
4  summary(dados)
5
6  # Gráfico de dispersão
7  plot(dados$experiencia, dados$salario,
8      xlab = "Anos de Experiência", ylab = "Salário",
9      main = "Relação entre Experiência e Salário")
10
11 # Ajustar modelo de regressão linear
12 modelo <- lm(salario ~ experiencia, data = dados)
13 summary(modelo)
14
```

Fonte: elaborada pelo autor.

O código fornecido é um exemplo de como realizar uma análise de dados em R, começando com a importação de um conjunto de dados a partir de um arquivo CSV chamado "dados.csv". Após carregar os dados em um data frame, o código gera um resumo estatístico que oferece uma visão geral das principais características dos dados, como médias e distribuições. Em seguida, cria-se um gráfico de dispersão para visualizar a relação entre os anos de experiência e o salário dos indivíduos no conjunto de dados, com eixos devidamente rotulados e um título descritivo. Posteriormente, ajusta-se um modelo de regressão linear para examinar a relação entre a experiência (variável independente) e o salário (variável dependente). O modelo é então resumido para fornecer detalhes como coeficientes, significância estatística e outras métricas importantes, ajudando a avaliar a força e a natureza da relação entre as duas variáveis.

4. Conclusão

Em suma, a linguagem R é uma ferramenta indispensável para análise estatística e científica de dados, oferecendo uma estrutura flexível; além da grande variedade de funcionalidades por meio de seus comandos e pacotes, que vão desde a manipulação inicial dos dados até a modelagem estatística avançada e a visualização de resultados. R se destaca como uma escolha preferida para profissionais que lidam com grandes volumes de dados e desejam extrair dados com eficiência. Ter domínio sobre os comandos e as estruturas essenciais em R capacita os analistas a explorar, modelar e interpretar dados de forma precisa.

Referências

ANDRADE, E. L. **Introdução à pesquisa operacional**: métodos e modelos para análise de decisões. 4. ed. Rio de Janeiro: LTC, 2009.

ALCOFORADO, L. F. **Utilizando a Linguagem R**. Rio de Janeiro: Alta Books, 2021. [Minha Biblioteca]

FÁVERO, L. P. **Análise de dados**. Rio de Janeiro: Elsevier, 2015. [Minha Biblioteca].

SICSÚ, A. L.; DANA, S. **Estatística aplicada**: análise exploratória de dados. São Paulo: Saraiva, 2012.

VIEIRA, S. **Estatística básica**. 2. ed. São Paulo: Cengage Learning, 2018.

Estatística Descritiva, Hipóteses, Correlação e Causalidade e Regressões lineares

Autoria: Anderson Emidio de Macedo Gonçalves

Leitura crítica: Edneuci Denise Audacio

Objetivos

- Compreender e aplicar as medidas de tendência central para resumir e interpretar conjuntos de dados de forma eficaz.
- Entender o conceito de desvio padrão e sua importância na medição da variabilidade dos dados.
- Desenvolver a capacidade de construir e interpretar intervalos de confiança, formular e testar hipóteses, analisar a correlação entre variáveis, distinguir correlação de causalidade e aplicar regressões lineares para modelar relações entre variáveis.

1. Introdução

A estatística é uma ferramenta essencial para transformar dados em informações relevantes. Com isso, neste Tema, vamos explorar três pilares dessa ciência.

O primeiro deles é a estatística descritiva: média, mediana e moda, em que vamos descobrir como resumir e interpretar conjuntos de dados utilizando as principais medidas de tendência central.

O segundo pilar é o desvio padrão e os conceitos de amostra, no qual aprenderemos a avaliar a variabilidade dos dados e a importância de trabalhar com amostras representativas para inferir sobre populações maiores.

Por fim, exploraremos os intervalos de confiança, hipóteses, correlação, causalidade e regressões lineares, em que será possível desenvolvermos habilidades para estimar a precisão de análises, testar hipóteses, identificar relações entre variáveis e modelar essas relações para previsões precisas.

Prepare-se para adquirir conhecimentos que são essenciais em diversas áreas, aprimorando sua capacidade de análise e tomada de decisões com base em dados.

2. Estatística descritiva: média, mediana e moda

Para enfrentar a maioria dos desafios globais, é essencial ter acesso a dados ou informações pertinentes. Mas que tipo de informação é necessária e em qual quantidade? E depois de obtê-los, como podemos



interpretá-los e utilizá-los de maneira eficaz? Nesse contexto, a estatística é crucial, pois ela liga os dados ao problema a ser resolvido, identifica as informações necessárias e define os métodos adequados de coleta. Além disso, a estatística capacita pesquisadores, profissionais e cientistas a extrair conclusões significativas desses dados, comunicando-as de forma clara e acessível para todos. Profissionais de várias áreas, como cientistas sociais, economistas, engenheiros e agrônomos, utilizam métodos estatísticos para aumentar a eficiência em suas respectivas disciplinas.

É necessário “trabalhar os dados para transformá-los em informações, para compará-los com outros resultados, ou ainda para julgar sua adequação a alguma teoria” (Bussab; Morettin, 2003, p. 1). Já Montgomery e Runger (2003, p. 14) destacam que:

[...] sumários e apresentações de dados bem estruturados são essenciais para um bom julgamento estatístico, pois permitem focar nas características importantes dos dados ou discernir o tipo de modelo que deve ser usado para resolver o problema em questão.

As medidas de tendência central nos ajudam a compreender a concentração dos dados e a identificar qual valor representa melhor a “média” de um conjunto de dados. Desse modo, elas funcionam como um ponto de referência, permitindo resumir grandes volumes de dados em um único valor representativo. Tais medidas são denominadas assim porque indicam um ponto onde os dados tendem a se agrupar, geralmente refletindo o centro da distribuição.

Nesse sentido, Reis (1998), afirma que:

O valor a escolher depende das características dos dados. Por exemplo, num estudo agrícola sobre a produção de trigo por hectare de terra arável podemos estar interessados em conhecer o valor mais elevado da produtividade do solo agrícola das várias explorações analisadas.

Num outro estudo sobre os resultados de uma turma de estudantes universitários talvez seja mais interessante conhecer o resultado médio obtido por 50% dos estudantes. Num outro estudo sobre os rendimentos per capita dos países da CEE, a comparação entre países será facilitada se calcularmos os rendimentos médios de cada país.

Neste tópico ainda, vamos examinar detalhadamente três medidas fundamentais de tendência central: média, mediana e moda. Para isso, utilizaremos exemplos práticos para demonstrar como essas medidas funcionam na prática e como podem ser interpretadas.

1. Média: é a medida de tendência central mais comum, calculada somando todos os valores de um conjunto de dados e dividindo pelo número total de observações. Por exemplo, considere as notas de um aluno em cinco provas: 85, 90, 78, 92, e 88.

- Para calcular a média dessas notas, primeiro somamos todos os valores:

$$85 + 90 + 78 + 92 + 88 = 433$$

- Em seguida, dividimos pelo número total de observações, que nesse caso é 5:

$$433 \div 5 = 86,6$$

- ▶ Portanto, a média das notas desse aluno é 86,6. Isso significa que, em média, a nota do aluno nessas cinco provas é 86,6.

2. Mediana: é o valor que separa um conjunto de dados ordenado em duas metades, com metade dos valores situados abaixo e metade acima desse ponto. Para determinar a mediana, primeiro organizamos os dados em ordem crescente ou decrescente. Se o número de observações for ímpar, a mediana é o valor central.

Mas se o número de observações for par, a mediana é calculada como a média dos dois valores centrais. Observe o seguinte exemplo que ilustra a medida central mediana.

- Considere os salários mensais (em reais) de um grupo de sete pessoas:

2.500,00 - 3.200,00 - 2.700,00 - 4.000,00 - 2.900,00 - 3.500,00 e 3.100,00.

- Primeiro, ordenamos os salários em ordem crescente:

2500,00 - 2.700,00 - 2.900,00 - 3.100,00 - 3.200,00 - 3.500,00 - 4.000,00

- Como temos um número ímpar de observações (7), a mediana é o valor central, que é o quarto valor na lista ordenada:

$$\text{Mediana} = 3.100,00$$

- Portanto, a mediana dos salários desse grupo é 3100 reais, indicando que metade dos salários é menor que 3100 reais e a outra metade é maior.

3. Moda: é o valor que aparece com maior frequência em um conjunto de dados. Um conjunto de dados pode ter uma única moda (unimodal), duas modas (bimodal), várias modas (multimodal) ou nenhuma moda se todos os valores ocorrerem com a mesma frequência (amodal). Segundo Guedes *et al.* (2005, p. 31), a moda é especialmente útil quando se precisa de uma medida de tendência central rapidamente. Além disso, um ponto positivo da moda é que ela não é influenciada por valores extremos no conjunto de dados. Nesse contexto, observe o exemplo a seguir para que esse conceito fique mais claro:

- Suponha que estamos analisando as alturas (em centímetros) de um grupo de dez pessoas:

165, 170, 160, 170, 175, 170, 165, 160, 165, 170

- Para determinar a moda das alturas, identificamos o valor que ocorre com mais frequência. Nesse caso, a altura 170 cm aparece três vezes, enquanto 160 cm e 165 cm aparecem duas vezes cada. Portanto, a moda das alturas deste grupo é 170 cm.
- ▶ Assim, a moda indica que 170 cm é a altura mais frequente entre as pessoas analisadas.

3. Desvio padrão e conceitos de amostra

O desvio padrão e os conceitos de amostra são fundamentais para a estatística, oferecendo informações importantes sobre a variabilidade dos dados e a representatividade das informações obtidas a partir de uma parte de uma população maior. Então, compreender esses conceitos não apenas permite uma análise mais precisa dos dados, mas também ajuda na interpretação correta das conclusões estatísticas.

O desvio padrão é uma medida que quantifica a dispersão dos valores em relação à média de um conjunto de dados. Ele indica o quanto os dados estão espalhados ao redor da média. Com isso, um desvio padrão maior significa que os valores estão mais dispersos, enquanto um desvio padrão menor indica que os valores estão mais próximos da média. O cálculo do desvio padrão envolve várias etapas: primeiro, calcula-se a diferença entre cada valor e a média; em seguida, eleva-se essas diferenças ao quadrado; calcula-se a média desses quadrados; e, por fim, tira-se a raiz quadrada desse resultado. Isso resulta em uma medida numérica que ajuda a interpretar a variabilidade dos dados de maneira

mais precisa. Vamos considerar um exemplo prático para ilustrar o desvio padrão:

- Suponha que temos as seguintes idades de um grupo de cinco pessoas: 20, 25, 30, 35 e 40 anos.

Passo 1: calculamos a média das idades:

$$20 + 25 + 30 + 35 + 40 \div 5 = 150 \div 5 = 30$$

Passo 2: em seguida, calculamos o desvio de cada idade em relação à média:

$$\text{Para 20 anos: } 20 - 30 = -10$$

$$\text{Para 25 anos: } 25 - 30 = -5$$

$$\text{Para 30 anos: } 30 - 30 = 0$$

$$\text{Para 35 anos: } 35 - 30 = 5$$

$$\text{Para 40 anos: } 40 - 30 = 10$$

Passo 3: elevamos esses desvios ao quadrado:

$$(-10)^2 = 100$$

$$(-5)^2 = 25$$

$$0^2 = 0$$

$$5^2 = 25$$

$$10^2 = 100$$

Passo 4: calculamos a média dos quadrados dos desvios:

$$100 + 25 + 0 + 25 + 100 \div 5 = 250 \div 5 = 50$$

Passo 5: por fim, tiramos a raiz quadrada dessa média:

$$\sqrt{50} \approx 7,07$$

Portanto, o desvio padrão das idades desse grupo é de aproximadamente 7,07 anos. Isso indica que, em média, as idades variam cerca de 7,07 anos em torno da média de 30 anos.

Quando lidamos com grandes populações, muitas vezes não é prático ou viável analisar todos os indivíduos. Então, utilizamos amostras que são subconjuntos representativos da população maior. A qualidade da amostra, nesse caso, é fundamental para garantir que as conclusões tiradas a partir dela sejam generalizáveis para toda a população. Conceitos estatísticos como aleatoriedade na seleção da amostra, tamanho adequado da amostra e técnicas de amostragem estratificada ou por conglomerados são fundamentais para garantir a validade das inferências estatísticas.

- Suponha que você é um pesquisador interessado em conhecer a altura média dos estudantes de uma universidade com 10.000 alunos. Analisar a altura de todos os 10.000 alunos seria muito trabalhoso e demorado, então você decide utilizar uma amostra representativa. Dessa forma, observe o passo a passo para analisar esses dados por meio de amostra:
- 1. Definir a população:** todos os 10.000 alunos da universidade.
 - 2. Escolher o tamanho da amostra:** você decide que uma amostra de 100 alunos será suficiente para obter uma estimativa precisa da altura média.
 - 3. Método de amostragem:** você escolhe um método de amostragem aleatória simples para garantir que cada aluno tenha a mesma probabilidade de ser selecionado.

- 4. Coletar dados:** você utiliza um gerador de números aleatórios para selecionar 100 alunos da lista total de estudantes. Suponha que as alturas (em cm) dos 100 alunos selecionados sejam as seguintes:

160, 165, 170, 175, 160, 165, 170, 180, 150, 155, ...

(Os dados reais conteriam 100 valores, mas para simplificação, vamos usar apenas 10 valores aqui).

5. Calcular estatísticas descritivas:

Média

$$160 + 165 + 170 + 175 + 160 + 165 + 170 + 180 + 150 + 155 \div 10 = \\ 1650 \div 10 = 165 \text{ cm}$$

Desvio padrão simplificado

- Calcule a média dos quadrados dos desvios.

$$\text{Desvio-padrão} \approx (160 - 165)^2 + (165 - 165)^2 + \dots (155 - 165)^2 \approx \\ \sqrt{62.5} \approx 7.91 \text{ cm}$$

6. Inferência estatística:

Intervalo de confiança para a média:

- Suponha que o intervalo de confiança de 95% para a média é calculado usando a fórmula:

$$\text{Média} \pm Z \times \frac{\text{Desvio Padrão}}{\sqrt{n}} \\ 165 \pm 1.96 \times \frac{7.91}{\sqrt{10}} \approx 165 \pm 4.9 \\ \text{Intervalo de Confiança} = [160.1, 169.9]$$

Com base na análise da amostra de 100 alunos, você pode estimar que a altura média dos estudantes da universidade está entre 160,1 cm e 169,9 cm com 95% de confiança. Essa amostra representativa permitiu fazer inferências sobre a população inteira sem a necessidade de medir a altura de todos os 10.000 alunos, demonstrando a eficácia da análise de dados de amostra.

Concluindo, o desvio padrão e os conceitos de amostra desempenham papéis de grande importância na análise estatística. Enquanto o desvio padrão fornece uma medida quantitativa da dispersão dos dados em torno da média, os conceitos de amostra garantem que as conclusões estatísticas sejam baseadas em evidências representativas e confiáveis. Assim, dominar esses conceitos não apenas fortalece a capacidade de interpretar dados de maneira eficaz, mas também capacita os profissionais de diversas áreas a tomar decisões informadas com base em análises estatísticas sólidas.

4. Estratégias avançadas: intervalos de confiança, hipóteses, correlação, causalidade e regressões lineares

No campo da estatística, algumas estratégias são essenciais para realizar análises mais profundas, entre elas os intervalos de confiança, os testes de hipóteses, a correlação, a causalidade e as regressões lineares desempenham papéis fundamentais. Elas permitem aos pesquisadores descrever dados, fazer inferências, testar teorias, explorar relações entre variáveis e prever tendências futuras. Neste tópico, exploraremos brevemente esses conceitos e demonstraremos alguns deles por meio de exemplos.

Intervalos de confiança

Intervalos de confiança são um tipo de ferramenta estatística que fornece uma faixa de valores dentro da qual podemos esperar que um parâmetro populacional, como a média ou a proporção, se encontre com uma certa probabilidade. Em outras palavras, um intervalo de confiança nos dá uma estimativa do valor de um parâmetro desconhecido e a certeza (ou confiança) de que o valor verdadeiro está dentro dessa faixa. O intervalo de confiança, portanto, é composto de dois limites: o limite inferior e o limite superior. Esses limites são calculados a partir dos dados da amostra e de um nível de confiança especificado (geralmente 95% ou 99%). Este último indica a probabilidade de que o intervalo calculado contenha o parâmetro populacional verdadeiro.

Hipóteses

Em estatística, uma hipótese é uma suposição ou afirmação que pode ser testada usando dados. Na análise de dados, as hipóteses são declarações que fazemos sobre a população com base em uma amostra, e depois testamos essas declarações para ver se elas são verdadeiras ou não. Paes (1998, p. 575), afirma que:

Podemos definir como hipóteses questões levantadas relacionadas ao problema em estudo e que, se respondidas, podem ajudar a solucioná-lo. O papel fundamental da hipótese na pesquisa científica é sugerir explicações para os fatos. Uma vez formuladas as hipóteses, estas devem ser comprovadas ou não através do estudo com a ajuda de testes estatísticos. Num teste estatístico são formuladas duas hipóteses chamadas hipótese nula (H_0) e hipótese alternativa (H_A). Hipótese nula é aquela que é colocada à prova, enquanto que a hipótese alternativa é aquela que será considerada como aceitável, caso a hipótese nula seja rejeitada.

Como citado acima, existem dois tipos principais de hipóteses:

1. **Hipótese nula (H_0):** é uma afirmação que indica que não há efeito ou diferença. Geralmente, é uma declaração de “nenhuma mudança” ou “nenhuma relação”.
2. **Hipótese alternativa (H_A):** é uma afirmação que sugere a existência de um efeito ou diferença. Contrapõe a hipótese nula.

O processo de teste de hipóteses envolve coletar dados e usar uma estatística de teste para decidir se há evidência suficiente para rejeitar a hipótese nula em favor da hipótese alternativa.

Correlação

A correlação é uma medida estatística que descreve a força e a direção do relacionamento linear entre duas variáveis. Ela quantifica a maneira como as mudanças em uma variável estão associadas com as mudanças em outra variável. Contudo, essa correlação pode ser positiva, negativa ou nula:

- **Correlação positiva:** quando uma variável aumenta, a outra também tende a aumentar. Por exemplo, há uma correlação positiva entre a altura e o peso das pessoas – em geral, pessoas mais altas tendem a pesar mais.
- **Correlação negativa:** quando uma variável aumenta, a outra variável tende a diminuir. Por exemplo, há uma correlação negativa entre o número de horas de exercício e o peso corporal – em geral, quanto mais uma pessoa se exercita, menos ela pesa.
- **Correlação nula:** não há uma relação linear discernível entre as duas variáveis. As mudanças em uma variável não estão associadas de maneira previsível com as mudanças na outra variável.

O coeficiente de correlação, frequentemente representado pela letra “r”, é um número que varia entre -1 e 1:

- $r = 1$: correlação positiva perfeita.
- $r = -1$: correlação negativa perfeita.
- $r = 0$: nenhuma correlação linear.

O coeficiente de correlação mais comum é o **coeficiente de correlação de Pearson**, que é calculado usando a fórmula:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Em que:

- X_i Y_i são os valores das variáveis X e Y .
- $\bar{X}$ e $\bar{Y}$ são as médias das variáveis X e Y .

Causalidade

A causalidade se refere a uma relação de causa e efeito entre duas ou mais variáveis. Quando afirmamos que uma variável causa uma mudança em outra, estamos estabelecendo um vínculo causal.

Diferentemente da correlação, que apenas indica que duas variáveis estão associadas, a causalidade sugere que mudanças em uma variável resultam diretamente em mudanças na outra.

Para estabelecer causalidade, é necessário mais do que apenas observar uma correlação. Algumas das abordagens comuns incluem:

- Experimentos controlados: em experimentos controlados, os pesquisadores manipulam uma variável (variável independente) e observam o efeito dessa manipulação em outra variável (variável dependente), enquanto controlam outras variáveis que possam influenciar os resultados.

Por exemplo, em um estudo clínico sobre um novo medicamento, um grupo de pacientes recebe o medicamento (grupo experimental) e outro grupo recebe um placebo (grupo controle). Se o grupo experimental mostrar melhorias significativas em relação ao grupo controle, isso sugere uma relação causal.

- Estudos longitudinais: observam as mesmas variáveis ao longo do tempo. Se uma mudança na variável independente preceder consistentemente uma mudança na variável dependente, pode haver uma sugestão de causalidade.

Por exemplo, se um estudo acompanha pessoas ao longo de décadas e observa que aqueles que começaram a fumar na adolescência têm taxas mais altas de câncer de pulmão na idade adulta, isso fortalece a evidência de causalidade.

- Modelagem estatística: técnicas como regressão múltipla podem ajudar a controlar outras variáveis que possam influenciar a relação observada.

Por exemplo, ao analisar a relação entre exercício físico e saúde cardíaca, um modelo estatístico pode controlar variáveis como idade, dieta e histórico familiar de doenças cardíacas, isolando o efeito do exercício na saúde cardíaca.

Regressões lineares

A regressão linear é uma técnica estatística usada para entender a relação entre duas variáveis. Em termos simples, ela nos ajuda a descobrir como uma variável pode ser prevista com base em outra variável. Imagine que você quer saber como a quantidade de horas que você estuda (variável independente) afeta sua nota em um exame (variável dependente). A regressão linear ajusta uma linha reta através dos dados que você tem e essa linha representa a melhor estimativa de como uma variável se relaciona com outra. A fórmula dessa linha é:

$$y = \beta_0 + \beta_1 x$$

Em que:

- y é a variável que queremos prever (nota do exame).
- x é a variável que usamos para fazer a previsão (horas de estudo).
- b_0 é o ponto em que a linha intercepta o eixo y (nota prevista quando o tempo de estudo é zero).
- b_1 é a inclinação da linha, mostrando quanto y muda para cada mudança em x .

Imagine que você tem dados de cinco alunos sobre o número de horas que estudaram e as notas que obtiveram:

Tabela 1 - Dados dos alunos

Horas estudadas (x)	Notas (y)
1	50
2	55
3	60
4	65
5	70

Fonte: elaborada pelo autor.

Quando aplicamos a regressão linear a esses dados, podemos encontrar uma linha que melhor os representa. A equação dessa linha pode ser algo como:

$$\text{Nota} = 45 + 5 \times \text{Horas Estudadas}$$

- O número 45 é a nota esperada se você não estudar nada.
- O número 5 indica que, para cada hora adicional de estudo, a nota aumenta em média 5 pontos.

A regressão linear é uma maneira eficaz de entender e prever a relação entre duas variáveis. Ela é amplamente usada em diversas áreas, desde economia até ciências sociais, para fazer previsões e tomar decisões informadas.

Dessa forma, os conceitos apresentados neste tópico são fundamentais para a análise estatística avançada. Eles permitem não apenas descrever e resumir dados, mas também fazer inferências precisas, testar teorias, explorar relações complexas e prever resultados futuros. Desse modo,

dominar esses conceitos capacita pesquisadores e profissionais a tomar decisões baseadas em dados de maneira mais eficiente, contribuindo significativamente para diversas áreas do conhecimento e prática profissional.

5. Conectando a realidade

Contexto: você é um analista de dados em uma empresa de varejo que está buscando entender melhor o desempenho de vendas de seus produtos em diferentes regiões. A empresa vende uma ampla variedade de produtos e opera em várias localidades, enfrentando desafios para identificar tendências e padrões claros nos dados de vendas.

Desafio: utilizando conceitos estatísticos como moda, média e mediana, você precisa fornecer ideias inovadoras para otimizar as estratégias de estoque e marketing da empresa.

Etapas do Estudo de Caso:

Coleta e preparação de dados

1. Primeiramente, colete e organize os dados de vendas por produto e por região. Isso inclui a quantidade vendida e o valor das vendas ao longo de um período específico.

Análise descritiva

2. Aplique estatísticas descritivas, como moda, média e mediana, para entender a distribuição das vendas. Por exemplo, determine qual produto tem a moda de vendas mais alta (ou seja, o mais vendido com maior frequência), a média das vendas totais por mês e a mediana das vendas por região.

Interpretação dos resultados

3. Compare moda, média e mediana para identificar discrepâncias significativas nos dados de vendas. Por exemplo, pode ser que a média de vendas de um produto seja alta devido a um ou dois meses excepcionais, enquanto a mediana pode fornecer uma visão mais estável do desempenho ao longo do tempo.

Recomendações e estratégias

4. Com base nas análises, recomende estratégias para melhorar o estoque e o posicionamento dos produtos. Por exemplo, se a moda das vendas indica um produto muito popular, recomende aumentar o estoque nesse item. Se a mediana das vendas por região mostrar variações significativas, sugira ajustes nas estratégias de marketing localizadas.

Benefícios do estudo de caso

Esse estudo de caso demonstra a aplicação prática de conceitos estatísticos, como moda, média e mediana, e ainda destaca como essas medidas podem fornecer ideias inovadoras para melhorar o desempenho das vendas e a eficiência operacional em um ambiente de varejo dinâmico e competitivo.

6. Conclusão

Neste material de estudos, exploramos conceitos fundamentais de estatística, incluindo medidas de tendência central como média, mediana e moda, que nos ajudam a entender a distribuição de dados; desvio padrão e amostra, essenciais para avaliar a variabilidade dos dados; e intervalos de confiança e testes de hipóteses, que são cruciais

para fazer inferências sobre populações a partir de amostras. Além disso, também discutimos sobre correlação e causalidade, destacando a diferença entre relações associativas e de causa e efeito, e analisamos a regressão linear como uma ferramenta poderosa para modelar e prever relações entre variáveis.

O entendimento dos conceitos de estatística discutidos aqui torna-se fundamental por diversos motivos, primeiramente, as medidas de tendência central como média, mediana e moda, nos ajudam a resumir grandes conjuntos de dados em valores representativos, facilitando a compreensão e interpretação das informações. O desvio padrão e os conceitos de amostra, por sua vez, são essenciais para avaliar a variabilidade dos dados e a confiabilidade das conclusões, habilidades cruciais para qualquer análise quantitativa.

Os intervalos de confiança e os testes de hipóteses nos permitem fazer inferências sobre populações maiores a partir de amostras, um processo fundamental para a pesquisa científica e a tomada de decisões baseada em dados. A compreensão de correlação e causalidade ajuda a distinguir entre meras associações e relações de causa e efeito, prevenindo conclusões errôneas.

Por fim, a regressão linear é uma ferramenta poderosa para modelar e prever relações entre variáveis, aplicável em diversas áreas, desde economia até ciências sociais. No geral, esses conceitos formam a base da análise de dados, permitindo transformar dados brutos em informações úteis e precisas.

Referências

BUSSAB, W. O.; MORETTIN, P. A. **Estatística básica**. São Paulo: Saraiva, 2003.

GUEDES, T. A. *et al.* Aprender Fazendo Estatística. **IME-USP**, 2005. Disponível em: https://www.ime.usp.br/~rvicente/Guedes_etal_Estatistica_Descritiva.pdf. Acesso em: 17 set. 2024.

MONTGOMERY, D. C.; RUNGER, G. C. **Estatística aplicada e probabilidade para engenheiros**. Rio de Janeiro: Livros Técnicos e Científicos, 2003.

PAES, Â. T. Itens essenciais em bioestatística. **Arquivos Brasileiros de Cardiologia**, [s. l.], v. 71, n. 4, p. 575-580, 1998.

REIS, E. **Estatística descritiva**. 4. ed. Lisboa: Silabo, 1998.

Visualização de Dados: Gráficos para análise de dados com a linguagem R e análise exploratória.

Autoria: Anderson Emidio de Macedo Gonçalves

Leitura crítica: Edneuci Denise Audacio

Objetivos

- Compreender os conceitos básicos de visualização de dados utilizando a linguagem R, incluindo a importância da visualização de dados na análise exploratória e os tipos de gráficos disponíveis.
- Entender os diversos tipos de gráficos (como histogramas, *box plots*, *scatter plots* e gráficos de barras) em R, utilizando bibliotecas para analisar e interpretar conjuntos de dados.
- Compreender uma análise exploratória de dados completa utilizando gráficos em R, identificando padrões a partir de dados reais, e comunicando suas descobertas de forma clara e eficaz através de visualizações gráficas.

1. Introdução

Iniciando este Tema, queremos destacar a visualização de dados como uma ferramenta poderosa no campo da análise de dados, permitindo que conjuntos com grandes volumes de dados sejam apresentados de maneira intuitiva e compreensível. Com o advento de tecnologias e linguagens de programação avançadas, como a linguagem R, a capacidade de criar visualizações detalhadas e informativas se tornou acessível tanto para analistas de dados quanto para pesquisadores de diversas áreas.

A linguagem R é amplamente reconhecida devido às suas capacidades robustas de análise estatística e visualização de dados. Por meio de suas bibliotecas e pacotes, como ggplot2, R oferece uma vasta lista de opções para criação de gráficos que ajudam a revelar padrões e tendências não imediatamente aparentes através de tabelas de dados tradicionais, porém com sua devida importância.

Durante o Tema, exploraremos os seguintes assuntos: fundamentos da visualização de dados na linguagem R, tipos de gráficos e suas utilizações e criação de gráficos com ggplot 2.

2. Fundamentos da visualização de dados em R

A importância da visualização de dados se justifica na capacidade de transformar dados brutos em informações úteis para tomada de decisões. Nesse contexto, gráficos bem elaborados podem revelar padrões, identificar *outliers*, mostrar tendências e resumir dados de uma maneira que facilita a comunicação de resultados para diferentes públicos. No geral, as versões de programação orientada a objetos em R



podem ser úteis para gerenciar a complexidade de determinados tipos de dados subjacentes (Chambers, 2008).

Há várias características da visualização de dados em que podemos utilizar muitas técnicas para que isso seja possível, entre as quais podemos destacar as seguintes principais características:

Flexibilidade e personalização: R permite criar uma ampla variedade de gráficos, desde simples gráficos de linhas até complexas visualizações interativas. A flexibilidade do R vem de seus numerosos pacotes, como ggplot2, que permitem aos usuários personalizar quase todos os aspectos dos gráficos.

Ampla biblioteca de pacotes: R possui uma rica coleção de pacotes dedicados à visualização de dados, como ggplot2, lattice, plotly e shiny. Esses pacotes facilitam a criação de visualizações estáticas e interativas, adaptadas às necessidades específicas dos usuários.

Integração com análise estatística: a capacidade de R de integrar a visualização de dados com análise estatística é uma de suas maiores forças. Isso permite que os usuários visualizem os resultados das análises estatísticas de maneira intuitiva e compreensível.

Os benefícios da adoção da linguagem de programação R em suas aplicações também são inúmeros. A seguir destacamos alguns deles:

Comunicação eficaz de resultados: a visualização de dados ajuda a transformar dados complexos em informações visuais fáceis de entender, facilitando a comunicação de insights e resultados para uma audiência ampla, incluindo aqueles sem formação técnica.

Exploração de dados: gráficos e visualizações permitem uma exploração rápida e interativa dos dados, auxiliando a identificar

padrões, tendências e anomalias que podem não ser visíveis em tabelas de dados tradicionais.

Tomada de decisão informada: visualizações claras e informativas ajudam na tomada de decisões, fornecendo uma base visual sólida sobre a qual conclusões e ações podem ser baseadas.

Algumas das funções e pacotes de visualização de dados na linguagem de programação R são:

1. Ggplot2

- a. **Função Principal:** `ggplot()`;
- b. **Descrição:** `ggplot2` é uma implementação da gramática de gráficos em R, permitindo a criação de gráficos complexos de maneira sistemática e modular.
- c. **Benefícios:** oferece grande controle sobre a aparência e a funcionalidade dos gráficos, incluindo a capacidade de adicionar camadas de dados e customizar praticamente todos os aspectos visuais.

2. Plotly

- a. **Função Principal:** `plot_ly()`;
- b. **Descrição:** `plotly` é usado para criar gráficos interativos em R. Ele pode ser integrado com `ggplot2` para adicionar interatividade aos gráficos.
- c. **Benefícios:** facilita a criação de gráficos interativos que podem ser explorados dinamicamente, ideal para apresentações e *dashboards*.

3. Lattice

- a. **Função Principal:** `xplot()`;
- b. **Descrição:** lattice é um sistema de gráficos trellised que facilita a visualização de dados multivariados.
- c. **Benefícios:** útil para gráficos condicionais e comparações de subgrupos dentro de um conjunto de dados.

Exemplos na Linguagem R

O desenvolvimento de gráficos com a utilização da linguagem de programação R é inerente da criação de visualizações dados baseados em conjuntos e amostras para tomada de decisões. Para tanto, vamos exibir um código para geração de um gráfico simples na linguagem R, como você pode observar na figura a seguir.

Figura 1- Demonstração de um gráfico utilizando "R"

```

1  # Instalar e carregar o pacote ggplot2
2  install.packages("ggplot2")
3  library(ggplot2)
4
5  # Conjunto de dados exemplo: mtcars
6  data(mtcars)
7
8  # Criar um gráfico de dispersão com ggplot2
9  ggplot(mtcars, aes(x = wt, y = mpg)) +
10    geom_point(color = "blue") +
11    labs(title = "Relação entre Peso e MPG",
12         x = "Peso do Carro (1000 lbs)",
13         y = "Milhas por Galão (MPG)") +
14    theme_minimal()

```

Fonte: elaborada pelo autor.

Explicando um pouco o código da Figura 1, a linha 9: `ggplot(mtcars, aes(x = wt, y = mpg))`: define o conjunto de dados `mtcars` e mapeia as variáveis `wt` (peso) e `mpg` (milhas por galão). Na linha 10, o código `geom_point(color = "blue")`: adiciona uma camada de pontos no gráfico, com

cor azul. Na linha 11, a função `Labs(title = "Relação entre Peso e MPG", x = "Peso do Carro (1000 lbs)", y = "Milhas por Galão (MPG)")` adiciona títulos e rótulos aos eixos, e por fim, na linha 14 `theme_minimal()`, aplica um tema minimalista ao gráfico.

Outro exemplo utilizando a biblioteca `ggplot2` é a criação de um *box plot*. Observe a figura a seguir.

Figura 2 - Criação de um *box plot* utilizando "R"

```
1 # Criar um box plot para visualizar a distribuição do MPG por cilindros
2 √ ggplot(mtcars, aes(x = factor(cyl), y = mpg)) +
3   geom_boxplot(fill = "lightgreen", color = "darkgreen") +
4   labs(title = "Distribuição de MPG por Número de Cilindros",
5         x = "Número de Cilindros",
6         y = "Milhas por Galão (MPG)") +
7   theme_minimal()
```

Fonte: elaborada pelo autor.

Explicando o código da Figura 2, se trata de um gráfico que mostra a relação entre o consumo de combustível dos carros (medido em milhas por galão ou MPG) e o número de cilindros dos motores dos carros.

Descrição simplificada

Eixos do gráfico:

- Eixo horizontal (x): representa o número de cilindros nos motores dos carros. Temos três categorias: 4 cilindros, 6 cilindros e 8 cilindros.
- Eixo vertical (y): representa o consumo de combustível em milhas por galão (MPG). Quanto maior o valor, mais eficiente é o carro em termos de consumo de combustível.

Caixas (*box plots*):

- Cada caixa mostra como os valores de MPG estão distribuídos para carros com diferentes números de cilindros.
- A linha no meio de cada caixa representa o valor mediano de MPG para cada grupo de carros.
- As extremidades das caixas mostram onde se encontra a maior parte dos dados (entre o primeiro quartil e o terceiro quartil).

Linhas verticais (chamadas “bigodes”):

- As linhas verticais que saem das caixas mostram a extensão dos dados, com exceção dos valores considerados extremos (*outliers*).
- Pontos fora dessas linhas são considerados *outliers*, ou seja, valores que são muito diferentes da maioria dos dados.

Interpretação

Carros com 4 cilindros:

- Têm os valores mais altos de MPG, indicando que esses carros são os mais eficientes em termos de consumo de combustível.
- A mediana de MPG é mais alta comparada aos carros com 6 e 8 cilindros.

Carros com 6 cilindros:

- Têm um consumo de combustível intermediário, com valores de MPG menores que os carros de 4 cilindros, mas maiores que os de 8 cilindros.

Carros com 8 cilindros:

- Têm os valores mais baixos de MPG, indicando que esses carros consomem mais combustível e são os menos eficientes.
- A mediana de MPG é a mais baixa comparada aos outros dois grupos.

Enfim, esse gráfico nos ajuda a ver rapidamente que carros com menos cilindros tendem a ser mais eficientes em termos de consumo de combustível. Já carros com 4 cilindros têm, em média, um consumo de combustível mais baixo (mais milhas por galão) em comparação com carros com 6 ou 8 cilindros.

3. Tipos de gráficos e suas utilizações

A visualização de dados é essencial para compreender e comunicar informações de maneira eficaz dentro da equipe ou empresa. Na linguagem de programação R, uma variedade de gráficos pode ser utilizada para diferentes finalidades analíticas. Cada tipo de gráfico possui características e aplicações específicas que ajudam a destacar padrões e tendências nos dados. Por esse motivo, é fundamental ter um cuidado especial ao construir uma base de dados, como no Excel, evitando a inserção de espaços em branco. No entanto, o R oferece uma solução para esse tipo de situação (Wickham, 2010).

Diante disso, vamos abordar os principais tipos de gráficos em R, suas características, aplicações práticas e exemplos de codificação.

Histogramas

Um histograma é um tipo de gráfico usado para representar a distribuição de uma variável contínua. Ele divide os dados em intervalos (chamados de “bins”) e conta o número de observações em cada intervalo. Então, essas contagens são representadas por barras verticais, em que a altura de cada barra indica a frequência ou a densidade das observações dentro daquele intervalo.

Como principais características de um histograma, podemos destacar:

Eixo horizontal (x): representa os intervalos (bins) nos quais os dados contínuos são divididos. Cada intervalo cobre uma faixa específica de valores da variável.

Eixo vertical (y): representa a frequência ou densidade das observações dentro de cada intervalo. A altura da barra corresponde ao número de observações que caem dentro do intervalo respectivo.

Barras: as barras são desenhadas sem espaços entre elas, indicando a continuidade dos dados. A largura de cada barra é proporcional ao intervalo que ela cobre.

Aplicação prática

Os histogramas são utilizados para visualizar a distribuição de dados e identificar padrões como a normalidade, a assimetria ou a presença de *outliers*. Como objetivo, eles permitem comparar a distribuição de uma variável entre diferentes grupos ou categorias. Nesse ponto, podemos implementar a análise exploratória de dados (EDA) como ferramentas fundamentais para entender a estrutura dos dados antes de aplicar modelos estatísticos ou *machine learning* (aprendizagem de máquina).

Box plots

O *box plot*, ou diagrama de caixa, é um gráfico que mostra a distribuição de um conjunto de dados ao longo de um eixo. Ele é composto por uma caixa que se estende do primeiro ao terceiro quartil, representando a faixa interquartil na qual se encontra a metade dos dados. No meio da caixa, uma linha marca a mediana, indicando o ponto central dos dados. Linhas verticais, chamadas de “bigodes”, se estendem da caixa até os valores mínimos e máximos, com exceção dos *outliers*, que são pontos de dados que se situam fora dessa faixa e são representados individualmente. O *box plot* é útil para visualizar a dispersão dos dados, identificar a presença de *outliers* e comparar distribuições entre diferentes grupos de dados.

Como principais características de um *box plots*, podemos destacar:

- Mostram a dispersão dos dados e a presença de outliers.
- Exibem os quartis, a mediana e os extremos dos dados.

Scatter plots

Os *scatter plots*, ou gráficos de dispersão, são gráficos que mostram a relação entre duas variáveis contínuas. Cada ponto no gráfico representa uma observação no conjunto de dados, com a posição do ponto determinada pelos valores das duas variáveis. O eixo horizontal (x), geralmente, representa a variável independente; enquanto o eixo vertical (y) representa a variável dependente. *Scatter plots* são usados para identificar padrões, tendências e possíveis correlações entre as variáveis. Eles também podem revelar a presença de *outliers* ou *clusters* de dados. Tais gráficos são particularmente úteis em análises exploratórias de dados para visualizar a distribuição e a relação entre variáveis.

Como principais características de um *scatter plots*, podemos destacar:

- Mostram a relação entre duas variáveis contínuas.
- Cada ponto no gráfico representa uma observação.

4. Criação de gráficos com ggplot 2

Hadley Wickham, junto com alguns colaboradores, desenvolveu o pacote ggplot2 com o objetivo de oferecer aos usuários do R uma ferramenta capaz de implementar um modelo poderoso para a criação de gráficos complexos em várias camadas.

Nesse sentido, Correa (2022) afirma que:

Além de uma filosofia bem fundamentada, o ggplot2 ainda traz outras vantagens em relação aos gráficos do R base, possuindo gráficos naturalmente mais bonitos, de fácil personalização e uma estrutura padronizada das funções, deixando o aprendizado mais intuitivo.

Para o gráfico de dispersão, vamos demonstrar um exemplo de criação. Certamente iremos utilizar a linguagem R e o pacote “ggplot2” para plotar o gráfico, ou seja, exibi-lo na ferramenta escolhida.

Passo 1: preparação do ambiente

Primeiramente, vamos garantir que o pacote “ggplot2” está instalado e carregado. Esse pacote é essencial para criar gráficos em R. A Figura 3 apresenta esse processo.

Figura 3 - Instalação do pacote ggplot2

```
# Passo 1: Instalar e carregar o pacote ggplot2
install.packages("ggplot2")
library(ggplot2)
```

Fonte: elaborada pelo autor.

Passo 2: criar o conjunto de dados

Para esse exemplo, criamos um conjunto de dados fictício contendo informações sobre a idade e o salário de 100 indivíduos. Veja a figura a seguir que apresenta as linhas de código necessárias.

Figura 4 - Conjunto de dados

```
# Passo 2: Criar o conjunto de dados
num_individuos <- 100
set.seed(123) # Definir uma seed para reprodutibilidade
idades <- rnorm(num_individuos, mean = 35, sd = 10)
salarios <- 2000 + 150 * idades + rnorm(num_individuos, mean = 0, sd = 5000)
dados <- data.frame(Idade = idades, Salario = salarios)
```

Fonte: elaborada pelo autor.

Passo 3: explorar os dados

Antes de criar o gráfico de dispersão, é útil dar uma olhada nos dados gerados. Vamos exibir as primeiras linhas do "Data Frame" dados. Observe a Figura 5 que apresenta a codificação para o passo 3.

Figura 5 - Primeiras linhas dos dados

```
# Passo 3: Explorar os dados
# Mostrar as primeiras linhas do conjunto de dados
head(dados)
```

Fonte: elaborada pelo autor.

Isso mostrará uma tabela com duas colunas: "Idade" e "Salário", em qual cada linha representa a idade e o salário de um indivíduo.

Passo 4: criar o gráfico de dispersão

Antes de criar o gráfico de dispersão, é útil dar uma olhada nos dados gerados. Vamos exibir as primeiras linhas do “Data Frame” dados. Nesse contexto, observe a Figura 6 que apresenta a codificação necessária para construção do gráfico.

Figura 6 - Primeiras linhas dos dados

```
# Passo 4: Criar o gráfico de dispersão
# Criar um gráfico de dispersão para as variáveis Idade e Salario
grafico_dispersao <- ggplot(dados, aes(x = Idade, y = Salario)) +
  geom_point(color = "blue", alpha = 0.6) +
  labs(title = "Relação entre Idade e Salário",
       x = "Idade (anos)",
       y = "Salário (dólares)") +
  theme_minimal()

# Mostrar o gráfico
print(grafico_dispersao)
```

Fonte: elaborada pelo autor.

Após o passo 4, o gráfico pode ser executado na ferramenta. Você pode utilizar ferramentas como o “R Studio” ou o próprio “VS Code” para esse processo.

Depois de executar o código, o gráfico de dispersão exibirá a relação entre a idade e o salário dos indivíduos no conjunto de dados fictício. Observe a Figura 7, que apresenta o gráfico na ferramenta **R Studio**.

Figura 7 - Gráfico de dispersão em R



Fonte: elaborada pelo autor.

Por meio de um script criado na linguagem R, você poderá realizar todos os passos conjuntamente e executá-los de uma vez. Após executar o código, o gráfico de dispersão exibirá a relação entre a idade e o salário dos indivíduos no conjunto de dados fictício. Aqui está como interpretar o gráfico:

Eixo horizontal (x): representa a idade dos indivíduos em anos.

Eixo vertical (y): representa o salário dos indivíduos em dólares.

Pontos: cada ponto no gráfico representa um indivíduo, com a posição no eixo x indicando sua idade e a posição no eixo y indicando seu salário.

5. Conectando a realidade

Contexto: você é um analista de dados em uma empresa de saúde que está buscando entender melhor os dados dos pacientes para melhorar os serviços e os tratamentos oferecidos. A empresa coleta uma ampla gama de dados, incluindo informações demográficas, histórico médico e resultados de exames, enfrentando desafios para identificar padrões e insights úteis.

Desafio: utilizando a linguagem R e as ferramentas de visualização de dados como ggplot2, você precisa fornecer visualizações claras e informativas para ajudar os médicos e gestores a tomar decisões baseadas em dados. Seu objetivo é criar gráficos que facilitem a compreensão dos dados complexos e ajudem a identificar tendências e anomalias que possam impactar a qualidade do atendimento ao paciente.

Etapas do estudo de caso:

Coleta e preparação de dados: primeiramente, colete e organize os dados dos pacientes, incluindo idade, gênero, histórico de doenças, resultados de exames laboratoriais e visitas ao médico. Certifique-se de que os dados estejam limpos e prontos para análise.

Análise descritiva: aplique estatísticas descritivas para obter uma compreensão inicial dos dados. Por exemplo, calcule a média de idade dos pacientes, a distribuição de gênero e a mediana dos resultados de exames específicos.

Criação de gráficos com “ggplot2”: utilize o pacote ggplot2 em R para criar diferentes tipos de gráficos que ajudem a visualizar os dados. Por exemplo, crie histogramas para mostrar a distribuição de idades, gráficos de dispersão para analisar a relação entre idade e resultados de exames, e gráficos de barras para comparar a frequência de diferentes condições médicas por gênero.

Interpretação dos resultados: analise os gráficos para identificar padrões e tendências. Por exemplo, um histograma pode revelar que a maioria dos pacientes está na faixa etária de 40 a 60 anos, enquanto um gráfico de dispersão pode mostrar uma correlação entre idade avançada e níveis elevados de colesterol.

Recomendações e estratégias: com base nas visualizações, recomende estratégias para melhorar os serviços de saúde. Por exemplo, se os gráficos mostram que os pacientes mais velhos têm níveis elevados de colesterol, sugira campanhas de prevenção e tratamentos específicos para essa faixa etária. Se os gráficos de barras indicam uma alta prevalência de uma condição médica em um gênero específico, recomende programas de triagem direcionados.

Benefícios do estudo de caso: esse estudo de caso demonstra a aplicação prática da visualização de dados com R e ggplot2, destacando como essas ferramentas podem transformar dados complexos em insights acionáveis. As visualizações claras e informativas ajudam os profissionais de saúde a entender melhor os dados dos pacientes, permitindo decisões mais informadas e melhoria na qualidade do atendimento.

6. Conclusão

Como podemos observar, a visualização de dados na linguagem R é uma habilidade essencial para analisar e interpretar grandes volumes de dados de forma eficiente. Com a linguagem R, é possível criar uma ampla variedade de gráficos que facilitam a identificação de padrões, tendências e anomalias nos dados, tornando a análise exploratória de dados mais acessível e informativa.

Os tipos de gráficos e suas utilizações em R são vastos e diversificados, incluindo histogramas, gráficos de dispersão, gráficos de barras, entre outros, cada um com suas características e aplicações específicas. A criação de gráficos com o pacote “ggplot2” em R eleva ainda mais a qualidade visual e a personalização dos gráficos, permitindo que os analistas de dados desenvolvam visualizações sofisticadas e profissionais com facilidade.

Referências

CHAMBERS, J. M. **Software for Data Analysis:** Programming with R. Nova York: Springer, 2008.

CORREA, F. *et al.* Ciência de Dados em R. 2022. Disponível em: <https://livro.curso-r.com/index.html>. Acesso em: 12 set. 2024.



UNIVERSIDADE FEDERAL FLUMINENSE. Construindo gráficos com o ggplot2. *In*: **Ciência de Dados em R - Módulo I**. Niterói: UFF, 2024. Disponível em: https://bookdown.org/jarraais/ciencia-dados-r-modi/_book/construindogr%C3%A1ficos-com-o-ggplot2.html. Acesso em: 12 set. 2024.

WICKHAM, H. Stringr: modern, consistent string processing. **The RJournal**, [s. l.], v. 2, n. 2, dez. 2010. Disponível em: https://journal.r-project.org/archive/2010-2/RJournal_2010-2_Wickham.pdf. Acesso em: 12 set. 2024.

Manipulação de Dados: Banco de dados e sumarização estatística usando R.

Autoria: Anderson Emidio de Macedo Gonçalves

Leitura crítica: Edneuci Denise Audacio

Objetivos

- Compreender e utilizar a linguagem SQL para manipulação de dados.
- Aprender a projetar esquemas de banco de dados que sejam eficientes e normalizados, garantindo a integridade dos dados e minimizando redundâncias.
- Desenvolver habilidades para usar R na computação de medidas estatísticas descritivas.
- Aprender a utilizar ferramentas de visualização de dados em R.



1. Introdução

Vivemos em um mundo onde a informação é um dos ativos mais valiosos, e a habilidade de manipular e interpretar dados é essencial para qualquer profissional. Neste estudo, você terá a oportunidade de se aprofundar em dois pilares fundamentais dessa área: banco de dados e sumarização estatística usando R. Com esses conhecimentos, você estará preparado para enfrentar os desafios do mundo moderno, onde decisões baseadas em dados são determinantes para o sucesso.

Nosso primeiro foco será nos bancos de dados, um recurso indispensável para armazenar, organizar e acessar grandes volumes de informações de maneira eficiente. Aqui, você aprenderá a criar e gerenciar bancos de dados utilizando a linguagem SQL para realizar consultas e manipular dados. Com esse conhecimento, você será capaz de entender a estrutura e o funcionamento dos bancos de dados, além de desenvolver a capacidade de projetar esquemas eficientes, garantindo a integridade e a segurança dos dados.

O segundo pilar do nosso estudo é a sumarização estatística usando R. A linguagem R é uma das mais poderosas ferramentas para análise estatística e visualização de dados, dessa forma, você aprenderá a calcular e interpretar medidas estatísticas descritivas, essenciais para compreender os dados com os quais está trabalhando. Além disso, desenvolverá habilidades para criar visualizações de dados eficazes utilizando bibliotecas, como ggplot2, que facilitarão a comunicação das suas percepções de forma mais clara.

Combinando a análise estatística e a visualização de dados, você estará pronto para transformar dados brutos em informações precisas, capazes de orientar diferentes decisões estratégicas.

2. Banco de dados

No mundo moderno, onde a quantidade de informações cresce exponencialmente, os bancos de dados se tornaram ferramentas essenciais para armazenar, organizar e acessar dados de maneira eficiente. Desde pequenas empresas até grandes corporações, todos dependem de bancos de dados para gerenciar informações, como registros de clientes, transações financeiras e inventários de produtos. Desse modo, entender o funcionamento dos bancos de dados é fundamental para qualquer profissional que lida com dados no dia a dia.

Um banco de dados é essencialmente um sistema que permite armazenar grandes volumes de dados de forma organizada, facilitando a recuperação e a manipulação dessas informações. Por exemplo, considere um supermercado que precisa rastrear seus produtos, preços e vendas. Um banco de dados permite que o supermercado registre cada item em estoque, seu preço, quantidade disponível e as vendas realizadas. Com um simples comando, o gerente pode acessar rapidamente o número de produtos vendidos em um dia específico ou verificar quais itens precisam ser reabastecidos.

Nesse sentido, Elmasri e Navathe (2011, p. 3) define que na expressão “banco de dados” estão subentendidas as seguintes propriedades:

Um banco de dados é uma coleção logicamente coerente de dados com algum significado inerente. Uma variedade aleatória de dados não pode ser corretamente chamada de banco de dados.

Um banco de dados é projetado, construído é populado com dados para uma finalidade específica. Ele possui um grupo definido de usuários e algumas aplicações previamente concebidas nas quais esses usuários estão interessados.



Os bancos de dados utilizam a linguagem Structured Query Language (SQL) para realizar operações de criação, leitura, atualização e exclusão de dados, conhecidas como operações CRUD. Imagine um banco de dados de uma biblioteca, com SQL, o bibliotecário pode adicionar novos livros ao sistema (*create*), consultar a disponibilidade de um livro específico (*read*), atualizar informações sobre um livro emprestado (*update*) e remover registros de livros obsoletos (*delete*). Essas operações, por sua vez, tornam a gestão de dados eficiente e precisa, economizando tempo e reduzindo erros.

De acordo com Date (2003, p. 6), um sistema de banco de dados é “um sistema informatizado cuja função principal é armazenar informações e possibilitar que os usuários as consultem e atualizem conforme necessário”. Para o autor, tais sistemas são constituídos por dados, hardware, software e usuários.

Vale ressaltar que existem diferentes tipos de bancos de dados, mas os mais comuns são os relacionais e os não relacionais. Os bancos de dados relacionais, como MySQL, organizam dados em tabelas que se relacionam entre si por meio de chaves. Já os bancos de dados não relacionais, como MongoDB e Cassandra, são mais flexíveis e armazenam dados em formatos como documentos ou grafos. A seguir vamos observar dois exemplos desses tipos de banco de dados na criação e na inserção de dados para que fique mais clara essa compreensão, observe:

Exemplo 1: banco de dados relacional (MySQL)

Vamos usar o MySQL para um exemplo de um banco de dados de uma biblioteca.

- Criando uma tabela e inserindo dados:

Figura 1 - Criação de tabela e inserção de dados em MySQL

A screenshot of the MySQL Workbench interface. The top toolbar includes icons for file operations, execution, and search. A status bar at the top right indicates 'Limit to 1000 rows'. The main editor area displays SQL code with line numbers on the left. The code consists of two parts: a CREATE TABLE statement for a table named 'livros' and an INSERT INTO statement with three rows of data. The first part of the code is commented as '-- Cria a tabela de livros' and the second as '-- Insere alguns registros na tabela de livros'.

```
1 -- Cria a tabela de livros
2 CREATE TABLE livros (
3     id INT AUTO_INCREMENT PRIMARY KEY,
4     titulo VARCHAR(255) NOT NULL,
5     autor VARCHAR(255) NOT NULL,
6     ano_publicacao INT
7 );
8
9 -- Insere alguns registros na tabela de livros
10 INSERT INTO livros (titulo, autor, ano_publicacao)
11 VALUES
12 ('Dom Casmurro', 'Machado de Assis', 1899),
13 ('O Alquimista', 'Paulo Coelho', 1988),
14 ('Grande Sertão: Veredas', 'João Guimarães Rosa', 1956);
```

Fonte: captura de tela do MySQL Workbench.

Nesse exemplo, o código SQL cria uma tabela chamada *livros* com quatro colunas: *id* (chave primária com incremento automático), *título* (não nulo), *autor* (não nulo) e *ano_publicacao*. Em seguida, insere três registros nessa tabela, adicionando os livros *Dom Casmurro* de Machado de Assis, publicado em 1899; *O Alquimista* de Paulo Coelho, publicado em 1988; e *Grande Sertão: Veredas* de João Guimarães Rosa, publicado em 1956.

Exemplo 2: banco de dados não relacional (MongoDB)

Vamos usar o MongoDB para um exemplo de um banco de dados de uma rede social.

- Conectando e inserindo dados

Figura 2 - Conectando e inserindo dados em MongoDB

```
1 // Conecta ao MongoDB e seleciona o banco de dados "rede_social"
2 use rede_social
3
4 // Insere alguns documentos na coleção "usuarios"
5 db.usuarios.insertMany([
6   { nome: "Alice", idade: 30, interesses: ["leitura", "viagens"] },
7   { nome: "Bob", idade: 25, interesses: ["esportes", "música"] },
8   { nome: "Carlos", idade: 35, interesses: ["tecnologia", "filmes"] }
9 ]);
```

Fonte: elaborada pelo autor.

Nesse segundo exemplo, vemos que o código em JavaScript conecta ao banco de dados MongoDB chamada “rede_social” e insere três documentos na coleção “usuarios”. Cada documento representa um usuário com os campos nome, idade e interesses, na qual “Alice” tem 30 anos e se interessa por leitura e viagens; “Bob” tem 25 anos e seus interesses são esportes e música; e “Carlos” tem 35 anos se interessa por tecnologia e filmes.

Concluindo, os bancos de dados são fundamentais para a gestão eficiente de grandes volumes de informações no mundo atual. Eles permitem que empresas e organizações armazenem, organizem e acessem dados de forma rápida e precisa, melhorando a tomada de decisões e a operação diária. Seja utilizando bancos de dados relacionais para estruturas mais rígidas ou não relacionais para maior flexibilidade, o domínio dessa tecnologia é indispensável para qualquer profissional que deseja se destacar no mercado de trabalho. Ao entender como os bancos de dados funcionam e como utilizá-los, você, futuro programador, estará preparado para enfrentar os desafios do atual cenário, em que cada vez mais a utilização de banco de dados se faz necessária.

3. Sumarização estatística usando R

A sumarização estatística é uma técnica fundamental para a análise de dados, pois permite transformar grandes volumes de dados em informações compreensíveis. Com o uso da linguagem de programação R, uma das ferramentas mais poderosas para análise estatística e visualização de dados, é possível calcular medidas estatísticas descritivas, criar gráficos e obter informações de forma eficiente. Neste tópico, por sua vez, exploraremos como a sumarização estatística em R pode ser aplicada, proporcionando exemplos práticos para facilitar a compreensão do conteúdo.

A sumarização estatística envolve o cálculo de medidas descritivas que resumem as principais características de um conjunto de dados. Entre as medidas mais comuns estão média, mediana, moda, variância e desvio padrão. As medidas de tendência central nos ajudam a compreender a concentração dos dados e a identificar qual valor representa melhor a “média” de um conjunto de dados. Elas funcionam como um ponto de referência, permitindo resumir grandes volumes de dados em um único valor representativo. Tais medidas, por sua vez, são denominadas assim porque indicam um ponto onde os dados tendem a se agrupar, geralmente refletindo o centro da distribuição.

Nesse sentido, Reis (1998) afirma que:

O valor a escolher depende das características dos dados. Por exemplo, num estudo agrícola sobre a produção de trigo por hectare de terra arável podemos estar interessados em conhecer o valor mais elevado da produtividade do solo agrícola das várias explorações analisadas. Num outro estudo sobre os resultados de uma turma de estudantes universitários talvez seja mais interessante conhecer o resultado médio obtido por 50% dos estudantes. Num outro estudo sobre os rendimentos per capita dos países da CEE, a comparação entre países será facilitada se calcularmos os rendimentos médios de cada país.

Em R, essas operações são realizadas de maneira simples e intuitiva. A seguir, observe, por meio de dois exemplos, como essa relação ocorre na prática.

Exemplo 1: medidas descritivas

- Considere um conjunto de dados que representa as notas de uma turma em um exame:

Figura 3 - Exemplo de medidas descritivas

```
167 # Cálculo da média
168 media <- mean(notas)
169 # Cálculo da mediana
170 mediana <- median(notas)
171 # Cálculo da variância
172 variancia <- var(notas)
173 # Cálculo do desvio padrão
174 desvio_padrao <- sd(notas)
175
176 # Exibição dos resultados
177 cat("Média:", media, "\n")
178 cat("Mediana:", mediana, "\n")
179 cat("Variância:", variancia, "\n")
180 cat("Desvio Padrão:", desvio_padrao, "\n")
181
```

Fonte: captura de tela do RStudio.

Neste exemplo, criamos um vetor com as notas dos alunos e calculamos as medidas descritivas. A média fornece uma ideia geral do desempenho da turma, enquanto a mediana indica o valor central das notas. Já a variância e o desvio padrão medem a dispersão das notas em relação à média, mostrando quão espalhadas estão as notas.

Exemplo 2: visualização de dados

- A visualização de dados é uma parte crucial da sumarização estatística, pois permite identificar padrões e tendências de forma visual. Utilizando o pacote ggplot2 em R, podemos criar gráficos informativos e esteticamente agradáveis.

Figura 4 - Exemplo de visualização de dados

```
183 # Instalação e carregamento do pacote ggplot2
184 install.packages("ggplot2")
185 library(ggplot2)
186
187 # Criação de um data frame com as notas
188 dados <- data.frame(notas)
189
190 # Criação de um histograma das notas
191 ggplot(dados, aes(x = notas)) +
192   geom_histogram(binwidth = 0.5, fill = "blue", color = "black") +
193   labs(title = "Distribuição das Notas dos Alunos", x = "Notas", y = "Frequência")
194
```

Fonte: captura de tela do RStudio.

Neste exemplo, criamos um histograma que mostra a distribuição das notas dos alunos. Esta é uma ferramenta indispensável para visualizar a frequência de diferentes intervalos de valores em um conjunto de dados, ajudando a identificar padrões como a concentração de notas em determinadas faixas.

Dessa forma, a sumarização estatística usando R é uma habilidade essencial para qualquer profissional que trabalha com dados. Ela permite transformar dados brutos em informações concretas por meio de medidas descritivas e visualizações claras. Assim, ao aprender a calcular e interpretar estatísticas descritivas, bem como criar gráficos informativos, você estará apto a extrair informações significativas dos dados e comunicar esses dados de maneira eficaz. Com exemplos práticos como os apresentados, fica claro como a sumarização estatística pode ser aplicada de forma eficiente utilizando a linguagem R.

4. Conectando a realidade - estudo de caso

Contexto: nesse estudo de caso, vamos explorar como um supermercado pode utilizar um banco de dados para gerenciar suas operações de forma eficiente. Por meio da organização de informações



sobre produtos, clientes e vendas, o supermercado pode otimizar o controle de estoque, melhorar a experiência do cliente e aumentar a precisão na análise de vendas. Veremos como essas práticas podem ser aplicadas e quais benefícios elas trazem para a administração do supermercado.

Estrutura do banco de dados

Para atender às necessidades operacionais do supermercado, o banco de dados será estruturado em três tabelas principais:

1. Produtos: essa tabela armazena informações detalhadas sobre cada item disponível no supermercado, incluindo o nome do produto, categoria, preço e quantidade em estoque. Por sua vez, essa organização permite um controle eficiente do inventário e ajuda a garantir que os produtos estejam sempre disponíveis para os clientes.
2. Clientes: A tabela de clientes contém dados pessoais dos consumidores, como nome, e-mail e telefone. Ter essas informações bem organizadas possibilita ao supermercado personalizar o atendimento, oferecer promoções específicas e manter um relacionamento mais próximo com seus clientes.
3. Vendas: A tabela de vendas registra todas as transações realizadas no supermercado, incluindo a identificação do cliente, os produtos comprados, a quantidade de cada produto e a data da venda. Esses registros são essenciais para analisar o desempenho de vendas, identificar padrões de consumo e planejar estratégias de marketing.

Exemplo prático: gestão de produtos

Suponha que o supermercado deseja analisar o estoque de produtos para evitar rupturas e excessos. Ao consultar a tabela de produtos,

a administração pode identificar itens que estão com estoque baixo e precisam ser reabastecidos. Por exemplo, se a quantidade de leite está abaixo do nível ideal, o gerente pode solicitar um novo pedido ao fornecedor. Da mesma forma, produtos que estão encalhados podem ser identificados e colocados em promoção para liberar espaço no estoque.

Exemplo prático: fidelização de clientes

Com base na tabela de clientes, o supermercado pode criar campanhas de marketing direcionadas. Por exemplo, ao analisar os dados, a equipe de marketing identifica que um grupo de clientes costuma comprar produtos de panificação regularmente. Com essa informação, eles podem enviar cupons de desconto para esses clientes, incentivando-os a comprar mais produtos dessa categoria. Além disso, o supermercado pode enviar e-mails personalizados no aniversário dos clientes, oferecendo descontos especiais, o que ajuda a aumentar a fidelidade dos consumidores.

Exemplo prático: análise de vendas

A tabela de vendas permite uma análise detalhada do desempenho do supermercado. Nesse contexto, suponha que a administração queira avaliar as vendas de um determinado produto, como o arroz. Ao revisar os registros, eles percebem que as vendas de arroz aumentam significativamente durante o final de semana. Com essa informação, o supermercado pode planejar melhor o estoque e organizar promoções específicas para maximizar as vendas nesse período.

Concluindo, ficou claro que os benefícios da utilização de banco de dados são inúmeros, neste estudo de caso específico, vimos como um supermercado pode utilizar um banco de dados para melhorar suas operações e aumentar a eficiência. Assim, ao organizar informações

sobre produtos, clientes e vendas de maneira estruturada, o supermercado pode tomar decisões mais informadas, personalizar o atendimento e otimizar o controle de estoque. A utilização de um banco de dados não apenas facilita a gestão, mas também contribui significativamente para o sucesso do negócio em um mercado cada vez mais competitivo.

5. Conclusão

A manipulação de dados em bancos de dados é essencial para a organização e eficiência no armazenamento e recuperação de informações. A capacidade de inserir, atualizar, deletar e consultar dados de maneira eficaz permite que empresas e pesquisadores gerenciem grandes volumes de informações de forma estruturada e acessível. Isso não só facilita a tomada de decisões baseadas em dados, mas também garante a integridade e consistência das informações armazenadas. Logo, dominar técnicas de manipulação de dados em bancos de dados é fundamental para qualquer profissional que lida com dados, proporcionando uma base sólida para análises mais complexas e detalhadas.

A sumarização estatística usando R complementa a manipulação de dados ao fornecer ferramentas avançadas para a análise e visualização de dados. Com R, é possível realizar análises estatísticas detalhadas que ajudam a identificar padrões, tendências e relações entre variáveis, oferecendo informações que podem orientar estratégias e tomadas de decisões. Ademais, a combinação dessas habilidades permite que profissionais não apenas gerenciem dados de maneira eficiente, mas também extraiam informações significativas a partir desses dados.



Referências

DATE, C. J. **Introdução a sistemas de bancos de dados**. 8. ed. Rio de Janeiro: Elsevier, 2003.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de banco de dados**. 6. ed. São Paulo: Addison Wesley, 2011.

REIS, E. **Estatística descritiva**. 4. ed. Lisboa: Silabo, 1998.



Bons estudos!