



WBA0753_v2.0

Linguagens de programação para ciência de dados (Python com Spark)




PySpark – Análise de Dados

Introdução


Bloco 1


Rodrigo Rocha



Vamos refletir?

Como podemos alavancar a eficiência do processamento distribuído do PySpark para transformar grandes volumes de dados em insights valiosos, otimizando nossas decisões e estratégias de negócios?





Para iniciarmos a conversa

Vamos refletir a partir de uma pergunta muito importante:

Como o uso do PySpark pode revolucionar a análise de Big Data na sua organização, transformando vastos volumes de dados em decisões estratégicas ágeis e informadas?



Fonte: Banco do Office.




PySpark




PySpark é uma API de processamento de dados em larga escala que integra o Apache Spark, uma plataforma de computação distribuída, com a linguagem de programação Python.



Ela permite que desenvolvedores criem aplicativos de Big Data de forma rápida e eficiente.





Começando com o PySpark



Instalar o Spark



Fazer o download e a instalação do Apache Spark na máquina local ou em um ambiente de cluster.



Integrar com Python



Configurar o PySpark para trabalhar com a linguagem Python, instalando as dependências necessárias.




Escrever código



Começar a escrever código em Python para processar e analisar dados usando as APIs do PySpark.





Tipos de dados


CSV (Comma-Separated Values):

- CSV é um formato amplamente utilizado para armazenar dados tabulares em texto simples, em que cada linha representa um registro e as colunas são separadas por vírgulas.

JSON (JavaScript Object Notation):

- JSON é um formato leve de intercâmbio de dados que é fácil para humanos lerem e escreverem, e fácil para máquinas interpretarem e gerarem.





DataFrames

Demonstração

Criação

Leitura

Escrita

Filtragem

Agregação

Operações de união




PySpark – Análise de Dados

Processamento distribuído

Bloco 2

Rodrigo Rocha



Introdução

O processamento distribuído envolve a divisão de tarefas e recursos entre vários computadores conectados em rede, permitindo um desempenho e eficiência superiores em comparação a sistemas centralizados.

Essa abordagem revoluciona a forma como processamos e armazenamos informações no mundo digital.



Arquiteturas



Cliente-servidor



Nesta arquitetura, os clientes solicitam serviços a um servidor central, que processa e retorna as respostas.



Peer-to-Peer



Neste modelo, os computadores atuam tanto como clientes quanto como servidores, compartilhando recursos e tarefas de forma descentralizada.




Computação em nuvem



A computação em nuvem centraliza recursos em datacenters remotos, permitindo acesso sob demanda a serviços e infraestrutura.





Desafios e benefícios

Desafios

- Coordenação, segurança, escalabilidade e confiabilidade das conexões são alguns dos principais desafios a serem superados.


Benefícios

- Maior disponibilidade, tolerância a falhas, escalabilidade e eficiência no uso de recursos computacionais.

Aplicações críticas

- Áreas como Big Data, Internet das Coisas, sistemas de saúde e serviços financeiros se beneficiam enormemente do processamento distribuído.





Aplicações e casos de uso



Computação em nuvem



Uso de recursos computacionais remotos sob demanda.



Serviços distribuídos



Aplicações web, APIs e microserviços em larga escala.




Big Data e análise



Processamento e análise de grandes volumes de dados.



Internet das Coisas



Coordenação e processamento de dados de dispositivos IoT.




PySpark – Análise de Dados

MLlib – *Machine learning*

Bloco 3


Rodrigo Rocha



O MLlib é a biblioteca de *machine learning* do Apache Spark, que oferece uma ampla gama de algoritmos e ferramentas que podem ser facilmente integrados a aplicações de Big Data.



Com recursos avançados e desempenho excepcional, o MLlib se destaca como uma poderosa plataforma para análise preditiva e tomada de decisão.




Principais recursos



Algoritmos de aprendizado



O MLlib oferece uma variedade de algoritmos de aprendizado supervisionado e não supervisionado, como regressão, classificação, agrupamento e redução de dimensionalidade.



Otimização e avaliação



Recursos avançados para otimização de hiperparâmetros e avaliação de modelos, garantindo a melhor performance.



Pipelines e persistência



Pipelines reutilizáveis para construir, treinar e testar modelos, com a possibilidade de salvar e carregar modelos.





Aplicações

Recomendação de produtos

Utilizar algoritmos de filtragem colaborativa para sugerir produtos personalizados aos usuários.

Detecção de fraude

Aplicar técnicas de classificação para identificar transações fraudulentas em tempo real.

Previsão de demanda

Usar modelos preditivos para antecipar a demanda por produtos ou serviços.

Segmentação de clientes

Agrupar clientes com base em características e comportamentos semelhantes.



Integração do MLlib com o PySpark



LEITURA DE DADOS

CARREGAR CONJUNTOS DE DADOS ESTRUTURADOS OU NÃO ESTRUTURADOS USANDO O PYSARK.



PREPARAÇÃO DE DADOS

REALIZAR A LIMPEZA, TRANSFORMAÇÃO E ENGENHARIA DE RECURSOS COM AS FERRAMENTAS DO PYSARK.



TREINAMENTO DE MODELOS

UTILIZAR OS ALGORITMOS DO MLlib PARA TREINAR MODELOS PREDITIVOS.



IMPLANTAÇÃO E AVALIAÇÃO

IMPLANTAR OS MODELOS TREINADOS E AVALIAR SEU DESEMPENHO EM DADOS DE TESTE.



PySpark – Análise de Dados

Teoria em prática

Bloco 4


Rodrigo Rocha

Reflita sobre a seguinte situação

Uma grande loja on-line está passando por dificuldades para lidar com grandes quantidades de dados de vendas e comportamento dos clientes. Os sistemas atuais não estão conseguindo lidar com a quantidade e rapidez dos dados, o que está resultando em atrasos na produção de relatórios e análises, afetando negativamente a tomada de decisões e a otimização das operações.

Como podemos usar o Apache Spark para auxiliar a Empresa Y no processamento eficiente de seus extensos dados, obter insights acionáveis em tempo real e integrar várias fontes de dados para melhorar as decisões e otimizar as operações?





Norte para a resolução




Pontos para pensar

- Principais problemas.
- Processar dados em tempo real.
- Tipos de análise.

Outros pontos-chaves

- Integração das fontes de dados.
- Insights.
- Garantir segurança e privacidade dos dados.






Norte para a resolução



- Pesquisar e identificar os componentes:




Bons estudos!

PySpark – Análise de Dados

Consolidando o aprendizado

Bloco 5

Rodrigo Rocha



Consolidando o aprendizado

- O PySpark tem a capacidade de manipular e processar grandes volumes de dados de maneira eficiente e distribuída. PySpark permite o uso de RDDs e DataFrames para realizar operações complexas de filtragem, agregação e transformação de dados em um ambiente de cluster, melhorando a escalabilidade e o desempenho em comparação com outras ferramentas de análise de dados.
- PySpark suporta a leitura e escrita de arquivos em formatos como CSV, JSON, Parquet, entre outros, facilitando a ingestão e exportação de dados de diferentes sistemas. Essa flexibilidade permite que os dados sejam preparados e transformados de maneira a atender às necessidades específicas de análise e relatórios.
- PySpark inclui a aplicação de algoritmos de *machine learning* por meio da biblioteca MLlib. Isso envolve a construção de pipelines que automatizam o processo de pré-processamento de dados, treinamento e avaliação de modelos. A capacidade de criar e ajustar modelos preditivos de maneira escalável e eficiente é crucial para a realização de análises avançadas e para a implementação de soluções de inteligência artificial em diversos domínios de negócios.



Quiz



Leia as afirmações a seguir sobre PySpark e indique se são verdadeiras (V) ou falsas (F):

- I. PySpark permite a manipulação de grandes volumes de dados distribuídos usando DataFrames e RDDs.
- II. PySpark não suporta operações de *machine learning*.
- III. PySpark só pode ser utilizado em clusters locais, sem suporte para clusters distribuídos.
- IV. PySpark oferece uma API que facilita a execução de operações SQL-like em grandes conjuntos de dados.

A

V – F – V – F.

B

V – F – F – V.

C

F – V – F – V.

D

F – F – V – V.

Quiz



Leia as afirmações a seguir sobre PySpark e indique se são verdadeiras (V) ou falsas (F):

- I. PySpark permite a manipulação de grandes volumes de dados distribuídos usando DataFrames e RDDs.
- II. PySpark não suporta operações de *machine learning*.
- III. PySpark só pode ser utilizado em clusters locais, sem suporte para clusters distribuídos.
- IV. PySpark oferece uma API que facilita a execução de operações SQL-like em grandes conjuntos de dados.

A

V – F – V – F.

B


V – F – F – V.

C

F – V – F – V.

D

F – F – V – V.



Quiz – Resolução

Resposta correta: **B) V – F – F – V.**


Verdadeiro: PySpark permite a manipulação de grandes volumes de dados distribuídos usando DataFrames e RDDs. Essas estruturas de dados são projetadas para processamento paralelo em clusters, melhorando a eficiência e a escalabilidade das operações de análise de dados.

Falso: PySpark suporta operações de *machine learning* por meio da biblioteca MLlib. MLlib oferece uma variedade de algoritmos para tarefas como classificação, regressão e clustering, permitindo a criação de modelos preditivos em grande escala.

Falso: PySpark pode ser utilizado tanto em clusters locais quanto em clusters distribuídos. Ele é projetado para escalar horizontalmente, o que significa que pode aproveitar a capacidade de processamento de múltiplos nós em um cluster.

Verdadeiro: PySpark oferece uma API que facilita a execução de operações SQL-like em grandes conjuntos de dados. Com DataFrames e Spark SQL, os usuários podem realizar consultas estruturadas de forma eficiente e integrada.






Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!






Indicação de leitura 1

O artigo a seguir demonstra na prática a aplicação de algoritmos de *machine learning* para validar um modelo de aprendizado profundo (*deep learning* - DL) na estimativa da idade óssea em indivíduos paulistas. Este modelo é comparado com o método tradicional de Greulich e Pyle, oferecendo uma análise detalhada da eficácia e precisão de ambas as abordagens.

Referência

SERPA, Augusto *et al.* Validação de algoritmo de aprendizado profundo para detecção da idade óssea em pacientes de São Paulo, Brasil. **Radiologia Brasileira**, v. 56, n. 5, 2023.






Indicação de leitura 2

O artigo a seguir apresenta uma análise sobre a ocorrência de grandes incêndios florestais (GIFs) no noroeste de Portugal, sob condições meteorológicas extremas, no período de 2001 a 2020. Utilizando imagens Landsat e ferramentas de *machine learning*, especificamente o algoritmo Random Forest no Google Earth Engine, foi mapeada a extensão e evolução dos GIFs, que queimaram milhares de hectares, destruíram infraestruturas e resultaram em perdas humanas.

Referência

SANTOS, Sarah Moura Batista dos *et al.* Grandes Incêndios Florestais no noroeste de Portugal: Explorando padrões espaciais entre 2001 e 2020, com base em dados Landsat. **Revista Sociedade e Natureza**, v. 35, 2023.





Referências


APACHE SPARK. **Apache Spark - Unified Engine for large-scale data analytics**. Disponível em: <https://spark.apache.org/>. Acesso em: 1 jul. 2024.

APACHE SPARK. **PySpark**. Disponível em: <https://spark.apache.org/docs/latest/api/python/>. Acesso em: 9 jul. 2024.

BEHRMAN, Kennedy R. **Fundamentos de Python para ciência de dados**. Porto Alegre: Grupo A, 2023. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788582605974/>. Acesso em: 20 maio 2024.

PEREIRA, Mariana A. *et al.* **Framework de Big Data**. Porto Alegre: Grupo A, 2020. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9786556900803/>. Acesso em: 01 jul. 2024.






Referências

SANTOS, Sarah Moura Batista dos *et al.* Grandes Incêndios Florestais no noroeste de Portugal: Explorando padrões espaciais entre 2001 e 2020, com base em dados Landsat. **Revista Sociedade e Natureza**, v. 35, 2023. Disponível em: <https://www.scielo.br/j/sn/a/Lv6pn7BGbjCj4GghNVfGHdw/?lang=pt#>. Acesso em: 29 jul. 2024.

SERPA, Augusto *et al.* Validação de algoritmo de aprendizado profundo para detecção da idade óssea em pacientes de São Paulo, Brasil. **Radiologia Brasileira**, v. 56, n. 5, 2023. Disponível em: <https://www.scielo.br/j/rb/a/pDQRNvzWMWng4R7jJqPm5XK/?lang=pt#>. Acesso em: 29 jul. 2024.





Bons estudos!