



WBA0753_v2.0

Linguagens de programação para ciência de dados (Python com Spark)



Big Data e Apache Spark

Para iniciarmos a conversa


Bloco 1

Rodrigo Rocha



Vamos refletir?

Como podemos garantir que aproveitaremos plenamente os valiosos conhecimentos e benefícios econômicos que o Big Data oferece, ao mesmo tempo em que respeitamos as preocupações éticas e de privacidade das pessoas, assegurando que a aplicação dessas tecnologias seja feita de forma responsável e equitativa?



Para iniciarmos a conversa

Vamos refletir a partir de uma pergunta muito importante:

Para processamento de dados em grande escala e análise unificada, qual ferramenta posso usar?




Fonte: Banco do Office.



Big Data

Big Data se refere a conjuntos de dados extremamente grandes e complexos que exigem ferramentas e processamento avançados para extrair informações valiosas.





Características do Big Data

Volume

Grandes volumes de dados sendo coletados e armazenados.

Velocidade

Dados sendo gerados e processados em tempo real.


Variedade

Dados estruturados, semiestruturados e não estruturados.

Veracidade

Qualidade e confiabilidade dos dados sendo cruciais.





Aplicações do Big Data

Marketing

Segmentação de clientes e personalização de campanhas.


Saúde

Deteção precoce de doenças e acompanhamento de pacientes.

Finanças

Análise de tendências, deteção de fraude e risco.





Desafios e oportunidades

Segurança

Garantir a privacidade e segurança dos dados.

Habilidades

Profissionais capacitados para trabalhar com Big Data.

Infraestrutura

Investir em tecnologias e recursos adequados.

Insights

Transformar dados em informações valiosas.




Big Data e Apache Spark

Apache Spark


Bloco 2


Rodrigo Rocha



Introdução

- O Apache Spark é uma poderosa ferramenta de processamento de dados em tempo real, que permite a análise e transformação de grandes volumes de informações de forma rápida e eficiente. Sua arquitetura distribuída e resiliente o torna ideal para lidar com conjuntos de dados em constante crescimento.





Recursos e funcionalidades

Processamento de dados


O Spark possui APIs intuitivas para processamento de dados estruturados, semiestruturados e não estruturados, permitindo a transformação e análise de conjuntos de dados complexos.


Machine learning

Sua biblioteca de aprendizado de máquina, o MLlib, oferece uma ampla gama de algoritmos para modelos preditivos e de classificação, simplificando o desenvolvimento de soluções avançadas.

Processamento em streaming

O Spark Streaming permite o processamento de dados em tempo real, possibilitando a criação de aplicações que reagem instantaneamente a eventos e tendências emergentes.





Aplicações e casos de uso

Análise de Big Data

Processamento e análise de grandes volumes de dados em tempo real, como logs, sensores e mídias sociais.

Ciência de Dados

Desenvolvimento de modelos preditivos, segmentação de clientes e outras soluções avançadas de aprendizado de máquina.


Aplicações em streaming

Monitoramento de atividades em tempo real, como detecção de fraude, análise de tráfego e IoT.

Processamento distribuído

Execução de tarefas complexas em clusters de computadores, aproveitando a escalabilidade e paralelismo do Spark.





Implementação e integração

Plataforma

O Spark pode ser implantado em várias plataformas, incluindo Hadoop, Kubernetes e nuvem.

Ecosistema

Integração com outros componentes do ecossistema, como Kafka, Hive e Cassandra, ampliando as possibilidades de uso.

Ferramentas

Disponibilidade de ferramentas como Jupyter Notebook, facilitando o desenvolvimento e a colaboração entre equipes.




Big Data e Apache Spark

Componentes

Bloco 3

Rodrigo Rocha



Componentes do Apache Spark

Core:

Funções básicas de processamento e gerenciamento de tarefas.

Manipulação de dados em memória para alta performance.

SQL:

Permite consultas SQL em dados estruturados.

Compatível com ANSI SQL, suporta DataFrames e Datasets.

MLlib:

Biblioteca de aprendizado de máquina.

Inclui algoritmos para classificação, regressão, clustering e filtragem colaborativa.



RDDs (*Resilient Distributed Datasets*)

Definição:

Estrutura de dados fundamental no Spark.

Conjuntos de dados imutáveis, distribuídos e tolerantes a falhas.

Características:

Operações distribuídas e em memória.

Suporta dois tipos de operações: transformações e ações.

Transformações:

Lazy evaluations (não executadas imediatamente).


Ex.: `map()`, `filter()`, `flatMap()`.

Ações:

Executam computações e retornam resultados.

Ex.: `collect()`, `count()`, `saveAsTextFile()`.





DataFrames e Spark SQL

DataFrames:

Estruturas de dados distribuídas com colunas nomeadas.

Semelhante a tabelas em bases de dados relacionais.

Suporta operações como seleção, filtragem, agregação e *joins*.

Spark SQL:

Módulo para processamento de dados estruturados.

Permite consultas SQL em DataFrames.


Integração com fontes de dados como Hive, Avro, Parquet e JSON.

Vantagens:

Otimização de consultas via Catalyst Optimizer.

Suporte a uma variedade de fontes de dados.





Transformações

Transformações:

Operações que criam um novo RDD a partir de um existente.

Lazy evaluations (ex.: `map()`, `filter()`, `reduceByKey()`).


Exemplos de transformações:

`map()`: aplica uma função a cada elemento do RDD.

`filter()`: seleciona elementos que atendem a um critério.

`reduceByKey()`: agrega valores com a mesma chave.





Operações

Ações:

Executam operações em RDDs e retornam valores.

Trigger (disparam) a execução das transformações acumuladas.

Ex.: `collect()`, `count()`, `saveAsTextFile()`.

Exemplos de ações:

`collect()`: retorna todos os elementos do RDD.

`count()`: conta o número de elementos do RDD.

`saveAsTextFile()`: salva os dados em um arquivo texto.



Big Data e Apache Spark

Teoria em prática

Bloco 4


Rodrigo Rocha

Reflita sobre a seguinte situação

Uma grande loja on-line está passando por dificuldades para lidar com grandes quantidades de dados de vendas e comportamento dos clientes. Os sistemas atuais não estão conseguindo lidar com a quantidade e rapidez dos dados, o que está resultando em atrasos na produção de relatórios e análises, afetando negativamente a tomada de decisões e a otimização das operações.

Como podemos usar o Apache Spark para auxiliar a Empresa Y no processamento eficiente de seus extensos dados, obter insights acionáveis em tempo real e integrar várias fontes de dados para melhorar as decisões e otimizar as operações?





Norte para a resolução





Pontos para pensar

- Principais problemas.
- Processar dados em tempo real.
- Tipos de análise.

Outros pontos-chaves

- Integração das fontes de dados.
- Insights.
- Garantir segurança e privacidade dos dados.






Norte para a resolução



- Pesquisar e identificar os componentes:




Bons estudos!

Big Data e Apache Spark

Consolidando o aprendizado


Bloco 5

Rodrigo Rocha



Consolidando o aprendizado

- Big Data abrange uma quantidade imensa de informações, tanto estruturadas quanto não estruturadas, que são geradas e coletadas pelas empresas diariamente. Esse enorme volume de dados, quando devidamente processado e analisado, pode revelar insights valiosos que auxiliam na tomada de decisões estratégicas.
- O Apache Spark é uma ferramenta open-source para análise de dados desenvolvida para lidar com grandes volumes de informações de forma rápida e eficiente. Inicialmente criado no AMPLab da Universidade da Califórnia, em Berkeley, e atualmente mantido pela Apache Software Foundation, o Spark se destaca por sua velocidade, capacidade para processamento em tempo real e flexibilidade, suportando múltiplas linguagens de programação como Java, Scala, Python e R.
- Spark disponibiliza um conjunto completo de bibliotecas que abrangem SQL e DataFrames para consultas estruturadas, MLlib para aprendizado de máquina, GraphX para processamento de gráficos e Spark Streaming para processamento de dados em tempo real.



Quiz



Qual das seguintes afirmações sobre o Apache Spark é verdadeira?

A

Apache Spark só pode ser usado com a linguagem de programação Scala.

B

Apache Spark permite o processamento de dados em memória, o que acelera consideravelmente o tempo de análise.

C

Apache Spark é uma ferramenta de código fechado desenvolvida exclusivamente para análise de dados em tempo real.

D

Apache Spark foi desenvolvido pelo Google e é mantido por eles.

Quiz



Qual das seguintes afirmações sobre o Apache Spark é verdadeira?

A

Apache Spark só pode ser usado com a linguagem de programação Scala.

B


Apache Spark permite o processamento de dados em memória, o que acelera consideravelmente o tempo de análise.

C

Apache Spark é uma ferramenta de código fechado desenvolvida exclusivamente para análise de dados em tempo real.

D

Apache Spark foi desenvolvido pelo Google e é mantido por eles.




Quiz – Resolução

Resposta correta: **B)** Apache Spark permite o processamento de dados em memória, o que acelera consideravelmente o tempo de análise.

Uma das características principais e vantagens do Apache Spark é sua habilidade de processar dados na memória. Isso quer dizer que os dados são carregados na memória RAM do sistema, permitindo que operações repetitivas sejam executadas de forma consideravelmente mais rápida em comparação com sistemas que dependem de acesso constante ao disco rígido.

Esse processamento em memória possibilita ao Apache Spark realizar tarefas de análise de dados e aprendizado de máquina com uma velocidade significativamente maior, especialmente para grandes volumes de dados. Consequentemente, o Spark é amplamente utilizado em aplicações que demandam processamento veloz, como streaming de dados em tempo real, análise de dados históricos e machine learning.






Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!






Indicação de leitura 1

O artigo a seguir fala sobre a utilização de Big Data e Inteligência Artificial (IA) na pesquisa translacional no contexto da Covid-19. Realizou-se uma revisão rápida para identificar como técnicas de IA têm sido aplicadas na translação de tecnologias para enfrentar a pandemia.

Referência

RAMOS, Maíra Catharina *et al.* Big Data e Inteligência Artificial para pesquisa translacional na Covid-19: revisão rápida. **Saúde Debate**, Rio de Janeiro, v. 46, n. 135, p. 1202-1214, 2022.

.




Indicação de leitura 2

O artigo a seguir fala sobre a utilização do Apache Spark como um framework promissor para a execução de experimentos científicos baseados em simulação em ambientes de alto desempenho. Apesar de suas vantagens, a configuração do Spark, que envolve mais de 180 parâmetros, pode ser complexa e propensa a erros. O estudo explora o uso de múltiplos métodos de aprendizado de máquina para auxiliar na configuração desses parâmetros.

Referência

OLIVEIRA, Luís Felipe *et al.* Definição de Parâmetros do Spark por meio de Aprendizado de Máquina: um Estudo com Dataflows de Astronomia. In: BRAZILIAN E-SCIENCE WORKSHOP (BRESOI), 15., 2021. **Anais...** Porto Alegre: Sociedade Brasileira de Computação, 2021 . p. 25-32.






Referências

APACHE SPARK. **Apache Spark - Unified Engine for large-scale data analytics**. Disponível em: <https://spark.apache.org/>. Acesso em: 1 jul. 2024.

BEHRMAN, Kennedy R. **Fundamentos de Python para ciência de dados**. Porto Alegre: Grupo A, 2023. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788582605974/>. Acesso em: 20 maio 2024.

OLIVEIRA, Luís Felipe *et al.* Definição de Parâmetros do Spark por meio de Aprendizado de Máquina: um Estudo com Dataflows de Astronomia. In: BRAZILIAN E-SCIENCE WORKSHOP (BRESOI), 15., 2021. **Anais...** Porto Alegre: Sociedade Brasileira de Computação, 2021 . p. 25-32. Disponível em: <https://sol.sbc.org.br/index.php/bresoi/article/view/15785/15626>. Acesso em: 29 jul. 2024.





Referências

RAMOS, Maíra Catharina *et al.* Big Data e Inteligência Artificial para pesquisa translacional na Covid-19: revisão rápida. **Saúde Debate**, Rio de Janeiro, v. 46, n. 135, p. 1202-1214, 2022.

Disponível em:

<https://www.scielo.br/j/sdeb/a/6vdbxCL9DQZQJtBGLPLyppJ/?format=pdf&lang=pt>. Acesso em: 29 jul. 2024.

SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business intelligence e análise de dados para gestão do negócio**. Porto Alegre: Grupo A, 2019. Disponível em:

<https://integrada.minhabiblioteca.com.br/#/books/9788582605202/>. Acesso em: 21 ago. 2023.





Bons estudos!