



WBA0753\_v2.0

# Linguagens de programação para ciência de dados (Python com Spark)




# Linguagens de programação para ciência de dados: configuração de ambiente, sintaxe e bibliotecas

Para iniciarmos a conversa

**Bloco 1**


Rodrigo Rocha



## Vamos refletir?

A Ciência de Dados tornou-se vital para as empresas, proporcionando uma vantagem competitiva significativa. Ao transformar grandes volumes de dados em insights, as empresas podem tomar decisões mais estratégicas e mais informadas.





## Para iniciarmos a conversa

Vamos refletir a partir de uma pergunta muito importante:





Fonte: Banco do Office.



# Python

- Python é uma linguagem de programação de alto nível.
- Popular tanto entre iniciantes quanto desenvolvedores experientes.
- Suporta múltiplos paradigmas de programação.
  - Programação orientada a objetos.
  - Programação funcional.
  - Programação imperativa.
- Vasta quantidade de bibliotecas e frameworks disponíveis.





# Ciência de Dados



**Ciência de Dados é o campo que combina técnicas de estatística, matemática, computação e análise para extrair insights e conhecimento a partir de dados.**



**Crucial para a tomada de decisões informadas e estratégicas em diversos setores, como negócios, saúde, finanças e tecnologia.**




## Aplicações práticas

**Negócios:** análise de mercado, segmentação de clientes, previsão de demanda e otimização de processos.

**Saúde:** diagnóstico assistido por IA, análise de genomas e predição de surtos de doenças.

**Finanças:** detecção de fraudes, análise de risco e trading algorítmico.

**Tecnologia:** desenvolvimento de sistemas de recomendação, análise de redes sociais e melhoria de motores de busca.



# Ferramentas e tecnologias

---


**Linguagens de programação:** Python, R e SQL são amplamente utilizadas na Ciência de Dados.


---

**Bibliotecas e frameworks:** Pandas, NumPy, Scikit-Learn, TensorFlow e PyTorch para análise e aprendizado de máquina.

---

**Plataformas de Big Data:** Hadoop e Spark para processamento e análise de grandes volumes de dados.





# Fluxo



**Coleta de dados:** obtenção de dados de diversas fontes, incluindo bancos de dados, APIs, *web scraping* e dispositivos IoT.



**Processamento e limpeza:** preparação dos dados para análise, eliminando ruídos, preenchendo lacunas e correção de erros.



**Análise e modelagem:** utilização de métodos estatísticos e algoritmos de *machine learning* para identificar padrões e prever tendências.



**Visualização de dados:** criação de gráficos e dashboards que facilitam a interpretação dos resultados e a comunicação das percepções.






# Linguagens de programação para ciência de dados: configuração de ambiente, sintaxe e bibliotecas

Sintaxe, comandos e estruturas de decisão e repetição


**Bloco 2**


Rodrigo Rocha



# Fundamentos

- Variáveis.
  - int (números inteiros), float (números reais), string (texto), boolean (verdadeiro ou falso).
- Operadores aritméticos.
  - + (adição) - (subtração) \* (multiplicação) / (divisão) // (divisão inteira) % (módulo) \*\* (exponenciação).
- Operadores de atribuição.
  - = (atribuir valor) += (somar) -= (subtrair).






# Listas e dicionários


- Listas
  - São estruturas de dados que armazenam coleções ordenadas de itens. Elas são mutáveis, o que significa que seus elementos podem ser alterados após a criação da lista. Listas podem conter elementos de diferentes tipos, como inteiros, strings, flutuantes ou até mesmo outras listas.

- Exemplo:

# Lista de strings

```
frutas = ["maçã", "banana", "laranja"]
```





# Listas e dicionários

- Dicionário
  - São coleções de pares chave-valor, nas quais cada chave é única e mapeada para um valor correspondente

- Exemplo:


```
dicionario = {}
```


```
aluno = { "nome": "Rodrigo",
```

```
"idade": 33,
```

```
"curso": "Ciência dos Dados"
```

```
• }
```







# Estruturas de comparação

- IF (se)
  - Permite executar um bloco de código apenas se uma determinada condição for verdadeira. Basicamente, ele avalia uma expressão booleana (verdadeira ou falsa) e, se a condição for verdadeira, o bloco de código associado ao "if" é executado. Se a condição for falsa, o bloco de código é ignorado.

IF (se) ELSE (senão)


IF (se) ELIF (senão se) ELSE (senão)





# Estruturas de repetição

- FOR
  - Um loop "for" é usado para iterar sobre uma sequência (que pode ser uma lista, uma tupla, um dicionário, um conjunto ou uma string).
- WHILE
  - Com o loop "while" podemos executar um conjunto de instruções enquanto uma condição for verdadeira.



# Linguagens de programação para ciência de dados: configuração de ambiente, sintaxe e bibliotecas

Bibliotecas para Ciência de Dados: NumPy, Pandas, Matplotlib e Seaborn

**Bloco 3**

Rodrigo Rocha



# NumPy

NumPy é uma biblioteca fundamental para a computação científica em Python, amplamente utilizada para realizar operações numéricas de forma eficiente.

NumPy oferece suporte a arrays e matrizes multidimensionais, junto com uma coleção de funções matemáticas para operar nesses arrays.

Exemplo:

```
data = np.array([1, 2, 3, 4, 5, 6])
```

```
# Média
```

```
mean = np.mean(data) # Resultado: 3.5
```


```
# Desvio padrão
```

```
std_dev = np.std(data)
```

```
# Resultado: 1.707825127659933
```







# Pandas

Pandas é uma biblioteca essencial para análise e manipulação de dados.

Ela fornece estruturas de dados flexíveis, como DataFrames, facilitando o manuseio e a análise de grandes conjuntos de dados.

Exemplo:


```
import pandas as pd


data = {'nome': ['Rodrigo', 'João', 'Vivian'], 'age': [48, 46, 8]}
df = pd.DataFrame(data)

print(df)

print(df.head())    # Exibir as primeiras linhas

print(df.describe()) # Estatísticas descritivas
```





# Matplotlib

Matplotlib é uma biblioteca de plotagem em 2D que permite a criação de gráficos estáticos, animados e interativos em Python.

Exemplo:

```
pip install matplotlib # instalação
```

```
import matplotlib.pyplot as plt
```

```
plt.plot([1, 2, 3, 4], [1, 4, 9, 16])
```


```
plt.xlabel('x')
```

```
plt.ylabel('y')
```

```
plt.title('Gráfico Simples')
```

```
plt.show()
```





# Scikit-learn

Scikit-learn é uma biblioteca de *machine learning* (aprendizado de máquina) em Python, que oferece ferramentas simples e eficientes para análise e mineração de dados. Ela é construída sobre outras bibliotecas populares de Python, como NumPy, SciPy e Matplotlib.

## Aprendizado supervisionado

- O modelo é treinado usando um conjunto de dados rotulado. Isso significa que cada exemplo de treinamento é composto por uma entrada e a saída desejada (rótulo). O objetivo do modelo é aprender a mapear as entradas para as saídas corretas, de modo a fazer previsões precisas para novos dados não vistos.

## Aprendizado não supervisionado

- O modelo é treinado usando um conjunto de dados sem rótulos. O objetivo é identificar padrões ou estruturas ocultas nos dados. Como não há saídas conhecidas, o modelo busca agrupar os dados com base em similaridades ou reduzir a dimensionalidade para simplificar a análise.



# Linguagens de programação para ciência de dados: configuração de ambiente, sintaxe e bibliotecas

## Teoria em prática

### **Bloco 4**


Rodrigo Rocha

## Reflita sobre a seguinte situação

Uma empresa de e-commerce deseja realizar uma análise detalhada de seus dados de vendas para identificar tendências de mercado, comportamento de clientes e oportunidades de crescimento. Com uma base de dados robusta contendo informações sobre transações, produtos, clientes e datas de vendas, a empresa busca obter insights que auxiliem na tomada de decisões estratégicas.

**Qual(is) bibliotecas de Python você utilizaria e por quê?**





# Norte para a resolução




## Pontos para pensar

- Identificar sazonalidade.
- Gerenciar estoque.
- Tipos de visualização.


## Outros pontos-chaves

- Planejar estratégias de marketing.
- Insights.
- Tomar decisões informadas.






# Norte para a resolução



- Pesquisar e identificar os componentes:




# Linguagens de programação para ciência de dados: configuração de ambiente, sintaxe e bibliotecas

Consolidando o aprendizado

**Bloco 5**

Rodrigo Rocha





# Consolidando o aprendizado

- A Ciência de Dados é o campo que combina Estatística, Matemática e Computação para extrair insights e conhecimento a partir de dados.
- Python é de grande relevância para a Ciência dos Dados devido à sua simplicidade e versatilidade, que facilitam a manipulação e análise de grandes volumes de dados.
- Sua sintaxe intuitiva e a forte comunidade de desenvolvedores tornam Python acessível tanto para iniciantes quanto para profissionais experientes.
- Possui uma vasta gama de bibliotecas especializadas, como Pandas para manipulação de dados, NumPy para cálculos numéricos, Matplotlib e Seaborn para visualização, e Scikit-learn para aprendizado de máquina.





## Quiz



Qual biblioteca de Python é usada para manipulação e análise de dados estruturados?

**A**

Matplotlib.

**B**

Pandas.

**C**

Scikit-learn.

**D**

TensorFlow.



## Quiz



Qual biblioteca de Python é usada para manipulação e análise de dados estruturados?

**A**

Matplotlib.

**B**


Pandas.

**C**

Scikit-learn.

**D**


TensorFlow.




## Quiz – Resolução

Resposta correta: **B) Pandas.**

Pandas é a biblioteca de Python amplamente utilizada para manipulação e análise de dados estruturados, oferecendo ferramentas poderosas para trabalhar com DataFrames e séries temporais.






## Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!






## Indicação de leitura 1

O artigo a seguir fala sobre a identificação do maior aeroporto do interior do Estado de São Paulo, utilizando fatores que determinam a viabilidade de hubs regionais do modal aeroportuário, com dados de 2008 a 2014. Para isso, utiliza técnicas de Ciência de Dados.

### Referência

BONETTE, Luiz Rodrigo *et al.* Análise do aeroporto de Ribeirão Preto sobre a perspectiva de séries temporais de passageiros e cargas aplicadas por regressão linear múltipla. **Revista de Ciências Exatas e Tecnologia**, v. 11, n. 11, 2016.




## Indicação de leitura 2

O artigo a seguir fala sobre o paradigma de "*reservoir computing*", uma rede neural recorrente construída de forma aleatória cuja camada intermediária não precisa ser treinada. Ele sintetiza conceitos, métodos e pesquisas recentes sobre o tema, servindo como apoio teórico para outros trabalhos. A revisão bibliográfica abrange pesquisas de 2007 a 2017, focando na implementação e otimização do paradigma. O artigo apresenta trabalhos recentes que contribuem para o desenvolvimento de "*reservoir computing*" e destaca diversos tópicos abertos à pesquisa, oferecendo direcionamento para a comunidade científica.

### Referência

JULIANI, Fernando. Reservoir Computing: uma Abordagem Conceitual. **Revista de Ciências Exatas e Tecnologia**, v. 13, n. 13, 2018.





# Referências

BONETTE, Luiz Rodrigo *et al.* Análise do aeroporto de Ribeirão Preto sobre a perspectiva de séries temporais de passageiros e cargas aplicadas por regressão linear múltipla. **Revista de Ciências Exatas e Tecnologia**, v. 11, n. 11, 2016. Disponível em: <https://exatastecnologias.pgsscogna.com.br/rcext/article/view/4244>. Acesso em: 29 jul. 2024.


JULIANI, Fernando. Reservoir Computing: uma Abordagem Conceitual. **Revista de Ciências Exatas e Tecnologia**, v. 13, n. 13, 2018. Disponível em: <https://exatastecnologias.pgsscogna.com.br/rcext/article/view/5424>. Acesso em: 29 jul. 2024.

NUMPY. **NumPy**. Disponível em: <https://numpy.org/>. Acesso em: 15 jun. 2024.

PYTHON. **Python**. Disponível em: <https://pytohn.org/>. Acesso em: 15 jun. 2024.








# Referências

SCIKIT LEARN. **Scikit-learn Machine Learning in Python**. Disponível em: <https://scikit-learn.org>. Acesso em: 15 jun. 2024.

SEABORN. **Seaborn: statistical data visualization**. Disponível em: <https://seaborn.pydata.org/>. Acesso em: 15 jun. 2024.





Bons estudos!