



MACHINE LEARNING

Stella Marys Dornelas Lamounier

MACHINE LEARNING

1ª edição

Londrina
Editora e Distribuidora Educacional S.A.
2024

© 2024 por Editora e Distribuidora Educacional S.A.

Todos os direitos reservados. Nenhuma parte desta publicação poderá ser reproduzida ou transmitida de qualquer modo ou por qualquer outro meio, eletrônico ou mecânico, incluindo fotocópia, gravação ou qualquer outro tipo de sistema de armazenamento e transmissão de informação, sem prévia autorização, por escrito, da Editora e Distribuidora Educacional S.A.

Diretora Sr. de Pós-graduação & OPM

Silvia Rodrigues Cima Bizatto

Conselho Acadêmico

Alessandra Cristina Fahl
Ana Carolina Gulelmo Staut
Camila Braga de Oliveira Higa
Camila Turchetti Bacan Gabiatti
Giani Vendramel de Oliveira
Gislaine Denisale Ferreira
Henrique Salustiano Silva
Juliana Schiavetto Dauricio
Juliane Raniro Hehl
Mariana Gerardi Mello
Nirse Ruscheinsky Breternitz

Coordenador

Juliana Schiavetto Dauricio

Revisor

Lucas dos Santos Araujo Claudino

Editorial

Beatriz Meloni Montefusco
Márcia Regina Silva
Paola Andressa Machado Leal
Rosana Silverio Siqueira

Dados Internacionais de Catalogação na Publicação (CIP)

L236m Lamounier, Stella Marys Dornelas
Machine learning / Stella Marys Dornelas Lamounier. –
Londrina: Editora e Distribuidora Educacional S.A., 2024.
32 p.

ISBN 978-65-5903-732-2

1. Aprendizado de máquina. 2. Algoritmos de
machine learning. 3. Inteligência artificial. I. Título.

CDD 006.31

Evelyn Moraes – CRB 8/010289

2024
Editora e Distribuidora Educacional S.A.
Avenida Paris, 675 – Parque Residencial João Piza
CEP: 86041-100 — Londrina — PR
Homepage: <https://www.cogna.com.br/>

 MACHINE LEARNING**SUMÁRIO**

Apresentação da disciplina	05
Introdução ao Machine Learning e Ambientes de Desenvolvimento	07
Aprendizado Supervisionado – Técnicas de Classificação e Regressão	21
Aprendizado Não Supervisionado e Redução de Dimensionalidade	36
Sistemas de recomendação	51

Apresentação da disciplina

Bem-vindo(a) à disciplina *Machine Learning*, uma das áreas mais abrangentes da tecnologia moderna. Muitas inovações, incluindo a aprendizagem de máquina, moldam a forma como interagimos com dados e fazemos decisões certas. O machine learning oferece ferramentas poderosas para automatizar e otimizar processos em várias áreas, como recomendar produtos, fazer previsões de vendas ou analisar grandes volumes de dados.

O objetivo inicial desta disciplina é fornecer uma visão geral de machine learning e ensinar a você os métodos necessários para análise e construção de modelos preditivos. A aprendizagem supervisionada e não supervisionada serão abordadas ao longo da disciplina, e você vai adquirir uma compreensão de seus algoritmos principais e aprender a aplicá-los a problemas reais, a fim de distinguir os modelos de classificação e regressão.

Você ainda obterá o domínio das bibliotecas Python mais importantes usadas para análise de dados e aprendizagem de máquina, como Scikit-learn, Pandas e Matplotlib, que são essenciais para o desenvolvimento e a visualização dos modelos apresentados. Além disso, abordaremos métodos sofisticados de visualização de dados de alta dimensionalidade, que são essenciais para a interpretação de grandes conjuntos de dados.

Por meio desta disciplina, você será capaz de utilizar esses conhecimentos de forma prática, preparando-se para atuar em um mercado cada vez mais movido por dados e tecnologia. Machine learning não apenas expande suas perspectivas profissionais, mas também desempenha um papel importante na criação de soluções

que têm um impacto real nas sociedades e nas empresas. Você pode transformar grandes quantidades de dados em insights valiosos ao dominar essa tecnologia. Isso ajudará as empresas a fazer escolhas mais inteligentes, melhorar seus processos e oferecer experiências personalizadas para seus clientes – e tudo isso você aprenderá nesta fascinante disciplina.

Introdução ao Machine Learning e Ambientes de Desenvolvimento

Autoria: Stella Marys Dornelas Lamounier

Leitura crítica: Lucas dos Santos Araujo Claudino

Objetivos

- Fornecer uma visão geral de machine learning.
- Entender as técnicas aprendizagem supervisionada e não supervisionada.
- Compreender a aplicação das principais bibliotecas Python para análise de dados em machine learning.


1. Visão geral do aprendizado de máquina

Recentemente, o aprendizado de máquina (machine learning) se tornou um tópico comumente discutido no contexto das ferramentas tecnológicas que auxiliam as empresas nos processos decisórios. Cada vez mais este termo ganha espaço nas organizações – mas não é um método totalmente novo no mercado: sua utilização começou por volta da década de 1950 com o engenheiro Arthur Samuel, que codificou um programa que simulava um jogo de damas cujo sistema computacional era capaz de aprimorar seu desempenho a cada nova jogada.

Sua popularização tomou força devido à grande quantidade de dados gerados pelas organizações atualmente. Além disso, a melhora no hardware também contribuiu para o desenvolvimento da aprendizagem de máquina. Este último elemento (hardware) proporciona uma maior acessibilidade das ferramentas de machine learning devido à diminuição do preço que suporta efetivamente estas atividades tecnológicas. Nos dias de hoje, é possível processar enormes quantidades de dados com um baixo custo de operação (Marques, 2017).

Nesse cenário, a aprendizagem de máquina é também um campo preocupado com a construção de programas de computador, os quais melhoram automaticamente a experiência do usuário ao focarem em aprender e realizar previsões ou decisões com base em dados. Em vez de serem explicitamente programados para executar uma tarefa específica como é feito na programação convencional (conforme ilustrado na Figura 1), seus algoritmos de aprendizado de máquina são projetados para aprender e melhorar ao longo do tempo, analisando grandes volumes de dados. Por isso, são amplamente usados em vários setores para tarefas como reconhecimento de imagem e fala, diagnóstico médico, sistemas de recomendação e previsões financeiras.

Figura 1 – Comparativo entre programação tradicional e aprendizagem de máquina (machine learning)




Fonte: Ris-Ala (2023, p. 18).

É muito importante saber diferenciar os principais algoritmos e técnicas de aprendizagem que norteiam este modelo. Podemos citar os modelos supervisionados, os não supervisionados e os modelos por reforço, que veremos a seguir.

2. Aprendizagem supervisionada e não supervisionada

Modelos supervisionados vêm como alternativa para trabalhar com dados já existentes, ou seja, seu modelo (algoritmo) é modulado de acordo com dados previamente existentes, e seu aprendizado se dá a partir deste conjunto de dados, conhecidos com dados de entradas ou *dataset*. Por exemplo, dados históricos que o profissional ou gestor já conhece, quer podem vir de uma base de dados com informações importantes de clientes em potencial, prontuários médicos e até mesmo históricos de compras. A Figura 2 retrata o funcionamento do aprendizado supervisionado.

Figura 2 – Estrutura de uma abordagem de aprendizado de máquina do tipo supervisionado



Fonte: adaptada de Escovedo (2020).

De acordo com a figura é possível estabelecer uma conexão entre a existência de dados de entrada que é relacionada como “Rótulo de dados” e “Dados de entrada”. O modelo de algoritmo de machine learning é treinado de acordo com essa base de dados já existente, e cada exemplo já vem acompanhado previamente de um rótulo de dados ou informação já existente, permitindo que o algoritmo aprenda a mapear as entradas para as saídas corretas, classificando ou predizendo o resultado/saída desejada.

2.1 Aprendizagem não supervisionada

Outra técnica amplamente utilizada em machine learning é de aprendizagem não supervisionada, que, diferentemente do modelo supervisionado, consiste em modelos que não necessitam de um conjunto de dados a priori, isto é, os dados que jamais foram classificados ou rotulados previamente. É um termo bastante utilizado em machine learning por realizar tarefas de agrupamento de dados



volumosos com diferentes tipos de dados que são agrupados de acordo com sua similaridade ou por meio de extração de padrões nos valores dos atributos.


Neste contexto, esta abordagem não supervisionada é caracterizada com conjunto de dados não rotulados, ou seja, os resultados ainda são desconhecidos. Analisando a estrutura que os dados produzem e seu modelo, é possível perceber que os dados diminuem a redundância de dados ou até mesmo agrupam dados semelhantes.

Porto Filho (2017, p. 24) complementa:

A Aprendizagem de Máquina não Supervisionada é feita com dados não rotulados, ou seja, não se sabe quantas ou classes existem. É uma técnica usada para encontrar subgrupos ou projetos. O objetivo é classificar as entidades em grupos mutuamente exclusivos baseados em similaridade entre as instâncias. Os grupos não são pré-definidos e não há a presença de um “professor”, daí o elemento não supervisionado.

Trata-se de um modelo um pouco mais complexo que o de aprendizagem supervisionada, exatamente porque ainda não se tem dados de entrada, assim, seus atributos são definidos pela própria máquina. A Figura 3 ilustra o esquema da aprendizagem não supervisionada.

Figura 3 – Estrutura de uma abordagem de aprendizado de máquina do tipo não supervisionado




Fonte: elaborada pela autora.

Observando a figura, é possível notar que não existe a presença do rótulo de dados, característica que difere os dois modelos apresentados.

3. Aprendizagem por reforço e ambientes de desenvolvimento

Aprendizagem por reforço é uma técnica em que o agente interage com o ambiente, sendo capaz de tomar decisões baseadas a partir das consequências de suas ações – ou seja, ele recebe uma “recompensa” ou “punição” para aprender com essa experiência, como mostra a Figura 4.

Figura 4 – Estrutura de aprendizagem por reforço



Fonte: elaborada pela autora.

Este modelo de aprendizagem é amplamente usado em áreas como robótica, sistema aéreos, terrestre e aquático, visão computacional para carros autônomos, e em jogos de xadrez, por apresentar altas taxas de sucesso quando se trata de tarefas complexas e com possibilidade de descobrir quais são as melhores ações mesmo sem conhecer totalmente o ambiente.

Como vemos, o funcionamento dessa técnica se dá pelo comportamento do agente que descobre a sua melhor performance por meio de tentativa e erro ele, recebendo um feedback acerca da escolha realizada, o que garante um reforço maior por parte.

De acordo com Ris-Ala (2023, p. 23, 24), é importante, quando utilizar este tipo de aprendizagem, ter em mente alguns conceitos:

- **Agente:** responsável pela interação com o ambiente.
- **Ação:** comportamento, situações e ações do agente; atividades que ele é capaz de executar, como direcionar para alguns lugares, movimentar-se etc.

- **Estado:** é a posição ou conjuntura em que o agente se encontra em um determinado momento.
- **Recompensa:** é a retribuição, que pode ser tanto negativa quanto positiva.
- **Política:** é o objetivo da aprendizagem; são as estratégias que o agente deve percorrer a fim que seja conduzido à melhor solução do problema.
- **Episódio:** é o cenário como um todo; o conjunto das ações que só termina quando se alcança um determinado objetivo.

Sabemos, então, que machine learning é utilizado para fornecer à máquina a habilidade de entender/aprender os padrões contidos nos dados sem a utilização de uma programação explícita, por meio de experiências passadas. Foram apresentadas três abordagens de diferentes modelos de aprendizagem, e antes mesmo da escolha da técnica a ser empregada, é fundamental analisar as peculiaridades e a complexidade de cada uma a fim de chegar a uma melhor solução, de modo que esta possa ser bem adaptada para resolução de um problema, enquanto alguma outra técnica pode apresentar-se como desastrosa.

4. Ferramentas e ambientes de desenvolvimento

Ferramentas e ambientes de desenvolvimento são produtos ou trabalhos de que um projeto necessita para a implementação de sistemas, independentemente do tipo de linguagem de programação adotada, ou seja, é um conjunto de atividades que, quando colocado



em prática, faz com que o projeto funcione de modo eficiente e mais atrativo para os usuários.

Trata-se também de sistemas de apoio a processos de desenvolvimento de software que visam apoiar cada uma das atividades durante o ciclo de vida do software, combinando técnicas, métodos e ferramentas para abranger e facilitar as atividades relacionadas ao planejamento, gerenciamento, desenvolvimento, testes e, principalmente, ao controle de qualidade.

Inúmeras são essas ferramentas que possibilitam a criação de sistemas computacionais, em especial aquelas que trabalham com machine learning. Neste contexto, temos que pensar que, além das ferramentas, nos importamos também com o ambiente computacional a ser trabalhado e a linguagem de programação mais apropriada, para que os insights gerados sejam os mais precisos possível.

Neste cenário destaca-se uma linguagem de alto nível, orientada a objetos, conhecida como Python, ideal para o desenvolvimento em diversos tipos de plataformas. Ela tem, em sua essência, liberdade, disponibilidade e alta produtividade, por ser de código aberto e altamente modular, significando que algum outro desenvolvedor já fez partes ou o todo de um programa que ainda vai ser criado.

Em Python existe uma variedade de bibliotecas com finalidades diferentes, que são caracterizadas por seus módulos e funções específicas, oferecendo inúmeros recursos. Quando se pretende trabalhar com machine learning, é preciso compreender as bibliotecas próprias para este tipo de técnica – como dito, existe uma gama de bibliotecas que trabalham com aprendizado de máquina, das quais destacar as mais usadas: NumPy, Pandas e Matplotlib.

4.1 NumPy

NumPy ou Numerical Python é uma poderosa biblioteca Python usada para trabalhar com cálculos numéricos e científicos, por exemplo, com álgebra linear e matrizes multidimensionais (arrays).

Ao se falar de matrizes em Python, temos que considerar que são verdadeiramente lentas, e utilizando NumPy seu poder de processamento aumenta em mais de 50 vezes quando comparada a outras bibliotecas tradicionais. Isso se dá pelo fato de que esses arrays são armazenados em um local contínuo na memória, diferentemente das listas, para que os processos possam acessá-las e manipulá-las de forma muito eficiente, o que as torna de extrema importância em machine learning, em que velocidade e recursos são de extrema importância para a manipulação de dados.

A biblioteca pode ser encontrada para download de forma gratuita e de código aberto no site da própria biblioteca NumPy¹.

Portanto, NumPy, além de fornecer um conjunto de funções e operações aritméticas utilizando matrizes, é amplamente utilizada em modelos de machine learning por disponibilizar em suas bibliotecas maneiras de execução de cálculos de forma rápida e fácil, com o uso de arrays capazes de armazenar de forma precisa dados de treinamento e parâmetros dos diversos modelos de aprendizado de máquina.

4.2 Pandas

Pandas também é um pacote Python de código aberto, muito conhecida na ciência de dados. Seu nome advém do termo *Panel Data*, relacionado

¹ 1 Biblioteca NumPy: <https://pypi.org/project/numpy/>

ao campo da econometria para conjuntos de dados que incluem observações em vários períodos para os mesmos indivíduos.

Fornece estruturas de dados rápidas, flexíveis e expressivas projetadas para tornar o trabalho com dados mais fácil e intuitivo, realizando atividades em machine learning que vão desde limpeza, análise, exploração e visualização de dados, para fornecer estruturas de dados rápidas, flexíveis e expressivas.

A funcionalidade da Pandas inclui transformações de dados em Python, tabulações na forma de linhas e colunas (DataFrames) para a tabulação de dados seja para reorganizar, formatar, manipular ou agregar em subconjuntos de dados, como também para calcular dados estatísticos de forma resumida como a média. A Tabela 1 ilustra DataFrames.

Tabela 1 – DataFrames

Código	Nome	Matemática	Português
0	Maria	6,5	8,5
1	Pedro	4,5	9,2
2	Marcelo	5,2	9,8
3	Patrícia	8,0	4,9
4	Soraia	5,2	6,3

Fonte: elaborada pela autora.

É perceptível que um DataFrame é composto por linhas e colunas, fornecendo assim a manipulação dos dados de forma estruturada, o que possibilita, para a análise de dados, benefícios de um código com menos linhas e de melhor entendimento, visualização de dados univariados e bivariados de forma mais clara e intuitiva, e agilidade ao trabalhar com grande volume de dados, mesmo que estes dados estejam ausentes.

4.3 Matplotlib

Matplotlib é uma biblioteca para plotagem de gráficos em Python usada para criar visualizações estáticas, animadas e interativas. O propósito principal do Matplotlib é fornecer aos usuários ferramentas e funcionalidades para representar dados graficamente em 2D e 3D, tornando-os mais fáceis de analisar e entender.

Suas principais características englobam versatilidade e personalização, por apresentar inúmeros modelos de gráficos, como gráfico de linhas, de haste, de barras, histogramas, dispersão, de pilha etc., como pode ser observado na Figura 5. É uma biblioteca multiplataforma que pode ser usada tanto em Linux quanto Windows e MacOS. Dispõe de uma documentação muito rica e um forte suporte em sua comunidade de usuários e desenvolvedores, facilitando a busca por ajuda, tutoriais e exemplos.

Matplotlib apresenta uma extensa variedade de formatos gráficos, o que torna essa biblioteca muito abrangente quanto se fala em visualizações de Python, criando figuras com qualidade e interativas em todas as plataformas em que é implantada.

Portanto, existem inúmeras bibliotecas em Python, cada uma com seus propósitos particulares, que trazem para os desenvolvedores e usuários uma melhor otimização do código. O que deve ser levado em consideração na hora da escolha é identificar qual o tipo de aprimoramento e objetivo que se quer e alcançar, para que você seja capaz de produzir resultados satisfatórios.

Conectando à Realidade: Exemplos Práticos

Imagine que você trabalha em uma grande instituição financeira e seu papel é fazer a análise de dados para prospecção de novos clientes, utilizando novas estratégias de marketing que podem alavancar essa captação.

Neste caso, você terá que analisar o grande banco de dados dessa empresa, que contém informações pessoais de cada cliente e seu comportamento financeiro ao longo do tempo. Usando técnicas de machine learning, e com base nos conhecimentos adquiridos na disciplina, você será capaz de extrair e transformar esses dados para auxiliar os gestores a captarem clientes em potencial, resultando em maior receita e melhor relação com os clientes.

Aplicabilidade

Realizar a extração dos dados, analisá-los para notar qualquer erro nos dados brutos e, posteriormente, transformá-los a ponto que, independentemente da técnica utilizada, o resultado saia sem haver qualquer tipo de erro que possa atrapalhar na tomada de decisão.

Analisar as técnicas de machine learning mencionadas para captar futuros clientes que coincidam com o perfil que a instituição financeira deseja.

Aplicar a técnica escolhida na linguagem Python com a biblioteca apropriada para a execução do algoritmo.

Referências

ESCOVEDO, T. **Machine Learning**: Conceitos e Modelos. Medium, 28 um. 2020. Disponível em: <https://tatianaesc.medium.com/machine-learning-conceitos-e-modelos-f0373bf4f445>. Acesso em: 20 jun. 2024.

HUNTER, J. *et al.* **Plot Types**. Matplotlib, [s. d.]. Disponível em: https://matplotlib.org/stable/plot_types/index.html. Acesso em: 9 jul. 2024.

MARQUES, K. L. **O que é Machine Learning (ML)? Exemplos & Aplicações!** Bencode, 1 set. 2017. Disponível em: <https://becode.com.br/o-que-e-machine-learning/>. Acesso em: 6 jul. 2024.

MULINARI, B. **Numpy Python:** O que é, vantagens e tutorial inicial. Harce, [s. d.]. Disponível em: <https://harve.com.br/blog/programacao-python-blog/numpy-python-o-que-e-vantagens-e-tutorial-inicial/>. Acesso em: 9 jul. 2024.

PORTO FILHO, C. H. **Técnicas de aprendizado não supervisionado baseadas no algoritmo da caminhada do turista.** 2017. 122 f. Dissertação (Mestrado em Ciências) - Universidade de São Paulo, São Carlos, 2017. Disponível em: https://www.teses.usp.br/teses/disponiveis/82/82131/tde-20082018-122603/publico/Dissert_CarlosPortoFilho_corrigida.pdf. Acesso em: 2 ago. 2024.

RIS-ALA, R. **Fundamentos de Aprendizagem por Reforço.** [S. l.]: Rafael Ris-Ala, 2023.

SANTOS, E. C. **Alocação de Recursos baseada em Clustering com Aprendizado de Características e Orientação a QoS em Redes LTE-Advanced.** 2019. 130 f. Tese (Doutorado em Engenharia Elétrica) – Programa de Pós-Graduação em Engenharia Elétrica, Faculdade de Engenharia Elétrica da Universidade Federal de Uberlândia, Uberlândia, MG, 2019. Disponível em: <https://repositorio.ufu.br/bitstream/123456789/25825/1/Aloca%C3%A7%C3%A3oRecursosBaseada.pdf>. Acesso em: 8 out. 2024.

SERRA, M. R. G. **Aplicações de aprendizagem por reforço em controle de tráfego veicular urbano.** 2004. Tese (Doutorado em Engenharia Elétrica) - Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal de Santa Catarina, Florianópolis, SC.

Aprendizado Supervisionado – Técnicas de Classificação e Regressão

Autoria: Stella Marys Dornelas Lamounier

Leitura crítica: Lucas dos Santos Araujo Claudino

Objetivos

- Entender o funcionamento da técnica de aprendizagem supervisionada.
- Compreender e diferenciar modelos de classificação e regressão.
- Entender a aplicação dos principais algoritmos de classificação e regressão.

1. Aprendizado de Máquina (Machine Learning)

Cada vez mais o aprendizado de máquina tem ganhado espaço no mercado de trabalho e tomando forças graças às imensas massas de dados geradas pelas organizações depois da popularização da internet. Além disso, o melhoramento tecnológico de hardware potencializou ainda mais o desenvolvimento desta tecnologia. Este último elemento (potência) proporciona uma maior acessibilidade das ferramentas de machine learning devido à diminuição do preço dos hardwares que suportam efetivamente essas atividades tecnológicas, deste modo, atualmente é possível processar enormes quantidades de dados com um baixo custo de operação, ajudando a encontrar insights e padrões valiosos nos dados, que não são identificados por métodos tradicionais. No mundo real, essas técnicas oferecem uma maneira de identificar tendências, prever comportamentos e fazer recomendações baseadas em fatos para aplicações de gestão, mecanismos de segurança, carros autônomos e campanhas de marketing, por exemplo (Brink *et al.*, 2017).

Sabemos que o aprendizado de máquina é uma ferramenta poderosa para aquisição de conhecimento e resultados satisfatórios, mas por si só não é possível aplicar técnicas em uma massa de dados em seu formato original, devido a diferentes características, dimensões e formatos que estes dados podem apresentar no espaço de tempo. É, então, necessário, antes de iniciar o processamento, realizar o tratamento dos dados, ou seja, tratar as informações que podem prejudicar o resultado esperado – por exemplo, dados faltosos, inconsistentes ou ruidosos –, tornando a base de dados suscetível à utilização de técnicas.

Após a análise destes dados, deve-se também observar que aprendizado de máquina não apresenta apenas um algoritmo, e sim uma infinidade

de modelos com características distintas e singulares. É importante entender como suas limitações e a utilização da técnica apropriada permitem ao usuário escolher o modelo mais adequado para a resolução do problema

2. Aprendizagem Supervisionada

Nestes modelos, os dados de entrada já estão previamente rotulados, isto é, os atributos de entrada e saída já são conhecidos – por exemplo, são dados históricos relacionados a perfil de habitantes de uma certa região, classificação de e-mails como spam e não spam, informações de imóveis que contenham dados como localização e tamanhos –, e busca-se, a partir destes conjuntos, dados já conhecidos, para prever resultados mais precisos em relação à predição de valores para novos dados.

De acordo com Silva (2018), o conceito de aprendizado supervisionado é:

Aprendizagem supervisionada é a tarefa de encontrar uma função a partir de dados de treinamento rotulados. O objetivo é encontrar os parâmetros ótimos que ajustem um modelo que possa prever rótulos desconhecidos em outros objetos (o conjunto de teste). Se o rótulo é um número real, a tarefa chama-se regressão. Se o rótulo vem de um conjunto finito e não ordenado, então a tarefa chama-se classificação.


Modelos de aprendizado supervisionados são divididos em modelos de classificação e regressão. Os modelos classificatórios são mais utilizados, mais populares e com maior número de algoritmos em machine learning, porém, são tratados como os mais complexos da categoria.

2.1 Modelos de Classificação: algoritmos kNN, SVM (*Support Vector Machines*) e Random Forest

Em problemas de classificação, os dados buscam encontrar suas classes dentro dos limites estabelecidos. Tais limites podem ser letras ou palavras, e por isso são tratadas como variáveis categóricas.

Os dados são organizados em classes com bolinhas azuis e cruzeiros de cor lilás, enquanto as bolinhas amarelas representam os dados mais recentes a serem classificados, como pode ser notada, na Figura 1, a classificação de um e-mail como “é spam” ou “não é spam”. O conceito é obter um conjunto de dados em que já existam essas duas categorias, permitindo que o algoritmo encontre os padrões determinados por cada classe. Isso permite que ele leia e classifique um e-mail com uma bolinha amarela e o considere spam ou não spam.

Figura 1 – Separação e classificação de dados



Fonte: Korbut (2017).

Ainda de acordo com esse modelo, podemos dizer que algoritmos de classificação buscam classificar os dados em diferentes classes, ou seja, um certo conjunto de dados é associado a uma determinada classe – seu agrupamento se dá de acordo com características de grupos específicos, e associa-se ou classifica-se um item em uma ou várias classes predefinidas. Seu objetivo maior é atribuir classes (ou rótulos) a um conjunto finito de dados, e suas respostas geralmente são definidas

por variáveis ditas categóricas, com resultados nominais, que por muitas vezes são aplicadas em detecção de spam, reconhecimento de imagens e fala.

Muitos algoritmos podem ser utilizados para resolver problemas de classificação, e a seguir vamos conhecer alguns.

2.1.1 Algoritmo k-NN k-Nearest Neighbors (KNN)

O kNN ou Nearest Neighbour Retrieval (vizinho mais próximo) é um modelo de algoritmo que não necessita de métodos de aprendizagem. Sua função principal é o armazenamento de dados inteiros. Para isso, a previsão é feita utilizando o conjunto de dados de treinamento, dados estes já com conhecimento a priori.

Segundo Kotsiantis *et al.* (2006), K-Nearest Neighbor é um método de predição que utiliza da distância entre a amostra atual e seus k vizinhos mais próximos no conjunto de treinamento para definir qual será o resultado de sua predição. Ele pode ser utilizado tanto para a realização de regressão quanto para a classificação. Neste último caso, a máquina determina um grupo com base nas amostras vizinhas.

A distância mais comum utilizada para a medição é a distância euclidiana, mas outras podem ser usadas, como a distância de Chebyshev, a distância Manhattan e a distância Minkowski.

Com base na distância, após a definição do conjunto de dados para treinamento o algoritmo classifica o novo dado, e os K vizinhos mais próximos do novo dado servem para decidir a qual classe ele pertence. É utilizando o método de votação simples que a classe com maior frequência recebe o novo dado (Witten; Frank; Hall, 2011).

Para melhor compreensão deste modelo, apresentamos o seguinte pseudocódigo:

Inicialização:

Preparar o conjunto de dados de entrada e saída.

Informar o valor de K .

Para cada nova amostra faça:

Calcular a distância de todas as amostras.

Determinar o conjunto de k 's distâncias mais próximas.

O rótulo com mais representantes dos conjuntos dos k 's.


Vizinho será escolhido.

Fim para

Retornar: conjunto de dados de classificação.

Ainda podemos exemplificar o kNN com suas classes definidas pelos rótulos do conjunto de dados de treinamento. A Figura 2 ilustra um conjunto de dados dividido em três classes ($k=3$) e dois atributos (salário e idade). Quando uma nova instância é adicionada, o algoritmo calcula a distância entre esse dado e seus k vizinhos mais próximos. A partir da proximidade, determina-se a qual classe o novo dado pertence. No exemplo da Figura 2, pode-se verificar que a nova instância está mais próxima ao grupo B; portanto, ela pertence a este grupo.

Figura 2 – Separação de dados em classes algoritmo KNN



Fonte: elaborada pela autora.


2.1.2 Máquina de Vetores de Suporte (SVM)

A máquina de vetores de suporte (SVM – *Support Vector Machine*) é um algoritmo de aprendizado supervisionado criado a partir de ideias iniciadas em 1964 no trabalho *Generalised Portrait Method*, de Vapnik e Chervonenkins (Chervonenkins, 2013). O SVM inicialmente foi criado como uma técnica de classificação, e posteriormente se tornou uma ferramenta eficaz na estimativa de funções que utilizam regressão de valores reais. Na literatura, a nomenclatura na regressão pode ser encontrada como SVM ou SVR (*Support Vector Regression*). Este tipo de algoritmo mapeia os dados de entrada de treinamento para encontrar um hiperplano que separe as duas categorias no espaço multidimensional, e após o treinamento o mecanismo é capaz de

determinar a qual dessas classes um item desconhecido pertence. O melhor hiperplano para um SVM significa aquele com a maior margem entre as duas classes (Russell; Norvig, 2013).

Muitas são as características deste modelo, e ele é muito usado para reconhecimento de voz, imagem e visão computacional. A Figura 3 mostra duas classes separadas: uma azul e outra laranja; se novos objetos, ao entrarem para a análise, estiverem mais para a esquerda serão classificados na classe azul, caso contrário, se estiverem posicionados mais à esquerda serão classificados na classe laranja.

Figura 3 – Separação de dados no modelo SVM simples



Fonte: <https://analisemacro.com.br/wp-content/uploads/2023/10/svm1.jpeg>. Acesso em: 8 out. 2024.

2.1.3 Random Forest

Random forest, ou florestas aleatórias como são popularmente conhecidos, é um modelo de algoritmo de aprendizagem de máquina que tem como objetivo principal fornecer uma saída desejada a partir de um conjunto de árvores de decisão que trabalham juntas.




Neste contexto, o algoritmo cria modelos árvores de decisão de forma aleatória baseado na utilização de vários conjuntos de dados para treinamento, criando, assim, subconjuntos de árvores de decisão altamente adaptáveis, formando uma floresta aleatória. Cada árvore é construída usando este subconjunto retirado do conjunto de dados para medir um subconjunto aleatório de recursos em cada partição. Essa aleatoriedade introduz variabilidade entre árvores individuais, reduzindo o risco de *overfitting*, melhorando o desempenho geral da previsão e fornecendo previsões confiáveis em diferentes ambientes.

Segundo Raschka (2019), na predição, o algoritmo agrega os resultados de todas as árvores, seja por votação (para tarefas de classificação) ou por média (para tarefas de regressão). Esse processo de tomada de decisão colaborativa, apoiado por várias árvores com seus insights, fornece um exemplo de resultados estáveis e precisos. Florestas aleatórias são amplamente usadas para funções de classificação e regressão, que são conhecidas por sua capacidade de lidar com dados complexos.

O modelo cria regras para a tomada de decisão, gerando uma estrutura com nós na qual determinada condição é verificada, simulando um formato de fluxograma. Caso essa condição seja satisfatória, o fluxo segue para o próximo nó, caso contrário, segue-se para outro nó até que seja finalizada a árvore (Han *et al.*, 2011).

A Figura 4 ilustra como este modelo é confeccionado para selecionar amostras de treino de forma aleatória. Nessa etapa, é usado o *bootstrap*, um método de amostragem no qual as amostras selecionadas podem ser repetidas durante o processo de seleção. A próxima etapa é a definição e a seleção dos nós que são as condições que devem ser analisadas para o processo de decisão.

Figura 4 – Representação do algoritmo random forest



Fonte: <https://www.researchgate.net/publication/371135250/figure/fig1/AS:11431281162694074@1685405275570/Figura-1-Representacao-esquematica-de-uma-Floresta-Aleatoria-Fonte-Os-autores-2022.png>. Acesso em: 8 out. 2024.

2.2 Modelos de regressão e peculiaridades de implementação

A tarefa de aprender uma função $f(x)$ que mapeie cada conjunto de atributos x em uma saída com valor contínuo y é a definição da regressão. Portanto, é uma modelagem preditiva que analisa as dependências entre um conjunto de valores de atributos e cria um modelo capaz de prever valores de atributos para novos (Tan; Steinbach; Kumar, 2006).

Modelos de algoritmos que tratam problemas de regressão têm como tarefa prever uma variável numérica por meio do atributo de saída. Portanto, utilizando valores de entrada, deve-se encontrar uma função que mapeie o exemplo de cada número, prevendo um valor real.



Os modelos de regressão predizem um número, também conhecido como predição funcional – por exemplo, quanto de receita ou despesas que um cliente gerará no próximo ano ou mês.

O modelo de regressão é um dos métodos mais populares em estatística. É, por exemplo, utilizado para determinar quanto cada fator específico, como a alta do dólar, influencia o movimento do preço de um determinado produto. A análise de regressão é usada para prever um número conhecido como resposta ou variável Y. Com regressão linear, é possível estabelecer uma relação entre uma variável dependente com uma ou mais independentes. Essa técnica pode ser dividida em regressão linear simples, em que uma variável independente explica e/ou prediz o resultado de Y; regressão múltipla, que prevê o resultado usando duas ou mais variáveis independentes; ou regressão logística, que prevê variáveis desconhecidas de uma variável discreta usando os valores conhecidos de outras variáveis.

A variável de resposta é categórica, o que significa que pode assumir apenas um número limitado de valores. A regressão logística realiza a classificação binária, portanto, o rótulo de resposta tem apenas dois valores, como 0 ou 1, contudo, o modelo mais usual é aquele que apresenta rótulos com número real (Silva, 2018).


De acordo com Nagai (2000), entende-se como regressão:

A Regressão consiste na modelagem dos dados com a finalidade de prever valores de um atributo meta-contínuo. Essa modelagem pode assumir diferentes formas de representação, com diferentes abordagens de aprendizado.

Inúmeras técnicas de regressão são originadas da estatística – por exemplo, a regressão linear simples, como afirma Paternelli (2003), como uma técnica capaz de verificar a existência de uma relação entre duas variáveis contínuas, ou seja, quando X pode explicar Y. Quando

essas duas variáveis estão relacionadas, é possível prever um valor de resposta. Neste modelo é fornecida uma linha que melhor ajusta o conjunto de dados que são usadas para a mudança na variável de resposta quando o preditor muda e prevê o valor de uma variável de resposta (y) para qualquer variável preditora (x), demonstrando a resposta desejada. Deste modo, é válido lembrar que a variável Y depende da variável X, conforme pode ser observado na Figura 5.

Figura 5 – Diagrama de dispersão das variáveis Prestígio e Educação



Fonte: adaptada de <https://www.researchgate.net/publication/370278860/figure/fig2/AS:1431281154241407@1682730909642/Figura-3-Exemplo-de-grafico-de-dispersao-e-reta-de-regressao-entre-as-variaveis-X-e-Y.png>. Acesso em: 8 out. 2024.

Para melhor entendimento dos dois modelos de regressão, o Quadro 1 a seguir faz comparação entre os dois modelos.

Quadro 1 – Regressão Linear versus Logística

Linear	Logística
Usada para prever a variável dependente contínua.	Usada para prever a variável dependente categórica.
A relação entre a variável dependente e variável independente deve ser linear.	Não é necessária a linearidade entre a variável dependente e a independente.
Estimamos na unidade de medida da variável dependente.	Estimamos a probabilidade da variável dependente.

Fonte: elaborado pela autora.

Portanto, vale ressaltar que existe uma infinidade de algoritmos que trabalham com as técnicas citadas, e cabe ao profissional de T.I. escolher o modelo certo para a aplicação na base de dados escolhida.

Conectando à Realidade:

Imagine que você trabalhe em uma empresa que desenvolve sistemas baseados em inteligência artificial. Você foi selecionado para analisar os dados para aplicar algumas técnicas de machine learning para a bolsa de valores. Neste contexto já se sabe que deve escolher uma técnica de regressão, pois ela é capaz de tratar dados numéricos e posteriormente realizar as seguintes etapas:

Coleta de Dados

Análise Exploratória de Dados

Pré-processamento dos Dados

Construção e Treinamento de Modelos

Validação e Avaliação dos Modelos

Implementação e Monitoramento

Uma boa medida de aplicabilidade deste modelo é utilizar primeiramente bases de dados disponíveis na internet, para depois usar a base real da empresa, a fim de demonstrar para o cliente como esses dados são analisados. Algumas bases para estudo e treinamento pode ser obtidas em <https://www.dadosdemercado.com.br/> ou utilizando APIs das bolsas.

Referências

- BARRETO, C. A. da S. **Uso de técnicas de aprendizado de máquina para identificação de perfis de uso de automóveis baseado em dados automotivos**. 2018. 92 f. Dissertação (Mestrado Profissional em Engenharia de Software) - Instituto Metr pole Digital, Universidade Federal do Rio Grande do Norte, Natal, 2018.
- BRINK, H. *et al.* **Real-world machine learning**. Shelter Island, NY: Manning, 2017.
- BRINK, H.; RICHARDS, J. W.; FETHEROLF, M. **Real-World Machine Learning**. [S. l.]: Manning, 2016. Dispon vel em: <https://www.manning.com/books/real-world-machine-learning>. Acesso em: 8 ago. 2024.
- CHERVONENKIS, A. Y. **Early history of support vector machines**. Springer, Berlin: Heidelberg, 2013.
- HAN, J.; KAMBER, M.; PEI, J. **Data Mining: concepts and techniques**. 3. ed. Amsterdam; Boston: Elsevier: Morgan Kaufmann, 2011.
- KORBUT, D. **Machine learning algorithms: which one to choose for your problem**. Medium, 2017. Dispon vel em: <https://medium.com/cube-dev/machine-learning-algorithms-183cc73197c>. Acesso em: 28 ago. 2024.
- KOTSIANTIS, S. B. *et al.* Aprendizado de m quina: uma revis o das t cnicas de classifica o e combina o. **Artif Intell Ver**, [s. l.], v. 26, p. 159-190, 2006.
- KUHN, M.; JOHNSON, K. **Applied Predictive Modelling**. V. 126. Springer: New York, 2013.
- NAGAI, A. W. **Avalia o do conhecimento extra do de problemas de Regress o**. 2000. 112 f. Disserta o (Mestrado em Ci ncias) - Universidade de S o Paulo, S o Carlos, SP, 2000 Dispon vel em: <https://teses.usp.br/teses/disponiveis/55/55134/tde-01032018-165127/publico/WalterAioiamaNagai.pdf>. Acesso em: 8 ago. 2024.
- PATERNELLI, L. A. **Regress o linear e correla o**. S o Paulo: USP, 2003.
- RUSSELL, S.; NORVIG, P. **Intelig ncia Artificial**. 3. ed. Rio de Janeiro: Elsevier, 2013. p. 859-865.

SILVA, J. C. da. **Algoritmos de Aprendizagem de Máquina: qual deles escolher.** 2018. Disponível em: <https://medium.com/machina-sapiens/algoritmos-de-aprendizagem-de-m%C3%A1quina-qual-deles-escolher-67040ad68737>. Acesso em: 8 ago. 2024.

TAN, P.-N.; STEINBACH, M.; KUMAR, V. **Introduction to data mining.** New Delhi: Pearson, 2006.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Data Mining:** practical machine learning tools and techniques. 3. ed. São Paulo: MK, 2011.

Aprendizado Não Supervisionado e Redução de Dimensionalidade

Autoria: Stella Marys Dornelas Lamounier

Leitura crítica: Lucas dos Santos Araujo Claudino

Objetivos

- Entender o funcionamento da técnica de aprendizagem não supervisionada.
- Entender os principais algoritmos de aprendizagem não supervisionada.
- Entender a aplicação dos principais algoritmos de classificação e regressão.

1. Aprendizagem não supervisionada

Analisar e transformar dados atualmente já são tarefas imprescindíveis para prever resultados de forma eficiente, porém, nem todos os dados estão dispostos em algum banco de dados ou outro local de armazenamento, o que pode dificultar muito o trabalho de um analista de dados.

Com o aumento da tecnologia e a criação de novas técnicas de machine learning, prever situações inexistentes já é possível, com resultados satisfatórios que podem auxiliar em processos muito complexos.

São técnicas que agrupam os dados que chegam utilizando a sua similaridade, ou seja, o quão um dado é similar ao outro. Esse método é a aprendizagem não supervisionada.

Estes modelos de aprendizado não supervisionada não necessitam de um conjunto de dados a priori, isto é, os dados jamais foram classificados ou rotulados previamente. Neste contexto, pode-se dizer que os dados aprendem sem a figura de um “professor”. É um processo bastante utilizado em machine learning, e realiza tarefas de agrupamento de dados volumosos com diferentes tipos de dados que são agrupados de acordo com sua semelhança ou por meio de extração de padrões nos valores dos atributos.

Segundo Mueller e Massaron (2020), quando algoritmos não supervisionados são usados, o conjunto de dados não é rotulado e os resultados ainda são desconhecidos. É com a análise de sua estrutura que os dados produzem o modelo pedido. Este tipo de análise pode ser usado para diminuir a redundância de dados ou até mesmo para agrupar dados semelhantes, ou seja, o computador não conhece nenhuma associação entre os dados, ele descobre relações implícitas

em um conjunto de dados não rotulados. De fato, ele identifica padrões para rotular os dados.

Porto Filho (2017, p. 24), complementa:

A Aprendizagem de Máquina não Supervisionada é feita com dados não rotulados, ou seja, não se sabe quantas ou classes existem. É uma técnica usada para encontrar subgrupos ou projetos. O objetivo é classificar as entidades em grupos mutuamente exclusivos baseados em similaridade entre as instâncias. Os grupos não são pré-definidos e não há a presença de um “professor”, daí o elemento não supervisionado.

Este processo é bem mais complexo que o dos modelos supervisionados, já que é a própria máquina que tem que definir sozinha o número de clusters e seus atributos típicos.

Para melhor entendimento dessa aprendizagem, destacamos alguns termos:

- **Classe:** é um conjunto de padrões que têm características similares entre si.
- **Característica ou atributo:** é um dado extraído de algum conjunto de dados por meio de alguma medida ou processamento. Um vetor de característica é comumente utilizado para organizá-la.
- **Classificação:** consiste em agrupar os dados em classes, levando em consideração suas características.
- **Ruído:** é uma falha, distorção ou imprecisão que pode ser encontrada durante a extração dos dados.
- **Classificadores:** são usados na classificação dos dados e descobrimento de padrões por meio de suas características.

Além dos termos apresentados, quando se utiliza a aprendizagem não supervisionada é necessário escolher os melhores atributos/variáveis para que o processamento dos dados seja feito no menor tempo possível, evitando o *overfitting*, isto é, o ajuste excessivo dos dados de treinamento, ocasionando uma baixa capacidade de generalização.

Por fim, após o entendimento desses termos deve-se escolher o modelo de algoritmo mais apropriado para resolução de problemas, visto que a clusterização desempenha um papel muito útil quando se fala em aplicabilidade de aprendizagem não supervisionada.

2. Técnicas de Clusterização

Primeiramente, um cluster é um conceito por vezes subjetivo, sendo designado como uma forma de divisão de dados em grupos, com objetivo de criar agrupamentos naturais, chamados de clusters, de acordo com a semelhança ou a padronização entre os dados, agrupando automaticamente instâncias similares. Um exemplo é agrupar pessoas ou objetos em grupos com características comuns, conforme podemos observar na Figura 1.

Figura 1 – Agrupamento de pessoas por características



Fonte: Santana (2017, [s. p.]).

Neste contexto, a clusterização é um processo de agrupar dados abstratos por características comuns. Um cluster nada mais é que uma coleção de dados agrupados dentro de um mesmo grupo similar ou em grupos distintos. Suas classes de dados não podem ser reconhecidas, dividindo as instâncias pelas suas similaridades.

Trata-se de uma análise de dados utilizada para agrupar objetos em uma coleção com padrões com algum tipo de similaridade. É, também, um processo realizado pela extração de dados com características comuns a um grupo, visando identificar a qual grupo em uma série de grupos o elemento tenderá a pertencer.

A clusterização é uma das áreas mais utilizadas em machine learning, podendo ser usada para a análise de dados estatísticos em muitas áreas, como em reconhecimento de padrões, mineração de dados, processamento de imagens e tomadas de decisão quando não existirem informações exatas sobre os dados apresentados. Veremos, a seguir, alguns algoritmos que usam essa técnica.

3. Algoritmo *k-means* (k-médias)

De acordo com Carvalho (2021), o algoritmo chamado de k-médias (ou *k-means*, em inglês) é a abordagem mais simples e conhecida da técnica de clustering. É um algoritmo de particionamento que determina k pontos de forma aleatória, os chamados centroides do cluster. Subsequentemente, calcula-se a distância euclidiana de cada instância de dados dos clusters, com a intenção de identificar o grupo (cluster) mais próximo de cada dado, que, então, será direcionado para este cluster mais próximo. Depois da designação das instâncias para o seu respectivo cluster, as médias das distâncias das instâncias em cada cluster de seu centroide são calculadas, identificando os novos

centroides dos clusters por meio destas médias. O algoritmo se repete até que o centroide de todos os clusters sejam os mesmos em todas as iterações. Em síntese, as etapas deste algoritmo são:


1. Escolher os valores de pontos k (clusters) de forma aleatória.
2. Calcular a distância euclidiana (matriz de distância) de cada instância de dados dos clusters.
3. Identificar o cluster mais próximo de cada instância e direcioná-la ao grupo.
4. Calcular a média das distâncias das instâncias em cada cluster e identificar a nova localização do centroide dos clusters.
5. Calcular os novos centroides para cada classe.
6. Repetir o algoritmo até que os pontos dos centroides sejam coincidentes para todas as iterações.

O algoritmo k -médias é um algoritmo de particionamento. Estes algoritmos consideram um conjunto de dados de n objetos que são organizados em clusters, e k é o número de clusters a serem utilizados no algoritmo ($k \leq n$). A formação dos clusters é dada para otimizar um critério baseado em uma função objetivo, como uma função de distância, para que os objetos em um cluster sejam semelhantes, enquanto os objetos de diferentes grupos sejam diferentes em termos de atributos do conjunto de dados (Han; Kamber, 2001, p. 401).

Exemplificando:

Han e Kamber (2001, p. 403) trazem o exemplo do funcionamento do algoritmo k -médias para $k = 3$, na Figura 2 a seguir.

Figura 2 – Exemplo de funcionamento do algoritmo k-médias



Fonte: Han e Kamber (2001, p. 403).

A partir da primeira iteração (a), as instâncias são designadas a clusters específicos dependendo de suas distâncias, conforme o algoritmo avança com os cálculos das médias das distâncias. É possível identificar na iteração final (c) que alguns dados que inicialmente foram agrupados em clusters iniciais foram rearranjados em diferentes clusters ao final das iterações.

4. DBSCAN

Conhecido também como agrupamento espacial baseado em densidade de aplicações com ruído, DBSCAN é outro algoritmo de clusterização, amplamente utilizado para a identificação de cluster. É baseado em densidade espacial, sendo amplamente efetivo quanto se trata de separar os grupos de acordo com seu tamanho e formato binário ou até mesmo para identificar ruídos nos dados, descobrindo clusters de diversos formatos e tamanhos – porém, este modelo é mais indicado em casos nos quais os clusters estão bem compactados e bem separados.


O algoritmo DBSCAN é baseado em “clusters” e “ruído”. A ideia-chave é que para cada ponto de um cluster, a vizinhança de um dado raio tem

que conter pelo menos um número mínimo de pontos, conforme pode ser observado na Figura 3.

Esse algoritmo é baseado em dois parâmetros fundamentais:

- **MinPts:** o número de pontos mínimos agrupados em uma região ou no raio de eps. Para que este ponto seja considerado central, quanto maior o conjunto de dados analisados, maior é o valor de MinPts a ser escolhido.
- **Eps:** uma medida que define distância e que será usada para localizar os pontos na vizinhança de qualquer ponto – isto é, esse parâmetro é usado para medir a distância entre dois pontos. Se considerada menor, pode-se dizer que estes dados são vizinhos, definindo o raio da vizinhança em relação ao ponto.

Figura 3 – Representação gráfica do algoritmo DBSCAN



Fonte: adaptada de Kassambara ([s. d.]).

- **Ponto central:** é o ponto central no cluster, e deverá ter pelo menos três MinPts dentro de uma distância de eps.

- **Ponto de borda:** ponto de fronteira, um ponto que tem menos MinPts dentro de eps, mas está na vizinhança de um ponto central.
- **Ruído ou outlier:** um ponto que não é um ponto central ou ponto de fronteira. Este ponto, então, é considerado um ruído.

5. Redução de Dimensionalidade

Ao falar da redução de dimensionalidade em algoritmo de machine learning, primeiramente deve-se entender o conceito da maldição da dimensionalidade como um processo que precisa ser levado em consideração quando se trabalha com algoritmos inteligentes. Essa problemática está associada ao aumento exponencial da complexidade de um problema devido ao aumento da sua dimensionalidade e aumento do número de atributos no espaço matemático.

Todavia, existem alguns métodos capazes de minimizá-la, como a redução da dimensionalidade de dados (RDD), que é uma diminuição no espaço de busca de hipóteses, melhorando o desempenho. Outra maneira é usar uma projeção linear dos dados em um espaço unidimensional, de modo que um vetor de entrada x seja projetado no vetor y , dado por $y = wTx$. Em geral, essa projeção em espaço unidimensional pode conduzir a considerável perda de informação, já que as classes que estavam bem separadas no espaço dimensional podem tornar-se fortemente sobrepostas em uma dimensão. Contudo, ao ajustar os componentes do vetor de pesos (w) pode-se selecionar uma projeção que vai maximizar a separação das classes.


Outro método amplamente utilizado é a análise de componentes principais (ACP) ou PCA, cuja técnica consiste em trabalhar com objetivo de reduzir ao máximo a dimensionalidade dos dados com o mínimo de perda da variabilidade destes dados, pois muitas vezes grande

massas de dados têm atributos irrelevantes para análises. A ACP pode diminuir esse excesso de dados a fim de que o conjunto contenha apenas informações relevantes, ou então pode ser usada para excluir redundância de dados e correlações indesejadas.

Um de seus objetivos é encontrar um novo conjunto de variáveis menor que o conjunto original que preserve a maior parte da informação presente nos dados, reduzir a dimensionalidade, obter combinações interpretáveis das variáveis originais e descrever/compreender a estrutura de correlação entre essas variáveis.

Podemos analisar na Figura 4 a interpretação geométrica da análise de componentes principais (PCA).

Figura 4 – Representação gráfica de PCA



Fonte: elaborada pela autora.

Onde ($p = 2$), vetor X com dois componentes x_1 e x_2

O gráfico demonstra que a direção de Y_1 representa a direção da maior variabilidade dos dados, e o Y_2 a segunda maior variabilidade dos

dados que não está correlacionada com a anterior, isto é, Y_2 não está correlacionado com Y_1 .

Além da PCA, a análise discriminante linear (LDA) é outra técnica amplamente usada para redução de dimensionalidade, especialmente em problemas de classificação. A LDA busca encontrar uma projeção linear dos dados que maximize a separação entre as diferentes classes. Diferentemente da PCA, que não leva em consideração a classe dos dados, a LDA utiliza informações de classe para encontrar as direções que melhor separam os diferentes grupos.

A LDA funciona da seguinte maneira:

1. **Calcular a média de cada classe:** para cada classe, calcular a média dos vetores de características.
2. **Calcular a matriz de dispersão dentro das classes (*within-class scatter matrix*):** esta matriz mede a dispersão dos pontos de dados dentro de cada classe.
3. **Calcular a matriz de dispersão entre as classes (*between-class scatter matrix*):** esta matriz mede a dispersão das médias das classes em relação à média global.
4. **Encontrar as direções de máxima separação:** resolver um problema de autovalores para encontrar as direções que maximizam a razão entre a dispersão entre as classes e a dispersão dentro das classes.

A LDA é particularmente útil quando se deseja reduzir a dimensionalidade dos dados enquanto se preserva a separação entre as classes, tornando-a uma ferramenta poderosa em problemas de classificação.

Existe uma infinidade de métodos que podem auxiliar na redução de dimensionalidade, mas deve-se ficar atento não apenas à escolha mais correta deste método, como também às características que compõem o conjunto de dados e os objetivos da análise, e realizar um comparativo entre diferentes métodos, a fim de avaliar o melhor desempenho.

6. Técnicas de visualização de dados

Aprendemos os principais algoritmos de aprendizagem não supervisionada e como reduzir problemas com a dimensionalidade; a seguir, veremos algumas técnicas de visualização de dados.

Para analisar dados, existem diferentes métodos tradicionais que demonstram diversos modelos de gráficos tradicionais, como de barras, de dispersão, linear etc., porém, estes modelos se mostram um pouco ineficientes quando se trata de conjunto de dados com alta dimensionalidade, devido ao pequeno espaço de dados que por muitas vezes podem afetar a estrutura e performance de visualização.

Outras técnicas podem ser usadas sem que o desempenho seja afetado, como a *Multidimensional Scaling* (MDS), que é representação visual de distâncias utilizando uma matriz de proximidades de semelhança e até mesmo dissemelhança entre conjuntos de objetos – isto é, preserva as distâncias ou diferenças originais, fornecendo uma visualização mais intuitiva, tanto no espaço de dados em 2D como em 3D. Esta técnica pode simplificar o conjunto de dados em alta dimensão, tornando-os mais fáceis para visualizar e analisar. Outra característica é que se trata de objetos semelhantes que são posicionados mais próximos, refletindo a sua similaridade.

Outra técnica bastante difundida é a utilização de árvores por similaridade, que apresenta uma estrutura hierárquica aproveitando

todo o espaço visual disponível para a representação dos dados organizados por meio de conexão pai e filho, e mostrando que quanto mais próximo estiver a instância, maior é sua similaridade.

Este modelo computacional é semelhante ao conceito de filogenia molecular, conforme dito por Rosa (2007):

A filogenia molecular é o ramo da biologia que estuda as relações evolutivas entre as espécies, com base nas moléculas de DNA. Estas relações são expressas em estruturas denominadas árvores filogenéticas. Uma vez que a construção apresenta alto índice de complexidade, em função ao número de espécies analisadas, é necessário adoção de técnicas que são capazes de explorar o espaço de forma simultânea. (Rosa, 2007, p. 10)

Quando se trata desta técnica, existem várias metodologias que podem representar este modelo, e vamos dar ênfase à árvore *neighbor-joining*.

Este é um método baseado em hierarquia de árvores, construído a partir de distâncias genéticas da filogenia. Essa distância pode ser ajustada para diferentes taxas de evolução dos ramos; sua entrada é uma matriz de distância e sua saída é representada por árvore filogenética obtida pelo algoritmo *neighbor-joining*.

Conectando à Realidade: Exemplos Práticos

Situação: Seleção de materiais para componentes eletrônicos.

Imagine que você está trabalhando em um projeto de desenvolvimento de um dispositivo eletrônico avançado, como um smartphone. Nesse caso, é fundamental entender as propriedades dos materiais utilizados na fabricação dos componentes, como a condutividade elétrica, a resistência térmica e a durabilidade. Com base nos conhecimentos

adquiridos na disciplina, você será capaz de selecionar os materiais mais adequados para garantir o desempenho e a confiabilidade do dispositivo.

Aplicabilidade:

- Realizar testes de condutividade elétrica e resistência térmica em diferentes materiais para identificar aqueles que melhor atendem aos requisitos do dispositivo.
- Utilizar técnicas de simulação computacional para prever o desempenho dos materiais em condições específicas de uso.
- Realizar análises de durabilidade e envelhecimento dos materiais para garantir sua longevidade e confiabilidade.

Referências

CARVALHO, J. C. N. Análise de agrupamentos e o algoritmo k-means. **Medium**, 2021.

HAN, J.; KAMBER, M. (2001). Cluster Analysis. *In*: MORGAN PUBLISHERS (ed.). **Data Mining: Concepts and Techniques**. Chapter 8. New York, USA: Academic Press, 2001.

KASSAMBARA, A. **DBSCAN: Density-Based Clustering Essentials**. Datanovia, [s. d.]. Disponível em: <https://www.datanovia.com/en/lessons/dbscan-density-based-clustering-essentials/>. Acesso em: 2 ago. 2024.

MUELLER, J. P.; MASSARON, L. **Aprendizado de máquina para leigos**. Rio de Janeiro: Alta Books, 2019.

PORTO FILHO, C. H. **Técnicas de aprendizado não supervisionado baseadas no algoritmo da caminhada do turista**. 2017. 122 f. Dissertação (Mestrado em Ciências) - Universidade de São Paulo, São Carlos, 2017. Disponível em: https://www.teses.usp.br/teses/disponiveis/82/82131/tde-20082018-122603/publico/Dissert_CarlosPortoFilho_corrigida.pdf. Acesso em: 2 ago. 2024.

RODRIGUES, A. R. **Métodos de redução de dimensionalidade e seleção de atributos**. São Paulo: USP, [s. d.]. Disponível em: http://www.lcad.icmc.usp.br/~jbatista/procing/Aula4_Feature_selection_dim_red.pdf. Acesso em: 1 ago. 2024.

ROSA, C. E. **Computação Evolutiva Aplicada na Reconstrução de Árvores Filogenéticas**. 2007. 122 f. Monografia (Bacharelado em Ciência da Computação) - Universidade Federal de Goiás, Campus Catalão, Catalão, GO, 2007.

SANTANA, F. **Entenda o algoritmo K-means e saiba como aplicar essa técnica**. [s. l.], 2017.

SILVA, R. A. C. Inteligência artificial aplicada a ambientes de Engenharia de Software: uma visão geral. Viçosa: Universidade Federal de Viçosa, 2005. **NFOCOMP Journal of Computer Science**, [S. l.], v. 4, n. 4, p. 27-37, 2005. Disponível em: <https://infocomp.dcc.ufla.br/index.php/infocomp/article/view/109>. Acesso em: 1 ago. 2024.

Sistemas de recomendação

Autoria: Stella Marys Dornelas Lamounier

Leitura crítica: Lucas dos Santos Araujo Claudino

Objetivos

- Estudar os princípios básicos e as técnicas utilizadas em sistemas de recomendação, incluindo filtragem colaborativa, filtragem baseada em conteúdo e métodos híbridos.
- Discutir os desafios atuais e as oportunidades futuras no desenvolvimento de sistemas de recomendação, como a personalização em tempo real e a privacidade dos dados dos usuários.
- Analisar os diferentes tipos de algoritmos e suas aplicações práticas em diversos setores, como e-commerce, streaming de mídia e redes sociais.

1. Introdução

Com o avanço das tecnologias, o aumento da massa de dados de diversas naturezas e formato, há uma grande quantidade de informações. Vivemos em tempos de muita competitividade nas empresas em praticamente todos os setores. Conhecer seu cliente, ou seu futuro cliente, é elemento básico para qualquer empresa que deseja obter lucratividade. Neste contexto, o gestor deve saber tirar proveito dessa grande quantidade de dados e informações que são criados a todo momento, utilizando técnicas de análise de dados disponíveis no meio computacional.

Ferramentas de sistemas de recomendação utilizam uma variedade de algoritmos, análise de dados preditivos e até mesmo a inteligência artificial (IA) para fazer recomendações on-line de produtos, serviços e conteúdos. Dependendo do objetivo de cada plataforma, da quantidade de dados coletados e do tipo de tecnologia utilizada para construir o sistema de recomendações, essas recomendações podem ser adaptadas a cada usuário ou indivíduo.

Um exemplo é o uso dos sistemas de recomendação, que empregam algoritmos com regras de associação para não apenas aumentar as vendas, mas também identificar tendências e explorar comportamentos a fim de maximizar a quantidade de itens vendidos.

Atualmente, os problemas de mineração de dados que utilizam as regras de associação são altamente valorizados pelos pesquisadores de banco de dados, inteligência artificial, estatística, recuperação de informação, visível, ciência da informação e muitos outros campos.

Neste cenário, as regras de associação de dados estão relacionadas com a tarefa da mineração de dados em que associações entre dados em um conjunto de dados consultados são identificadas. Nesta tarefa,

encontram-se elementos que indicam a presença de outros elementos em uma mesma consulta de dados. O Quadro 1 relaciona a mineração de dados com suas principais tarefas, abordadas na disciplina.

Quadro 1 – Mineração de dados e suas principais tarefas

Mineração de Dados	Principais tarefas
	Agrupamento: consiste no agrupamento de dados com características similares em um mesmo grupo (os clusters).
	Classificação: está relacionada com a tarefa de identificar um modelo ou função que descreve e identifica uma classe de dados.
	Associação: é a tarefa que encontra associações entre os dados, por meio da identificação de elementos que implicam a presença de outros elementos.

Fonte: elaborado pela autora.

Segundo Vasconcelos e Carvalho (2004, p. 8), normalmente as regras de associação representam os padrões que já existem em transações armazenadas na organização. Os autores exemplificam esta tarefa de associação de dados com a regra {camisetas ou bermudas} → {tênis ou sandálias}, que pode identificar uma representação de roupas leves e calçados, como ilustrado na Figura 1, em uma base de dados de uma empresa. Esta regra indica que o cliente que compra cinto e bolsa também compra sapato, levando em consideração um grau de certeza. Dois índices são definidos neste grau de certeza: o **fator de suporte**, que é uma medida da frequência com que um conjunto de itens aparece no banco de dados empregando o cálculo:


$$\text{Suporte}(A) = \frac{\text{Número de transações que contém } A}{\text{Total de transações}}$$

Onde A é um conjunto de itens.

E o **fator de confiança**: a confiança de uma regra de associação é a medida de quão frequentemente os itens em *B* aparecem nas transações que contêm *A*, matematicamente representado por:

$$\text{Suporte}(A) = \frac{\text{Número de transações que contém } A}{\text{Total de transações}}$$

Figura 1 – Organização de regras de associação em níveis



Fonte: elaborada pela autora.

Além disso, os autores também mencionam como exemplo a utilização de códigos de barras, que possibilitou a coleta e armazenamento de uma enorme quantidade de dados com informações de compras realizadas pelos clientes. A partir da utilização do conhecimento desses dados, o departamento de marketing das empresas pode direcionar suas estratégias de layout e catálogos aos produtos que geram maior vantagem para a organização, como nos exemplos seguintes de grandes empresas que utilizam esse modelo.



A gigante Walmart conseguiu, utilizando análise de dados, mapear o perfil de seu consumidor, constatando que pais que iam comprar fraldas à noite sempre compravam cerveja. Assim, o Walmart pode notar um aumento significativo nas vendas como resultado de sua decisão de colocar, em um mesmo setor, fraldas e cerveja. Com base na análise de padrões estatísticos, a empresa pode prever a próxima compra de um cliente mesmo antes que ele perceba a necessidade.

Outro exemplo é do Banco Itaú, que por meio da análise de dados conseguiu que suas malas-diretas fossem enviadas a um público específico, ou seja, apenas a clientes com maior chance de responder. Com esse modelo de análise – em um gigantesco conjunto de dados do banco com mais de 3 milhões de clientes –, a taxa de retorno subiu para 30% e os custos com postagem foram reduzidos a um quinto.


Neste contexto, sistemas de recomendação que utilizam regras de associação oferecem uma maneira eficaz de sugerir itens baseados em padrões de compra comuns. Embora possam ser limitados em termos de personalização, são extremamente úteis em contextos em que a relação entre itens é evidente e baseada em dados históricos robustos.

Outras empresas, como Netflix, Amazon e Spotify, utilizam também sistemas de recomendação. A Netflix usa algoritmos de aprendizado de máquina, Big data e processamento de linguagem natural para sugerir e recomendar conteúdo a seus clientes. A plataforma também utiliza uma abordagem colaborativa que pode ser categorizada como:

- **Baseada em usuário:** a abordagem colaborativa baseada em usuário é baseada na noção de que as preferências de um usuário podem ser estimadas observando as preferências de outros usuários que têm características semelhantes.

Um exemplo de como este modelo pode ser usado em um serviço de streaming é o seguinte: se um usuário A e um usuário B assistiram a vários filmes semelhantes e gostaram deles, e o usuário B assistiu a um filme que o usuário A ainda não viu, o usuário A pode receber uma recomendação do filme para o usuário A com base na similaridade entre os dois, como pode-se perceber na Figura 2.

Figura 2 – Abordagem colaborativa baseada em usuário




Fonte: Vinisk (2024).

Baseada no item: uma técnica de sistemas de recomendação conhecida como abordagem colaborativa baseada no item concentra-se nas semelhanças entre itens em vez de entre usuários. Neste modelo, as recomendações são feitas com base na análise de itens com conexões ou gostos anteriores do usuário. Um exemplo de como você pode ser empregado é o seguinte: ao comprar um telefone celular em uma loja on-line, o sistema pode sugerir acessórios como capas ou fones de ouvido, que outros usuários costumam comprar com o mesmo modelo. Depois que esses itens foram identificados como comparáveis ou

complementares ao item original, essas recomendações foram criadas, como ilustrado na Figura 3.


Figura 3 – Abordagem colaborativa baseada no item



Fonte: Vinisk (2024).

Sistemas híbridos: para aumentar a precisão, a diversidade e a robustez das recomendações, os sistemas híbridos de recomendação combinam duas ou mais abordagens diferentes. Os sistemas híbridos são projetados para combinar os benefícios de várias abordagens de recomendação, reduzindo, ao mesmo tempo, suas deficiências. Os sistemas híbridos são amplamente utilizados em contextos em que a experiência do usuário é vital para a diversidade e precisão das recomendações, como em plataformas de streaming, e-commerce e redes sociais, conforme ilustrado na Figura 4.


Figura 4 – Abordagem colaborativa sistemas híbridos



Fonte: Vinisk (2024).

Portanto, sistemas de recomendação são amplamente utilizados em diversos segmentos, e sua atuação tem proporcionado ao gestor entender o perfil de seus clientes baseado nas suas preferências. A Figura 5 ilustra de uma forma geral este conceito, independentemente do modelo adotado.

Figura 5 – Modelo do processo de recomendação



Fonte: Sampaio (2006).

2. Desafios e limitações: problema do início frio, viés e diversidade. escalabilidade e privacidade

Os sistemas de recomendação se tornaram cruciais em plataformas de e-commerce, serviços de streaming, redes sociais e outras áreas nas quais a personalização da experiência do usuário é essencial. Mas esses sistemas têm muitos problemas e limitações que podem prejudicar sua eficiência e confiabilidade.

Cazella, Nunes e Reategui (2010) afirmam que o maior obstáculo para esses sistemas é a combinação relevante entre o que o usuário deseja e os produtos, serviços e pessoas recomendados, pois estão diretamente ligados à escolha das fontes de informação adequadas que fornecerão subsídios para que os algoritmos possam estabelecer as conexões adequadas e, assim, fornecer dados convincentes aos tomadores de decisão.

Apesar de serem ferramentas poderosas para personalizar o engajamento do usuário e o conteúdo, têm algumas limitações que podem prejudicar a experiência do usuário e sua eficiência. As principais limitações desses sistemas são as seguintes:

2.1 Problema do início frio

Uma das principais questões nos sistemas de recomendação é o “Problema do Início Frio”, especialmente nos estágios iniciais de uso, para novos usuários e novos itens, quando o sistema não tem dados históricos de novos usuários ou novos itens. O sistema tem dificuldade em fazer recomendações precisas sem interações anteriores. Como o sistema ainda não sabe quais são suas preferências, as recomendações para novos usuários podem ser genéricas ou irrelevantes. Quando se

trata de itens recém-adicionados, o sistema pode não ter informações suficientes sobre eles, o que pode afetar sua descoberta e adoção pelos usuários.

Como podemos resolver esta limitação?

No início do cadastro, coletar as preferências dos usuários pode ajudar na criação de um perfil inicial para recomendações, sugerir itens populares ou bem avaliados para novos usuários até que o sistema colete mais informações sobre eles ou até mesmo introduzir uma fase de exploração em que o sistema sugere uma variedade de itens para entender rapidamente as preferências do usuário

Devemos compreender alguns conceitos importantes quando se trata do Problema de Início Frio, que serão destacados a seguir.

Viés

Os sistemas de recomendação podem ter viés, o que pode resultar em recomendações que não atendem totalmente aos interesses do usuário. Alguns tipos de viés são:

Viés do algoritmo: isso ocorre quando um algoritmo favorece alguns usuários ou itens com base em dados históricos, o que pode levar a perpetuação de desigualdades.

Viés de popularidade: quando um sistema prioriza itens populares, pode ser difícil encontrar novos ou nichos de interesse.

Viés de interação: quando as recomendações do sistema são baseadas em interações passadas, eles podem não saber se os interesses dos usuários mudaram ao longo do tempo.

Diversidade



Diversidade nas recomendações significa que vários itens foram sugeridos ao usuário. Um sistema de recomendações variadas ajuda a descobrir novos conteúdos que podem interessar ao usuário, evitando mostrar os mesmos tipos de itens a cada vez. Os usuários podem se sentir saturados e insatisfeitos se houver pouca diversidade; o que pode indicar que o sistema não está entendendo seus desejos.

A criação de métricas que promovam a diversidade e a criação de algoritmos que equilibrem as recomendações populares com as opções menos comuns podem ser úteis para manter o interesse dos usuários.

Escalabilidade

O termo escalabilidade refere-se à capacidade do sistema de recomendação de se adaptar a um número maior de usuários e itens sem perder sua eficiência. Mesmo à medida que a base de dados se expande, um sistema escalável deve ser capaz de processar grandes quantidades de dados e fornecer recomendações instantâneas. Neste contexto, pode-se ainda usar técnicas de amostragem, implementar sistemas em infraestrutura de computação em nuvem e usar algoritmos distribuídos para aumentar a escalabilidade.

Privacidade

Privacidade envolve proteger os dados pessoais dos usuários. É fundamental para sistemas de recomendação garantir que a privacidade dos usuários seja preservada e que as informações usadas para fazer recomendações sejam tratadas de forma segura. Como os dados são coletados, armazenados e utilizados, e como os usuários são educados sobre seu uso podem ser questões de privacidade. Para proteger os usuários, é necessário implementar práticas sólidas de segurança de dados, como criptografia e anonimização de dados.

Qualidade dos Dados

Os recomendadores dependem fortemente da qualidade dos dados, o que cria outro desafio. As recomendações errôneas ou irrelevantes podem resultar de dados imprecisos, incompletos ou desatualizados. O processo de limpeza e verificação de dados, bem como a implementação de mecanismos para a atualização contínua de informações, são necessários para manter a qualidade das recomendações.

Por fim, os sistemas de recomendação enfrentam problemas complicados que requerem soluções complexas e multifacetadas. Embora a experiência do usuário possa ser significativamente melhorada, é fundamental estar ciente dessas limitações e trabalhar para reduzi-las, a fim de garantir que as recomendações sejam úteis, justas e seguras.

Conectando à Realidade:

Os sistemas de recomendação podem ser implementados em uma variedade de instituições e setores. Considere a situação em que você trabalha como analista de dados em uma grande rede de padaria e é responsável por personalizar a experiência do cliente, sugerindo produtos que atendem aos interesses de cada cliente, usando informações como seus hábitos de compra, preferências e outras informações relevantes. Um sistema de recomendação pode ser facilmente implementado nestes locais, com os benefícios e os desafios, obedecendo algumas técnicas.

Aplicabilidade

Histórico de compras: por exemplo: os clientes podem ver o que compraram no sistema. Neste contexto, o sistema identificaria padrões se um cliente comprasse croissants e pães integrais com frequência.

Preferências declaradas: se a padaria tivesse um programa de fidelidade, os clientes poderiam registrar suas preferências, como “preferência por produtos sem glúten” ou “gosta de doces com baixo teor de açúcar”.

Feedback: obtenha classificações ou comentários dos clientes sobre os produtos comprados.

Análise de dados

Algoritmos de recomendação: pode-se aplicar algoritmos de recomendação, como filtragem colaborativa (que recomenda produtos com base em comportamentos de outros clientes) ou sistemas baseados em conteúdo (que recomendam produtos baseados em comportamentos anteriores de clientes).

Agrupamento de clientes: recomendações mais precisas podem ser feitas dividindo os clientes em grupos de acordo com hábitos de compra semelhantes.

Recomendações personalizadas

Produtos relacionados: se um cliente costuma comprar café, o sistema pode sugerir combinações de alimentos, como pães doces, bolos ou sanduíches.

Promoções personalizadas: oferecer descontos ou promoções em produtos que o cliente ainda não comprou, mas que se encaixam em seus interesses.

Notificações: envie mensagens personalizadas como “Temos um novo tipo de croissant que pode lhe interessar!” ou “Seu pão preferido está fresco e saindo do forno”.

Utilizando essas técnicas, o estabelecimento pode aumentar suas vendas, fidelizar clientes, reduzir desperdícios e ainda lançar promoções direcionadas a um certo nicho de clientes.



Referências

CAZELLA, S. C.; NUNES, M. A. S.; REATEGUI, E. B. A Ciência da Opinião: Estado da arte em Sistemas de Recomendação. *In*: CONGRESSO DA SOCIEDADE BRASILEIRA DE COMPUTAÇÃO – JORNADA DE ATUALIZAÇÃO EM INFORMÁTICA (JAI), 30., 2010, Belo Horizonte. **Anais** [...]. Belo Horizonte, 2010.

SAMPAIO, I. A. **Aprendizagem ativa em sistemas de filtragem colaborativa**. 2006. 86 f. Dissertação (Mestrado em Ciência da Computação) - Universidade Federal de Pernambuco, Recife, 2006.

VASCONCELOS, M. R.; CARVALHO C. L. **Aplicação de regras de associação para mineração**. Technical Report - RT-INF004-04 - Relatório Técnico, [s. l.], 2004.

VINISK, A. D. **O que fazem os sistemas de recomendação?** LinkedIn, 7 jan. 2021. Disponível em: <https://www.linkedin.com/pulse/o-que-fazem-os-sistemas-de-recomenda%C3%A7%C3%A3o-antonio-david-viniski/>. Acesso: 28 ago. 2024.



Bons estudos!