



WBA0754_v2.0

Machine Learning



Aprendizado Não Supervisionado e Redução de Dimensionalidade

Aprendizagem não supervisionada

Bloco 1


Lucas Claudino



Vamos refletir?

Imagine que você possui uma base de dados de e-Commerce e precisa identificar grupos de clientes com comportamentos semelhantes com base nos dados disponíveis, mas sem qualquer rótulo predefinido. Como você abordaria o problema de segmentar esses clientes? Reflita sobre como a redução de dimensionalidade pode afetar a interpretação dos resultados.





Aprendizado não supervisionado e cenários de aplicação



Método de descoberta de padrões em dados não rotulados.



Pode ser usado para clustering, detecção de anomalias e redução de dimensionalidade.




Aplicações: identificação de grupos de clientes em e-commerce e análise de dados de sensores para detectar falhas de equipamentos em fábricas.



Clusterização


Exemplos de clusterização de dados



Fonte: Priy (2024).

Diferentes formas de clusterização

Classificação dos algoritmos preditivos



Fonte: elaborada pelo autor.



E como trabalhar com muitos dados?

REDUÇÃO DE DIMENSIONALIDADE: diminuir o número de variáveis ou características em um conjunto de dados.

Vantagens da redução de dimensionalidade.



Melhora a Eficiência Computacional: Reduz o custo computacional.



Facilita a Visualização: Permite visualizar dados complexos em 2D ou 3D.




Reduz o Risco de Overfitting: Menos características podem levar a modelos mais simples e generalizáveis.



Remove Ruído: Elimina variáveis irrelevantes ou redundantes.

Fonte: elaborada pelo autor.





E como visualizar os dados?



Técnica para representação gráfica de informações e padrões em grandes conjuntos de dados.



Gráficos de barras, gráficos de dispersão, mapas de calor e diagramas de caixa.



A escolha da técnica de visualização adequada depende dos dados que estão sendo analisados e dos resultados que se espera alcançar.




Aprendizado Não Supervisionado e Redução de Dimensionalidade

Técnicas de clusterização

Bloco 2

Lucas Claudino




Clusterização

Objetivo: encontrar grupos com características similares.


- Critérios de separação:
 - Compactação.
 - Encadeamento ou ligação.
 - Separação espacial.
- Algoritmos de agrupamento:
 - Hierárquico (aglomerativo ou divisivo).
 - Baseados em erro quadrático (k-means).
 - Baseados em densidade.
 - Baseados em grafo.
 - Baseados em redes neurais.





Agrupamento hierárquico


Exemplo de clusterização hierárquica



Fonte: Faceli et al. (2011, p. 210).


K-means

Fluxo de rotina k-means




Fonte: elaborada pelo autor.






Baseados em densidade

Esquema de clusterização por densidade




MinPts = 6

(a)



(b)

Fonte: Ester et. al (1996).



Exemplo de k-means

Exemplo de k-means

```
kMeans1 <- function(dados, k=2){  
  # função que calcula a distância euclidiana  
  euc.dist <- function(x1, x2) sum((x1 - x2) ^ 2)  
  rotulo = 1:k      # labels  
  rownames(dados)[nrow(dados)] = 1  
  for(i in 1:nrow(dados)){  
    rownames(dados)[i] <- sample(rotulo, 1)  
  } # centroides aleatorios  
  centroids <- colMeans(dados[rownames(dados) == 1, ])  
  for(j in 2:k){  
    centroids <- rbind(centroids,  
      | | | | | colMeans(dados[rownames(dados) == j, ]))  
  }  
  # identifica o centroide de cada grupo  
  rownames(centroids) = 1:k
```

Fonte: elaborada pelo autor.






Exemplo de k-means



```
for(i in 1:nrow(dados)){
  distancias = NULL
  for(j in 1:k){
    distancias[j] = euc.dist(dados[i,], centroids[j,])
  }
  names(distancias) = 1:k
  rownames(dados)[i] = as.numeric(names(distancias[distancias == min(distancias)]))
  # recalcula las medias
  centroids <- colMeans(dados[rownames(dados) == 1, ])
  for(z in 2:k){
    centroids <- rbind(centroids, colMeans(dados[
      rownames(dados) == z, ]))
  })
# centroides
return(list(centroides = centroids, grupo1 = dados[
  rownames(dados) == 1, ],
  grupo2 = dados[rownames(dados) == 2, ],
  grupo3 = dados[rownames(dados) == 3, ],
  clusters = as.numeric(rownames(dados)))))
```

Fonte: elaborada pelo autor.



Exemplo de k-means

Exemplo de k-means comparando duas metodologias diferentes



Fonte: elaborada pelo autor.

Aprendizado Não Supervisionado e Redução de Dimensionalidade

Redução de dimensionalidade

Bloco 3

Lucas Claudino

E como trabalhar com muitos dados?

REDUÇÃO DE DIMENSIONALIDADE: diminuir o número de variáveis ou características em um conjunto de dados.

Vantagens da redução de dimensionalidade.



Melhora a Eficiência Computacional: Reduz o custo computacional.



Facilita a Visualização: Permite visualizar dados complexos em 2D ou 3D.



Reduz o Risco de Overfitting: Menos características podem levar a modelos mais simples e generalizáveis.



Remove Ruído: Elimina variáveis irrelevantes ou redundantes.

Fonte: elaborada pelo autor.



Técnicas de Redução de Dimensionalidade

Análise de Componentes Principais (PCA)

- Aplicações comuns: Imagens, compressão de dados, pré-processamento para aprendizado de máquina.

Análise de Discriminantes Lineares (LDA)

- Aplicações comuns: Reconhecimento de padrões e classificação.


t-Distributed Stochastic Neighbor Embedding (t-SNE)

- Aplicações comuns: Visualização de dados em alta dimensão.

Autoencoders

- Aplicações comuns: Compressão de dados e aprendizado de características.





Aplicações e desafios

Aplicações

Pré-processamento de Dados para Modelos de Machine Learning.

Visualização de Dados Complexos.

Remoção de Ruído e Compressão de Dados.

Facilitação da Interpretação de Modelos.


Desafios e Considerações

Perda de Informação: Riscos e como mitigá-los.

Escolha da Técnica Adequada: Critérios de escolha baseados no problema e nos dados.

Implementação em Ambientes de Produção: Cuidado com a escalabilidade e eficiência computacional.





Exemplo de Redução de Dimensionalidade

PCA para redução de dimensionalidade de um conjunto de dados fictícios de flores (semelhante ao famoso dataset “iris”)

```
# Carregar o dataset iris
```

```
data(iris)
```

```
# Remover a coluna de classificação
```

```
iris_data <- iris[, -5]
```

```
# Aplicar PCA
```

```
pca_result <- prcomp(iris_data, center = TRUE,  
scale. = TRUE)
```

```
# Resumo do PCA para verificar a variância  
explicada
```

```
summary(pca_result)
```



Exemplo de Redução de Dimensionalidade

```
# Visualização do resultado PCA
```

```
library(ggplot2)
```

```
pca_df <- as.data.frame(pca_result$x)
```

```
pca_df$Species <- iris$Species
```

```
ggplot(pca_df, aes(x = PC1, y = PC2, color =  
Species)) +
```

```
  geom_point(size = 2) +
```

```
  labs(title = "PCA de Iris Dataset",
```

```
        x = "Componente Principal 1",
```

```
        y = "Componente Principal 2") +
```

```
  theme_minimal()
```



Exemplo de Redução de Dimensionalidade



Passos: Carregamos o dataset iris, removemos a coluna de classificação, aplicamos PCA e plotamos os dois primeiros componentes principais.



Objetivo: Mostrar como o PCA pode ser usado para reduzir a dimensionalidade e visualizar a separação de classes.



Resultados: A visualização resultante mostra como diferentes espécies de flores se agrupam em um espaço de menor dimensão, facilitando a análise visual e a interpretação.



Aprendizado Não Supervisionado e Redução de Dimensionalidade

Teoria em prática

Bloco 4

Lucas Claudino




Reflita sobre a seguinte situação

Imagine que você trabalha em uma empresa de serviços financeiros que está interessada em **segmentar seus clientes** com base em suas características **financeiras** e **comportamentais**.

A empresa deseja identificar **grupos de clientes** com perfis semelhantes para direcionar campanhas de marketing mais efetivas e personalizar os serviços oferecidos.





Norte para a resolução

Considere um conjunto de dados hipotéticos que contém as seguintes variáveis para cada cliente:


Idade: Idade do cliente.

Renda_Anuar: Renda anual do cliente (em milhares de reais).

Pontuacao_Credito: Pontuação de crédito do cliente.

Saldo_Medio: Saldo médio na conta bancária (em milhares de reais).





Norte para a resolução

PASSO 1: Instalação e carregamento de pacotes.

```
install.packages("tidyverse")
```

```
install.packages("cluster")
```

```
install.packages("factoextra")
```


```
# Carrega os pacotes
```

```
library(tidyverse)
```

```
library(cluster)
```

```
library(factoextra)
```





Norte para a resolução

PASSO 2: carregar e visualizar dados.

Criar um conjunto de dados fictício

```
set.seed(123) # Para reprodutibilidade
```

```
clientes <- data.frame(
```

```
  Idade = sample(18:70, 100, replace = TRUE),
```

```
  Renda_Anual = sample(20:150, 100, replace = TRUE),
```

```
  Pontuacao_Credito = sample(300:850, 100, replace =  
TRUE),
```


```
  Saldo_Medio = sample(0:100, 100, replace = TRUE)
```

```
)
```

Visualizar as primeiras linhas do conjunto de dados

```
head(clientes)
```





Norte para a resolução

PASSO 3: pré-processamento de dados.


Padronizar os dados (z-score)

```
clientes_scaled <- scale(clientes)
```

Visualizar as primeiras linhas dos dados padronizados

```
head(clientes_scaled)
```





Norte para a resolução

PASSO 4: determinar número ótimo de clientes.

```
# Calcular o total de within-cluster sum of squares (WSS) para  
diferentes valores de k
```

```
wss <- function(k) {  
  kmeans(clientes_scaled, k, nstart = 10)$tot.withinss  
}
```

```
# Definir uma faixa de valores de k
```

```
k_values <- 1:10
```


```
# Calcular o WSS para cada k
```

```
wss_values <- map_dbl(k_values, wss)
```

```
# Plotar o gráfico do Elbow Method
```

```
plot(k_values, wss_values,  
     type = "b", pch = 19, frame = FALSE,  
     xlab = "Número de Clusters K",  
     ylab = "Total de WSS")
```





Norte para a resolução

PASSO 5: aplicar k-means.

Aplicar o K-means com 3 clusters

```
set.seed(123)  # Para reprodutibilidade
```

```
kmeans_result <- kmeans(clientes_scaled,  
centers = 3, nstart = 25)
```


Adicionar os rótulos dos clusters ao conjunto de dados original

```
clientes$Cluster <-  
as.factor(kmeans_result$cluster)
```

Visualizar as primeiras linhas com os clusters atribuídos

```
head(clientes)
```





Norte para a resolução

PASSO 6: visualização.


```
# Visualizar os clusters
```

```
fviz_cluster(kmeans_result, data =  
clientes_scaled,
```

```
          geom = "point", ellipse.type =  
"convex",
```


```
          ggtheme = theme_minimal()) +  
  labs(title = "Segmentação de Clientes usando K-  
means")
```





Norte para a resolução

Resultado de clusterização




Fonte: elaborada pelo autor.

Aprendizado Não Supervisionado e Redução de Dimensionalidade

Consolidando o aprendizado

Bloco 5

Lucas Claudino



Consolidando o aprendizado

- Aprendizagem não supervisionada: descoberta de padrões.
- Clusterização.
- Aplicações: identificação, segmentação, análise de dados, detecção de falhas etc.
- Manipulação de dados: redução de dimensionalidade.
- Visualização: essencial para interpretação.






Quiz



Imagine que você é um gestor de um supermercado e deseja entender melhor o comportamento de compra de seus clientes para otimizar a disposição dos produtos nas prateleiras e melhorar as vendas. Como você aplicaria as técnicas de clusterização e redução de dimensionalidade para atingir esses objetivos?






Quiz - resolução



Agrupar clientes com padrões de compras semelhantes.




Resultado: otimização de disposição de produtos frequentemente comprados em conjunto.



Redução de dimensionalidade: foco em características principais – frequência de compra, ticket médio, horário de preferência.






Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!





Indicação de leitura 1

Esta leitura contém uma descrição teórica detalhada e exemplos práticos de redução de dimensionalidade aplicados em conceitos estatísticos e de aprendizado de máquina.


Referência

BLUHM, Thiago. **Redução de dimensionalidade**. 2024.

Disponível em:

<https://comunidadeestatistica.com.br/reducao-de-dimensaoalidade/>. Acesso em: 18 set. 2024.






Indicação de leitura 2

Este artigo contém uma explicação de teoria bastante profissional sobre o conceito básico de clusterização hierárquica, levando o leitor a entender o processo desta importante técnica de aprendizado de máquina.

Referência

REDDY, Chaitanya. **Understanding the concept of Hierarchical clustering Technique**. 2018. Disponível em: <https://medium.com/towards-data-science/understanding-the-concept-of-hierarchical-clustering-technique-c6e8243758ec>. Acesso em: 18 set. 2024.





Referências

ESTER, Martin; KRIEGEL, Hans-peter; SANDER, Jörg. A density-based algorithm for discovering clusters in large spatial databases with noise. **Proceedings Of The Second International Conference On Knowledge Discovery And Data Mining**. Oregon, p. 226-231. 4 ago. 1996.

FACELI, K.; LORENA, A. C.; GAMA, J.; CARVALHO, A. C. P. L. F. **Inteligência artificial**: uma abordagem de aprendizado de máquina. São Paulo: LTC Editora, 2011.

PRIY, Surya. **Clustering in Machine Learning**. 2024. Disponível em: <https://www.geeksforgeeks.org/clustering-in-machine-learning/>. Acesso em: 18 set. 2024.

RAO, T. Srinivas; HEMA, M.; PRIYA, K. Sai; KRISHNA, K. Vamsi; ALI, M. Sakhavath. Iris Flower Classification Using Machine Learning, **International Journal of All Research Education and Scientific Methods (IJARESM)**, vol. 9, issue 6, June, 2021, ISSN: 2455-6211.





Bons estudos!