



WBA0754\_v2.0

# Machine Learning



# Aprendizado Supervisionado – Técnicas de Classificação e Regressão

## Aprendizado de Máquina (Machine Learning)

### **Bloco 1**


Lucas Claudino



## Vamos refletir?


Você já se perguntou como o seu banco consegue detectar uma transação suspeita no seu cartão de crédito quase que instantaneamente, ou como o seu streaming de filmes sempre parece saber exatamente o que você quer assistir a seguir? Que tipo de algoritmos inteligentes estão por trás dessas decisões, e como eles aprendem a fazer previsões tão precisas com base no seu comportamento?






# Classificação

Classificação do AM.





# Modelos preditivos

Classificação dos algoritmos preditivos.

## Preditivo de classificação

- Dados finitos com valores nominais.


## Preditivo de regressão

- Dados infinitos.




# Métodos preditivos baseados em distância

Classificação dos algoritmos preditivos.



Fonte: elaborada pelo autor.

**Hipótese:** dados semelhantes ficam dispostos de maneira concentrada no domínio do conjunto da função.



## Métodos probabilísticos

- Usados quando falta informação.
- Baseados no Teorema de Bayes:


- $$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- $$P(\Omega) = 1$$

- $$P(E) \leq 1$$

- $$P(F \cup G) = P(F) + P(G)$$






# Métodos baseados em procura

Todo problema de procura deve possuir:

- Espaço de estados.
- Estado de início.
- Teste de objetivo.
- A solução é uma sequência de atos (plano).
- Plano concretizado pelo algoritmo.







# Métodos baseados em procura

Busca não  
informada

- Busca em largura.
- Busca em profundidade.


Busca  
informada

- Busca gráfica.
- *A\* Search.*
- *Greedy Search.*




# Métodos baseados em otimização

Função custo multivariável



Fonte: elaborada pelo autor.

- Otimização de funções custo.
  - Maximização ou Minimização.




# Aprendizado Supervisionado – Técnicas de Classificação e Regressão

Modelos de classificação: algoritmos kNN, SVM e  
Random Forest

**Bloco 2**

Lucas Claudino



# kNN


- AM supervisionado baseado em distância.
- Treinamento: memoriza o conjunto -> “lazy”.
- Descobre o rótulo através da distância entre os objetos:

$$d(x_i, x_j) = \sqrt{\sum_{l=1}^d (x_i^l - x_j^l)^2}$$




Fator  $k$  pode gerar classificações diferentes!

Distribuição de objetos para classificação




Fonte: elaborada pelo autor.




# kNN – influência de k

Classificação por kNN.



$k=1$




$k=5$

Fonte: Boccato e Attux (2018).




# Random Forest e árvore de decisão

Exemplo de árvore de decisão




Fonte: HAN *et al.* (2011).

- Inferência a partir dos dados.
- Árvore criada a partir de perguntas e respostas sobre os dados.
- Começar pela raiz e então dividir os dados.
- Árvore muito grande -> overfitting -> métodos de poda.



# Random Forest



COMBINAR  
ESTIMADORES  
FRACOS PARA  
CONSTRUIR UM  
MODELO  
ROBUSTO.



META-  
ESTIMADOR QUE  
AGREGA  
DIVERSAS  
ÁRVORES DE  
DECISÃO.



QUANTIDADE DE  
CARACT. A SEREM  
DIVIDIDAS EM  
CADA NÓ É  
LIMITADA.




CADA ÁRVORE  
EXTRAI UMA  
AMOSTRA  
ALEATÓRIA.



CADA ÁRVORE  
CRIADA É UM  
ESTIMADOR  
DIFERENTE.








# Random Forest

Exemplo de conjunto de árvores de decisão




Fonte: Maini (2017, p. 53).



# Random Forest

Exemplo de conjunto de árvores de decisão



Fonte: MainI (2017, p. 53).



# Aprendizado Supervisionado – Técnicas de Classificação e Regressão

Modelos de regressão e peculiaridades de  
implementação

**Bloco 3**

Lucas Claudino


# Regressão

- **Objetivo:** criar uma função matemática a partir dos dados.
- Estimar  $\hat{f}(x_i) \approx f(x_i)$
- A função tem que satisfazer  $[\hat{f}(x_i) - f(x_i)] < \delta$




# Regressão linear e intervalo de confiança

Exemplo de regressão linear




Fonte: elaborada pelo autor.




# Regressão multivariável

Exemplo de regressão multivariável




Fonte: elaborada pelo autor.



# Decision tree

- Critérios para divisão: ganho de informação.
- Entropia.
- Como evitar *overfitting*?
  - Limitar o número de interações.
  - Técnicas de poda.






# Poda em árvores de decisão

```
1  Algoritmo 2 Poda em Árvore de decisão
2  Data: função  $f(T, m)$  (estimativa para o erro de generalização,
   baseado no tamanho  $m$  da amostra)
3  Result: Substituição ou não do nó
4  for nó  $j$  em um caminho de baixo para cima do
5      | Encontre  $T'$  que minimize  $f(T, m)$ , onde  $T'$  é qualquer:
6      | a árvore atual após substituir o nó  $j$  por uma folha 1
7      | a árvore atual após substituir o nó  $j$  por uma folha 0
9      | a árvore atual após substituir o nó  $j$  por sua sub-árvore
   esquerda
10     | a árvore atual após substituir o nó  $j$  por sua sub-árvore
   direita
11 end
```








# Método ensemble

## Estrutura de um ensemble



Fonte: elaborada pelo autor.

# Aprendizado Supervisionado – Técnicas de Classificação e Regressão


Teoria em prática

**Bloco 4**


Lucas Claudino

# Teoria em prática - Problema Íris

Flores do problema íris.



Fonte: Rao *et al.* (2021).




# Teoria em prática

Vantagens do kNN:

- Fácil implementação
- Pacote para uso de kNN em R.
- Treinamento: vai memorizar a distribuição.
- Banco com 150 objetos (50 de cada classe).
- Pode-se variar a proporção de treinamento e teste.






# Teoria em prática

```
1  require("class") #carrega pacote
2  require("datasets")
3  data("iris") #carrega Iris
4  #set.seed(99) #caso queira sempre o mesmo resultado
5  rnum <- samples(rep(1:500)) #num aleat de 1 a 150
6  iris <- iris[rnum,] #embaralha o "iris"
7  normalize <- function(x) {
9      return ((x-min(x))/(max(x)-min(x)))
10 }
11 iris.new <-
  as.data.frame(lapply(iris[,c(1,2,3,4)],normalize))
12 head(iris.new)
13 iris.train <- iris.new[1:120]
14 iris.train.target <- iris[1:120,5]
15 iris.test <- iris.new[121:150,]
```





## Teoria em prática

```
16 iris.train.target <- iris[121:150,5]
17 summary(iris.new)
18 model1 <- knn(train=iris.train, test=iris.test,
  cl=iris.train.target, k=26) #modelo
19 table(iris.test.target,model1)
```




# Aprendizado Supervisionado – Técnicas de Classificação e Regressão

Consolidando o aprendizado

**Bloco 5**

Lucas Claudino



## Consolidando o aprendizado

- Classificação do aprendizado de máquina.
- Método de classificação: kNN.
- Método de classificação: Ensemble, Random Forest.
- Métodos de regressão: linear e multivariável.
- Implementação: critérios para divisão, overfitting e podas.








## Quiz



Explique como os algoritmos de machine learning, como Random Forest, k-Nearest Neighbors (kNN) e Regressão, podem ser aplicados em situações do cotidiano para resolver problemas específicos. Escolha um algoritmo e descreva um caso de uso real, detalhando como ele pode ser implementado, quais seriam as vantagens e limitações de sua aplicação, e como os resultados obtidos poderiam impactar a tomada de decisões.





## Quiz - Resolução




**Detecção de fraudes em transações bancárias utilizando o *Random Forest*:** envolve o uso de um conjunto de dados de transações passadas, que inclui atributos como o valor da transação, localização geográfica, horário da transação, histórico de transações do cliente, entre outros.



**Vantagens:** é robusto contra overfitting, especialmente quando há muitos dados e variáveis. Ele também é capaz de capturar relações não lineares e interações complexas entre variáveis.



**Limitações:** consumo computacional, especialmente com conjuntos de dados muito grandes. Além disso, o modelo é menos interpretável em comparação com outros algoritmos como árvores de decisão simples ou regressão linear.




## Leitura Fundamental

Prezado estudante, as indicações a seguir podem estar disponíveis em algum dos parceiros da nossa Biblioteca Virtual (faça o login por meio do seu AVA), e outras podem estar disponíveis em sites acadêmicos (como o SciELO), repositórios de instituições públicas, órgãos públicos, anais de eventos científicos ou periódicos científicos, todos acessíveis pela internet.

Isso não significa que o protagonismo da sua jornada de autodesenvolvimento deva mudar de foco. Reconhecemos que você é a autoridade máxima da sua própria vida e deve, portanto, assumir uma postura autônoma nos estudos e na construção da sua carreira profissional.

Por isso, nós o convidamos a explorar todas as possibilidades da nossa Biblioteca Virtual e além! Sucesso!





## Indicação de leitura 1

Esta leitura contém uma comparação teórica e prática (utilizando códigos em Python e R) dos principais algoritmos de machine learning utilizados atualmente.


### Referência

RAY, Sunil. **Top 10 Machine Learning Algorithms to Use in**

**2024**. 2024. Disponível em:

<https://www.analyticsvidhya.com/blog/2017/09/common-machine-learning-algorithms/>. Acesso em: 24 set. 2024.





## Indicação de leitura 2


Este artigo contém um resumo e aplicação de um dos problemas mais clássicos utilizados para o ensinamento do aprendizado de máquina: Problema Íris.

### Referência

RAO, T. S.; HEMA, M.; PRIYA, K. S.; KRISHNA, K. V.; ALI, S.  
Iris Flower Classification Using Machine Learning.

**International Journal of All Research Education and Scientific Methods (IJARESM)**, v. 9, issue 6, June, 2021,  
ISSN: 2455-6211.





# Referências

BOCCATO, Levy; ATTUX, Romis. **K-Nearest Neighbors**. 2018. Disponível em: [http://www.dca.fee.unicamp.br/~lboccato/topico\\_5\\_k\\_nearest\\_neighbor.pdf](http://www.dca.fee.unicamp.br/~lboccato/topico_5_k_nearest_neighbor.pdf). Acesso em: 26 ago. 2024.

FACELI, K.; LORENA, A. C.; GAMA, J.; CARVALHO, A. C. P. L. F. **Inteligência artificial**: uma abordagem de aprendizado de máquina. São Paulo: LTC Editora, 2011.

HAN, J.; KAMBER, M.; PEI, J. **Data Mining**: concepts and techniques. Elsevier, 2011. ISBN 0123814804.

MAINI, Vishal; SABRI, Samer. **Machine Learning for Humans**. 2017. Disponível em: <https://everythingcomputerscience.com/books/Machine%20Learning%20for%20Humans.pdf>. Acesso em: 24 set. 2024.

RAO, T. S.; HEMA, M.; PRIYA, K. S.; KRISHNA, K. V.; ALI, S. Iris Flower Classification Using Machine Learning. **International Journal of All Research Education and Scientific Methods (IJARESM)**, v. 9, issue 6, June, 2021, ISSN: 2455-6211.





Bons estudos!