FIAP ON

CAMPO DA INOVAÇÃO - UMA PLANTAÇÃO DE CÓDIGOS

# OS BASTIDORES DE UMA IA

2

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

## LISTA DE FIGURAS

Figura 1 - Robô com simulação de sua área a ser limpa via aplicativo.....6
Figura 2 - Lançamento de dados é um processo estocástico .....14
Figura 3 - Rede de Petri é similar ao jogo de tabuleiro .....21
Figura 4 - Jardim em forma de labirinto, construído em Ribeauville, no leste da França .....31
Figura 5 - Filtro anti-spam do Gmail .....39
Figura 6 - Processo de clustering.....42
Figura 7 - Projeto de humanoides da Tesla .....49
Figura 8 - Machine Learning aprendendo como selecionar uma maçã.....52
Figura 9 - Aprendizado Não Supervisionado: o algoritmo procura padrões e semelhanças e tenta agrupar os iguais, mas nem sempre acerta, como é o caso do pepino verde e vermelho juntos .....53
Figura 10 - Aprendizado por reforço: a máquina memoriza sua própria pontuação quando sabe que bateu a própria meta.....54

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

**SUMÁRIO**

1 OS BASTIDORES DE UMA IA.....5
1.1 Princípios de Modelagem e Simulação .....5
1.1.1 Elementos da Modelagem.....5
1.1.2 Modelo.....8
1.1.3 Simulação.....9
1.1.4 Validação.....10
1.1.5 Calibração .....10

2 TIPOS DE MODELOS.....12
2.1 Modelos Determinísticos .....12
2.1.1 Características .....12
2.1.2 Exemplos de Modelos Determinísticos.....13
2.1.3 Aplicações.....13
2.2 Modelos Estocásticos.....14
2.2.1 Características .....15
2.2.2 Exemplos.....15
2.2.3 Aplicações.....16
2.3 Modelos Contínuos .....17
2.3.1 Características .....17
2.3.2 Exemplos.....17
2.3.3 Aplicações.....18
2.4 Modelos Discretos.....19
2.4.1 Características .....20
2.4.2 Exemplos.....21
2.4.3 Aplicações.....22

3 QUAL MODELO ESCOLHER? .....24
3.1 Entenda a Natureza do Problema .....24
3.2 Considere a Disponibilidade de Dados .....24
3.3 Avalie a Complexidade do Problema .....24
3.4 Mentalize as Ferramentas Disponíveis .....25
3.5 Considere as Limitações de Cada Modelo.....25
3.6 Experimente e Compare.....25

4 ONDE ENCONTRAR FERRAMENTAS PARA MODELAR?.....27
4.1 Modelos Determinísticos .....27
4.2 Modelos Estocásticos.....27
4.3 Modelos Contínuos .....27
4.4 Modelos Discretos.....28

5 QUAIS AS TENDÊNCIAS FUTURAS DESSES MODELOS? .....29

6 PILARES DOS ALGORITMOS BÁSICOS DE IA .....31
6.1 Detalhes dos Pilares .....32
6.1.1 Busca .....32
6.1.2 Heurísticas .....33
6.1.3 Otimização .....34

7 QUAIS SÃO OS PROBLEMAS QUE UMA IA PODE RESOLVER?.....39
7.1 Classificação: A Arte de Categorizar.....39

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

7.2 Regressão: Previsão dos Valores Numéricos .....40
7.3 Clustering: Agrupando Dados Semelhantes.....41

8 REPRESENTAÇÃO DO CONHECIMENTO: A LINGUAGEM DA IA .....44
8.1 Lógica Proposicional .....44
8.2 Lógica de Primeira Ordem (LPO) .....45
8.3 Redes Semânticas .....47

9 APRENDIZADO DE MÁQUINA.....48
9.1 Diferença de IA para ML.....48
9.2 Exemplos de Aplicações de IA e ML Comerciais .....49
9.3 Detalhes de uma ML .....51
9.4 Tipos de Aprendizado .....51
9.5 Exemplos de Algoritmos.....54
9.6 Limitações do Aprendizado de Máquina .....55

CONCLUSÃO.....56

REFERÊNCIAS.....58

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 1 OS BASTIDORES DE UMA IA

## 1.1 Princípios de Modelagem e Simulação

A modelagem e a simulação são pilares fundamentais da Inteligência Artificial (IA), permitindo a criação de sistemas inteligentes capazes de representar, analisar e prever o comportamento de fenômenos complexos. Neste contexto, a modelagem consiste em construir representações abstratas e simplificadas de sistemas do mundo real, enquanto a simulação envolve a execução dessas representações para gerar dados e insights.

### 1.1.1 Elementos da Modelagem

Imagine que você está desenvolvendo um robô aspirador de pó inteligente. Para ele funcionar de modo eficiente, é necessário desenvolver um modelo que represente o ambiente em que ele irá operar. Esse modelo pode ser um mapa ou uma planta baixa (aquele desenho em CAD — Computer-Aided Design ou Desenho Auxiliado por Computador muito utilizado em engenharias), com informações sobre a localização de paredes, móveis, tapetes e outros obstáculos. A **modelagem** nesse caso envolve:

- **Abstração**, que representa o ambiente real de forma simplificada, utilizando um mapa bidimensional com informações relevantes para o robô, como paredes e obstáculos.
- **Simplificação**, pois, em um primeiro momento, é necessário ignorar detalhes irrelevantes para o funcionamento do robô, como a textura do piso ou a cor das paredes.
- **Representação**, quando se utiliza uma estrutura de dados adequada para armazenar as informações do modelo, como um grafo, uma matriz ou um banco de dados.

Com o modelo do ambiente em mãos, é possível realizar **simulações** para testar diferentes estratégias de limpeza e otimizar o desempenho do robô, até para que ele tenha uma maior autonomia na bateria. Por exemplo, você pode simular o

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

robô se movendo pelo ambiente, coletando dados sobre o tempo gasto, a área coberta e a quantidade de energia consumida. Observe na figura “Robô com simulação de sua área a ser limpa via aplicativo” um exemplo de robô que possui simulação via aplicativo.

Figura 1 - Robô com simulação de sua área a ser limpa via aplicativo
Fonte: site amazon (2022)

E como o robô saberia que ele limpou o cômodo inteiro? Quando os sensores das suas rodinhas calculam a área percorrida em linha reta, e essa área bate aproximadamente com a área livre de obstáculos prevista no desenho da planta baixa existe uma probabilidade considerável de que o robô percorreu toda a área destinada para a limpeza. E se suas escovas limpantes não travaram ao longo da trajetória, então conclui-se que a limpeza foi feita. A única certeza do sucesso e da qualidade dessa missão é a observação feita por um humano, que decidirá se a marca do robô é boa ou não para realizar essa função.

Ainda aprofundando o quesito **simulação** nesse caso, tem-se:

- **Execução do modelo:** é uma simulação do movimento do robô no ambiente virtual, utilizando algoritmos de planejamento de trajetória e controle de movimento.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Coleta de dados:** registrar informações sobre o desempenho do robô durante a simulação, como tempo gasto, área coberta e energia consumida.
- **Análise dos resultados:** avaliar as diferentes estratégias de limpeza e identificar a mais eficiente em termos de tempo, cobertura e consumo de energia.

Através da modelagem e da simulação, é possível testar e aprimorar o robô aspirador de pó antes mesmo de construí-lo fisicamente, economizando tempo e recursos. Além disso, a simulação permite explorar diferentes cenários e condições, como a presença de animais de estimação ou a disposição dos móveis, garantindo que o robô seja capaz de se adaptar a diferentes situações. Estudaremos mais adiante que as melhores marcas de robôs varredores são capazes de memorizar as melhores execuções de limpeza reais ao analisar os resultados obtidos. Vale ressaltar que o nome disso é Aprendizado de Máquina ou Machine Learning (ML).

Portanto, para esse início de capítulo, vamos definir mais alguns conceitos importantes**:**

- **Modelo:** é a representação simplificada de um sistema, processo ou fenômeno, que captura suas características essenciais e permite a análise e predição de seu comportamento.
- **Simulação:** é o processo que executa um modelo computacional para observar sua dinâmica e gerar dados, permitindo a análise e avaliação de diferentes cenários.
- **Validação:** é o processo que verifica se o modelo representa adequadamente o sistema real, comparando seus resultados com dados observados.
- **Calibração:** é a etapa de ajuste dos parâmetros do modelo para garantir que ele reproduza com precisão o comportamento observado do sistema real.

Vamos analisar melhor esses conceitos para entendermos o que acabamos de ver por meio de um exemplo na área de Previsão de Vendas. Pense que você é um gerente de vendas e deseja prever as vendas futuras de um determinado produto com base em dados históricos. Para isso, você pode utilizar um modelo de aprendizado de

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

máquina supervisionado chamado regressão linear. Então, os quatro itens citados anteriormente, ficariam assim nesse contexto:

### 1.1.2 Modelo

O modelo de regressão linear estabelece uma relação matemática entre as vendas do produto (variável dependente, isto é, uma variável que pode assumir valores a depender de outra variável) e outros fatores que podem influenciá-las (variáveis independentes, que são variáveis de valor fixo). Por exemplo, as variáveis independentes podem incluir:

- Investimento em publicidade, isto é, quanto mais a empresa investe em publicidade, maiores podem ser as vendas.
- Preço do produto, pois o preço pode influenciar a demanda pelo produto.
- Sazonalidade, visto que as vendas podem variar de acordo com a época do ano (exemplo: Natal, Dia das Mães).

A equação do modelo de regressão linear pode ser expressa da seguinte forma:

*Vendas = a + b1 * Publicidade + b2 * Preço + b3 * Sazonalidade*

Em que:

- **Vendas** é a variável dependente, que representa as vendas do produto.
- **Publicidade**, **Preço** e **Sazonalidade** são as variáveis independentes.
- **a** é o intercepto, que representa as vendas quando todas as variáveis independentes são zero.
- **b1**, **b2** e **b3** são os coeficientes de regressão, que indicam o impacto de cada variável independente nas vendas, ou seja, são ponderadores.

E por fim, para treinar o modelo, você precisa de dados históricos de vendas, investimento em publicidade, preço do produto e sazonalidade. Assim, o algoritmo de regressão linear poderá analisar esses dados e encontrar os valores dos coeficientes **a**, **b1**, **b2** e **b3** que melhor se ajustam aos dados.

Suponha que o modelo treinado tenha a seguinte equação:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

*Vendas = 1000 + 2 * Publicidade - 0,5 * Preço + 300 * Sazonalidade*

Isso significa que as vendas básicas, sem investimento em Publicidade = 0, com Preço = 0 fora de períodos sazonais (0), serão de 1000 unidades:

*Vendas = 1000 + 2 * 0 - 0,5 * 0 + 300 * 0 = 1000*

- Cada unidade adicional investido em publicidade, aumenta as vendas em 2 unidades.
- Vendas = 1000 + 2 * 1 - 0,5 * 0 + 300 * 0 = 1002
- Cada real a mais no preço do produto, diminui as vendas em 0.5 unidades.
- Em períodos sazonais, as vendas aumentam em 300 unidades.

### 1.1.3 Simulação

A simulação é uma técnica poderosa que permite utilizar um modelo computacional para replicar o comportamento de um sistema real em diferentes cenários. No contexto da IA, a simulação é essencial para testar e refinar modelos, prever resultados e tomar decisões estratégicas sem correr riscos ou incorrer em custos no mundo real.

Após o treinamento de um modelo de aprendizado de máquina, como o exemplo da regressão linear para previsão de vendas, a simulação entra em cena. Imagine que você deseja saber como um aumento de 10% no investimento em publicidade afetaria as vendas do seu produto. Ao invés de arriscar um investimento real e esperar para ver os resultados, você pode utilizar o modelo treinado para simular esse cenário.

Além disso, a simulação permite explorar um vasto leque de possibilidades, alterando as variáveis de entrada do modelo e observando como essas mudanças afetam os resultados. No exemplo das vendas, você pode simular diferentes níveis de investimento em publicidade, preços e sazonalidades para entender como cada fator contribui para o sucesso do produto.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

As informações obtidas por meio da simulação são valiosas para a tomada de decisões estratégicas. Quando simulamos diferentes cenários, podemos identificar as melhores estratégias para maximizar as vendas, minimizar os custos e otimizar o desempenho do negócio.

### 1.1.4 Validação

A validação é uma etapa crucial no desenvolvimento de modelos de aprendizado de máquina, pois garante que o modelo seja capaz de generalizar para novos dados e não apenas memorizar os dados de treinamento. Existem diversas técnicas de validação, como a validação cruzada, que divide os dados em subconjuntos para treinamento e teste, e a validação holdout, que separa uma parte dos dados para teste e utiliza o restante para treinamento.

A escolha da técnica de validação depende do tamanho do conjunto de dados, da complexidade do modelo e do objetivo da análise. É importante escolher uma técnica que permita avaliar o desempenho do modelo de forma imparcial e evitar o overfitting, que ocorre quando o modelo se ajusta muito bem aos dados de treinamento, mas não generaliza para novos dados.

Depois da validação, caso o modelo apresente um desempenho insatisfatório, é possível realizar ajustes nos parâmetros do modelo ou experimentar diferentes algoritmos de aprendizado de máquina. Esse processo iterativo de validação e ajuste do modelo é fundamental para garantir que o modelo seja capaz de realizar previsões precisas e confiáveis em situações reais.

### 1.1.5 Calibração

Se as previsões do modelo não forem suficientemente precisas, podemos realizar a calibração, que consiste em ajustar os parâmetros do modelo (coeficientes da equação de regressão) para melhorar seu desempenho.

A calibração pode envolver a coleta de mais dados, a utilização de diferentes algoritmos de aprendizado de máquina ou a alteração da forma da equação. O objetivo da calibração é garantir que o modelo represente o sistema real da forma mais precisa possível, permitindo previsões mais confiáveis.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Vamos analisar o seguinte exemplo: suponha que o modelo inicial preveja um aumento de 5% nas vendas caso ocorra um aumento de 10% no investimento em publicidade. No entanto, ao comparar essa previsão com os dados reais, observamos o aumento das vendas em apenas 2%. Nesse caso, podemos calibrar o modelo ajustando o coeficiente que representa o impacto da publicidade nas vendas, de modo que o modelo reflita melhor a realidade observada.

Portanto, ao entender e aplicar os conceitos de modelagem, simulação, validação e calibração, podemos construir modelos de aprendizado de máquina mais precisos e confiáveis, que podem ser utilizados para tomar decisões estratégicas e otimizar o desempenho de um negócio.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 2 TIPOS DE MODELOS

Neste tópico, exploraremos os quatro tipos principais de modelos utilizados em IA: **determinísticos**, **estocásticos**, **contínuos** e **discretos**. Existem outros, mas serão discutidos na disciplina de Machine Learning e Redes Neurais nas fases futuras, por enquanto, vamos entender esses primeiro. Cada um desses tipos possui características e aplicações específicas, e a compreensão de suas diferenças é fundamental para a construção de modelos eficazes.

## 2.1 Modelos Determinísticos

Um modelo determinístico é aquele em que o resultado é completamente determinado pelas condições iniciais e pelas entradas do sistema. Em outras palavras, ao determinar um conjunto de entradas e condições iniciais, o modelo sempre produzirá o mesmo resultado, sem qualquer elemento de aleatoriedade.

A palavra "determinístico" tem origem no termo "determinismo", que por sua vez se derivou do verbo "determinar". O verbo "determinar" se originou do latim *determinare*, e significa "fixar os limites" ou "definir com precisão". No contexto filosófico, o determinismo é a teoria que afirma que todos os eventos, incluindo as ações humanas, são determinados por causas anteriores e, portanto, são previsíveis.

### 2.1.1 Características

- **Previsibilidade:** significa que os modelos determinísticos são altamente previsíveis, pois seus resultados são determinados por relações matemáticas ou lógicas precisas.
- **Repetibilidade:** dado o mesmo conjunto de entradas e condições iniciais, o modelo sempre produzirá o mesmo resultado, independentemente de quantas vezes a simulação for executada. Essa característica é muito importante.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Simplicidade:** em muitos casos, os modelos determinísticos são mais simples de construir e analisar em comparação aos modelos estocásticos, pois não envolvem elementos de aleatoriedade.

### 2.1.2 Exemplos de Modelos Determinísticos

- **Modelo de Queda Livre:** este modelo descreve o movimento de um objeto em queda livre sob a influência da gravidade. Fornecida a altura inicial e a velocidade inicial do objeto, o modelo pode prever com precisão a trajetória e o tempo de queda, desde que estejamos no mesmo planeta, onde a força gravitacional não se altera (previsibilidade).
- **Modelo de Crescimento Populacional Exponencial:** este modelo descreve o crescimento de uma população em um ambiente idealizado, onde não exista recursos limitados. Fornecida a taxa de crescimento e a população inicial, o modelo pode prever o tamanho da população em qualquer momento futuro.
- **Modelos de Circuitos Elétricos:** estes modelos descrevem o comportamento dos circuitos elétricos, utilizando leis físicas como a Lei de Ohm e as Leis de Kirchhoff. Fornecidas as características dos componentes do circuito e as tensões e correntes aplicadas, o modelo pode prever as tensões e correntes em qualquer ponto do circuito. Provavelmente, você deve lembrar desse assunto que foi visto nas aulas de Física, do Ensino Médio.

### 2.1.3 Aplicações

Os modelos determinísticos são amplamente utilizados em diversas áreas, como física, engenharia, economia e ciências sociais. Eles são particularmente úteis quando o comportamento do sistema é bem compreendido e pode ser descrito por relações matemáticas ou lógicas precisas.

Embora esses modelos sejam poderosos em muitas situações, eles possuem suas limitações. Por exemplo, os modelos determinísticos não são adequados para modelar sistemas complexos que envolvem aleatoriedade ou incerteza, como o clima

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

ou o mercado de ações. Nesses casos, modelos estocásticos, que incorporam elementos de aleatoriedade, são mais apropriados.

## 2.2 Modelos Estocásticos

Um modelo estocástico é aquele que incorpora elementos de aleatoriedade, onde o resultado é influenciado por fatores probabilísticos. Ou seja, mesmo com o conjunto fixo de dados de entrada e condições iniciais, o modelo pode produzir resultados diferentes em diferentes execuções ou épocas (termo técnico no universo da IA quando o modelo realiza uma volta inteira nos dados de entrada para reproduzir sua saída).

Por exemplo, o lançamento de um dado conforme a figura a seguir é um processo estocástico. Mesmo que você lance o dado da mesma maneira todas as vezes, o resultado (o número que aparece na face superior) será diferente a cada lançamento, pois é influenciado por fatores aleatórios, como a força do lançamento, a superfície em que o dado cai etc.

Figura 2 - Lançamento de dados é um processo estocástico
Fonte: Mundo Educação (2021)

Portanto, um modelo estocástico é aquele que incorpora elementos de aleatoriedade para representar a incerteza e a variabilidade presentes em muitos sistemas do mundo real. Esses modelos são frequentemente utilizados em áreas como finanças, meteorologia, biologia e engenharia, onde o comportamento do

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

sistema é influenciado por fatores aleatórios ou quando existem incertezas em relação às entradas ou condições iniciais.

### 2.2.1 Características

- **Incerteza:** os modelos estocásticos lidam com a incerteza inerente a muitos sistemas do mundo real, onde o resultado não é completamente determinado pelas entradas e condições iniciais.
- **Variabilidade:** os resultados deste modelo podem variar de uma execução para outra, mesmo com as mesmas entradas e condições iniciais.
- **Complexidade:** em muitos casos, os modelos estocásticos são mais complexos de construir e analisar do que os modelos determinísticos, pois envolvem a modelagem de distribuições de probabilidade e processos aleatórios.

### 2.2.2 Exemplos

- **Modelo de Previsão do Tempo:** este modelo utiliza dados meteorológicos e equações físicas para prever o tempo futuro. No entanto, devido à natureza caótica da atmosfera, o modelo sempre terá um grau de incerteza, ou seja, suas previsões podem variar de uma execução para outra.
- **Modelos de Mercado Financeiro:** estes modelos tentam prever o comportamento de mercados financeiros, como o preço de ações ou a taxa de câmbio. No entanto, devido à complexidade e à imprevisibilidade dos mercados, os modelos estocásticos são necessários para capturar a incerteza e a volatilidade.
- **Modelos de Simulação de Monte Carlo:** estes modelos utilizam técnicas de amostragem aleatória para simular o comportamento de sistemas complexos, como o desempenho de um portfólio de investimentos ou a propagação de uma doença.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

### 2.2.3 Aplicações

Os modelos estocásticos são amplamente utilizados em áreas como finanças, meteorologia, biologia, engenharia e ciências sociais. Eles são particularmente úteis quando o comportamento do sistema é influenciado por fatores aleatórios ou quando existe incerteza em relação às entradas ou condições iniciais.

Contudo, é importante entender as limitações desse tipo de modelo. Por exemplo, eles podem ser mais complexos comparados aos modelos determinísticos, tanto em termos de construção quanto de análise. Isso se deve à necessidade de modelar distribuições de probabilidade, processos aleatórios e relações complexas entre variáveis. A complexidade pode dificultar a interpretação dos resultados e aumentar o tempo e o custo computacional das simulações.

Além disso, os modelos estocásticos geralmente exigem uma grande quantidade de dados para estimar os parâmetros das distribuições de probabilidade e calibrar o modelo. A falta de dados suficientes ou de qualidade pode levar a estimativas imprecisas e a resultados pouco confiáveis.

Em seguida, temos a validação, onde os modelos estocásticos podem ser mais desafiadores do que a de modelos determinísticos, devido à presença de aleatoriedade. É necessário realizar múltiplas simulações e comparar os resultados com dados observados para avaliar a precisão e a robustez do modelo.

Vale mencionar que eles podem ser computacionalmente intensivos, especialmente para modelos complexos com muitas variáveis e interações. Isso pode limitar a aplicação de modelos estocásticos em tempo real ou em sistemas com recursos computacionais limitados.

Em muitos casos, os modelos estocásticos são baseados em aproximações e simplificações da realidade, o que pode levar a resultados imprecisos ou incompletos. É importante saber que os modelos são apenas representações da realidade e não a realidade propriamente dita.

Apesar dessas limitações, os modelos estocásticos são ferramentas valiosas para representar e analisar sistemas complexos que envolvem incerteza e variabilidade. Ao compreender suas limitações e utilizá-los com cautela, podemos

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

obter insights importantes e tomar decisões mais informadas em diversas áreas, como finanças, saúde, engenharia e ciências sociais.

### 2.3 Modelos Contínuos

Um modelo contínuo é aquele em que as variáveis do sistema mudam continuamente ao longo do tempo. Em outras palavras, o estado do sistema pode ser descrito em qualquer instante de tempo, e as mudanças ocorrem de forma suave e gradual.

#### 2.3.1 Características

- **Continuidade:** as variáveis do sistema evoluem de forma contínua, sem saltos ou interrupções abruptas.
- **Equações diferenciais:** os modelos contínuos são frequentemente descritos por equações diferenciais, que relacionam as taxas de variações das variáveis com o estado do sistema.
- **Análise matemática:** a análise de modelos contínuos geralmente envolve técnicas de cálculo diferencial e integral.

#### 2.3.2 Exemplos

- **Modelo de Crescimento Populacional Contínuo:** este modelo descreve o crescimento de uma população em um ambiente idealizado, onde a taxa de crescimento é proporcional ao tamanho da população. A população é representada por uma variável contínua que passa por mudanças suaves ao longo do tempo.
- **Modelo de Movimento de um Pêndulo:** este modelo descreve o movimento oscilatório de um pêndulo sob a influência da gravidade. A posição e a velocidade do pêndulo são representadas por variáveis contínuas que mudam suavemente ao longo do tempo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Modelos de Dinâmica de Fluidos:** estes modelos descrevem o movimento de fluidos, como água ou ar. As variáveis do sistema, como velocidade, pressão e densidade, são representadas por campos contínuos que variam suavemente no espaço e no tempo.

### 2.3.3 Aplicações

Os modelos contínuos são amplamente utilizados em áreas como física, engenharia, biologia e ciências ambientais, assim como o Modelo Estocástico. Porém, os Contínuos são particularmente úteis para descrever sistemas dinâmicos que evoluem suavemente ao longo do tempo, como o movimento de objetos, o fluxo de fluidos e o crescimento de populações.

Suas limitações tem relação com o envolvimento de equações diferenciais, que podem ser complexas de resolver analiticamente. Em muitos casos, são necessárias técnicas numéricas de aproximação, como o método de Euler ou Runge-Kutta, para obter soluções. Essa complexidade matemática pode dificultar a implementação e análise de modelos contínuos em sistemas de IA.

Além disso, a natureza contínua dos modelos pode não representar fielmente a realidade, que muitas vezes é discreta ou apresenta mudanças abruptas. Por exemplo, na verdade, o crescimento de uma população não é perfeitamente contínuo, pois ocorrem eventos discretos como nascimentos e mortes. A aproximação da realidade por um modelo contínuo pode levar a erros de previsão e limitar sua aplicabilidade em certas situações.

Inclusive, os modelos contínuos podem ser sensíveis aos valores dos parâmetros, como constantes de taxa ou coeficientes de equações diferenciais. Pequenas variações nesses parâmetros podem ocasionar grandes diferenças nos resultados do modelo, o que exige uma calibração cuidadosa e a consideração da incerteza nos parâmetros.

Em relação ao custo computacional, a resolução numérica de equações diferenciais pode ser computacionalmente intensiva, especialmente para modelos complexos com muitas variáveis e interações. Isso pode limitar a aplicação de

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

modelos contínuos em sistemas de IA em tempo real ou com recursos computacionais limitados.

Apesar dessas limitações, os modelos contínuos são ferramentas poderosas para representar e analisar sistemas dinâmicos que evoluem suavemente ao longo do tempo. Ao compreender suas limitações e utilizá-las em conjunto com outras técnicas de modelagem, podemos obter insights valiosos e construir sistemas de IA mais eficazes e robustos.

Em alguns casos, é necessário combinar modelos contínuos com modelos discretos para representar adequadamente o comportamento do sistema.

## 2.4 Modelos Discretos

Um modelo discreto é aquele em que as variáveis do sistema mudam em instantes discretos de tempo. Em outras palavras, o estado do sistema é atualizado em intervalos de tempo específicos, e as mudanças ocorrem em saltos discretos.

Enquanto em Modelos Contínuos descrevem a evolução suave e gradual das variáveis ao longo do tempo, utilizando equações diferenciais e análise matemática, os Modelos Discretos focam em eventos instantâneos e mudanças abruptas. A escolha entre um modelo contínuo ou discreto depende da natureza do sistema em estudo e do nível de detalhe necessário para a análise.

Portanto, os Modelos Contínuos são adequados para sistemas que evoluem suavemente, como o movimento de objetos ou o fluxo de fluidos, enquanto os Modelos Discretos são mais apropriados para sistemas que envolvem eventos discretos, como filas de espera ou sistemas de estoque.

Em alguns casos, é possível combinar modelos contínuos e discretos para representar sistemas híbridos que apresentam tanto comportamentos Contínuos quanto comportamentos Discretos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

### 2.4.1 Características

- **Eventos Discretos:** os modelos discretos são frequentemente descritos por eventos discretos, que representam mudanças instantâneas no estado do sistema.
- **Autômatos e Redes de Petri:** os modelos discretos podem ser representados por autômatos finitos, redes de Petri ou grafos de eventos, que **descrevem as transições entre os diferentes estados do sistema**. Você deve estar se questionando sobre o que são autômatos e Redes de Petri, irei explicar a seguir. Vamos lá!
    - Imagine um robô simples que só pode realizar algumas ações, como andar para frente, virar à esquerda ou virar à direita. Esse robô possui um conjunto limitado de "estados" (como parado, andando ou virando) e pode mudar de um estado para outro ao receber um comando específico. Um autômato é como esse robô: um modelo matemático que representa um sistema com um conjunto finito de estados e regras para transitar entre eles. Cada estado representa uma configuração possível do sistema, e as regras de transição determinam como o sistema muda de um estado para outro em resposta a eventos ou entradas. Autômatos são utilizados em diversas áreas, como ciência da computação, linguística e engenharia, para modelar e analisar sistemas que exibem comportamentos discretos e sequenciais.
    - Sobre Redes de Petri, pense em um jogo de tabuleiro como o da figura “Rede de Petri é similar ao jogo de tabuleiro” onde cada casa representa um estado diferente e as peças se movem entre as casas de acordo com regras específicas. As peças podem representar recursos, como dinheiro ou soldados, e as regras determinam como esses recursos são consumidos e produzidos durante o jogo. Uma Rede de Petri é como esse jogo de tabuleiro: um modelo gráfico que representa um sistema com lugares (casas), transições (regras) e tokens (peças). Os lugares representam as diferentes condições ou estados do sistema, as transições seriam as ações ou eventos que causam mudanças no sistema, e os tokens representam os recursos ou objetos que fluem pelo

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

sistema. As Redes de Petri são utilizadas para modelar e analisar sistemas concorrentes e distribuídos, como sistemas de manufatura, redes de computadores e processos de negócios. Elas permitem visualizar o fluxo de recursos, identificar gargalos e otimizar o desempenho do sistema.

Figura 3 - Rede de Petri é similar ao jogo de tabuleiro
Fonte: Clube Nerd (2023)

- **Simulação de Eventos Discretos:** a análise de modelos discretos geralmente envolve a simulação de eventos discretos, que consiste em simular a ocorrência de eventos em ordem cronológica e atualizar o estado do sistema a cada evento.

### 2.4.2 Exemplos

- **Modelo de Fila de Espera:** este modelo descreve a formação e o atendimento de filas em um sistema, como um caixa de supermercado ou um *call center*. O número de clientes na fila e o tempo de espera são variáveis discretas que mudam em instantes discretos de tempo, quando um cliente chega ou é atendido.
- **Modelo de Inventário:** este modelo descreve o estoque de produtos em um armazém ou loja. O nível de estoque é uma variável discreta que pode

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

mudar em instantes discretos de tempo, quando um produto é comprado ou vendido.

- **Modelos de Redes de Computadores:** estes modelos descrevem o tráfego de dados em redes de computadores. O número de pacotes em trânsito e o tempo de transmissão são variáveis discretas que podem variar em instantes discretos de tempo, quando um pacote é enviado ou recebido.

### 2.4.3 Aplicações

Os Modelos Discretos são amplamente utilizados em áreas como logística, manufatura, telecomunicações e ciência da computação. Eles são particularmente úteis para descrever sistemas que envolvem eventos discretos (binários, do tipo, tem ou não, está ou não está), como filas de espera, sistemas de estoque e redes de comunicação.

Contudo, é bom discutir as principais limitações dos Modelos Discretos, pois elas se manifestam em diferentes aspectos, impactando sua capacidade de representar e analisar sistemas do mundo real.

Por exemplo, ao focar em eventos discretos e ignorar a dinâmica contínua entre eles, os Modelos Discretos podem simplificar demais a realidade. Isso pode levar à perda de informações importantes e à imprecisão na representação de sistemas que apresentam comportamentos complexos e interdependentes.

Além disso, os Modelos Discretos não são adequados para representar sistemas que evoluem continuamente ao longo do tempo, como o movimento de um pêndulo ou o fluxo de água em um rio. Nesses casos, a descontinuidade do tempo, isto é, torná-lo binário (sim ou não), pode levar a erros de aproximação e à perda de informações sobre a dinâmica do sistema.

Em sistemas complexos com muitos estados e eventos possíveis, o número de combinações e sequências de eventos pode crescer exponencialmente, tornando a análise do modelo computacionalmente intratável. Essa explosão combinatória pode limitar a aplicação de Modelos Discretos em sistemas de grande escala ou com alta complexidade.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Além disso, os Modelos Discretos geralmente assumem que os eventos ocorrem em instantes de tempo bem definidos e que as transições entre estados são determinísticas. No entanto, muitos sistemas do mundo real apresentam incerteza e variabilidade, o que pode ser difícil de representar em um modelo discreto.

E por fim, a interpretação dos resultados de modelos discretos pode ser complexa, especialmente quando o modelo é grande e envolve muitas interações entre estados e eventos. A visualização do modelo e a análise de suas propriedades podem ajudar a entender seu comportamento e extrair informações relevantes.

Apesar dessas limitações, os modelos discretos são ferramentas essenciais para representar e analisar sistemas que envolvem eventos discretos, como filas de espera, sistemas de estoque e redes de comunicação. Ao compreender suas limitações e utilizá-los em conjunto com outras técnicas de modelagem, podemos construir modelos mais precisos e eficazes para representar a complexidade do mundo real.

FIAP

**PDF exclusivo para Francismar Alves Martins Júnior - rm562869**
**yggdrasil.git@gmail.com**

# 3 QUAL MODELO ESCOLHER?

Após explorar os quatro tipos de modelos de IA (determinísticos, estocásticos, contínuos e discretos), é hora de decidir qual deles melhor se adapta ao seu problema. Aqui estão algumas dicas para te ajudar nessa escolha:

## 3.1 Entenda a Natureza do Problema

O sistema é previsível ou imprevisível? Se o comportamento do sistema for bem compreendido e puder ser descrito por relações matemáticas ou lógicas precisas, um Modelo Determinístico pode ser suficiente. Caso contrário, se o sistema apresentar aleatoriedade ou incerteza, um Modelo Estocástico será mais adequado.

As variáveis mudam continuamente ou em instantes discretos? Se as variáveis do sistema evoluírem suavemente ao longo do tempo, um Modelo Contínuo é apropriado. Porém, se as mudanças ocorrerem em momentos específicos, um Modelo Discreto será mais adequado.

## 3.2 Considere a Disponibilidade de Dados

Você possui dados suficientes e de qualidade? Modelos Estocásticos geralmente exigem mais dados para estimar parâmetros e validar o modelo. Se você tiver poucos dados ou dados de baixa qualidade, um Modelo Determinístico ou discreto pode ser uma opção mais viável.

## 3.3 Avalie a Complexidade do Problema

O sistema é simples ou complexo? Modelos Determinísticos e Discretos tendem a ser mais simples de implementar e analisar do que Modelos Estocásticos e Contínuos. Se o sistema for muito complexo, com muitas variáveis e interações, um Modelo Estocástico ou Contínuo pode ser necessário para capturar essa complexidade, mas esteja preparado para um desafio maior.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

### 3.4 Mentalize as Ferramentas Disponíveis

Você tem acesso a ferramentas de simulação e análise? A escolha do modelo pode ser influenciada pelas ferramentas disponíveis. Se você tiver acesso a softwares de simulação de eventos discretos, pode ser mais fácil implementar um Modelo Discreto. Se você tiver experiência com equações diferenciais e ferramentas de análise numérica, um Modelo Contínuo pode ser mais adequado.

### 3.5 Considere as Limitações de Cada Modelo

Lembre-se das limitações discutidas anteriormente. Cada tipo de modelo tem suas próprias limitações. Modelos Determinísticos não capturam a aleatoriedade, Modelos Estocásticos podem ser complexos, Modelos Contínuos podem não representar eventos discretos e Modelos Discretos podem simplificar demais a realidade. Leve em consideração essas limitações ao escolher o modelo mais adequado para o seu problema.

### 3.6 Experimente e Compare

Não tenha medo de experimentar: a melhor maneira de escolher o modelo certo é experimentar diferentes abordagens e comparar seus resultados. Comece com um modelo simples e, se necessário, aumente a complexidade gradualmente. Avalie o desempenho de cada modelo em termos de precisão, robustez e interpretabilidade.

A escolha do modelo certo é um processo iterativo e pode exigir ajustes e refinamentos ao longo do tempo. Esteja aberto a novas ideias e abordagens, e não hesite em buscar ajuda de especialistas em modelagem e simulação até você se tornar um deles, resolvendo vários problemas reais, como:

- **Simulação de Tráfego:** modelos de tráfego são utilizados para prever o fluxo de veículos em diferentes cenários, otimizar o planejamento urbano e gerenciar o trânsito.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Modelos Climáticos:** são usados para prever mudanças no clima, avaliar o impacto de diferentes políticas ambientais e desenvolver estratégias de adaptação.
- **Modelos Econômicos:** são aplicados para analisar o comportamento de mercados, prever tendências econômicas e avaliar o impacto de políticas governamentais.
- **Simulação de Processos Industriais:** são utilizados para otimizar a produção, identificar gargalos e melhorar a eficiência.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 4 ONDE ENCONTRAR FERRAMENTAS PARA MODELAR?

As ferramentas para desenvolver os quatro tipos de modelagem em IA não se resumem somente ao Python. Na verdade, além de linguagens de programação e bibliotecas, existem diversas opções de softwares, desde os específicos até os mais abrangentes. A escolha da ferramenta ideal dependerá do tipo de modelo, da complexidade do problema e da experiência do usuário. Lembrando que o curso vai focar em Python e R agora nas fases iniciais, e vai entrar C++ nas fases futuras.

## 4.1 Modelos Determinísticos

- Linguagens de Programação: Python, R, MATLAB, Julia.
- Bibliotecas: NumPy, SciPy (para cálculos numéricos e científicos), SymPy (para manipulação simbólica de equações), Scikit-learn.
- Softwares de Modelagem: MATLAB, Simulink, Mathematica.

## 4.2 Modelos Estocásticos

- Linguagens de Programação: Python, R, MATLAB, Julia.
- Bibliotecas: NumPy, SciPy, Pandas (para análise de dados), Scikit-learn.
- Softwares de Simulação: AnyLogic, Arena, Simio.

## 4.3 Modelos Contínuos

- Linguagens de Programação: Python, R, MATLAB, Julia.
- Bibliotecas: NumPy, SciPy, odeint (para resolver equações diferenciais), GEKKO (para otimização e modelagem dinâmica).
- Softwares de Modelagem: MATLAB, Simulink, OpenModelica.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

## 4.4 Modelos Discretos

- Linguagens de Programação: Python, C++, Java.
- Bibliotecas: SimPy (para simulação de eventos discretos), Ciw (para simulação de filas de espera), DEVS (para simulação de sistemas discretos baseados em eventos), Matplotlib e Seaborn.
- Softwares de Modelagem: AnyLogic, Arena, Simio.

Além das ferramentas mencionadas, existem diversas outras opções disponíveis, como:

- Plataformas de Machine Learning: TensorFlow, PyTorch, Keras (para desenvolvimento de redes neurais e outros modelos de aprendizado de máquina).
- Ferramentas de Visualização: Matplotlib, Seaborn, Plotly (para criar gráficos e visualizações de dados).
- Ambientes de Desenvolvimento Integrado (IDEs): PyCharm, Spyder, RStudio (para facilitar o desenvolvimento e a depuração de código), Colab do Google.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

## 5 QUAIS AS TENDÊNCIAS FUTURAS DESSES MODELOS?

As tendências futuras do uso dos quatro tipos de modelos de IA são promissoras e apontam para avanços significativos em diversas áreas.

Para os Modelos Determinísticos, espera-se cada vez mais o uso de Modelos Híbridos, onde há uma combinação entre o Modelo Determinístico com o Modelo Estocástico, que permitirá representar sistemas complexos com maior precisão e realismo.

Nesse sentido, os avanços em algoritmos de otimização e poder computacional permitirão a utilização de Modelos Determinísticos para otimizar sistemas em tempo real, como o controle de tráfego ou a gestão de energia.

Vale mencionar que a crescente demanda por transparência e interpretabilidade em IA impulsionará o desenvolvimento de Modelos Determinísticos mais explicáveis, que permitam entender as razões por trás das decisões e previsões do modelo.

No futuro do campo dos Modelos Estocásticos deve existir o Deep Learning Probabilístico, que é a combinação de redes neurais profundas com técnicas de modelagem probabilística, permitindo criar modelos estocásticos mais poderosos e flexíveis, capazes de aprender e representar distribuições de probabilidade complexas.

Nesse sentido, a Inferência Bayesiana Escalável representará avanços em algoritmos de inferência Bayesiana e, aliada ao poder computacional, permitirão a aplicação de modelos estocásticos em problemas de grande escala e em tempo real, como previsão do tempo e análise de risco financeiro.

E ainda, os Modelos Generativos, que são modelos estocásticos generativos, como as Redes Adversárias Generativas (GANs), serão cada vez mais utilizados para criar dados sintéticos realistas, que podem ser usados para treinar outros modelos de IA, melhorar a privacidade de dados e criar novas formas de arte e entretenimento, e que, em certa medida, já acontece com o ChatGPT e Gemini.

No campo dos Modelos Contínuos, os avanços em poder computacional e técnicas de simulação permitirão a criação de modelos contínuos em escala

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

molecular, que podem ser utilizados para estudar o comportamento de materiais, proteínas e outros sistemas complexos em nível atômico. Os Modelos Contínuos também serão cada vez mais utilizados para otimizar e controlar sistemas dinâmicos complexos, como robôs, veículos autônomos e processos industriais.

Além disso, a combinação de Modelos Contínuos com técnicas de aprendizado de máquina permitirá a criação de sistemas híbridos que podem aprender e se adaptar a partir de dados, melhorando a precisão e a robustez das previsões.

Por fim, no campo dos Modelos Discretos, estes serão cada vez mais utilizados para simular sistemas complexos em larga escala, como cidades inteligentes, redes de energia e sistemas de transporte. Técnicas de análise de desempenho baseadas em modelos discretos serão aprimoradas para otimizar o design e a operação de sistemas complexos, como redes de comunicação e cadeias de suprimentos.

A combinação de Modelos Discretos com técnicas de IA distribuída permitirá a criação de sistemas autônomos e colaborativos que podem tomar decisões e resolver problemas de forma descentralizada.

Portanto, as tendências futuras dos quatro tipos de modelos de IA apontam para um aumento da complexidade, da capacidade de aprendizado e da aplicabilidade em diversas áreas.

A combinação de diferentes tipos de modelos, o uso de técnicas de aprendizado de máquina e a integração com outras tecnologias, como a Internet das Coisas (IoT) e a computação em nuvem, impulsionarão a próxima geração de sistemas inteligentes e autônomos.

FIAP

**PDF exclusivo para Francismar Alves Martins Júnior - rm562869**
**yggdrasil.git@gmail.com**

## 6 PILARES DOS ALGORITMOS BÁSICOS DE IA

Você já se perguntou como um GPS encontra o caminho mais rápido para o seu destino? Ou como um programa de xadrez consegue prever os movimentos do seu oponente? A resposta está nos algoritmos de IA básicos: busca, heurísticas e otimização.

Imagine que você está em um labirinto gigante semelhante a figura “Jardim em forma de labirinto, construído em Ribeauville, no leste da França”, com inúmeras bifurcações e caminhos sem saída. Como você encontraria a saída? Quais estratégias você usaria para tomar decisões inteligentes e evitar andar em círculos? Há quem diga que se você usar a lógica da sua mão direita, onde vai deslizando sua própria mão direita continuamente na parede da direita, e percorrendo os infinitos corredores do labirinto, uma hora você sairá dele.

Figura 4 - Jardim em forma de labirinto, construído em Ribeauville, no leste da França
Fonte: G1 (2007)

E se você fosse um detetive investigando um crime, como você encontraria as pistas mais relevantes e as combinaria para chegar à solução do caso?

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Essas situações, aparentemente distintas, possuem algo em comum: a necessidade de encontrar soluções em um espaço de possibilidades. E é aí que entram os algoritmos de IA básicos.

**Busca** é como explorar o labirinto, procurando sistematicamente pela saída, testando diferentes caminhos e aprendendo com os erros.

**Heurísticas** são como as pistas do detetive, regras práticas que ajudam a focar a busca nas direções mais promissoras, economizando tempo e recursos.

**Otimização** é como encontrar a melhor combinação de ingredientes para uma receita, testando diferentes proporções e avaliando o resultado final para chegar à receita perfeita.

Neste momento, vamos mergulhar no mundo dos algoritmos de IA básicos, explorando como eles funcionam, quais são seus tipos e como são aplicados em diversas áreas. Prepare-se para desvendar os segredos por trás da inteligência artificial e descobrir como ela pode ser utilizada para solucionar problemas complexos e tomar decisões inteligentes.

### 6.1 Detalhes dos Pilares

Já se sabe que uma IA se baseia em algoritmos que permitem aos sistemas tomar decisões, resolver problemas e aprender com dados. Mas, por trás disso, existem três pilares fundamentais da IA: os algoritmos de busca, heurísticas e otimização. Vamos explorar cada um deles em detalhes.

#### 6.1.1 Busca

A busca é o processo de encontrar soluções em um espaço de estados, que representa todas as configurações possíveis de um problema. Voltemos ao problema do labirinto: cada ponto no labirinto é um estado, e o objetivo é encontrar um caminho do estado inicial (entrada do labirinto) até o estado final (saída do labirinto). Algoritmos de busca, como busca em largura ou Breadth-First Search (BFS) e busca em profundidade ou Depth-First Search (DFS), exploram sistematicamente o espaço de estados para encontrar soluções. Vejamos melhor como isso funciona:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Busca em Largura (BFS): explora todos os estados vizinhos do estado atual antes de avançar para o próximo nível de vizinhos. É útil quando a solução está próxima do estado inicial. Por exemplo: encontrar o caminho mais curto em um mapa rodoviário. Você olha todas as cidades e formatos da rodovia em torno do ponto que você está até o ponto que precisa chegar. Nessa hora, você está fazendo o BFS.
- Busca em Profundidade (DFS): explora um caminho até o fim antes de voltar e explorar outros caminhos. É útil quando a solução está em um ramo profundo da árvore de busca. Por exemplo: resolver um quebra-cabeça de Sudoku, ou o Dr. Estranho analisando todas as possibilidades de cada futuro antes de começar a guerra com o Thanos, no filme *Vingadores: Guerra Infinita*, lembra dessa cena? Aquilo seria um DFS, pois ele observa cada futuro que envolve todos os Vingadores diante do desafio de vencer Thanos, mais especificamente, o Doutor Estranho calculou 14 milhões de cenários possíveis para os maiores heróis da Terra, e que em apenas um eles venceriam o Thanos. Quer dizer que o Dr. Estranho teria um cérebro de IA?

Vale ressaltar que há limitações na Busca. Em problemas complexos, o número de estados possíveis pode ser enorme, tornando a busca exaustiva e inviável. Por exemplo, considere que você tem vários caminhos para percorrer no mapa saindo do ponto A para o ponto B ao ponto de ficar impossível de decidir o caminho. Em muitas das vezes o Waze faz isso conosco (brincadeira, não é assim também) e o critério de decisão dele é de 1 minuto de economia de tempo, porém, te faz ir por um caminho que você não gosta.

Além disso, a busca pode consumir muitos recursos computacionais, especialmente em espaços de estados grandes.

### 6.1.2 Heurísticas

Heurísticas são regras práticas ou "atalhos" que ajudam a guiar a busca em direção a soluções promissoras, sem explorar todo o espaço de estados. Elas não garantem a solução ótima, mas podem encontrar soluções aproximadas de forma eficiente.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Por exemplo, em um jogo de xadrez, uma heurística pode avaliar a posição das peças no tabuleiro e atribuir uma pontuação a cada jogador, indicando quem está em vantagem. Essa heurística pode ser utilizada para guiar a busca por bons movimentos, sem analisar todas as jogadas possíveis.

É natural que haja limitações das Heurísticas, e nesse sentido, teremos as Soluções Subótimas, ou seja, soluções que não são as melhores possíveis, mas são boas o suficiente para o propósito. Além disso, esse pilar das Heurísticas pode ser específico para cada problema e pode não funcionar de forma adequada em outros contextos, isto é, cada problema tem a sua heurística, não podemos generalizar um método que atende todos os problemas da vida real.

### 6.1.3 Otimização

A otimização é o processo de encontrar a melhor solução dentre um conjunto de possibilidades. Isso envolve definir uma função objetivo (que mede a qualidade de uma solução) e encontrar os valores das variáveis que maximizam ou minimizam essa função. Algoritmos de otimização, como Algoritmos Genéticos (AGs) e colônia de formigas, são inspirados em processos naturais e buscam soluções eficientes em problemas complexos.

- **Algoritmos Genéticos:** inspirados na evolução biológica, esses algoritmos geram uma população de soluções candidatas, em seguida selecionam as melhores, as combinam (cruzamento) e introduzem pequenas variações (mutação) para gerar novas soluções. Por exemplo: otimizar o design de uma asa de avião.

  Assim como a natureza seleciona os indivíduos mais aptos para sobreviver e se reproduzir, os AGs buscam as melhores soluções para um problema através de um processo iterativo de seleção, cruzamento e mutação.

**Como eles funcionam?**

As soluções candidatas para o problema são codificadas como "cromossomos", que podem ser sequências de bits, números ou outras estruturas de dados. Uma

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

população inicial de cromossomos é gerada aleatoriamente ou a partir de soluções conhecidas. Cada cromossomo é avaliado de acordo com uma função de aptidão, que mede a qualidade da solução que ele representa. Os cromossomos mais aptos são selecionados para reprodução, com maior probabilidade de serem escolhidos os que possuem melhor aptidão.

Os cromossomos selecionados são combinados para gerar novos cromossomos (filhos), herdando características de seus pais. Além disso, pequenas alterações aleatórias são introduzidas nos cromossomos filhos, para aumentar a diversidade da população e explorar novas soluções. Os cromossomos filhos substituem os pais, formando uma nova geração de soluções candidatas. O processo se repete por várias gerações, com a população evoluindo em direção a soluções cada vez melhores.

**Como seriam as aplicações dos AGs?**

Os AGs estão sendo aplicados com sucesso em diversas áreas, como na otimização do design de produtos, por exemplo em antenas, asas de avião e circuitos eletrônicos. Na otimização do planejamento da produção em fábricas, minimizando custos e maximizando a eficiência. Além de otimizar os parâmetros de modelos de aprendizado de máquina, como redes neurais, e otimizar o alinhamento de sequências de DNA e a descoberta de novos medicamentos.

**Algumas Vantagens e Desvantagens das AGs**

As AGs são robustas a ruídos e incertezas nos dados. E podem ser aplicadas a uma ampla variedade de problemas de otimização, com diferentes tipos de soluções. Elas são naturalmente paralelizáveis (*multi thread*), o que permite acelerar o processo de otimização.

Contudo, os pontos de limitações mais frequentes estão no algoritmo AG que pode convergir para um ótimo local, ou seja, uma solução que é boa em relação às soluções vizinhas, mas não é a melhor solução global. Quanto aos parâmetros, o desempenho do algoritmo depende da escolha adequada dos parâmetros, como o tamanho da população, a taxa de cruzamento e a taxa de mutação. A qualidade da

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

solução encontrada depende da definição de uma função de aptidão que represente adequadamente o problema.

Os algoritmos genéticos são uma poderosa ferramenta de otimização inspirada na evolução natural. Sua capacidade de encontrar soluções eficientes em problemas complexos os torna uma escolha popular em diversas áreas da ciência e da engenharia. Apesar de suas limitações, os AGs continuam sendo uma área de pesquisa ativa, com novas técnicas e aplicações sendo desenvolvidas constantemente.

- **Colônia de Formigas**: inspirados no comportamento de formigas em busca de alimento, esses algoritmos utilizam “feromônios virtuais” para guiar a busca por soluções em um grafo. Vamos entender melhor esse conceito.

  A colônia de formigas é um algoritmo de otimização inspirado no comportamento coletivo das formigas em busca de alimento. Assim como as formigas deixam rastros de feromônio para indicar o caminho mais curto para a fonte de alimento, o algoritmo Ant Colony Optimization (ACO) utiliza "feromônios virtuais" para guiar a busca por soluções em um espaço de estados.

**Como ele funciona?**

Um conjunto de “formigas artificiais” é colocado em um grafo (nesse momento, entenda que um grafo é uma estrutura matemática que representa relações entre objetos e consiste em um conjunto de vértices — nós — conectados por arestas, ou seja, ligações) que representa o problema a ser resolvido. Cada formiga começa em um nó aleatório e percorre o grafo, escolhendo os próximos nós com base em uma combinação de dois fatores:

- Visibilidade: a atratividade de um caminho, que pode ser a distância entre os nós ou outra medida relevante para o problema.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Feromônio: a quantidade de feromônio virtual depositado em um caminho, indicando a frequência com que outras formigas já passaram por aquele caminho.
- Construção de soluções: cada formiga constrói uma solução completa para o problema, percorrendo o grafo e escolhendo os nós de acordo com a regra de transição mencionada acima.
- Atualização de feromônio: após todas as formigas construírem suas soluções, a quantidade de feromônio em cada caminho é atualizada. Os caminhos que levam a soluções melhores recebem mais feromônio, enquanto os caminhos menos promissores têm seu feromônio evaporado.
- Repetição: o processo se repete por várias iterações, com as formigas utilizando as informações de feromônio atualizadas para guiar suas buscas. Com o tempo, o feromônio se concentra nos caminhos mais promissores, levando a soluções cada vez melhores.

**Como seria uma aplicação do ACO?**

O algoritmo ACO tem sido aplicado com sucesso em diversos problemas de otimização, como por exemplo o Problema do Caixeiro Viajante ou Traveling Salesman Problem (TSP), que serve para encontrar o caminho mais curto que passa por todas as cidades e retorna à cidade de origem. Temos também o Roteamento de Veículos ou Vehicle Routing Problem (VRP) que serve para otimizar as rotas de veículos e minimizar o tempo de viagem e o custo de transporte. Uma terceira aplicação é atribuir tarefas para máquinas ou recursos de forma a minimizar o tempo total de execução, e uma quarta aplicação seria projetar redes de comunicação ou transporte para maximizar a eficiência e minimizar o custo.

**Algumas Vantagens e Desvantagens do ACO**

Sobre as vantagens, o algoritmo ACO é resistente a mudanças no ambiente e nos parâmetros do problema. Além de poder ser facilmente paralelizado, o que permite acelerar a busca por soluções em problemas complexos. E por fim, o algoritmo

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

se adapta às características do problema, ajustando a importância da visibilidade e do feromônio.

Em relação às desvantagens, em alguns casos, o algoritmo pode levar muitas iterações para convergir em uma boa solução. O desempenho do algoritmo depende da escolha adequada dos parâmetros, como a taxa de evaporação do feromônio e o número de formigas. O algoritmo pode ficar preso em ótimos locais, ou seja, soluções que são boas localmente, mas não globalmente.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 7 QUAIS SÃO OS PROBLEMAS QUE UMA IA PODE RESOLVER?

A IA oferece uma variedade de ferramentas e técnicas para resolver problemas complexos do mundo real. Nesta seção, exploraremos os três tipos fundamentais de problemas que a IA pode solucionar: classificação, regressão e clustering. Ao entender como a IA aborda esses desafios, você terá uma base sólida para aplicar esses conceitos em suas próprias aplicações.

## 7.1 Classificação: A Arte de Categorizar

Imagine um filtro de spam em sua caixa de entrada de e-mail. Ele analisa cada mensagem recebida e a classifica como "spam" ou "não spam". Essa é a essência da classificação em IA, isto é, atribuir categorias ou rótulos a dados.

Figura 5 - Filtro anti-spam do Gmail
Fonte: Dinamize (2015)

Ela funciona da seguinte forma: ela precisa de dados de treinamento. Algoritmos de classificação, como árvores de decisão, Naive Bayes e Support Vector Machines (SVM), aprendem com um conjunto de dados rotulados, onde cada exemplo possui uma categoria predefinida. Em outras palavras, um humano precisa classificar várias mensagens como “spam” e “não spam” para o algoritmo encontrar o padrão e, a partir disso, começar a fazer isso sozinho.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Então, o algoritmo identifica padrões e características relevantes nos dados que distinguem as diferentes categorias. Com base nos padrões aprendidos, o algoritmo classifica novos dados em uma das categorias predefinidas.

Vejamos alguns exemplos:

- Diagnóstico médico: classificar pacientes como saudáveis ou doentes com base em seus sintomas e exames.
- Reconhecimento de imagens: classificar imagens em diferentes categorias, como gatos, cachorros ou carros.
- Análise de sentimento: classificar textos como positivos, negativos ou neutros com base no seu conteúdo emocional.

Considerando o que você aprendeu até aqui, a classificação pode ser vista como uma busca pela categoria mais provável para um novo dado, explorando o espaço de características aprendidas pelo modelo. Algoritmos de classificação podem utilizar heurísticas para tomar decisões rápidas e eficientes, como regras de decisão simples ou medidas de distância entre dados. O treinamento de modelos de classificação envolve otimizar seus parâmetros para minimizar o erro de classificação.

### 7.2 Regressão: Previsão dos Valores Numéricos

Suponha que você queira prever o preço de um imóvel com base em suas características, como tamanho, número de quartos e localização. A regressão é a ferramenta ideal para essa tarefa: prever valores numéricos contínuos a partir de dados de entrada.

A regressão funciona da seguinte forma: seja uma regressão linear ou regressão polinomial, ela aprende com um conjunto de dados onde cada exemplo possui um valor numérico associado. Você estudará isso com mais detalhes na disciplina de Machine Learning nas próximas fases. O algoritmo encontra uma função matemática que descreve a relação entre as variáveis de entrada e a variável de saída (o valor a ser previsto). Com base na função aprendida, o algoritmo prevê o valor numérico para novos dados de entrada.

Vejamos alguns exemplos:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Previsão de vendas: prever o volume de vendas de um produto com base em fatores como preço, publicidade e sazonalidade.
- Previsão do tempo: prever a temperatura, a precipitação e outras variáveis meteorológicas com base em dados históricos e modelos climáticos.
- Previsão de demanda de energia: prever a demanda de energia elétrica com base em fatores como temperatura, hora do dia e dia da semana.

E mais uma vez, considerando o que você já aprendeu até agora neste capítulo, o treinamento de modelos de regressão envolve **otimizar** seus parâmetros para minimizar o erro de previsão. A regressão linear é um exemplo de **Modelo Determinístico**, onde o resultado é completamente determinado pelas entradas e pelos parâmetros do modelo.

### 7.3 Clustering: Agrupando Dados Semelhantes

Imagine que você tem um conjunto de dados sobre clientes, com informações como idade, renda e hábitos de compra. Você deseja agrupar esses clientes em segmentos com características semelhantes para direcionar suas campanhas de marketing. O clustering é a técnica ideal para essa tarefa, pois permite agrupar dados em grupos (clusters) com base em sua similaridade. A figura “Processo de clustering” exemplifica esse processo.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

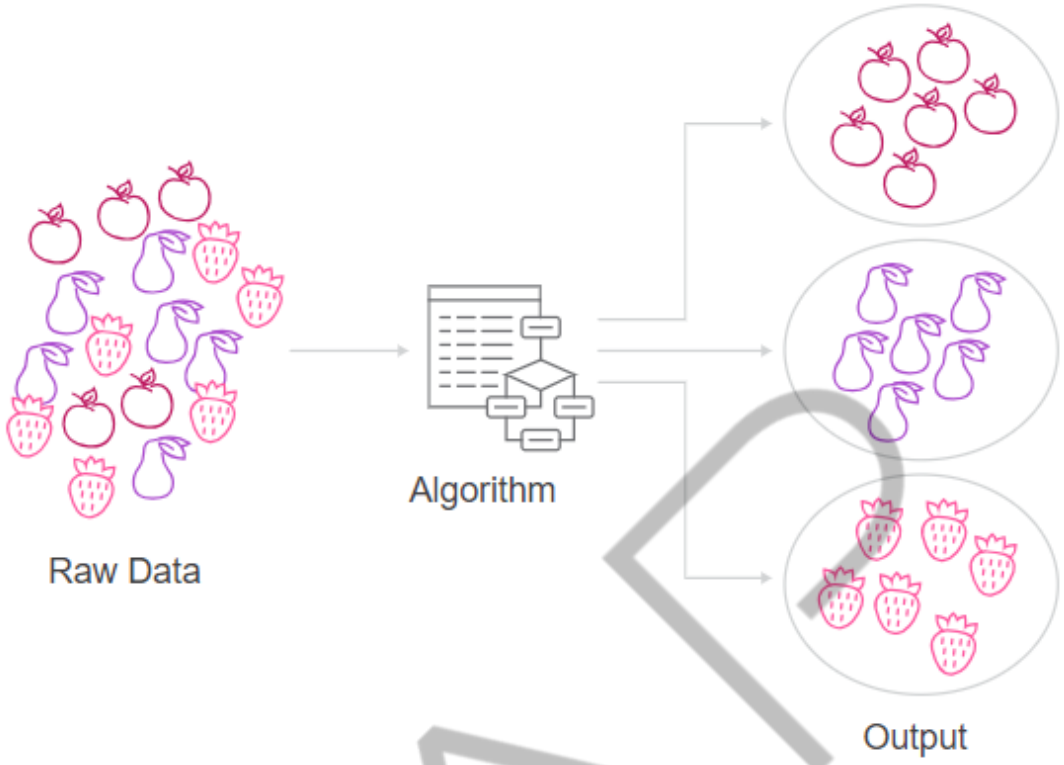


Figura 6 - Processo de clustering
Fonte: Blog Data Camp (2024)

Seu funcionamento ocorre da seguinte forma: os algoritmos de clustering, como k-means e clustering hierárquico, trabalham com dados não rotulados, ou seja, sem categorias predefinidas. Em outras palavras, não houve um humano pré-categorizando cada dado de forma direta, como você separa o lixo orgânico e não orgânico da sua casa. Na verdade, o algoritmo define uma medida de similaridade entre os dados, como a distância euclidiana ou a correlação. Então, o algoritmo agrupa os dados em clusters de forma que os dados dentro de um cluster sejam mais semelhantes entre si do que com dados de outros clusters. E assim é realizada a classificação por uma máquina. Entretanto, quase nunca essa classificação obtém 100% de sucesso, tenha isso em mente!

Alguns exemplos:

- Segmentação de clientes: agrupar clientes em segmentos com base em seus perfis de compra.
- Análise de redes sociais: identificar comunidades de usuários com base em seus interesses e interações.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Bioinformática: agrupar genes com base em sua expressão em diferentes condições experimentais.

O clustering é um exemplo de aprendizado de máquina **não supervisionado**, onde o algoritmo descobre padrões nos dados sem a necessidade de rótulos. Esses algoritmos de clustering podem utilizar **heurísticas** para definir o número ideal de clusters ou para escolher a melhor medida de similaridade.

Classificação, regressão e clustering são os três pilares da inteligência artificial, cada um com suas próprias aplicações e desafios. Ao dominar esses conceitos, você estará preparado para aplicar a IA em diversas áreas e resolver problemas complexos do mundo real.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 8 REPRESENTAÇÃO DO CONHECIMENTO: A LINGUAGEM DA IA

Considere que você quer ensinar um computador a entender o mundo ao seu redor. Como você faria isso? Como você representaria o conhecimento para que a máquina possa compreendê-lo e raciocinar sobre ele? A representação do conhecimento é um campo fundamental da IA que busca responder a essas perguntas, fornecendo as ferramentas para que os sistemas inteligentes possam armazenar, manipular e utilizar informações sobre o mundo.

## 8.1 Lógica Proposicional

A lógica proposicional (que pertence a um propósito) é o alicerce da representação do conhecimento em IA. Ela permite representar fatos e relações simples entre eles, utilizando proposições (afirmações que podem ser verdadeiras ou falsas) e conectivos lógicos (e, ou, não, se… então… coisas do Python e R, certo?). Por exemplo, a frase "Se chover, então a rua ficará molhada" pode ser representada em lógica proposicional como:

$$\text{Chover} \rightarrow \text{RuaMolhada}$$

Essa representação permite ao sistema inferir que, se a proposição "Chover" for verdadeira, então a proposição "RuaMolhada" também será verdadeira. Parece muito simples e óbvio, e é mesmo. Mas sem essa base, não existiria a IA.

Desde o momento em que você acorda até o momento de dormir, você aplica a Lógica Proposicional. Observe:

- As proposições, tecnicamente, são os blocos básicos de construção da lógica proposicional. Exemplos: "Está chovendo", "O gato está na caixa", "2 + 2 = 4".
- Conectivos Lógicos são os operadores que conectam proposições, como "e" (conjunção), "ou" (disjunção), "não" (negação), "se… então…" (implicação) e "… se e somente se …" (equivalência).
- Tabelas da Verdade são ferramentas para analisar o valor de verdade de expressões lógicas complexas, mostrando todas as combinações possíveis

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

de valores de verdade para as proposições envolvidas. Nos capítulos iniciais de Python explica-se isso.

Exemplos:

- Sistemas especialistas utilizam a lógica proposicional para representar o conhecimento de especialistas em um determinado domínio, como medicina ou finanças, e inferir diagnósticos ou recomendações.
- Jogos de lógica tem como base a lógica proposicional em diversos jogos de lógica, como Sudoku e quebra-cabeças lógicos, onde o objetivo é deduzir informações a partir de um conjunto de regras e fatos.
- Raciocínio automatizado permite que sistemas de IA deduzam novas informações a partir de fatos conhecidos, utilizando regras lógicas.
- Verificação formal é utilizada para verificar a correção de programas de computador e sistemas de hardware, garantindo que eles atendam às especificações desejadas. Neste último, estamos falando dos compiladores de software e giga de testes.

É bom verificar as limitações. Nem tudo são flores na área de TI. A Lógica Proposicional não permite representar informações sobre objetos individuais ou quantidades, limitando sua capacidade de representar o conhecimento do mundo real. Além disso, uma vez que uma proposição é considerada verdadeira, ela permanece verdadeira, mesmo que novas informações sejam adicionadas. Isso pode levar a inconsistências em situações onde o conhecimento muda ao longo do tempo.

## 8.2 Lógica de Primeira Ordem (LPO)

Outra forma de representar o conhecimento é pela Lógica de Primeira Ordem, que é uma extensão e uma superação da Lógica Proposicional, e que permite representar objetos, suas propriedades e as relações entre eles. Ela utiliza quantificadores ou símbolos matemáticos (todos, existe) para expressar afirmações sobre conjuntos de objetos (assunto de Ensino Médio). Por exemplo, a frase "Todos os humanos são mortais" pode ser representada em lógica de primeira ordem como:

$$\forall x\ (\text{Humanos}(x) \rightarrow \text{Mortal}(x))$$

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Essa representação permite ao sistema inferir que, se um objeto for um humano, então ele também será mortal.

A LPO utiliza:

- Constantes, que representam objetos específicos, como "João" ou "Brasil".
- Variáveis, que representam objetos genéricos, como "x" ou "y".
- Predicados, que representam propriedades de objetos ou relações entre objetos, como "É_Humano(x)" ou "É_Maior_Que(x, y)".
- Quantificadores, que são símbolos, por exemplo, "Para todo" (∀) e "Existe" (∃) permitem expressar afirmações sobre conjuntos de objetos. Agora faz mais sentido essa expressão?

$$\forall x\ (\text{Humanos}(x) \rightarrow \text{Mortal}(x))$$

Observe algumas aplicações do dia a dia:

- Processamento de Linguagem Natural, onde a LPO é utilizada para representar o significado de frases e textos, permitindo a análise semântica e a inferência de informações.
- Bancos de Dados, onde a lógica de primeira ordem é a base da linguagem SQL, utilizada para consultar e manipular dados em bancos de dados relacionais. Você vai aprender SQL nas fases seguintes, fique ligado!
- Planejamento Automatizado, que permite aos sistemas de IA planejarem ações para alcançar objetivos, levando em consideração as restrições do ambiente e as relações entre os objetos.

As limitações também estão nessa forma de representação. Nem todas as fórmulas da LPO podem ser provadas ou refutadas automaticamente, o que limita a capacidade de raciocínio automático em alguns casos. A inferência em LPO pode ser computacionalmente cara, especialmente para fórmulas complexas e grandes conjuntos de dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

### 8.3 Redes Semânticas

Outro exemplo são as Redes Semânticas, que são grafos que representam o conhecimento em termos de conceitos (nós) e relações (arestas) entre eles. Cada nó representa um conceito, como "gato", "animal" ou "miado", e cada aresta representa uma relação entre dois conceitos, como "é um" (gato é um animal) ou "faz" (gato faz miado). Elas permitem representar informações de forma estruturada e flexível, facilitando a inferência de novas informações e a descoberta de padrões.

Exemplos:

- Motores de busca: eles utilizam redes semânticas para entender o significado das consultas dos usuários e fornecer resultados mais relevantes (exemplos: Google e Bing).
- Chatbots: eles utilizam redes semânticas para representar o conhecimento sobre um determinado domínio e responder às perguntas dos usuários de forma mais natural e precisa (exemplos: ChatGPT e Gemini).
- Sistemas de recomendação: que utilizam redes semânticas para representar os gostos e preferências dos usuários e recomendar produtos, filmes ou músicas que possam ser do seu interesse (exemplos: sites de compras, Netflix, Spotify etc.).

Quanto às suas limitações, a construção de Redes Semânticas geralmente requer um esforço manual significativo para definir conceitos, relações e regras de inferência. Experimente buscar notícias e especulações na Internet sobre como foi treinar a primeira versão do ChatGPT. A linguagem natural é inerentemente ambígua, podendo dificultar a representação precisa do conhecimento em redes semânticas.

Portanto, a representação do conhecimento é um campo fundamental da IA e permite aos sistemas inteligentes armazenar, manipular e utilizar informações sobre o mundo. A **lógica proposicional**, a **lógica de primeira ordem** e as **redes semânticas** são algumas das principais ferramentas utilizadas para representar o conhecimento em IA, e cada uma possui suas próprias vantagens e aplicações. Ao dominar esses conceitos, você estará preparado para construir sistemas de IA mais inteligentes e capazes de interagir com o mundo de forma mais natural e eficaz.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# 9 APRENDIZADO DE MÁQUINA

Agora que você chegou até aqui, vamos esclarecer alguns pontos. A Inteligência Artificial (IA) é um termo que frequentemente é utilizado de forma errada. Inclusive, nesse capítulo deveríamos retornar e mudar a sigla IA para ML (Machine Learning).

## 9.1 Diferença de IA para ML

Em sua essência, a IA busca criar sistemas capazes de assemelhar ou até superar as tarefas que exigem inteligência humana, como reconhecimento de padrões, tomada de decisões, aprendizado e adaptação. A IA, em sua definição básica, é um cérebro humano em forma de algoritmos que abrange uma ampla gama de técnicas e abordagens, desde sistemas baseados em regras até redes neurais complexas. Porém, se até o momento não desvendamos todos os mistérios do cérebro humano, como podemos copiar um? E a consciência? Como codificá-la e colocar um processador para sentir o que exatamente sentimos? Ainda não temos respostas para isso.

O aprendizado de máquina é um subcampo da IA, e se concentra em algoritmos que permitem aos sistemas aprender e melhorar seu desempenho em uma tarefa específica a partir de dados, sem serem explicitamente programados. Ao invés de seguir instruções rígidas, os algoritmos de ML analisam dados, identificam padrões e tomam decisões ou fazem previsões com base nesses padrões.

É importante ressaltar que nem todo algoritmo é considerado IA. Algoritmos tradicionais, como algoritmos de ordenação ou busca, são projetados para executar tarefas específicas de forma determinística, seguindo instruções predefinidas. Já os algoritmos puramente de IA, seriam (ainda não são, porque estamos no campo da teoria) projetados para aprender e se adaptar a partir de dados, o que os torna mais flexíveis e capazes de lidar com situações complexas e imprevisíveis, e até com consciência.

Contudo, o mercado de trabalho prefere dar um “banho de loja” em suas soluções, em especial, as principais BigTechs, como Google, Meta, OpenIA, Apple,

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

etc., nomeando quase tudo que se tem de serviço na Internet, de IA. Contudo, não seria correto.

Até o momento, e de forma comercial e acessível para os meros mortais, o que existe são ML bem desenvolvidas. O dia que existir um robô na rua se lamentando e ajudando um andarilho passando fome, então provavelmente teremos que mudar esse texto para IA.

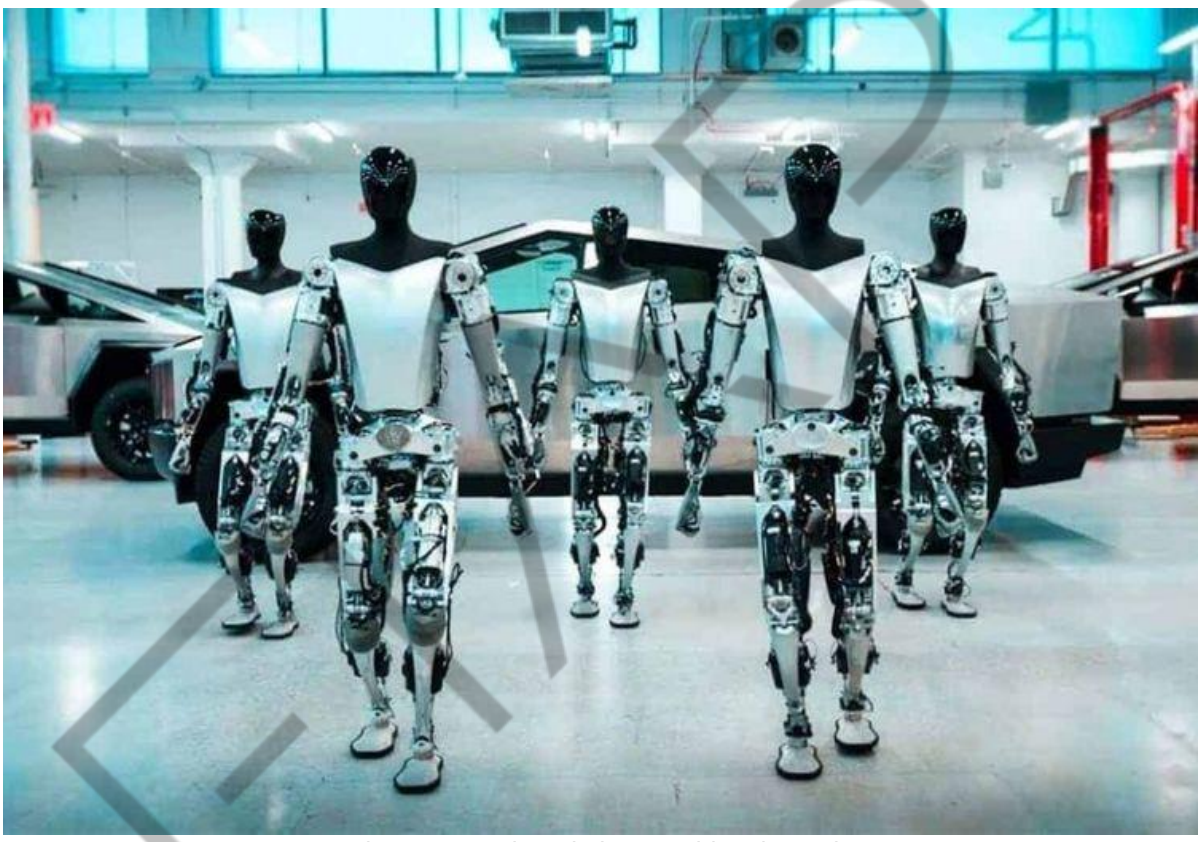

Figura 7 - Projeto de humanoides da Tesla
Fonte: Olhar Digital (2023)

## 9.2 Exemplos de Aplicações de IA e ML Comerciais

- Reconhecimento de voz: sistemas como a Siri e a Alexa utilizam aprendizado de máquina para entender a linguagem humana e responder a comandos de voz.
- Recomendação de produtos: plataformas como a Amazon e a Netflix utilizam ML para analisar o comportamento dos usuários e recomendar produtos e filmes relevantes.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Carros autônomos: veículos autônomos utilizam IA (mas na verdade ainda são ML avançadas) para processar informações de sensores, tomar decisões de direção e navegar em ambientes complexos.
- Diagnóstico médico: algoritmos de ML podem analisar imagens médicas e dados de pacientes para auxiliar no diagnóstico de doenças.
- A arquitetura de rede neural transformer, como a que o Gemini e ChatGPT utilizam, se encaixa no contexto de modelagem e algoritmos de IA da seguinte forma:
    - **Modelagem:** a rede neural transformer é um tipo de modelo de aprendizado de máquina, ou seja, ela representa uma forma de aprender padrões e relações a partir de dados. Já o modelo do GPT e Gemini aprendem a relação entre palavras e frases para gerar textos coerentes e relevantes.
    - **Algoritmos de IA:** a **rede neural transformer** utiliza algoritmos de aprendizado supervisionado para treinar o modelo a partir de um grande conjunto de dados de texto. Durante o treinamento, o modelo aprende a prever a próxima palavra em uma sequência, com base nas palavras anteriores. Esse processo de aprendizado envolve a otimização dos parâmetros do modelo para minimizar o erro de previsão.
    - **Busca e Otimização:** embora a rede neural transformer não utilize algoritmos de busca tradicionais, como BFS ou DFS, ela realiza uma forma de busca implícita durante o processo de geração de texto. Ao gerar cada palavra, o modelo busca a palavra mais provável de seguir, com base no contexto anterior. Esse processo pode ser visto como uma busca em um espaço de palavras, onde o modelo busca a palavra que melhor se encaixa na sequência. Além disso, o treinamento da rede neural envolve a otimização dos parâmetros do modelo para maximizar sua capacidade de gerar textos de alta qualidade.
    - **Heurísticas:** as redes neurais transformer podem ser consideradas como um tipo de heurística, pois elas aprendem a partir de dados a tomar decisões sobre quais palavras são mais prováveis em um determinado

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

contexto. Essa heurística é baseada em padrões estatísticos e relações semânticas aprendidas a partir de um grande *corpus* de texto.

## 9.3 Detalhes de uma ML

Já que estamos ainda no universo da ML e não tecnicamente da IA, não vamos desmerecer e nem esquecer que uma ML possui muitas capacidades que um único humano levaria anos para adquirir, como a previsão do tempo, contagem de ervas daninhas em um talhão da lavoura, separação de grãos estragados numa colheita de milho ou café, etc. Essas tarefas repetitivas são ótimas para as MLs.

Pense em um programa de computador que melhora seu desempenho em uma tarefa à medida que ganha experiência. Ele não precisa ser explicitamente instruído sobre como realizar a tarefa, mas aprende a partir de exemplos e feedbacks. Essa é a essência da ML, um ramo da IA que revolucionou a forma como interagimos com a tecnologia.

No aprendizado de máquina, os algoritmos são projetados para aprender com dados, em vez de seguir instruções pré-programadas. Eles identificam padrões nos dados, fazem previsões e tomam decisões com base nesses padrões. Essa capacidade de aprendizado permite que os sistemas de IA se adaptem a novas situações e melhorem seu desempenho ao longo do tempo.

## 9.4 Tipos de Aprendizado

Basicamente, existem três principais tipos de aprendizado de máquina que vamos explicar, mas fique tranquilo pois novos capítulos virão para aprofundar ainda mais, inclusive o algoritmo utilizado. Se prepare!

O Aprendizado Supervisionado é quando o algoritmo aprende a partir de um conjunto de dados rotulados como ilustrado na figura “Machine Learning aprendendo como selecionar uma maçã”, onde cada exemplo possui uma resposta correta. O objetivo é construir um modelo que possa prever a resposta correta para novos exemplos. Podemos citar como exemplo um modelo que aprende a classificar e-mails como spam ou não spam com base em exemplos de e-mails rotulados ou uma criança

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

jogando o jogo da memória com figuras de animais, onde cada carta tem a figura do animal e o nome abaixo.

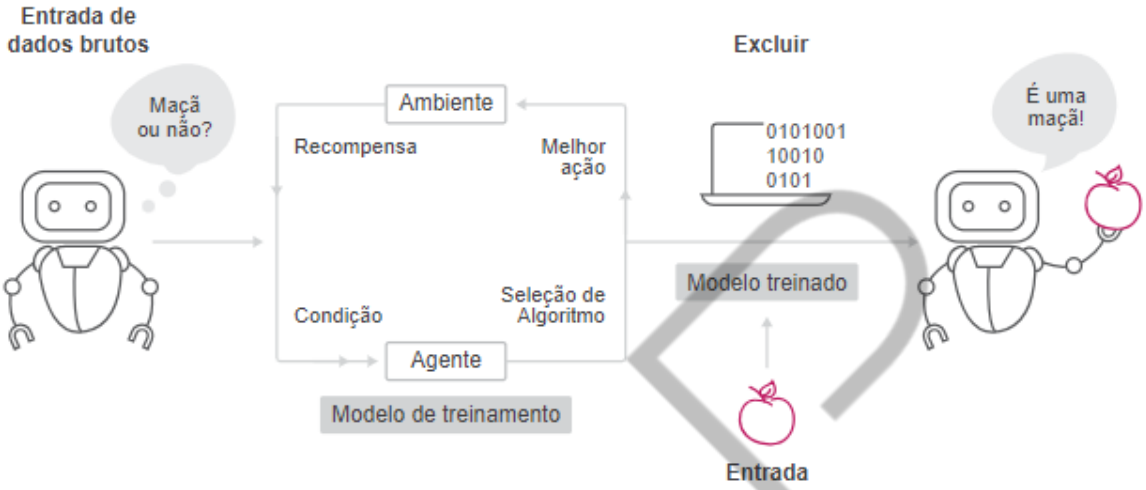


Figura 8 - Machine Learning aprendendo como selecionar uma maçã
Fonte: Solvimm (2018)

O Aprendizado Não Supervisionado é quando o algoritmo aprende a partir de um conjunto de dados não rotulados, sem respostas corretas. O objetivo é descobrir padrões e estruturas nos dados, como grupos de exemplos semelhantes. Podemos citar como exemplo um modelo que agrupa clientes com base em seus hábitos de compras para segmentar o mercado, ou uma criança de 2 anos que aprende que cachorro sempre tem 4 patas, um focinho e um rabinho, e quando ela encontra um porco, ela o chama de “auau”. Ela estaria correta? Em partes sim, pois ela identificou alguns padrões comuns entre o cachorro e o porco. Mas o resultado estaria errado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

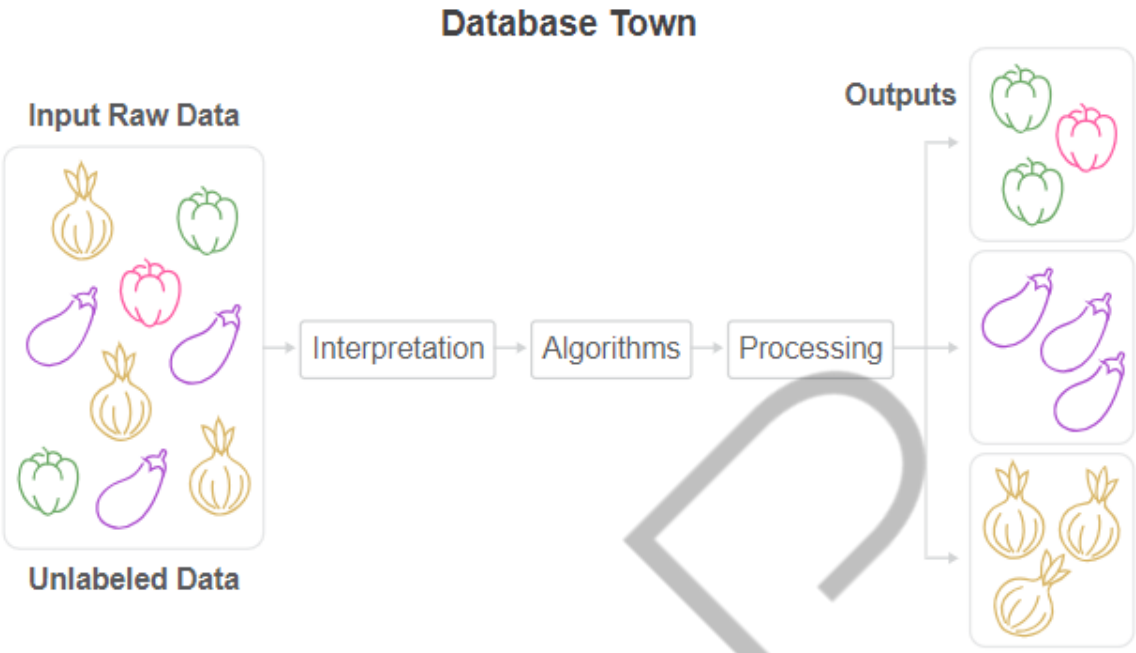


Figura 9 - Aprendizado Não Supervisionado: o algoritmo procura padrões e semelhanças e tenta agrupar os iguais, mas nem sempre acerta, como é o caso do pepino verde e vermelho juntos
Fonte: Database Town (2023)

Aprendizado por Reforço é quando o algoritmo aprende a tomar decisões em um ambiente interativo, recebendo feedback na forma de recompensas ou punições, como ilustrado na figura “Aprendizado por reforço: a máquina memoriza sua própria pontuação quando sabe que bateu a própria meta”. O objetivo é maximizar a recompensa total ao longo do tempo. Um exemplo seria um modelo que aprende a jogar um jogo de videogame, recebendo pontos por ações bem-sucedidas e perdendo pontos por ações mal sucedidas. Ou um robô varredor de chão, que memoriza um ponto (+1) em sua memória todas as vezes que reduz o tempo de limpeza da sala sem deixar nenhum canto da sala sujo. Nesse caso, ele deve ter a metragem da sala em sua memória e a contagem dos metros é feita pelo número de voltas que a rodinha dá, ao terminar a faxina o aplicativo do robô pergunta no celular do dono se a limpeza está ok ou não a cada dia que executa a tarefa.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

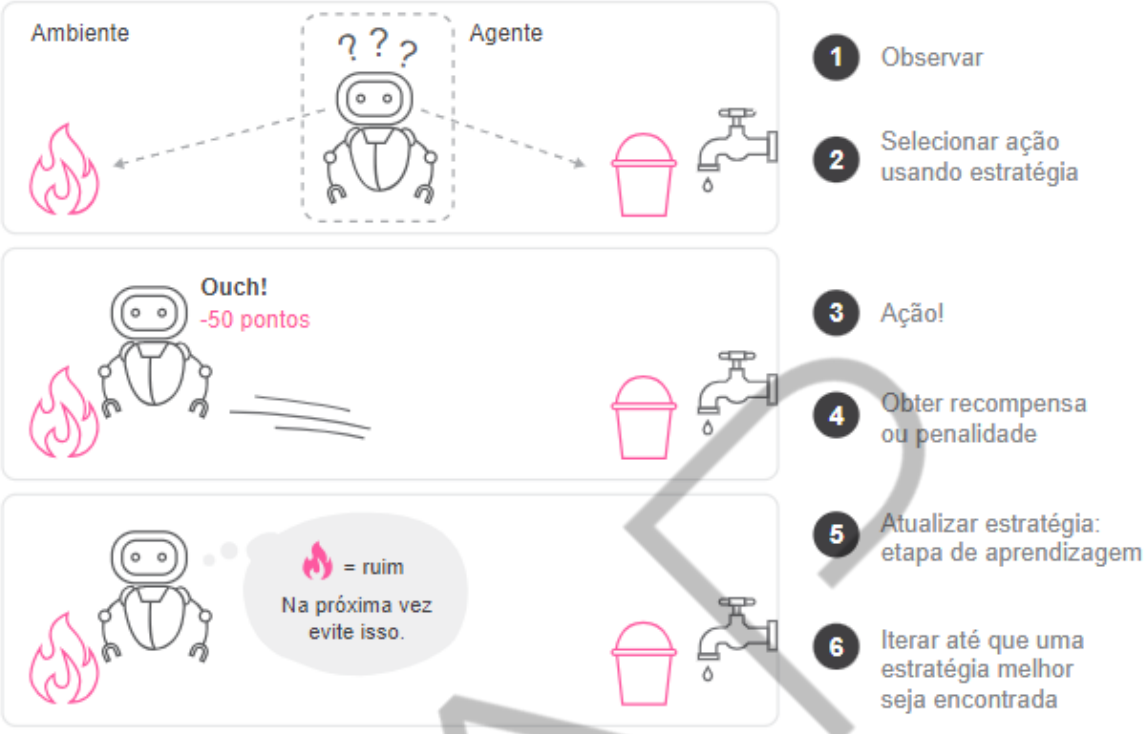


Figura 10 - Aprendizado por reforço: a máquina memoriza sua própria pontuação quando sabe que bateu a própria meta
Fonte: Data Science (2020), adaptada por FIAP (2024)

## 9.5 Exemplos de Algoritmos

Aqui estão alguns principais exemplos de algoritmos que vamos abordar nesse curso, em especial na disciplina de Machine Learning e Redes Neurais.

- Regressão Linear: é um algoritmo simples e eficiente para prever valores numéricos contínuos, como o preço de um imóvel ou a demanda de um produto.
- Árvores de Decisão: é um algoritmo que divide o espaço de dados em regiões menores e atribui uma previsão a cada região. É útil para problemas de classificação e regressão.
- Redes Neurais: são algoritmos inspirados no funcionamento do cérebro humano, capazes de aprender padrões complexos em dados e realizar tarefas como reconhecimento de imagem e tradução de idiomas.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Support Vector Machines (SVM): é um algoritmo poderoso para classificação e regressão, que busca encontrar o melhor hiperplano que separa os dados em diferentes classes.
- K-means: é um algoritmo de clustering que agrupa dados em *k* grupos, com base na distância entre os pontos de dados.

### 9.6 Limitações do Aprendizado de Máquina

Os modelos de aprendizado de máquina podem ser influenciados por vieses presentes nos dados de treinamento, levando a resultados discriminatórios ou injustos. No primeiro capítulo desta disciplina, você aprendeu as consequências sociais que ocorrem quando uma base de dados possui esses vieses, como por exemplo, só ter imagens de pessoas briguentas usando sempre a mesma camisa de algum time de futebol. Para o algoritmo, a pessoa que torce para aquele time sempre será briguenta na rua.

Overfitting é um termo técnico muito utilizado na modelagem de ML. O modelo pode se ajustar muito bem aos dados de treinamento, mas ter um desempenho ruim ao se relacionar com novos dados devido à memorização de padrões específicos em vez de generalização. O caso mencionado da “pessoa briguenta” se encaixa aqui.

Interpretabilidade também é outro termo técnico, onde alguns modelos, como redes neurais profundas, podem ser difíceis de interpretar, tornando difícil entender as razões por trás de suas decisões. Em outras palavras, é difícil responder a pergunta: “Como foi que a ML chegou nesse resultado?”.

Dados de Qualidade é outro fator altamente limitante dos sistemas. A qualidade dos dados de treinamento é crucial para o desempenho do modelo. Dados ruidosos, incompletos ou inconsistentes podem ocasionar resultados imprecisos.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

## CONCLUSÃO

O aprendizado de máquina é uma ferramenta poderosa para extrair conhecimento e *insights* de dados, permitindo a criação de sistemas inteligentes que podem aprender e se adaptar a novas situações. Ao compreender os diferentes tipos de aprendizado, os algoritmos disponíveis e suas limitações, você estará preparado para aplicar o aprendizado de máquina em seus próprios projetos e contribuir para o avanço da inteligência artificial.

Ao longo deste capítulo, exploramos os conceitos fundamentais da modelagem e simulação em IA, ferramentas essenciais para representar, analisar e prever o comportamento de sistemas complexos. Começamos com os princípios básicos de modelagem e simulação, entendendo como criar representações abstratas e simplificadas do mundo real e como executá-las para obter informações valiosas.

Em seguida, mergulhamos nos diferentes tipos de modelos, desde os determinísticos, que oferecem previsibilidade e repetibilidade, até os estocásticos, que incorporam a aleatoriedade e a incerteza inerentes a muitos fenômenos. Exploramos também os modelos contínuos, que descrevem a evolução suave das variáveis ao longo do tempo, e os modelos discretos, que se concentram em eventos instantâneos e mudanças abruptas.

Abordamos as principais ferramentas de modelagem, como equações diferenciais, autômatos celulares e redes neurais, cada uma com suas próprias vantagens e aplicações. Além disso, discutimos a importância da validação e calibração dos modelos para garantir que eles representem adequadamente a realidade e produzam resultados confiáveis.

Examinamos exemplos práticos de modelagem e simulação em diversas áreas, como economia, biologia, engenharia e saúde, demonstrando a versatilidade e o poder dessas ferramentas para resolver problemas complexos e tomar decisões informadas.

Por fim, discutimos os principais algoritmos de IA, como busca, heurísticas e otimização, que são utilizados para encontrar soluções eficientes em espaços de estados complexos. A busca nos permite explorar sistematicamente as possibilidades,

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

as heurísticas nos guiam em direção a soluções promissoras e a otimização nos ajuda a encontrar a melhor solução possível.

Com este capítulo, você adquiriu uma base sólida para entender e aplicar os conceitos de modelagem e simulação em seus próprios projetos de IA. Ao dominar essas ferramentas, você estará preparado para enfrentar os desafios do mundo real e criar soluções inovadoras que podem transformar a sociedade.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

# REFERÊNCIAS


ALL, Moez. Agrupamento no aprendizado de máquina: 5 Algoritmos de agrupamento essenciais. **Blog Data Camp**. Abr. 2024. Disponível em: https://www.datacamp.com/pt/blog/clustering-in-machine-learning-5-essential-clustering-algorithms. Acesso em: 25 jun. 2024.

AMAZON. **Dreametech Robô aspirador de pó**. 2022. Disponível em: https://www.amazon.com.br/Dreametech-D10-Plus-autolimpante-compat%C3%ADvel/dp/B09VKZT1FQ. Acesso em: 25 jun. 2024.

BISHOP, Christopher M. **Pattern recognition and machine learning**. Springer [Google Scholar], v. 2, p. 1122-1128, 2006.

DATABASE TOWN. **Unsupervised Learning: Types, Applications & Advantages**. 2023. Disponível em: https://databasetown.com/unsupervised-learning-types-applications/. Acesso em: 25 jun. 2024.

DATA SCIENCE. **Introdução ao aprendizado de máquinas para iniciantes**. 02 maio 2020. Disponível em: https://datascience.eu/pt/aprendizado-de-maquina/introducao-ao-aprendizado-de-maquinas-para-iniciantes/. Acesso em: 25 jun. 2024.

DINAMIZE. **Filtro do spam do Gmail: Veja como ele funciona**. 2015. Disponível em: https://www.dinamize.com.br/wp-content/uploads/2015/09/blog.fw-min.png. Acesso em: 25 jun. 2024.

G1. **França faz labirinto gigante de árvores**. 09 jul. 2007. Disponível em: https://g1.globo.com/Noticias/PlanetaBizarro/0,,MUL66585-6091,00-FRANCA+FAZ+LABIRINTO+GIGANTE+DE+ARVORES.html. Acesso em: 25 jun. 2024.

KOZA, John R. **Genetic programming: on the programming of computers by means of natural selection**. Cambridge. MA: MIT Press. [Google Scholar], 1992.

LORENZO, Di Alessandro. Robô humanoide da Tesla chega às lojas dos EUA. **Olhar Digital**. 11 jul. 2023. Disponível em: https://olhardigital.com.br/2023/07/11/pro/robo-humanoide-da-tesla-chega-as-lojas-dos-eua/. Acesso em: 25 jun. 2024.

LUZ, Erick. Jogo de Tabuleiro: O que é? Exemplos e história. **Clube Nerd Jogos de Tabuleiro**. 7 nov. 2023. Disponível em: https://www.clubenerd.com/o-que-e-jogo-de-tabuleiro/. Acesso em: 25 jun. 2024.

OLIVEIRA, Raul Rodrigues de. Combinação com repetição. 2021. **Mundo Educação**. Disponível em: https://mundoeducacao.uol.com.br/matematica/combinacao-com-repeticao.htm. Acesso em: 25 jun. 2024.

RUSSELL, Stuart J.; NORVIG, Peter. **Artificial intelligence: a modern approach**. Pearson, 2016.


**PDF exclusivo para Francismar Alves Martins Júnior - rm562869**
**yggdrasil.git@gmail.com**

SUTTON, Richard S.; BARTO, Andrew G. **Reinforcement learning: An introduction**. MIT press, 2018.

SOLVIMM. **O que é Machine Learning**. Blog. 6 set. 2018. Disponível em: https://solvimm.com/blog/o-que-e-machine-learning/. Acesso em: 25 jun. 2024.

TAN, Seng Chee; LEE, Alwyn Vwen Yen; LEE, Min. A systematic review of artificial intelligence techniques for collaborative learning over the past two decades. **Computers and Education**: Artificial Intelligence, v. 3, p. 100097, 2022.

FIAP

**PDF exclusivo para Francismar Alves Martins Júnior - rm562869**
**yggdrasil.git@gmail.com**