FIAP ON

CAMPO DA INOVAÇÃO - UMA PLANTAÇÃO DE CÓDIGOS

DECOLANDO COM CIÊNCIAS DE DADOS

7

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Curva de Distribuição Normal 11

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 DECOLANDO COM CIÊNCIAS DE DADOS 4
1.1 Definição e Fundamentos da Estatística 5
1.2 Análise Descritiva de Dados com R 7
1.3 Análise Inferencial de Dados com R 10
1.4 Visualização dos Dados 12
1.5 Estudo de Caso 1: Análise do Desempenho de Modelos de IA do tipo PLN (Processamento de Linguagem Natural) 14
1.6 Estudo de Caso 2: Inferência sobre a precisão média de modelos preditivos 15
REFERÊNCIAS 17

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 DECOLANDO COM CIÊNCIAS DE DADOS

A Estatística é uma disciplina que historicamente evoluiu do desejo de compreender e interpretar dados. Atualmente pode ser considerada uma pedra angular na era da tecnologia. Esta ciência, que se dedica à coleta, análise, interpretação e apresentação de dados, desempenha um papel crítico em praticamente todos os aspectos do mundo moderno, principalmente no setor tecnológico. A relevância da Estatística na tecnologia não se limita a um único domínio, pois permeia diversas áreas, desde a Ciência de Dados até a Inteligência Artificial (IA), do Desenvolvimento de Software à Análise de Redes.

No campo da tecnologia, a Estatística é vital para a Ciência de Dados, uma disciplina que se concentra na extração de *insights* de grandes volumes de dados. Como explicam Gelman e Hill (2006), a análise Estatística é crucial para identificar padrões, fazer previsões e informar decisões em um mundo cada vez mais orientado por dados. Esta relevância é exemplificada na maneira como as empresas usam a análise Estatística para entender o comportamento do consumidor, otimizar operações e prever tendências de mercado.

Na inteligência artificial e no Aprendizado de Máquina (ML), a Estatística manifesta-se de maneira ainda mais robusta. Algoritmos de ML, conforme explicado por Hastie *et al*. (2009), são essencialmente métodos estatísticos que aprendem padrões de dados e fazem previsões. Por exemplo, a Estatística é utilizada no treinamento de modelos de IA para reconhecimento facial, onde grandes conjuntos de dados são analisados para identificar características faciais comuns e distintas. Já no desenvolvimento de software, a Estatística ajuda a otimizar processos e a melhorar a eficiência dos sistemas. A análise Estatística de bugs e falhas em softwares, por exemplo, pode levar a melhorias significativas na qualidade do produto final sendo fundamental um cenário onde softwares desempenham papéis críticos em quase todos os setores, desde saúde até finanças. Além disso, na análise de redes, especialmente em áreas como segurança cibernética e gerenciamento de tráfego de internet, a Estatística é fundamental. Conforme descrito por Morettin e Singer (2022), a análise Estatística de padrões de tráfego pode ajudar a identificar anomalias, prever falhas de rede e melhorar a segurança.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Dessa forma, a capacidade de interpretar corretamente dados estatísticos é uma habilidade inestimável no mundo tecnológico. Sem uma compreensão adequada da Estatística, os profissionais podem facilmente interpretar de maneira errada os dados, levando a conclusões errôneas. Esta compreensão é ainda mais crítica quando se considera o volume e a complexidade dos dados gerados no mundo digital atual. Exemplos práticos da aplicação da Estatística na tecnologia são abundantes. No marketing digital, por exemplo, as empresas utilizam a análise Estatística para segmentar clientes, personalizar campanhas e medir a eficácia de diferentes estratégias de marketing. Em relação ao setor da saúde, a Estatística é usada para analisar resultados de ensaios clínicos, melhorar diagnósticos e desenvolver tratamentos mais eficazes. Além disso, na área de redes sociais, a análise Estatística de padrões de interação e compartilhamento de conteúdo pode fornecer *insights* valiosos sobre o comportamento do usuário, permitindo que as plataformas otimizem suas funcionalidades e interfaces.

1.1 Definição e Fundamentos da Estatística

A Estatística é a ciência responsável pela coleta, análise, interpretação e apresentação de dados. Surgiu dos esforços humanos primitivos para contar e medir, evoluindo ao longo dos séculos para se tornar uma disciplina central em diversas áreas, notavelmente na tecnologia (Favero *et al*., 2023). Esta ciência tem suas raízes na antiga civilização, com registros dos egípcios e babilônios utilizando métodos básicos de contagem para organizar populações e recursos (Morettin & Singer, 2022). A formalização como uma disciplina científica começou no século XVII com o desenvolvimento da teoria de probabilidade por matemáticos como Blaise Pascal e Pierre de Fermat. Eles introduziram conceitos fundamentais para quantificar incerteza e variabilidade, elementos fundamentais na moderna análise de dados (Favero *et al.*, 2023; Morettin & Singer, 2022). O século XIX viu avanços significativos com figuras como Francis Galton e Karl Pearson, que desenvolveram métodos gráficos e conceitos como correlação e regressão, essenciais para a análise de dados complexos (Wickham *et al.*, 2023). Atualmente, a Estatística é uma ferramenta indispensável na tecnologia, fornecendo métodos para transformar grandes quantidades de dados brutos em informações úteis. A Estatística descritiva, que

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

envolve medidas como média, mediana, moda, variância e desvio padrão, ajuda a resumir características de conjuntos de dados (Wickham *et al.*, 2023). Estas ferramentas são vitais para entender as propriedades centrais e a dispersão dos dados.

Na Engenharia de Software, conceitos de Estatística Descritiva como média, mediana, moda, variância e desvio padrão são fundamentais para analisar e entender dados relacionados ao desenvolvimento de software. A média, que representa o valor central de um conjunto de dados, pode ser utilizada para determinar o tempo médio de desenvolvimento de um novo recurso. A mediana é o valor do meio em um conjunto ordenado de números, que pode indicar o tempo mediano de resposta a bugs, útil em distribuições com outliers. A moda é o valor mais frequente em um conjunto de dados, pode revelar o erro mais comum encontrado em testes de software. A variância e o desvio padrão podem medir a dispersão dos dados em torno da média, e são úteis para entender a consistência no tempo de resposta do software ou na variabilidade dos esforços de codificação entre diferentes projetos. Essas medidas ajudam os engenheiros de software a identificar padrões, avaliar a eficiência dos processos e garantir a qualidade do produto final.

Dessa forma, a Estatística Inferencial vai além, permitindo previsões e inferências sobre populações a partir de amostras. Conceitos como intervalos de confiança e testes de hipóteses são fundamentais para generalizar os resultados e tirar conclusões baseadas em dados amostrais (Casella & Berger, 2021). Em tecnologia, a Estatística Inferencial é usada em aplicações como previsão de tendências de mercado e avaliação de algoritmos. Logo, o papel da Estatística é ainda mais evidente na Ciência de Dados e na inteligência artificial. Na Ciência de Dados, é essencial para extrair padrões e *insights* de grandes volumes de dados, enquanto na IA, métodos estatísticos são utilizados para desenvolver algoritmos de aprendizado de máquina (Trevor *et al*., 2009).

Os conceitos estatísticos de intervalos de confiança, testes de hipóteses, população e amostra são essenciais para fazer inferências e tomar decisões baseadas em dados. Intervalos de confiança fornecem uma faixa estimada na qual um parâmetro da população (como o tempo médio necessário para corrigir um bug) é provável que esteja considerando um determinado nível de confiança permitindo que engenheiros façam melhores previsões. Testes de hipóteses são usados para verificar

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

a validade de uma suposição, como testar se uma nova ferramenta de desenvolvimento pode melhorar a eficiência do código em comparação com ferramentas existentes. O conceito de população refere-se ao conjunto completo de dados de interesse (por exemplo, todas as instâncias de falhas em um software), enquanto uma amostra é um subconjunto dessa população, utilizada para fazer inferências sobre a população total. Na Engenharia de Software, frequentemente trabalha-se com amostras devido à impraticabilidade de examinar cada instância ou elemento da população, como testar cada possível interação do usuário em um software. Estes conceitos são cruciais para tomar decisões fundamentadas e melhorar práticas e produtos na Engenharia de Software.

1.2 Análise Descritiva de Dados com R

A análise descritiva de dados é um passo fundamental na compreensão de qualquer conjunto de dados pois fornece uma visão geral dos dados, destacando tendências centrais, dispersão e a distribuição geral. A seguir será apresentada uma visão prática da análise descritiva de dados utilizando a Linguagem R:

Medidas de Tendência Central:

- Cálculo da Média: a média é uma medida de tendência central, indicando o ponto médio dos dados.
- Cálculo da Mediana: a mediana divide o conjunto de dados em duas metades iguais e é útil em distribuições assimétricas.
- Cálculo da Moda: a moda apresenta o(s) elemento(s) com maior frequência absoluta, podendo ser: Amodal (nenhuma moda), Unimodal (uma moda), Bimodal (duas modas) ou Multimodal (três ou mais modas).

Medidas de Dispersão:

- Mínimo: representa o menor valor do conjunto de dados.
- Máximo: representa o maior valor do conjunto de dados.
- Cálculo da Amplitude: representa a distância entre o valor máximo e o valor mínimo em um conjunto de dados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- Cálculo da Variância: representa a variabilidade ao redor da média, porém, esta medida altera a grandeza dos dados (é uma medida quadrática, ou seja, os valores são elevados ao quadrado, não podendo ser utilizada para fins interpretativos, apenas como parâmetro de análise).
- Cálculo do Desvio Padrão: representa a variabilidade dos dados ao redor da média, desta vez, na grandeza correta dos dados.
- Cálculo do Coeficiente de Variação: representa uma medida relativa entre o desvio padrão e a média, sendo representado em porcentagem. Se o resultado for menor que 10%, a variabilidade dos dados é classificada como baixa. Se o resultado estiver entre 10 e 20%, a variabilidade dos dados é classificada como média. Se o resultado estiver entre 20 e 30%, a variabilidade dos dados é classificada como alta. E se o resultado for maior do que 30%, a variabilidade dos dados é classificada como muito alta.

Medidas Separatrizes:

- Quartil: são os valores que dividem um conjunto de dados em 4 partes iguais, de 25 em 25%.
- Decil: são os valores que dividem um conjunto de dados em 10 partes iguais, de 10 em 10%.
- Centil: são os valores que dividem um conjunto de dados em 100 partes iguais, de 1 em 1%.

Agora, aplicamos esses conceitos a um conjunto de dados prático, e então, vamos supor que temos dados de vendas mensais de uma loja.

```R
# Criando a base de dados de vendas mensais:
vendas <- c(120, 150, 130, 170, 200, 180, 160, 190, 150)
# Calculando a Média:
media_vendas <- mean(vendas)
```

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Calculando a Mediana:
mediana_vendas <- median(vendas)
# Calculando a Moda:
Baixar e habilitar o pacote DescTools
moda_vendas <- Mode(vendas)
# Máximo:
máximo_vendas <- max(vendas)
#Mínimo:
mínimo_vendas <- min(vendas)
# Calculando a Amplitude:
amplitude_vendas <- diff(range(vendas)
# Calculando a Variância:
variancia_vendas <- var(vendas)
# Calculando o Desvio Padrão:
desvio_padrao_vendas <- sd(vendas)
# Calculando o Coeficiente de Variação:
cv_vendas <- (sd(vendas)/mean(vendas))*100
# Calculando os Quartis:
quartis_vendas <- quantile(vendas, probs=c(0.25, 0.50, 0.75))
# Calculando os Decis:
decis_vendas <- quantile(vendas, probs = seq(0.1, 0.9, by = 0.1))
# Calculando os Centis:
centis_vendas <- quantile(x, probs = seq(0.01, 0.99, by = 0.01))
´´´
```

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Neste exemplo em R, foram utilizadas as funções básicas para calcular medidas descritivas do conjunto de dados de vendas. A função ‘mean’ calcula a Média, ‘median’ para a Mediana, ‘Mode’ para a Moda, ‘max’ para o Máximo, ‘min’ para o Mínimo, ‘diff(range())’ para a Amplitude, ‘var’ para a Variância, ‘sd’ para o Desvio Padrão, ‘(sd()/mean())*100’ para o Coeficiente de Variação, ‘quantile’ para os Quartis, Decis e Centis. Estas funções são fundamentais na análise descritiva e oferecem uma visão rápida do comportamento dos dados. A análise descritiva de dados é um componente fundamental da análise de dados, fornecendo um entendimento do conjunto de dados em análise. Utilizando a Linguagem R, podemos efetivamente resumir e visualizar dados, o que é essencial para qualquer análise posterior, seja ela preditiva, inferencial ou para tomada de decisões baseadas em dados.

1.3 Análise Inferencial de Dados com R

A Estatística Inferencial é a parte da Estatística que busca fazer afirmações, por meio de **Testes de Hipótese**, sobre características de uma **população** (que possui **parâmetros**), com base nas **amostras** desta população (que possui **estimadores**).

Exemplos de hipóteses estatísticas:

- A droga 1 é tão eficiente quanto a droga 2.
- A altura média da população brasileira é de 1,65m.
- A proporção de paulistas com a doença X é de 62%.
- Homens e mulheres realizam a tarefa Y em um mesmo intervalo de tempo.

Para que isso seja feito, é necessário conhecer a **Distribuição de Probabilidade** do fenômeno e aplicar o **Teste de Hipótese** apropriado.

Entre todas as Distribuições de Probabilidade que existem, a mais utilizada para explicar fenômenos é a **Distribuição Normal**, representada no gráfico a seguir:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

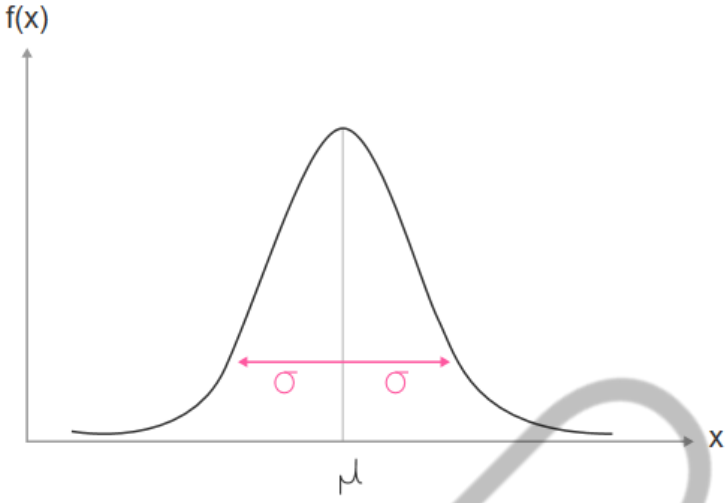

Figura 1 - Curva de Distribuição Normal
Fonte: Elaborado pelo autor (2024)

O gráfico mostra que a probabilidade de um evento aleatório ocorrer, quanto mais próximo da média (μ) ele for, maior sua probabilidade de ocorrência, e quanto mais afastado da média, menor a sua probabilidade de ocorrência.

O desvio padrão (σ) representa a variabilidade dos dados. Quanto maior o desvio padrão, mais larga será a curva e quanto menor o desvio padrão, menos larga será a curva.

Um Teste de Hipótese pode ser entendido como uma regra de decisão que consiste em **aceitar ou rejeitar H0**, baseado nos dados amostrais. As hipóteses estatísticas são:

- **H0** = Hipótese Nula: representa a afirmação, igualdade.
- **H1** ou **Ha** = Hipótese Alternativa: representa o complemento de **H0**.

Para resolver problemas de Teste de Hipótese, podemos utilizar várias metodologias diferentes. Pelo método da Região Crítica, devemos seguir os seguintes passos para realizar o Teste de Hipótese:

1) Enunciar as Hipóteses H0 e H1.
2) Fixar o Nível de Significância (α), que é a margem de erro, e identificar a Distribuição de Probabilidade associada ao teste (Normal, t-Student, F, x^2, ...).

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

3) Determinar as regiões de aceitação e rejeição de H0, baseados em H1 e no α (é necessário ter as respectivas tabelas de Distribuição de Probabilidade quando realizado manualmente).
4) Calcular a estatística do teste.
5) Aceitar ou rejeitar H0 com base em 3) e 4).

Agora, vamos aplicar esses conceitos a uma situação prática: um comprador de tijolos acha que a qualidade dos tijolos está diminuindo. Ao observar experiências anteriores, considerou que a resistência média ao desmoronamento de tais tijolos é igual a 200 kg, com um desvio padrão de 10 kg. Uma amostra de 100 tijolos, escolhidos ao acaso, forneceu uma média de 195 kg. Ao nível de significância de 5%, pode-se afirmar que a resistência média ao desmoronamento diminuiu?

```R
Declarar as hipóteses: H0 : μ ≥ 200 kg , e definir as regiões de aceitação e
                       H1 : μ < 200 kg                                rejeição

Encontrar o valor de Zc: Zc <- (195 – 200)/(10/sqrt(100))
Encontrar o valor de Zα: Za <- qnorm(0.05)

Decisão: ifelse (Zc < Za, "Rejeita Ho", "Aceita Ho")
´´´
```

Portanto, ao nível de significância de 5%, a resistência média ao desmoronamento diminuiu.

1.4 Visualização dos Dados

Além das medidas estatísticas, as visualizações gráficas são parte importante da análise descritiva.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O tipo de gráfico depende da natureza da variável em análise:

- Variável Qualitativa: para variáveis que representam categorias ou nomes, utiliza-se o Gráfico de Barras Horizontais, Gráfico de Barras Verticais ou o Gráfico de Setores (pizza);
- Variável Quantitativa: para variáveis que representam números ou medidas, utiliza-se o Histograma ou Boxplot.

Vamos criar um gráfico de barras para visualizar as vendas mensais do primeiro exemplo.

```R
# Carregando o pacote ggplot2 para visualização
install.packages("ggplot2")
library(ggplot2)
# Criando um data frame para os dados de vendas
dados_vendas <- data.frame(Mês = 1:9, Vendas = vendas)
# Criando um gráfico de barras
ggplot(dados_vendas, aes(x=Mês, y=Vendas)) +
  geom_bar(stat="identity", fill="blue") +
  ggtitle("Vendas Mensais") +
  xlab("Mês") +
  ylab("Vendas")
```

Neste script, foi utilizado o `ggplot2`, um pacote que faz parte do Tidyverse para criar gráficos personalizados em R. É importante destacar que o R gera gráficos automaticamente sem a necessidade de utilizar pacotes adicionais. Foi utilizado o pacote `ggplot2` apenas para deixar o gráfico mais elegante, atrativo e personalizado.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

O gráfico de barras gerado oferece uma visualização clara das vendas mensais, facilitando a identificação de padrões ou tendências, como meses com desempenho de vendas acima ou abaixo da média.

1.5 Estudo de Caso 1: Análise do Desempenho de Modelos de IA do tipo PLN (Processamento de Linguagem Natural)

Considere que você está analisando o desempenho de diferentes modelos de Processamento de Linguagem Natural (PLN) em uma tarefa de classificação de sentimentos em uma escala de 1 a 5 pontos (1 para sentimento negativo e 5 para sentimento positivo). Os resultados para um conjunto de 20 amostras são os seguintes: 3, 4, 2, 5, 3, 2, 4, 4, 3, 5, 4, 2, 3, 4, 4, 5, 2, 3, 4, 4.

Faça a análise descritiva completa desse conjunto de dados.

```R
# Criando a base de dados:
dados <- c(3, 4, 2, 5, 3, 2, 4, 4, 3, 5, 4, 2, 3, 4, 4, 5, 2, 3, 4, 4)
# Calculando a Média:
media_dados <- mean(dados)
# Calculando a Mediana:
mediana_dados <- median(dados)
# Calculando a Moda:
Baixar e habilitar o pacote DescTools
moda_dados <- Mode(dados)
# Máximo:
máximo_dados <- max(dados)
#Mínimo:
mínimo_dados <- min(dados)
# Calculando a Amplitude:
```

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
amplitude_dados <- diff(range(dados)

# Calculando a Variância:

variancia_dados <- var(dados)

# Calculando o Desvio Padrão:

desvio_padrao_dados <- sd(dados)

# Calculando o Coeficiente de Variação:

cv_dados <- (sd(dados)/mean(dados))*100

# Calculando os Quartis:

quartis_dados <- quantile(dados, probs=c(0.25, 0.50, 0.75))

# Calculando os Decis:

decis_dados <- quantile(dados, probs = seq(0.1, 0.9, by = 0.1))

# Calculando os Centis:

centis_dados <- quantile(dados, probs = seq(0.01, 0.99, by = 0.01))
```

1.6 Estudo de Caso 2: Inferência sobre a precisão média de modelos preditivos

Um sistema de inteligência artificial está sendo utilizado para avaliar a qualidade das previsões de demanda de um produto em uma empresa de e-commerce. Historicamente, a precisão média das previsões da demanda do produto é de 200 unidades, com um desvio padrão de 10 unidades. Recentemente, a IA coletou uma amostra aleatória de 100 previsões e calculou a precisão média dessa amostra, que foi de 195 unidades. Utilizando um nível de significância de 5%, a IA deve determinar se a precisão média das previsões realmente diminuiu.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```R
Declarar as hipóteses: H0 : μ ≥ 200 unidades, e definir as regiões de aceitação
                       H1 : μ < 200 unidades                                e rejeição

Encontrar o valor de Zc: Zc <- (195 - 200)/(10/sqrt(100))
Encontrar o valor de Zα: Za <- qnorm(0.05)

Decisão: ifelse (Zc < Za, "Rejeita Ho", "Aceita Ho")
```

Portanto, ao nível de significância de 5%, a precisão média de produtos diminuiu.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

CASELLA, G., & Berger, R. L. (2021). **Statistical inference**. Cengage Learning.

FAVERO, L. P., Belfiore, P., & de Freitas Souza, R. (2023). **Data science, analytics and machine learning with R.** Academic Press.

GELMAN, A., & Hill, J. (2006). **Data analysis using regression and multilevel/hierarchical models.** Cambridge university press.

MORETTIN, P. A., & Singer, J. da M. (2022). **Estatística e ciência de dados.**

TREVOR, H., Robert, T., & Jerome, F. (2009). **The elements of statistical learning: Data mining, inference, and prediction.** Spinger.

WICKHAM, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). **R for data science**. O'Reilly Media, Inc.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com