FIAP ON

CAMPO DA INOVAÇÃO - UMA PLANTAÇÃO DE CÓDIGOS

ACELERA COM DATA SCIENCE

8

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

LISTA DE FIGURAS

Figura 1 - Resultado da Regressão.....8
Figura 2 - Tabela de resultado 9

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

SUMÁRIO

1 ACELERA COM DATA SCIENCE 4
1.1 Fundamentos Teóricos da Regressão Linear 5
1.2 Regressão Linear Simples em R 7
1.3 Regressão Linear Múltipla em R 11
1.4 Pressupostos da Regressão Linear 11
1.5 Testando Independência dos Erros 15
1.6 Interpretação para a Regressão Linear 16
1.7 Testando Homoscedasticidade 17
1.8 Testando Normalidade dos Erros 18
1.9 Exemplo Completo 19
REFERÊNCIAS 22

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1 ACELERA COM DATA SCIENCE

A Regressão Linear é um método estatístico desenvolvido para modelar a relação entre uma variável dependente e uma ou mais variáveis independentes, possui um papel relevante na Engenharia de Software (Favero *et al*., 2023). Essencial para prever tendências, otimizar processos e tomar decisões baseadas em dados, a Regressão Linear serve como uma ferramenta para os engenheiros de software. Este capítulo introduz os conceitos fundamentais da Regressão Linear, enfatizando sua relevância e aplicabilidade em projetos de Ciência de Dados, Inteligência Artificial (IA) e Engenharia de Software.

No início do século XIX, a Regressão Linear originou-se nos trabalhos de matemáticos como Legendre e Gauss. Embora Gauss tenha feito trabalho preliminar na metodologia em 1809, é Legendre quem geralmente é creditado com a publicação do primeiro tratado sobre o método dos mínimos quadrados em 1805, um conceito central na Regressão Linear (Gelman & Hill, 2006). Originalmente desenvolvida no contexto da astronomia e da física para modelar as órbitas dos corpos celestes e reduzir erros de medição, a Regressão Linear evoluiu ao longo do tempo. O termo "regressão" foi introduzido mais tarde, no final do século XIX, por Francis Galton, ao estudar a relação entre as alturas dos pais e seus filhos. Desde então, a Regressão Linear expandiu-se para além de suas raízes em Ciências Naturais, encontrando aplicações em campos tão diversos quanto Economia, Biologia, Engenharia, Ciências Sociais e, mais recentemente, na Ciência de Dados.

Nos princípios básicos da Regressão Linear, a relação entre as variáveis é representada por uma linha reta (em casos de Regressão Linear Simples) ou um plano (em Regressão Linear Múltipla). A equação geral, $Y = a + bX$, descreve essa relação, onde Y é a variável dependente que estamos tentando prever, X é a variável independente que influencia Y, 'a' é o ponto de interseção da linha com o eixo Y (o valor de Y quando X é zero), e 'b' é o coeficiente da variável independente (Casella & Berger, 2021). Este coeficiente reflete o grau e a direção da relação entre X e Y.

Um aspecto importante na análise da Regressão Linear é a avaliação do erro, que é a diferença entre os valores observados dos dados e os valores previstos pelo modelo. Em termos didáticos, se imaginarmos cada ponto de dados como uma casa

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

e a linha de regressão como o nível da rua, o erro seria a distância vertical de cada casa até essa rua. O objetivo da Regressão Linear é ajustar essa 'rua' de modo que a soma dos quadrados dessas 'distâncias verticais' seja a menor possível. Este processo é conhecido como método dos mínimos quadrados. Ao minimizar esses erros, o modelo de Regressão Linear se torna uma representação mais precisa e confiável da relação entre as variáveis estudadas.

O processo da técnica começa com a coleta de dados, seguida por sua análise e modelagem por meio da Regressão Linear, logo, interpretar os resultados é o passo final para embasar decisões informadas. Este capítulo, portanto, destaca a aplicabilidade prática e serve como ponto de partida para entender a Regressão Linear e sua aplicação na Engenharia de Software. As seções aprofundarão nos aspectos teóricos e práticos, abordando os tipos de regressão, pressupostos, diagnóstico, validação de modelos, e aplicações práticas em estudos de caso.

1.1 Fundamentos Teóricos da Regressão Linear

Começamos com a Regressão Linear Simples, que envolve uma variável dependente e uma independente. Por exemplo, em um projeto de software, a variável dependente poderia ser o tempo de resposta do sistema (Y), enquanto a variável independente poderia ser o número de usuários simultâneos (X). A relação é descrita pela equação Y = a + bX, onde 'Y' representa o tempo de resposta, 'X' é o número de usuários, 'a' é o tempo de resposta quando não há usuários, e 'b' mostra como o tempo aumenta com cada usuário adicional.

Na Regressão Linear Múltipla, incluímos mais variáveis independentes. Utilizando o mesmo sistema como exemplo, podemos adicionar 'Z' para representar a quantidade de dados processados. A equação então se torna Y = a + b1X + b2Z, onde 'X' e 'Z' são variáveis independentes (número de usuários e quantidade de dados, respectivamente), e b1 e b2 são coeficientes que indicam o impacto de cada variável no tempo de resposta (Y).

Na Regressão Linear, o estimador é uma fórmula matemática usada para calcular os coeficientes (como 'a' e 'b' na equação Y = a + bX) que definem a linha de melhor ajuste entre as variáveis. Podemos pensar no estimador como o algoritmo que

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

nos ajuda a encontrar a linha que melhor "descreve" a relação entre a variável independente (X) e a variável dependente (Y). Esse processo de estimativa é realizado através do método dos mínimos quadrados, que busca minimizar a soma dos quadrados das diferenças (erros) entre os valores observados e os valores previstos pelo modelo. Imagine que cada ponto no gráfico é uma pessoa em um balão, flutuando acima ou abaixo de uma linha. O objetivo do estimador é ajustar a linha de tal forma que a soma das distâncias verticais (para cima ou para baixo) de cada pessoa até a linha seja a menor possível. Esse ajuste resulta nos valores de 'a' (intercepto, ou onde a linha cruza o eixo Y) e 'b' (inclinação da linha), proporcionando a melhor representação linear possível da relação entre X e Y.

Vamos considerar um exemplo para um sistema de software: Tempo de Resposta (Y): 2, 3, 4, 5 segundos; Número de Usuários (X): 1, 2, 3, 4; e Quantidade de Dados (Z): 100, 200, 300, 400 MB. Após analisar esses dados, suponhamos que chegamos à equação $Y = 1 + 0.5X + 0.01Z$. A interpretação dessa equação é a seguinte:

1. O termo '1' (o valor de 'a') indica que o tempo de resposta base do sistema, sem usuários e sem processamento de dados, é de 1 segundo.
2. O coeficiente '0.5' (o valor de 'b1') sugere que para cada usuário adicional, o tempo de resposta aumenta em meio segundo.
3. O coeficiente '0.01' (o valor de 'b2') indica que para cada 100 MB adicionais de dados processados, o tempo de resposta aumenta em 0.01 segundo.

Este exemplo demonstra como a Regressão Linear pode ser utilizada para modelar e prever o comportamento de um sistema de software em diferentes condições de uso. Compreender essa relação entre variáveis é fundamental para otimizar o desempenho do software e melhorar a experiência do usuário.

A seguir vamos aplicar a discussão com a Linguagem R:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.2 Regressão Linear Simples em R

Nosso objetivo será analisar a relação entre o número de horas dedicadas ao desenvolvimento de software (variável independente) e a quantidade de bugs identificados no software (variável dependente).

```R
# Instalando e carregando o pacote necessário
if (!require(ggplot2)) install.packages("ggplot2")
library(ggplot2)

# Dados
horas <- c(10, 20, 30, 40, 50, 60, 70, 80)
bugs <- c(7, 13, 20, 28, 35, 45, 55, 65)

# Criando um dataframe
dados <- data.frame(horas, bugs)

# Plotando os dados
ggplot(dados, aes(x = horas, y = bugs)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  theme_minimal() +
  xlab("Horas de Desenvolvimento") +
  ylab("Quantidade de Bugs")

# Realizando a Regressão Linear Simples
modelo_Simples <- lm(bugs ~ horas, data = dados)
summary(modelo_Simples)
```

A Figura a seguir apresenta visualmente o resultado da regressão:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

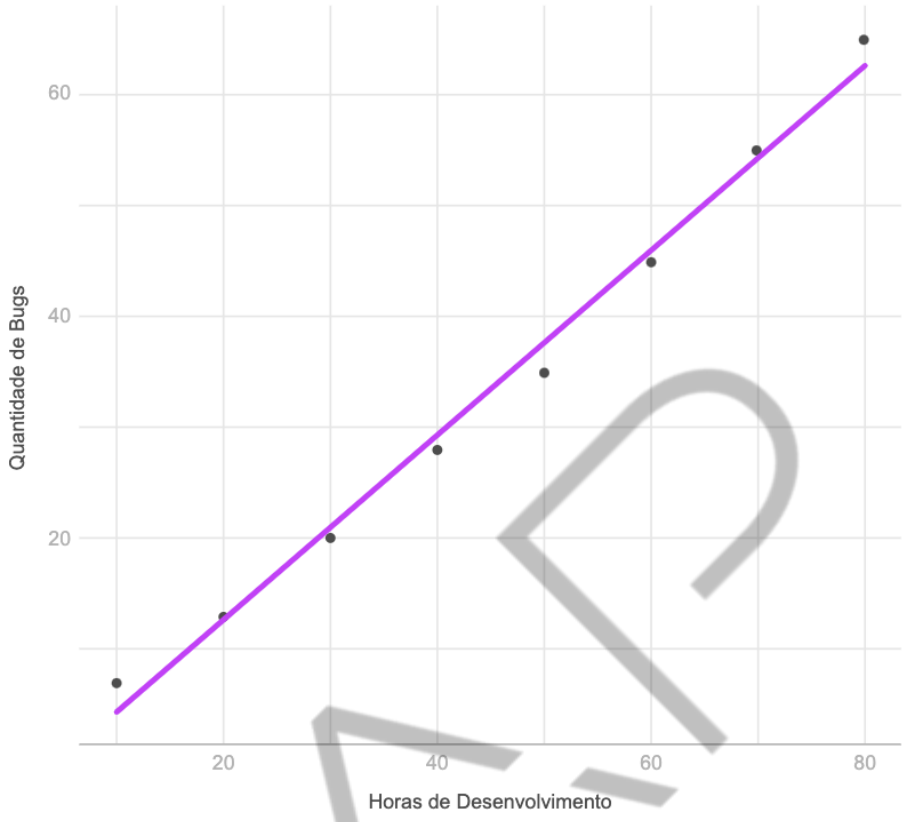

Figura 1 - Resultado da Regressão
Fonte: Elaborado pelo autor (2023)

A reta lilás é chamada de reta da regressão e cada ponto representa a observação quando cruzamos as variáveis que criamos, no caso, bugs e horas.

A Figura “Tabela de Resultado” apresenta a tabela do resultado da nossa regressão:

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
Call:
lm(formula = bugs ~ horas, data = dados)

Residuals:
    Min      1Q  Median      3Q     Max 
-2.6548 -1.1131 -0.3452  1.1488  2.5833 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) -3.89286    1.55761  -2.499   0.0466 *  
horas        0.83095    0.03085  26.939 1.73e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.999 on 6 degrees of freedom
Multiple R-squared:  0.9918,	Adjusted R-squared:  0.9904 
F-statistic: 725.7 on 1 and 6 DF,  p-value: 1.728e-07
```

Figura 2 - Tabela de resultado
Fonte: Elaborado pelo autor (2023)

Interpretação da Tabela de Resultados:

1. **Estimativas (*Estimate*):** você verá o intercepto ('(*Intercept*)') e o coeficiente da variável independente ('horas'). O intercepto indica o valor previsto de 'bugs' quando 'horas' é zero. O coeficiente de 'horas' mostra como a quantidade de 'bugs' é esperada para mudar com cada hora adicional de desenvolvimento.

2. **Valor-p (Pr(>|t|)):** este valor indica a probabilidade de observar um efeito tão extremo quanto o que o modelo encontrou, assumindo que não há efeito (hipótese nula). Um valor-p baixo (geralmente < 0.05) sugere que a relação observada entre as variáveis é estatisticamente significativa, logo, a relação prevista no modelo acontece.

3. **R-squared**: representa o coeficiente de determinação e mede a proporção da variação na variável dependente que é explicada pela variável independente no modelo de regressão (Wickham *et al.*, 2023). Um R-squared de 1 indica que o modelo explica toda a variação na variável dependente, enquanto um valor mais baixo sugere uma menor proporção de variação explicada. No entanto, o R-squared tem uma limitação

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

importante: tende a aumentar à medida que mais variáveis independentes são adicionadas ao modelo, independentemente se essas variáveis realmente melhorarem o modelo podendo ocasionar uma interpretação equivocada de que o modelo está se tornando melhor com a adição de mais variáveis, mesmo quando não são úteis. Dessa forma, entender o conceito de Adjusted R-squared, que ajusta o R-squared para o número de variáveis no modelo é importante, pois incorpora um termo de penalidade que diminui o valor quando variáveis irrelevantes são adicionadas ao modelo (Favero *et al.*, 2023; Morettin & Singer, 2022). Assim, o Adjusted R-squared pode diminuir se uma variável que não contribui significativamente para a explicação da variável dependente for incluída. Em suma, o Adjusted R-squared é uma medida mais robusta para modelos com Múltiplas variáveis, pois considera tanto o número de variáveis quanto o ajuste do modelo aos dados. Portanto, ao avaliar a qualidade de um modelo de regressão, especialmente um com várias variáveis, é preferível olhar para o Adjusted R-squared em vez do R-squared Simples. Vale destacar que dificilmente encontraremos o valor 1, afinal, podemos não conseguir captar todas as variáveis necessárias para o modelo.

4. **F-statistic e seu valor-p correspondente:** a estatística F e o valor-p associado testam se há uma relação estatisticamente significativa entre a variável dependente e a variável independente no modelo. Um valor-p baixo (geralmente < 0.05) indica que o modelo é estatisticamente significativo, ou seja, é improvável que os resultados sejam devido ao acaso.

É importante lembrar que enquanto a tabela de regressão fornece informações sobre a relação entre as variáveis, a interpretação deve considerar o contexto dos dados e outras possíveis variáveis que não estão incluídas no modelo. A Regressão Linear é uma ferramenta poderosa, mas também tem suas limitações e pressupostos que precisam ser considerados na análise dos resultados.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.3 Regressão Linear Múltipla em R

Agora, vamos expandir o exemplo anterior adicionando uma nova variável independente: a complexidade do código (medida em algum índice de complexidade).

```R
# Dados
complexidade <- c(5, 7, 6, 9, 8, 7, 8, 10)

# Adicionando a nova variável ao dataframe
dados$complexidade <- complexidade

# Realizando a Regressão Linear Múltipla
modelo_multiplo <- lm(bugs ~ horas + complexidade, data = dados)
summary(modelo_multiplo)
```

Interpretação dos resultados:

- Assim como na regressão Simples, observamos os coeficientes para cada variável independente que mostram como a quantidade de bugs é influenciada pelas horas de desenvolvimento e pela complexidade do código.
- O `R-squared` aumentou em comparação com a regressão Simples, o que pode indicar que adicionar a complexidade do código fornece uma melhor explicação para a variação na quantidade de bugs.
- Os valores p para cada coeficiente ajudam a entender a significância estatística de cada variável no modelo.

1.4 Pressupostos da Regressão Linear

Vamos discutir os pressupostos da Regressão Linear e as técnicas de diagnóstico para validar esses pressupostos. A compreensão e verificação desses pressupostos são fundamentais para garantir a validade e confiabilidade dos modelos

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

de Regressão Linear, especialmente em aplicações relacionadas à Ciência de Dados, Inteligência Artificial e Engenharia de Software.

A Regressão Linear baseia-se em vários pressupostos que precisam ser satisfeitos para que as conclusões do modelo sejam válidas, incluindo:

1. **Linearidade:** a relação entre as variáveis independentes e a variável dependente deve ser linear. Isto significa que uma mudança em uma variável independente deve resultar em uma mudança proporcional na variável dependente.
2. **Independência dos Erros:** os erros (diferenças entre os valores observados e os valores previstos) devem ser independentes uns dos outros. A correlação entre erros pode levar a inferências incorretas.
3. **Homoscedasticidade:** a variância dos erros deve ser constante para todas as observações. Isso significa que a precisão do modelo é consistente em todos os níveis da variável independente.
4. **Normalidade dos Erros:** os erros devem ser distribuídos normalmente, pois são considerados especialmente importantes para fazer inferências e calcular intervalos de confiança.

A verificação desses pressupostos é realizada por meio de técnicas de diagnóstico, incluindo:

- **Gráficos de Resíduos**: são utilizados para visualizar a distribuição dos erros e verificar a homoscedasticidade. Um padrão aleatório dos pontos sugere que os pressupostos de linearidade e homoscedasticidade estão sendo atendidos.
- **Testes de Normalidade:** testes como o de Shapiro-Wilk são utilizados para verificar a normalidade dos erros. A distribuição normal dos erros é uma indicação de que as inferências e previsões do modelo são válidas.
- **Gráficos Q-Q (Quantil-Quantil):** estes gráficos são uma ferramenta visual para avaliar se os erros seguem uma distribuição normal. Os dados são plotados em relação a uma distribuição normal teórica de tal forma que, se

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

os dados forem distribuídos normalmente, formarão aproximadamente uma linha reta.

Especialmente em projetos de Ciência de Dados, IA e Engenharia de Software, a verificação dos pressupostos da Regressão Linear é essencial para garantir a precisão e confiabilidade das previsões e inferências feitas com base no modelo. Por exemplo, em um modelo que prediz a performance do software, ou o número de falhas que é esperado um modelo de Machine Learning cometer, ou a quantidade de vendas esperadas para o próximo mês de uma empresa, a violação desses pressupostos pode levar a estimativas imprecisas, afetando a tomada de decisões e a otimização de recursos.

Vamos ilustrar com um exemplo didático relacionado à engenharia de software os pressupostos discutidos: considere que estamos desenvolvendo um modelo de Regressão Linear para prever o tempo de carregamento de uma página web (variável dependente) com base no tamanho do conteúdo da página em megabytes (variável independente). Primeiro, coletamos dados que incluem o tamanho das páginas e os respectivos tempos de carregamento.

1. **Linearidade:** verificamos se o aumento no tamanho do conteúdo está associado a um aumento proporcional no tempo de carregamento. Isso pode ser visualizado com um gráfico de dispersão; esperamos ver uma relação linear aproximada entre as variáveis.
2. **Independência dos Erros:** investigamos se os erros (as diferenças entre os tempos de carregamento observados e os previstos pelo modelo) são independentes. Para isso, utilizamos testes estatísticos, como o teste de Durbin-Watson, para avaliar a independência dos erros.
3. **Homoscedasticidade:** procuramos uma variância constante nos erros. Isso é verificado por meio de um gráfico de resíduos, onde esperamos ver os pontos distribuídos aleatoriamente e sem formar padrões específicos ao longo do eixo horizontal (tamanho do conteúdo).
4. **Normalidade dos Erros:** realizamos testes, como o Shapiro-Wilk, e construímos um gráfico Q-Q para verificar se os erros seguem uma distribuição normal. No gráfico Q-Q, os pontos devem alinhar-se aproximadamente com a linha diagonal.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

Ao aplicar esses pressupostos ao nosso exemplo, podemos garantir que o modelo de Regressão Linear desenvolvido é confiável e válido para prever o tempo de carregamento de páginas web com base no tamanho do conteúdo. Essa abordagem assegura que as inferências feitas a partir do modelo são sólidas e que as previsões são precisas, fundamentais para a otimização de websites e a melhoria da experiência do usuário.

Para ilustrar os pressupostos da Regressão Linear em R, vamos criar um exemplo no contexto de áreas tecnológicas, como Ciência de Dados, IA e Engenharia de Software. Considere que estamos analisando a relação entre a complexidade do código (medida, por exemplo, pelo Índice de Complexidade Ciclomática) e o número de bugs encontrados em um software. Vamos gerar dados e aplicar as técnicas para verificar os pressupostos da Regressão Linear.

Para uma melhor compreensão dos códigos vamos as interpretações:

1. **Preparação de Dados:** criamos dados representando a complexidade do código e o número de bugs associados.
2. **Modelagem de Regressão:** realizamos uma Regressão Linear Simples com esses dados.
3. **Testando Linearidade**: utilizamos um gráfico de dispersão com a linha de regressão para avaliar visualmente se a relação parece linear.

O gráfico de dispersão com a linha de regressão é uma ferramenta para avaliar a relação entre duas variáveis em análise de Regressão Linear. No contexto de complexidade do código e número de bugs em software, este gráfico fornece *insights* específicos:

1. **Pontos no Gráfico:** cada ponto representa uma observação do conjunto de dados. Um ponto pode indicar que, para um certo nível de complexidade do código, um número específico de bugs foi observado.
2. **Linha de Regressão:** a linha através dos pontos é a linha de Regressão Linear, representando a estimativa da relação linear entre complexidade do

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

código e número de bugs. Esta linha é determinada minimizando a soma dos quadrados das distâncias verticais dos pontos até a linha.

3. **Inclinação da Linha**: a inclinação da linha indica a relação entre as variáveis. Uma linha ascendente sugere uma relação positiva, indicando que o aumento da complexidade do código resulta em um aumento no número de bugs. Uma linha descendente indicaria uma relação negativa.
4. **Ajuste da Linha aos Dados:** a proximidade dos pontos à linha e sua distribuição indicam o quão bem o modelo de Regressão Linear se ajusta aos dados. Pontos próximos e uniformemente distribuídos sugerem um bom ajuste, enquanto uma dispersão ampla indica um ajuste menos preciso.
5. **Previsão:** a linha de regressão pode ser utilizada para prever o número esperado de bugs para um nível de complexidade não presente nos dados, encontrando o valor correspondente na linha de regressão para aquele nível de complexidade.

O gráfico de dispersão com a linha de regressão, portanto, é uma representação visual da relação entre as variáveis e ajuda na avaliação da adequação do modelo de Regressão Linear, além de elucidar a natureza da relação entre as variáveis no desenvolvimento de software.

1.5 Testando Independência dos Erros

O Teste de Durbin-Watson avalia a independência dos erros, ou seja, valores próximos de 2 indicam independência.

A independência dos erros é um pressuposto chave na Regressão Linear, isso significa que os resíduos (erros) do modelo não devem ser correlacionados. O Teste de Durbin-Watson é uma ferramenta estatística utilizada para avaliar esse pressuposto. Veja como interpretar os resultados do Teste de Durbin-Watson:

1. **Objetivo do Teste:** é projetado para detectar a presença de autocorrelação (uma relação entre valores sequenciais) nos resíduos de uma análise de regressão.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

2. **Valores do Teste:** o teste gera um valor que varia de 0 a 4.

- Um valor próximo de 2 sugere que não há autocorrelação nos resíduos.
- Valores significativamente menores que 2 indicam autocorrelação positiva. Isso significa que um valor de erro positivo provavelmente será seguido por outro valor de erro positivo.
- Valores significativamente maiores que 2 sugerem autocorrelação negativa, onde um valor de erro positivo provavelmente será seguido por um valor de erro negativo.

1.6 Interpretação para a Regressão Linear

- **Sem Autocorrelação (Valor ~2):** indica que os resíduos são independentes entre si, satisfazendo um dos pressupostos da Regressão Linear. Isso significa que o modelo é adequado e que as previsões feitas são confiáveis.
- **Autocorrelação Positiva (Valor <2):** pode indicar que o modelo está deixando de capturar alguma informação importante. Por exemplo, em um contexto de Engenharia de Software, isso pode acontecer se o modelo não levar em conta algum fator que influencia consistentemente o número de bugs de forma crescente ao longo do tempo.
- **Autocorrelação Negativa (Valor >2):** embora menos comum, uma autocorrelação negativa também pode indicar problemas no modelo, como uma variável independente que afeta os resíduos de maneira oscilante.

Em resumo, o Teste de Durbin-Watson é um instrumento importante para verificar a independência dos erros em um modelo de Regressão Linear, garantindo que o modelo seja confiável e suas previsões sejam válidas. A detecção de qualquer forma de autocorrelação pode exigir uma revisão no modelo ou uma investigação mais profunda das variáveis envolvidas.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

1.7 Testando Homoscedasticidade

Um gráfico de resíduos *versus* valores ajustados ajudam a verificar se a variância dos erros é constante (homoscedasticidade).

A homoscedasticidade é um pressuposto importante na Regressão Linear, que afirma que os erros (ou resíduos) do modelo devem ter variância constante em relação às variáveis independentes. O gráfico de resíduos *versus* valores ajustados é uma ferramenta visual utilizada para verificar esse pressuposto. Como podemos interpretá-lo:

1. **Criação do Gráfico:** este gráfico plota os resíduos (a diferença entre os valores observados e os valores previstos pelo modelo) no eixo vertical contra os valores ajustados (valores previstos) no eixo horizontal.

2. **Padrão dos Pontos:**

- **Homoscedasticidade (Variação Constante):** em um modelo ideal, os pontos no gráfico devem formar um padrão aleatório e sem forma específica ao redor da linha horizontal zero. Isso indicaria que a variância dos erros é constante em todos os níveis das variáveis independentes, satisfazendo o pressuposto de homoscedasticidade.
- **Heteroscedasticidade (Variação Não Constante):** se os resíduos exibirem padrões (como forma de funil ou forma em U), isso sugere que a variância dos erros varia com os valores ajustados, violando o pressuposto de homoscedasticidade. Por exemplo, se os resíduos se expandirem ou contraírem em um dos lados do gráfico, indica que os erros são maiores para determinados valores das variáveis independentes.

3. **Interpretação para Regressão Linear:**

- **Homoscedasticidade Confirmada:** isso indica que o modelo é bem especificado e os resultados da regressão são confiáveis. Ou seja, o modelo está tratando de forma igualmente precisa os dados em todo o espectro das variáveis independentes.
- **Heteroscedasticidade Detectada:** se houver evidência de heteroscedasticidade, isso pode afetar a confiabilidade das estimativas dos

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

parâmetros e dos testes de hipóteses, pois os erros padrões podem estar incorretos. Em contextos como a Ciência de Dados, Inteligência Artificial e Engenharia de Software, isso pode significar que o modelo de regressão pode não ser adequado para todos os níveis de, por exemplo, complexidade do código.

Em resumo, o gráfico de resíduos *versus* valores ajustados é uma ferramenta diagnóstica essencial para avaliar se um modelo de Regressão Linear satisfaz o pressuposto de homoscedasticidade. A identificação de padrões neste gráfico pode sinalizar a necessidade de modificar o modelo ou considerar transformações nas variáveis para melhorar a precisão e confiabilidade do modelo.

1.8 Testando Normalidade dos Erros

O gráfico Q-Q (Quantil-Quantil) compara a distribuição dos resíduos com uma distribuição normal. Os pontos devem alinhar-se aproximadamente com a linha.

O gráfico Q-Q é uma ferramenta visual utilizada para avaliar se os erros (ou resíduos) de um modelo de Regressão Linear seguem uma distribuição normal, um pressuposto importante para muitas análises estatísticas, incluindo a Regressão Linear.

Interpretação do gráfico Q-Q:

1. **Criação do Gráfico:** no gráfico Q-Q, os quantis (ou pontos percentuais) dos resíduos do modelo são plotados em relação aos quantis de uma distribuição normal teórica. Se os resíduos seguem uma distribuição normal, os pontos no gráfico devem alinhar-se aproximadamente com a linha diagonal.

2. **Análise dos Pontos:**

- **Distribuição Normal:** caso os resíduos estejam distribuídos normalmente, os pontos no gráfico Q-Q devem cair ao longo de uma linha reta. Pequenos desvios podem ser normais, mas em geral, um alinhamento próximo à linha sugere que a normalidade dos erros foi atingida.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

- **Desvios da Normalidade:** se os pontos desviam significativamente da linha diagonal, isso indica uma violação da normalidade. Por exemplo:
  - **Pontos em um padrão em "S" ou curvado:** indicam uma distribuição dos resíduos que é mais pesada ou mais leve nas caudas do que a distribuição normal.
  - **Pontos agrupados em uma extremidade do gráfico:** podem indicar uma distribuição de resíduos assimétrica.

3. **Implicações para a Regressão Linear:**

- **Normalidade Confirmada:** indica que os métodos estatísticos baseados na suposição de normalidade, como testes de hipóteses e intervalos de confiança, são apropriados e confiáveis.
- **Violação da Normalidade:** caso os resíduos não sigam uma distribuição normal, pode afetar a validade de alguns testes estatísticos aplicados aos coeficientes da regressão (Trevor *et al.*, 2009). Isso é particularmente relevante para tamanhos de amostra pequenos, pois a Regressão Linear é menos sensível à violação da normalidade em amostras grandes.

Logo, o gráfico Q-Q é uma ferramenta diagnóstica fundamental para verificar a normalidade dos resíduos em um modelo de Regressão Linear. Avaliar corretamente a distribuição dos resíduos é fundamental para garantir a precisão e confiabilidade das inferências estatísticas realizadas a partir do modelo. Se a normalidade for violada, pode ser necessário considerar transformações de dados ou modelos estatísticos alternativos.

Resumo do Modelo: oferece uma visão geral, incluindo estatísticas como R-squared e os p-values dos coeficientes.

1.9 Exemplo Completo

Considere que estamos avaliando o impacto de horas de desenvolvimento (Simples) e de complexidade do código (Múltipla) sobre o número de bugs encontrados em um software.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```R
# Instalando e carregando pacotes necessários
if (!require(ggplot2)) install.packages("ggplot2")
if (!require(car)) install.packages("car")
library(ggplot2)
library(car)

# Dados fictícios
horas <- c(10, 20, 30, 40, 50, 60, 70, 80) # Horas de desenvolvimento
complexidade <- c(5, 3, 6, 7, 2, 8, 7, 4)  # Complexidade do código
bugs <- c(2, 5, 7, 9, 5, 11, 14, 15)       # Número de bugs

# Criando um dataframe
dados <- data.frame(horas, complexidade, bugs)

# Regressão Linear Simples
modelo_Simples <- lm(bugs ~ horas, data = dados)

# Regressão Linear Múltipla
modelo_multiplo <- lm(bugs ~ horas + complexidade, data = dados)

# Resumo dos modelos
summary(modelo_Simples)
summary(modelo_multiplo)

# Diagnóstico dos modelos

# Verificação de Linearidade (Gráfico de Dispersão com a Reta de Regressão)
plot(dados$horas, dados$bugs)
abline(modelo_Simples, col = "red")

# Verificação de Homoscedasticidade
par(mfrow=c(1,2))
plot(modelo_Simples$fitted.values, resid(modelo_Simples))
plot(modelo_multiplo$fitted.values, resid(modelo_multiplo))
```

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

```
# Verificação de Normalidade (Gráfico Q-Q)
par(mfrow=c(1,2))
qqPlot(modelo_Simples, main = "Modelo Simples")
qqPlot(modelo_multiplo, main = "Modelo Múltiplo")

# Teste de Independência (Durbin-Watson)
dwtest(modelo_Simples)
dwtest(modelo_multiplo)
```

Este exemplo ilustra como realizar Regressões Linear Simples e Múltipla em R e como diagnosticar os pressupostos críticos para a validade desses modelos. A interpretação destes testes e gráficos ajuda a confirmar se o modelo de regressão é adequado e confiável para a análise pretendida.

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com

REFERÊNCIAS

CASELLA, G., & Berger, R. L. (2021). **Statistical inference.** Cengage Learning.

FAVERO, L. P., Belfiore, P., & de Freitas Souza, R. (2023). **Data science, analytics and machine learning with R.** Academic Press.

GELMAN, A., & Hill, J. (2006). **Data analysis using regression and multilevel/hierarchical models**. Cambridge university press.

MORETTIN, P. A., & Singer, J. da M. (2022). **Estatística e ciência de dados**.

TREVOR, H., Robert, T., & Jerome, F. (2009). **The elements of statistical learning: Data mining, inference, and prediction.** Spinger.

WICKHAM, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). **R for data science.** O'Reilly Media, Inc.

FIAP

PDF exclusivo para Francismar Alves Martins Júnior - rm562869
yggdrasil.git@gmail.com